

На правах рукописи

Грабовой Андрей Валериевич

О СЛОЖНОСТИ МОДЕЛЕЙ И ДАННЫХ
В ПАРАМЕТРИЧЕСКИХ МОДЕЛЯХ МАШИННОГО ОБУЧЕНИЯ

1.2.1 — Искусственный интеллект и машинное обучение

АВТОРЕФЕРАТ
диссертации на соискание ученой степени
доктора физико-математических наук

Москва — 2026

Работа выполнена в Лаборатории 42 «Интеллектуального анализа данных» Института проблем управления им. В.А.Трапезникова РАН.

Научный консультант:

Воронцов Константин Вячеславович

доктор физико-математических наук, профессор РАН, Федеральный исследовательский центр «Информатика и управление» Российской академии наук, отдел интеллектуальных систем, ведущий научный сотрудник.

Официальные оппоненты:

Ведущая организация:

Защита состоится _____ года в 14:00 на заседании диссертационного совета Д 002.073.05 при Федеральном исследовательском центре «Информатика и управление» Российской академии наук (ФИЦ ИУ РАН) по адресу: 119333, г. Москва, ул. Вавилова, д. 40.

С диссертацией можно ознакомиться в библиотеке Федерального государственного учреждения Федеральный исследовательский центр «Информатика и управление» Российской академии наук и на сайте <http://www.frccsc.ru/>

Автореферат разослан

2026 года.

Ученый секретарь

диссертационного совета Д 002.073.05

к.т.н.

И. А. Рейер

Общая характеристика работы

Актуальность темы. С начала XXI века наблюдается экспоненциальный рост производительности вычислительных систем, измеряемой в операциях с плавающей запятой (англ. FLOPS): от терафлопсов в начале столетия до эксафлопсов в настоящий момент. Параллельно происходит сопоставимый рост сложности моделей глубокого обучения, выраженный в увеличении количества обучаемых параметров на несколько порядков — от тысяч в начале нулевых годов до миллиардов и сотен миллиардов в двадцатых, с прогнозируемым переходом к триллионам параметров в ближайшем десятилетии. Современные исследования анализа сложности таких моделей преимущественно опираются на эмпирические корреляции, связывающие эффективность моделей с количественными метриками — числом параметров и вычислительными затратами на обучение или применение. Отсутствие строгой теоретической основы для предсказания поведения моделей при масштабировании делает процесс разработки экономически и энергетически неэффективным и зачастую приводит к получению необоснованных и противоречивых результатов.

Особую остроту проблема приобретает при разработке больших языковых моделей (англ. LLM), обучение которых требует значительных вычислительных, энергетических и финансовых ресурсов. Для снижения непредсказуемости процесса обучения на предварительной стадии (англ. pretrain) эмпирически подбираются оптимальные соотношения между размером модели в параметрах и объемом обучающих данных в токенах при заданном вычислительном ресурсе. Однако эмпирические оценки, полученные для одной архитектуры, не переносятся на другие модели, что ограничивает применимость подобных подходов и приводит к непредвиденным результатам при полномасштабном обучении. В связи с этим разработка теоретических оценок сложности моделей становится критически важной, поскольку такие оценки позволяют связать сложность модели со сложностью выборки еще на этапе проектирования архитектуры, обеспечивая рациональный выбор параметров модели и объема данных.

Классические подходы к оценке сложности моделей машинного обучения, разработанные для традиционных методов, находят ограниченное применение при анализе моделей глубокого обучения. Фундаментальный вклад в теорию оценивания сложности моделей внесли работы Владимира Наумовича Вапника и Алексея Яковлевича Червоненкиса, заложившие основы статистической теории обучения, а также Лесли Вэлианта, предложившего подход приближенно правильного обучения (англ. PAC-Learning). В основном современные подходы к определению сложности основаны на Радемахеровской сложности, предложенной Владимиром Кольчинским и Дмитрием Панченко, и комбинаторном подходе к оценке обучаемости алгоритмов Константина Вячеславовича Воронцова, в котором разработан математический аппарат на основе комбинаторных оценок вероятности переобучения моделей. Однако современные исследования в области теории машинного обучения редко рассматривают нейросетевые мо-

дели глубокого обучения ввиду их высокой сложности и трудности получения адекватных оценок сложности таких моделей. Значительная часть современных исследований посвящена классическим методам машинного обучения и улучшению оценок для известных методов, так как текущие оценки сложности даже для классических моделей являются сильно завышенными.

Отдельным направлением в исследованиях являются оценки репрезентативной способности моделей глубокого обучения к аппроксимации по прецедентам. основополагающий результат принадлежит Джорджу Цибенко, который доказал, что нейронные сети аппроксимируют непрерывные функции с некоторыми ограничениями с произвольной точностью. Йохану Хестаду принадлежат первые оценки, указывающие на рост аппроксимирующей способности моделей глубокого обучения с глубиной модели. В более современных работах Яна Лекуна, Йошуа Бенджио, Надава Коэна эти оценки получены с более мягкими ограничениями на класс рассматриваемых функций. В целом все эти оценки наряду с работой Охада Шамира указывают на экспоненциальное увеличение аппроксимирующей способности моделей глубокого обучения с ростом числа слоев.

В настоящей работе предлагается теоретический анализ нейросетевых моделей, опирающийся на анализ их матриц Гессе. Матрица Гессе функции потерь по параметрам модели содержит информацию о локальной кривизне оптимизационного ландшафта и используется для анализа сложности модели и обучающей выборки, а также для оценки важности параметров в задачах прореживания нейросетевых моделей. Локализация исследования: рассматриваются параметрические нейросетевые модели в постановке минимизации эмпирического риска; в центр ставится согласованность сложности модели с характеристиками выборки, а не построение новых универсальных аппроксиматоров.

Степень разработанности темы диссертационного исследования. Классические подходы к оценке сложности моделей машинного обучения, основанные на VC-размерности, PAC-обучаемости и радемахеровской сложности, разработаны для моделей с ограниченным числом параметров и ориентированы на анализ худшего случая, что делает их оценки слишком консервативными для перепараметризованных нейронных сетей. Эти оценки не учитывают специфику параметрических моделей глубокого обучения, такие как сверточные фильтры, остаточные связи и механизмы внимания, а также не отражают влияние регуляризации, ранней остановки и особенностей процесса оптимизации на обобщающую способность моделей. Комбинаторный подход К.В. Воронцова позволяет снизить оценки Вапника–Червоненкиса, но остается применимым лишь к ограниченным классам моделей.

Что касается оценки сложности данных, существующие подходы преимущественно сводятся к анализу размера выборки для обучения, что является неполным, так как сложность выборки также определяется сложностью каждого объекта. Современные методы оценки сложности объектов выборки опираются на исследования сложности многообразий, аппроксимирующих элементы выборки. Для больших языковых моделей используются эмпирические законы

масштабирования, полученные Джаредом Капланом и Джорданом Хофманом, однако эти законы не имеют строгого теоретического обоснования и не объясняют механизмы, лежащие в основе зависимостей между параметрами, данными и качеством модели.

В области снижения сложности моделей используются несколько основных направлений, включая квантизацию параметров, прореживание и дистилляцию знаний. Однако существующие методы не опираются на строгие теоретические оценки сложности моделей и данных, что ограничивает их эффективность и предсказуемость.

Таким образом, на текущий момент в исследованиях отсутствует единый теоретический аппарат для описания сложности моделей глубокого обучения, позволяющий получить асимптотические оценки и формализовать согласованность сложности модели с характеристиками обучающей выборки. Разработка такого аппарата позволит проводить сравнительный анализ различных параметрических моделей глубокого обучения для выбора оптимального решения для заданной задачи, характеризуемой выборкой определенной сложности.

Объектом исследования являются процессы параметрического обучения моделей машинного обучения по конечным выборкам.

Предмет исследования: согласованность сложности параметрических моделей машинного обучения с характеристиками обучающей выборки, формализуемая мерами на модели и на выборке.

Цель и задачи исследования. Целью исследования является построение теоретического аппарата оценки согласованности сложности параметрических моделей машинного обучения с характеристиками обучающей выборки и методов снижения сложности таких моделей на основе анализа ландшафта функции потерь.

Для достижения цели были поставлены и решены следующие задачи:

- введение определений мер сложности моделей и выборок в рамках теории мер и формулировка критерия согласованности модели и выборки;
- построение ландшафтной меры сложности модели по матрицам Гессе и установление ее связи с приращением эмпирического риска при изменении выборки;
- получение теоретических оценок ландшафтной меры для полносвязных, сверточных и трансформерных архитектур;
- построение методов оценки достаточного объема выборки и анализ их связи со сложностью модели через условную сложность данных и стабилизацию эмпирического риска;
- построение методов снижения сложности моделей, опирающихся на локальную геометрию функции потерь;
- демонстрация применимости построенного аппарата в прикладных задачах.

Методы исследования. Для решения поставленных задач в диссертации используются методы теории мер, линейной алгебры, матричного анализа, включая матричное дифференцирование и спектральный анализ матриц, методы теории вероятностей, математической статистики, включая байесовский анализ, анализ сходимости случайных процессов, методы теории оптимизации, анализа функций многих переменных, методы статистической теории обучения.

Научная новизна.

1. Введены формальные определения меры сложности выборки $\mu_D(D)$ и меры сложности модели $\mu_f(f)$ в рамках теории мер, сформулирован критерий согласованности модели и выборки $\mu_f(f) \leq \mu_D(D)$.
2. Введена ландшафтная мера сложности модели $\mu_f(f|D) = \mathbb{E}_i \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_j \mathbf{H}_j(\boldsymbol{\theta}^*)\|_2$, где ожидания берутся по равномерному выбору объектов i, j из выборки D , а $\|\cdot\|_2$ — спектральная норма матрицы; мера задает количественную связь между изменением выборки и локальной геометрией оптимизационного ландшафта.
3. Для полносвязных, сверточных и трансформерных архитектур получены оценки ландшафтной меры через спектральные нормы матриц Гессе: оценки растут экспоненциально с глубиной сети и полиномиально с шириной и числом каналов.
4. Показано, что байесовские критерии достаточного объема выборки по близости апостериорных распределений параметров корректны в модели линейной регрессии и допускают анализ сходимости. Их связь со сложностью модели задается через условную сложность данных и наблюдаемую стабилизацию эмпирического риска.
5. Предложены прореживание по ковариации градиентов, многодоменная дистилляция и антидистилляция как методы снижения сложности, опирающиеся на локальную геометрию функции потерь.
6. Для низкоранговой адаптации параметров доказана состоятельность оценки при стандартных условиях. Для многозадачного обучения получено сравнение верхних оценок эмпирической радемахеровской сложности на задачу при справедливом масштабировании нормы энкодера.

Теоретическая значимость работы. Результаты вписывают локальный анализ матриц Гессе в теорию сложности обучаемости как вычислимый мост между архитектурными параметрами модели и вопросом согласования модели с выборкой, расширяя классические подходы на основе VC-размерности, РАС-обучаемости и радемахеровской сложности на случай перепараметризованных моделей. Полученные оценки ландшафтной меры дают основание для сравнительного анализа архитектур и для сопоставления методов оценки достаточного объема выборки со сложностью модели. Основной вклад работы состоит в построении ландшафтной меры сложности параметрической модели и в установлении на ее основе вычислимой связи между архитектурой модели, стабилизацией обучения и характеристиками выборки.

Практическая значимость работы. Разработанный теоретический аппарат применен к решению прикладных задач машинного обучения: многозадачного обучения, декодирования фМРТ-изображений и детекции машинно-генерированного контента. Полученные методы оценки и снижения сложности моделей и данных экспериментально проверены на реальных задачах компьютерного зрения, обработки естественного языка и классификации.

Положения, выносимые на защиту:

1. Меры сложности модели и выборки вместе с критерием их согласованности задают формальный аппарат соответствия параметрической модели машинного обучения характеристикам обучающей выборки.
2. Ландшафтная мера на основе спектральных свойств матриц Гессе количественно связывает архитектуру модели с изменением эмпирического риска при изменении выборки.
3. Оценки ландшафтной меры растут экспоненциально с глубиной сети и полиномиально с шириной и числом каналов.
4. Методы оценки достаточного объема выборки по близости апостериорных распределений сходятся в модели линейной регрессии.
5. Редукция пространства обучаемых параметров уменьшает число параметров модели при сохранении порядка качества аппроксимации.

Ключевые математические результаты, соответствующие указанным положениям, в основном содержании автореферата приведены в виде формулировок теорем без доказательств.

Степень достоверности результатов. Достоверность научных результатов работы подтверждается непротиворечивостью и согласованностью с известными фактами и исследованиями в рассматриваемой области, высокой степенью сходимости теоретических результатов с данными экспериментов и определяется применением теоретических и методологических основ разработок ведущих ученых в области обработки естественного языка, корректным и обоснованным использованием математического аппарата, экспериментальными исследованиями разработанных моделей и методов.

Соответствие диссертации паспорту специальности. Тема и основные результаты диссертации соответствуют следующим областям исследований паспорта специальности 1.2.1 — Искусственный интеллект и машинное обучение.

2 Исследования в области оценки качества и эффективности алгоритмических и программных решений для систем искусственного интеллекта и машинного обучения. Методики сравнения и выбора алгоритмических и программных решений при многих критериях.

4 Разработка методов, алгоритмов и создание систем искусственного интеллекта и машинного обучения для обработки и анализа текстов на естественном языке, для изображений, речи, биомедицины и других специальных видов данных.

16 Исследования в области специальных методов оптимизации, проблем сложности и элиминации перебора, снижения размерности.

17 Исследования в области многослойных алгоритмических конструкций, в том числе – многослойных нейросетей.

Апробация результатов диссертации. Основные результаты работы докладывались и обсуждались на Всероссийской конференции с международным участием «Математические методы распознавания образов» (Москва, 2019, Москва, 2021, Муром, 2025), Международной конференции «Интеллектуализация обработки информации» (Гаэта, 2018, Москва, 2020, Москва, 2022), Всероссийской научной конференции МФТИ (Москва, 2018, 2019, 2020, 2021, 2023, 2024, 2025, 2026), VI Международная научно-практическая конференция «Магия ИННО: Перспективы развития лингвистики и лингводидактики в современных условиях» (Москва, 2023), Ivannikov Ispras Open Conference (Москва, 2021, 2022, 2023, 2024, 2025), Ivannikov Memorial Workshop (Казань, 2022, Этномир, 2026), Iberian Languages Evaluation Forum co-located with the Conference of the Spanish Society for Natural Language Processing (Андалусия, 2023, 2024), 11-я Международная научно-практическая конференция «Научное издание международного уровня – 2023: достижения, реалии, перспективы» (Москва, 2023), 35th Conference of Open Innovations Association (Тампере, 2024), Fourth Workshop on Scholarly Document Processing (Бангкок, 2024), 1st Workshop on GenAI Content Detection (GenAIDetect) (Абу-Даби 2025), 19th International Workshop on Semantic Evaluation (Вена, 2025).

Публикации. По теме диссертации опубликовано 56 научных работ, из которых 17 статей в научно-технических журналах, входящих в перечень ВАК, 32 — в изданиях, входящих в международные наукометрические базы Scopus и Web of Science. В трудах российских и международных конференций опубликовано 39 работ. Также на основе работ автора зарегистрировано 13 программ для ЭВМ.

Личный вклад соискателя. Все выносимые на защиту результаты и положения, составляющие основное содержание диссертационного исследования, разработаны и получены лично автором или при его непосредственном участии вместе с учениками. В работах, опубликованных в соавторстве, соискателю принадлежит определяющая роль в построении теоретических методов и направлении исследований.

Структура и объем работы. Диссертация состоит из оглавления, введения, шести разделов, заключения, списка иллюстраций, списка таблиц, перечня основных обозначений и списка литературы из 261 наименования. Основной текст занимает 374 страницы.

Основное содержание работы

Во **введении** обоснована актуальность темы диссертации, сформулирована цель исследования, указаны основные задачи и научные положения, выносимые на защиту, охарактеризованы научная новизна, теоретическая и практическая значимость, указаны используемые методы исследования.

В **первой главе** дан обзор теории обучаемости и классических мер сложности моделей; глава носит методический характер и мотивирует переход к локальному анализу ландшафта функции потерь.

В **разделе 1.1** фиксируются обозначения постановки статистического обучения: выборка $D = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ из неизвестного распределения $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$, класс моделей $\mathfrak{F}$ и функция потерь ℓ . Истинный риск $R(f) = \mathbb{E}[\ell(f(\mathbf{X}), \mathbf{Y})]$ противопоставляется эмпирическому риску $\hat{R}_m(f)$ по выборке; обучение рассматривается как минимизация эмпирического риска. Центральным объектом классической теории является уклонение $|R(f) - \hat{R}_m(f)|$ и его равномерная оценка по классу $\mathfrak{F}$.

В **разделе 1.2** кратко обсуждаются классические меры емкости класса: VC-размерность, PAC-обучаемость и комбинаторные оценки К.В. Воронцова. Для перепараметризованных нейросетей эти подходы дают слишком консервативные оценки наихудшего случая и не учитывают архитектуру, регуляризацию и локальный режим оптимизации. В дальнейшем используется радемахеровская сложность, поскольку она применяется при сопоставлении с ландшафтной мерой и в анализе многозадачного обучения.

Определение 1 (Эмпирическая радемахеровская сложность). Пусть $\mathcal{F}$ — класс вещественных функций на $\mathcal{X}$, $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathcal{X}$ — конечная выборка, и $\sigma_1, \dots, \sigma_m$ — независимые случайные переменные Радемахера, то есть $\mathbb{P}\{\sigma_i = +1\} = \mathbb{P}\{\sigma_i = -1\} = 1/2$ для всех $i = 1, \dots, m$. Эмпирическая радемахеровская сложность класса $\mathcal{F}$ на выборке D определяется как

$$\hat{\mathfrak{R}}_D(\mathcal{F}) = \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(\mathbf{x}_i) \right],$$

где математическое ожидание берется по распределению случайных переменных Радемахера.

Определение 2 (Ожидаемая радемахеровская сложность). Ожидаемая радемахеровская сложность класса $\mathcal{F}$ для выборок размера m определяется как

$$\mathfrak{R}_m(\mathcal{F}) = \mathbb{E}_{D \sim \mathbb{P}^m} [\hat{\mathfrak{R}}_D(\mathcal{F})],$$

где математическое ожидание берется по распределению выборок D размера m , порожденных распределением $\mathbb{P}$ на $\mathcal{X}$.

Радемахеровская сложность задает равномерную емкость класса на конкретной выборке и входит в стандартные границы обобщения вида $R(f) \leq \hat{R}_m(f) + 2\hat{\mathfrak{R}}_D(\mathcal{F}) + O(\sqrt{\log(1/\delta)/m})$. Вместе с тем она не различает две модели одной архитектуры, оказавшиеся в разных областях параметрического пространства, и поэтому недостаточна как единственная мера сложности глубокой сети.

В **разделе 1.3** рассматриваются выразительная способность глубоких сетей и анализ ландшафта функции потерь через матрицы Гессе. Показано, что

качество модели определяется не только числом параметров, но и областью параметрического пространства, в которую приводит оптимизация. Спектральная структура матрицы Гессе — концентрация большинства собственных значений около нуля и малое число доминирующих направлений кривизны — указывает на необходимость локального, а не только глобально-емкостного описания сложности. Это мотивирует переход от емкости класса к разбросу локальных вторых производных функции потерь.




Рис. 1: Идея анализа сходимости ландшафта: абсолютная разность $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ при добавлении объекта уменьшается с ростом объема выборки k и служит основой для введения ландшафтной меры сложности модели.

В **разделе 1.4** обсуждаются эмпирические законы масштабирования языковых моделей и методы снижения сложности: прореживание, квантизация, дистилляция и низкоранговые адаптеры. Эмпирические соотношения между числом параметров, объемом данных и качеством имеют практическое значение, однако не дают теоретического критерия согласованности архитектуры и выборки. Методы сжатия и адаптации, как правило, также не опираются на строгие оценки такой согласованности, что ограничивает их теоретическую предсказуемость.

В **разделе 1.5** формулируются пробелы, на устранение которых направлена диссертация: отсутствие вычислимой меры сложности, учитывающей архитектуру и локальный оптимум; слабая связь классических оценок с ростом выборки; недостаточность теоретических оценок спектральных норм матриц Гессе для полносвязных, сверточных и трансформерных моделей. Предлагаемый аппарат связывает меры μ_D , μ_f и ландшафтную меру $\mu_f(f|D)$ с оценками матриц Гессе и методами снижения сложности.

Таким образом, первая глава задает контекст теории обучаемости и обосновывает переход к локальной геометрии функции потерь в последующих главах.

Во **второй главе** разрабатывается теоретический формализм, в котором общие меры сложности модели и данных вводятся как исходная формализация задачи, а основной вычисляемый объект задается ландшафтной мерой параметрической модели.

В разделе 2.1 вводятся формальные определения мер сложности в рамках теории мер. Множество конечных выборок рассматривается как алгебра подмножеств генеральной совокупности, что позволяет применять стандартные свойства конечных мер. Для меры сложности выборки требуется субаддитивность:

$$\mu_D(D_1 \cup D_2) \leq \mu_D(D_1) + \mu_D(D_2).$$

Это свойство отражает естественное требование: объединение двух наборов данных не должно иметь сложность больше суммы их сложностей. При непересекающихся выборках равенство соответствует аддитивному случаю, когда объекты не дублируют информацию друг о друге. Монотонность меры сложности конечных выборок используется как следствие субаддитивности и не требует дополнительных предположений в рассматриваемой конечной постановке.

Определение 3 (Генеральная совокупность данных). *Генеральной совокупностью данных Γ назовем произвольное множество объектов, которые исследуются в рамках той или иной задачи. В общем случае нет никаких ограничений на счетность множества генеральной совокупности.*

Определение 4 (Однородная и многородная генеральная совокупность). *Генеральную совокупность Γ назовем однородной, если все объекты генеральной совокупности порождаются из одного распределения. В противном случае генеральную совокупность назовем k -родной, где k является числом распределений, на основе которых была сгенерирована генеральная совокупность.*

Пусть задана генеральная совокупность данных Γ . Множество всех подмножеств объектов, образующих кольцо выборок, обозначим как:

$$\mathfrak{D} = \{D_\Gamma^i\}, \quad D_\Gamma^i \subset \Gamma.$$

Определение 5 (Мера сложности выборки). *Мерой сложности выборки назовем отображение μ_D , такое, что:*

$$\mu_D(D_i) : \mathfrak{D}_\Gamma \rightarrow \mathbb{R}_+,$$

удовлетворяющее свойству:

$$\mu_D(D_i \cup D_j) \leq \mu_D(D_i) + \mu_D(D_j),$$

где равенство достигается при условии $D_i \cap D_j = \emptyset$.

Лемма 1 (Монотонность меры сложности выборки). *Мера сложности выборки μ_D , определенная в определении меры сложности выборки, обладает свойством монотонности: для любых выборок $D_1, D_2 \in \mathfrak{D}$ таких, что $D_1 \subseteq D_2$, выполняется неравенство*

$$\mu_D(D_1) \leq \mu_D(D_2).$$

Пусть задано множество параметрических моделей $\mathfrak{F} = \{f_i\}$.

Определение 6 (Мера сложности модели). *Мерой сложности модели f назовем отображение $\mu_f(f_i)$:*

$$\mu_f(f_i) : \mathfrak{F} \rightarrow \mathbb{R}_+.$$

В отличие от классических мер емкости класса функций, мера $\mu_f(f)$ относится к конкретной модели или конкретному элементу параметрического семейства. Такой выбор важен для глубоких моделей: две модели из одного класса могут иметь одинаковую архитектуру, но находиться в разных областях параметрического пространства и иметь различную локальную геометрию функции потерь. Поэтому дальнейшая конкретизация μ_f выполняется через матрицы Гессе, вычисленные в окрестности опорной точки.

Определение 7 (Обучаемость модели на выборке). *Назовем модель $f \in \mathfrak{F}$ обучаемой на выборке $D \in \mathfrak{D}$, если*

$$\mu_f(f) \leq \mu_D(D).$$

Это определение используется как абстрактный критерий согласованности выбранных числовых характеристик сложности модели и сложности выборки. В таком виде оно не является самостоятельным критерием качества аппроксимации и служит основой для введения вычислимых частных мер.

Предложение 2 (Сохранение критерия согласованности при расширении выборки). *Пусть мера сложности данных μ_D монотонна по включению в том смысле, что из $D \subseteq D''$ следует $\mu_D(D) \leq \mu_D(D'')$. Если для выборки D выполнено $\mu_f(f) \leq \mu_D(D)$, то для любой выборки D' выполняется $\mu_f(f) \leq \mu_D(D \cup D')$.*

Субаддитивность $\mu_D(D \cup D') \leq \mu_D(D) + \mu_D(D')$ дает дополнительную верхнюю оценку сложности объединения через сложности частей и используется в других рассуждениях главы.

В разделе 2.2 вводится понятие условной сложности выборки, учитывающее зависимость сложности данных от выбранной модели.

Ключевым понятием становится *условная сложность выборки*:

$$\mu_D(D|f) : \mathfrak{D} \rightarrow \mathbb{R}_+,$$

которая характеризует сложность данных $D \in \mathfrak{D}$ относительно заданной параметрической модели f в рамках выбранной меры μ_D . Мера сложности модели $\mu_f(f)$ индуцирует меру сложности выборки следующим образом:

$$\mu_D(D|f) = \inf\{\mu_D(D') : D' \subseteq D, \quad \mu_f(f) \leq \mu_D(D')\},$$

при этом по стандартному соглашению $\inf \emptyset = +\infty$, если подходящей подвыборки D' не существует.

Определение 8 (Условная сложность выборки). Условной сложностью выборки D относительно заданной параметрической модели f назовем отображение $\mu_D(D|f) : \mathfrak{D} \rightarrow \mathbb{R}_+$, определяемое выражением

$$\mu_D(D|f) = \inf\{\mu_D(D') : D' \subseteq D, \quad \mu_f(f) \leq \mu_D(D')\}.$$

Эта величина показывает, что одна и та же выборка может быть простой для одной модели и сложной для другой. Поэтому сложность данных в диссертации не рассматривается как автономная универсальная характеристика: она используется как формальный аппарат описания соответствия между выборкой, моделью и функцией потерь. Такое уточнение важно для интерпретации достаточного объема данных и для отделения общей меры $\mu_D(D)$ от вычислимой ландшафтной меры $\mu_f(f|D)$.

Рассматривается частный случай простой генеральной совокупности, в котором каждому объекту в мере μ_D приписана одинаковая стоимость C . Такая постановка соответствует методам оценки достаточного объема выборки, в которых характеристика данных сводится к числу объектов.

Определение 9 (Простая генеральная совокупность). Однородную генеральную совокупность Γ_C назовем простой, если она состоит из объектов одинаковой сложности C .

Следствие 3 (Мера сложности выборки для простой генеральной совокупности). Для простой генеральной совокупности Γ_C мера сложности любой выборки $D \subset \Gamma_C$ равна ее объему, умноженному на константу сложности:

$$\mu_D(D) = C \cdot |D|.$$

Определение 10 (Достаточный размер выборки). Размер выборки m^* называется достаточным согласно критерию T , если T выполняется для всех $k \geq m^*$.

Достаточный размер выборки играет вспомогательную роль во второй главе и подробно раскрывается в главе 4 как семейство вычислимых критериев стабильности. Понятие простой генеральной совокупности используется только как частная модель, позволяющая связать абстрактную меру сложности данных с привычным понятием объема выборки. В общем случае объекты могут иметь различную сложность, и тогда объем выборки сам по себе не является достаточным описанием данных. Однако в простой совокупности условие $\mu_D(D) = C|D|$ позволяет интерпретировать достаточный объем как частный случай достаточной сложности выборки.

В разделе 2.3 разрабатывается ландшафтная мера сложности модели, основанная на анализе сходимости функции потерь при увеличении объема выборки. Рассматривается параметрическая модель f_θ и эмпирический риск $\mathcal{L}_k(\theta)$. При добавлении нового объекта изменение функции потерь имеет вид

$$\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta) = \frac{1}{k+1}(\ell(f_\theta(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \mathcal{L}_k(\theta)).$$

В предположении о сохранении локального минимума и с использованием квадратичного приближения Тейлора получена оценка

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{M_\ell}{k+1} + \frac{\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2}{2(k+1)} \left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2,$$

где $\mathbf{H}_i(\boldsymbol{\theta})$ — матрица Гессе для i -го объекта.

Оценка изменения ландшафта задает некоторое свойство параметрического семейства функций f на заданной выборке D . Определим данное свойство как условную сложность модели f на выборке D :

$$\mu_f(f|D) : \mathfrak{F} \rightarrow \mathbb{R}_+.$$

Более подробно рассмотрим частный случай условной меры сложности параметрического семейства функций f вида:

$$\mu_f(f|D) = \mathbb{E}_{\mathbf{x}_i \in D} \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_{\mathbf{x}_i \in D} \mathbf{H}_i(\boldsymbol{\theta}^*)\|_2.$$

Определение 11 (Условная сложность параметрической модели). *Условной сложностью параметрической модели f относительно заданной выборки D назовем отображение $\mu_f(f|D) : \mathfrak{F} \rightarrow \mathbb{R}_+$.*

Определение 12 (Ландшафтная мера сложности). *Ландшафтной мерой сложности параметрической функции f назовем условную сложность параметрической модели f , заданную выражением*

$$\mu_f(f|D) = \mathbb{E}_{\mathbf{x}_i \in D} \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_{\mathbf{x}_i \in D} \mathbf{H}_i(\boldsymbol{\theta}^*)\|_2. \quad (1)$$

Из основной оценки следует асимптотическая связь

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{M_\ell}{k+1} + \frac{\mu_f(f|D)}{k+1} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2.$$

Для простой генеральной совокупности, когда $\mu_D(D') = C|D'|$, оценка ландшафтного приращения связывает размер подвыборки с допустимым изменением эмпирического риска. Если в R -окрестности опорной точки требуется

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \varepsilon,$$

то из предыдущей оценки следует достаточное условие

$$k+1 \geq \frac{M_\ell + \mu_f(f|D)R^2}{\varepsilon}.$$

Это соотношение используется как связь общей постановки меры сложности данных с ландшафтным анализом параметрической модели, а не как универсальное описание сложности данных. В результате достаточный объем выборки связывается с допустимым изменением эмпирического риска в окрестности

опорной точки. Если ландшафтная мера велика, то добавление объектов может сильнее менять локальную геометрию функции потерь, и для стабилизации требуется больший объем данных. Если же пообъектные матрицы Гессе имеют малый разброс, то эмпирический риск меняется более устойчиво при увеличении выборки.

Далее на основе результатов о спектральных нормах матриц Гессе получены оценки ландшафтной меры для конкретных архитектур.

В подразделе 2.3.1 для полносвязных сетей доказана теорема.

Теорема 4 (Сходимость ландшафта функции потерь для полносвязных сетей). Пусть параметры $\boldsymbol{\theta}$ выбраны так, что $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \leq R^2$ для некоторого $R > 0$. Если существует неотрицательная константа M_ℓ такая, что $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_\ell$ для всех объектов $i = 1, \dots, t$ в наборе данных, то при выполнении условий соответствующей теоремы основного текста справедливо:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{1}{k+1} \left(2M_\ell + \left(L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1} \right) R^2 \right),$$

причем выражение асимптотически стремится к 0, то есть

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \rightarrow 0 \text{ при } k \rightarrow \infty.$$

Таким образом, имеет место следующая пропорциональность:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \propto \frac{L(hM)^{2L}R^2}{k}.$$

Эта оценка показывает, что глубина сети входит в сложность существенно сильнее, чем ширина: увеличение числа слоев приводит к экспоненциальному росту верхней оценки, тогда как увеличение ширины входит полиномиально через размер скрытого слоя. Данный результат согласуется с известными оценками выразительной способности глубоких сетей, но описывает не аппроксимационную способность, а локальную чувствительность функции потерь к изменению выборки.

Следствие 5 (Асимптотика ландшафтной меры для полносвязных сетей). Ландшафтная мера сложности параметрической функции f полносвязной нейросетевой модели глубокого обучения имеет асимптотику:

$$\mu_f(f|D) \propto L(hM)^{2L},$$

где M — некоторая константа, ограничивающая параметры и данные.

В регрессионной постановке с квадратичной функцией потерь и FC ReLU-сетями получена более точная локальная оценка. Пообъектная квадратичная функция потерь имеет вид

$$\ell_i(\boldsymbol{\theta}) = \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{2}(f_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2, \quad \mathbf{y}_i = y_i \in \mathbb{R}. \quad (2)$$

Следующая лемма задает константу $M_{\mathbf{H}}$ для полносвязных ReLU-сетей без смещений при спектральных ограничениях на веса и входы.

Лемма 6 (Спектральная норма пообъектной матрицы Гессе для квадратичной потери и FC-сетей). *Рассмотрим полносвязную ReLU-сеть без смещений, для которой $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$, $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ для всех p и i . Тогда существует константа $M_{\mathbf{H}}$ такая, что для каждого i и каждой точки параметрического пространства, где требуемые производные существуют,*

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq M_{\mathbf{H}} := L M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L} + \sum_{s=1}^L M_{\mathbf{W}}^{2s}.$$

Если $|w_{ij}^{(p)}| \leq M$ на блоках размера $h \times h$, то $M_{\mathbf{W}} \leq hM$ и асимптотически $\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 = O(L(hM)^{2L})$.

Теорема 7 (Локальная оценка ландшафтного приращения для квадратичной потери и FC-сетей). Пусть $\boldsymbol{\theta}$ удовлетворяет $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2 \leq R$. Предположим, что $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_{\ell}$ для всех i , лемма 6 применима в точке $\boldsymbol{\theta}^*$, а в опорной точке выполнено условие приближенной стационарности: существует $\varepsilon_g \geq 0$ такое, что

$$\|\nabla \mathcal{L}_k(\boldsymbol{\theta}^*)\|_2 \leq \varepsilon_g, \quad \|\nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*)\|_2 \leq \varepsilon_g.$$

Тогда при условии локальной прокси-оценки приращения эмпирического риска

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2}{k+1} (M_{\ell} + M_{\mathbf{H}} R^2) + 2 \varepsilon_g R.$$

Это оценка худшего случая, полученная из равномерного контроля матрицы Гессе в локальной прокси-постановке. С учетом асимптотики $M_{\mathbf{H}}$ вклад кривизны имеет порядок

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| = O\left(\frac{L(hM)^{2L} R^2}{k}\right)$$

как в лемме 2 работы [6].

Далее фиксируется уточнение, учитывающее величину остатков. Если, кроме того,

$$|f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y, \quad i = 1, \dots, m,$$

и каждый наблюдаемый вход остается в фиксированной области активации в окрестности $\boldsymbol{\theta}^*$, зададим

$$\mathbf{g}_i := \nabla_{\boldsymbol{\theta}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \quad M_{\nabla^2 f} := \max_{1 \leq i \leq m} \|\nabla_{\boldsymbol{\theta}}^2 f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)\|_2.$$

Тогда

$$\|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbf{g}_i \mathbf{g}_i^{\top}\|_2 \leq \varepsilon_y M_{\nabla^2 f} \quad (3)$$

для каждого i , и

$$\mu_f(f \mid D) \leq 2 \max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 + 2 \varepsilon_y M_{\nabla^2 f}. \quad (4)$$

следовательно,

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{\varepsilon_y^2 + 2R^2(\max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 + \varepsilon_y M_{\nabla^2 f})}{k+1} + 2\varepsilon_g R.$$

Если дополнительно $\|\mathbf{W}^{(p)\star}\|_2 \leq M_{\mathbf{W}}$ для каждого слоя и $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ для всех i , то

$$\max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2},$$

откуда

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{\varepsilon_y^2 + 2R^2(LM_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2} + \varepsilon_y M_{\nabla^2 f})}{k+1} + 2\varepsilon_g R.$$

В этой окрестности функция $f_{\boldsymbol{\theta}}$ дважды дифференцируема на наблюдаемых входах. Частный случай $\varepsilon_y = 0$ соответствует точной интерполяции и сводит (3) к тождеству Гаусса–Ньютона.

Теорема уточняет общую ландшафтную оценку: кроме члена $O(M_{\mathbf{H}}R^2/k)$ появляется вклад остатков и возможный стационарный член, связанный с неточным совпадением локальных минимумов на соседних объемах выборки. Для приложений это означает, что даже при квадратичной потере одной только асимптотики $L(hM)^{2L}$ недостаточно, если остатки модели в опорной точке не малы.

Следствие 8 (Линейная модель). Если $f_{\boldsymbol{\theta}}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$, где $\boldsymbol{\theta} = \mathbf{w} \in \mathbb{R}^n$, и используется та же квадратичная функция потерь (2), то $\mathbf{H}_i(\boldsymbol{\theta}) = \mathbf{x}_i \mathbf{x}_i^\top$ не зависит от $\mathbf{w}$ и y_i , поэтому $\|\mathbf{H}_i\|_2 = \|\mathbf{x}_i\|_2^2$. При $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ можно положить $M_{\mathbf{H}} = M_{\mathbf{x}}^2$ в лемме 6 и следствии 10, заменив оценку для ReLU-сети этой ранговой матрицей Гессе. Ландшафтная мера сложности (1) в этом случае определяется разбросом ранговых матриц $\mathbf{x}_i \mathbf{x}_i^\top$ вокруг их выборочного среднего.

Следствие 9 (Один скрытый слой, FC ReLU). Рассмотрим один скрытый слой ширины h : $\mathbb{R}^n \rightarrow \mathbb{R}^h \rightarrow \mathbb{R}$ с ReLU и матрицами весов без смещений, удовлетворяющими тем же спектральным ограничениям, что и в лемме 6. В обозначениях следствия 10 это случай $L = 2$, поэтому (5) дает верхнюю оценку $\mu_f(f | D) = O((hM)^4)$, в отличие от более глубоких сетей, где множитель $(hM)^{2L}$ быстрее растет по L . Отдельно, если в опорной точке $\boldsymbol{\theta}^*$ пообъектные остатки равномерно малы, $|f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y$ для всех i , то учитывающая остатки часть теоремы 7 и точное тождество (3) дают оценку (4) для $\mu_f(f | D)$; при покоординатных ограничениях это уточняет оценку худшего случая $O(h^4)$.

Лемма 6 также задает порядок ландшафтной меры сложности (1) через глубину, ширину и нормовые ограничения.

Следствие 10 (Масштабирование ландшафтной меры сложности). *При условиях леммы 6, покоординатных ограничениях $|w_{ij}^{(p)}| \leq M$ на соответствующих блоках весов размера $h \times h$ и фиксированном ограничении $M_{\mathbf{x}}$ на входы мера (1) удовлетворяет оценке*

$$\mu_f(f \mid D) = O(L(hM)^{2L}), \quad (5)$$

где h обозначает ширину скрытого слоя, L — глубину, а M — покоординатное ограничение на веса; ограничение $M_{\mathbf{x}}$ включено в неявную константу.

В подразделе 2.3.2 для сверточных сетей получены следующие результаты.

Теорема 11 (Сходимость ландшафта для 1D-сверточных сетей). *Пусть параметры θ находятся в R -окрестности оптимума:*

$$\|\theta - \theta^*\| \leq R,$$

а функция потерь ограничена некоторой константой:

$$\exists M_\ell > 0 : \forall i |\ell_i| \leq M_\ell.$$

Пусть все объекты в наборе данных ограничены:

$$\exists M_{\mathbf{x}} > 0 \forall i \|\mathbf{x}_i\| \leq M_{\mathbf{x}}.$$

Тогда в условиях соответствующей теоремы основного текста:

$$\begin{aligned} |\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)| &\leq \frac{2}{k+1} M_\ell + \\ &+ \frac{2}{k+1} R^2 \sqrt{2} d^2 M_{\mathbf{x}}^2 (L+1) (C^2 w^2 k d)^L, \end{aligned}$$

где $M_{\mathbf{x}}$ — константа, ограничивающая нормы объектов данных.

Теорема 12 (Сходимость ландшафта для 2D-сверточных сетей). *Пусть параметры θ находятся в R -окрестности оптимума:*

$$\|\theta - \theta^*\| \leq R.$$

Также функция потерь ограничена некоторой константой:

$$\exists M_\ell > 0 : \forall i |\ell_i| \leq M_\ell.$$

Пусть все объекты в наборе данных также ограничены:

$$\exists M_{\mathbf{x}} > 0 \forall i \|\mathbf{x}_i\| \leq M_{\mathbf{x}}.$$

Тогда при выполнении условий соответствующей теоремы основного текста справедливо:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2}{k+1} M_\ell + \frac{2}{k+1} R^2 \sqrt{2} q^2 M_{\mathbf{x}}^2 (L+1) (C^2 k^2 w^2 m n)^L,$$

где $q^2 = C^2 k^2 m n$, а $M_{\mathbf{x}}$ — константа, ограничивающая нормы объектов данных.

Следствие 13 (Асимптотика ландшафтной меры для 1D-сверточных сетей). Ландшафтная мера сложности параметрической функции f 1D-сверточной модели глубокого обучения имеет асимптотику:

$$\mu_f(f|D) \propto L(C^2 M^2 k d)^L,$$

где C — максимальное число каналов, d — длина входной последовательности, k — размер свертки, M — некоторая константа, ограничивающая параметры и данные.

Следствие 14 (Асимптотика ландшафтной меры для 2D-сверточных сетей). Ландшафтная мера сложности параметрической функции f 2D-сверточной модели глубокого обучения имеет асимптотику:

$$\mu_f(f|D) \propto C^2 k^2 L (C^2 k^2 M^2 m n)^L,$$

где C — максимальное число каналов, m, n — размеры входного изображения, k — размер свертки, M — некоторая константа, ограничивающая параметры и данные.

Оценки для сверточных сетей показывают, что число каналов, размер ядра и пространственный размер входа входят в верхние границы мультипликативно. Это позволяет сравнивать архитектурные решения не только по числу параметров, но и по их влиянию на локальную кривизну функции потерь.

Следствие 15 (Снижение ландшафтной меры при пулинге). Пусть выполнены условия теоремы о сходимости ландшафта для 2D-сверточных сетей, а сеть дополнительно содержит слой *MaxPool2D* или *AvgPool2D* с ядром $k_{\text{pool}} \times k_{\text{pool}}$ в позиции l . Тогда верхняя оценка ландшафтной меры приобретает множитель $(1/k_{\text{pool}}^2)^{L-l+2}$:

$$\mu_f(f|D) \propto C^2 k^2 L \left(\frac{1}{k_{\text{pool}}^2} \right)^{L-l+2} (C^2 k^2 M^2 m n)^L.$$

В частности, более раннее расположение пулинга (меньшая позиция l) сильнее снижает верхнюю оценку сложности модели.

Таким образом, операция пулинга частично компенсирует рост ландшафтной сложности с глубиной сети и выступает теоретически обоснованным фактором стабилизации.

В подразделе 2.3.3 для трансформеров доказана теорема.

Теорема 16 (Сходимость ландшафта для трансформеров). *Для одного блока самовнимания и одного блока трансформера при условии ограниченности функции потерь*

$$0 \leq \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \leq L,$$

и ограниченности норм матриц Гессе справедливо:

$$|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \leq \frac{2L}{k+1} + \frac{M \|\mathbf{w} - \mathbf{w}^*\|_2^2}{(k+1)},$$

где для блока самовнимания константа M задается оценкой нормы матрицы Гессе слоя самовнимания, а для блока трансформера $M = M_{\text{tr}}$ — оценкой нормы матрицы Гессе трансформера.

Неравенство отделяет два источника изменения эмпирического риска: ограниченность потерь (слагаемое порядка $L/(k+1)$) и вклад кривизны через константу M , которая неоднородна по блокам трансформера. Поэтому последующий детальный анализ матриц Гессе блоков самовнимания, послойной нормализации и полносвязных подсетей в третьей главе необходим: без него нельзя явно связать архитектурные блоки с скоростью стабилизации ландшафта.

Для трансформерных моделей анализ показывает, что вклад различных блоков в локальную кривизну неоднороден. Компоненты самовнимания, нормализации и полносвязной части дают разные слагаемые в оценках, поэтому общая сложность трансформера не сводится к числу параметров или числу слоев. Такой результат важен для последующего анализа масштабирования языковых моделей, поскольку он показывает, какие структурные элементы архитектуры могут сильнее влиять на изменение ландшафта при росте выборки.

В разделе 2.4 представлены результаты вычислительных экспериментов, подтверждающие теоретические оценки на наборах данных MNIST, FashionMNIST, CIFAR-10/100. Показано, что увеличение глубины сети замедляет сходимость ландшафта, а увеличение ширины — ускоряет; для сверточных сетей исследовано влияние гиперпараметров; для трансформеров продемонстрирована стабилизация ландшафта с ростом объема данных. Для полносвязных сетей варьируются число слоев и число нейронов в скрытых слоях. Эксперименты показывают, что увеличение глубины приводит к более медленному уменьшению разности $|\mathcal{L}_{k+1} - \mathcal{L}_k|$, что согласуется с экспоненциальной зависимостью верхней оценки от L . Увеличение ширины при фиксированной глубине может ускорять эмпирическую стабилизацию, поскольку модель получает большую аппроксимационную способность без столь резкого роста глубинного множителя.




Рис. 2: Зависимость $|\mathcal{L}_{k+1}(\hat{\theta}) - \mathcal{L}_k(\hat{\theta})|$ от размера выборки k для полносвязной сети на MNIST: слева — при фиксированной глубине $L = 5$ и вариации ширины h ; справа — при фиксированной ширине $h = 16$ и вариации глубины L .

Для сверточных сетей анализируются число каналов, размер ядра, глубина и положение операций пулинга. Полученные зависимости подтверждают, что структурные элементы архитектуры влияют на локальную меру сложности не только через число параметров, но и через способ распространения сигнала по слоям. Отдельно рассмотрена регрессионная постановка для линейной и двухслойной ReLU-архитектур. В этой постановке выполнено сопоставление ландшафтной меры с эмпирической радемахеровской сложностью. Показано, что радемахеровская сложность описывает равномерную емкость класса функций, тогда как ландшафтная мера фиксирует разброс пообъектных матриц Гессе в выбранной точке параметрического пространства. Поэтому эти величины не заменяют друг друга, а описывают разные аспекты сложности модели.

Таблица 1: Теоретические верхние порядки ландшафтной меры μ_f и эмпирической радемахеровской сложности для линейной модели и двухслойной FC ReLU-сети при квадратичной функции потерь.

	Линейная модель	Двухслойная FC ReLU
$\mu_f(f \mid D)$	$O(n)$	$O((hM)^4)$ в худшем случае
$\hat{\mathfrak{R}}_m$	$O(W\sqrt{n/m})$	$O(\text{poly}(h)/\sqrt{m})$

В линейной регрессии матрица Гессе имеет простую структуру, что позволяет явно сопоставить зависимость ландшафтной меры от размерности признакового пространства с оценками радемахеровской сложности. Для двухслойной ReLU-сети зависимость становится более сложной из-за кусочно-линейной структуры активаций и изменения активных областей. Численные эксперименты показывают, что рост ширины и размера выборки по-разному влияет на две меры, что подтверждает необходимость рассматривать ландшафтную меру как

отдельный инструмент анализа.

Для языковых моделей семейства GPT-2 проведен эмпирический анализ динамики выборочной ландшафтной меры на корпусе WikiText-103. Рассматриваются несколько моделей, обучаемых при разных настройках, и для них сравниваются траектории функции потерь, валидационного качества и выборочной ландшафтной меры. Полученные результаты показывают, что динамика ландшафтной меры содержит информацию о геометрическом режиме обучения, которая не сводится к одной только функции потерь. В частности, фаза уменьшения ошибки и фаза стабилизации геометрии могут не совпадать, что подчеркивает самостоятельную роль ландшафтного анализа. Дополнительно анализируется зависимость ландшафтной меры от времени обучения, валидационной ошибки и архитектурных настроек. Для части моделей наблюдается немонотонная динамика: уменьшение функции потерь может сопровождаться ростом или стабилизацией ландшафтной меры. Это показывает, что локальная кривизна функции потерь отражает не только качество аппроксимации, но и характер найденной области параметрического пространства.

В заключении к главе сформулированы основные результаты: общие меры сложности модели и выборки задают исходную формализацию задачи, а основной вычислимый объект главы задается ландшафтной мерой параметрической модели. Получены явные асимптотические оценки для основных архитектур и проведено численное сопоставление ландшафтной меры с эмпирической радимахеровской сложностью. Эти результаты создают основу для дальнейших оценок матриц Гессе и практических методов анализа достаточного объема выборки. В частности, достаточное условие $k + 1 \geq (M_\ell + \mu_f(f|D)R^2)/\varepsilon$ показывает, что при фиксированной точности ε требуемый объем данных растет вместе с ландшафтной мерой модели: более «кривая» локальная геометрия требует большей выборки для той же стабилизации эмпирического риска. В результате вторая глава формализует теоретическую связь между сложностью модели и достаточным объемом данных, а последующая четвертая глава дает наблюдаемые критерии, по которым этот объем можно оценивать на практике без прямого вычисления матриц Гессе.

Ограничения постановки второй главы связаны с детерминистическим характером анализа, предположением о существовании общей опорной точки минимума для последовательных размеров выборки и тем, что полученные верхние оценки могут быть улучшены за счет учета разреженности активаций. Вместе с тем даже в такой постановке ландшафтная мера дает вычислимо интерпретируемую связь между архитектурой, локальной геометрией функции потерь и изменением эмпирического риска при росте выборки.

В **третьей главе** исследуются матрицы Гессе функции потерь для основных семейств нейросетевых архитектур. Цель главы — сделать ландшафтную меру второй главы вычислимо оцениваемой: $\mu_f(f|D)$ определяется через разброс пообъектных матриц Гессе, а прямое построение полной матрицы вторых производных для современных сетей непрактично. Поэтому основными резуль-

татами являются факторизованные представления и верхние оценки спектральной нормы, зависящие от глубины, ширины, каналов, размеров ядер и блоков самовнимания.

Теорема 17 (Факторизация матрицы Гессе). *Пусть функция нейронной сети $f_{\theta}(\mathbf{x})$ представима в матричной форме через последовательность линейных операторов, нелинейных масок и параметрических преобразований. Тогда матрица Гессе функции потерь относительно параметров модели может быть представлена в факторизованной форме*

$$\mathbf{H}_O(\theta) = \mathbf{Q}^\top \mathbf{F}^\top \mathbf{A} \mathbf{F} \mathbf{Q},$$

где $\mathbf{H}_O$ описывает G -компоненту матрицы Гессе, матрица $\mathbf{A}$ задает вторые производные функции потерь по выходу модели, матрица $\mathbf{F}$ описывает распространение возмущений через архитектуру, а матрица $\mathbf{Q}$ задает параметризацию слоев.

Смысл факторизации состоит в разделении трёх вкладов: параметризации слоёв ($\mathbf{Q}$), распространения сигнала через архитектуру ($\mathbf{F}$) и вторых производных функции потерь по выходу ($\mathbf{A}$). Такой разбор делает возможным дальнейший вывод порядков $L(hM)^{2L}$ для полносвязных сетей и аналогичных оценок для сверток и трансформеров.

Для полносвязных сетей в диссертации получена оценка спектральной нормы и установлен асимптотический порядок $\|\mathbf{H}_i(\theta)\|_2 = O(L(hM)^{2L})$, показывающий экспоненциальную зависимость оценки от глубины и полиномиальную зависимость от ширины. Для одномерных и двумерных сверточных сетей получены оценки через число каналов, размеры ядер и пространственные размеры входа. Снижение ландшафтной сложности при MaxPool и AvgPool оформлено как следствие: множитель $(1/k_{\text{pool}}^2)^{L-l+2}$ усиливается при более раннем пулинге. Указанные оценки используются как конструктивные следствия факторизованного представления; детальные спектральные формулировки для отдельных слоев приведены в основном тексте диссертации.

Теорема 18 (Оценка нормы матрицы Гессе для слоя самовнимания). *Пусть $\|\cdot\|_2$ является спектральной нормой, тогда для слоя самовнимания получаем:*

$$\|\mathbf{H}_i(\mathbf{w}^*)\|_2 \leq M,$$

зде

$$\begin{aligned}
M = 3 \cdot \max & \left(\frac{2L}{d_V} \|\mathbf{X}\|_2^2, \right. \\
& \frac{8}{L^3 d_V d_K} \|\mathbf{W}_K\|_2^2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\
& + \frac{12}{d_V d_K} \sqrt{\min(L, d_V)} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^5, \\
& \frac{4}{L d_V \sqrt{d_K}} \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^4 + \\
& + \frac{4 \sqrt{\min(L, d_V)}}{L^2 \sqrt{d_K}} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^3, \\
& \frac{8}{L^3 d_V d_K} \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\
& + \frac{4 \sqrt{\min(L, d_V)} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2)}{L d_V \sqrt{d_K}} \|\mathbf{W}_V\|_2 \cdot \\
& \cdot \left(3L \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{X}\|_2^5 + \frac{d_V}{L} \|\mathbf{X}\|_2^3 \right) \Big).
\end{aligned}$$

Полученная константа M полиномиально зависит от норм входа и матриц $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ и входит в оценку сходимости ландшафта трансформера как коэффициент при $\|\mathbf{w} - \mathbf{w}^*\|_2^2 / (k+1)$. Слагаемое $\frac{2L}{d_V} \|\mathbf{X}\|_2^2$ выделяет вклад проекции значений; остальные члены отражают взаимодействие запросов и ключей через softmax-внимание. Следовательно, разные группы параметров трансформера влияют на локальную стабилизацию ландшафта по-разному, что согласуется с экспериментальной гетерогенностью блоков запросов, ключей и значений.

Факторизованная форма важна тем, что она отделяет три источника сложности: структуру параметризации, прямое распространение сигнала через сеть и вторые производные функции потерь по выходам модели. Это позволяет единообразно выводить оценки для разных архитектур, не повторяя полный по-компонентный расчет всех вторых производных. В результате матрица Гессе рассматривается не только как объект численного анализа, но и как аналитический инструмент для вывода асимптотических зависимостей от глубины, ширины и структурных параметров сети.

Для полносвязных сетей оценка спектральной нормы матрицы Гессе уточняет результат второй главы: рост сложности обусловлен произведением норм весовых матриц по слоям и накоплением второпорядковых вкладов при обратном распространении. Если нормы параметров ограничены константой M , а ширина слоя равна h , то основной порядок оценки имеет вид $L(hM)^{2L}$. Эта зависимость показывает, что увеличение глубины меняет локальную геометрию функции потерь существенно сильнее, чем умеренное увеличение ширины.

Для сверточных сетей в главе отдельно рассматриваются одномерная и двумерная свертки. В одномерном случае оценка зависит от числа каналов C , размера ядра k , длины входной последовательности d и глубины L . В двумерном случае дополнительно учитываются пространственные размеры изображения m и n . Операции максимального и среднего пулинга анализируются через их влияние на ландшафтную меру: множитель $(1/k_{\text{pool}}^2)^{L-l+2}$ объясняет стабилизирующую роль раннего пулинга. Это согласуется с экспериментами главы о сложности и оформлено там как следствие о снижении ландшафтной меры.

Для трансформерных моделей в диссертации дополнительно получены блочные оценки нормы полной матрицы Гессе блока трансформера и вспомогательные соотношения для послойной нормализации. Анализ показывает, что блоки самовнимания вносят неодинаковый вклад в кривизну функции потерь: в вычислительном эксперименте на небольшой трансформерной модели на MNIST наибольшие спектральные нормы наблюдаются для блоков Key и Value. Такой результат важен для методов регуляризации и оптимизации, поскольку указывает на целесообразность раздельного анализа групп параметров.




Рис. 3: Спектральные нормы блоков параметров трансформера (слева) и соответствующих блоков матрицы Гессе (справа) на батче MNIST. Наибольшие значения норм соответствуют блокам Key и Value.

В главе также обсуждается практическая трудность полного вычисления матриц Гессе для современных моделей. Даже для умеренных архитектур полная матрица вторых производных имеет размер, квадратичный по числу параметров, поэтому прямое вычисление становится непрактичным. Полученные факторизованные выражения и спектральные оценки позволяют перейти от полного вычисления матрицы к анализу ее нормы и структурных верхних границ. В силу этого результаты главы применимы в дальнейшем: ландшафтная мера из второй главы требует оценки разброса пообъектных матриц Гессе, а третья глава дает аппарат для получения таких оценок по архитектуре модели.

Вычислительные эксперименты третьей главы служат эмпирической про-

веркой полученных оценок. Для полносвязных сетей проверяется согласованность порядка $L(hM)^{2L}$ с наблюдаемым ростом спектральных характеристик при увеличении глубины и ширины. Для сверточных сетей варьируются число каналов, размер ядра и положение пулинга; эксперименты согласуются с теоретическим выводом о редуцирующем влиянии раннего пулинга. Для трансформера эксперимент ограничен масштабом небольшой архитектуры и не исчерпывает анализ больших языковых моделей, но демонстрирует гетерогенность блоков: наибольший вклад в локальную кривизну дают блоки Key и Value. Это является важным промежуточным результатом: теория указывает на различный вклад блоков, а эксперимент подтверждает, что этот вклад можно наблюдать численно.

В **четвертой главе** разработаны методы определения достаточного размера выборки, основанные на наблюдаемой стабильности процесса обучения. В главе развивается теоретическая линия предыдущих разделов: во второй главе достаточный объем данных введен как частный случай условной сложности выборки $\mu_D(D|f)$, а для простой генеральной совокупности мера имеет вид $\mu_D(D) = C|D|$; ландшафтная мера $\mu_f(f|D)$ связывает требуемый объем с приращением эмпирического риска. Оценки третьей главы делают порядок этой меры явным для конкретных архитектур, но прямое вычисление матриц Гессе для крупных моделей остается дорогостоящим. Поэтому здесь предлагаются практические критерии m^* , использующие наблюдаемые характеристики процесса обучения: стабильность функции правдоподобия и близость апостериорных распределений параметров на соседних подвыборках. В отличие от теоретических оценок через μ_f , эти критерии не требуют явного спектра матрицы Гессе, но отвечают на тот же качественный вопрос: начиная с какого объема добавление данных перестает существенно менять свойства обученной модели. Рассмотрены ограничения классических статистических подходов, требующих заранее неизвестных характеристик распределения, и предложены два семейства критериев.

Первое семейство использует функцию правдоподобия. Предполагается, что доступная выборка $\mathfrak{D}_m$ уже содержит не меньше объектов, чем искомый достаточный размер m^* , и требуется выделить минимальный объем подвыборки, начиная с которого оценки параметров и значение функции правдоподобия стабилизируются.

Определение 13 (D-достаточный размер выборки). Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* назовем D-достаточным, если для всех $k \geq m^*$ выполняется условие:

$$D(k) = \mathbb{D}_{\hat{\mathbf{w}}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon.$$

Определение 14 (M-достаточный размер выборки). Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* назовем M-достаточным, если для всех $k \geq m^*$ выполняется условие:

$$M(k) = \left| \mathbb{E}_{\hat{\mathbf{w}}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\hat{\mathbf{w}}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \right| \leq \varepsilon.$$

Для D -достаточности рассматривается величина дисперсии функции правдоподобия на случайных (бутстрэп-)подвыборках фиксированного размера. Если эта дисперсия становится малой и остается малой при дальнейшем увеличении объема данных, то выборка считается достаточной в смысле устойчивости значения правдоподобия. Критерий M -достаточности ближе к анализу сходимости эмпирического риска: он фиксирует момент, начиная с которого добавление новых объектов практически не меняет ожидаемое значение функции ошибки. Для линейной регрессии в диссертации показано, что при сходимости оценок параметров и ковариационных матриц критерий M -достаточности корректно стабилизируется. По смыслу постановки это близко к ландшафтной постановке второй главы, где стабилизация $|\mathcal{L}_{k+1} - \mathcal{L}_k|$ тоже означает, что добавление объекта почти не меняет эмпирический риск в окрестности опорной точки. При этом достаточность проверяется по наблюдаемой функции правдоподобия (или функции потерь) на бутстрэп-подвыборках, а не через явную оценку $\mu_f(f|D)$. Тем самым M - и D -критерии дают наблюдаемый критерий согласованности сложности модели и объема данных для постановок, где гессианы недоступны.

Второе семейство критериев основано на близости апостериорных распределений параметров на соседних подвыборках.

Определение 15 (Бликие подвыборки). *Подвыборки $\mathfrak{D}^1$ и $\mathfrak{D}^2$ назовем близкими, если $\mathcal{I}_2$ может быть получено из $\mathcal{I}_1$ путем удаления, замены или добавления одного элемента. Формально это условие записывается как*

$$|\mathcal{I}_1 \triangle \mathcal{I}_2| = |(\mathcal{I}_1 \setminus \mathcal{I}_2) \cup (\mathcal{I}_2 \setminus \mathcal{I}_1)| = 1,$$

где $\triangle$ обозначает симметрическую разность множеств.

Определение 16 (KL-достаточный размер выборки). *Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* называется KL-достаточным, если для всех $k \geq m^*$*

$$KL(k) = D_{KL}(p_k \| p_{k+1}) = \int p_k(\mathbf{w}) \log \frac{p_k(\mathbf{w})}{p_{k+1}(\mathbf{w})} d\mathbf{w} \leq \varepsilon.$$

Определение 17 (S-достаточный размер выборки). *Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* называется S-достаточным, если для всех $k \geq m^*$*

$$S(k) = s\text{-score}(p_k, p_{k+1}) \geq 1 - \varepsilon.$$

В KL -достаточности сравниваются апостериорные распределения на близких подвыборках: малое значение D_{KL} означает, что добавление одного объекта существенно не меняет распределение параметров. В S -достаточности используется функция схожести, менее чувствительная к отдельным изменениям моментов; в экспериментах она дает менее консервативные оценки. Для нормального апостериорного распределения линейной регрессии доказана сходимость математических ожиданий и ковариационных матриц при условии роста минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ быстрее, чем $\sqrt{k}$.

Теорема 19 (Сходимость апостериорных распределений в линейной регрессии). Пусть множества значений признаков и целевой переменной ограничены, то есть существует константа $M \in \mathbb{R}$ такая, что $\|\mathbf{x}\|_2 \leq M$ и $|y| \leq M$ для всех объектов выборки. Если $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$, то в модели линейной регрессии с нормальным априорным распределением параметров $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$.

На этой сходимости моментов в диссертации основана корректность критериев KL - и S -достаточности: при сближении апостериорных распределений на соседних подвыборках функции $KL(k)$ и $S(k)$ стабилизируются. Для линейной регрессии достаточные условия такой сходимости дает условие $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$; при его выполнении достаточный размер выборки корректно определяется через $KL(k)$ или $S(k)$. В контексте положений диссертации это означает, что методы четвертой главы не заменяют ландшафтную меру, а задают наблюдаемый критерий стабильности обучения, согласованный с общей постановкой $\mu_f(f) \leq \mu_D(D)$ и со случаем $\mu_D(D) = C|D|$. Чем консервативнее критерий (типично KL), тем ближе он к требованию почти полной выборки; более мягкий S -критерий выделяет меньшие m^* , что соответствует разным уровням допустимого изменения модели при росте данных.

Экспериментальная часть главы включает синтетические и реальные наборы данных: синтетическую регрессию, Liver Disorders, Boston Housing, Diabetes, Forest Fires и Servo. В экспериментах проверяются три аспекта: сходимость функций $KL(k)$ и $S(k)$, зависимость достаточного размера выборки от порога ε и устойчивость оценки при изменении доступного объема данных. Показано, что $KL(k)$ убывает к нулю, а $S(k)$ стремится к единице при росте размера выборки, что согласуется с теоретической интерпретацией критериев.




Рис. 4: Сходимость критериев $KL(k)$ и $S(k)$ на синтетической регрессии: $KL(k)$ стремится к нулю, а $S(k)$ — к единице при росте объема выборки.

Сравнение с классическими статистическими методами показывает, что разные критерии описывают разные уровни осторожности: методы на основе KL чаще требуют почти полной выборки, тогда как S -достаточность выделяет

меньшие подвыборки. Практический смысл этого результата состоит в возможности выбирать критерий достаточности в зависимости от допустимого риска недообучения и стоимости получения новых данных. Для методов на основе функции правдоподобия используется бутстрэпирование подвыборок. Это позволяет оценивать не только одно значение функции ошибки, но и разброс этого значения при повторном формировании обучающего набора. В прикладных задачах такая процедура полезна тогда, когда заранее неизвестны параметры распределения данных и невозможно воспользоваться классическими формулами для мощности статистических критериев. Для методов на основе апостериорных распределений важным оказывается выбор меры близости: KL -расхождение чувствительно к изменениям математического ожидания и ковариации, а s -score ведет себя мягче при широких распределениях. Поэтому глава не утверждает существование единственного универсального критерия достаточности, а предлагает набор критериев, различающихся по степени консервативности. Полученные результаты обосновывают четвертое положение, выносимое на защиту: методы оценки достаточного объема выборки по близости апостериорных распределений сходятся в модели линейной регрессии. Их связь со сложностью моделей задается через общую постановку условной сложности данных и через наблюдаемый критерий стабилизации эмпирического риска при росте k . Перспективным направлением, уже намеченным в диссертации, остается более тесная количественная интеграция этих критериев с явными оценками $\mu_f(f|D)$ для нейросетевых архитектур.

В **пятой главе** предложены методы снижения сложности параметрических моделей глубокого обучения. Первый класс методов связан с удалением параметров на основе ковариационной матрицы градиентов функции ошибки: параметры ранжируются по влиянию на функцию потерь, после чего наименее значимые удаляются. Дополнительно разработан вариант прореживания на основе модификации метода Белсли, использующий сингулярное разложение ковариационной матрицы и анализ дисперсионных долей. Эксперименты показывают возможность удаления до $\approx 80\%$ параметров без существенной потери качества и повышенную устойчивость метода Белсли к шуму.

Ковариационная матрица градиентов используется как эмпирическая характеристика чувствительности функции потерь к изменению отдельных параметров. Если параметр дает малый вклад в вариацию градиента, то его удаление с меньшей вероятностью приводит к существенному изменению функции потерь. В методе Белсли дополнительно учитывается мультиколлинеарность параметров: параметры могут быть по отдельности значимыми, но находиться в зависимых направлениях, что делает часть из них избыточной. Поэтому анализ сингулярных чисел и дисперсионных долей позволяет выявлять группы параметров, которые можно удалять более устойчиво, чем при простом ранжировании по индивидуальным величинам.

Второй класс методов связан с дистилляцией. Байесовская постановка ниже используется как теоретический инструмент согласования архитектур учи-




Рис. 5: Точность классификации на выборке Wine в зависимости от доли удаленных параметров для разных методов прореживания. Оптимальное прореживание, вариационный метод и метод Белсли допускают удаление около 80% параметров без существенной потери качества.

теля и ученика; центральными прикладными конструкциями главы являются многодоменная дистилляция, антидистилляция, прореживание и низкоранговая адаптация, тогда как байесовские теоремы об удалении нейрона и слоя поддерживают вероятностную интерпретацию сжатия параметрического пространства. В байесовской постановке априорное распределение параметров ученика задается через апостериорное распределение параметров учителя; для случаев удаления нейронов и слоя используются соотношения, описывающие сохранение нормального вида распределения параметров после выравнивания архитектур. Эксперименты на синтетических данных и Fashion-MNIST показывают, что такой априор повышает правдоподобие модели ученика при существенном сокращении числа параметров. Байесовская дистилляция формулируется через маргинальное правдоподобие данных при заданных параметрах априорного распределения:

$$\mathcal{M}(\mathcal{D}, \mathbf{A}) = \int p(\mathcal{D}|\mathbf{w})p(\mathbf{w}|\mathbf{A}) d\mathbf{w}.$$

Задача состоит в выборе таких параметров априорного распределения ученика, которые сохраняют информацию, содержащуюся в апостериорном распределении учителя. При вариационном приближении это приводит к минимизации расхождения Кульбака–Лейблера между апостериорным распределением параметров и выбранным семейством аппроксимирующих распределений. Соотношения для распределения параметров при удалении нейрона и слоя показывают, как нормальное распределение параметров преобразуется при согласовании архитектур учителя и ученика. В результате байесовская дистилляция задает не только эвристическую процедуру переноса знаний, но и вероятностную постановку уменьшения размерности параметрического пространства.

Распределение параметров при удалении нейрона.

Теорема 20 (Распределение параметров при удалении нейрона). Пусть выполняются условия:

1. апостериорное распределение параметров модели учителя имеет вид

$$p(\mathbf{u}|\mathcal{D}) = \mathcal{N}(\mathbf{m}, \Sigma);$$

2. число слоев модели учителя равно числу слоев модели ученика: $T = L$;
3. размеры соответствующих слоев удовлетворяют условию $n_t^{(\text{tr})} \geq n_t^{(\text{st})}$.

Пусть преобразование $\phi(t, \mathbf{u})$ удаляет один нейрон из t -го слоя модели учителя, а $\mathbf{v} = \phi(t, \mathbf{u})$ — вектор оставшихся параметров. Тогда распределение параметров после такого преобразования также является нормальным:

$$p(\mathbf{v}|\mathcal{D}) = \mathcal{N}(\boldsymbol{\mu}_v, \Xi_{v,v}).$$

При этом параметры условного нормального распределения вычисляются как

$$\begin{aligned}\boldsymbol{\mu} &= \mathbf{m}_{\bar{\nu}_1} + \Sigma_{\bar{\nu}_1, \nu_1} \Sigma_{\nu_1, \nu_1}^{-1} (\mathbf{0} - \mathbf{m}_{\nu_1}), \\ \Xi &= \Sigma_{\bar{\nu}_1, \bar{\nu}_1} - \Sigma_{\bar{\nu}_1, \nu_1} \Sigma_{\nu_1, \nu_1}^{-1} \Sigma_{\nu_1, \bar{\nu}_1},\end{aligned}$$

где ν_1 — зануляемые параметры, ν_2 — удаляемые параметры, $\bar{\nu}_1 = [\nu^\top, \nu_2^\top]^\top$, а $\boldsymbol{\mu}_v$ и $\Xi_{v,v}$ являются соответствующими подвектором и подматрицей.

Распределение параметров при удалении слоя.

Теорема 21 (Распределение параметров при удалении слоя). Пусть выполняются условия:

1. апостериорное распределение параметров модели учителя имеет вид

$$p(\mathbf{u}|\mathcal{D}) = \mathcal{N}(\mathbf{m}, \Sigma);$$

2. размеры соседних слоев модели учителя совпадают, $n_t^{(\text{tr})} = n_{t-1}^{(\text{tr})}$, то есть матрица $\mathbf{U}_t$ является квадратной;
3. функция активации удовлетворяет свойству идемпотентности $\sigma \circ \sigma = \sigma$.

Пусть преобразование $\psi(t, \mathbf{u})$ удаляет t -й слой модели учителя, а $\mathbf{v} = \psi(t, \mathbf{u})$ — вектор оставшихся параметров. Тогда апостериорное распределение оставшихся параметров также является нормальным:

$$\begin{aligned}p(\mathbf{v}|\mathcal{D}) &= \mathcal{N}(\mathbf{m}_v + \Sigma_{v, \bar{v}} \Sigma_{\bar{v}, \bar{v}}^{-1} (\mathbf{i} - \mathbf{m}_{\bar{v}}), \\ &\quad \Sigma_{v,v} - \Sigma_{v, \bar{v}} \Sigma_{\bar{v}, \bar{v}}^{-1} \Sigma_{\bar{v}, v}),\end{aligned}$$

где $\bar{v}$ — вектор параметров удаляемого слоя, а

$$\mathbf{i} = [\underbrace{1, 0, \dots, 0}_{n_t}, \underbrace{0, 1, \dots, 0}_{n_t}, \dots, \underbrace{0, \dots, 1}_{n_t}]^\top.$$

В многодоменной дистилляции предложена функция потерь, учитывающая модель-учитель и отображение между доменами данных, что позволяет переносить знания между различными предметными областями.

Определение 18 (Близкие генеральные совокупности). *Генеральная совокупность объектов B называется близкой к генеральной совокупности A , если существует инъективное отображение $\varphi : A \rightarrow B$.*

В экспериментах на ImageNet сравниваются обучение без учителя, дистилляция в одном домене и дистилляция с доменной адаптацией через φ . Модель с учителем и адаптацией домена заметно превосходит базовый вариант без дистилляции, хотя обучение строго в одном домене дает наилучшие абсолютные показатели. На OPUS-100 для пар fr-en и de-en многодоменная дистилляция снижает ошибку перекрестной энтропии и повышает BLEU относительно обучения ученика без учителя. Таким образом, учет доменной связи позволяет использовать информацию из домена сильной модели для улучшения модели в другом домене.

В антидистилляции рассматривается обратная задача: простая модель используется для устойчивой инициализации более сложной модели; функция потерь включает регуляризацию близости параметров, устойчивости к шуму и матрицы Гессе функции потерь. В экспериментах на Fashion-MNIST сравниваются Xavier-инициализация, Zero Pad, Uniform Pad, Transfer Learning, Net2Net, вариант с шумом данных и варианты антидистилляции. Антидистилляция достигает точности $0,86 \pm 0,05$, показывает лучшую устойчивость к FGSM-атаке ($0,57 \pm 0,03$) и сохраняет высокую точность при шуме в параметрах ($0,73 \pm 0,04$ для варианта без регуляризации гессиана). Эти результаты показывают, что снижение сложности может состоять не только в уменьшении числа параметров, но и в контролируемом увеличении сложности модели при сохранении устойчивости обучения. Полученные результаты обосновывают пятое положение, выносимое на защиту: редукция пространства обучаемых параметров уменьшает число параметров модели при сохранении порядка качества аппроксимации. Положение закрывается методами снижения и перераспределения сложности пятой главы, а также низкоранговой адаптацией и многозадачным обучением шестой главы.

В **шестой главе** показаны прикладные применения разработанного аппарата. Теоретическая часть главы вместе с пятой главой обосновывает пятое положение, выносимое на защиту: редукция пространства обучаемых параметров уменьшает число параметров модели при сохранении порядка качества аппроксимации. Экспериментальные разделы иллюстрируют практическую значимость аппарата на внешних задачах. В задаче многозадачного обучения получены результаты о статистической состоятельности LoRA-адаптеров и сравнении верхних оценок эмпирической радемахеровской сложности на задачу при совместном обучении T задач; эксперименты по детекции машинно-генерированного текста показывают, что LoRA использует малую долю параметров полной модели, а MTL улучшает качество и снижает оценку эмпириче-

ской сложности. Для LoRA-адаптеров рассматривается параметризация низкорангового обновления матрицы весов $\Delta W = AB$, где ранг r существенно меньше исходных размерностей слоя. В теоретическом анализе показано, что минимизация эмпирического риска в такой параметризации остается согласованной с минимизацией истинного риска при выполнении стандартных предположений о классе функций и сходимости эмпирического риска. Отдельно проверяется корректность выходного слоя: низкоранговое обновление изменяет параметры модели, но сохраняет стандартную форму классификационного правила и распределение вероятностей на том же пространстве классов. Для многозадачного обучения получено сравнение верхних оценок эмпирической радемахеровской сложности на задачу при справедливом масштабировании параметров энкодера.

Теорема 22 (Состоятельность оценки). *Пусть $\mathcal{D} = \{(X_i, c_i)\}_{i=1}^n$ — независимые одинаково распределенные пары из распределения P_{true} на $\mathcal{X} \times [N_c]$, где $[N_c] = \{1, \dots, N_c\}$. Рассмотрим компактное множество $K \subset \mathbb{R}^p$ и параметрическую модель $P_{\Phi_0 + \Theta}(c | X)$ при $\Theta \in K$, где Φ_0 — замороженный вектор предобученных параметров. Предположим:*

1. *Существует единственная точка $\Theta^* \in K$, минимизирующая ожидаемый риск*

$$L(\Theta) = \mathbb{E}_{(X,c) \sim P_{\text{true}}} [-\log P_{\Phi_0 + \Theta}(c | X)], \quad \Theta \in K.$$

2. *Функция $(X, c, \Theta) \mapsto -\log P_{\Phi_0 + \Theta}(c | X)$ непрерывна на своей области допустимых значений и*

$$\mathbb{E}_{(X,c) \sim P_{\text{true}}} \left[\sup_{\Theta \in K} |\log P_{\Phi_0 + \Theta}(c | X)| \right] < \infty.$$

3. *Эмпирический риск задается в виде*

$$\mathcal{L}_n(\Theta) = -\frac{1}{n} \sum_{i=1}^n \log P_{\Phi_0 + \Theta}(c_i | X_i),$$

а оценка $\hat{\Theta}_n$ выбирается как измеримый минимизатор $\mathcal{L}_n$ на K (если минимум достигается; иначе — ε_n -минимизатор с $\varepsilon_n \downarrow 0$).

Тогда $\hat{\Theta}_n \xrightarrow{P} \Theta^$ при $n \rightarrow \infty$.*

Теорема 23 (Корректность при низкоранговых обновлениях). *Предположим следующее:*

1. *Выходной слой задается в виде*

$$\hat{\mathbf{y}} = \text{softmax}(W_{\text{upd}}^\top \mathbf{x}),$$

где $\mathbf{x} \in \mathbb{R}^d$ — это вектор признаков BERT, $W \in \mathbb{R}^{d \times k}$ — замороженные предобученные веса, а

$$W_{\text{upd}} = W + \Delta W.$$

2. Вместо непосредственного обучения $\Delta W \in \mathbb{R}^{d \times k}$, обновление параметризуется в низкоранговой форме:

$$\Delta W = AB, \quad A \in \mathbb{R}^{d \times r}, B \in \mathbb{R}^{r \times k}, r \ll \min(d, k).$$

3. Выполнены условия соответствующей теоремы основного текста, т.е. модель остается статистически состоятельной при минимизации эмпирического риска.

Тогда при параметризации выход модели $\hat{y}$ сохраняется в том смысле, что низкоранговое обновление не искажает корректность классификационного слоя.

Следствие 24 (Низкоранговая адаптация с теоретическим обоснованием). Объединяя теорему о состоятельности оценки и теорему о корректности при низкоранговых обновлениях, получаем, что тонкая настройка на основе низкоранговой адаптации одновременно сохраняет статистическую состоятельность оценки и корректность выходного слоя, при этом требуя существенно меньшего числа обучаемых параметров.

Теорема 25 (Сложность Радемахера на задачу при MTL). Пусть $S_t = \{x_i\}_{i=1}^n$ — выборка фиксированной целевой задачи t с $\|x_i\|_2 \leq R$. Пусть $\phi(\cdot; w)$ — энкодер, и рассмотрим линейные головы $f_{w,h}(x) = h^\top \phi(x; w)$ с $\|h\|_2 \leq B_{\text{head}}$. Предположим:

1. Ограничение на признаки: для всех x, w $\|\phi(x; w)\|_2 \leq L \|w\|_2 \|x\|_2$.
2. Энкодер STL удовлетворяет $\|w_{\text{enc}}\| \leq B_{\text{enc}}$, общий энкодер MTL удовлетворяет $\|w_{\text{shared}}\| \leq B_{\text{shared}}$.
3. Многозадачное масштабирование: $B_{\text{shared}} \leq B_{\text{enc}}/\sqrt{T}$.

Обозначим через $\hat{\mathfrak{R}}_n(\cdot; S_t)$ эмпирическую сложность Радемахера на S_t . Пусть $\mathcal{F}_{\text{STL}}^{(t)}$ совпадает с семейством $\mathcal{F}(B_{\text{enc}})$, а $\mathcal{F}_{\text{MTL}}^{(t)}$ — с семейством $\mathcal{F}(B_{\text{shared}})$, где класс $\mathcal{F}(B)$ задается в основном тексте диссертации. Введем функцию

$$U_n(B) := \frac{B_{\text{head}} L R B}{\sqrt{n}}.$$

Тогда

$$\hat{\mathfrak{R}}_n(\mathcal{F}_{\text{MTL}}^{(t)}; S_t) \leq U_n(B_{\text{shared}}) \leq \frac{1}{\sqrt{T}} U_n(B_{\text{enc}}), \quad \hat{\mathfrak{R}}_n(\mathcal{F}_{\text{STL}}^{(t)}; S_t) \leq U_n(B_{\text{enc}}).$$

Следовательно, одна и та же величина вида $U_n(B)$ дает верхнюю оценку эмпирической сложности Радемахера в STL- и MTL-постановках, а предположение 3 обеспечивает не менее чем $1/\sqrt{T}$ -кратное уменьшение шаблонной верхней оценки при переходе от B_{enc} к B_{shared} .




Рис. 6: Зависимость F_1 от ранга r адаптеров LoRA (DeBERTa-v3-base) в задаче детекции машинно-генерированного текста. Наилучшее качество достигается при $r = 8$.

В экспериментах по детекции машинно-генерированного текста LoRA-адаптеры с рангом $r = 8$ требуют только 0,16% параметров полной модели. При этом снижение метрик качества относительно полной тонкой настройки остается небольшим, а потери на валидации уменьшаются на 36,3% при ускорении обучения на 12,6%.

Многозадачная постановка с тремя выходными головками повышает F_1 с 0,781 до 0,826 и ROC-AUC с 0,788 до 0,834. Оценка эмпирической сложности Радемахера уменьшается с $0,0159 \pm 0,0009$ до $0,0111 \pm 0,0010$, что качественно согласуется с уменьшением измеряемой сложности при многозадачной регуляризации энкодера. Эти результаты связывают прикладную задачу детекции машинно-генерированного текста с общей темой диссертации. LoRA-адаптеры уменьшают число обучаемых параметров, многозадачная постановка уменьшает оценку сложности на задачу, а экспериментальные метрики показывают, что такое снижение сложности не приводит к существенной потере качества. В результате адаптерная тонкая настройка рассматривается как пример практического снижения сложности модели.

В задаче декодирования фМРТ-изображений предложена схема реконструкции томографических данных из видеопоследовательностей с предварительным сжатием фМРТ-представлений. Показано, что снижение размерности существенно сокращает время обучения без ухудшения качества реконструкции. В задаче детекции машинно-генерированного контента предложены метрики качества наборов данных KL_{TTS} , PHD, Δ_{shift} и $KL_{shuffle}$, основанные на сравнении распределений, топологической статистике и устойчивости к возмущению.

ям. Эти результаты демонстрируют применимость теории сложности моделей и данных к выбору компактных адаптационных механизмов, снижению размерности биомедицинских данных и контролю качества обучающих наборов. В задаче декодирования фМРТ-изображений используется представление видеокадров с помощью ResNet152 и линейная регрессия с L_2 -регуляризацией для предсказания изменений фМРТ-сигнала. Проверяются коэффициенты сжатия признакового описания 2, 4 и 8. Время обучения уменьшается с 36,3 секунды до 6,7, 1,6 и 1,4 секунды соответственно, при этом качество реконструкции остается сопоставимым с исходным представлением. Оптимальное значение регуляризации $\alpha \approx 1000$ сохраняется при разных коэффициентах сжатия, что указывает на устойчивость предложенной процедуры снижения размерности.

В задаче детекции машинно-генерированного контента рассматривается не только качество детектора, но и качество самих оценочных наборов. Метрика KL_{TTS} сравнивает распределения признаков текстов, RHD отражает топологические характеристики облака представлений, Δ_{shift} оценивает устойчивость к адверсарным сдвигам, а $KL_{shuffle}$ измеряет чувствительность к перемешиванию предложений. Сравнение нескольких наборов данных и детекторов показывает, что высокие показатели на одном наборе не гарантируют устойчивости на другом. Качественные наборы данных характеризуются близкими топологическими распределениями человеческих и машинно-сгенерированных текстов, что делает их более пригодными для оценки современных детекторов. Практический вывод состоит в том, что сложность данных нельзя сводить к объему выборки: два набора одного размера могут различаться по устойчивости к возмущениям и по степени перекрытия распределений «человек/машина». Поэтому контроль качества данных является необходимым дополнением к анализу сложности модели при построении и сравнении детекторов.

Таким образом, последняя глава показывает, что аппарат сложности полезен не только для анализа архитектур, но и для проектирования адаптационных механизмов, снижения размерности биомедицинских данных и диагностики качества обучающих наборов. Это завершает общую линию диссертации от теоретических мер сложности к практическим методам анализа моделей и данных.

Основные результаты и выводы

В диссертации разработан единый математический аппарат оценки согласованности и снижения сложности моделей глубокого обучения и данных, основанный на теории мер, анализе матриц Гессе и ландшафте оптимизационной задачи. Основные результаты состоят в следующем.

1. Разработан формальный аппарат мер сложности выборки μ_D и модели μ_f и сформулирован критерий согласованности $\mu_f(f) \leq \mu_D(D)$.
2. Введена ландшафтная мера $\mu_f(f|D)$ через разброс пообъектных матриц Гессе; установлена ее связь с приращением эмпирического риска при росте выборки.

3. Получены теоретические оценки ландшафтной меры и спектральных норм матриц Гессе для полносвязных, сверточных и трансформерных архитектур, выявляющие роль глубины, ширины, каналов, ядер и блоков самовнимания.
4. Построены критерии достаточного объема выборки (D -, M -, KL - и S -достаточность) и доказана их корректность в модели линейной регрессии при сходимости моментов оценок или апостериорных распределений; связь со сложностью моделей задается через постановку условной сложности данных и наблюдаемый критерий стабилизации эмпирического риска, а сами критерии дают наблюдаемую оценку m^* без прямого вычисления матриц Гессе.
5. Разработаны методы снижения и перераспределения сложности: прореживание по ковариации градиентов и метод Белсли, байесовская и многодоменная дистилляция, антидистилляция.
6. Для LoRA-адаптеров доказана состоятельность оценки при стандартных условиях, а для многозадачного обучения получено сравнение верхних оценок эмпирической радемахеровской сложности на задачу при справедливом масштабировании нормы энкодера.
7. Прикладные эксперименты по детекции машинно-генерированного текста, декодированию фМРТ и оценке качества наборов данных подтверждают практическую применимость аппарата.

Совокупность полученных результатов позволяет считать научную проблему оценки согласованности и снижения сложности моделей и данных формализованной в рамках единого теоретического подхода, применимого к широкому классу нейросетевых архитектур.

Список работ, опубликованных автором по теме диссертации

1. Варламова К. Д., Дорин Д. Д., Грабовой А. В. За чертой знакомых доменов: исследование обобщающей способности детекторов машинно сгенерированных изображений // Доклады Российской академии наук. Математика, информатика, процессы управления. 2025. Т. 527, № 7. С. 103–116. DOI: 10.7868/S2686954325070094.
2. Дорин Д. Д., Грабовой А. В., Стрижов В. В. Улучшение декодирования данных ФМРТ с использованием пространственно-временных характеристик в условиях ограниченного набора данных // Доклады Российской академии наук. Математика, информатика, процессы управления. 2025. Т. 527, № 7. С. 11–30. DOI: 10.7868/S2686954325070021.
3. Kiselev N. S., Grabovoy A. V. Sample Size Determination: Likelihood Bootstrapping // Computational Mathematics and Mathematical Physics. 2025. Vol. 65, no. 2. pp. 416–423. DOI: 10.1134/s0965542524702002.
4. Kiselev Nikita, Grabovoy Andrey. Sample size determination: posterior distributions proximity // Computational Management Science. 2025. Vol. 22, no. 1. pp. 1. DOI: 10.1007/s10287-024-00528-9.

5. Gritsai G. M., Khabutdinov I. A., Grabovoy A. V. Stack More LLM's: Efficient Detection of Machine-Generated Texts via Perplexity Approximation // Doklady Mathematics. 2024. Vol. 110, no. S1. pp. S203–S211. DOI: 10.1134/s1064562424602075.
6. Kiselev N. S., Grabovoy A. V. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // Doklady Mathematics. 2024. Vol. 110, no. S1. pp. S49–S61. DOI: 10.1134/s1064562424601987.
7. Dorin Daniil, Kiselev Nikita, Grabovoy Andrey, Strijov Vadim. Forecasting fMRI images from video sequences: linear model analysis // Health Information Science and Systems. 2024. Vol. 12, no. 1. pp. 55. DOI: 10.1007/s13755-024-00315-5.
8. Gritsay G. M., Grabovoy A. V., Kildyakov A. S., Chekhovich Yu V. Artificially Generated Text Fragments Search in Academic Documents // Doklady Mathematics. 2024. DOI: 10.1134/s1064562423701211.
9. Grabovoy A. V., Gadaev T. T., Motrenko A. P., Strijov V. V. Numerical Methods of Sufficient Sample Size Estimation for Generalised Linear Models // Lobachevskii Journal of Mathematics. 2022. Vol. 43, no. 9. pp. 2453–2462. DOI: 10.1134/s1995080222120125.
10. Grabovoy A. V., Strijov V. V. Probabilistic Interpretation of the Distillation Problem // Automation and Remote Control. 2022. Vol. 83, no. 1. pp. 123–137. DOI: 10.1134/s000511792201009x.
11. Grabovoy A. V., Strijov V. V. Bayesian Distillation of Deep Learning Models // Automation and Remote Control. 2021. Vol. 82, no. 11. pp. 1846–1856. DOI: 10.1134/s0005117921110023.
12. Грабовой А. В., Бахтеев О. Ю., Стрижов В. В. Введение отношения порядка на множестве параметров аппроксимирующих моделей // Информатика и ее применения. 2020. Т. 14, № 2. С. 58–65. DOI: 10.14357/19922264200208.
13. Грабовой А. В., Бахтеев О. Ю., Стрижов В. В. Определение релевантности параметров нейросети // Информатика и ее применения. 2019. DOI: 10.14357/19922264190209.

Материалы международных конференций, индексируемые Scopus и/или Web of Science

14. Gritsai G., Voznuyk A., Khabutdinov I., Grabovoy A. Advacheck at GenAI Detection Task 1: AI Detection Powered by Domain-Aware Multi-Tasking // Proceedings of the 1st Workshop on GenAI Content Detection (GenAIDetect). 2025. Pp. 236–243. International Conference on Computational Linguistics, Abu Dhabi, UAE.
15. Poimanov D., Mestetsky L., Grabovoy A. N-Gram Perplexity-Based AI-Generated Text Detection // 2024 Ivannikov Ispras Open Conference (ISPRAS). 2024. Pp. 1–8. DOI: 10.1109/ispras64596.2024.10899150. IEEE.

16. Meshkov V., Kiselev N., Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // 2024 Ivannikov Ispras Open Conference (ISPRAS). 2024. Pp. 1–10. DOI: 10.1109/ispras64596.2024.10899113. IEEE.
17. Boeva G., Gritsay G., Grabovoy A. Team ap-team at PAN: LLM Adapters for Various Datasets // Working Notes of the Conference and Labs of the Evaluation Forum (CLEF 2024). 2024. Vol. 3740 (CEUR Workshop Proceedings). Pp. 2527–2535. CEUR-WS.org.
18. Gritsai G., Khabutdinov I., Grabovoy A. Multi-head Span-based Detector for AI-generated Fragments in Scientific Papers // Proceedings of the Fourth Workshop on Scholarly Document Processing (SDP 2024). 2024. Pp. 220–225. DOI: 10.18653/v1/2024.sdp-1.21. Association for Computational Linguistics, Bangkok, Thailand.
19. Petrushina K., Bakhteev O., Grabovoy A., Strijov V. Anti-Distillation: Knowledge Transfer from a Simple Model to the Complex One // 2022 Ivannikov Ispras Open Conference (ISPRAS). 2022. DOI: 10.1109/ispras57371.2022.10076855. IEEE.
20. Gritsay G., Grabovoy A., Chekhovich Y. Automatic Detection of Machine Generated Texts: Need More Tokens // Ivannikov Memorial Workshop Proceedings 2022. 2022. DOI: 10.1109/ivmem57067.2022.9983964.

Публикации в других изданиях

21. Грабовой А. В. О сложности моделей и данных в задачах обучения нейросетевых моделей // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 72–73. ООО "МАКС Пресс", Москва.
22. Киселев Н. С., Мешков В. С., Грабовой А. В. Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 73–76. ООО "МАКС Пресс", Москва.
23. Грицай Г. М., Грабовой А. В. Неявная регуляризация векторного представления текстов в подходе многозадачного обучения // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 78–79. ООО "МАКС Пресс", Москва.
24. Дорин Д. Д., Киселев Н. С., Грабовой А. В. Декодирование визуальных стимулов из мультимодальных сигналов мозга // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 124–126. ООО "МАКС Пресс", Москва.

25. Мешков В. С., Киселев Н. С., Грабовой А. В. Сходимость ландшафта сверточных нейронных сетей: анализ матричных сетей на основе матрицы Гессе // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.
26. Киселев Н. С., Грабовой А. В. Сходимость поверхности функции потерь как признак достаточного размера выборки // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.
27. Дорин Д. Д., Грабовой А. В. Улучшение декодирования фМРТ в условиях ограниченной выборки // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.
28. Грицай Г. М., Грабовой А. В. Выравнивание представлений в подходе многозадачного обучения для детектирования машинно-сгенерированных текстов // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.
29. Киселев Н., Грабовой А. Определение достаточного размера выборки по апостериорному распределению параметров модели // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. 2024. С. 141. ISBN 978-5-89155-414-6. (Прикладная математика и информатика). Физматкнига.
30. Баязитов К. М., Грабовой А. В., Стрижов В. В. Дистилляция моделей глубокого обучения на многодоменных выборках // Интеллектуализация обработки информации: Тезисы докладов 14-й Международной конференции. 2022. С. 98–99. ISBN 978-5-907366-77-0. Российская академия наук, Москва.