

На правах рукописи

Грабовой Андрей Валериевич

О СЛОЖНОСТИ МОДЕЛЕЙ И ДАННЫХ
В ПАРАМЕТРИЧЕСКИХ МОДЕЛЯХ МАШИННОГО ОБУЧЕНИЯ

1.2.1 — Искусственный интеллект и машинное обучение

АВТОРЕФЕРАТ
диссертации на соискание ученой степени
доктора физико-математических наук

Москва — 2026

Работа выполнена в Лаборатории 42 «Интеллектуального анализа данных» Института проблем управления им. В.А.Трапезникова РАН.

Научный консультант: **Воронцов Константин Вячеславович**
доктор физико-математических наук, профессор
РАН, Федеральный исследовательский центр «Информатика и управление» Российской академии наук, отдел интеллектуальных систем, ведущий научный сотрудник.

Официальные оппоненты: _____

Ведущая организация: Автономная некоммерческая организация высшего образования «Университет Иннополис».

Защита состоится _____ года в 14:00 на заседании диссертационного совета Д 002.073.05 при Федеральном исследовательском центре «Информатика и управление» Российской академии наук (ФИЦ ИУ РАН) по адресу: 119333, г. Москва, ул. Вавилова, д. 40.

С диссертацией можно ознакомиться в библиотеке Федерального государственного учреждения Федеральный исследовательский центр «Информатика и управление» Российской академии наук и на сайте <http://www.frccsc.ru/>

Автореферат разослан _____ 2026 года.

Ученый секретарь
диссертационного совета Д 002.073.05
к.т.н.

И. А. Рейер

Общая характеристика работы

Актуальность темы. С начала XXI века производительность вычислительных систем, измеряемая в операциях с плавающей запятой (англ. FLOPS), выросла экспоненциально: от терафлопсов до эксафлопсов. Параллельно на несколько порядков выросла и сложность моделей глубокого обучения: от тысяч обучаемых параметров в начале 2000-х до миллиардов и сотен миллиардов в 2020-х; в ближайшее десятилетие ожидается переход к триллионам. Анализ сложности таких моделей сегодня в основном опирается на эмпирические корреляции: качество связывают с числом параметров и с вычислительными затратами на обучение и вывод. Без строгой теории, позволяющей предсказывать поведение моделей при масштабировании, разработка оказывается затратной по вычислениям и энергии, а получаемые результаты — часто плохо воспроизводимыми и противоречивыми.

Особенно остро проблема стоит для больших языковых моделей (англ. LLM): их обучение требует больших вычислительных, энергетических и финансовых затрат. Чтобы уменьшить неопределённость при предобучении (англ. pretrain), на практике эмпирически подбирают соотношение между числом параметров модели и объёмом данных (в токенах) при заданном вычислительном бюджете. Но оценки, полученные для одной архитектуры, обычно не переносятся на другие, поэтому такие подходы ограничены и при полномасштабном обучении нередко дают неожиданные результаты. Поэтому нужны теоретические оценки сложности: они позволяют ещё на этапе проектирования связать сложность модели со сложностью выборки и обоснованно выбрать размер модели и объём данных.

Классические подходы к оценке сложности моделей машинного обучения, разработанные для традиционных методов, находят ограниченное применение при анализе моделей глубокого обучения. Фундаментальный вклад в теорию оценивания сложности моделей внесли работы Владимира Наумовича Вапника и Алексея Яковлевича Червоненкиса, заложившие основы статистической теории обучения, а также Лесли Вэлианта, предложившего подход приближенно правильного обучения (англ. PAC-Learning). В основном современные подходы к определению сложности основаны на Радемахеровской сложности, предложенной Владимиром Кольчинским и Дмитрием Панченко, и комбинаторном подходе к оценке обучаемости алгоритмов Константина Вячеславовича Воронцова, в котором разработан математический аппарат на основе комбинаторных оценок вероятности переобучения моделей. Однако современные исследования в области теории машинного обучения редко рассматривают нейросетевые модели глубокого обучения ввиду их высокой сложности и трудности получения адекватных оценок сложности таких моделей. Значительная часть современных исследований посвящена классическим методам машинного обучения и улучшению оценок для известных методов, так как текущие оценки сложности даже для классических моделей являются сильно завышенными.

Отдельным направлением в исследованиях являются оценки репрезентативной способности моделей глубокого обучения к аппроксимации по прецедентам. Основополагающий результат принадлежит Джорджу Цибенко, который доказал, что нейронные сети аппроксимируют непрерывные функции с некоторыми ограничениями с произвольной точностью. Йохану Хестада принадлежат первые оценки, указывающие на рост аппроксимирующей способности моделей глубокого обучения с глубиной модели. В более современных работах Яна Лекуна, Йошуа Бенджио, Надава Коэна эти оценки получены с более мягкими ограничениями на класс рассматриваемых функций. В целом все эти оценки наряду с работой Охада Шамира указывают на экспоненциальное увеличение аппроксимирующей способности моделей глубокого обучения с ростом числа слоев.

В настоящей работе предлагается теоретический анализ нейросетевых моделей, опирающийся на анализ их матриц Гессе. Матрица Гессе функции потерь по параметрам модели содержит информацию о локальной кривизне оптимизационного ландшафта и используется для анализа сложности модели и обучающей выборки, а также для оценки важности параметров в задачах прореживания нейросетевых моделей. Локализация исследования: рассматриваются параметрические модели машинного обучения в постановке минимизации эмпирического риска; в центр ставится согласованность сложности модели с характеристиками выборки, а не построение новых универсальных аппроксиматоров. **Степень разработанности темы диссертационного исследования.** Классические оценки сложности — VC-размерность, PAC-обучаемость и радемахеровская сложность — построены для моделей с умеренным числом параметров и ориентированы на наихудший случай. Для перепараметризованных нейронных сетей такие оценки обычно слишком консервативны: они не учитывают сверточные фильтры, остаточные связи и механизмы внимания и не отражают влияние регуляризации, ранней остановки и хода оптимизации на обобщающую способность. Комбинаторный подход К. В. Воронцова снижает оценки Вапника–Червоненкиса, но применим лишь к узким классам моделей.

Оценка сложности данных чаще всего сводится к объёму выборки, хотя сложность определяется свойствами отдельных объектов. Современные методы оценки сложности объектов опираются на анализ многообразий, аппроксимирующих элементы выборки. Для больших языковых моделей широко используют эмпирические законы масштабирования Каплана и Хофмана, однако у них нет строгого теоретического обоснования, и они не объясняют механизмы связи между параметрами, данными и качеством модели.

Для снижения сложности моделей применяют квантизацию, прореживание и дистилляцию знаний. Эти методы, как правило, не опираются на строгие оценки сложности модели и данных, поэтому их эффективность и предсказуемость ограничены.

В итоге единого теоретического аппарата, который давал бы асимптотические оценки сложности моделей глубокого обучения и формализовал согласованность модели с обучающей выборкой, до сих пор нет. Такой аппарат нужен,

чтобы сравнивать параметрические модели и выбирать архитектуру под задачу с выборкой заданной сложности.

Объектом исследования являются процессы параметрического обучения моделей машинного обучения по конечным выборкам.

Предмет исследования: согласованность сложности параметрических моделей машинного обучения с характеристиками обучающей выборки, формализуемая мерами на модели и на выборке.

Цель и задачи исследования. Целью исследования является построение теоретического аппарата оценки согласованности сложности параметрических моделей машинного обучения с характеристиками обучающей выборки и методов снижения сложности таких моделей на основе анализа ландшафта функции потерь.

Для достижения цели были поставлены и решены следующие задачи:

- введение определений мер сложности моделей и выборок в рамках теории мер и формулировка критерия согласованности модели и выборки;
- построение ландшафтной меры сложности модели по матрицам Гессе и установление ее связи с приращением эмпирического риска при изменении выборки;
- получение теоретических оценок ландшафтной меры для полносвязных, сверточных и трансформерных архитектур;
- построение методов оценки достаточного объема выборки и анализ их связи со сложностью модели через условную сложность данных и стабилизацию эмпирического риска;
- построение методов снижения сложности моделей, опирающихся на локальную геометрию функции потерь;
- демонстрация применимости построенного аппарата в прикладных задачах.

Методы исследования. В работе используются теория мер, линейная алгебра и матричный анализ (в том числе матричное дифференцирование и спектральный анализ), теория вероятностей и математическая статистика (включая байесовский подход и сходимост случайных процессов), теория оптимизации, анализ функций многих переменных и статистическая теория обучения.

Научная новизна.

1. Введены меры сложности выборки $\mu_D(D)$ и модели $\mu_f(f)$ в терминах теории мер и сформулирован критерий согласованности $\mu_f(f) \leq \mu_D(D)$.
2. Введена ландшафтная мера сложности модели

$$\mu_f(f|D) = \mathbb{E}_i \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_j \mathbf{H}_j(\boldsymbol{\theta}^*)\|_2,$$

где ожидания берутся по равномерному выбору объектов i, j из выборки D , а $\|\cdot\|_2$ — спектральная норма; мера количественно связывает изменение выборки с локальной геометрией ландшафта функции потерь.

3. Для полносвязных, сверточных и трансформерных архитектур получены оценки ландшафтной меры через спектральные нормы матриц Гессе; оценки растут экспоненциально по глубине и полиномиально по ширине и числу каналов.
4. Для линейной регрессии обоснованы байесовские критерии достаточного объема выборки по близости апостериорных распределений параметров и проанализирована их сходимость; связь со сложностью модели проводится через условную сложность данных и стабилизацию эмпирического риска.
5. Предложены методы снижения сложности, опирающиеся на локальную геометрию функции потерь: прореживание по ковариации градиентов, многодоменная дистилляция и антидистилляция.
6. Для низкоранговой адаптации параметров доказана состоятельность оценки при стандартных условиях; для многозадачного обучения сравнены верхние оценки эмпирической радемахеровской сложности на задачу при справедливом масштабировании нормы энкодера.

Теоретическая значимость работы. Результаты вписывают локальный анализ матриц Гессе в теорию сложности обучаемости как вычислимый мост между архитектурными параметрами модели и вопросом согласования модели с выборкой, расширяя классические подходы на основе VC-размерности, PAC-обучаемости и радемахеровской сложности на случай перепараметризованных моделей. Полученные оценки ландшафтной меры дают основание для сравнительного анализа архитектур и для сопоставления методов оценки достаточного объема выборки со сложностью модели. Основной вклад работы состоит в построении ландшафтной меры сложности параметрической модели и в установлении на ее основе вычислимой связи между архитектурой модели, стабилизацией обучения и характеристиками выборки.

Практическая значимость работы. Разработанный теоретический аппарат применен к решению прикладных задач машинного обучения: многозадачного обучения, декодирования фМРТ-изображений и детекции машинно-генерированного контента. Полученные методы оценки и снижения сложности моделей и данных экспериментально проверены на реальных задачах компьютерного зрения, обработки естественного языка и классификации.

Положения, выносимые на защиту:

1. Меры сложности модели и выборки вместе с критерием их согласованности задают формальный аппарат соответствия параметрической модели машинного обучения характеристикам обучающей выборки.
2. Ландшафтная мера на основе спектральных свойств матриц Гессе количественно связывает архитектуру модели с изменением эмпирического риска при изменении выборки.
3. Оценки ландшафтной меры растут экспоненциально с глубиной сети и полиномиально с шириной и числом каналов.

4. Методы оценки достаточного объема выборки по близости апостериорных распределений сходятся в модели линейной регрессии.
5. Редукция пространства обучаемых параметров уменьшает число параметров модели при сохранении порядка качества аппроксимации.

Ключевые математические результаты, соответствующие указанным положениям, в основном содержании автореферата приведены в виде формулировок теорем без доказательств.

Степень достоверности результатов. Достоверность научных результатов работы подтверждается непротиворечивостью и согласованностью с известными фактами и исследованиями в рассматриваемой области, высокой степенью сходимости теоретических результатов с данными экспериментов и определяется применением теоретических и методологических основ разработок ведущих ученых в области обработки естественного языка, корректным и обоснованным использованием математического аппарата, экспериментальными исследованиями разработанных моделей и методов.

Соответствие диссертации паспорту специальности. Тема и основные результаты диссертации соответствуют следующим областям исследований паспорта специальности 1.2.1 — Искусственный интеллект и машинное обучение.

2 Исследования в области оценки качества и эффективности алгоритмических и программных решений для систем искусственного интеллекта и машинного обучения. Методики сравнения и выбора алгоритмических и программных решений при многих критериях.

4 Разработка методов, алгоритмов и создание систем искусственного интеллекта и машинного обучения для обработки и анализа текстов на естественном языке, для изображений, речи, биомедицины и других специальных видов данных.

16 Исследования в области специальных методов оптимизации, проблем сложности и элиминации перебора, снижения размерности.

17 Исследования в области многослойных алгоритмических конструкций, в том числе – многослойных нейросетей.

Апробация результатов диссертации. Основные результаты работы докладывались и обсуждались на Всероссийской конференции с международным участием «Математические методы распознавания образов» (Москва, 2019, Москва, 2021, Муром, 2025), Международной конференции «Интеллектуализация обработки информации» (Гаэта, 2018, Москва, 2020, Москва, 2022), Всероссийской научной конференции МФТИ (Москва, 2018, 2019, 2020, 2021, 2023, 2024, 2025, 2026), VI Международная научно-практическая конференция «Магия ИННО: Перспективы развития лингвистики и лингводидактики в современных условиях» (Москва, 2023), Ivannikov Ispras Open Conference (Москва, 2021, 2022, 2023, 2024, 2025), Ivannikov Memorial Workshop (Казань, 2022, Этномир, 2026), Iberian Languages Evaluation Forum co-located with the Conference of the Spanish Society for Natural Language Processing (Андалусия, 2023, 2024), 11-я Международная научно-практическая конференция «Научное издание

международного уровня – 2023: достижения, реалии, перспективы» (Москва, 2023), 35th Conference of Open Innovations Association (Тампере, 2024), Fourth Workshop on Scholarly Document Processing (Бангкок, 2024), 1st Workshop on GenAI Content Detection (GenAIDetect) (Абу-Даби 2025), 19th International Workshop on Semantic Evaluation (Вена, 2025).

Публикации. По теме диссертации опубликовано 56 научных работ, из которых 17 статей в научно-технических журналах, входящих в перечень ВАК, 32 — в изданиях, входящих в международные наукометрические базы Scopus и Web of Science. В трудах российских и международных конференций опубликовано 39 работ. Также на основе работ автора зарегистрировано 13 программ для ЭВМ.

Личный вклад соискателя. Все выносимые на защиту результаты и положения, составляющие основное содержание диссертационного исследования, разработаны и получены лично автором или при его непосредственном участии вместе с учениками. В работах, опубликованных в соавторстве, соискателю принадлежит определяющая роль в построении теоретических методов и направлении исследований.

Структура и объем работы. Диссертация состоит из оглавления, введения, шести разделов, заключения, списка иллюстраций, списка таблиц, перечня основных обозначений и списка литературы из 261 наименования. Основной текст занимает 374 страницы.

Основное содержание работы

Во **введении** обоснована актуальность темы диссертации, сформулирована цель исследования, указаны основные задачи и научные положения, выносимые на защиту, охарактеризованы научная новизна, теоретическая и практическая значимость, указаны используемые методы исследования.

В **первой главе** дан обзор теории обучаемости и классических мер сложности моделей; глава носит методический характер и мотивирует переход к локальному анализу ландшафта функции потерь.

В **разделе 1.1** фиксируются обозначения постановки статистического обучения: выборка $D = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ из неизвестного распределения $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$, класс моделей $\mathfrak{F}$ и функция потерь ℓ . Истинный риск $R(f) = \mathbb{E}[\ell(f(\mathbf{X}), \mathbf{Y})]$ противопоставляется эмпирическому риску $\hat{R}_m(f)$ по выборке; обучение рассматривается как минимизация эмпирического риска. Центральным объектом классической теории является отклонение $|R(f) - \hat{R}_m(f)|$ и его равномерная оценка по классу $\mathfrak{F}$.

В **разделе 1.2** кратко обсуждаются классические меры емкости класса: VC-размерность, PAC-обучаемость и комбинаторные оценки К.В. Воронцова. Для перепараметризованных нейросетей эти подходы дают слишком консервативные оценки наихудшего случая и не учитывают архитектуру, регуляризацию и локальный режим оптимизации. В дальнейшем используется радемахеровская

сложность, поскольку она применяется при сопоставлении с ландшафтной мерой и в анализе многозадачного обучения.

Определение 1 (Эмпирическая радемахеровская сложность). Пусть $\mathcal{F}$ — класс вещественных функций на $\mathcal{X}$, $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathcal{X}$ — конечная выборка, и $\sigma_1, \dots, \sigma_m$ — независимые случайные переменные Радемахера, то есть $\mathbb{P}\{\sigma_i = +1\} = \mathbb{P}\{\sigma_i = -1\} = 1/2$ для всех $i = 1, \dots, m$. Эмпирическая радемахеровская сложность класса $\mathcal{F}$ на выборке D определяется как

$$\hat{\mathfrak{R}}_D(\mathcal{F}) = \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(\mathbf{x}_i) \right],$$

где математическое ожидание берется по распределению случайных переменных Радемахера.

Определение 2 (Ожидаемая радемахеровская сложность). Ожидаемая радемахеровская сложность класса $\mathcal{F}$ для выборок размера m определяется как

$$\mathfrak{R}_m(\mathcal{F}) = \mathbb{E}_{D \sim \mathbb{P}^m} [\hat{\mathfrak{R}}_D(\mathcal{F})],$$

где математическое ожидание берется по распределению выборок D размера m , порожденных распределением $\mathbb{P}$ на $\mathcal{X}$.

Радемахеровская сложность задает равномерную емкость класса на конкретной выборке и входит в стандартные границы обобщения вида $R(f) \leq \hat{R}_m(f) + 2\hat{\mathfrak{R}}_D(\mathcal{F}) + O(\sqrt{\log(1/\delta)/m})$. Вместе с тем она не различает две модели одной архитектуры, оказавшиеся в разных областях параметрического пространства, и поэтому недостаточна как единственная мера сложности глубокой сети.

В разделе 1.3 рассматриваются выразительная способность глубоких сетей и анализ ландшафта функции потерь через матрицы Гессе. Показано, что качество модели зависит не только от числа параметров, но и от области параметрического пространства, в которую приводит оптимизация. Спектр матрицы Гессе обычно имеет большинство собственных значений около нуля и лишь несколько доминирующих направлений кривизны; это указывает на необходимость локального описания сложности, а не только глобальной емкости класса. Отсюда переход от емкости класса к разбросу локальных вторых производных функции потерь.

В разделе 1.4 обсуждаются эмпирические законы масштабирования языковых моделей и методы снижения сложности: прореживание, квантизация, дистилляция и низкоранговые адаптеры. Соотношения между числом параметров, объемом данных и качеством полезны на практике, но не дают теоретического критерия согласованности архитектуры и выборки. Методы сжатия и адаптации обычно тоже не опираются на строгие оценки такой согласованности, поэтому их предсказуемость ограничена.




Рис. 1: Идея анализа сходимости ландшафта: разность $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ при добавлении объекта уменьшается с ростом объёма выборки k ; на этой идее строится ландшафтная мера сложности модели.

В **разделе 1.5** фиксируются пробелы, на которые отвечает диссертация: нет вычислимой меры сложности, учитывающей архитектуру и локальный оптимум; классические оценки слабо связаны с ростом выборки; теоретические оценки спектральных норм матриц Гессе для полносвязных, сверточных и трансформерных моделей недостаточны. Предлагаемый аппарат связывает меры μ_D , μ_f и ландшафтную меру $\mu_f(f|D)$ с оценками матриц Гессе и методами снижения сложности.

Таким образом, первая глава задает контекст теории обучаемости и обосновывает переход к локальной геометрии функции потерь в последующих главах.

Во **второй главе** разрабатывается теоретический формализм, в котором общие меры сложности модели и данных вводятся как исходная формализация задачи, а основной вычислимый объект задается ландшафтной мерой параметрической модели.

В **разделе 2.1** вводятся формальные определения мер сложности в рамках теории мер. Множество конечных выборок рассматривается как алгебра подмножеств генеральной совокупности, что позволяет применять стандартные свойства конечных мер. Для меры сложности выборки требуется субаддитивность:

$$\mu_D(D_1 \cup D_2) \leq \mu_D(D_1) + \mu_D(D_2).$$

Это свойство отражает естественное требование: объединение двух наборов данных не должно иметь сложность больше суммы их сложностей. При непересекающихся выборках равенство соответствует аддитивному случаю, когда объекты не дублируют информацию друг о друге. Монотонность меры сложности конечных выборок используется как следствие субаддитивности и не требует дополнительных предположений в рассматриваемой конечной постановке.

Определение 3 (Генеральная совокупность данных). *Генеральной совокупностью данных Γ назовем произвольное множество объектов, которые исследуются в рамках той или иной задачи. В общем случае нет никаких ограничений*

на счетность множества генеральной совокупности.

Определение 4 (Однородная и многогородная генеральная совокупность). Генеральную совокупность Γ назовем однородной, если все объекты генеральной совокупности порождаются из одного распределения. В противном случае генеральную совокупность назовем k -родной, где k является числом распределений, на основе которых была сгенерирована генеральная совокупность.

Пусть задана генеральная совокупность данных Γ . Множество всех подмножеств объектов, образующих кольцо выборок, обозначим как:

$$\mathfrak{D} = \{D_\Gamma^i\}, \quad D_\Gamma^i \subset \Gamma.$$

Определение 5 (Мера сложности выборки). Мерой сложности выборки назовем отображение μ_D , такое, что:

$$\mu_D(D_i) : \mathfrak{D}_\Gamma \rightarrow \mathbb{R}_+,$$

удовлетворяющее свойству:

$$\mu_D(D_i \cup D_j) \leq \mu_D(D_i) + \mu_D(D_j),$$

где равенство достигается при условии $D_i \cap D_j = \emptyset$.

Лемма 1 (Монотонность меры сложности выборки). Мера μ_D монотонна: если $D_1 \subseteq D_2$, то

$$\mu_D(D_1) \leq \mu_D(D_2).$$

Пусть задано множество параметрических моделей $\mathfrak{F} = \{f_i\}$.

Определение 6 (Мера сложности модели). Мера сложности модели f — отображение

$$\mu_f(f_i) : \mathfrak{F} \rightarrow \mathbb{R}_+.$$

В отличие от классических мер емкости класса функций, $\mu_f(f)$ относится к конкретной модели (или к конкретному элементу параметрического семейства). Для глубоких сетей это существенно: две модели одной архитектуры могут оказаться в разных областях параметрического пространства и иметь разную локальную геометрию функции потерь. Поэтому μ_f далее конкретизируется через матрицы Гессе в окрестности опорной точки.

Определение 7 (Обучаемость модели на выборке). Модель $f \in \mathfrak{F}$ назовём обучаемой на выборке $D \in \mathfrak{D}$, если

$$\mu_f(f) \leq \mu_D(D).$$

Это абстрактный критерий согласованности числовых характеристик сложности модели и выборки. Сам по себе он не задаёт качество аппроксимации; на его основе вводятся вычислимые частные меры.

Предложение 2 (Сохранение критерия согласованности при расширении выборки). Пусть μ_D монотонна по включению: из $D \subseteq D''$ следует $\mu_D(D) \leq \mu_D(D'')$. Если $\mu_f(f) \leq \mu_D(D)$, то для любой выборки D' верно $\mu_f(f) \leq \mu_D(D \cup D')$.

Субаддитивность $\mu_D(D \cup D') \leq \mu_D(D) + \mu_D(D')$ даёт верхнюю оценку сложности объединения и используется в дальнейших рассуждениях главы.

В разделе 2.2 сложность данных ставится в зависимость от модели. Условная сложность выборки D относительно f :

Определение 8 (Условная сложность выборки).

$$\mu_D(D|f) = \inf\{\mu_D(D') : D' \subseteq D, \mu_f(f) \leq \mu_D(D')\}, \quad \inf \emptyset = +\infty.$$

То есть это минимальная сложность подвыборки $D' \subseteq D$, при которой ещё выполнен критерий обучаемости $\mu_f(f) \leq \mu_D(D')$. Отсюда: одна и та же D может быть простой для одной модели и сложной для другой; $\mu_D(D)$ и вычисляемая ландшафтная мера $\mu_f(f|D)$ — разные объекты.

Определение 9 (Простая генеральная совокупность). Однородная генеральная совокупность Γ_C проста, если каждому объекту приписана одна и та же сложность C .

Следствие 3. Для $D \subset \Gamma_C$

$$\mu_D(D) = C \cdot |D|.$$

В этом случае

$$\mu_D(D|f) = C \cdot m^*(f), \quad m^*(f) = \min\{|D'| : D' \subseteq D, \mu_f(f) \leq C|D'|\},$$

и достаточный размер выборки m^* — частный случай условной сложности данных (далее гл. 4).

Определение 10 (Достаточный размер выборки). Размер m^* достаточен по критерию T , если T выполняется для всех $k \geq m^*$.

В разделе 2.3 разрабатывается ландшафтная мера сложности модели, основанная на анализе сходимости функции потерь при увеличении объема выборки. Рассматривается параметрическая модель f_{θ} и эмпирический риск $\mathcal{L}_k(\theta)$. При добавлении нового объекта изменение функции потерь имеет вид

$$\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta) = \frac{1}{k+1} (\ell(f_{\theta}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \mathcal{L}_k(\theta)).$$

В предположении о сохранении локального минимума и с использованием квадратичного приближения Тейлора получена оценка

$$|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)| \leq \frac{M_{\ell}}{k+1} + \frac{\|\theta - \theta^*\|_2^2}{2(k+1)} \left\| \mathbf{H}_{k+1}(\theta^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\theta^*) \right\|_2,$$

где $\mathbf{H}_i(\boldsymbol{\theta})$ — матрица Гессе для i -го объекта.

Оценка изменения ландшафта задаёт свойство модели f на выборке D — условную сложность

$$\mu_f(f|D) : \mathfrak{F} \rightarrow \mathbb{R}_+.$$

В частности, рассматривается

$$\mu_f(f|D) = \mathbb{E}_{\mathbf{x}_i \in D} \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_{\mathbf{x}_i \in D} \mathbf{H}_i(\boldsymbol{\theta}^*)\|_2.$$

Определение 11 (Условная сложность параметрической модели). *Условная сложность модели f относительно выборки D — отображение $\mu_f(f|D) : \mathfrak{F} \rightarrow \mathbb{R}_+$.*

Определение 12 (Ландшафтная мера сложности). *Ландшафтная мера сложности параметрической функции f — условная сложность*

$$\mu_f(f|D) = \mathbb{E}_{\mathbf{x}_i \in D} \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_{\mathbf{x}_i \in D} \mathbf{H}_i(\boldsymbol{\theta}^*)\|_2. \quad (1)$$

Из основной оценки следует

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{M_\ell}{k+1} + \frac{\mu_f(f|D)}{k+1} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2.$$

Для простой генеральной совокупности ($\mu_D(D') = C|D'|$) оценка ландшафтного приращения связывает размер подвыборки с допустимым изменением эмпирического риска. Если в R -окрестности опорной точки требуется

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \varepsilon,$$

то достаточно

$$k+1 \geq \frac{M_\ell + \mu_f(f|D)R^2}{\varepsilon}.$$

Так общая постановка меры сложности данных связывается с ландшафтным анализом модели, без претензии на универсальное описание сложности данных. В итоге достаточный объём выборки определяется через допустимое изменение эмпирического риска около опорной точки. При большой ландшафтной мере добавление объектов сильнее меняет локальную геометрию, и для стабилизации нужно больше данных; при малом разбросе пообъектных матриц Гессе эмпирический риск при росте выборки меняется устойчивее.

Далее на основе результатов о спектральных нормах матриц Гессе получены оценки ландшафтной меры для конкретных архитектур.

В подразделе 2.3.1 для полносвязных сетей доказана теорема.

Теорема 4 (Сходимость ландшафта функции потерь для полносвязных сетей). *Пусть параметры $\boldsymbol{\theta}$ удовлетворяют $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \leq R^2$ для некоторого*

$R > 0$. Если существует $M_\ell \geq 0$ такая, что $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_\ell$ для всех $i = 1, \dots, t$, то при условиях соответствующей теоремы основного текста

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{1}{k+1} \left(2M_\ell + \left(L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1} \right) R^2 \right),$$

и при $k \rightarrow \infty$

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \rightarrow 0.$$

В итоге

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \propto \frac{L(hM)^{2L}R^2}{k}.$$

Оценка показывает, что глубина входит в сложность сильнее ширины: рост числа слоёв даёт экспоненциальный вклад в верхнюю границу, а ширина — полиномиальный через размер скрытого слоя. Это согласуется с известными оценками выразительности глубоких сетей, но описывает не аппроксимацию, а локальную чувствительность функции потерь к изменению выборки.

Следствие 5 (Асимптотика ландшафтной меры для полносвязных сетей). *Ландшафтная мера сложности параметрической функции f полносвязной нейросетевой модели глубокого обучения имеет асимптотику:*

$$\mu_f(f|D) \propto L(hM)^{2L},$$

где M — некоторая константа, ограничивающая параметры и данные.

В регрессионной постановке с квадратичной функцией потерь и FC ReLU-сетями получена более точная локальная оценка. Пообъектная квадратичная функция потерь имеет вид

$$\ell_i(\boldsymbol{\theta}) = \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{2}(f_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2, \quad \mathbf{y}_i = y_i \in \mathbb{R}. \quad (2)$$

Следующая лемма задает константу $M_{\mathbf{H}}$ для полносвязных ReLU-сетей без смещений при спектральных ограничениях на веса и входы.

Лемма 6 (Спектральная норма пообъектной матрицы Гессе для квадратичной потери и FC-сетей). *Рассмотрим полносвязную ReLU-сеть без смещений, для которой $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$, $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ для всех p и i . Тогда существует константа $M_{\mathbf{H}}$ такая, что для каждого i и каждой точки параметрического пространства, где требуемые производные существуют,*

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq M_{\mathbf{H}} := L M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L} + \sum_{s=1}^L M_{\mathbf{W}}^{2s}.$$

Если $|w_{ij}^{(p)}| \leq M$ на блоках размера $h \times h$, то $M_{\mathbf{W}} \leq hM$ и асимптотически $\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 = O(L(hM)^{2L})$.

Теорема 7 (Локальная оценка ландшафтного приращения для квадратичной потери и FC-сетей). Пусть $\boldsymbol{\theta}$ удовлетворяет $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2 \leq R$. Предположим, что $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_\ell$ для всех i , лемма 6 применима в точке $\boldsymbol{\theta}^*$, а в опорной точке выполнено условие приближенной стационарности: существует $\varepsilon_g \geq 0$ такое, что

$$\|\nabla \mathcal{L}_k(\boldsymbol{\theta}^*)\|_2 \leq \varepsilon_g, \quad \|\nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*)\|_2 \leq \varepsilon_g.$$

Тогда при условии локальной прокси-оценки приращения эмпирического риска

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2}{k+1} (M_\ell + M_{\mathbf{H}} R^2) + 2\varepsilon_g R.$$

Это оценка худшего случая, полученная из равномерного контроля матрицы Гессе в локальной прокси-постановке. С учетом асимптотики $M_{\mathbf{H}}$ вклад кривизны имеет порядок

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| = O\left(\frac{L(hM)^{2L} R^2}{k}\right)$$

как в лемме 2 работы [6].

Далее фиксируется уточнение, учитывающее величину остатков. Если, кроме того,

$$|f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y, \quad i = 1, \dots, m,$$

и каждый наблюдаемый вход остается в фиксированной области активации в окрестности $\boldsymbol{\theta}^*$, зададим

$$\mathbf{g}_i := \nabla_{\boldsymbol{\theta}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \quad M_{\nabla^2 f} := \max_{1 \leq i \leq m} \|\nabla_{\boldsymbol{\theta}}^2 f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)\|_2.$$

Тогда

$$\|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbf{g}_i \mathbf{g}_i^\top\|_2 \leq \varepsilon_y M_{\nabla^2 f} \quad (3)$$

для каждого i , и

$$\mu_f(f \mid D) \leq 2 \max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 + 2\varepsilon_y M_{\nabla^2 f}. \quad (4)$$

следовательно,

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{\varepsilon_y^2 + 2R^2 (\max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 + \varepsilon_y M_{\nabla^2 f})}{k+1} + 2\varepsilon_g R.$$

Если дополнительно $\|\mathbf{W}^{(p)*}\|_2 \leq M_{\mathbf{W}}$ для каждого слоя и $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ для всех i , то

$$\max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 \leq L M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2},$$

откуда

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{\varepsilon_y^2 + 2R^2 (L M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2} + \varepsilon_y M_{\nabla^2 f})}{k+1} + 2\varepsilon_g R.$$

В этой окрестности функция f_{θ} дважды дифференцируема на наблюдаемых входах. Частный случай $\varepsilon_y = 0$ соответствует точной интерполяции и сводит (3) к тождеству Гаусса–Ньютона.

Теорема уточняет общую ландшафтную оценку: кроме члена $O(M_{\mathbf{H}}R^2/k)$ появляется вклад остатков и возможный стационарный член, связанный с неточным совпадением локальных минимумов на соседних объемах выборки. Для приложений это означает, что даже при квадратичной потере одной только асимптотики $L(hM)^{2L}$ недостаточно, если остатки модели в опорной точке не малы.

Следствие 8 (Линейная модель). Если $f_{\theta}(\mathbf{x}) = \mathbf{w}^{\top} \mathbf{x}$, где $\theta = \mathbf{w} \in \mathbb{R}^n$, и используется та же квадратичная функция потерь (2), то $\mathbf{H}_i(\theta) = \mathbf{x}_i \mathbf{x}_i^{\top}$ не зависит от $\mathbf{w}$ и y_i , поэтому $\|\mathbf{H}_i\|_2 = \|\mathbf{x}_i\|_2^2$. При $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ можно положить $M_{\mathbf{H}} = M_{\mathbf{x}}^2$ в лемме 6 и следствии 10, заменив оценку для ReLU-сети этой ранговой матрицей Гессе. Ландшафтная мера сложности (1) в этом случае определяется разбросом ранговых матриц $\mathbf{x}_i \mathbf{x}_i^{\top}$ вокруг их выборочного среднего.

Следствие 9 (Один скрытый слой, FC ReLU). Рассмотрим один скрытый слой ширины h : $\mathbb{R}^n \rightarrow \mathbb{R}^h \rightarrow \mathbb{R}$ с ReLU и матрицами весов без смещений, удовлетворяющими тем же спектральным ограничениям, что и в лемме 6. В обозначениях следствия 10 это случай $L = 2$, поэтому (5) дает верхнюю оценку $\mu_f(f \mid D) = O((hM)^4)$, в отличие от более глубоких сетей, где множитель $(hM)^{2L}$ быстрее растет по L . Отдельно, если в опорной точке θ^* пообъектные остатки равномерно малы, $|f_{\theta^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y$ для всех i , то учитывая остатки часть теоремы 7 и точное тождество (3) дают оценку (4) для $\mu_f(f \mid D)$; при покоординатных ограничениях это уточняет оценку худшего случая $O(h^4)$.

Лемма 6 также задает порядок ландшафтной меры сложности (1) через глубину, ширину и нормовые ограничения.

Следствие 10 (Масштабирование ландшафтной меры сложности). При условиях леммы 6, покоординатных ограничениях $|w_{ij}^{(p)}| \leq M$ на соответствующих блоках весов размера $h \times h$ и фиксированном ограничении $M_{\mathbf{x}}$ на входы мера (1) удовлетворяет оценке

$$\mu_f(f \mid D) = O(L(hM)^{2L}), \quad (5)$$

где h обозначает ширину скрытого слоя, L — глубину, а M — покоординатное ограничение на веса; ограничение $M_{\mathbf{x}}$ включено в неявную константу.

В подразделе 2.3.2 для сверточных сетей получены следующие результаты.

Теорема 11 (Сходимость ландшафта для 1D-сверточных сетей). Пусть параметры θ находятся в R -окрестности оптимума:

$$\|\theta - \theta^*\| \leq R,$$

а функция потерь ограничена некоторой константой:

$$\exists M_\ell > 0 : \forall i |\ell_i| \leq M_\ell.$$

Пусть все объекты в наборе данных ограничены:

$$\exists M_{\mathbf{x}} > 0 \forall i \|\mathbf{x}_i\| \leq M_{\mathbf{x}}.$$

Тогда в условиях соответствующей теоремы основного текста:

$$\begin{aligned} |\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| &\leq \frac{2}{k+1} M_\ell + \\ &+ \frac{2}{k+1} R^2 \sqrt{2} d^2 M_{\mathbf{x}}^2 (L+1) (C^2 w^2 k d)^L, \end{aligned}$$

где $M_{\mathbf{x}}$ — константа, ограничивающая нормы объектов данных.

Теорема 12 (Сходимость ландшафта для 2D-сверточных сетей). Пусть параметры $\boldsymbol{\theta}$ находятся в R -окрестности оптимума:

$$\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\| \leq R.$$

Также функция потерь ограничена некоторой константой:

$$\exists M_\ell > 0 : \forall i |\ell_i| \leq M_\ell.$$

Пусть все объекты в наборе данных также ограничены:

$$\exists M_{\mathbf{x}} > 0 \forall i \|\mathbf{x}_i\| \leq M_{\mathbf{x}}.$$

Тогда при выполнении условий соответствующей теоремы основного текста справедливо:

$$\begin{aligned} |\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| &\leq \frac{2}{k+1} M_\ell + \\ &+ \frac{2}{k+1} R^2 \sqrt{2} q^2 M_{\mathbf{x}}^2 (L+1) (C^2 k^2 w^2 m n)^L, \end{aligned}$$

где $q^2 = C^2 k^2 m n$, а $M_{\mathbf{x}}$ — константа, ограничивающая нормы объектов данных.

Следствие 13 (Асимптотика ландшафтной меры для 1D-сверточных сетей). Ландшафтная мера сложности параметрической функции f 1D-сверточной модели глубокого обучения имеет асимптотику:

$$\mu_f(f|D) \propto L(C^2 M^2 k d)^L,$$

где C — максимальное число каналов, d — длина входной последовательности, k — размер свертки, M — некоторая константа, ограничивающая параметры и данные.

Следствие 14 (Асимптотика ландшафтной меры для 2D-сверточных сетей). Ландшафтная мера сложности параметрической функции f 2D-сверточной модели глубокого обучения имеет асимптотику:

$$\mu_f(f|D) \propto C^2 k^2 L (C^2 k^2 M^2 m n)^L,$$

где C — максимальное число каналов, m, n — размеры входного изображения, k — размер свертки, M — некоторая константа, ограничивающая параметры и данные.

Оценки для сверточных сетей показывают, что число каналов, размер ядра и пространственный размер входа входят в верхние границы мультипликативно. Это позволяет сравнивать архитектурные решения не только по числу параметров, но и по их влиянию на локальную кривизну функции потерь.

Следствие 15 (Снижение ландшафтной меры при пулинге). Пусть выполнены условия теоремы о сходимости ландшафта для 2D-сверточных сетей, а сеть дополнительно содержит слой *MaxPool2D* или *AvgPool2D* с ядром $k_{\text{pool}} \times k_{\text{pool}}$ в позиции l . Тогда верхняя оценка ландшафтной меры приобретает множитель $(1/k_{\text{pool}}^2)^{L-l+2}$:

$$\mu_f(f|D) \propto C^2 k^2 L \left(\frac{1}{k_{\text{pool}}^2} \right)^{L-l+2} (C^2 k^2 M^2 m n)^L.$$

В частности, более ранний пулинг (меньшая l) сильнее снижает верхнюю оценку сложности.

Пулинг частично компенсирует рост ландшафтной сложности с глубиной и служит теоретически обоснованным фактором стабилизации.

В подразделе 2.3.3 для трансформеров. Выход одной головы самовнимания:

$$\text{Attn}(\mathbf{X}) = \text{softmax}\left(\frac{\mathbf{X}\mathbf{W}_Q(\mathbf{X}\mathbf{W}_K)^\top}{\sqrt{d_K}}\right)\mathbf{X}\mathbf{W}_V.$$

Блок трансформера: самовнимание, послойная нормализация и FFN; локальная кривизна задаётся блоками $\{\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V\}$ и полносвязной частью.

Теорема 16 (Сходимость ландшафта для трансформеров). При $0 \leq \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \leq L$ и ограниченных нормах матриц Гессе

$$|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \leq \frac{2L}{k+1} + \frac{M\|\mathbf{w} - \mathbf{w}^*\|_2^2}{k+1},$$

где $M = \|\mathbf{H}\|_2$ для слоя самовнимания либо $M = M_{\text{tr}}$ для полного блока.

Разложение источников:

$$\underbrace{\frac{2L}{k+1}}_{\text{ограниченность потерь}} + \underbrace{\frac{M\|\mathbf{w} - \mathbf{w}^*\|_2^2}{k+1}}_{\text{кривизна } (\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V, \text{FFN})}.$$

Константа M неоднородна по блокам, поэтому $\|\mathbf{H}\|_2$ для Q/K/V и FFN оценивается отдельно в гл. 3; сложность трансформера не сводится к числу параметров или слоёв.

В разделе 2.4 на MNIST, FashionMNIST и CIFAR-10/100 проверены теоретические оценки: увеличение глубины замедляет сходимость ландшафта, увеличение ширины — ускоряет; для сверток исследованы гиперпараметры; для трансформеров показана стабилизация ландшафта при росте объёма данных. Для полносвязных сетей варьировались число слоёв и число нейронов в скрытых слоях. С ростом глубины разность $|\mathcal{L}_{k+1} - \mathcal{L}_k|$ убывает медленнее, что согласуется с экспоненциальной зависимостью верхней оценки от L . При фиксированной глубине увеличение ширины может ускорять эмпирическую стабилизацию: модель получает большую аппроксимационную способность без столь резкого роста глубинного множителя.




Рис. 2: Зависимость $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для полносвязной сети на MNIST: слева — при фиксированной глубине $L = 5$ и вариации ширины h ; справа — при фиксированной ширине $h = 16$ и вариации глубины L .

Для сверточных сетей анализировались число каналов, размер ядра, глубина и положение пулинга. Зависимости подтверждают: структурные элементы влияют на локальную меру сложности не только через число параметров, но и через распространение сигнала по слоям. Отдельно рассмотрена регрессия для линейной и двухслойной ReLU-архитектур и сопоставление ландшафтной меры с эмпирической радемахеровской сложностью. Радемахеровская сложность описывает равномерную ёмкость класса функций, а ландшафтная мера — разброс пообъектных матриц Гессе в выбранной точке параметров; величины не заменяют друг друга, а описывают разные стороны сложности.

В линейной регрессии матрица Гессе имеет простую структуру, поэтому зависимость ландшафтной меры от размерности признаков явно сопоставима с оценками радемахеровской сложности. Для двухслойной ReLU-сети зависимость сложнее из-за кусочно-линейных активаций и смены активных областей. Численно рост ширины и размера выборки по-разному влияет на две меры,

Таблица 1: Теоретические верхние порядки ландшафтной меры μ_f и эмпирической радемахеровской сложности для линейной модели и двухслойной FC ReLU-сети при квадратичной функции потерь.

	Линейная модель	Двухслойная FC ReLU
$\mu_f(f D)$	$O(n)$	$O((hM)^4)$ в худшем случае
$\hat{\mathfrak{R}}_m$	$O(W\sqrt{n/m})$	$O(\text{poly}(h)/\sqrt{m})$

поэтому ландшафтную меру нужно рассматривать как отдельный инструмент.

Для моделей семейства GPT-2 на корпусе WikiText-103 проанализирована динамика выборочной ландшафтной меры. Сравнивались траектории функции потерь, валидационного качества и ландшафтной меры при разных настройках обучения. Динамика ландшафтной меры несёт информацию о геометрическом режиме обучения, не сводимую к одной только функции потерь: фаза уменьшения ошибки и фаза стабилизации геометрии могут не совпадать. Дополнительно изучалась зависимость меры от времени обучения, валидационной ошибки и архитектуры. У части моделей динамика немонотонна: убывание потерь сопровождается ростом или стабилизацией ландшафтной меры. Локальная кривизна отражает не только качество аппроксимации, но и характер найденной области параметров.

Итог главы: общие меры μ_D и μ_f задают исходную формализацию, а основной вычислимый объект — ландшафтная мера параметрической модели. Получены явные асимптотические оценки для основных архитектур и численное сопоставление с эмпирической радемахеровской сложностью; это основа для оценок матриц Гессе и методов анализа достаточного объёма выборки. В частности, условие $k + 1 \geq (M_\ell + \mu_f(f|D)R^2)/\varepsilon$ показывает: при фиксированной точности ε требуемый объём данных растёт вместе с ландшафтной мерой — более «кривая» локальная геометрия требует большей выборки для той же стабилизации эмпирического риска. Так вторая глава формализует связь сложности модели с достаточным объёмом данных, а глава 4 даёт наблюдаемые критерии оценки этого объёма на практике без прямого вычисления матриц Гессе.

Ограничения постановки: детерминистический анализ, общее предположение об опорной точке минимума для последовательных размеров выборки и возможность улучшения верхних оценок за счёт разреженности активаций. Даже при этом ландшафтная мера даёт вычислимо интерпретируемую связь архитектуры, локальной геометрии функции потерь и изменения эмпирического риска при росте выборки.

В **третьей главе** исследуются матрицы Гессе функции потерь для основных семейств нейросетевых архитектур. Цель — сделать ландшафтную меру второй главы вычислимо оцениваемой: $\mu_f(f|D)$ определяется через разброс по-объектных матриц Гессе, а полное построение матрицы вторых производных для современных сетей непрактично. Основные результаты — факторизован-

ные представления и верхние оценки спектральной нормы в зависимости от глубины, ширины, каналов, размеров ядер и блоков самовнимания.

Теорема 17 (Факторизация матрицы Гессе). *Пусть функция нейронной сети $f_{\theta}(\mathbf{x})$ представима в матричной форме через последовательность линейных операторов, нелинейных масок и параметрических преобразований. Тогда матрица Гессе функции потерь по параметрам допускает факторизацию*

$$\mathbf{H}_O(\theta) = \mathbf{Q}^\top \mathbf{F}^\top \mathbf{A} \mathbf{F} \mathbf{Q},$$

где $\mathbf{H}_O$ — G -компонента матрицы Гессе, $\mathbf{A}$ — вторые производные функции потерь по выходу, $\mathbf{F}$ — распространение возмущений через архитектуру, $\mathbf{Q}$ — параметризация слоёв.

Факторизация разделяет три вклада: параметризацию слоёв ($\mathbf{Q}$), распространение сигнала ($\mathbf{F}$) и вторые производные по выходу ($\mathbf{A}$). Отсюда далее выводятся порядки $L(hM)^{2L}$ для полносвязных сетей и аналогичные оценки для сверток и трансформеров.

Для полносвязных сетей получена оценка спектральной нормы с асимптотикой $\|\mathbf{H}_i(\theta)\|_2 = O(L(hM)^{2L})$: экспоненциально по глубине и полиномиально по ширине. Для одномерных и двумерных сверток оценки выражены через число каналов, размеры ядер и пространственные размеры входа. Снижение ландшафтной сложности при MaxPool и AvgPool оформлено следствием: множитель $(1/k_{\text{pool}}^2)^{L-l+2}$ усиливается при более раннем пулинге. Это конструктивные следствия факторизации; детальные спектральные формулировки по слоям — в основном тексте диссертации.

Теорема 18 (Оценка нормы матрицы Гессе для слоя самовнимания). *Пусть $\|\cdot\|_2$ — спектральная норма. Тогда для слоя самовнимания*

$$\|\mathbf{H}_i(\mathbf{w}^*)\|_2 \leq M,$$

зде

$$\begin{aligned}
M = 3 \cdot \max & \left(\frac{2L}{d_V} \|\mathbf{X}\|_2^2, \right. \\
& \frac{8}{L^3 d_V d_K} \|\mathbf{W}_K\|_2^2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\
& + \frac{12}{d_V d_K} \sqrt{\min(L, d_V)} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^5, \\
& \frac{4}{L d_V \sqrt{d_K}} \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^4 + \\
& + \frac{4 \sqrt{\min(L, d_V)}}{L^2 \sqrt{d_K}} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^3, \\
& \frac{8}{L^3 d_V d_K} \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\
& + \frac{4 \sqrt{\min(L, d_V)} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2)}{L d_V \sqrt{d_K}} \|\mathbf{W}_V\|_2 \cdot \\
& \cdot \left(3L \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{X}\|_2^5 + \frac{d_V}{L} \|\mathbf{X}\|_2^3 \right) \Big).
\end{aligned}$$

Константа M полиномиально зависит от норм входа и матриц $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ и входит в оценку сходимости ландшафта трансформера как коэффициент при $\|\mathbf{w} - \mathbf{w}^*\|_2^2 / (k + 1)$. Слагаемое $\frac{2L}{d_V} \|\mathbf{X}\|_2^2$ выделяет вклад проекции значений; остальные члены — взаимодействие запросов и ключей через softmax-внимание. Разные группы параметров трансформера по-разному влияют на локальную стабилизацию ландшафта, что согласуется с экспериментальной неоднородностью блоков запросов, ключей и значений.

Факторизация отделяет три источника сложности: параметризацию, прямое распространение сигнала и вторые производные функции потерь по выходам. Так можно единообразно получать оценки для разных архитектур, не пересчитывая все вторые производные покомпонентно. Матрица Гессе выступает не только объектом численного анализа, но и инструментом вывода асимптотик по глубине, ширине и структурным параметрам.

Для полносвязных сетей оценка спектральной нормы уточняет результат второй главы: рост сложности связан с произведением норм весовых матриц по слоям и накоплением вкладов второго порядка при обратном распространении. При ограничении норм параметров константой M и ширине слоя h основной порядок $L(hM)^{2L}$: глубина сильнее меняет локальную геометрию, чем умеренный рост ширины.

Для сверток отдельно рассмотрены одномерный и двумерный случаи. В одномерном оценка зависит от числа каналов C , размера ядра k , длины входа d и глубины L ; в двумерном — ещё от размеров изображения m и n . Пулинг влияет

на ландшафтную меру через множитель $(1/k_{\text{pool}}^2)^{L-l+2}$, что объясняет стабилизирующую роль раннего пулинга и согласуется с экспериментами второй главы.

Для трансформеров дополнительно получены блочные оценки нормы полной матрицы Гессе блока и вспомогательные соотношения для послойной нормализации. Вклады блоков самовнимания в кривизну неодинаковы: в эксперименте на небольшой модели на MNIST наибольшие спектральные нормы у блоков Key и Value. Для регуляризации и оптимизации это аргумент в пользу отдельного анализа групп параметров.




Рис. 3: Спектральные нормы блоков параметров трансформера (слева) и соответствующих блоков матрицы Гессе (справа) на батче MNIST. Наибольшие значения норм соответствуют блокам Key и Value.

В главе также обсуждается трудность полного вычисления матриц Гессе: даже для умеренных архитектур размер матрицы квадратичен по числу параметров, и прямое вычисление непрактично. Факторизованные выражения и спектральные оценки позволяют вместо полной матрицы анализировать её норму и структурные верхние границы. Это нужно дальше: ландшафтная мера второй главы требует оценки разброса пообъектных матриц Гессе, а третья глава даёт аппарат таких оценок по архитектуре.

Вычислительные эксперименты проверяют оценки эмпирически. Для полносвязных сетей согласованность порядка $L(hM)^{2L}$ с ростом спектральных характеристик при увеличении глубины и ширины; для сверток — варьирование каналов, ядра и положения пулинга подтверждает редуцирующее влияние раннего пулинга. Для трансформера эксперимент ограничен небольшой архитектурой и не исчерпывает большие языковые модели, но показывает неоднородность блоков: наибольший вклад в локальную кривизну дают Key и Value. Теория предсказывает разный вклад блоков, эксперимент подтверждает его наблюдаемость.

В **четвертой главе** достаточный размер m^* оценивается по наблюдаемой стабильности обучения (без явного спектра $\mathbf{H}$). Связь с гл. 2: при $\mu_D(D) = C|D|$

и требовании $|\mathcal{L}_{k+1} - \mathcal{L}_k| \leq \varepsilon$ в R -окрестности опорной точки

$$k + 1 \geq \frac{M_\ell + \mu_f(f|D)R^2}{\varepsilon}.$$

Ниже m^* ищется через стабильность правдоподобия и близость апостериоров p_k, p_{k+1} на соседних подвыборках.

Семейство по функции правдоподобия. Пусть $\mathfrak{D}_m$ уже не меньше искомого m^* , $\hat{\mathbf{w}}_k$ — оценка на подвыборке размера k , $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$ — правдоподобие на полной выборке. На практике $\mathbb{E}$ и $\mathbb{D}$ — по B бутстрэп-подвыборкам размера k .

Определение 13 (D- / M-достаточность). При $\varepsilon > 0$ размер m^* называется D-достаточным, если для всех $k \geq m^*$

$$D(k) = \mathbb{D}_{\hat{\mathbf{w}}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon,$$

и M-достаточным, если для всех $k \geq m^*$

$$M(k) = |\mathbb{E}_{\hat{\mathbf{w}}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\hat{\mathbf{w}}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)| \leq \varepsilon.$$

$D(k)$ — устойчивость значения правдоподобия; $M(k)$ ближе к стабилизации $|\mathcal{L}_{k+1} - \mathcal{L}_k|$.

Теорема 19 (Корректность M-достаточности). Если $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$ ($\mathbf{m}_k = \mathbb{E}\hat{\mathbf{w}}_k$, $\Sigma_k = \mathbb{D}\hat{\mathbf{w}}_k$), то в линейной регрессии для любого $\varepsilon > 0$ существует m^* с $M(k) \leq \varepsilon$ при $k \geq m^*$.

Семейство по апостериорным распределениям. Подвыборки близки, если $|\mathcal{I}_1 \Delta \mathcal{I}_2| = 1$. Пусть p_k — апостериор на размере k .

$$\text{s-score}(g_1, g_2) = \frac{\int g_1(\mathbf{w})g_2(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int g_1(\mathbf{w} - \mathbf{b})g_2(\mathbf{w}) d\mathbf{w}}.$$

Определение 14 (KL- / S-достаточность).

$$KL(k) = D_{\text{KL}}(p_k \| p_{k+1}) = \int p_k \log \frac{p_k}{p_{k+1}} d\mathbf{w} \leq \varepsilon,$$

$$S(k) = \text{s-score}(p_k, p_{k+1}) \geq 1 - \varepsilon.$$

Теорема 20 (Сходимость апостериоров в линейной регрессии). При $\|\mathbf{x}\|_2 \leq M$, $|y| \leq M$ и $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ для нормального априора

$$\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0, \quad \|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0.$$

Отсюда корректность KL - и S -критериев: KL требует сближения моментов (консервативнее), для $S \rightarrow 1$ достаточно $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$.

Эмпирически на синтетике и наборах Liver Disorders, Boston Housing, Diabetes, Forest Fires, Servo:

$$D(k), M(k), KL(k) \rightarrow 0, \quad S(k) \rightarrow 1 \quad (k \uparrow).$$




Рис. 4: Сходимость $KL(k) \rightarrow 0$ и $S(k) \rightarrow 1$ на синтетической регрессии.

Критерии не заменяют μ_f , а дают наблюдаемое m^* при недоступных гессиях; согласованы с $\mu_f(f) \leq \mu_D(D)$ при $\mu_D(D) = C|D|$. Это четвёртое положение на защиту.

В **пятой главе** — методы снижения сложности параметрических моделей. На защиту опираются прореживание по ковариации градиентов, многодоменная дистилляция и антидистилляция; байесовская дистилляция — теоретический инструмент согласования архитектур.

Прореживание по ковариации градиентов. Эмпирический риск $\mathcal{L}(\mathbf{w}, \mathcal{D}) = \frac{1}{m} \sum_i \ell(\mathbf{x}_i, y_i, \mathbf{w})$. На итерации оптимизации обновляется оценка ковариации градиентов:

$$\mathbf{C}_t = (1 - \kappa_t) \mathbf{C}_{t-1} + \kappa_t (\mathbf{g}_{1,t} - \mathbf{g}_{S,t}) (\mathbf{g}_{1,t} - \mathbf{g}_{S,t})^\top, \quad \kappa_t = \frac{1}{t},$$

где $\mathbf{g}_{S,t}$ — градиент на подвыборке размера S , $\mathbf{g}_{1,t}$ — на одном её элементе. По диагонали $\mathbf{C}_{t_0}$ строится порядок индексов $\mathcal{I}_{\mathbf{w}_{t_0}}$; фиксация наименее значимых параметров — маской $\alpha(\zeta)$:

$$\mathbf{w}_t = \mathbf{w}_{t-1} + \alpha(\zeta) \cdot \Delta \mathbf{w}(\mathbf{g}_{S,t}, \mathbf{w}_{t-1}, \dots).$$

Вариант Белсли: пусть $\mathbf{A}_{\text{ps}}$ — ковариация параметров в оптимуме,

$$\mathbf{A}_{\text{ps}} = \mathbf{U} \mathbf{\Lambda} \mathbf{V}^\top, \quad \eta_j = \frac{\max_i \Lambda_{ii}}{\Lambda_{jj}}, \quad \xi = \arg \max_j \eta_j;$$

по дисперсионным долям q_j удаляются мультиколлинеарные направления. Эксперименты (Wine и др.): удаление до $\approx 80\%$ параметров без существенной потери качества; метод Белсли устойчивее к шуму.

Байесовская дистилляция. Априор ученика задаётся апостериором учителя $p(\mathbf{u}|\mathcal{D}) = \mathcal{N}(\mathbf{m}, \Sigma)$. Маргинальное правдоподобие

$$\mathcal{M}(\mathcal{D}, \mathbf{A}) = \int p(\mathcal{D}|\mathbf{w}) p(\mathbf{w}|\mathbf{A}) d\mathbf{w};$$




Рис. 5: Точность на Wine от доли удалённых параметров; оптимальное прореживание, вариационный метод и метод Белсли допускают удаление $\approx 80\%$.

вариационно: $\min D_{\text{KL}}(q\|p(\cdot|\mathcal{D}))$. Ниже — нормальность апостериора при удалении нейрона/слоя.

Теорема 21 (Распределение параметров при удалении нейрона). *Пусть выполняются условия:*

1. апостериорное распределение параметров модели учителя имеет вид

$$p(\mathbf{u}|\mathcal{D}) = \mathcal{N}(\mathbf{m}, \Sigma);$$

2. число слоев модели учителя равно числу слоев модели ученика: $T = L$;

3. размеры соответствующих слоев удовлетворяют условию $n_t^{(\text{tr})} \geq n_t^{(\text{st})}$.

Пусть преобразование $\phi(t, \mathbf{u})$ удаляет один нейрон из t -го слоя модели учителя, а $\mathbf{v} = \phi(t, \mathbf{u})$ — вектор оставшихся параметров. Тогда распределение параметров после такого преобразования также является нормальным:

$$p(\mathbf{v}|\mathcal{D}) = \mathcal{N}(\boldsymbol{\mu}_v, \Xi_{v,v}).$$

При этом параметры условного нормального распределения вычисляются как

$$\begin{aligned} \boldsymbol{\mu} &= \mathbf{m}_{\bar{\nu}_1} + \Sigma_{\bar{\nu}_1, \nu_1} \Sigma_{\nu_1, \nu_1}^{-1} (\mathbf{0} - \mathbf{m}_{\nu_1}), \\ \Xi &= \Sigma_{\bar{\nu}_1, \bar{\nu}_1} - \Sigma_{\bar{\nu}_1, \nu_1} \Sigma_{\nu_1, \nu_1}^{-1} \Sigma_{\nu_1, \bar{\nu}_1}, \end{aligned}$$

где ν_1 — зануляемые параметры, ν_2 — удаляемые параметры, $\bar{\nu}_1 = [\mathbf{v}^\top, \nu_2^\top]^\top$, а $\boldsymbol{\mu}_v$ и $\Xi_{v,v}$ являются соответствующими подвектором и подматрицей.

Распределение параметров при удалении слоя.

Теорема 22 (Распределение параметров при удалении слоя). *Пусть выполняются условия:*

1. апостериорное распределение параметров модели учителя имеет вид

$$p(\mathbf{u}|\mathcal{D}) = \mathcal{N}(\mathbf{m}, \Sigma);$$

2. размеры соседних слоев модели учителя совпадают, $n_t^{(\text{tr})} = n_{t-1}^{(\text{tr})}$, то есть матрица $\mathbf{U}_t$ является квадратной;
3. функция активации удовлетворяет свойству идемпотентности $\sigma \circ \sigma = \sigma$.

Пусть преобразование $\psi(t, \mathbf{u})$ удаляет t -й слой модели учителя, а $\mathbf{v} = \psi(t, \mathbf{u})$ — вектор оставшихся параметров. Тогда апостериорное распределение оставшихся параметров также является нормальным:

$$p(\mathbf{v}|\mathcal{D}) = \mathcal{N}(\mathbf{m}_v + \Sigma_{v,\bar{v}}\Sigma_{\bar{v},\bar{v}}^{-1}(\mathbf{i} - \mathbf{m}_{\bar{v}}), \Sigma_{v,v} - \Sigma_{v,\bar{v}}\Sigma_{\bar{v},\bar{v}}^{-1}\Sigma_{\bar{v},v}),$$

где $\bar{\mathbf{v}}$ — вектор параметров удаляемого слоя, а

$$\mathbf{i} = [\underbrace{1, 0, \dots, 0}_{n_t}, \underbrace{0, 1, \dots, 0}_{n_t}, \dots, \underbrace{0, \dots, 1}_{n_t}]^T.$$

Многодоменная дистилляция. Учитель $\mathbf{f} : \mathbb{X}_s \rightarrow \mathbb{Y}'$ на домене A , ученик $\mathbf{g} : \mathbb{X}_t \rightarrow \mathbb{Y}'$ на домене B ; связь $\varphi : \mathbb{X}_t \rightarrow \mathbb{X}_s$ инъективна (близкие генеральные совокупности).

$$\begin{aligned} \mathcal{L}(\mathbf{w}, \mathbf{X}, \mathbf{Y}, \mathbf{f}, \varphi) = & -\lambda \sum_{i,r} \mathbb{I}[y_i = r] \log g^r(\mathbf{x}_i, \mathbf{w}) \\ & - (1 - \lambda) \sum_{i,r} (f \circ \varphi)^r(\mathbf{x}_i) \log g^r(\mathbf{x}_i, \mathbf{w}), \end{aligned} \quad \hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \mathcal{L}.$$

На ImageNet вариант с φ лучше базового без дистилляции; на OPUS-100 (fr-en, de-en) снижается CE и растёт BLEU относительно ученика без учителя.

Антидистилляция. Простая модель $\mathbf{g}_{\text{tr}}(\cdot, \hat{\mathbf{u}})$ на $\mathcal{D}_1$ инициализирует более сложную $\mathbf{f}_{\text{st}}(\cdot, \mathbf{w})$:

$$\mathcal{L}(\mathbf{w}) = \lambda_1 \mathcal{L}_{\text{ce}}(\mathbf{w}, \mathcal{D}_1) + \lambda_2 \|\mathbf{u} - \text{Pr}[\mathbf{w}]\|_2^2 + \lambda_3 \sum_{(\mathbf{x}, y) \in \mathcal{D}_1} \mathbb{E}_{\mathbf{x}' \sim U_\delta(\mathbf{x})} \mathcal{L}_{\text{ce}}(\mathbf{w}, \mathbf{x}', y) + \lambda_4 \text{tr} \left(\frac{\partial^2 \mathcal{L}_{\text{ce}}}{\partial \mathbf{w}^2} \right),$$

где $\mathcal{L}_2$ — близость параметров, $\mathcal{L}_3$ — устойчивость к шуму входа, $\mathcal{L}_4$ — регуляризация кривизны ($\lambda_2 > 0$). На Fashion-MNIST: точность $0,86 \pm 0,05$, FGSM $0,57 \pm 0,03$, шум параметров $0,73 \pm 0,04$. Редукция пространства параметров при сохранении порядка качества аппроксимации — пятое положение; оно же продолжается LoRA/MTL в гл. 6.

В **шестой главе** — приложения аппарата. **LoRA и MTL.** Низкоранговое обновление

$$\Delta W = AB, \quad A \in \mathbb{R}^{d \times r}, \quad B \in \mathbb{R}^{r \times k}, \quad r \ll \min(d, k),$$

число обучаемых параметров $r(d + k)$ вместо dk . Ожидаемый и эмпирический риски при замороженном Φ_0 :

$$L(\Theta) = \mathbb{E}[-\log P_{\Phi_0+\Theta}(c \mid X)], \quad \mathcal{L}_n(\Theta) = -\frac{1}{n} \sum_{i=1}^n \log P_{\Phi_0+\Theta}(c_i \mid X_i).$$

Выход классификатора сохраняет вид

$$\hat{\mathbf{y}} = \text{softmax}((W + \Delta W)^\top \mathbf{x}).$$

Для MTL при справедливом масштабировании $\|w_{\text{shared}}\| \leq B_{\text{enc}}/\sqrt{T}$ верхняя оценка эмпирической радемахеровской сложности на задачу уменьшается не менее чем в $1/\sqrt{T}$ раз (см. теоремы ниже).

Теорема 23 (Состоятельность оценки). Пусть $\mathcal{D} = \{(X_i, c_i)\}_{i=1}^n$ — независимые одинаково распределенные пары из распределения P_{true} на $\mathcal{X} \times [N_c]$, где $[N_c] = \{1, \dots, N_c\}$. Рассмотрим компактное множество $K \subset \mathbb{R}^p$ и параметрическую модель $P_{\Phi_0+\Theta}(c \mid X)$ при $\Theta \in K$, где Φ_0 — замороженный вектор предобученных параметров. Предположим:

1. Существует единственная точка $\Theta^* \in K$, минимизирующая ожидаемый риск

$$L(\Theta) = \mathbb{E}_{(X,c) \sim P_{\text{true}}}[-\log P_{\Phi_0+\Theta}(c \mid X)], \quad \Theta \in K.$$

2. Функция $(X, c, \Theta) \mapsto -\log P_{\Phi_0+\Theta}(c \mid X)$ непрерывна на своей области допустимых значений и

$$\mathbb{E}_{(X,c) \sim P_{\text{true}}} \left[\sup_{\Theta \in K} |\log P_{\Phi_0+\Theta}(c \mid X)| \right] < \infty.$$

3. Эмпирический риск задается в виде

$$\mathcal{L}_n(\Theta) = -\frac{1}{n} \sum_{i=1}^n \log P_{\Phi_0+\Theta}(c_i \mid X_i),$$

а оценка $\hat{\Theta}_n$ выбирается как измеримый минимизатор $\mathcal{L}_n$ на K (если минимум достигается; иначе — ε_n -минимизатор с $\varepsilon_n \downarrow 0$).

Тогда $\hat{\Theta}_n \xrightarrow{P} \Theta^*$ при $n \rightarrow \infty$.

Теорема 24 (Корректность при низкоранговых обновлениях). Предположим следующее:

1. Выходной слой задается в виде

$$\hat{\mathbf{y}} = \text{softmax}(W_{\text{upd}}^\top \mathbf{x}),$$

где $\mathbf{x} \in \mathbb{R}^d$ — это вектор признаков BERT, $W \in \mathbb{R}^{d \times k}$ — замороженные предобученные веса, а

$$W_{\text{upd}} = W + \Delta W.$$

2. Вместо непосредственного обучения $\Delta W \in \mathbb{R}^{d \times k}$, обновление параметризуется в низкоранговой форме:

$$\Delta W = AB, \quad A \in \mathbb{R}^{d \times r}, B \in \mathbb{R}^{r \times k}, r \ll \min(d, k).$$

3. Выполнены условия соответствующей теоремы основного текста, т.е. модель остается статистически состоятельной при минимизации эмпирического риска.

Тогда при параметризации выход модели $\hat{y}$ сохраняется в том смысле, что низкоранговое обновление не искажает корректность классификационного слоя.

Следствие 25 (Низкоранговая адаптация с теоретическим обоснованием). Объединяя теорему о состоятельности оценки и теорему о корректности при низкоранговых обновлениях, получаем, что тонкая настройка на основе низкоранговой адаптации одновременно сохраняет статистическую состоятельность оценки и корректность выходного слоя, при этом требуя существенно меньшего числа обучаемых параметров.

Теорема 26 (Сложность Радемахера на задачу при MTL). Пусть $S_t = \{x_i\}_{i=1}^n$ — выборка фиксированной целевой задачи t с $\|x_i\|_2 \leq R$. Пусть $\phi(\cdot; w)$ — энкодер, и рассмотрим линейные головы $f_{w,h}(x) = h^\top \phi(x; w)$ с $\|h\|_2 \leq B_{\text{head}}$. Предположим:

1. Ограничение на признаки: для всех x, w $\|\phi(x; w)\|_2 \leq L \|w\|_2 \|x\|_2$.
2. Энкодер STL удовлетворяет $\|w_{\text{enc}}\| \leq B_{\text{enc}}$, общий энкодер MTL удовлетворяет $\|w_{\text{shared}}\| \leq B_{\text{shared}}$.
3. Многозадачное масштабирование: $B_{\text{shared}} \leq B_{\text{enc}}/\sqrt{T}$.

Обозначим через $\hat{\mathfrak{R}}_n(\cdot; S_t)$ эмпирическую сложность Радемахера на S_t . Пусть $\mathcal{F}_{\text{STL}}^{(t)}$ совпадает с семейством $\mathcal{F}(B_{\text{enc}})$, а $\mathcal{F}_{\text{MTL}}^{(t)}$ — с семейством $\mathcal{F}(B_{\text{shared}})$, где класс $\mathcal{F}(B)$ задается в основном тексте диссертации. Введем функцию

$$U_n(B) := \frac{B_{\text{head}} L R B}{\sqrt{n}}.$$

Тогда

$$\hat{\mathfrak{R}}_n(\mathcal{F}_{\text{MTL}}^{(t)}; S_t) \leq U_n(B_{\text{shared}}) \leq \frac{1}{\sqrt{T}} U_n(B_{\text{enc}}), \quad \hat{\mathfrak{R}}_n(\mathcal{F}_{\text{STL}}^{(t)}; S_t) \leq U_n(B_{\text{enc}}).$$

Следовательно, одна и та же величина вида $U_n(B)$ дает верхнюю оценку эмпирической сложности Радемахера в STL- и MTL-постановках, а предположение 3 обеспечивает не менее чем $1/\sqrt{T}$ -кратное уменьшение шаблонной верхней оценки при переходе от B_{enc} к B_{shared} .




Рис. 6: Зависимость F_1 от ранга r адаптеров LoRA (DeBERTa-v3-base) в задаче детекции машинно-генерированного текста. Наилучшее качество достигается при $r = 8$.

В экспериментах по детекции машинно-генерированного текста LoRA с рангом $r = 8$ требует только 0,16% параметров полной модели. Снижение метрик качества относительно полной тонкой настройки невелико, потери на валидации уменьшаются на 36,3% при ускорении обучения на 12,6%.

Многозадачная постановка с тремя выходными головками повышает $F1$ с 0,781 до 0,826 и ROC-AUC с 0,788 до 0,834. Оценка эмпирической сложности Радемахера уменьшается с $0,0159 \pm 0,0009$ до $0,0111 \pm 0,0010$, что качественно согласуется с уменьшением измеряемой сложности при многозадачной регуляризации энкодера. Так детекция машинно-генерированного текста связывается с общей темой диссертации: LoRA уменьшает число обучаемых параметров, MTL — оценку сложности на задачу, а метрики показывают, что снижение сложности не даёт существенной потери качества. Адаптерная тонкая настройка — пример практического снижения сложности модели.

В декодировании фМРТ предложена реконструкция томографических данных из видеопоследовательностей с предварительным сжатием фМРТ-представлений: снижение размерности существенно сокращает время обучения без ухудшения качества реконструкции. В детекции машинно-генерированного контента предложены метрики качества наборов KL_{TTS} , PHD , Δ_{shift} и $KL_{shuffle}$ (сравнение распределений, топологическая статистика, устойчивость к возмущениям). Результаты показывают применимость теории сложности к выбору компактных адаптеров, снижению размерности биомедицинских данных и контролю качества обучающих наборов. Для фМРТ используются представления кадров ResNet152 и линейная регрессия с L_2 -регуляризацией для предска-

зания изменений сигнала. При коэффициентах сжатия признакового описания 2, 4 и 8 время обучения падает с 36,3 с до 6,7, 1,6 и 1,4 с при сопоставимом качестве реконструкции. Оптимальное $\alpha \approx 1000$ сохраняется при разных коэффициентах сжатия — процедура снижения размерности устойчива.

В детекции машинно-генерированного контента оценивается не только детектор, но и качество оценочных наборов. KL_{TTS} сравнивает распределения признаков текстов, PHD — топологию облака представлений, Δ_{shift} — устойчивость к адверсарным сдвигам, KL_{shuffle} — чувствительность к перемешиванию предложений. Высокие показатели на одном наборе не гарантируют устойчивости на другом. Качественные наборы характеризуются близкими топологическими распределениями человеческих и машинных текстов и лучше подходят для оценки современных детекторов. Сложность данных нельзя сводить к объёму выборки: два набора одного размера могут различаться по устойчивости к возмущениям и по перекрытию распределений «человек/машина». Контроль качества данных — необходимое дополнение к анализу сложности модели при построении и сравнении детекторов.

Последняя глава показывает: аппарат сложности полезен не только для анализа архитектур, но и для проектирования адаптеров, снижения размерности биомедицинских данных и диагностики качества обучающих наборов. Этим завершается линия диссертации от теоретических мер сложности к практическим методам анализа моделей и данных.

Основные результаты и выводы

В диссертации разработан математический аппарат оценки согласованности и снижения сложности моделей глубокого обучения и данных на основе теории мер, анализа матриц Гессе и ландшафта оптимизационной задачи. Основные результаты:

1. Формальный аппарат мер сложности выборки μ_D и модели μ_f и критерий согласованности $\mu_f(f) \leq \mu_D(D)$.
2. Ландшафтная мера $\mu_f(f|D)$ через разброс пообъектных матриц Гессе и её связь с приращением эмпирического риска при росте выборки.
3. Теоретические оценки ландшафтной меры и спектральных норм матриц Гессе для полносвязных, сверточных и трансформерных архитектур (роль глубины, ширины, каналов, ядер и блоков самовнимания).
4. Критерии достаточного объёма выборки (D -, M -, KL - и S -достаточность) и их корректность в линейной регрессии при сходимости моментов оценок или апостериорных распределений; связь со сложностью — через условную сложность данных и стабилизацию эмпирического риска; критерии дают наблюдаемую оценку m^* без прямого вычисления матриц Гессе.
5. Методы снижения и перераспределения сложности: прореживание по ковариации градиентов и метод Белсли, байесовская и многодоменная дистилляция, антидистилляция.

6. Для LoRA — состоятельность оценки при стандартных условиях; для MTL — сравнение верхних оценок эмпирической радемахеровской сложности на задачу при справедливом масштабировании нормы энкодера.
7. Прикладные эксперименты по детекции машинно-генерированного текста, декодированию фМРТ и оценке качества наборов данных подтверждают применимость аппарата.

Совокупность результатов формализует оценку согласованности и снижение сложности моделей и данных в рамках единого подхода, применимого к широкому классу нейросетевых архитектур.

Список работ, опубликованных автором по теме диссертации

1. Варламова К. Д., Дорин Д. Д., Грабовой А. В. За чертой знакомых домёнов: исследование обобщающей способности детекторов машинно сгенерированных изображений // Доклады Российской академии наук. Математика, информатика, процессы управления. 2025. Т. 527, № 7. С. 103–116. DOI: 10.7868/S2686954325070094.
2. Дорин Д. Д., Грабовой А. В., Стрижов В. В. Улучшение декодирования данных ФМРТ с использованием пространственно-временных характеристик в условиях ограниченного набора данных // Доклады Российской академии наук. Математика, информатика, процессы управления. 2025. Т. 527, № 7. С. 11–30. DOI: 10.7868/S2686954325070021.
3. Kiselev N. S., Grabovoy A. V. Sample Size Determination: Likelihood Bootstrapping // Computational Mathematics and Mathematical Physics. 2025. Vol. 65, no. 2. pp. 416–423. DOI: 10.1134/s0965542524702002.
4. Kiselev Nikita, Grabovoy Andrey. Sample size determination: posterior distributions proximity // Computational Management Science. 2025. Vol. 22, no. 1. pp. 1. DOI: 10.1007/s10287-024-00528-9.
5. Gritsai G. M., Khabutdinov I. A., Grabovoy A. V. Stack More LLM's: Efficient Detection of Machine-Generated Texts via Perplexity Approximation // Doklady Mathematics. 2024. Vol. 110, no. S1. pp. S203–S211. DOI: 10.1134/s1064562424602075.
6. Kiselev N. S., Grabovoy A. V. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // Doklady Mathematics. 2024. Vol. 110, no. S1. pp. S49–S61. DOI: 10.1134/s1064562424601987.
7. Dorin Daniil, Kiselev Nikita, Grabovoy Andrey, Strijov Vadim. Forecasting fMRI images from video sequences: linear model analysis // Health Information Scient and Systems. 2024. Vol. 12, no. 1. pp. 55. DOI: 10.1007/s13755-024-00315-5.
8. Gritsay G. M., Grabovoy A. V., Kildyakov A. S., Chekhovich Yu V. Artificially Generated Text Fragments Search in Academic Documents // Doklady Mathematics. 2024. DOI: 10.1134/s1064562423701211.

9. Grabovoy A. V., Gadaev T. T., Motrenko A. P., Strijov V. V. Numerical Methods of Sufficient Sample Size Estimation for Generalised Linear Models // Lobachevskii Journal of Mathematics. 2022. Vol. 43, no. 9. pp. 2453–2462. DOI: 10.1134/s1995080222120125.
 10. Grabovoy A. V., Strijov V. V. Probabilistic Interpretation of the Distillation Problem // Automation and Remote Control. 2022. Vol. 83, no. 1. pp. 123–137. DOI: 10.1134/s000511792201009x.
 11. Grabovoy A. V., Strijov V. V. Bayesian Distillation of Deep Learning Models // Automation and Remote Control. 2021. Vol. 82, no. 11. pp. 1846–1856. DOI: 10.1134/s0005117921110023.
 12. Грабовой А. В., Бахтеев О. Ю., Стрижов В. В. Введение отношения порядка на множестве параметров аппроксимирующих моделей // Информатика и ее применения. 2020. Т. 14, № 2. С. 58–65. DOI: 10.14357/19922264200208.
 13. Грабовой А. В., Бахтеев О. Ю., Стрижов В. В. Определение релевантности параметров нейросети // Информатика и ее применения. 2019. DOI: 10.14357/19922264190209.
- Материалы международных конференций, индексируемые Scopus и/или Web of Science**
14. Gritsai G., Voznuyk A., Khabutdinov I., Grabovoy A. Advacheck at GenAI Detection Task 1: AI Detection Powered by Domain-Aware Multi-Tasking // Proceedings of the 1st Workshop on GenAI Content Detection (GenAIDetect). 2025. Pp. 236–243. International Conference on Computational Linguistics, Abu Dhabi, UAE.
 15. Poimanov D., Mestetsky L., Grabovoy A. N-Gram Perplexity-Based AI-Generated Text Detection // 2024 Ivannikov Ispras Open Conference (ISPRAS). 2024. Pp. 1–8. DOI: 10.1109/ispras64596.2024.10899150. IEEE.
 16. Meshkov V., Kiselev N., Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // 2024 Ivannikov Ispras Open Conference (ISPRAS). 2024. Pp. 1–10. DOI: 10.1109/ispras64596.2024.10899113. IEEE.
 17. Boeva G., Gritsay G., Grabovoy A. Team ap-team at PAN: LLM Adapters for Various Datasets // Working Notes of the Conference and Labs of the Evaluation Forum (CLEF 2024). 2024. Vol. 3740 (CEUR Workshop Proceedings). Pp. 2527–2535. CEUR-WS.org.
 18. Gritsai G., Khabutdinov I., Grabovoy A. Multi-head Span-based Detector for AI-generated Fragments in Scientific Papers // Proceedings of the Fourth Workshop on Scholarly Document Processing (SDP 2024). 2024. Pp. 220–225. DOI: 10.18653/v1/2024.sdp-1.21. Association for Computational Linguistics, Bangkok, Thailand.
 19. Petrushina K., Bakhteev O., Grabovoy A., Strijov V. Anti-Distillation: Knowledge Transfer from a Simple Model to the Complex

One // 2022 Ivannikov Ispras Open Conference (ISPRAS). 2022. DOI: 10.1109/ispras57371.2022.10076855. IEEE.

20. Gritsay G., Grabovoy A., Chekhovich Y. Automatic Detection of Machine Generated Texts: Need More Tokens // Ivannikov Memorial Workshop Proceedings 2022. 2022. DOI: 10.1109/ivmem57067.2022.9983964.

Публикации в других изданиях

21. Грабовой А. В. О сложности моделей и данных в задачах обучения нейросетевых моделей // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 72–73. ООО "МАКС Пресс", Москва.
22. Киселев Н. С., Мешков В. С., Грабовой А. В. Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 73–76. ООО "МАКС Пресс", Москва.
23. Грицай Г. М., Грабовой А. В. Неявная регуляризация векторного представления текстов в подходе многозадачного обучения // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 78–79. ООО "МАКС Пресс", Москва.
24. Дорин Д. Д., Киселев Н. С., Грабовой А. В. Декодирование визуальных стимулов из мультимодальных сигналов мозга // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. 2025. С. 124–126. ООО "МАКС Пресс", Москва.
25. Мешков В. С., Киселев Н. С., Грабовой А. В. Сходимость ландшафта сверточных нейронных сетей: анализ матричных сетей на основе матрицы Гессе // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.
26. Киселев Н. С., Грабовой А. В. Сходимость поверхности функции потерь как признак достаточного размера выборки // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.
27. Дорин Д. Д., Грабовой А. В. Улучшение декодирования фМРТ в условиях ограниченной выборки // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.
28. Грицай Г. М., Грабовой А. В. Выравнивание представлений в подходе многозадачного обучения для детектирования машинно-сгенерированных текстов // Труды 67-й Всероссийской научной конференции МФТИ. 2025. (Прикладная математика и информатика). Физматкнига.

29. Киселев Н., Грабовой А. Определение достаточного размера выборки по апостериорному распределению параметров модели // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. 2024. С. 141. ISBN 978-5-89155-414-6. (Прикладная математика и информатика). Физматкнига.
30. Баязитов К. М., Грабовой А. В., Стрижов В. В. Дистилляция моделей глубокого обучения на многодоменных выборках // Интеллектуализация обработки информации: Тезисы докладов 14-й Международной конференции. 2022. С. 98–99. ISBN 978-5-907366-77-0. Российская академия наук, Москва.