

На правах рукописи

ГРАБОВОЙ АНДРЕЙ ВАЛЕРИЕВИЧ

О СЛОЖНОСТИ МОДЕЛЕЙ И ДАННЫХ
В ПАРАМЕТРИЧЕСКИХ МОДЕЛЯХ МАШИННОГО ОБУЧЕНИЯ

1.2.1 — Искусственный интеллект и машинное обучение

Диссертация на соискание ученой степени
доктора физико-математических наук

Научный консультант:
профессор РАН К. В. Воронцов

Москва — 2025

Оглавление

	Стр.
Введение	6
Глава 1. Теория обучаемости	19
1.1. Основные понятия статистического обучения	19
1.2. Классические меры сложности как основа теории обучаемости	22
1.2.1. VC-размерность и ростовая функция	24
1.2.2. PAC-обучаемость: реализуемый и агностический случаи	26
1.2.3. Радемахеровская сложность и локальные оценки	27
1.2.4. Комбинаторный подход Воронцова	28
1.2.5. Ограничения классических мер	30
1.3. Методология обзора	31
1.4. Классические и информационно-теоретические оценки	35
1.5. Ландшафт функции потерь	40
1.6. Эмпирические оценки сложности	45
1.7. Сравнительный анализ и открытые вопросы	51
1.8. Заключение обзора	56
1.9. Открытые проблемы и вклад диссертации	57
Глава 2. Сложность моделей и данных	59
2.1. Оценка сложности моделей и данных	61
2.2. Достаточный объем выборки	65
2.3. Ландшафтная мера сложности модели	68
2.3.1. Теоретические оценки для полносвязных сетей	75
2.3.2. Теоретические оценки для сверточных сетей	78
2.3.3. Теоретические оценки для трансформеров	82
2.4. Ландшафтная мера и радемахеровская сложность в задаче регрессии	85
2.4.1. Постановка задачи регрессии	89

2.4.2.	Ландшафтная мера при квадратичной функции потерь	89
2.4.3.	Сопоставление с радемахеровской сложностью	98
2.4.4.	Сопоставление мер для линейной модели	99
2.4.5.	Сопоставление мер для двухслойной сети с активацией ReLU . . .	100
2.4.6.	Численное сопоставление ландшафтной меры и радемахеровской сложности	103
2.5.	Динамика ландшафтной меры при обучении языковых моделей . . .	107
2.5.1.	Постановка задачи анализа динамики	110
2.5.2.	Эксперимент по динамике меры для моделей GPT-2	112
2.6.	Вычислительные эксперименты	122
2.6.1.	Эксперименты для полносвязных сетей	123
2.6.2.	Эксперименты для сверточных сетей	128
2.6.3.	Эксперименты для трансформеров	129
2.7.	Заключение	129
Глава 3. Матрицы Гессе параметрических моделей		138
3.1.	Полносвязные сети	140
3.1.1.	Спектральная оценка матрицы Гессе	144
3.2.	Матричные и сверточные сети	146
3.2.1.	Факторизация матрицы Гессе	149
3.2.2.	Оценки спектральных норм для матричных сетей	151
3.3.	Трансформеры	157
3.3.1.	Слой самовнимания	159
3.3.2.	Слой LayerNorm	166
3.3.3.	Нелинейность ReLU	168
3.3.4.	Блок трансформера	170
3.3.5.	Спектральные оценки нормы Гессе трансформера	175
3.4.	Вычислительные эксперименты	176
3.5.	Заключение	182

Глава 4. Достаточный объем выборки	185
4.1. Статистические критерии мощности для обобщенных линейных моделей	188
4.2. Эвристические критерии по динамике качества	193
4.3. Байесовские критерии неопределенности параметров	195
4.4. D- и M-достаточность по функции правдоподобия	197
4.5. KL- и S-достаточность по апостериорным распределениям	200
4.6. Вычислительные эксперименты	209
4.6.1. Эксперименты для статистических критериев	210
4.6.2. Эксперименты для D- и M-достаточности	214
4.6.3. Эксперименты для KL- и S-достаточности	218
4.7. Заключение	224
Глава 5. Методы снижения сложности моделей	227
5.1. Удаление параметров по ковариации градиентов	227
5.2. Байесовская дистилляция	232
5.3. Многодоменная дистилляция	235
5.4. Антидистилляция	239
5.5. Вычислительные эксперименты	243
5.5.1. Эксперименты по удалению параметров	243
5.5.2. Эксперименты по многодоменной дистилляции	249
5.5.3. Эксперименты по антидистилляции	257
5.6. Заключение	262
Глава 6. Прикладные задачи	264
6.1. Сложность моделей в многозадачном обучении с LoRA-адаптерами .	264
6.1.1. Оценки радемахеровской сложности	264
6.1.2. Многозадачное обучение и низкоранговые адаптеры	270
6.2. Снижение размерности данных при декодировании фМРТ	276

6.3. Оценка качества данных для детекции машинно-генерированного контента	280
6.4. Вычислительные эксперименты	284
6.4.1. Эксперименты по многозадачному обучению с LoRA	284
6.4.2. Эксперименты по декодированию фМРТ	294
6.4.3. Эксперименты по оценке качества данных детекции	296
6.5. Заключение	303
Заключение	305
Общие свойства и определения	307
Дополнительные леммы и утверждения	311
Список иллюстраций	316
Список таблиц	329
Список литературы	335

Введение

Диссертационная работа решает проблему отсутствия теоретического аппарата для оценки согласованности сложности параметрических моделей машинного обучения с характеристиками обучающей выборки, а также методов снижения сложности таких моделей. В работе разработан теоретический подход, основанный на анализе ландшафта оптимизационной задачи, который обеспечивает получение асимптотических оценок сложности различных семейств параметрических моделей и формализует связь между сложностью модели и выборкой, используемой для ее обучения.

Актуальность темы. С начала XXI века наблюдается экспоненциальный рост производительности вычислительных систем, измеряемой в операциях с плавающей запятой (англ. FLOPS): от терафлопсов в начале столетия до эксафлопсов в настоящий момент. Параллельно происходит сопоставимый рост сложности моделей глубокого обучения, выраженный в увеличении количества обучаемых параметров на несколько порядков — от тысяч в начале нулевых годов до миллиардов и сотен миллиардов в двадцатых, с прогнозируемым переходом к триллионам параметров в ближайшем десятилетии. Современные исследования анализа сложности таких моделей преимущественно опираются на эмпирические корреляции, связывающие эффективность моделей с количественными метриками — числом параметров и вычислительными затратами на обучение или применение. Отсутствие строгой теоретической основы для предсказания поведения моделей при масштабировании делает процесс разработки экономически и энергетически неэффективным и зачастую приводит к получению необоснованных и противоречивых результатов.

Особую остроту проблема приобретает при разработке больших языковых моделей (англ. LLM), обучение которых требует значительных вычислительных, энергетических и финансовых ресурсов. Для снижения непредсказуемости процесса обучения на предварительной стадии (англ. pretrain) эмпирически под-

бираются оптимальные соотношения между размером модели в параметрах и объемом обучающих данных в токенах при заданном вычислительном ресурсе. Однако эмпирические оценки, полученные для одной архитектуры, не переносятся на другие модели, что ограничивает применимость подобных подходов и приводит к непредвиденным результатам при полномасштабном обучении. В связи с этим разработка теоретических оценок сложности моделей становится критически важной, поскольку такие оценки позволяют связать сложность модели со сложностью выборки еще на этапе проектирования архитектуры, обеспечивая рациональный выбор параметров модели и объема данных. Отметим, что глубоким теоретическим анализом выбора и порождения моделей на этапе проектирования архитектур моделей глубокого обучения занимается Вадим Викторович Стрижов [1].

Классические подходы к оценке сложности моделей машинного обучения, разработанные для традиционных методов, находят ограниченное применение при анализе моделей глубокого обучения. Фундаментальный вклад в теорию оценивания сложности моделей внесли работы Владимира Наумовича Вапника и Алексея Яковлевича Червоненкиса, заложившие основы статистической теории обучения [2], а также Лесли Вэлианта, предложившего подход приближенно правильного обучения (англ. PAC-Learning) [3]. Современные подходы к определению сложности основаны на Радемахеровской сложности, предложенной Владимиром Кольчинским и Дмитрием Панченко [4], и комбинаторном подходе к оценке обучаемости алгоритмов Константина Вячеславовича Воронцова [5], в котором разработан математический аппарат на основе комбинаторных оценок вероятности переобучения моделей. Однако современные исследования в области теории машинного обучения редко рассматривают нейросетевые модели глубокого обучения ввиду их высокой сложности и трудности получения адекватных оценок сложности таких моделей. Значительная часть современных исследований на ведущих конференциях посвящена классическим методам машинного обучения и улучшению оценок для известных методов, так как

текущие оценки сложности даже для классических моделей являются сильно завышенными.

Отдельным направлением в исследованиях являются оценки репрезентативной способности моделей глубокого обучения к аппроксимации по прецедентам. Основополагающий результат принадлежит Джорджу Цибенко [6], который доказал, что нейронные сети аппроксимируют непрерывные функции с некоторыми ограничениями с произвольной точностью. Йохану Хестада [7] принадлежат первые оценки, указывающие на рост аппроксимирующей способности моделей глубокого обучения с глубиной модели. В более современных работах Яна Лекуна [8], Йошуа Бенджио [9], Надава Коэна [10] эти оценки получены с более мягкими ограничениями на класс рассматриваемых функций. В целом все эти оценки наряду с работой Охада Шамира [11] указывают на экспоненциальное увеличение аппроксимирующей способности моделей глубокого обучения с ростом числа слоев.

В настоящей работе предлагается теоретический анализ нейросетевых моделей, опирающийся на анализ их матриц Гессе. Матрица Гессе функции потерь по параметрам модели содержит информацию о локальной кривизне оптимизационного ландшафта и используется для анализа сложности модели и обучающей выборки, а также для оценки важности [12, 13] параметров в задачах прореживания нейросетевых моделей. Локализация исследования: рассматриваются параметрические модели машинного обучения в постановке минимизации эмпирического риска; в центр ставится согласованность сложности модели с характеристиками выборки, а не построение новых универсальных аппроксиматоров.

Степень разработанности темы диссертационного исследования.

Классические подходы к оценке сложности моделей машинного обучения, основанные на VC-размерности, PAC-обучаемости и радемахеровской сложности, разработаны для моделей с ограниченным числом параметров и ориентированы на анализ худшего случая, что делает их оценки слишком консервативными для

перепараметризованных нейронных сетей [14]. Эти оценки не учитывают специфику параметрических моделей глубокого обучения, такие как сверточные фильтры, остаточные связи и механизмы внимания, а также не отражают влияние регуляризации, ранней остановки и особенностей процесса оптимизации на обобщающую способность моделей. Комбинаторный подход К.В. Воронцова [5] позволяет снизить оценки Вапника–Червоненкиса, но остается применимым лишь к ограниченным классам моделей.

Что касается оценки сложности данных, существующие подходы преимущественно сводятся к анализу размера выборки для обучения [15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28], что является неполным, так как сложность выборки также определяется сложностью каждого объекта. Современные методы оценки сложности объектов выборки опираются на исследования сложности многообразий, аппроксимирующих элементы выборки. Для больших языковых моделей используются эмпирические законы масштабирования [29, 30], полученные Джаредом Капланом и Джорданом Хофманом [31], однако эти законы не имеют строгого теоретического обоснования и не объясняют механизмы, лежащие в основе зависимостей между параметрами, данными и качеством модели.

В области снижения сложности моделей используются несколько основных направлений, включая квантизацию параметров, прореживание и дистилляцию знаний [32, 33, 34]. Однако существующие методы не опираются на строгие теоретические оценки сложности моделей и данных, что ограничивает их эффективность и предсказуемость.

Таким образом, на текущий момент в исследованиях отсутствует единый теоретический аппарат для описания сложности моделей глубокого обучения, позволяющий получить асимптотические оценки и формализовать согласование сложности модели с характеристиками обучающей выборки. Разработка такого аппарата позволит проводить сравнительный анализ различных параметрических моделей глубокого обучения для выбора оптимального решения

для заданной задачи, характеризуемой выборкой определенной сложности.

Объектом исследования являются процессы параметрического обучения моделей машинного обучения по конечным выборкам.

Предмет исследования: согласованность сложности параметрических моделей машинного обучения с характеристиками обучающей выборки, формализуемая мерами на модели и на выборке.

Цель и задачи исследования. Целью исследования является построение теоретического аппарата оценки согласованности сложности параметрических моделей машинного обучения с характеристиками обучающей выборки и методов снижения сложности таких моделей на основе анализа ландшафта функции потерь.

Для достижения цели были поставлены и решены следующие задачи:

- введение определений мер сложности моделей и выборок в рамках теории мер и формулировка критерия согласованности модели и выборки;
- построение ландшафтной меры сложности модели по матрицам Гессе и установление ее связи с приращением эмпирического риска при изменении выборки;
- получение теоретических оценок ландшафтной меры для полносвязных, сверточных и трансформерных архитектур;
- построение методов оценки достаточного объема выборки и анализ их связи со сложностью модели через условную сложность данных и стабилизацию эмпирического риска;
- построение методов снижения сложности моделей, опирающихся на локальную геометрию функции потерь;
- демонстрация применимости построенного аппарата в прикладных задачах.

Методы исследования. Для решения поставленных задач в диссертации используются методы теории мер, линейной алгебры, матричного анализа,

включая матричное дифференцирование и спектральный анализ матриц, методы теории вероятностей, математической статистики, включая байесовский анализ, анализ сходимости случайных процессов, методы теории оптимизации, анализа функций многих переменных, методы статистической теории обучения.

Научная новизна.

1. Введены формальные определения меры сложности выборки $\mu_D(D)$ и меры сложности модели $\mu_f(f)$ в рамках теории мер, сформулирован критерий согласованности модели и выборки $\mu_f(f) \leq \mu_D(D)$.
2. Введена ландшафтная мера сложности модели $\mu_f(f|D) = \mathbb{E}_i \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_j \mathbf{H}_j(\boldsymbol{\theta}^*)\|_2$, где ожидания берутся по равномерному выбору объектов i, j из выборки D , а $\|\cdot\|_2$ — спектральная норма матрицы; мера задает количественную связь между изменением выборки и локальной геометрией оптимизационного ландшафта.
3. Для полносвязных, сверточных и трансформерных архитектур получены оценки ландшафтной меры через спектральные нормы матриц Гессе: оценки растут экспоненциально с глубиной сети и полиномиально с шириной и числом каналов.
4. Показано, что байесовские критерии достаточного объема выборки по близости апостериорных распределений параметров корректны в модели линейной регрессии и допускают анализ сходимости. Их связь со сложностью модели задается через условную сложность данных и наблюдаемую стабилизацию эмпирического риска.
5. Предложены прореживание по ковариации градиентов, многодоменная дистилляция и антидистилляция как методы снижения сложности, опирающиеся на локальную геометрию функции потерь. Байесовская дистилляция рассматривается как развитие кандидатской постановки и не выносится отдельным положением на защиту докторской работы.
6. Для низкоранговой адаптации параметров доказана состоятельность оценки при стандартных условиях. Для многозадачного обучения полу-

но сравнение верхних оценок эмпирической радемахеровской сложности на задачу при справедливом масштабировании нормы энкодера.

Теоретическая значимость работы. Результаты вписывают локальный анализ матриц Гессе в теорию сложности обучаемости как вычислимый мост между архитектурными параметрами модели и вопросом согласования модели с выборкой, расширяя классические подходы на основе VC-размерности, PAC-обучаемости и радемахеровской сложности на случай перепараметризованных моделей. Полученные оценки ландшафтной меры дают основание для сравнительного анализа архитектур и для сопоставления методов оценки достаточного объема выборки со сложностью модели. Основной вклад работы состоит в построении ландшафтной меры сложности параметрической модели и в установлении на ее основе вычислимой связи между архитектурой модели, стабилизацией обучения и характеристиками выборки.

Практическая значимость работы. Разработанный теоретический аппарат применен к решению прикладных задач машинного обучения: многозадачного обучения, декодирования фМРТ-изображений и детекции машинно-генерированного контента. Полученные методы оценки и снижения сложности моделей и данных экспериментально проверены на реальных задачах компьютерного зрения, обработки естественного языка и классификации.

Положения, выносимые на защиту:

1. Меры сложности модели и выборки вместе с критерием их согласованности задают формальный аппарат соответствия параметрической модели машинного обучения характеристикам обучающей выборки.
2. Ландшафтная мера на основе спектральных свойств матриц Гессе количественно связывает архитектуру модели с изменением эмпирического риска при изменении выборки.
3. Оценки ландшафтной меры растут экспоненциально с глубиной сети и полиномиально с шириной и числом каналов.

4. Методы оценки достаточного объема выборки по близости апостериорных распределений сходятся в модели линейной регрессии.
5. Редукция пространства обучаемых параметров уменьшает число параметров модели при сохранении порядка качества аппроксимации.

Степень достоверности результатов. Достоверность научных результатов работы подтверждается непротиворечивостью и согласованностью с известными фактами и исследованиями в рассматриваемой области, высокой степенью сходимости теоретических результатов с данными экспериментов и определяется применением теоретических и методологических основ разработок ведущих ученых в области обработки естественного языка, корректным и обоснованным использованием математического аппарата, экспериментальными исследованиями разработанных моделей и методов.

Соответствие диссертации паспорту специальности. Тема и основные результаты диссертации соответствуют следующим областям исследований паспорта специальности 1.2.1 — Искусственный интеллект и машинное обучение.

2 Исследования в области оценки качества и эффективности алгоритмических и программных решений для систем искусственного интеллекта и машинного обучения. Методики сравнения и выбора алгоритмических и программных решений при многих критериях.

4 Разработка методов, алгоритмов и создание систем искусственного интеллекта и машинного обучения для обработки и анализа текстов на естественном языке, для изображений, речи, биомедицины и других специальных видов данных.

16 Исследования в области специальных методов оптимизации, проблем сложности и элиминации перебора, снижения размерности.

17 Исследования в области многослойных алгоритмических конструкций, в том числе – многослойных нейросетей.

Апробация результатов диссертации. Основные результаты работы докладывались и обсуждались на Всероссийской конференции с международ-

ным участием «Математические методы распознавания образов» (Москва, 2019, Москва, 2021, Муром, 2025), Международной конференции «Интеллектуализация обработки информации» (Гаэта, 2018, Москва, 2020, Москва, 2022), Всероссийской научной конференции МФТИ (Москва, 2018, 2019, 2020, 2021, 2023, 2024, 2025), Ivannikov Ispras Open Conference (Москва, 2021, 2022, 2023, 2024), Ivannikov Memorial Workshop (Казань, 2022), Iberian Languages Evaluation Forum co-located with the Conference of the Spanish Society for Natural Language Processing (Андалусия, 2023, 2024), 35th Conference of Open Innovations Association (Тампере, 2024), Fourth Workshop on Scholarly Document Processing (Бангкок, 2024), 1st Workshop on GenAI Content Detection (GenAIDetect) (Абу-Даби 2025), 19th International Workshop on Semantic Evaluation (Вена, 2025).

Публикации. По теме диссертации опубликовано 56 научных работ, из которых 17 статей в научно-технических журналах, входящих в перечень ВАК, 32 — в изданиях, входящих в международные наукометрические базы Scopus и Web of Science. В трудах российских и международных конференций опубликовано 39 работ. Также на основе работ автора зарегистрировано 13 программ для ЭВМ.

Личный вклад соискателя. Все выносимые на защиту результаты и положения, составляющие основное содержание диссертационного исследования, разработаны и получены лично автором или при его непосредственном участии вместе с учениками. В работах, опубликованных в соавторстве, соискателю принадлежит определяющая роль в построении теоретических методов и направлении исследований.

Структура и объем работы. Диссертация состоит из оглавления, введения, шести разделов, заключения, списка иллюстраций, списка таблиц, перечня основных обозначений и списка литературы из 261 наименований. Основной текст занимает 364 страницы.

Краткое содержание работы по главам.

В главе 1 после блока формальных определений (VC/PAC, радемахеровская сложность, комбинаторный подход Воронцова) излагается обзор литературы о сложности и обобщении с описанием процедуры построения корпуса, тематической группировкой источников и синтезом основных направлений; заключительный параграф формулирует выводы об обзорной части и связывает их с задачами последующих глав.

В главе 2 вводятся общие определения меры сложности моделей и данных как постановочная основа для вопроса о согласовании модели и выборки. Условная сложность выборки и достаточный объем данных рассматриваются как вспомогательные понятия; подробные методы оценки достаточного объема выборки вынесены в главу 4. Основной акцент главы сделан на условной сложности параметрических моделей глубокого обучения, частным и вычислимым случаем которой является ландшафтная мера, анализирующая изменение ландшафта функции потерь при вариации обучающей выборки. Ландшафтная мера основывается на исследовании пообъектных матриц Гессе в окрестности опорной точки; подробные результаты по оценке матриц Гессе для специальных семейств моделей глубокого обучения рассматриваются в главе 3. В главе получена связь между приращением эмпирического риска при росте выборки и ландшафтной мерой модели глубокого обучения. Из этих оценок получены частные результаты для полносвязных, сверточных и трансформерных моделей глубокого обучения. Полученные оценки имеют асимптотический характер и указывают на экспоненциальный рост ландшафтной меры при увеличении числа слоев сети и полиномиальный рост при увеличении числа параметров внутри слоя. Отдельным блоком рассматривается постановка скалярной регрессии с полносвязными сетями ReLU при квадратичной функции потерь: получены порядки ландшафтной меры разброса пообъектных матриц Гессе и выполнено теоретическое и численное сопоставление с эмпирической радемахеровской сложностью для линейной и двухслойной архитектур. Другим блоком приводится эмпирический анализ динамики выборочной ландшафтной меры

при обучении языковых моделей семейства GPT-2 на корпусе WikiText-103.

В главе 3 описываются ключевые теоремы об оценках матриц Гессе для различных семейств моделей глубокого обучения. Матрица Гессе функции ошибки по параметрам модели глубокого обучения содержит информацию о поведении функции вокруг некоторой точки и служит основой для введенной в главе 2 ландшафтной меры. В рамках данной главы получены выражения для матриц Гессе и оценки их спектральных норм для полносвязных, сверточных и трансформерных архитектур моделей глубокого обучения. Полученные оценки представляют самостоятельный научный результат и используются в других главах диссертации для анализа ландшафтной меры и методов снижения сложности моделей.

В главе 4 предлагаются методы оценки достаточного объема выборки для линейных и нейросетевых моделей глубокого обучения. В главе сравниваются классические и байесовские методы оценки достаточного объема выборки. Проведен анализ методов оценки достаточного объема выборки на основе семплирования эмпирической функции ошибки, для которого указана сходимость для линейной модели и эмпирически подтверждена работа для моделей глубокого обучения. Также проведен сравнительный анализ методов определения достаточного размера выборки, основанных на близости апостериорных распределений близких выборок, с теоретическими оценками сходимости для любых параметрических семейств с нормальным апостериорным распределением параметров.

В главе 5 рассматриваются методы снижения сложности моделей глубокого обучения. Предложены методы удаления параметров на основе анализа ковариационной матрицы градиентов функции ошибки по параметрам модели. Рассматривается байесовская дистилляция, в которой информация от модели учителя передается модели ученика через априорное распределение параметров; приведены теоремы о сохранении нормального вида распределения параметров при удалении нейрона и слоя. Также предложен метод дистилляции моделей на

многодоменных данных и метод антидистилляции для наращивания сложности модели, при котором использование информации из обученной небольшой модели учителя при обучении большой модели ученика обеспечивает повышенную устойчивость к шуму и более высокую точность аппроксимации.

В главе 6 рассматриваются прикладные применения теории сложности моделей глубокого обучения. Рассматривается оценка радемахеровской сложности в задаче многозадачного обучения; установлено, что совместное использование параметров энкодера в многозадачном обучении снижает радемахеровскую сложность на задачу. Сопоставление радемахеровской сложности с ландшафтной мерой в регрессионной постановке содержится в главе 2. Приведен пример снижения размерности признакового описания фМРТ-снимков без потери качества аппроксимации модели. Рассмотрено качество данных в задаче детекции машинно-генерированного контента; с использованием введенных метрик продемонстрировано, что качество данных непосредственно влияет на оценку детекторов.

Благодарности. Автор благодарен научной школе академиков РАН Константина Владимировича Рудакова и Юрия Ивановича Журавлева, в частности своим учителям доктору физико-математических наук Вадиму Викторовичу Стрижову и профессору РАН Константину Вячеславовичу Воронцову за интерес к работе, советы и поддержку в исследованиях, связанных с данной докторской диссертацией.

Также автор благодарен компании АО «Антиплагиат», где под руководством Юрия Викторовича Чеховича и Александра Сергеевича Кильдякова в отделе исследований проведено большое количество прикладных экспериментов, позволивших снизить общую сложность моделей глубокого обучения в продуктах компании.

Отдельно автор признателен своим ученикам, аспирантам и студентам Герману Грицаю, Никите Киселеву, Данилу Дорину, Ильдару Хабутдинову, Владиславу Мешкову, Игорю Игнашину, Анастасии Вознюк, Анне Зверевой, Камилу

Баязитову, Анне Ремизовой и Егору Петрову за обсуждение результатов, экспериментальную работу и развитие теоретического анализа моделей глубокого обучения, в частности теории их сложности.

Глава 1

Теория обучаемости

В настоящей главе вводятся основные понятия теории обучаемости и показывается, почему классические меры сложности оказываются недостаточными для анализа современных параметрических моделей глубокого обучения. Сначала рассматриваются определения статистического обучения и базовые меры сложности, затем эти меры сопоставляются с современными направлениями анализа обобщающей способности, ландшафта функции потерь, режимов обучения и масштабирования моделей. Такое построение необходимо для последующих глав, где сложность рассматривается уже не только как емкость класса функций, но и как характеристика локальной геометрии обученной параметрической модели и процесса ее обучения.

1.1. Основные понятия статистического обучения

В теории машинного обучения базовой является стохастическая постановка, в рамках которой данные рассматриваются как выборка из неизвестного распределения. Пусть задано вероятностное пространство $(\Omega, \mathcal{F}, \mathbb{P})$ и случайная пара $(\mathbf{X}, \mathbf{Y})$, принимающая значения в декартовом произведении пространств объектов и ответов $\mathcal{X} \times \mathcal{Y}$, с неизвестным совместным распределением $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$. Генеральная совокупность Γ задает множество всех возможных объектов, а кольцо выборок

$$\mathfrak{D} = \{D_{\Gamma}^i : D_{\Gamma}^i \subset \Gamma\}$$

состоит из всех конечных подмножеств, доступных для анализа. В дальнейшем под выборкой будем понимать произвольный элемент $D \in \mathfrak{D}$ вида

$$D = \{(\mathbf{x}_1, \mathbf{y}_1), \dots, (\mathbf{x}_m, \mathbf{y}_m)\},$$

который рассматривается как реализация независимых одинаково распределенных случайных величин $(\mathbf{X}_i, \mathbf{Y}_i) \sim \mathbb{P}_{\mathbf{X}, \mathbf{Y}}$.

Моделью (или гипотезой) называется отображение $f: \mathcal{X} \rightarrow \mathcal{Y}$, выбранное из фиксированного класса параметрических функций $\mathfrak{F}$. Для формализации качества модели вводится *функция потерь* $\ell: \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_+$, измеряющая несоответствие предсказания $f(\mathbf{x})$ и истинного ответа $\mathbf{y}$. В задачах классификации часто используют 0–1-потерю

$$\ell_{0-1}(f(\mathbf{x}), \mathbf{y}) = \mathbb{I}\{f(\mathbf{x}) \neq \mathbf{y}\},$$

а в задачах регрессии — квадратичную или абсолютную потери.

Определение 1 (Риск модели). *Риском модели $f \in \mathfrak{F}$ называют математическое ожидание потерь относительно истинного распределения данных:*

$$R(f) = \mathbb{E}_{(\mathbf{X}, \mathbf{Y}) \sim \mathbb{P}_{\mathbf{X}, \mathbf{Y}}} [\ell(f(\mathbf{X}), \mathbf{Y})].$$

Так как распределение $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$ неизвестно, прямой расчет $R(f)$ обычно невозможен. Вместо этого вводят *эмпирический риск* по выборке D :

$$\hat{R}_m(f) = \frac{1}{m} \sum_{i=1}^m \ell(f(\mathbf{x}_i), \mathbf{y}_i),$$

который рассматривается как статистическая оценка истинного риска. Связь между $R(f)$ и $\hat{R}_m(f)$ является центральным объектом исследования в теории обучаемости.

Замечание 1. В главах 2, 3 и далее для эмпирического риска параметризованных моделей используется обозначение $\mathcal{L}_m(\boldsymbol{\theta})$, которое совпадает с $\hat{R}_m(f)$ при параметризации $f_{\boldsymbol{\theta}}$. В настоящей главе оба обозначения рассматриваются как взаимозаменяемые.

Определение 2 (Алгоритм минимизации эмпирического риска). *Алгоритмом минимизации эмпирического риска называют отображение, которое по выборке $D \in \mathfrak{D}$ возвращает модель*

$$\hat{f}_{\text{ERM}} \in \arg \min_{f \in \mathfrak{F}} \hat{R}_m(f).$$

Даже если класс моделей достаточно богат, чтобы аппроксимировать зависимость между $\mathbf{X}$ и $\mathbf{Y}$, для конечной выборки D может возникать *переобучение*: алгоритм подстраивается под случайные шумы в данных, достигая малого эмпирического риска при высоком истинном риске. Поэтому важной задачей является построение оценок отклонения $|R(f) - \hat{R}_m(f)|$ для различных классов $\mathfrak{F}$ и схем выбора моделей.

Определение 3 (Наилучшая модель в классе и избыточный риск). *Модель f^* , минимизирующая риск в фиксированном классе $\mathfrak{F}$,*

$$f^* \in \arg \min_{f \in \mathfrak{F}} R(f),$$

называется наилучшей в классе. Величина

$$R(f) - R(f^*)$$

называется избыточным риском модели f .

В идеальном случае теоретические оценки должны гарантировать, что избыточный риск $(R(\hat{f}_{\text{ERM}}) - R(f^*))$ мал с высокой вероятностью при разумном объеме выборки m . При этом ключевую роль играет мера сложности класса моделей $\mathfrak{F}$, определяющая скорость сходимости эмпирического риска к истинному.

Определение 4 (Обучаемость класса моделей). *Пусть $\mathfrak{D}_m$ — множество выборок $D = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m$ размера m , независимых по распределению $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$. Класс моделей $\mathfrak{F}$ называется обучаемым в заданной постановке, если существует алгоритм $A: \bigcup_{m=1}^{\infty} \mathfrak{D}_m \rightarrow \mathfrak{F}$ (возможно, использующий дополнительную внутреннюю случайность, независимую от D) такой, что для любого распределения $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$ и любых $\varepsilon > 0$, $\delta \in (0, 1)$ найдется $m(\varepsilon, \delta) \in \mathbb{N}$, для которого при любом $m \geq m(\varepsilon, \delta)$ выполняется*

$$\mathbb{P}_D \{R(A(D)) - R(f^*) \leq \varepsilon\} \geq 1 - \delta,$$

где вероятность берется по случайной выборке D и, при наличии, по внутренним случайностям алгоритма A , а $f^ = \arg \min_{f \in \mathfrak{F}} R(f)$ — наилучшая модель в классе $\mathfrak{F}$.*

Дальнейший анализ в рамках классических подходов концентрируется на поиске верхних оценок $m(\varepsilon, \delta)$ через различные характеристики сложности класса $\mathfrak{F}$: VC-размерность, ростовую функцию, радемахеровскую сложность и другие. Эти меры играют фундаментальную роль в теории обучаемости и подробно рассматриваются в следующем разделе.

1.2. Классические меры сложности как основа теории обучаемости

Классические меры сложности задают исходный математический аппарат для постановки вопроса об обучаемости модели по конечной выборке. В настоящем разделе они рассматриваются как базовый блок: вводятся определения, необходимые для дальнейшего анализа, и сразу фиксируются ограничения этих понятий в контексте глубоких нейросетевых архитектур. Первые строгие представления о сложности моделей сформировались в рамках статистической теории распознавания [2, глава 5], где ключевую роль сыграли понятия VC-размерности и структурного риска. Пусть задано пространство объектов $\mathcal{X}$ и класс булевых моделей $\mathfrak{F} \subset \{0, 1\}^{\mathcal{X}}$.

Определение 5 (Разделимость выборки). *Набор точек $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathcal{X}$ называется разделимым классом $\mathfrak{F}$, если для любого разметочного вектора $(\mathbf{y}_1, \dots, \mathbf{y}_m) \in \{0, 1\}^m$ существует модель $f \in \mathfrak{F}$ такая, что $f(\mathbf{x}_i) = \mathbf{y}_i$ для всех $i = 1, \dots, m$.*

Определение 6 (VC-размерность). *VC-размерностью класса $\mathfrak{F}$ называется величина*

$$VC(\mathfrak{F}) = \sup \{m \in \mathbb{N} : \exists D \subset \mathcal{X}, |D| = m, D \text{ разделим классом } \mathfrak{F}\}.$$

Если множество в правой части пусто, полагаем $VC(\mathfrak{F}) = 0$. Если супремум не достигается, полагаем $VC(\mathfrak{F}) = +\infty$.

На основе введенных понятий VC-размерности и разделимости удалось связать обобщающую способность алгоритмов с ростовой функцией $\Pi_{\mathfrak{F}}(m)$ и получить верхние оценки разности между эмпирическим риском $\hat{R}_m(f)$ и истинным

риском $R(f)$ вида

$$R(f) \leq \hat{R}_m(f) + C \sqrt{\frac{\text{VC}(\mathfrak{F}) \log m}{m}},$$

где $C > 0$ некоторая универсальная константа. Однако такие оценки используют грубые верхние границы, мало чувствительные к структуре конкретной задачи и распределения данных.

Развитие РАС-подхода дополнило картину формальными критериями обучаемости [3, раздел 2].

Определение 7 (РАС-обучаемость). *Класс моделей $\mathfrak{F}$ называется РАС-обучаемым (англ. Probably Approximately Correct learnable), если существует алгоритм $A: \bigcup_{m=1}^{\infty} \mathfrak{D}_m \rightarrow \mathfrak{F}$ и функция $m: (0, 1) \times (0, 1) \rightarrow \mathbb{N}$, полиномиальная по $1/\varepsilon$ и $\log(1/\delta)$, такие что для любого распределения $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$ на $\mathcal{X} \times \{0, 1\}$, любых $\varepsilon > 0$, $\delta \in (0, 1)$ и любого $m \geq m(\varepsilon, \delta)$ при выборке $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$, составленной из независимых по $\mathbb{P}_{\mathbf{X}, \mathbf{Y}}$ наблюдений, выполняется*

$$\mathbb{P}_D \{R(A(D)) - R(f^*) \leq \varepsilon\} \geq 1 - \delta,$$

где $f^* = \arg \min_{f \in \mathfrak{F}} R(f)$, а под $\mathbb{P}_D$, как и в определении обучаемости, понимается распределение выборки и при необходимости внутренняя случайность алгоритма.

Для класса $\mathfrak{F}$ с конечной VC-размерностью $d = \text{VC}(\mathfrak{F}) < \infty$ известна оценка [3, раздел 2]

$$m(\varepsilon, \delta) \geq C \frac{1}{\varepsilon^2} \left(d \log \frac{1}{\varepsilon} + \log \frac{1}{\delta} \right),$$

где $C > 0$ — универсальная константа. Для реальных данных высокой размерности классические РАС-оценки остаются слабыми: они требуют огромных выборок даже для относительно простых архитектур и не учитывают внутреннюю структуру параметров, регуляризацию и специфику процесса оптимизации.

Более тонким инструментом анализа является радемахеровская сложность, связывающая способность класса функций к переобучению с эмпирическими оценками [4, раздел 2].

Определение 8 (Эмпирическая радемахеровская сложность). Пусть $\mathcal{F}$ — класс вещественных функций на $\mathcal{X}$, $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathcal{X}$ — конечная выборка, и $\sigma_1, \dots, \sigma_m$ — независимые случайные переменные Радемахера, то есть $\mathbb{P}\{\sigma_i = +1\} = \mathbb{P}\{\sigma_i = -1\} = 1/2$ для всех $i = 1, \dots, m$. Эмпирическая радемахеровская сложность класса $\mathcal{F}$ на выборке D определяется как

$$\hat{\mathfrak{R}}_D(\mathcal{F}) = \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(\mathbf{x}_i) \right],$$

где математическое ожидание берется по распределению случайных переменных Радемахера.

Определение 9 (Ожидаемая радемахеровская сложность). Ожидаемая радемахеровская сложность класса $\mathcal{F}$ для выборок размера m определяется как

$$\mathfrak{R}_m(\mathcal{F}) = \mathbb{E}_{D \sim \mathbb{P}^m} [\hat{\mathfrak{R}}_D(\mathcal{F})],$$

где математическое ожидание берется по распределению выборок D размера m , порожденных распределением $\mathbb{P}$ на $\mathcal{X}$.

Соответствующие неравенства связи с обобщающей способностью имеют вид

$$R(f) \leq \hat{R}_m(f) + 2\hat{\mathfrak{R}}_D(\mathcal{F}) + 3\sqrt{\frac{\log(2/\delta)}{2m}},$$

что позволяет учитывать адаптивность класса к конкретной выборке. Однако даже эти оценки остаются в основном асимптотическими и практически не отражают поведение современных нейронных сетей, имеющих миллионы параметров и сложные регуляризационные схемы [14]. Недостаток адаптивности классических мер к глубине, нелинейностям и особенностям оптимизации создает разрыв между теорией и практикой, который необходимо закрыть в дальнейших разделах обзора.

1.2.1. VC-размерность и ростовая функция

Одним из центральных понятий классической теории обучаемости является *ростовая функция* (англ. growth function) класса моделей.

Определение 10 (Индукцированные разметки). Для конечной выборки $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathcal{X}$ множество индуцированных разметок класса $\mathfrak{F}$ на выборке D определяется как

$$\mathfrak{F}|_D = \{(f(\mathbf{x}_1), \dots, f(\mathbf{x}_m)) : f \in \mathfrak{F}\} \subseteq \{0, 1\}^m.$$

Определение 11 (Ростовая функция). Ростовая функция класса $\mathfrak{F}$ определяется как

$$\Pi_{\mathfrak{F}}(m) = \max_{D \subset \mathcal{X}, |D|=m} |\mathfrak{F}|_D|,$$

где максимум берется по всем возможным выборкам D размера m из пространства $\mathcal{X}$.

Тривиальная верхняя оценка имеет вид $\Pi_{\mathfrak{F}}(m) \leq 2^m$. Если VC-размерность класса конечна и равна $d = \text{VC}(\mathfrak{F}) < \infty$, то лемма Сауэра [2, глава 5, лемма 5.1] обобщает эту грубую оценку и дает полиномиальный рост числа реализаций:

$$\Pi_{\mathfrak{F}}(m) \leq \sum_{k=0}^d \binom{m}{k} \leq \left(\frac{em}{d}\right)^d, \quad \text{для всех } m \geq d.$$

В сочетании с неравенствами концентрации это приводит к классическим оценкам равномерной сходимости эмпирического риска к истинному риску, которые лежат в основе принципа минимизации структурного риска.

Ключевым следствием конечности VC-размерности является возможность построения иерархии вложенных классов $\mathfrak{F}_1 \subset \mathfrak{F}_2 \subset \dots$ с возрастающей сложностью, что позволяет формализовать баланс между смещением и дисперсией модели. Однако на практике вычисление или даже оценка VC-размерности для сложных архитектур оказывается нетривиальной задачей: для линейных классификаторов в $\mathbb{R}^d$ верно $\text{VC}(\mathfrak{F}) = d + 1$, но для многослойных нейронных сетей VC-размерность оценивается как степенная функция от числа параметров и может быть астрономически велика, что делает полученные границы очень слабыми.

Кроме того, классические оценки через $\text{VC}(\mathfrak{F})$ не отражают влияние таких практических аспектов, как ранняя остановка, стохастическая оптимизация,

нормализация и другие регуляризаторы, которые существенно улучшают обобщающую способность, но никак не уменьшают формальную VC-размерность класса.

1.2.2. РАС-обучаемость: реализуемый и агностический случаи

В рамках РАС-подхода (англ. Probably Approximately Correct) различают два основных случая обучаемости: реализуемый и агностический. Для 0–1-потерь в бинарной классификации РАС-обучаемость сводится к поиску гипотезы с малой ошибкой обобщения при ограниченном числе прецедентов.

В реализуемой постановке предполагается, что существует модель $f^* \in \mathfrak{F}$, для которой $R(f^*) = 0$, то есть данные порождаются без шума в рамках выбранного класса. В этой ситуации удастся получить более сильные гарантии сходимости алгоритмов минимизации эмпирического риска:

$$\Pr \left\{ \sup_{f \in \mathfrak{F}} |R(f) - \hat{R}_m(f)| > \varepsilon \right\} \leq \delta,$$

при числе наблюдений $m(\varepsilon, \delta)$, логарифмически зависящем от $1/\delta$ и линейно зависящем от $VC(\mathfrak{F})$.

Примером служат линейные классификаторы в $\mathbb{R}^d$: для гиперплоскостей VC-размерность равна $d + 1$, и РАС-обучаемость достигается при $m = O((d/\varepsilon) \log(1/\varepsilon) + (1/\varepsilon) \log(1/\delta))$, что согласуется с персептроном Розенблатта. Связь с VC следует из леммы Vapnik–Chervonenkis [2, глава 5, теорема 5.1]: если $VC(\mathfrak{F}) = d < \infty$, то класс РАС-обучаем, с оценкой $m \geq (1/\varepsilon)(4d \log(13/\varepsilon) + \log(2/\delta))$.

В агностической постановке шум допускается, и оптимальная модель f^* достигает ненулевого риска $R(f^*) > 0$. В этом случае стандартной целью является достижение неравенства вида

$$R(f) \leq R(f^*) + \varepsilon$$

с вероятностью не менее $1 - \delta$. Соответствующие оценки на число наблюдений

имеют тот же порядок, что и в реализуемом случае, но константы и зависимости от параметров модели оказываются менее благоприятными. Следует подчеркнуть, что классические РАС-оценки делают акцент на наихудшем распределении данных и не используют информацию о структуре реальных задач.

Следует отметить, что РАС-анализ, как правило, не учитывает вычислительную сторону задачи: существование алгоритма, удовлетворяющего РАС-критериям, не гарантирует его практическую реализуемость с полиномиальной сложностью. Для глубоких нейронных сетей это особенно важно, так как реальное обучение основано на приближенных численных процедурах, которые не обязательно находят глобальный минимум риска.

1.2.3. Радемахеровская сложность и локальные оценки

Переход к радемахеровской сложности был мотивирован стремлением получить более точные, зависящие от данных оценки сложности класса функций. В отличие от VC-размерности, которая является глобальной характеристикой $\mathfrak{F}$, величина $\hat{\mathfrak{R}}_D(\mathcal{F})$ зависит от конкретной выборки D и потому позволяет учитывать геометрию данных. Через технику симметризации и цепочечные неравенства могут быть получены оценки общего вида

$$\mathbb{E} \left[\sup_{f \in \mathcal{F}} |R(f) - \hat{R}_m(f)| \right] \leq C \mathfrak{R}_m(\mathcal{F}),$$

где $\mathfrak{R}_m(\mathcal{F})$ — ожидаемая радемахеровская сложность, определенная выше.

Для типичных классов гладких функций могут быть получены явные верхние границы на $\mathfrak{R}_m(\mathcal{F})$ через нормы параметров и радиус области определения. Например, для линейных классификаторов

$$\mathcal{F} = \{x \mapsto \langle w, x \rangle : \|w\|_2 \leq B\},$$

при ограничении $\|x_i\|_2 \leq R$ для всех i верна оценка

$$\hat{\mathfrak{R}}_D(\mathcal{F}) \leq \frac{BR}{\sqrt{m}}.$$

Для нейронных сетей аналогичные оценки строятся через произведения норм весов по слоям, что уже лучше согласуется с эмпирическими наблюдениями о роли регуляризации весов.

Однако и здесь сохраняется ряд принципиальных ограничений. Во-первых, получение достаточно точных верхних границ для глубоких архитектур приводит к сильно завышенным оценкам, поскольку приходится применять грубые неравенства при переходе от нелинейных слоев к линейным аппроксимациям. Во-вторых, стандартные радемахеровские оценки учитывают только статический класс функций и не отражают динамику обучения, в частности, влияние траектории градиентного спуска и стохастичности минибатчей. В-третьих, даже будучи зависящими от данных, эти оценки по-прежнему нацелены на наихудший случай и плохо согласуются с наблюдаемой в практике устойчивостью крупных моделей к шуму в данных.

1.2.4. Комбинаторный подход Воронцова

Значительный вклад в развитие комбинаторной теории надежности обучения по прецедентам внес К.В. Воронцов, развивший идеи В.Н. Вапника и А.Я. Червоненкиса в русле комбинаторных границ для статистического обучения [5]. В его докторской диссертации [35, раздел 2] предложен комбинаторный подход к снижению оценок Вапника–Червоненкиса, основанный на учете структуры данных и специфики класса гипотез. Ключевая идея заключается в том, что классические VC-оценки используют анализ худшего случая и не учитывают комбинаторные свойства конкретной выборки, что приводит к завышенным границам на вероятность переобучения.

В рамках комбинаторного подхода Воронцов вводит меры, такие как α -расширение класса гипотез и энтропийные характеристики, которые позволяют получить более точные оценки вероятности переобучения. Для класса $\mathcal{F}$ с конечным VC-размером d комбинаторные оценки дают вероятность ошибки

обобщения вида [35, раздел 1.5]

$$\Pr\{R(f) - \hat{R}_m(f) > \varepsilon\} \leq 8\Pi_{\mathfrak{F}}(2m)e^{-m\varepsilon^2/32},$$

где $\Pi_{\mathfrak{F}}(2m)$ контролируется комбинаторными свойствами прецедентов, а не только глобальной VC-размерностью. В отличие от классических оценок, которые зависят только от $VC(\mathfrak{F})$ и размера выборки m , комбинаторный подход учитывает структуру данных через энтропийные характеристики, что позволяет получить более точные границы для конкретных задач.

Ключевым преимуществом комбинаторного подхода является возможность существенного снижения оценок по сравнению со стандартными границами Вапника–Червоненкиса. Это достигается за счет учета специфических свойств выборки, таких как коррелированность объектов, наличие кластерной структуры или дискретная природа данных. Воронцов также предложил алгоритмы для эмпирического расчета таких границ, что делает подход применимым к реальным задачам прецедентного обучения, в особенности в задачах распознавания образов, где данные имеют дискретную структуру.

Отдельно стоит подчеркнуть, что в диссертации Воронцова [35] установлена формальная связь комбинаторного подхода с радемахеровской сложностью [4]. В работе [35, раздел 2.2.1] показано, что комбинаторные оценки могут быть выражены через эмпирическую радемахеровскую сложность. Для класса функций $\mathfrak{F}$ и выборки D верна оценка

$$\hat{\mathfrak{R}}_D(\mathfrak{F}) \leq \sqrt{\frac{2 \log \Pi_{\mathfrak{F}}(m)}{m}},$$

где $\Pi_{\mathfrak{F}}(m)$ — ростовая функция класса $\mathfrak{F}$, контролируемая комбинаторными свойствами прецедентов. Обратно, комбинаторные границы на вероятность переобучения могут быть переформулированы через радемахеровскую сложность [35, раздел 2.2]:

$$\Pr\{R(f) - \hat{R}_m(f) > \varepsilon\} \leq \exp\left(-\frac{m\varepsilon^2}{8\hat{\mathfrak{R}}_D^2(\mathfrak{F}) + 2\varepsilon}\right),$$

что позволяет объединить преимущества обоих подходов: адаптивность к данным, характерную для радемахеровской сложности, и комбинаторную структуру, учитывающую специфику прецедентного обучения. Эта формальная связь демонстрирует, что комбинаторный подход не является изолированным методом, а естественным образом дополняет и развивает классические меры сложности, включая VC-размерность и радемахеровскую сложность.

Комбинаторный подход дополняет классический VC-анализ более адаптивными метриками, которые могут быть существенно ниже стандартных оценок, что особенно важно для практических приложений, где классические границы худшего случая оказываются слишком консервативными. Этот подход подчеркивает роль комбинаторной оптимизации в контроле сложности и демонстрирует, что учет структуры данных позволяет получать более реалистичные оценки обобщающей способности моделей.

1.2.5. Ограничения классических мер

Суммируя рассмотренные подходы, выделим следующие ключевые ограничения классических мер сложности в контексте современных моделей глубокого обучения.

Во-первых, большинство оценок строится в предположении фиксированного, конечномерного пространства признаков и не учитывает появление дополнительных структур, таких как сверточные фильтры, остаточные связи и механизмы внимания, которые существенно меняют эффективную сложность класса моделей.

Во-вторых, как VC-размерность, так и радемахеровская сложность ориентированы на анализ худшего случая и не используют специфические свойства реальных распределений данных, такие как низкая размерность многообразия, коррелированность признаков или наличие сильных инвариантностей. В результате получаемые границы оказываются слишком консервативными и часто

на несколько порядков хуже эмпирически наблюдаемых характеристик.

В-третьих, классические меры, как правило, рассматривают модель и данные отдельно: сложность гипотезы оценивается независимо от сложностей выборки, а влияние распределения на обучение учитывается лишь через общие вероятностные предположения. Для глубоких нейросетевых архитектур, где наблюдается сложное взаимодействие между параметрами, структурой данных и алгоритмом оптимизации, такое раздельное рассмотрение оказывается недостаточным для объяснения эмпирических фактов.

Четвертое ограничение заключается в том, что классические результаты в основном фокусируются на асимптотических режимах $m \rightarrow \infty$ и не описывают поведение моделей при конечных, но больших размерах выборок, характерных для реальных задач. Это особенно заметно при анализе крупных языковых и мультимодальных моделей, для которых наблюдаются устойчивые законы масштабирования качества от размера данных и модели, выходящие за рамки традиционных теоретических предсказаний.

Таким образом, классические меры сложности остаются необходимым основанием диссертационного исследования, но не дают полного описания рассматриваемой проблемы. Они отвечают на вопрос о емкости класса гипотез и возможности равномерной сходимости, тогда как в глубоких моделях существенными становятся свойства найденного решения, динамика оптимизации и согласование модели с данными. Поэтому далее обзор переходит от изложения классических определений к анализу современной литературы, где сложность рассматривается через несколько взаимосвязанных характеристик.

1.3. Методология обзора

Переход от классических определений к современным подходам требует явно зафиксировать, какие направления литературы рассматриваются и каким образом они отбираются. Задача настоящего раздела состоит в том, чтобы охва-

тить основные направления теоретической литературы о сложности и обобщении в методах машинного обучения, зафиксировать процедуру построения корпуса и обеспечить воспроизводимость отбора на уровне источников данных и критериев включения. Данный обзор не заменяет систематический обзор с полной регистрацией протокола по стандартам PRISMA (англ. Preferred Reporting Items for Systematic Reviews and Meta-Analyses), однако позволяет явно разделить широкий поисковый охват и содержательный анализ.

Первичный библиографический сбор публикаций по тематике исследования выполняется по трем открытым агрегаторам научных публикаций — OpenAlex¹, arXiv² и Crossref³. Поиск выполняется посредством однотипных по смыслу поисковых запросов. Запросы охватывают классические и современные направления исследований. К классическим относятся VC-размерность и радемахеровская сложность. К современным — PAC-байесовские и информационно-теоретические границы обобщения, алгоритмическая устойчивость, ландшафт функции потерь, спектр гессиана, двойной спуск, нейронное касательное ядро, режимы обучения, законы масштабирования, а также архитектуры трансформеров и диффузионных моделей. Для каждой формулировки запроса из каждого источника извлекается по 100 записей. Затем результаты объединяются в единый список публикаций с заголовками и, по возможности, аннотациями.

Записи с разных источников сопоставляются по идентификаторам DOI, совпадению нормализованных заголовков и близким полям описания. Дубликаты объединяются, причем для каждой уникальной работы сохраняется информация о числе поисковых попаданий и перечне запросов, которые ведут к включению работы в список. Такой подход учитывает устойчивость темы к различным формулировкам запроса, не подменяя содержательный отбор автоматически собранными показателями.

¹OpenAlex API: <https://developers.openalex.org/api-reference/introduction#api-overview>.

²arXiv API: <https://info.arxiv.org/help/api/index.html>.

³Crossref REST API: <https://www.crossref.org/documentation/retrieve-metadata/rest-api/>.

Полный дедуплицированный массив по объему не подлежит содержательному анализу целиком. Следовательно, на следующем этапе к каждой записи применяется правило-ориентированная процедура ранжирования, использующая данные заголовка и аннотации. Процедура учитывает совпадение с теоретически существенными лексическими шаблонами и принадлежность к заранее заданным тематическим группам, таким как классические методы, РАС-байесовские методы и информация, ландшафт и гессиан, режимы обучения нейронного касательного ядра (англ. Neural Tangent Kernel, NTK) и двойного спуска, масштабирование и архитектуры. Дополнительно учитывается число независимых поисковых попаданий и штрафы за доминирование узко прикладного контекста при слабой теоретической базе публикации. Все найденные публикации дополнительно распределяются по тематическим группам с ограничением перекоса, чтобы сокращенный перечень кандидатов сохранял представительность по исследовательским направлениям, а не сводился к одной выделенной области исследований. В результате для экспертного разбора формируется сокращенный перечень из 500 релевантных записей.

На этапе ручного отбора из сокращенного списка кандидатов исключаются публикации, в которых термины обобщения и сложности использовались преимущественно в прикладном или узкоотраслевом значении без теоретического вклада в предметную область. Также исключаются работы, не добавляющие к обзору нового содержания относительно уже включенных источников. Предпочтение отдается публикациям, удовлетворяющим условиям: (1) формулируется фундаментальный теоретический результат или нетривиальная оценка сложности, (2) предлагается современный механизм, существенный для понимания сложности, (3) фиксируется устойчивый эмпирический результат, который теория сложности обязана учитывать.

Независимо от сокращенного списка кандидатов в итоговый перечень публикаций вручную включен набор фундаментальных источников по статистической теории обучения, устойчивости, ключевым архитектурам и режимам

обучения. Такое дополнение методологически обосновано тем, что ранние канонические работы и отдельные базовые публикации по современным архитектурам не всегда устойчиво поднимаются в выдаче поиска по ключевым словам, ориентированного на недавнюю прикладную и вторичную литературу. Без явного включения этих источников корпус искажался бы в сторону современных обзоров.

Т а б л и ц а 1.1

Тематическое распределение кандидатов и финального корпуса

Тематическая группа	В 500	Доля, %	Auto	Manual+	В финале
Классические границы	101	20.2	13	6	19
РАС-байесовские методы и информация	120	24.0	5	2	7
Ландшафт и гессиан	96	19.2	11	4	15
Режимы обучения	84	16.8	11	4	15
Масштабирование и архитектуры	45	9.0	7	4	11
Обзорные работы	54	10.8	9	0	9
Итого	500	100.0	56	20	76

Итоговый аналитический корпус включает 76 публикаций, из них 13 опорных работ по ключевым направлениям обзора, 44 дополнительных источника для контекста и сопоставления близких направлений и 19 зафиксированных фундаментальных работ. Из табл. 1.1 видно, что в списке из 500 кандидатов крупнейшие доли имеют вероятностно-информационная и классическая группы. Наблюдаемая неравномерность групп отражает свойства поисковой процедуры и текущую структуру доступной литературы, а не априорную иерархию важности направлений.

Несмотря на формализованную процедуру отбора, предложенная методология имеет ряд ограничений. Во-первых, поиск опирается на покрытие выбранных библиографических агрегаторов и может неполно отражать работы, индексируемые неравномерно или с задержкой. Во-вторых, ключевые запросы и лексические шаблоны неизбежно задают тематическое смещение, так как они преимущественно извлекают публикации, использующие устоявшийся сло-

варь теории обобщения, по сравнению с работами с близким содержанием, но иной терминологией. В-третьих, правило-ориентированное ранжирование и последующий экспертный отбор снижают шум, но сохраняют зависимость от выбранной исследовательской постановки обзора. В-четвертых, обзор предметной области ориентирован на структурирование области и сравнительный анализ, а не на метаанализ, поэтому выводы носят концептуальный, а не статистически агрегированный характер. Представленная процедура не претендует на полноту в смысле систематического обзора всех существующих публикаций по теме. Назначение работы — обеспечить прозрачный путь от широкого поиска к управляемому набору источников и зафиксировать границы обзорного анализа.

1.4. Классические и информационно-теоретические оценки

После введения формальных определений рассмотрим, какую роль классические и вероятностно-информационные меры играют в современной теории глубокого обучения. Здесь они анализируются уже не как набор изолированных определений, а как направления литературы, каждое из которых объясняет отдельный аспект обобщающей способности и одновременно имеет собственные ограничения. Классическая теория обучения связывает обобщение с контролем мощности класса гипотез. VC-размерность измеряет способность класса реализовывать все возможные бинарные разметки на конечных выборках и тем самым служит критерием равномерной сходимости эмпирического риска к истинному [2]. В PAC-постановке это приводит к оценкам требуемого объема выборки через параметры точности и сложность класса [3]. Для классов гипотез умеренной сложности такая картина остается концептуально строгой: конечная VC-размерность означает обучаемость, а рост сложности увеличивает требования к данным. Для бинарной задачи это выражается оценкой обобщения через

VC-размерность:

$$R(h) \leq \hat{R}_S(h) + \sqrt{\frac{d_{VC} \left(\log \frac{2n}{d_{VC}} + 1 \right) + \log \frac{4}{\delta}}{n}}, \quad (1.1)$$

где $R(h)$ — истинный риск, $\hat{R}_S(h)$ — эмпирический риск на выборке S объема n , d_{VC} — VC-размерность класса, $\delta \in (0, 1)$ — уровень доверия.

Для моделей с большим числом параметров VC-оценки становятся завышенными и перестают быть информативными. Поэтому для глубоких моделей машинного обучения VC-размерность сохраняет значение как формальное понятие статистической теории сложности, но не дает ответа на вопрос, почему обученная модель демонстрирует обобщающую способность. Проблема в том, что если две модели имеют одинаковую архитектуру, то их VC-размерность совпадает с точностью до порядка величины, однако после обучения они ведут себя по-разному. Следовательно, сама мощность класса не определяет тот объект, который фактически определяет качество модели.

Отдельно стоит упомянуть комбинаторный подход [5], который учитывает структуру выборки, а не только грубую оценку в худшем случае класса. В рамках этого подхода объектом исследования остается класс гипотез, а не локальные геометрические характеристики решения в параметрическом пространстве.

Дальнейшим развитием теории сложности является радемахеровская сложность [4, 36], которая зависит от рассматриваемой выборки и учитывает геометрию данных [37, 38]. Для линейных моделей и некоторых специальных классов моделей радемахеровский подход дает более точные оценки. Данный подход применяется в глубоком обучении, поскольку оценки, зависящие от выборки, частично отделяют реально наблюдаемую сложность задачи от чисто комбинаторной мощности класса моделей [37, 38]. Современные исследования развивают радемахеровскую сложность в нескольких направлениях. Например, для обобщения классических оценок [39], а также оценок для сложных классов функций [40]. Различные обзорные работы, также подчеркивают, что радемахе-

ровский подход для глубоких сетей связан не столько с поиском одной универсальной оценки, сколько с выявлением границ применимости моделей [41, 42]. Эмпирическая радемахеровская сложность класса $\mathcal{H}$ на выборке $S = (x_i)_{i=1}^n$ определяется выражением:

$$\hat{\mathfrak{R}}_S(\mathcal{H}) = \mathbb{E}_\sigma \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right],$$

где $\sigma_i \in \{-1, +1\}$ — независимые случайные знаки Радемахера. Для липшицевых потерь оценка принимает вид:

$$R(h) \leq \hat{R}_S(h) + 2 \hat{\mathfrak{R}}_S(\mathcal{H}) + 3 \sqrt{\frac{\log(2/\delta)}{2n}}.$$

Разница радемахеровского подхода с VC-размерностью (1.1) состоит в том, что сложность зависит от заданной выборки, а не только от мощности класса функций. Однако радемахеровские оценки по-прежнему характеризуют весь класс функций, тогда как обучение исследует лишь малую и структурированную его часть. Поэтому две модели одинаковой архитектуры, обученные разными оптимизаторами или с разными инициализациями, могут иметь сопоставимые оценки сложности сверху, но заметно отличаться по обобщающей способности.

С практической точки зрения важно, что оценки, зависящие от выборки, часто оказываются содержательными лишь после введения дополнительных структурных ограничений, таких как ограничение норм весов, липшицевых ограничений или специальных возмущений данных. Ввод специальных ограничений делает решение не полным, так как для получения оценки требуется заранее встраивать в модель информацию о геометрии решения, то есть теория частично объясняет обобщение, а частично уже предполагает его.

С другой стороны, достоинство PAC-байесовских оценок состоит в том, что они связывают обобщение не только с функцией, но и с распределением над параметрами. Базовые постановки этого подхода даны в [43, 44], а современные обобщения и обзорные интерпретации представлены в [45, 46, 47, 48]. На практике эти оценки оказываются одними из наиболее содержательных среди

современных оценок. Внутри этого же направления появляются и более специализированные приложения, например анализ стохастического градиентного спуска в РАС-байесовском подходе [49, 50]. Однако и эти оценки зависят от выбора априорного распределения, формы возмущений и параметризации и потому задают скорее гибкую математическую постановку, чем прямое объяснение того, почему заданная модель глубокого обучения достигает решения с высокой обобщающей способностью. В одной из канонических форм РАС-байесовская оценка записывается как

$$\mathbb{E}_{\theta \sim Q} R(\theta) \leq \mathbb{E}_{\theta \sim Q} \hat{R}_S(\theta) + \sqrt{\frac{\text{KL}(Q \| P) + \log \frac{2\sqrt{n}}{\delta}}{2(n-1)}}, \quad (1.2)$$

где P — априорное распределение, Q — апостериорное, $\text{KL}(Q \| P)$ — дивергенция Кульбака–Лейблера. В (1.2) видно, что сложность перенесена с класса функций на стоимость перехода от априорного распределения к апостериорному через KL-дивергенцию.

Задача в рамках информационно-теоретического подхода ставится иначе. Он связывает ошибку обобщения с количеством информации, извлекаемой алгоритмом из данных [51]. В глубоких моделях машинного обучения при этом сохраняются трудности с получением численных оценок. Примером такого результата является оценка:

$$|\mathbb{E}[R(W) - \hat{R}_S(W)]| \leq \sqrt{\frac{2\sigma^2}{n} I(W; S)}, \quad (1.3)$$

где W — параметры после обучения, $I(W; S)$ — взаимная информация между параметрами и выборкой, σ — параметр субгауссовости потерь. Неравенство (1.3) отражает алгоритмическую сложность, то есть чем меньше информации, записанной в параметрах выборки, тем ниже ожидаемая ошибка обобщения.

В совокупности эти подходы указывают на методологический сдвиг. Теория постепенно отказывается от предположения, что существует одна универсальная мера сложности, одинаково адекватная для всех методов обучения. Вместо этого формируется набор частичных, но более предметных описаний: одни

применимы к анализу класса функций, другие — к стохастической динамике алгоритма, третьи — к локальной устойчивости уже найденного решения. В литературе этот сдвиг описывается как переход от единой статистической меры сложности к семейству взаимодополняющих описаний. Этот тезис последовательно проводится как в обзорных работах [52, 53, 54], так и в теоретических работах [55, 56, 57, 58].

Одним из важных направлений исследований теории сложности является теория устойчивости моделей машинного обучения [59, 60]. Данная теория занимает промежуточное положение между классической статистической теорией и современной алгоритмической постановкой вопроса. С одной стороны, устойчивость по-прежнему связана с обобщением через формальные оценки сверху. С другой стороны, устойчивость напрямую зависит от свойств алгоритма и потому анализирует реальный процесс обучения, а не только класс гипотез. Для глубокого обучения это связано с тем, что стохастический градиентный спуск является шумным и траекторно-зависимым алгоритмом. Устойчивость тесно связана с размером батча, длительностью обучения, кривизной ландшафта и типом регуляризации. Поэтому устойчивость оказывается полезной не столько как самостоятельная универсальная мера сложности, сколько как часть более широкой картины, связывающей оптимизацию и геометрию. В этой постановке теория устойчивости помогает понять, почему современные исследования все чаще рассматривают сложность как свойство процесса обучения модели, а не только класса функций модели. Она не решает проблему полностью, но указывает направление развития: от емкостных описаний к алгоритмозависимым описаниям. В канонической постановке для β -устойчивого алгоритма используется оценка вида

$$|R(A(S)) - \hat{R}_S(A(S))| \leq \beta, \quad (1.4)$$

где A — алгоритм обучения, S — обучающая выборка, β — параметр устойчивости. Запись (1.4) фиксирует формальную связь между устойчивостью алго-

ритма и ошибкой обобщения.

Ограниченность классических мер сложности проявляется не в том, что они неверны, а в том, что они описывают иной уровень абстракции по сравнению с тем, который требуется для анализа современных глубоких моделей. В перепараметризованных моделях важно не только то, насколько велик класс возможных функций, но и то, какое подмножество решений реально достижимо конкретным методом оптимизации, каковы локальные геометрические характеристики этих решений и какие индуктивные смещения встроены в архитектуру. Эти идеи проявились после работ, показавших, что глубокие сети способны идеально настраиваться на случайные метки, оставаясь при этом успешными на реальных данных [61]. Отсюда следует вывод, что теория сложности для глубокого обучения не ограничивается контролем емкости класса гипотез. Она учитывает, по меньшей мере, три дополнительных аспекта: *алгоритм обучения, локальные геометрические характеристики решений и структуру данных, согласованную с архитектурой*. Это и мотивирует переход к современным геометрическим и ландшафтным подходам.

1.5. Ландшафт функции потерь

Ограничения емкостных и вероятностно-информационных оценок приводят к необходимости анализировать не только весь класс функций, но и конкретные решения, найденные алгоритмом обучения. Если классические меры оценивают пространство всех потенциально допустимых решений, то ландшафтные подходы ориентированы на анализ свойств локальных минимумов, к которым приводит обучение. Интерес к данному направлению усилился после работ по визуализации ландшафта потерь, показавших, что решения с высокой обобщающей способностью часто располагаются в более широких областях пространства параметров [62, 63, 64]. Идея плоских минимумов как возможного объяснения этого эффекта восходит к ранним работам по нейронным сетям [65].

В дальнейшем она была переосмыслена в терминах спектра гессиана, локальной устойчивости и неявной регуляризации алгоритмов обучения, а также в терминах нормализованных и параметризационно-устойчивых характеристик плоскости [66].

В данном направлении понятие сложности получает иную интерпретацию. Речь идет не о размере класса реализуемых функций, а о свойствах найденного решения в локальной геометрии. В этом смысле ландшафтная сложность оказывается ближе к эффективной сложности обучения, чем к абстрактной мощности параметрического семейства.

В этом направлении часто используется анализ гессиана функции потерь и его спектра. Эмпирические работы показывают типичную структуру спектра, где мало доминирующих направлений кривизны и много почти плоских направлений [67, 68, 69]. Это согласуется с гипотезой, что решения с высоким обобщением чаще лежат не в острых изолированных минимумах, а в более широких областях параметрического пространства. Локальная геометрия задается матрицей гессиана

$$H(\theta) = \nabla_{\theta}^2 \mathcal{L}(\theta),$$

а ее спектральные характеристики описываются вещественными собственными значениями (для симметричной матрицы Гессе), упорядоченными по невозрастанию:

$$\lambda_1(\theta) \geq \lambda_2(\theta) \geq \dots \geq \lambda_p(\theta).$$

Для дважды непрерывно дифференцируемой функции потерь матрица $H(\theta)$ симметрична; в общем случае собственные значения могут быть отрицательными, что соответствует направлениям положительной и отрицательной кривизны. В эмпирических исследованиях минимумов глубоких моделей часто обсуждают преобладание направлений с малыми по модулю или неотрицательными собственными значениями, однако универсальная неотрицательность спектра без дополнительных предположений не следует. Важными характери-

ками ландшафта остаются спектральный радиус $\|H(\theta)\|_2 = \max_i |\lambda_i(\theta)|$ и след $\text{tr}(H) = \sum_i \lambda_i$, отражающие, соответственно, масштаб кривизны в наиболее крутом направлении и суммарную кривизну в окрестности найденного решения.

С этой точки зрения плоские минимумы представляют интерес по двум причинам. Во-первых, они более устойчивы к малым возмущениям параметров и потому потенциально демонстрируют более стабильный перенос на новые данные. Во-вторых, они отражают не только свойства класса моделей, но и свойства траектории, посредством которой алгоритм достиг найденного решения. Поэтому связь между ландшафтом и обобщением тесно переплетается с анализом оптимизации.

Существуют и попытки формализовать эту интуицию в виде количественных мер. В частности, в недавних работах на основе гессиана предлагаются величины, характеризующие вариабельность кривизны по примерам и связывающие локальную геометрию с объемом выборки и устойчивостью обучения [70]. Значение таких подходов состоит в переводе обсуждения плоских и острых решений из качественной плоскости в количественную. В более широком контексте это направление включает также оценки, использующие представления о сложности через внутренние представления и предпочтение более простых функций в параметрическом отображении [71, 72].

Наряду с этим были предложены и алгоритмические методы, специально ориентированные на предпочтение широких минимумов. К таким работам относятся как анализ влияния размера батча и остроты минимума [73], так и методы, явно управляющие локальными геометрическими характеристиками решения, включая метод минимизации с учетом остроты (англ. Sharpness-Aware Minimization, SAM) и его более поздние обобщения на режим Edge of Stability (границы устойчивости) [74, 75]. Дополнительно есть работы, где предпочтение широких минимумов связывается с фильтрацией высокочастотных компонент стохастической динамики [76]. Это важно, поскольку влияние оптимизатора

на локальные геометрические характеристики решения означает необходимость учитывать в теории сложности не только архитектуру модели, но и динамику алгоритма. Для SAM целевая функция имеет характерную мини-макс форму:

$$\min_{\theta} \max_{\|\varepsilon\|_2 \leq \rho} \mathcal{L}(\theta + \varepsilon), \quad (1.5)$$

где ρ задает радиус локального возмущения. Выражение (1.5) формализует идею избегания острых минимумов в явной оптимизационной постановке и связывает выбор алгоритма с геометрией получаемого решения.

На стыке геометрии и оптимизации проявляется различие между классической и современной постановкой вопроса. В статистической теории обучения алгоритм часто рассматривался как вторичный элемент. Сначала задавался класс гипотез, затем для него выводились общие оценки. В глубоком обучении ситуация принципиально иная. Один и тот же класс гипотез, обученный разными вариантами стохастического градиентного спуска, может приводить к решениям с различной локальной кривизной и различным качеством обобщения. Поэтому шум стохастической оптимизации, размер батча и свойства траектории становятся частью самой теории сложности, а не внешней технической деталью [60, 59].

С этой точки зрения, оптимизатор действует как механизм отбора решений внутри большого перепараметризованного пространства. Даже если класс допустимых функций чрезвычайно богат, реальная траектория SGD не исследует его равномерно. Вместо этого она систематически приводит к решениям с определенными геометрическими характеристиками, чувствительностью к возмущениям и структурой признаков. Следовательно, эффективная сложность оказывается результатом совместного действия архитектуры, данных и алгоритма оптимизации. Современные работы описывают этот механизм на разных уровнях: от диффузионной аппроксимации, в которой SGD экспоненциально предпочитает плоские минимумы [77], до анализа динамической устойчивости, границы устойчивости и детальных оценок устойчивости самого стохастическо-

го градиентного спуска [78, 79, 80].

Этот подход связывает локальный анализ гессиана с более глобальными вопросами стабильности обучения. Если решение лежит в области, устойчивой к шуму оптимизации и малым возмущениям параметров, то его свойства могут согласовываться с более высоким обобщением. Тем самым ландшафтный анализ связывает геометрию минимумов и алгоритмическую теорию устойчивости. Такая интерпретация согласуется с работами о фрактальной структуре стохастической оптимизации, где свойства траектории и свойства обобщения рассматриваются совместно [81].

В анализе плоских минимумов необходимо учитывать методологическую проблему. Геометрия в пространстве параметров не всегда напрямую соответствует геометрии в пространстве функций. Для нейронных сетей характерны перенормировки, симметрии слоев и другие преобразования параметров, которые могут заметно менять локальную кривизну без изменения реализуемой функции. Поэтому простая интерпретация вида «более плоский минимум означает более высокое обобщение» требует оговорки. Отсюда вытекают два следствия. Во-первых, ландшафтные меры нужно по возможности строить так, чтобы они были более устойчивы к параметризационным артефактам или хотя бы явно учитывали их наличие. Во-вторых, эмпирическая полезность таких мер не отменяет необходимости осторожной причинной интерпретации. Если плоскость зависит от выбора параметризации, то она, вероятно, является не самостоятельной причиной высокого обобщения, а наблюдаемым маркером более глубокой структуры. Практическое направление решения этой проблемы связано с инвариантными или квази-инвариантными мерами. В литературе используются нормализованные варианты остроты минимума, в которых локальная кривизна масштабируется параметрами слоя или нормы весов [66]. Указанные ограничения не отменяют использование ландшафтного подхода, а уточняют границы его применимости. В наиболее строгой постановке речь идет не о тезисе плоских минимумов вообще, а о связи обобщения с устойчивыми геомет-

рическими свойствами решений, достигаемых конкретной динамикой обучения. Такая формулировка согласуется с современными эмпирическими данными и необходимостью учитывать архитектурную специфику.

Основное достоинство ландшафтного подхода состоит в том, что он описывает свойства уже найденного решения. Это позволяет частично компенсировать основной недостаток классических мер сложности — их слабую чувствительность к алгоритму и режиму обучения. Кроме того, геометрические характеристики естественно связываются с такими современными явлениями, как неявная регуляризация, влияние размера батча и различия между оптимизаторами [59, 60]. С другой стороны, у данного направления есть ряд недостатков. Во-первых, вычисление гессиана или даже его устойчивых спектральных характеристик остается ресурсоемкой задачей для больших моделей. Во-вторых, причинная интерпретация плоских минимумов далека от окончательной ясности: решения с высоким обобщением могут быть плоскими не потому, что плоскость сама по себе вызывает обобщение, а потому, что и плоскость, и хорошее обобщение являются следствиями более глубокой структуры данных и оптимизации. В-третьих, локальная геометрия фиксирует свойства конкретной точки, но не заменяет более широкую теорию методов обучения и масштабирования. Поэтому ландшафтный анализ следует понимать не как окончательную замену классических мер сложности, а как часть более общего теоретического аппарата, в котором учитываются геометрия решения, алгоритм его поиска и структура данных.

1.6. Эмпирические оценки сложности

Геометрические характеристики решений важны не только сами по себе, но и как возможное объяснение эмпирических закономерностей, наблюдаемых при изменении размера модели, объема данных и вычислительного бюджета. Эмпирически показано, что простая монотонная связь между сложностью и ошиб-

кой обобщения не выполняется. Это видно в классических работах по двойному спуску [82, 83], а также в последующих уточнениях для различных режимов и моделей [84, 85, 86]. Если в классических мерах сложности рост сложности модели после некоторой точки должен лишь ухудшать обобщение, то в реальности часто наблюдается другое. Сначала ошибка падает, затем возрастает, а затем снова уменьшается. Явление двойного спуска не образует завершенной теории, однако остается эмпирическим фактом. Оно показывает, что сложность в глубоком обучении не сводится к единственной скалярной величине вроде числа параметров или грубой мощности класса гипотез. Причем в разных режимах обучения одна и та же архитектура может функционировать по-разному, а качество обобщения определяется тем, в каком режиме обучения и при какой параметризации она работает. Для описания феномена двойного спуска используется кусочно-заданная форма тестовой ошибки

$$\mathcal{E}_{\text{test}}(m) \approx \begin{cases} \downarrow, & m < m_{\text{int}}, \\ \uparrow, & m \approx m_{\text{int}}, \\ \downarrow, & m > m_{\text{int}}, \end{cases} \quad (1.6)$$

где m — параметр сложности модели, m_{int} — интерполяционный порог. Запись (1.6) формализует немонотонность зависимости «сложность–ошибка».

В рамках режимной интерпретации двойного спуска обычно выделяются три фазы. До интерполяционного порога доминирует режим недообученной аппроксимации, и рост сложности чаще снижает смещение. Вблизи порога m_{int} усиливается чувствительность к шуму и нестабильности оптимизации, что приводит к локальному росту тестовой ошибки. После порога в сильно перепараметризованной области начинает доминировать режим селективной оптимизации, в котором алгоритм чаще находит решения с более благоприятной локальной геометрией.

Современная интерпретация этой проблемы часто формулируется в терминах двух режимов обучения. В достаточно широких нейросетевых моделях обу-

чение может быть близко к линеаризованному режиму, где динамика хорошо описывается через нейронное касательное ядро [87, 88, 89]. В этом случае модель ведет себя почти как ядерный метод, а часть классических гарантий становится более применимой. В этом режиме используется линеаризованная динамика предсказаний вида

$$f_{t+1}(x) \approx f_t(x) - \eta K_{\theta_0}(x, X) \nabla_f \mathcal{L}(f_t(X), y), \quad (1.7)$$

где K_{θ_0} — НТК в точке инициализации θ_0 , η — шаг обучения. Формула (1.7) задает формальный переход к ядерной аппроксимации в широких сетях.

Однако на практике в моделях глубокого обучения доминирует другой режим — обучение признаков, в котором внутренняя репрезентация данных существенно меняется по ходу оптимизации. Этот режим в большей степени согласуется с современными эмпирическими результатами, но в меньшей степени поддается классическому анализу. Ограничения НТК-приближений и роль эволюции признаков обсуждаются в [90, 91], а также в более поздних работах [92, 93]. В таком режиме эффективная сложность определяется не только архитектурой, но и траекторией перестройки признакового пространства, а значит снова выводит нас к геометрии решения и динамике оптимизации. Режимы обучения служат связующим звеном между классической статистической теорией и ландшафтным анализом. Они позволяют объяснить, почему одна и та же модель может подчиняться различным схемам в зависимости от размера модели, данных и метода оптимизации.

Формально различие между режимами можно зафиксировать через динамику касательного ядра. В НТК-режиме выполняется приближение

$$\|K_{\theta_t} - K_{\theta_0}\| \ll \|K_{\theta_0}\|, \quad (1.8)$$

поэтому обучение близко к линеаризованной модели с почти фиксированными признаками. В режиме обучения признаков существенной является противоположная ситуация

$$\|K_{\theta_t} - K_{\theta_0}\| = \mathcal{O}(1), \quad (1.9)$$

и тогда ключевым объектом анализа становится дрейф представлений. Соотношения (1.8)–(1.9) задают математический критерий, почему одна и та же архитектура требует разных мер сложности в разных режимах обучения.

Режимный анализ важен не только как теоретическая классификация, но и как средство интерпретации экспериментальных результатов. Когда модель находится ближе к ядерному режиму, ее поведение оказывается сравнительно более предсказуемым, а роль оптимизации сводится к подбору коэффициентов в почти фиксированном признаковом пространстве. Когда же обучение протекает в режиме обучения признаков, ключевым объектом анализа становится эволюция представлений, а следовательно, сложность должна описывать уже не только выходную функцию, но и динамику внутренней репрезентации.

Здесь проявляется причина, по которой одна универсальная мера сложности не получает убедительного теоретического обоснования. Показатель, эффективный в почти линеаризованном режиме, может оказаться малоинформативным в режиме активного обучения признаков. Следовательно, корректнее говорить не о единственной численной сложности, а о семействе взаимодополняющих описаний, чья применимость зависит от фазы обучения и архитектурного режима. Режимы обучения рассматриваются как объяснительный слой между общими теоретическими оценками и практикой больших нейронных сетей.

Еще одно современное направление связано с эмпирическими законами масштабирования. Базовые результаты для языковых моделей даны в [30, 29], а последующие обобщения и поправки обсуждаются в [94, 95]. Эти результаты показывают, что качество моделей часто изменяется по степенным законам при росте числа параметров, объема данных и вычислительного бюджета. Соответствующие зависимости оказываются практически полезными для проектирования больших моделей, однако сами по себе не дают объяснения механизма обобщения. В литературе этот блок рассматривается как отдельный макроуровень описания, связывающий теорию обобщения с инженерной практикой построения больших моделей [52, 53, 54]. В упрощенной форме такие зависимости

записываются как

$$\mathcal{L}(N, D, C) \approx \mathcal{L}_\infty + aN^{-\alpha} + bD^{-\beta} + cC^{-\gamma}, \quad (1.10)$$

где N — число параметров, D — объем данных, C — вычислительный бюджет, $\alpha, \beta, \gamma > 0$ — эмпирические показатели масштабирования. Формула (1.10) удобна как макроописание, но не задает сама по себе механизма, через который именно эти показатели возникают в разных режимах обучения.

Для трансформеров и диффузионных моделей наблюдается следующая картина. Эти архитектуры продемонстрировали масштабируемость, имеющую прикладное значение [96, 97]. В то же время для них отсутствует единая теория сложности, которая одновременно учитывала бы архитектурную специфику, оптимизацию, геометрию решения и режимы обучения. В этой постановке законы масштабирования задают описательный макроуровень, тогда как ландшафтные и режимные подходы ориентированы на объяснительный уровень. В работе [98] масштабирование связывается с анализом кривизны и полных спектральных характеристик гессиана для архитектуры трансформера. Статистико-аппроксимационные и архитектурно-специфические версии представлены в работах [99, 100, 101]. Эта траектория исследований соединяет макроэмпирические зависимости с локальной геометрией архитектурно-специфических моделей.

Для трансформеров одна из трудностей состоит в том, что их успешность определяется не только размером модели, но и специфическими индуктивными смещениями механизма внимания, глубиной сети, структурой токенизации и масштабом предварительного обучения. Поэтому перенос классических оценок обучаемости в этот контекст редко дает содержательное объяснение. На уровне практики законы масштабирования помогают выбирать баланс между параметрами, данными и вычислениями, но дают ограниченную информацию о том, почему архитектура механизма внимания оказывается столь эффективной в режиме обучения признаков.

Для большей детализации полезно разделять архитектурные механизмы по их влиянию на сложность. Для трансформеров это, прежде всего, механизм самовнимания, остаточные связи и нормализация слоев: вместе они стабилизируют оптимизацию глубоких стеков и меняют эффективную кривизну задачи обучения. На уровне анализа сложности это означает, что параметр N в законах масштабирования (1.10) агрегирует разные по роли степени свободы. Практически эквивалентный рост числа параметров может сопровождаться разной динамикой обобщения в зависимости от того, где добавляется емкость: в ширине блоков внимания, в числе слоев, в MLP-части или в словаре токенизации. Этот вывод согласуется с работами, где законы масштабирования выводятся из статистико-аппроксимационного анализа и из динамики обучения признаков [99, 100, 102].

Для диффузионных моделей проблема имеет иную структуру. Здесь качество зависит не только от выразительности аппроксимирующей сети, но и от самой многошаговой стохастической процедуры генерации из шума. Следовательно, сложность должна описывать не статическую функцию, а целую динамическую схему восстановления сигнала. Это демонстрирует ограниченность единой скалярной меры сложности. Даже если параметризация сети фиксирована, изменение режима шума, числа шагов и процедуры обучения способно существенно менять как стабильность, так и качество генерации [97].

Для диффузионных архитектур это особенно заметно: эффективная сложность определяется совместно параметризацией денойзера и расписанием шума. Поэтому даже при близких кривых законов масштабирования финальная генеративная способность может различаться из-за разных траекторий обучения по временным шагам и разной чувствительности к ошибкам на ранних и поздних уровнях шума [103].

Связь геометрического и масштабного уровней удобно описывать как трех-уровневую цепочку: локальные метрики формируют режим обучения, а режим обучения определяет вид наблюдаемой кривой закона масштабирования при

росте N, D, C . Ключевое методологическое следствие состоит в том, что одинаковая макрокривая качества не гарантирует одинаковый механизм обобщения.

Из этого следует вывод, что теория сложности глубокого обучения не может ограничиться ни одним из этих методов по отдельности. Классические оценки задают базовый аппарат, ландшафтные меры описывают локальные геометрические характеристики решений, анализ режимов обучения объясняет качественные переходы между динамическими фазами, а законы масштабирования фиксируют крупномасштабные эмпирические закономерности.

1.7. Сравнительный анализ и открытые вопросы

Рассмотренные работы в табл. 1.2 дают сравнительную картину современных подходов к сложности в глубоком обучении. Ключевой вывод состоит в том, что разные меры сложности отвечают на разные исследовательские вопросы. Классические меры описывают вместимость класса гипотез. Вероятностные и информационные методы частично учитывают данные и алгоритм. Геометрические и ландшафтные методы описывают свойства найденного решения. Режимные и масштабные подходы фиксируют качественные переходы и крупномасштабные закономерности.

Видно, что сохраняется разрыв между глобальной сложностью класса моделей и эффективной сложностью реально найденного решения. Первая необходима для формальной теории обучаемости, однако в глубоких сетях она недостаточна для объяснения практического обобщения. Вторая пока не имеет общепринятого формального описания, при этом современные геометрические и алгоритмические подходы в основном ориентированы на ее анализ. Классическая теория отвечает на вопрос о том, когда обучение в принципе возможно, тогда как современная практика требует ответа на вопрос, почему из множества допустимых решений обучение систематически приводит к подмножеству решений с благоприятными эмпирическими свойствами. Если первый вопрос

Сравнение подходов к анализу сложности моделей глубокого обучения

Подход	Что измеряет	Сильные стороны	Ограничения для глубокого обучения
VC- и RAC-подходы	Мощность класса гипотез в худшем случае	Строгие критерии обучаемости и ясная статистическая постановка	Классическая оценка сложности через мощность класса функций и гарантии обучаемости в вероятностной постановке; пессимистичны в перепараметризованных режимах, не учитывают алгоритм и найденное решение
Радемахеровские и нормовые оценки	Емкость класса функций, зависящая от данных	Более тонкие оценки сверху, чувствительность к выборке и нормам	Уточняют обобщение за счет геометрии выборки и ограничений на параметры; по-прежнему описывают весь класс, а не подмножество реально достижимых решений
RAC-байесовские и информационные границы	Связь обобщения с распределением параметров и информацией об обучении	Учитывают алгоритмический аспект и допускают адаптивный анализ	Формируют вероятностно-информационную постановку, связывающую обобщение с распределением параметров и информацией из данных; зависят от выбора априорных распределений, параметризации и часто остаются численно слабыми
Ландшафтные и гессиановые меры	Локальные геометрические характеристики решения	Отражают свойства минимумов, устойчивость и связь с оптимизацией	Геометрический анализ свойств найденного решения и его устойчивости к возмущениям; дороги вычислительно, причинная интерпретация плоскости и спектра не всегда однозначна
Режимы обучения и законы масштабирования	Качественные фазы обучения и крупномасштабные эмпирические зависимости	Описывают современную практику больших моделей	Описывают фазы обучения и закономерности качества при росте параметров, данных и вычислений; дают неполное объяснение механизма обобщения и требуют стыковки с геометрией и оптимизацией

относится к глобальной структуре класса гипотез, то второй — к селективности алгоритма и геометрии достижимых минимумов. Поэтому современные исследования движутся к многокомпонентному описанию сложности, а не к поиску единственной универсальной формулы.

Современная теория должна быть не только формально строгой, но и эмпирически релевантной. Иначе говоря, качество меры сложности сегодня определяется не только ее математической строгостью, но и тем, насколько она позволяет согласовать классические гарантии с реальными режимами обучения больших сетей. Ландшафт и оптимизация в этом случае выступают как аналитические компоненты, так как позволяют анализировать сложность не только теоретически, но и применительно к решениям, возникающим в современных вычислительных режимах.

Т а б л и ц а 1.3

Уровни объяснения и типы теоретических утверждений

Уровень объяснения	Тип утверждений	Типичный вопрос	Основной риск неверной интерпретации
Глобальный, статистический	Гарантии обучаемости, оценки сверху на ошибку	Когда обучение в принципе возможно?	Перенос оценок худшего случая на конкретную обученную модель без учета алгоритма
Алгоритмический	Устойчивость, неявная регуляризация, селективность траектории	Почему из многих решений выбираются именно эти?	Подмена причинного механизма постфактум корреляциями
Геометрический	Спектральные и ландшафтные характеристики найденного минимума	Какие свойства решения связаны с обобщением?	Игнорирование параметризационных инвариантностей и вычислительной чувствительности метрик
Эмпирический	Режимные переходы и законы масштабирования	Как меняется качество при росте ресурсов?	Объяснение механизма только по форме масштабной кривой

В табл. 1.3 представлены ключевые различия между различными направлениями исследований. Статистические оценки нередко интерпретируются так, будто они обязаны предсказывать локальную геометрию решения, а ландшафт-

ные наблюдения интерпретируются так, как будто они автоматически дают универсальные гарантии обучаемости. Методологически корректно рассматривать эти уровни как взаимодополняющие. С этой точки зрения содержательный вклад обзора состоит не только в перечислении направлений, но и в реконструкции их совместимой архитектуры. Классические оценки ограничивают область допустимых объяснений, алгоритмические и геометрические подходы описывают механизм селекции решений внутри этой области, режимный и масштабный анализ тестируют устойчивость механизма при изменении масштаба моделей, данных и вычислений. Такая схема дает более строгую постановку для формулировки открытых задач.

Из этого анализа выделяется четыре вывода. Во-первых, классические меры, основанные на емкости класса, не исчезают из современной теории, но они дают базовые ориентиры, а не окончательные оценки. Во-вторых, алгоритм обучения в глубоких сетях является частью самой сложности. В-третьих, геометрические свойства найденного решения сопоставимы по роли со свойствами класса допустимых функций. В-четвертых, крупномасштабные эмпирические закономерности, включая двойной спуск и законы масштабирования, выступают не альтернативой строгой теории, а ее тестом. Современные обзорные и синтетические работы подтверждают картину, в которой неявная регуляризация, геометрия ландшафта и режимы масштабирования рассматриваются как взаимодополняющие части одного исследовательского направления. Это видно в обзорных публикациях [52, 53, 54] и в работах, ориентированных на теоретический анализ [55, 57, 104].

Исходя из анализа, выделяются следующие направления исследований теории сложности моделей машинного обучения.

1. Эффективная сложность достижимых решений. Требуется теория, описывающая не только весь класс параметрически допустимых функций, но и подмножество решений, которое достигается обучением из заданных инициализаций при заданных алгоритмах. На этом уровне соединяются классиче-

ские оценки емкости класса и геометрический анализ найденных минимумов.

2. Совместное описание оптимизации и ландшафта. Ландшафтные меры рассматриваются после обучения, а теория оптимизации — отдельно. Для глубокого обучения этого уже недостаточно. Требуется теория, в которой свойства спектра, плоскости минимумов, размер батча, шум и выбор оптимизатора описываются как части единого механизма формирования обобщающего решения.

3. Теория для современных больших архитектур. Трансформеры, диффузионные модели и другие современные архитектуры демонстрируют устойчивые эмпирические закономерности, однако соответствующая теория сложности остается фрагментарной. Особенно важна задача согласовать законы масштабирования с более локальными геометрическими и динамическими характеристиками.

4. Согласование уровней объяснения и критериев верификации. Открытой проблемой остается построение единого метода сопоставления результатов разных типов: от статистических оценок до геометрических и режимных индикаторов. Для прогресса необходимы работы, в которых для одной и той же постановки задачи одновременно фиксируются глобальные оценочные характеристики, алгоритмические показатели устойчивости, ландшафтные метрики и эмпирические зависимости качества.

5. Переход от ретроспективного объяснения к прогностической теории. Значительная часть современных методов успешно объясняет уже наблюдаемые эффекты, но в меньшей степени дает проверяемые прогнозы до проведения полного вычислительного эксперимента. Соответственно, одним из направлений дальнейших исследований является разработка предсказательных критериев, позволяющих на ранних этапах обучения оценивать вероятный класс обобщающего решения и ожидаемую чувствительность к изменению масштаба. Это согласуется с результатами, где динамика спектра гессиана в раннем и среднем обучении коррелирует с последующей устойчивостью реше-

ния [68, 69]. Она также согласуется с работами, связывающими стабильность траектории SGD и итоговое обобщение [78, 79].

Остается открытым вопрос о форме будущей объединяющей теории. Вероятно, она не будет одной формулой или одной универсальной оценкой. Более обоснованным представляется подход, в котором на верхнем уровне рассматриваются укрупненные законы масштабирования и фазовые переходы, на среднем — режимы обучения и роль оптимизатора, а на локальном — геометрия минимумов, спектр гессиана и устойчивость. Такое расслоение в большей степени соответствует наблюдаемой практике глубокого обучения, чем попытка свести все эффекты к одной численной характеристике. Эти проблемы показывают, что развитие теории сложности в глубоком обучении состоит не в отказе от классических результатов, а в их переинтерпретации и расширении. Классическая теория остается необходимым основанием, но ее нужно дополнять анализом эффективной геометрии решений и алгоритмических режимов.

1.8. Заключение обзора

Теория сложности моделей глубокого обучения смещается от анализа абстрактной мощности класса гипотез к анализу эффективной сложности реально достигаемых решений. Настоящий раздел опирается на воспроизводимую процедуру построения корпуса публикаций и сопоставление классических, вероятностно-информационных, ландшафтных и режимно-масштабных линий исследований. Классические меры — VC-размерность, радемахеровские оценки, PAC-байесовские и информационные границы — остаются фундаментальной частью теории обучения, однако в перепараметризованных режимах уже не дают единственного объяснения обобщающей способности. Современные подходы описывают сложность через совместный анализ геометрии ландшафта, динамики оптимизации, режимов обучения и масштабных закономерностей. Ключевой вывод состоит в том, что архитектура, данные и алгоритм обучения должны

анализироваться совместно. Только в этом случае теория сохраняет и формальную строгость, и эмпирическую релевантность для современных больших моделей.

1.9. Открытые проблемы и вклад диссертации

Итоги настоящей главы показывают, что теория сложности глубокого обучения должна опираться одновременно на классические меры емкости класса, вероятностно-информационные границы, ландшафтные индикаторы и масштабные закономерности, причем каждый из этих подходов описывает собственный аспект проблемы. Классический аппарат задает формальную постановку обучаемости, но переход к современным нейросетевым моделям требует анализа того, какие решения реально выбираются алгоритмом и какие геометрические характеристики отличают эти решения от произвольных элементов класса гипотез.

Три ограничения существующего аппарата напрямую мотивируют содержание последующих глав диссертации. Во-первых, перепараметризованные сети систематически обобщаются лучше, чем предсказывают типичные оценки худшего случая на всем классе гипотез; комбинаторный подход Воронцова смягчает оценки Вапника—Червоненкиса, но не заменяет анализ множества решений, реально достижимых алгоритмом оптимизации. Во-вторых, эмпирические законы масштабирования фиксируют ресурсные зависимости качества, однако остаются без единой стыковки с локальной геометрией риска и с формальным критерием согласованности сложности модели и данных. В-третьих, полная матрица Гессе для миллиардных параметров недоступна, поэтому необходимы спектральные мажоранты и практически реализуемые индикаторы ландшафта.

Вклад диссертации, связанный с указанными проблемами, состоит в следующем. Во-первых, вводится и изучается ландшафтная мера сложности через разброс пообъектных матриц Гессе и ее связь с приращением эмпирического

риска при росте выборки. Эта мера не заменяет классические оценки емкости класса, а дополняет их локальным описанием обученной параметрической модели (гл. 2). Во-вторых, получены верхние спектральные оценки для полносвязных, сверточных и трансформерных архитектур, а также матричированных сетей; тем самым полный анализ матрицы Гессе заменяется вычислимыми мажорантами, применимыми к современным архитектурам (гл. 3). В-третьих, общая мера сложности данных используется для постановки задачи достаточного объема выборки, а не как самостоятельная универсальная теория сложности данных; в этой постановке формулируются и исследуются критерии достаточности выборки на основе вероятностных и байесовских характеристик (гл. 4). В-четвертых, разрабатываются методы снижения сложности моделей, включая отбор параметров, дистилляцию, байесовскую дистилляцию и антидистилляцию; эти методы показывают, как теоретическое понимание сложности переводится в процедуры изменения архитектуры и параметрического пространства (гл. 5). В-пятых, предложенные оценки и критерии проверяются в прикладных задачах, включая анализ fMRI-данных, оценку данных для генеративных моделей и эксперименты с языковыми моделями, что связывает обзорную часть с практическим применением построенного аппарата (гл. 6).

Таким образом, настоящая глава задает не самостоятельный набор несвязанных определений, а общую постановку всей диссертации. Классические меры сложности используются как исходные понятия, ландшафтные и спектральные характеристики — как основной инструмент анализа параметрических моделей, а достаточный объем выборки и методы снижения сложности — как способы проверить и использовать этот аппарат в последующих главах.

Глава 2

Сложность моделей и данных

Как было продемонстрировано в предыдущей главе, существующие подходы к анализу сложности моделей глубокого обучения характеризуются существенными ограничениями. Во-первых, классические оценки сложности не учитывают специфику перепараметризованных нейронных сетей. Во-вторых, они часто описывают класс моделей глобально и не отражают локальные свойства уже найденного решения. В-третьих, анализ матриц Гессе остается в основном эмпирическим и не обеспечивает строгих теоретических связей для конкретных архитектур. Поэтому центральной задачей настоящей главы является построение вычислимой характеристики сложности параметрической модели, связанной с геометрией ландшафта функции потерь.

Общая формализация мер сложности модели и выборки используется ниже как вспомогательная постановка вопроса о согласовании модели и данных. При этом сама по себе произвольная мера сложности данных не рассматривается как основной вычислительный объект главы. Конструктивная часть анализа начинается с параметрической модели, эмпирического риска и изменения ландшафта функции потерь при вариации обучающей выборки.

В общей постановке условие согласования сложности модели $\mu_f(f)$ и сложности данных $\mu_D(D)$ можно записать в виде:

$$\mu_f(f) \leq \mu_D(D),$$

однако дальнейший анализ сосредоточен не на произвольном выборе μ_D , а на вычислимом частном случае условной сложности параметрической модели, задаваемом через разброс пообъектных матриц Гессе.

Основным инструментом анализа служит изучение изменения функции потерь при добавлении объектов в выборку. В разделе 2.3. показывается, как абсолютное изменение функции потерь оценивается через спектральную нор-

му разности пообъектной матрицы Гессе и среднего Гессе по уже имеющейся выборке:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{M_\ell}{k+1} + \frac{1}{k+1} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2$$

Именно этот переход от общей меры сложности к локальной геометрии параметрической модели является основной частью главы. Результаты главы 3 позволяют получать аналитические верхние оценки спектральных свойств матриц Гессе, а значит делают ландшафтную меру вычислительно осуществимой даже в тех случаях, когда прямое вычисление полных матриц Гессе непрактично.

Таким образом, общие определения сложности данных и модели выполняют роль постановочной основы, а основной теоретический вклад главы связан с ландшафтной мерой параметрических моделей, ее спектральными оценками и эмпирическим анализом динамики при обучении.

Структура главы организована следующим образом. В разделе 2.1. вводятся формальные определения меры сложности выборки и меры сложности модели, необходимые для общей постановки задачи. В разделе 2.2. кратко рассматривается частный случай, связывающий эту постановку с понятием достаточного объема выборки. В разделе 2.3. разрабатывается основной объект главы — ландшафтная мера сложности модели на основе анализа изменения функции потерь, и получены теоретические оценки для полносвязных, сверточных и трансформерных моделей. Далее рассматриваются два приложения построенной меры: сопоставление ландшафтной меры с эмпирической радемахеровской сложностью в задаче скалярной регрессии для полносвязных ReLU-сетей при квадратичной функции потерь (раздел 2.4.3.) и анализ динамики выборочной ландшафтной меры при обучении языковых моделей. В разделе 2.6. представлены результаты вычислительных экспериментов, подтверждающие теоретические оценки основной части главы.

2.1. Оценка сложности моделей и данных

Как было указано во введении, существующие подходы часто рассматривают сложность модели и сложность данных изолированно. В настоящем разделе вводится минимальная формальная постановка для совместного описания этих двух объектов. Она нужна прежде всего для корректной постановки дальнейшего анализа; основной вычисляемый объект главы будет введен ниже как ландшафтная мера сложности параметрической модели.

Определение 12 (Генеральная совокупность данных). *Генеральной совокупностью данных Γ назовем произвольное множество объектов, которые исследуются в рамках той или иной задачи. В общем случае нет никаких ограничений на счетность множества генеральной совокупности.*

Определение 12 позволяет работать как с однородными, так и с генеральными совокупностями, образованными несколькими распределениями.

Определение 13 (Однородная и гетерогенная генеральная совокупность). *Генеральную совокупность Γ назовем однородной, если все ее объекты порождаются из одного распределения. В противном случае назовем ее гетерогенной; если совокупность образуется k различными распределениями, будем говорить о k -компонентной совокупности.*

В определении 13 примером двухкомпонентной (гетерогенной) генеральной совокупности служит выборка, содержащая объекты разной природы — например тексты и изображения. Многомодальные модели, одновременно обрабатывающие такие объекты, работают именно с гетерогенными генеральными совокупностями.

Пусть задана генеральная совокупность данных Γ . Множество всех подмножеств объектов, образующих семейство выборок (кольцо множеств в смысле теории меры), обозначим как:

$$\mathfrak{D} = \{D_\Gamma^i\}, \quad D_\Gamma^i \subset \Gamma.$$

Определение 14 (Мера сложности выборки). *Мерой сложности выборки назовем отображение μ_D , такое, что:*

$$\mu_D(D_i) : \mathfrak{D}_\Gamma \rightarrow \mathbb{R}_+,$$

удовлетворяющее свойству:

$$\mu_D(D_i \cup D_j) \leq \mu_D(D_i) + \mu_D(D_j),$$

где равенство достигается при условии $D_i \cap D_j = \emptyset$.

Определение 14 является классическим определением из теории меры, удовлетворяющим свойству конечной аддитивности. Конечной аддитивности достаточно, так как в исследованиях предполагается конечное число объектов при обучении моделей глубокого обучения. Предполагается сравнение выборок только из одной генеральной совокупности, однако этим никак не ограничивается сама генеральная совокупность, и в определении допускаются гетерогенные генеральные совокупности.

Лемма 1 (Монотонность меры сложности выборки). *Мера сложности выборки μ_D , определенная в определении 14, обладает свойством монотонности: для любых выборок $D_1, D_2 \in \mathfrak{D}$ таких, что $D_1 \subseteq D_2$, выполняется неравенство*

$$\mu_D(D_1) \leq \mu_D(D_2).$$

Доказательство. Пусть $D_1 \subseteq D_2$. Представим D_2 в виде объединения $D_2 = D_1 \cup (D_2 \setminus D_1)$, где $D_1 \cap (D_2 \setminus D_1) = \emptyset$. По свойству субаддитивности меры сложности выборки из определения 14 имеем:

$$\mu_D(D_2) = \mu_D(D_1 \cup (D_2 \setminus D_1)) \leq \mu_D(D_1) + \mu_D(D_2 \setminus D_1).$$

Учитывая, что $D_1 \cap (D_2 \setminus D_1) = \emptyset$, по определению 14 равенство в свойстве субаддитивности достигается:

$$\mu_D(D_2) = \mu_D(D_1 \cup (D_2 \setminus D_1)) = \mu_D(D_1) + \mu_D(D_2 \setminus D_1).$$

Поскольку мера сложности выборки принимает неотрицательные значения ($\mu_D : \mathfrak{D}_\Gamma \rightarrow \mathbb{R}_+$), имеем $\mu_D(D_2 \setminus D_1) \geq 0$. Следовательно,

$$\mu_D(D_2) = \mu_D(D_1) + \mu_D(D_2 \setminus D_1) \geq \mu_D(D_1) + 0 = \mu_D(D_1),$$

что и требовалось доказать. □

Замечание 2. Лемма 1 устанавливает монотонность меры сложности выборки как следствие субаддитивности. Данное свойство является общим свойством мер конечных множеств в теории меры. Однако в случае бесконечных выборок монотонность может не выполняться автоматически и требует более строгих формулировок в определении меры выборок, таких как счетная аддитивность или непрерывность меры снизу. В рамках настоящей работы рассматриваются только конечные выборки, что соответствует практическим задачам обучения моделей глубокого обучения.

Пусть задано множество параметрических аппроксимирующих моделей

$$\mathfrak{F} = \{f_i\},$$

где каждое f_i является некоторым множеством параметрических функций. В определении 15 вводится характеристика параметрического семейства функций f , которые в дальнейшем рассматриваются в качестве моделей глубокого обучения.

Определение 15 (Мера сложности модели). Мерой сложности модели f назовем отображение $\mu_f(f_i)$:

$$\mu_f(f_i) : \mathfrak{F} \rightarrow \mathbb{R}_+.$$

Определение меры сложности модели f не является определением меры в общем случае, так как множество $\mathfrak{F}$ не является кольцом. Поэтому данная мера представляет собой некоторое отображение, которое является характеристикой сложности. В качестве примера можно указать, что число параметров модели удовлетворяет определению 15.

После введения определений меры сложности как для выборки, так и для модели, переходим к определению обучаемости модели на выборке, которое сформулировано в определении 16.

Определение 16 (Обучаемость модели на выборке). *Назовем модель $f \in \mathfrak{F}$ обучаемой на выборке $D \in \mathfrak{D}$, если*

$$\mu_f(f) \leq \mu_D(D).$$

В определении 16 не вводится никакого ограничения на качество аппроксимации модели после обучения. Более подробно это будет определено для частных случаев мер в следующих разделах.

Определение 16 следует понимать как абстрактный критерий согласованности двух выбранных числовых характеристик: сложности модели и сложности выборки. В таком виде оно не является самостоятельным критерием качества аппроксимации и не заменяет анализ эмпирического или истинного риска. Его роль состоит в том, чтобы зафиксировать постановку, в которой далее можно формулировать вычислимые частные меры, зависящие от параметрической модели, выборки и функции потерь.

В диссертационной работе основной акцент делается именно на таком частном случае меры сложности модели: на оценке ландшафта оптимизационной задачи через матрицы Гессе для различных нейросетевых архитектур, которые описаны в главе 3. Подробнее этот вычислимый частный случай рассматривается в разделе 2.3..

Предложение 2 (Сохранение критерия согласованности при расширении выборки). *Пусть мера сложности данных μ_D монотонна по включению в том смысле, что из $D \subseteq D''$ следует $\mu_D(D) \leq \mu_D(D'')$. Если для выборки D выполнено $\mu_f(f) \leq \mu_D(D)$, то для любой выборки D' выполняется $\mu_f(f) \leq \mu_D(D \cup D')$.*

Доказательство. Имеем $D \subseteq D \cup D'$, откуда по монотонности $\mu_D(D) \leq \mu_D(D \cup D')$. С учетом $\mu_f(f) \leq \mu_D(D)$ получаем $\mu_f(f) \leq \mu_D(D \cup D')$. $\square$

Отдельно, свойство субаддитивности $\mu_D(D \cup D') \leq \mu_D(D) + \mu_D(D')$ дает лишь верхнюю оценку сложности объединения через сложности частей и не заменяет монотонность.

Введение формальных мер сложности моделей и данных создает постановочную основу для дальнейшего перехода к ландшафтной мере параметрических моделей.

2.2. Достаточный объем выборки

В предыдущем разделе было введено определение обучаемости модели на выборке через условие $\mu_f(f) \leq \mu_D(D)$. В таком общем виде это условие является постановочным: одна и та же выборка данных может представлять различную трудность для разных архитектур моделей и разных функций потерь.

Для учета этой зависимости в настоящем разделе вводится понятие условной сложности выборки. Оно связывает общую меру данных с анализом достаточного объема выборки, который подробно рассматривается в главе 4.

Ключевым понятием становится *условная сложность выборки*:

$$\mu_D(D|f) : \mathfrak{D} \rightarrow \mathbb{R}_+, \quad (2.1)$$

которая характеризует сложность данных $D \in \mathfrak{D}$ относительно заданной параметрической модели f в рамках выбранной меры μ_D .

Мера сложности модели $\mu_f(f)$ индуцирует меру сложности выборки следующим образом:

$$\mu_D(D|f) = \inf\{\mu_D(D') : D' \subseteq D, \quad \mu_f(f) \leq \mu_D(D')\}, \quad (2.2)$$

при этом по стандартному соглашению $\inf \emptyset = +\infty$, если подходящей подвыборки D' не существует; иными словами, условная сложность выборки задается как минимальная сложность подвыборки, достаточная для выполнения выбранного критерия согласованности.

Определение 17 (Условная сложность выборки). *Условной сложностью выборки D относительно заданной параметрической модели f назовем отображение (2.1), определяемое выражением (2.2).*

Рассмотрим частный случай меры сложности данных μ_D , соответствующий определению достаточного объема выборки. Предположим, что генеральная совокупность Γ_C состоит из объектов одинаковой сложности C , то есть для каждого объекта $\gamma \in \Gamma_C$ выполняется:

$$\mu_D(\gamma) = C,$$

где $C \in \mathbb{R}_+$ — некоторая агрегированная сложность одного объекта выборки. Указанное предположение представляет собой сильное ограничение и в общем случае не выполняется на практике, поскольку реальные объекты могут обладать разной информативностью, шумом и трудностью для конкретной модели.

Определение 18 (Простая генеральная совокупность). *Однородную генеральную совокупность Γ_C назовем простой, если она состоит из объектов одинаковой сложности C .*

Замечание 3 (Простая генеральная совокупность и оценки достаточного объема). *Простая генеральная совокупность фиксирует равновесный учёт данных: каждому объекту в мере μ_D приписана одинаковая стоимость C (часть $C = 1$), так что сложность выборки сводится к ее мощности, $\mu_D(D) = C|D|$. Это не утверждение о равенстве реализованной информативности объектов при содержательной мере сложности и не эквивалентность условию независимости и одинаковой распределенности наблюдений. Условие *i.i.d.* описывает закон порождения выборки и по смыслу близко к однородной генеральной совокупности, тогда как простота есть свойство выбранной меры μ_D : наблюдения учитываются только как единицы объема. Именно в такой постановке работают классические и большинство прикладных методов оценки достаточного размера выборки m^* : критерий достаточности формулируется в терминах числа объектов, без отдельной сложности точек. Та-*

ким образом, условие $\mu_D(\gamma) = C$ выделяет этот предельный случай внутри общей схемы мер сложности данных. Дальнейшие конструкции главы — условная сложность выборки и ландшафтная мера $\mu_f(f|D)$ — как раз допускают неоднородный вклад отдельных объектов.

Следствие 1 (Мера сложности выборки для простой генеральной совокупности). Для простой генеральной совокупности Γ_C мера сложности любой выборки $D \subset \Gamma_C$ равна ее объему, умноженному на константу сложности:

$$\mu_D(D) = C \cdot |D|.$$

Доказательство. Доказательство состоит из двух частей: сначала покажем, что функция $\mu_D(D) = C \cdot |D|$ является мерой сложности выборки в смысле определения 14, затем покажем, что она определяется условием $\mu_D(\gamma) = C$ для каждого объекта $\gamma \in \Gamma_C$.

Проверим, что функция $\mu_D(D) = C \cdot |D|$ удовлетворяет определению меры сложности выборки 14.

Поскольку $|D| \geq 0$ для любой выборки $D \subset \Gamma_C$, и константа $C \in \mathbb{R}_+$ по определению простой генеральной совокупности, имеем $\mu_D(D) = C|D| \geq 0$.

Для любых выборок $D_1, D_2 \subset \Gamma_C$ имеем:

$$\mu_D(D_1 \cup D_2) = C|D_1 \cup D_2|.$$

По свойству мощности множеств $|D_1 \cup D_2| \leq |D_1| + |D_2|$, причем равенство достигается при $D_1 \cap D_2 = \emptyset$. Следовательно,

$$\mu_D(D_1 \cup D_2) = C|D_1 \cup D_2| \leq C(|D_1| + |D_2|) = \mu_D(D_1) + \mu_D(D_2),$$

причем равенство достигается при $D_1 \cap D_2 = \emptyset$, что соответствует определению 14.

Покажем, как мера $\mu_D(D) = C \cdot |D|$ следует из условия $\mu_D(\gamma) = C$ для каждого объекта $\gamma \in \Gamma_C$.

Для произвольной выборки $D = \{\gamma_1, \gamma_2, \dots, \gamma_n\} \subset \Gamma_C$ рассмотрим последовательность одноэлементных множеств $D_i = \{\gamma_i\}$ для $i = 1, \dots, n$. По условию простой генеральной совокупности для каждого объекта γ_i выполняется $\mu_D(\gamma_i) = C$, то есть $\mu_D(D_i) = C$ для всех $i = 1, \dots, n$.

Поскольку одноэлементные множества D_i попарно не пересекаются ($D_i \cap D_j = \emptyset$ при $i \neq j$), по свойству конечной аддитивности меры сложности выборки (равенство в определении 14 при непересекающихся множествах) имеем:

$$\mu_D(D) = \mu_D\left(\bigcup_{i=1}^n D_i\right) = \sum_{i=1}^n \mu_D(D_i) = \sum_{i=1}^n C = C \cdot n = C \cdot |D|,$$

что и требовалось доказать.

Таким образом, для простой генеральной совокупности функция $\mu_D(D) = C \cdot |D|$ сводит меру сложности выборки к ее мощности с точностью до постоянного множителя. $\square$

В этой постановке достаточный объем выборки можно рассматривать как частный случай *условной сложности выборки*: он сводит вопрос о сложности данных к вопросу о минимальном числе объектов, требуемом для выполнения заранее выбранного критерия.

Определение 19 (Достаточный размер выборки). *Размер выборки m^* называется достаточным согласно критерию T , если T выполняется для всех $k \geq m^*$.*

Исследование достаточного объема выборки поэтому остается полезным частным направлением, однако в настоящей главе оно играет вспомогательную роль. Основной конструктивный анализ далее связан с ландшафтной мерой сложности параметрических моделей; подробные методы оценки достаточного объема выборки рассматриваются в главе 4.

2.3. Ландшафтная мера сложности модели

В предыдущих разделах были введены общие определения мер сложности модели и данных, а также условной сложности выборки. Эти определения зада-

ют общую постановку, но сами по себе еще не дают вычислимой характеристики для нейросетевой модели. В настоящем разделе разрабатывается основной объект главы — ландшафтная мера сложности параметрической модели, основанная на анализе изменения функции потерь при увеличении объема выборки.




Рис. 2.1: Изменение функции потерь $\mathcal{L}_k(\theta)$ при добавлении нового объекта в выборку. Иллюстрация демонстрирует зависимость абсолютной разности $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k , что является основой для анализа сходимости ландшафта и определения ландшафтной меры сложности модели.

Рассмотрим конечную обучающую выборку:

$$D = \{(\mathbf{x}_i, \mathbf{y}_i)\}, \quad i = 1, \dots, m, \quad \mathbf{x}_i \in \mathcal{X}, \quad \mathbf{y}_i \in \mathcal{Y}.$$

Рассмотрим некоторое параметрическое отображение $f_\theta : \mathcal{X} \rightarrow \mathcal{Y}$, которое аппроксимирует условное распределение целевой переменной для заданного признакового описания объекта $p(\mathbf{y}|\mathbf{x})$. Параметры θ функции f_θ принадлежат пространству $\mathbb{R}^P$, где P описывает число параметров отображения f_θ .

Пусть для выбора оптимального вектора параметров $\hat{\theta}$ используется подход минимизации эмпирического риска:

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L}_m(\theta),$$

где функция эмпирического риска для выборки размера $|D| = m$ задается в

следующем виде:

$$\mathcal{L}_m(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) \approx \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathbf{x}, \mathbf{y})} [\ell(f_{\boldsymbol{\theta}}(\mathbf{x}), \mathbf{y})],$$

где функция $\ell(\mathbf{z}, \mathbf{y})$ описывает ошибку на одном объекте. Далее в качестве функции ℓ будут рассматриваться либо кросс-энтропийная функция потерь, либо средняя квадратическая ошибка, в зависимости от рассматриваемой задачи и архитектуры модели.

Функция эмпирического риска $\mathcal{L}_m(\boldsymbol{\theta})$ задает некоторую поверхность в пространстве параметров размерности P . Изучение изменения этой поверхности при добавлении новых объектов данных позволяет количественно оценить влияние объема выборки на оптимизационный ландшафт.

Изменение значения функции потерь при добавлении одного объекта вычисляется следующим образом:

$$\begin{aligned} \mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta}) &= \frac{1}{k+1} \sum_{i=1}^{k+1} \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) = \\ &= \frac{1}{k+1} \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \sum_{i=1}^k \frac{1}{k(k+1)} \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) = \\ &= \frac{1}{k+1} (\ell(f_{\boldsymbol{\theta}}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \mathcal{L}_k(\boldsymbol{\theta})). \end{aligned} \quad (2.3)$$

Дальнейший анализ ландшафта связан с изучением этой разности, в том числе ее асимптотики при $k \rightarrow \infty$. Для последующих оценок вводится предположение 1; оно согласуется с численными наблюдениями, но является сильным упрощением, используемым в аналитических выкладках.

Предположение 1 (Сохранение локальных минимумов). Пусть $\boldsymbol{\theta}^*$ является локальным минимумом обеих эмпирических функций потерь $\mathcal{L}_k(\boldsymbol{\theta})$ и $\mathcal{L}_{k+1}(\boldsymbol{\theta})$, т.е.

$$\nabla \mathcal{L}_k(\boldsymbol{\theta}^*) = \nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*) = \mathbf{0}.$$

Теоретическое обоснование предположения 1 основано на нескольких фундаментальных принципах теории оптимизации и статистического обучения.

Во-первых, при достаточно большом объеме выборки k эмпирический риск $\mathcal{L}_k(\boldsymbol{\theta})$ сходится к истинному риску $R(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathbf{x}, \mathbf{y})}[\ell(f_{\boldsymbol{\theta}}(\mathbf{x}), \mathbf{y})]$ в соответствии с законом больших чисел. При условии равномерной сходимости градиентов эмпирического риска к градиентам истинного риска локальные минимумы эмпирического риска сходятся к локальным минимумам истинного риска [2].

Во-вторых, при добавлении одного объекта к выборке размера k изменение эмпирического риска имеет порядок $O(1/k)$, что следует из выражения (2.3). Для достаточно больших k указанное изменение становится пренебрежимо малым, и локальный минимум $\boldsymbol{\theta}^*$ функции $\mathcal{L}_k(\boldsymbol{\theta})$ остается в окрестности локального минимума функции $\mathcal{L}_{k+1}(\boldsymbol{\theta})$, при условии, что функция потерь является гладкой и локально выпуклой в окрестности $\boldsymbol{\theta}^*$.

В-третьих, работы по анализу ландшафта функции потерь нейронных сетей [62, 105] демонстрируют, что при достаточном объеме данных ландшафт функции потерь стабилизируется, и локальные минимумы становятся устойчивыми к малым возмущениям выборки. Указанное свойство особенно выражено для перепараметризованных моделей, где множество локальных минимумов образует связные многообразия [62].

При асимптотически большом объеме выборки указанное свойство не противоречит эмпирическим результатам, что подтверждается экспериментальной валидацией, представленной в разделе 2.6..

Воспользуемся квадратичным приближением Тейлора для указанных выше функций потерь в окрестности точки $\boldsymbol{\theta}^*$. Предполагается, что разложение до второго порядка является достаточным для изучения локального поведения. Член первого порядка обращается в ноль, поскольку градиенты $\nabla \mathcal{L}_k(\boldsymbol{\theta}^*)$ и $\nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*)$ равны нулю:

$$\mathcal{L}_k(\boldsymbol{\theta}) \approx \mathcal{L}_k(\boldsymbol{\theta}^*) + \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}^*)^\top \mathbf{H}^{(k)}(\boldsymbol{\theta}^*)(\boldsymbol{\theta} - \boldsymbol{\theta}^*), \quad (2.4)$$

где введено обозначение гессиана функции $\mathcal{L}_k(\boldsymbol{\theta})$ по параметрам $\boldsymbol{\theta}$ в точке $\boldsymbol{\theta}^*$ как $\mathbf{H}^{(k)}(\boldsymbol{\theta}^*) \in \mathbb{R}^{P \times P}$. Полный гессиан может быть записан как среднее значение

гессианов отдельных членов эмпирической функции потерь:

$$\mathbf{H}^{(k)}(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}}^2 \mathcal{L}_k(\boldsymbol{\theta}) = \frac{1}{k} \sum_{i=1}^k \nabla_{\boldsymbol{\theta}}^2 \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}).$$

Используя полученное квадратичное приближение (2.4), формула для разности потерь (2.3) принимает вид:

$$\begin{aligned} \mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta}) &= \frac{1}{k+1} \left(\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right) + \\ &+ \frac{1}{2(k+1)} (\boldsymbol{\theta} - \boldsymbol{\theta}^*)^\top \left(\mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right) (\boldsymbol{\theta} - \boldsymbol{\theta}^*), \end{aligned}$$

Используя неравенство треугольника, получаем следующую оценку:

$$\begin{aligned} |\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| &\leq \frac{1}{k+1} \left| \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| + \\ &+ \frac{1}{2(k+1)} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2. \end{aligned} \quad (2.5)$$

Первое слагаемое может быть легко ограничено константой, поскольку сама функция потерь принимает ограниченные значения. Выражение с гессианами требует более сложной оценки. Подробный анализ матриц Гессе для различных типов параметрических моделей глубокого обучения представлен в главе 3. Анализ локальной сходимости ландшафта функции потерь основан на ее матрице Гессе.

Получаем выражение для анализа, описывающее поведение ландшафта функции потерь:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{M_\ell}{k+1} + \frac{1}{2(k+1)} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2. \quad (2.6)$$

Установлено, что анализ сходимости ландшафта оптимизационной задачи сводится к анализу нормы матрицы Гессе, который подробно разобран в главе 3.

Оценка (2.6) задает некоторое свойство параметрического семейства функций f на заданной выборке D . Определим данное свойство как условную сложность модели f на выборке D :

$$\mu_f(f|D) : \mathfrak{F} \rightarrow \mathbb{R}_+, \quad (2.7)$$

Более подробно рассмотрим частный случай условной меры сложности параметрического семейства функций f вида:

$$\mu_f(f|D) = \mathbb{E}_{\mathbf{x}_i \in D} \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_{\mathbf{x}_i \in D} \mathbf{H}_i(\boldsymbol{\theta}^*)\|_2. \quad (2.8)$$

Определение 20 (Условная сложность параметрической модели). *Условной сложностью параметрической модели f относительно заданной выборки D назовем отображение (2.7).*

Определение 21 (Ландшафтная мера сложности). *Ландшафтной мерой сложности параметрической функции f назовем условную сложность параметрической модели f , заданную выражением (2.8).*

Определение 20 описывает прикладной способ задания сложности на параметрических семействах функций в контексте оптимизации на заданных выборках. Условная сложность модели $\mu_f(f|D)$ характеризует сложность архитектуры модели f при ее обучении на выборке данных D и позволяет количественно оценить степень соответствия модели данным. При этом слишком простая модель может недообучаться, а слишком сложная — переобучаться.

Ландшафтная мера сложности 21 представляет собой явный вид условной сложности, основанный на анализе оптимизационного ландшафта функции потерь. Выражение (2.8) содержательно указывает на степень изменения кривизны функции потерь в окрестности оптимума при добавлении нового объекта данных. В оценке (2.6) фигурирует спектральная норма разности пообъектной матрицы для нового индекса и среднего по уже имеющимся объектам; эта величина естественно согласуется с порядком величины спектрального разброса семейства $\{\mathbf{H}_i(\boldsymbol{\theta}^*)\}$, которым измеряется $\mu_f(f|D)$, что и используется при переходе к (2.9).

Дальнейшее изложение в главе посвящено оценкам ландшафтной меры для различных параметрических моделей f . Все результаты основываются на анализе матриц Гессе, описанных в главе 3.

Используя выражение (2.6) и определение ландшафтной меры сложности, получаем следующую асимптотическую связь между этими оценками:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{M_\ell}{k+1} + \frac{\mu_f(f|D)}{k+1} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2, \quad (2.9)$$

которая получается из (2.6) при мажорировании $\|\mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - k^{-1} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*)\|_2 \leq 2\mu_f(f|D)$; конкретный коэффициент в таком мажорировании зависит от постановки, а здесь он сведен к выбранному виду правой части.

Замечание 4 (Связь с достаточным объемом выборки). *В случае простой генеральной совокупности из раздела 2.2. мера сложности подвыборки пропорциональна ее мощности: $\mu_D(D') = C|D'|$. Тогда оценка (2.9) позволяет интерпретировать рост k как уменьшение верхней оценки на изменение эмпирического риска при добавлении нового объекта:*

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{M_\ell + \mu_f(f|D)R^2}{k+1}, \quad \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2 \leq R.$$

Поэтому в данной постановке требование малости изменения ландшафта, например

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \varepsilon,$$

приводит к достаточному условию на размер подвыборки:

$$k+1 \geq \frac{M_\ell + \mu_f(f|D)R^2}{\varepsilon}.$$

Это соотношение не является универсальной теоремой о сложности данных. Оно показывает только, как в случае одинаковой стоимости объектов общая мера μ_D связывается с более содержательным ландшафтным анализом параметрической модели.

2.3.1. Теоретические оценки для полносвязных сетей

В настоящем подразделе получены оценки ландшафтной меры сложности для полносвязных нейронных сетей, являющихся базовой архитектурой глубокого обучения. Анализ основан на результатах главы 3, а именно на теореме 10, в которой показана асимптотика нормы матрицы Гессе от гиперпараметров полносвязной нейросетевой модели:

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \propto L(hM)^{2L},$$

из которой следует, что спектральная норма матрицы Гессе имеет полиномиальную зависимость от размера слоя и экспоненциальную зависимость от числа слоев.

Теорема 3 (Сходимость ландшафта функции потерь для полносвязных сетей). Пусть параметры $\boldsymbol{\theta}$ выбраны так, что $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \leq R^2$ для некоторого $R > 0$. Если существует неотрицательная константа M_ℓ такая, что $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_\ell$ для всех объектов $i = 1, \dots, t$ в наборе данных, то при выполнении условий Теоремы 9 справедливо:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{1}{k+1} \left(2M_\ell + \left(L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1} \right) R^2 \right),$$

причем выражение асимптотически стремится к 0, то есть

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \rightarrow 0 \text{ при } k \rightarrow \infty.$$

Таким образом, имеет место следующая пропорциональность:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \propto \frac{L(hM)^{2L}R^2}{k}.$$

Доказательство. Доказательство основано на оценке разности функций потерь через выражение (2.5), которое получено из квадратичного приближения Тейлора и предположения 1.

Оценим первое слагаемое в выражении (2.5), используя неравенство треугольника для модуля разности:

$$\begin{aligned} & \left| \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| \leq \\ & \leq |\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1})| + \left| \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right|. \end{aligned}$$

Применяя неравенство треугольника к модулю суммы и используя условие ограниченности функции потерь $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_\ell$ для всех $i = 1, \dots, m$, получаем:

$$\begin{aligned} & \leq |\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1})| + \frac{1}{k} \sum_{i=1}^k |\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq \\ & \leq M_\ell + \frac{1}{k} \sum_{i=1}^k M_\ell = M_\ell + M_\ell = 2M_\ell. \end{aligned}$$

Таким образом, первое слагаемое ограничено константой $2M_\ell = \mathcal{O}(1)$ при $k \rightarrow \infty$.

Оценим норму разности матриц Гессе во втором слагаемом, используя свойства спектральной нормы матриц. Применяя неравенство треугольника для спектральной нормы, получаем:

$$\begin{aligned} & \left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2 \leq \\ & \leq \|\mathbf{H}_{k+1}(\boldsymbol{\theta}^*)\|_2 + \left\| \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2. \end{aligned}$$

Используя свойство субмультипликативности спектральной нормы и неравенство треугольника для суммы матриц, имеем:

$$\leq \|\mathbf{H}_{k+1}(\boldsymbol{\theta}^*)\|_2 + \frac{1}{k} \sum_{i=1}^k \|\mathbf{H}_i(\boldsymbol{\theta}^*)\|_2.$$

По теореме 9 о норме матрицы Гессе для полносвязных нейронных сетей, при выполнении условий теоремы существует константа $M_{\mathbf{H}}$ такая, что $\|\mathbf{H}_i(\boldsymbol{\theta}^*)\|_2 \leq$

$M_{\mathbf{H}}$ для всех $i = 1, \dots, k+1$, где

$$M_{\mathbf{H}} = L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1}.$$

Следовательно,

$$\left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2 \leq M_{\mathbf{H}} + \frac{1}{k} \sum_{i=1}^k M_{\mathbf{H}} = M_{\mathbf{H}} + M_{\mathbf{H}} = 2M_{\mathbf{H}}.$$

Таким образом, второе слагаемое ограничено константой $2M_{\mathbf{H}} = \mathcal{O}(1)$ при $k \rightarrow \infty$.

Подставляя полученные оценки в выражение (2.5), получаем:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2M_{\ell}}{k+1} + \frac{M_{\mathbf{H}}}{k+1} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2.$$

По условию теоремы параметры $\boldsymbol{\theta}$ находятся в R -окрестности оптимума, то есть $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \leq R^2$. Следовательно,

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{1}{k+1} (2M_{\ell} + M_{\mathbf{H}}R^2).$$

Подставляя выражение для $M_{\mathbf{H}}$, получаем требуемую оценку:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2}{k+1} \left(M_{\ell} + \left(L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1} \right) R^2 \right).$$

Поскольку M_{ℓ} и $M_{\mathbf{H}}$ являются константами, не зависящими от k , имеем:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2M_{\ell} + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}\left(\frac{1}{k}\right) \rightarrow 0 \text{ при } k \rightarrow \infty,$$

что доказывает асимптотическую сходимость к нулю.

Из выражения для $M_{\mathbf{H}}$ и асимптотики нормы матрицы Гессе $\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \propto L(hM)^{2L}$ (см. теорему 9) следует, что $M_{\mathbf{H}} \propto L(hM)^{2L}$, где h — размер скрытого слоя, а M — константа, ограничивающая параметры и данные. Следовательно,

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \propto \frac{L(hM)^{2L}R^2}{k},$$

что завершает доказательство. □

На основе теоремы 3 и использованных в ее доказательстве оценок нормы матрицы Гессе получается выражение для ландшафтной меры полносвязной нейросетевой модели глубокого обучения, которое сформулировано в следствии 2.

Следствие 2 (Асимптотика ландшафтной меры для полносвязных сетей). *Ландшафтная мера сложности параметрической функции f полносвязной нейросетевой модели глубокого обучения имеет асимптотику:*

$$\mu_f(f|D) \propto L(hM)^{2L},$$

где M — некоторая константа, ограничивающая параметры и данные.

Теорема 3 и следствие 2 устанавливают, что сходимость ландшафта функции потерь для полносвязных сетей происходит со скоростью $O(L(hM)^{2L}/k)$ при увеличении размера выборки k . Это означает, что для более глубоких сетей требуется больше данных для стабилизации ландшафта, что согласуется с интуитивным представлением о том, что сложные модели требуют большего объема данных для обучения.

В работе [11] показано, что существуют функции, которые могут быть эффективно представлены трехслойными сетями, но требуют экспоненциального числа нейронов в двухслойных сетях. Следствие 2 указывает на схожий результат: сложность модели увеличивается экспоненциально при увеличении числа слоев ($\mu_f(f|D) \propto L(hM)^{2L}$), и, следовательно, при уменьшении числа слоев для сохранения заданной сложности модели потребуется экспоненциальный рост параметров. Это демонстрирует фундаментальный компромисс между глубиной и шириной нейронных сетей с точки зрения их выразительной способности.

2.3.2. Теоретические оценки для сверточных сетей

В настоящем подразделе получены оценки ландшафтной меры сложности для сверточных нейронных сетей, широко применяющихся в задачах обработки

последовательностей и изображений. Анализ ландшафта основан на результатах о матрицах Гессе, представленных в главе 3.

Начнем с анализа 1D-сверточных сетей, применяющихся в обработке последовательностей, временных рядов и сигналов. Основные результаты для определения ландшафтной меры сложности сформулированы в теореме 4.

Теорема 4 (Сходимость ландшафта для 1D-сверточных сетей). *Пусть параметры $\boldsymbol{\theta}$ находятся в R -окрестности оптимума:*

$$\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\| \leq R,$$

а функция потерь ограничена некоторой константой:

$$\exists M_\ell > 0 : \forall i |\ell_i| \leq M_\ell.$$

Пусть все объекты в наборе данных ограничены:

$$\exists M_{\mathbf{x}} > 0 \forall i \|\mathbf{x}_i\| \leq M_{\mathbf{x}}.$$

Тогда в условиях теоремы 13:

$$\begin{aligned} |\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| &\leq \frac{2}{k+1} M_\ell + \\ &+ \frac{2}{k+1} R^2 \sqrt{2} d^2 M_{\mathbf{x}}^2 (L+1) (C^2 w^2 k d)^L, \end{aligned}$$

где $M_{\mathbf{x}}$ — константа, ограничивающая нормы объектов данных.

Доказательство. Доказательство проводится аналогично доказательству теоремы 3 с подстановкой оценок нормы матрицы Гессе из теоремы 13. $\square$

На основе теоремы 4 и использованных в ее доказательстве оценок нормы матрицы Гессе получается выражение для ландшафтной меры 1D-сверточной нейросетевой модели, которое сформулировано в следствии 3.

Следствие 3 (Асимптотика ландшафтной меры для 1D-сверточных сетей). *Ландшафтная мера сложности параметрической функции f 1D-сверточной модели глубокого обучения имеет асимптотику:*

$$\mu_f(f|D) \propto L(C^2 M^2 k d)^L,$$

где C — максимальное число каналов, d — длина входной последовательности, k — размер свертки, M — некоторая константа, ограничивающая параметры и данные.

Теорема 4 и следствие 3 показывают, что для 1D-сверточных сетей сходимость ландшафта происходит со скоростью $O(L(C^2 M^2 k d)^L / k)$. Полученные оценки демонстрируют, что сложность 1D-сверточных нейросетевых моделей экспоненциально зависит от глубины L и полиномиально — от остальных гиперпараметров архитектуры. Особенностью 1D-архитектур является линейная зависимость от длины последовательности d , что отражает специфику обработки последовательностей и отличает их от полносвязных сетей, где такая зависимость отсутствует.

Перейдем к анализу 2D-сверточных сетей, применяющихся в задачах обработки изображений.

Основные результаты для определения ландшафтной меры сложности 2D-сверточных сетей сформулированы в теореме 5.

Теорема 5 (Сходимость ландшафта для 2D-сверточных сетей). *Пусть параметры θ находятся в R -окрестности оптимума:*

$$\|\theta - \theta^*\| \leq R.$$

Также функция потерь ограничена некоторой константой:

$$\exists M_\ell > 0 : \forall i |\ell_i| \leq M_\ell.$$

Пусть все объекты в наборе данных также ограничены:

$$\exists M_x > 0 \forall i \|\mathbf{x}_i\| \leq M_x.$$

Тогда при выполнении условий теоремы 14 справедливо:

$$\begin{aligned} |\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)| &\leq \frac{2}{k+1} M_\ell + \\ &+ \frac{2}{k+1} R^2 \sqrt{2} q^2 M_x^2 (L+1) (C^2 k^2 w^2 m n)^L, \end{aligned}$$

где $q^2 = C^2 k^2 m n$, а M_x — константа, ограничивающая нормы объектов данных.

Доказательство. Доказательство проводится аналогично доказательству теоремы 3 с подстановкой оценок нормы матрицы Гессе из теоремы 14. $\square$

На основе теоремы 5 и использованных в ее доказательстве оценок нормы матрицы Гессе получается выражение для ландшафтной меры 2D-сверточной нейросетевой модели, которое сформулировано в следствии 4.

Следствие 4 (Асимптотика ландшафтной меры для 2D-сверточных сетей). *Ландшафтная мера сложности параметрической функции f 2D-сверточной модели глубокого обучения имеет асимптотику:*

$$\mu_f(f|D) \propto C^2 k^2 L (C^2 k^2 M^2 m n)^L,$$

где C — максимальное число каналов, m, n — размеры входного изображения, k — размер свертки, M — некоторая константа, ограничивающая параметры и данные.

Теорема 5 и следствие 4 устанавливают, что для 2D-сверточных сетей сходимость ландшафта происходит со скоростью $O(C^2 k^2 L (C^2 k^2 M^2 m n)^L / k)$. Для 2D-сверточных сетей наблюдается более быстрый рост сложности по сравнению с 1D-архитектурами, что обусловлено двумерной природой данных: зависимость от размеров изображения $m \times n$ является квадратичной, в отличие от линейной зависимости от длины последовательности в 1D-сверточных сетях.

Следствие 5 (Снижение ландшафтной меры при пулинге). *Пусть выполнены условия теоремы 5, а сверточная сеть дополнительно содержит слой MaxPool2D или AvgPool2D с ядром $k_{\text{pool}} \times k_{\text{pool}}$ в позиции l в смысле теорем 15 и 16. Тогда верхняя оценка ландшафтной меры приобретает множитель $(1/k_{\text{pool}}^2)^{L-l+2}$:*

$$\mu_f(f|D) \propto C^2 k^2 L \left(\frac{1}{k_{\text{pool}}^2} \right)^{L-l+2} (C^2 k^2 M^2 m n)^L.$$

В частности, более раннее расположение пулинга (меньшая позиция l) сильнее снижает верхнюю оценку сложности модели.

Следствие 5 переносит на ландшафтную меру снижающий эффект пулинга, известный для спектральных норм матриц Гессе: операция пулинга частично компенсирует рост сложности с глубиной сети.

2.3.3. Теоретические оценки для трансформеров

Архитектура трансформеров представляет собой один из наиболее значимых результатов в области глубокого обучения последних лет. Указанные модели демонстрируют лучшие на текущий момент результаты в задачах обработки естественного языка, компьютерного зрения и других областях. Особенностью трансформеров является механизм самовнимания, который позволяет модели учитывать глобальные зависимости в данных независимо от их положения. В настоящем подразделе получены оценки ландшафтной меры сложности для трансформерных моделей, основанные на анализе матриц Гессе компонентов трансформера.

Теорема 6 (Сходимость ландшафта для трансформеров). *Для одного блока самовнимания и одного блока трансформера 3.9 при условии ограниченности функции потерь*

$$0 \leq \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \leq L,$$

и ограниченности норм матриц Гессе справедливо:

$$|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \leq \frac{2L}{k+1} + \frac{M \|\mathbf{w} - \mathbf{w}^*\|_2^2}{(k+1)},$$

где для блока самовнимания константа M может быть непосредственно вычислена из Теоремы 18, а для блока трансформера $M = M_{tr}$ вычисляется в соответствии с Теоремой 27.

Доказательство. Доказательство проводится в несколько этапов. На первом этапе оценивается разность значений функции потерь в оптимальной точке,

на втором этапе оценивается разность гессианов. На третьем этапе, используя результаты обоих этапов, производится объединение оценок.

Рассмотрим разность эмпирических функций потерь при добавлении нового объекта. Используя разложение разности и свойства норм, получаем:

$$\begin{aligned} |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| &\leq \frac{1}{k+1} \left| \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| + \\ &\quad + \frac{1}{2(k+1)} \|\mathbf{w} - \mathbf{w}^*\|_2^2 \left\| \mathbf{H}_{k+1}(\mathbf{w}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2. \end{aligned}$$

Первое слагаемое характеризует изменение значения функции потерь в оптимальной точке параметров $\mathbf{w}^*$ при добавлении нового объекта. Это разность между значением потерь на новом объекте и средним значением потерь на предыдущей выборке, до добавления нового объекта. Предположим, что функция потерь $\ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i)$ ограничена сверху константой L для всех объектов выборки:

$$0 \leq \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \leq L.$$

Это предположение является естественным для большинства функций потерь, используемых в машинном обучении, таких как кросс-энтропия или средне-квадратичная ошибка. Тогда для нового объекта выполняется:

$$\ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) \leq L,$$

а для среднего значения по предыдущей выборке:

$$\frac{1}{k} \sum_{i=1}^k \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \leq \frac{1}{k} \sum_{i=1}^k L = L.$$

Используя неравенство треугольника для модуля разности, получаем:

$$\left| \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| \leq L + L = 2L.$$

Таким образом, вклад первого слагаемого в общую оценку не превосходит:

$$\frac{1}{k+1} \left| \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| \leq \frac{2L}{k+1}.$$

Второе слагаемое в оценке связано с изменением гессиана функции потерь. Рассмотрим выражение:

$$\left\| \mathbf{H}_{k+1}(\mathbf{w}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2,$$

где $\mathbf{H}_{k+1}(\mathbf{w}^*) = \nabla_{\mathbf{w}}^2 \ell(\mathbf{f}_{\mathbf{w}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1})$ — матрица Гессе функции потерь для нового объекта, а $\frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) = \mathbf{H}_k(\mathbf{w}^*)$ — средняя матрица Гессе по всей предыдущей выборке. Перепишем это выражение в эквивалентной форме:

$$\begin{aligned} \mathbf{H}_k(\mathbf{w}^*) &= \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*), \\ \mathbf{H}_{k+1}(\mathbf{w}^*) - \mathbf{H}_k(\mathbf{w}^*) &= \mathbf{H}_{k+1}(\mathbf{w}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*). \end{aligned}$$

Для оценки нормы этой разности используем неравенство треугольника:

$$\left\| \mathbf{H}_{k+1}(\mathbf{w}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2 \leq \|\mathbf{H}_{k+1}(\mathbf{w}^*)\|_2 + \left\| \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2.$$

Предположим, что выполняется ограниченность следующих матриц Гессе:

$$\|\mathbf{H}_i(\mathbf{w}^*)\|_2 \leq M$$

для некоторой константы M . Тогда для гессиана нового объекта:

$$\|\mathbf{H}_{k+1}(\mathbf{w}^*)\|_2 \leq M,$$

а для суммы гессианов:

$$\left\| \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2 \leq \sum_{i=1}^k \|\mathbf{H}_i(\mathbf{w}^*)\|_2 \leq kM.$$

Следовательно:

$$\left\| \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2 \leq \frac{1}{k} \cdot kM = M.$$

Объединяя полученные оценки, получаем:

$$\left\| \mathbf{H}_{k+1}(\mathbf{w}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2 \leq M + M = 2M.$$

Теперь оценим вклад второго слагаемого в общую разность функций потерь:

$$\begin{aligned} \frac{1}{2(k+1)} \|\mathbf{w} - \mathbf{w}^*\|_2^2 \|\mathbf{H}_{k+1}(\mathbf{w}^*) - \mathbf{H}_k(\mathbf{w}^*)\|_2 &\leq \frac{2M}{2(k+1)} \|\mathbf{w} - \mathbf{w}^*\|_2^2 = \\ &= \frac{M \|\mathbf{w} - \mathbf{w}^*\|_2^2}{k+1}. \end{aligned}$$

Комбинируя оценки для обоих слагаемых, получаем итоговую оценку:

$$|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \leq \frac{2L}{k+1} + \frac{M \|\mathbf{w} - \mathbf{w}^*\|_2^2}{k+1}.$$

□

2.4. Ландшафтная мера и радемахеровская сложность в задаче регрессии

Глубокие нейронные сети обучаются через решение высокоразмерных невыпуклых задач оптимизации. Поэтому геометрия ландшафта функции потерь существенна для анализа оптимизации и локальной устойчивости решений [106, 107, 108]. В то же время статистическая теория обучения описывает классы моделей через меры емкости, контролирующие расхождение между эмпирическим и генеральным риском [36, 109]. Для задачи скалярной регрессии с полносвязными ReLU-сетями существенны оба взгляда, однако при квадратичной функции потерь их связь обычно не формулируется через единый объект сложности [36, 109, 70].

В литературе уже имеются необходимые элементы такого анализа [36, 107, 70]. Эмпирические и теоретические исследования изучают спектры матриц Гессе, концентрацию кривизны и структурные свойства поверхностей потерь нейронных сетей [107, 108, 110, 111, 112]. Классическая теория сложности использует радемахеровскую, гауссовскую, VC- и псевдоразмерностные характеристики для контроля равномерных отклонений на классах нейросетевых функций [36, 109, 113]. Для полносвязных ReLU-архитектур ранее были получены гессиановые спектральные оценки в постановке кросс-энтропии, а также связь

этих оценок с анализом приращения эмпирического риска при росте выборки [70].

Тем не менее регрессионная постановка остается неполной [36, 109, 70]. Оценки равномерной емкости описывают размер класса гипотез, но не измеряют напрямую изменение кривизны по объектам обучения при фиксированном значении параметров [36, 109]. Гессиановый анализ, напротив, имеет локальный характер и часто разрабатывается для других функций потерь или других задач [70, 114, 115]. В результате для скалярной регрессии при квадратичной функции потерь роль разброса пообъектных матриц Гессе не выделена в явном виде и не сопоставлена напрямую с эмпирической радемахеровской сложностью для тех же полносвязных архитектур [36, 70].

В настоящем разделе указанный пробел восполняется анализом ландшафтной меры сложности [70]. Мера определяется как разброс пообъектных матриц Гессе относительно их эмпирического среднего. Ее введение мотивируется гессиановым анализом приращения эмпирического риска при увеличении обучающей выборки [70]. Здесь предыдущие спектральные оценки для полносвязных сетей адаптируются к постановке среднеквадратичной ошибки. Аргументы, связанные с ростом выборки, используются только для пояснения того, почему величина разброса матриц Гессе является естественным локальным показателем [70, 116]. Так возникает регрессионная локальная мера сложности, которую можно сопоставлять с эмпирической радемахеровской сложностью для тех же классов моделей [36, 109, 70].

Полученные результаты показывают, как ландшафтная мера сложности зависит от глубины, ширины и нормовых ограничений в полносвязных сетях без смещений. Также показано, чем эта зависимость отличается от поведения эмпирической радемахеровской сложности в линейном и двухслойном режимах [36, 113, 70]. Отдельно выделяется упрощение, возникающее для квадратичной функции потерь по сравнению с softmax-шаблоном. Теоретические порядки сведены в сравнительную таблицу и дополнены контролируемыми численными

экспериментами, качественно согласующимися с теоретическими оценками [70]. Таким образом, в этом разделе ландшафтная мера сложности строится как регрессионная гессиановая характеристика и сопоставляется с классической равномерной сложностью для полносвязных ReLU-моделей [36, 109, 70].

Обзор предшествующих результатов.

Исследования ландшафтов функции потерь нейронных сетей развиваются в нескольких направлениях. Качественный анализ невыпуклых поверхностей выделяет локальные минимумы, седловую структуру и геометрию бассейнов [117, 106]. Работы по визуализации изучают низкоразмерные проекции высокоразмерных целевых функций [62, 105]. Более количественная линия исследований сосредоточена на спектрах матриц Гессе и структуре кривизны. В эмпирических работах часто наблюдается основная масса почти нулевых собственных значений и небольшое число доминирующих направлений [107, 108, 110, 111]. Подходы на основе случайных матриц и масштабирования связывают такие структуры с шириной сети, случайностью данных и размером модели [112, 118]. Связь геометрии с обобщением также обсуждается через плоские и острые минимумы и связанные с ними представления об устойчивости [65, 119, 120]. Для рассматриваемой регрессионной постановки эта литература задает геометрический контекст, но сама по себе не дает единой локальной меры сложности, специально адаптированной к квадратичной функции потерь.

Второе направление изучает нейронные модели через глобальные меры сложности. Классические результаты, основанные на VC-размерности, числах покрытия, радемахеровской и гауссовской сложности, контролируют равномерные отклонения на классах гипотез [109, 36]. Для ReLU-сетей псевдоразмерность и связанные комбинаторные оценки уточняют зависимость от архитектуры и параметризации [113]. Эти инструменты являются фундаментальными для статистической теории обучения, однако они характеризуют емкость класса функций в худшем случае. Они не описывают изменение кривизны по обу-

чающим объектам при фиксированном опорном значении параметров. В этом смысле они отвечают на другой вопрос, чем локальная гессиановая постановка, развиваемая в данном разделе.

Отметим также несколько близких направлений с иной исследовательской целью. Анализ нейронного касательного ядра и предельно широких сетей связывает широкие модели с ядерными предикторами и почти линеаризованной динамикой обучения [114, 115]. Однако эти подходы не предназначены для количественного описания разброса пообъектных матриц Гессе в выбранной точке параметрического пространства. С технической стороны тензорные формы правил дифференцирования композиций помогают организовать разложения матриц Гессе в композиционных моделях [116]. Структурные исследования гессиановых отображений уточняют низкоранговые и послойные явления в нейронных сетях [111]. Здесь эти результаты используются главным образом как математический фон для последующих регрессионных формул.

Наиболее близкой предпосылкой является гессиановый анализ полносвязных ReLU-классификаторов [70]. В этой постановке пообъектные матрицы Гессе контролируются в спектральной норме и связываются с оценками приращения эмпирического риска при росте выборки для кросс-энтропии. Близкие гессиановые аргументы были также развиты для сверточных и матричных архитектур [121]. В настоящем разделе сохраняется полносвязная архитектурная постановка, но меняются три элемента анализа: классификация заменяется скалярной регрессией, кросс-энтропия заменяется квадратичной функцией потерь, а основной объект смещается от оценки приращения риска к самой ландшафтной мере сложности. Поэтому естественно сопоставить полученную локальную гессиановую характеристику с эмпирической радемахеровской сложностью для тех же линейных и двухслойных классов моделей.

2.4.1. Постановка задачи регрессии

Пусть пары $(\mathbf{x}, \mathbf{y})$ независимы и одинаково распределены на $\mathbb{R}^n \times \mathbb{R}$, а целевая переменная скалярна: $\mathbf{y}_i \in \mathbb{R}$. Пусть

$$D = \{(\mathbf{x}_1, \mathbf{y}_1), \dots, (\mathbf{x}_m, \mathbf{y}_m)\}, \quad |D| = m, \quad \mathbf{x}_i \in \mathbb{R}^n.$$

Пусть $f_{\boldsymbol{\theta}} : \mathbb{R}^n \rightarrow \mathbb{R}$ — L -слойная полносвязная ReLU-сеть с вектором параметров $\boldsymbol{\theta} \in \mathbb{R}^P$. Основные спектральные оценки матриц Гессе ниже дополнительно предполагают архитектуру без смещений и равномерные ограничения на веса и входы. Пообъектная квадратичная функция потерь имеет вид

$$\ell_i(\boldsymbol{\theta}) = \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{2}(f_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2, \quad \mathbf{y}_i = y_i \in \mathbb{R}. \quad (2.10)$$

Эмпирический риск на первых k наблюдениях равен

$$\mathcal{L}_k(\boldsymbol{\theta}) = \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i), \quad k = 1, \dots, m.$$

2.4.2. Ландшафтная мера при квадратичной функции потерь

В этом разделе ландшафтная мера сложности формализуется для квадратичной функции потерь. Исходной точкой служит гессиановый аппарат для полносвязных сетей [70]. Разность $\mathcal{L}_{k+1} - \mathcal{L}_k$ играет здесь вспомогательную роль: она показывает один из естественных второпорядковых механизмов, через который разброс матриц Гессе появляется при добавлении нового объекта в обучающую выборку. Второпорядковое приближение показывает, что ключевой член контролируется разностью между матрицей Гессе нового объекта и средней матрицей Гессе по первым k объектам. Ландшафтная мера сложности (2.11) количественно описывает типичный размер такого отклонения в спектральной норме. Сначала определяется мера μ_f и мягкое условие стационарности в опорной точке $\boldsymbol{\theta}^*$. Затем неравенство приращения выборки (2.13) выводится только как мотивация появления μ_f . После этого доказываются спектральные оценки

для $\|\mathbf{H}_i\|_2$ при равномерных ограничениях на веса и входы и выводится порядок роста μ_f . Следствия отдельно фиксируют линейный и односкрытослойный режимы.

Определение 22 (Ландшафтная мера сложности). Пусть $\mathbf{H}_i(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}}^2 \ell(f_{\boldsymbol{\theta}}(\mathbf{x}_i), \mathbf{y}_i)$. Ландшафтная мера сложности задается выражением

$$\mu_f(f \mid D) = \mathbb{E}_{\mathbf{x}_i \in D} \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbb{E}_{\mathbf{x}_i \in D} \mathbf{H}_i(\boldsymbol{\theta}^*)\|_2, \quad (2.11)$$

где $\mathbb{E}_{\mathbf{x}_i \in D}$ означает математическое ожидание по равномерно выбранному индексу из D при фиксированной опорной точке $\boldsymbol{\theta}^*$. Таким образом, μ_f велика, когда пообъектные матрицы Гессе существенно расходятся в операторной норме относительно своего среднего по D .

Для ReLU-сетей приведенные ниже выражения для матриц Гессе понимаются на областях пространства параметров, где паттерн активации каждого наблюдаемого входа фиксирован. Такие области покрывают пространство параметров с точностью до границ излома меры ноль, поэтому производные ниже интерпретируются почти всюду по $\boldsymbol{\theta}$ и, в частности, в тех опорных точках $\boldsymbol{\theta}^*$, где они существуют.

Предположение 2 (Приближенная стационарность в точке $\boldsymbol{\theta}^*$). Для некоторого $\varepsilon_g \geq 0$ выполнено

$$\|\nabla \mathcal{L}_k(\boldsymbol{\theta}^*)\|_2 \leq \varepsilon_g, \quad \|\nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*)\|_2 \leq \varepsilon_g. \quad (2.12)$$

Вместо точной критической точки допускаются малые градиенты в $\boldsymbol{\theta}^*$. Случай $\varepsilon_g = 0$ соответствует стационарной постановке, используемой в близких работах.

Пусть $\mathbf{H}^{(k)}(\boldsymbol{\theta}) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta})$. На областях, где соответствующие производные существуют, второпорядковое приближение $\mathcal{L}_{k+1}$ и $\mathcal{L}_k$ в окрестности $\boldsymbol{\theta}^*$ выделяет три вклада. Первый является членом нулевого порядка и связан с изменением средней функции потерь. Второй является квадратичным членом, определяемым разностью $\mathbf{H}^{(k+1)} - \mathbf{H}^{(k)}$. Третий состоит из линейных остатков,

контролируемых градиентными ограничениями (2.12). При предположении 2 это мотивирует локальную прокси-оценку

$$\begin{aligned} |\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| &\leq \frac{1}{k+1} \left| \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| \\ &\quad + \frac{\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2}{k+1} \left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2 + 2\varepsilon_g \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2. \end{aligned} \quad (2.13)$$

Соотношение (2.13) используется только как локальная прокси-оценка, основанная на приближении. Оно связывает рост выборки с разбросом матриц Гессе, но не является самостоятельным точным тождеством. Средний член в (2.13) связывает эту оценку с (2.11). Ограничение величины $\|\mathbf{H}_{k+1} - \frac{1}{k} \sum_{i \leq k} \mathbf{H}_i\|_2$ близко к контролю разброса пообъектных матриц Гессе вокруг их эмпирического среднего.

Обоснование. Обозначим $\boldsymbol{\delta} = \boldsymbol{\theta} - \boldsymbol{\theta}^*$. При предположении 2 и на областях, где соответствующие производные существуют, второпорядковые приближения имеют вид

$$\mathcal{L}_k(\boldsymbol{\theta}) \approx \mathcal{L}_k(\boldsymbol{\theta}^*) + \nabla \mathcal{L}_k(\boldsymbol{\theta}^*)^\top \boldsymbol{\delta} + \frac{1}{2} \boldsymbol{\delta}^\top \mathbf{H}^{(k)}(\boldsymbol{\theta}^*) \boldsymbol{\delta},$$

Здесь $\mathbf{H}^{(k)}(\boldsymbol{\theta}^*) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*)$. Аналогичная формула выполняется для $\mathcal{L}_{k+1}$. Вычитая два выражения, получаем

$$\begin{aligned} \mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta}) &\approx \mathcal{L}_{k+1}(\boldsymbol{\theta}^*) - \mathcal{L}_k(\boldsymbol{\theta}^*) + (\nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*) - \nabla \mathcal{L}_k(\boldsymbol{\theta}^*))^\top \boldsymbol{\delta} \\ &\quad + \frac{1}{2} \boldsymbol{\delta}^\top (\mathbf{H}^{(k+1)}(\boldsymbol{\theta}^*) - \mathbf{H}^{(k)}(\boldsymbol{\theta}^*)) \boldsymbol{\delta}. \end{aligned}$$

Разность нулевого порядка $\mathcal{L}_{k+1}(\boldsymbol{\theta}^*) - \mathcal{L}_k(\boldsymbol{\theta}^*)$ равна $\frac{1}{k+1} (\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i))$. Если $\varepsilon_g = 0$, линейные члены исчезают. Тогда квадратичный вклад сводится к форме из [70]. При $\varepsilon_g \geq 0$ к квадратичному члену применимы те же оценки модуля. По неравенству Коши–Буняковского и (2.12)

$$|(\nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*) - \nabla \mathcal{L}_k(\boldsymbol{\theta}^*))^\top \boldsymbol{\delta}| \leq (\|\nabla \mathcal{L}_{k+1}(\boldsymbol{\theta}^*)\|_2 + \|\nabla \mathcal{L}_k(\boldsymbol{\theta}^*)\|_2) \|\boldsymbol{\delta}\|_2 \leq 2\varepsilon_g \|\boldsymbol{\delta}\|_2.$$

Совместно с неравенством треугольника и оценкой $|\mathbf{u}^\top \mathbf{M} \mathbf{u}| \leq \|\mathbf{u}\|_2^2 \|\mathbf{M}\|_2$ для квадратичной части это приводит к локальной прокси-оценке (2.13).

Пусть $u = f_{\theta}(\mathbf{x})$. Для квадратичной функции потерь $\partial^2 \ell / \partial u^2 = 1$; для softmax-кросс-энтропии на логитах $\mathbf{u}$ выполнено $\|\partial^2 \ell / \partial \mathbf{u}^2\|_2 \leq \sqrt{2}$ [70]. Разложение $\mathbf{H}_i$ по правилу дифференцирования композиции следует из [70, раздел 3.4]. Для скалярного выхода оно сводится к сумме члена типа Гаусса–Ньютона и члена, взвешенного градиентом функции потерь. Следующая лемма задает конкретную величину $M_{\mathbf{H}}$ для полносвязных ReLU-сетей без смещений при спектральных ограничениях на веса и входы. Это выражение получается специализацией K -классовой оценки из [70, теорема 1] на скалярный выход и квадратичную функцию потерь.

Лемма 7 (Спектральная норма пообъектной матрицы Гессе для квадратичной потери и FC-сетей). *Рассмотрим полносвязную ReLU-сеть без смещений, для которой $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$, $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ для всех p и i . Тогда существует константа $M_{\mathbf{H}}$ такая, что для каждого i и каждой точки параметрического пространства, где требуемые производные существуют,*

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq M_{\mathbf{H}} := L M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L} + \sum_{s=1}^L M_{\mathbf{W}}^{2s}. \quad (2.14)$$

Если $|w_{ij}^{(p)}| \leq M$ на блоках размера $h \times h$, то $M_{\mathbf{W}} \leq hM$ и асимптотически $\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 = O(L(hM)^{2L})$.

Доказательство. Обозначим $u_i = f_{\theta}(\mathbf{x}_i)$ и $\ell(u, y) = \frac{1}{2}(u - y)^2$. Разложение матрицы Гессе для скалярного выхода имеет следующий вид. Для K -мерного вектора логитов $\mathbf{z}$ в [70, раздел 3.4] используется разложение

$$\mathbf{H}_i(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta} \mathbf{z}_i} \frac{\partial^2 \ell}{\partial \mathbf{z}_i^2} \nabla_{\boldsymbol{\theta} \mathbf{z}_i}^{\top} + \sum_{k=1}^K \frac{\partial \ell}{\partial z_{ik}} \nabla_{\boldsymbol{\theta} z_{ik}}^2.$$

Здесь $K = 1$, $\mathbf{z}_i = u_i \in \mathbb{R}$, $\partial^2 \ell / \partial u_i^2 = 1$ и $\partial \ell / \partial u_i = u_i - y_i$, поэтому

$$\mathbf{H}_i(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta} u_i} \nabla_{\boldsymbol{\theta} u_i}^{\top} + (u_i - y_i) \nabla_{\boldsymbol{\theta} u_i}^2. \quad (2.15)$$

Первое слагаемое имеет ранг один, а его спектральная норма равна $\|\nabla_{\boldsymbol{\theta} u_i}\|_2^2$. Второе слагаемое является матрицей Гессе сети, взвешенной остатком. Для

softmax-кросс-энтропии $\partial^2 \ell / \partial \mathbf{z}^2 = \text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top$ и $\|\partial^2 \ell / \partial \mathbf{z}^2\|_2 \leq \sqrt{2}$ [70]; именно множитель $\sqrt{2}$ появляется в теореме 1 указанной работы.

Из (2.15) и неравенства треугольника следует поточечная спектральная оценка

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq \|\nabla_{\boldsymbol{\theta}} u_i\|_2^2 + |u_i - y_i| \|\nabla_{\boldsymbol{\theta}}^2 u_i\|_2. \quad (2.16)$$

Эта оценка явно выделяет остаток $|u_i - y_i|$ во втором слагаемом. В отличие от нее, лемма 7 фиксирует *равномерную* мажоранту вида (2.14). Такая мажоранта получается специализацией анализа полносвязных сетей из [70, теорема 1 и приложение A.2] с K -классового softmax на скалярный выход и квадратичную функцию потерь.

Теорема 1 из [70] для постановки кросс-энтропии утверждает, что

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq L\sqrt{2} M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L} + \sqrt{2} \frac{M_{\mathbf{W}}^2 (M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1}.$$

В приложении A.2 указанной работы эта замкнутая форма выводится при $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$ и $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$. Множители $\sqrt{2}$ соответствуют спектральной норме гессиана softmax-потери: $\|\partial^2 \ell / \partial \mathbf{z}^2\|_2 \leq \sqrt{2}$. Для скалярного выхода и квадратичной функции потерь внешний гессиан является скаляром $\partial^2 \ell / \partial u^2 = 1$. Якобиан $\nabla_{\boldsymbol{\theta}} \mathbf{z}_i$ сводится к столбцу $\nabla_{\boldsymbol{\theta}} u_i$. В этой специализации множитель softmax-потери $\sqrt{2}$ заменяется на 1, а зависимость от L , $M_{\mathbf{x}}$ и $M_{\mathbf{W}}$ сохраняется. Запись второго слагаемого в виде эквивалентной конечной суммы $\sum_{s=1}^L M_{\mathbf{W}}^{2s}$ устраняет съемную особенность при $M_{\mathbf{W}} = 1$ и дает (2.14).

Тождество (2.15) является точным, а (2.16) является поточечным неравенством. Замкнутая форма (2.14) является MSE-аналогом теоремы 1 из [70] и не претендует на точность по $|u_i - y_i|$ (ср. (2.16)). Если $|w_{ij}^{(p)}| \leq M$ на блоках $h \times h$, то $M_{\mathbf{W}} \leq hM$ и асимптотически $\|\mathbf{H}_i\|_2 = O(L(hM)^{2L})$.

Как следствие, локальная прокси-оценка (2.13) вместе либо с равномерной гессиановой оценкой из леммы 7, либо с точным MSE-разложением (2.15) дает вклад порядка $O(1/k)$ в величину $|\mathcal{L}_{k+1} - \mathcal{L}_k|$. Отдельный стационарный член, пропорциональный ε_g , в общем случае не исчезает.

Теорема 8 (Локальная оценка ландшафтного приращения для квадратичной потери и FC-сетей). Пусть $\boldsymbol{\theta}$ удовлетворяет $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2 \leq R$. Предположим, что $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_\ell$ для всех i , лемма 7 применима в точке $\boldsymbol{\theta}^*$, а предположение 2 выполнено с некоторым $\varepsilon_g \geq 0$. Тогда при условии локальной прокси-оценки (2.13)

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2}{k+1} (M_\ell + M_{\mathbf{H}} R^2) + 2\varepsilon_g R. \quad (2.17)$$

Это оценка худшего случая, полученная из равномерного контроля матрицы Гессе в локальной прокси-постановке. С учетом асимптотики $M_{\mathbf{H}}$ вклад кривизны имеет порядок

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| = O\left(\frac{L(hM)^{2L} R^2}{k}\right) \quad (2.18)$$

как в лемме 2 работы [70].

Далее фиксируется уточнение, учитывающее величину остатков. Если, кроме того,

$$|f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y, \quad i = 1, \dots, m,$$

и каждый наблюдаемый вход остается в фиксированной области активации в окрестности $\boldsymbol{\theta}^*$, зададим

$$\mathbf{g}_i := \nabla_{\boldsymbol{\theta}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \quad M_{\nabla^2 f} := \max_{1 \leq i \leq m} \|\nabla_{\boldsymbol{\theta}}^2 f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)\|_2.$$

Тогда

$$\|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbf{g}_i \mathbf{g}_i^\top\|_2 \leq \varepsilon_y M_{\nabla^2 f} \quad (2.19)$$

для каждого i , и

$$\mu_f(f \mid D) \leq 2 \max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 + 2\varepsilon_y M_{\nabla^2 f}. \quad (2.20)$$

следовательно,

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{\varepsilon_y^2 + 2R^2 (\max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 + \varepsilon_y M_{\nabla^2 f})}{k+1} + 2\varepsilon_g R. \quad (2.21)$$

Если дополнительно $\|\mathbf{W}^{(p)*}\|_2 \leq M_{\mathbf{W}}$ для каждого слоя и $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ для всех i , то

$$\max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2}, \quad (2.22)$$

откуда

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{\varepsilon_y^2 + 2R^2(LM_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2} + \varepsilon_y M_{\nabla^2 f})}{k+1} + 2\varepsilon_g R. \quad (2.23)$$

В этой окрестности функция $f_{\boldsymbol{\theta}}$ дважды дифференцируема на наблюдаемых входах. Частный случай $\varepsilon_y = 0$ соответствует точной интерполяции и сводит (2.19) к тождеству Гаусса–Ньютона.

Доказательство. Предположим выполнение локальной прокси-оценки (2.13).

Сначала ограничим первый член:

$$\left| \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| \leq \left| \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) \right| + \frac{1}{k} \sum_{i=1}^k \left| \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| \leq$$

где используется $|\ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i)| \leq M_{\ell}$ для каждого i . Для разности матриц Гессе неравенство треугольника дает

$$\left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2 \leq \|\mathbf{H}_{k+1}(\boldsymbol{\theta}^*)\|_2 + \frac{1}{k} \sum_{i=1}^k \|\mathbf{H}_i(\boldsymbol{\theta}^*)\|_2 \leq 2M_{\mathbf{H}},$$

так как $\|\mathbf{H}_i(\boldsymbol{\theta}^*)\|_2 \leq M_{\mathbf{H}}$ для всех i по лемме 7. Подставим это в (2.13) и используем $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2 \leq R$ и $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \leq R^2$:

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{2M_{\ell}}{k+1} + \frac{2M_{\mathbf{H}}R^2}{k+1} + 2\varepsilon_g R = \frac{2}{k+1}(M_{\ell} + M_{\mathbf{H}}R^2) + 2\varepsilon_g R,$$

что совпадает с (2.17). Порядок (2.18) при $\varepsilon_g = 0$ следует из подстановки асимптотической верхней оценки $M_{\mathbf{H}} = O(L(hM)^{2L})$ из леммы 7.

Теперь предположим, что $|f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y$ для каждого i , и зададим $\mathbf{g}_i := \nabla_{\boldsymbol{\theta}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)$ and $M_{\nabla^2 f} := \max_i \|\nabla_{\boldsymbol{\theta}}^2 f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)\|_2$. Тогда из (2.15) следует

$$\mathbf{H}_i(\boldsymbol{\theta}^*) = \mathbf{g}_i \mathbf{g}_i^{\top} + (f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i) \nabla_{\boldsymbol{\theta}}^2 f_{\boldsymbol{\theta}^*}(\mathbf{x}_i),$$

откуда

$$\|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbf{g}_i \mathbf{g}_i^{\top}\|_2 \leq \varepsilon_y M_{\nabla^2 f},$$

что и дает (2.19).

Пусть $\bar{\mathbf{H}} := \frac{1}{m} \sum_{j=1}^m \mathbf{H}_j(\boldsymbol{\theta}^*)$ и $\bar{\mathbf{G}} := \frac{1}{m} \sum_{j=1}^m \mathbf{g}_j \mathbf{g}_j^\top$. Тогда

$$\begin{aligned} \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \bar{\mathbf{H}}\|_2 &\leq \|\mathbf{g}_i \mathbf{g}_i^\top - \bar{\mathbf{G}}\|_2 + \|\mathbf{H}_i(\boldsymbol{\theta}^*) - \mathbf{g}_i \mathbf{g}_i^\top\|_2 + \|\bar{\mathbf{H}} - \bar{\mathbf{G}}\|_2 \\ &\leq \|\mathbf{g}_i\|_2^2 + \frac{1}{m} \sum_{j=1}^m \|\mathbf{g}_j\|_2^2 + \varepsilon_y M_{\nabla^2 f} + \frac{1}{m} \sum_{j=1}^m \|\mathbf{H}_j(\boldsymbol{\theta}^*) - \mathbf{g}_j \mathbf{g}_j^\top\|_2 \\ &\leq 2 \max_{1 \leq j \leq m} \|\mathbf{g}_j\|_2^2 + 2\varepsilon_y M_{\nabla^2 f}, \end{aligned}$$

поскольку $\|\mathbf{g}_i \mathbf{g}_i^\top\|_2 = \|\mathbf{g}_i\|_2^2$ и $\|\cdot\|_2$ является выпуклой функцией. Усреднение по i дает (2.20).

Вернемся к (2.13). Так как $\ell_i(\boldsymbol{\theta}^*) = \frac{1}{2}(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i)^2 \leq \frac{1}{2}\varepsilon_y^2$ для всех i , член нулевого порядка не превосходит $\varepsilon_y^2/(k+1)$. Для квадратичного члена имеем

$$\left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2 \leq 2 \max_{1 \leq i \leq m} \|\mathbf{g}_i\|_2^2 + 2\varepsilon_y M_{\nabla^2 f},$$

по тому же аргументу усреднения на первых $k+1$ объектах. Подстановка в (2.13) дает (2.21).

Остается доказать (2.22). Запишем прямые активации как $\mathbf{a}^{(0)} = \mathbf{x}_i$, $\mathbf{a}^{(p)} = \sigma(\mathbf{W}^{(p)*} \mathbf{a}^{(p-1)})$ для $p = 1, \dots, L-1$ и $f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) = \mathbf{W}^{(L)*} \mathbf{a}^{(L-1)}$. Так как ReLU является 1-липшицевой и положительно однородной функцией,

$$\|\mathbf{a}^{(p)}\|_2 \leq M_{\mathbf{W}}^p \|\mathbf{x}_i\|_2 \leq M_{\mathbf{W}}^p M_{\mathbf{x}}.$$

Для обратно распространяемых производных $\boldsymbol{\delta}^{(L)} = 1$ и $\boldsymbol{\delta}^{(p)} = \mathbf{D}^{(p)}(\mathbf{W}^{(p+1)*})^\top \boldsymbol{\delta}^{(p+1)}$ с диагональными ReLU-масками $\mathbf{D}^{(p)}$, удовлетворяющими $\|\mathbf{D}^{(p)}\|_2 \leq 1$, получаем

$$\|\boldsymbol{\delta}^{(p)}\|_2 \leq M_{\mathbf{W}}^{L-p}.$$

Градиент по весам слоя p равен $\nabla_{\mathbf{W}^{(p)}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) = \boldsymbol{\delta}^{(p)}(\mathbf{a}^{(p-1)})^\top$, поэтому его норма Фробениуса удовлетворяет оценке

$$\|\nabla_{\mathbf{W}^{(p)}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)\|_F \leq \|\boldsymbol{\delta}^{(p)}\|_2 \|\mathbf{a}^{(p-1)}\|_2 \leq M_{\mathbf{W}}^{L-p} M_{\mathbf{W}}^{p-1} M_{\mathbf{x}} = M_{\mathbf{x}} M_{\mathbf{W}}^{L-1}.$$

Суммирование квадратов норм Фробениуса по $p = 1, \dots, L$ дает

$$\left\| \nabla_{\boldsymbol{\theta}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) \right\|_2^2 = \sum_{p=1}^L \|\nabla_{\mathbf{W}^{(p)}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)\|_F^2 \leq L M_{\mathbf{x}}^2 M_{\mathbf{W}}^{2L-2},$$

что совпадает с (2.22). Подстановка этого соотношения в (2.21) доказывает (2.23).

Следующие утверждения фиксируют линейный и неглубокий случаи. Затем следствие 8 суммирует порядок роста μ_f , вытекающий из леммы 7. Для одного скрытого слоя $L = 2$, поэтому множитель $(hM)^{2L}$ в общей оценке превращается в $(hM)^4$, если ограничение на входы считается фиксированным и включается в неявную константу.

Следствие 6 (Линейная модель). *Если $f_{\boldsymbol{\theta}}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$, где $\boldsymbol{\theta} = \mathbf{w} \in \mathbb{R}^n$, и используется та же квадратичная функция потерь (2.10), то $\mathbf{H}_i(\boldsymbol{\theta}) = \mathbf{x}_i \mathbf{x}_i^\top$ не зависит от $\mathbf{w}$ и y_i , поэтому $\|\mathbf{H}_i\|_2 = \|\mathbf{x}_i\|_2^2$. При $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ можно положить $M_{\mathbf{H}} = M_{\mathbf{x}}^2$ в лемме 7 и следствии 8, заменив оценку для ReLU-сети этой ранговой матрицей Гессе. Ландшафтная мера сложности (2.11) в этом случае определяется разбросом ранговых матриц $\mathbf{x}_i \mathbf{x}_i^\top$ вокруг их выборочного среднего.*

Следствие 7 (Один скрытый слой, FC ReLU). *Рассмотрим один скрытый слой ширины h : $\mathbb{R}^n \rightarrow \mathbb{R}^h \rightarrow \mathbb{R}$ с ReLU и матрицами весов без смещений, удовлетворяющими тем же спектральным ограничениям, что и в лемме 7. В обозначениях следствия 8 это случай $L = 2$, поэтому (2.24) дает верхнюю оценку $\mu_f(f \mid D) = O((hM)^4)$, в отличие от более глубоких сетей, где множитель $(hM)^{2L}$ быстрее растет по L . Отдельно, если в опорной точке $\boldsymbol{\theta}^*$ пообъектные остатки равномерно малы, $|f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y$ для всех i , то учитывающая остатки часть теоремы 8 и точное тождество (2.19) дают оценку (2.20) для $\mu_f(f \mid D)$; при покоординатных ограничениях это уточняет оценку худшего случая $O(h^4)$.*

Лемма 7 также задает порядок ландшафтной меры сложности (2.11) через глубину, ширину и нормовые ограничения.

Следствие 8 (Масштабирование ландшафтной меры сложности). *При условиях леммы 7, покоординатных ограничениях $|w_{ij}^{(p)}| \leq M$ на соответствующих*

блоках весов размера $h \times h$ и фиксированном ограничении $M_{\mathbf{x}}$ на входы мера (2.11) удовлетворяет оценке

$$\mu_f(f \mid D) = O(L(hM)^{2L}), \quad (2.24)$$

где h обозначает ширину скрытого слоя, L — глубину, а M — покоординатное ограничение на веса; ограничение $M_{\mathbf{x}}$ включено в неявную константу.

2.4.3. Сопоставление с радемахеровской сложностью

В разделе 2.4.2. были получены локальные прокси-оценки приращения эмпирического риска, а также верхние оценки ландшафтной меры сложности $\mu_f(f \mid D)$ для полносвязных отображений. Здесь эти порядки сопоставляются с классической *равномерной* сложностью. Эмпирическая радемахеровская сложность (2.25) измеряет, насколько класс вещественнозначных функций может коррелировать со случайными знаками на наблюдаемых входах равномерно по всему классу [36]. Сравнение построено параллельно: используются одни и те же архитектуры и одна и та же квадратичная функция потерь (2.10). Однако две величины отвечают на разные вопросы. Ландшафтная мера сложности μ_f связана со второпорядковым разбросом пообъектных матриц Гессе в опорной точке, тогда как $\hat{\mathfrak{R}}_m$ связана с размером и липшицевой структурой семейства предикторов. В этом разделе выводятся явные или общие верхние оценки для $\hat{\mathfrak{R}}_m$, а также соответствующие оценки сверху для ландшафтной меры сложности μ_f из раздела 2.4.2.. Таблица 2.1 суммирует это сопоставление.

Определение 23 (Эмпирическая радемахеровская сложность). Пусть $\mathcal{F}$ — класс функций $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Для выборки D эмпирическая радемахеровская сложность определяется как

$$\hat{\mathfrak{R}}_m(\mathcal{F}) := \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(\mathbf{x}_i) \right], \quad (2.25)$$

где $\sigma_1, \dots, \sigma_m$ — независимые одинаково распределенные случайные знаки Радемахера.

Ниже $\mathcal{F}$ обозначает класс вещественнозначных предикторов $f_{\boldsymbol{\theta}}$ для соответствующей архитектуры; сравниваются $\hat{\mathfrak{R}}_m(\mathcal{F})$ и $\mu_f(f \mid D)$, построенная по матрицам Гессе тех же отображений в опорной точке $\boldsymbol{\theta}^*$.

2.4.4. Сопоставление мер для линейной модели

Линейный класс является простейшей постановкой: пообъектные матрицы Гессе являются ранговыми матрицами $\mathbf{x}_i \mathbf{x}_i^\top$, поэтому и $\hat{\mathfrak{R}}_m$, и μ_f допускают элементарные выражения через входы. Рассмотрим класс линейных предикторов

$$\mathcal{F}_{\text{lin}}(W) := \{f_{\mathbf{w}} : \mathbf{x} \mapsto \mathbf{w}^\top \mathbf{x} \mid \|\mathbf{w}\|_2 \leq W\}.$$

Радиус W является естественным аналогом нормовых ограничений на веса, возникающих в лемме 7 при $L = 1$.

Для эмпирической радемахеровской сложности из неравенства Коши–Буняковского следует $\frac{1}{m} \sum_i \sigma_i \mathbf{w}^\top \mathbf{x}_i = \mathbf{w}^\top \left(\frac{1}{m} \sum_i \sigma_i \mathbf{x}_i \right) \leq W \left\| \frac{1}{m} \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|_2$, причем равенство достигается при $\mathbf{w}$, параллельном $\sum_i \sigma_i \mathbf{x}_i$, если $\|\mathbf{w}\|_2 = W$. Следовательно,

$$\hat{\mathfrak{R}}_m(\mathcal{F}_{\text{lin}}(W)) = \frac{W}{m} \mathbb{E}_{\boldsymbol{\sigma}} \left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|_2. \quad (2.26)$$

Если $\|\mathbf{x}_i\|_2 \leq r$ для всех i , то $\mathbb{E}_{\boldsymbol{\sigma}} \left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|_2^2 = \sum_{i=1}^m \|\mathbf{x}_i\|_2^2$ и неравенство Йенсена дает $\mathbb{E}_{\boldsymbol{\sigma}} \left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|_2 \leq \left(\sum_{i=1}^m \|\mathbf{x}_i\|_2^2 \right)^{1/2}$, поэтому

$$\hat{\mathfrak{R}}_m(\mathcal{F}_{\text{lin}}(W)) \leq \frac{W}{m} \left(\sum_{i=1}^m \|\mathbf{x}_i\|_2^2 \right)^{1/2} \leq \frac{Wr}{\sqrt{m}}. \quad (2.27)$$

Если дополнительно координаты сопоставимы по масштабу так, что $\|\mathbf{x}_i\|_2^2 = \Theta(n)$ равномерно по i при $n \rightarrow \infty$, то верхняя оценка (2.27) имеет порядок $W\sqrt{n/m}$.

Аргументы на основе чисел покрытия и псевдоразмерности для линейных предикторов с ограниченной нормой также дают линейный по n порядок сложности в размерности пространства признаков при стандартных кодиров-

ках [36, 109]. Это совпадает с порядком верхней оценки для μ_f в (2.28). Основное сопоставление ниже проводится между (2.28) и (2.27).

Для ландшафтной меры сложности следствие 6 дает $\mathbf{H}_i = \mathbf{x}_i \mathbf{x}_i^\top$; обозначим $\bar{\mathbf{H}} := \frac{1}{m} \sum_{j=1}^m \mathbf{x}_j \mathbf{x}_j^\top$. Тогда

$$\|\mathbf{H}_i - \bar{\mathbf{H}}\|_2 \leq \|\mathbf{x}_i\|_2^2 + \|\bar{\mathbf{H}}\|_2 \leq \|\mathbf{x}_i\|_2^2 + \frac{1}{m} \sum_{j=1}^m \|\mathbf{x}_j\|_2^2,$$

где для второго слагаемого используется выпуклость нормы $\|\cdot\|_2$. Следовательно,

$$\mu_f(f \mid D) \leq 2 \max_{1 \leq i \leq m} \|\mathbf{x}_i\|_2^2 \quad (2.28)$$

для данной линейной модели; тот же аргумент усреднения лежит в основе следствия 8. Если $\|\mathbf{x}_i\|_2^2 = \Theta(n)$ при $n \rightarrow \infty$, то (2.28) дает верхнюю оценку $\mu_f(f \mid D) = O(n)$ с точностью до максимума по i .

При том же масштабировании входов μ_f допускает верхнюю оценку $O(n)$ по (2.28), тогда как $\hat{\mathfrak{R}}_m$ в (2.27) ограничена величиной порядка $W \sqrt{n/m}$.

2.4.5. Сопоставление мер для двухслойной сети с активацией ReLU

Далее рассматривается нелинейный класс с одним скрытым слоем. Эта постановка соответствует следствию 7 и лемме 7 при глубине $L = 2$. Верхняя оценка масштаба $\mu_f = O((hM)^4)$ из (2.24) уже существенно отличается от линейного случая. Поэтому естественно сопоставить ее с нормовыми радемахеровскими оценками, которые растут полиномиально по h , но содержат также множитель $m^{-1/2}$.

Рассмотрим один скрытый слой ширины h с $\sigma = \text{ReLU}$, весами без смещений и $f_\theta(\mathbf{x}) = \mathbf{w}^{(2)\top} \sigma(\mathbf{W}^{(1)} \mathbf{x})$. В обозначениях раздела 2.4.2. это глубина $L = 2$ в лемме 7.

Для эмпирической радемахеровской сложности обозначим через $\mathcal{F}_h$ указанный класс при ограничениях $\|\mathbf{W}^{(1)}\|_2 \leq M_{\mathbf{W}}$ и $\|\mathbf{w}^{(2)}\|_2 \leq M_{\mathbf{W}}$ либо при координатных ограничениях $|w_{ij}| \leq M$, как в лемме 7. Векторная контракция и

нормовые оценки [36] дают оценки вида

$$\hat{\mathfrak{R}}_m(\mathcal{F}_h) \lesssim \frac{C(\boldsymbol{\theta})}{m} \mathbb{E}_{\boldsymbol{\sigma}} \left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|_2 \lesssim \frac{C(\boldsymbol{\theta}) r}{\sqrt{m}}, \quad (2.29)$$

где $C(\boldsymbol{\theta})$ зависит от операторных норм или норм Фробениуса матриц $\mathbf{W}^{(1)}$ и $\mathbf{w}^{(2)}$ и при фиксированных покоординатных ограничениях $|w_{ij}| \leq M$ растет по h не быстрее полиномиально. Следовательно, радемахеровский член имеет порядок $O(m^{-1/2})$ по объему выборки и, при фиксированном M и ограниченных входах, порядок $O(\text{poly}(h)/\sqrt{m})$ по ширине. Равномерные оценки, основанные на числах покрытия или fat-shattering-размерности для кусочно-линейных сетей, также масштабируются с числом параметров и глубиной [36, 113]; эти оценки здесь не развиваются, а (2.29) используется как основной классический аналог для сопоставления с μ_f .

Для ландшафтной меры сложности следствие 7 и (2.24) при $L = 2$ дают верхнюю оценку $\mu_f(f \mid D) = O((hM)^4)$. При фиксированном M отсюда следует оценка худшего случая $\mu_f = O(h^4)$ при $h \rightarrow \infty$, тогда как приведенная выше радемахеровская оценка имеет вид $O(\text{poly}(h)/\sqrt{m})$ и при типичных нормовых ограничениях содержит меньшую степень по h .

Порядок $O(h^4)$ является *равномерной оценкой худшего случая*, следующей из леммы 7; он не использует специальную структуру квадратичной функции потерь в режиме малых остатков. Если остатки удовлетворяют $|f_{\boldsymbol{\theta}^*}(\mathbf{x}_i) - y_i| \leq \varepsilon_y$, то второй член в разложении (2.15) контролируется величиной ε_y , и применимо уточнение из теоремы 8. Для двухслойной сети с $|w_{ij}| \leq M$ имеем

$$\|\nabla_{\boldsymbol{\theta}} f_{\boldsymbol{\theta}^*}(\mathbf{x}_i)\|_2^2 = \sum_{j=1}^h \sigma((\mathbf{w}_j^{(1)*})^\top \mathbf{x}_i)^2 + \sum_{j=1}^h (w_j^{(2)*})^2 a_{ij} \|\mathbf{x}_i\|_2^2 \leq hM^2 (\|\mathbf{x}_i\|_1^2 + \|\mathbf{x}_i\|_2^2),$$

где $a_{ij} = \mathbf{1}\{(\mathbf{w}_j^{(1)*})^\top \mathbf{x}_i > 0\}$. Подстановка в (2.20) дает

$$\mu_f(f \mid D) \leq 2hM^2 \max_{1 \leq i \leq m} (\|\mathbf{x}_i\|_1^2 + \|\mathbf{x}_i\|_2^2) + 2\varepsilon_y M_{\nabla^2 f}.$$

В частности, если $\|\mathbf{x}_i\|_2^2 = \Theta(n)$ и $\|\mathbf{x}_i\|_1 = \Theta(n)$ равномерно по i , то $\mu_f(f \mid$

Таблица 2.1: Теоретические верхние порядки μ_f и эмпирической радемахеровской сложности для линейной модели и двухслойной FC ReLU-сети при квадратичной функции потерь. Для двухслойной μ_f спектральная оценка худшего случая сопоставляется с оценкой из теоремы 8, учитывающей малость остатков в окрестности θ^* .

	Линейная модель	Двухслойная FC ReLU
$\mu_f(f \mid D)$	$O(n)$	$O((hM)^4)$ в худшем случае и $O(hM^2n^2 + \varepsilon_y M_{\nabla^2 f})$ при учете остатков
$\hat{\mathfrak{R}}_m$	$O(W\sqrt{n/m})$	$O(\text{poly}(h)/\sqrt{m})$

$D) = O(hM^2n^2 + \varepsilon_y M_{\nabla^2 f})$; при малом ε_y и $n \asymp h$ ведущий член имеет порядок $O(M^2h^3)$.

При фиксированном M и ограниченных входах оценка худшего случая из следствия 7 и (2.24) имеет порядок $O(h^4)$, тогда как часть теоремы 8, учитывающая остатки, показывает, что в MSE-режиме малых остатков при покоординатных ограничениях масштабирование может улучшаться до $O(hM^2n^2 + \varepsilon_y M_{\nabla^2 f})$. Радемахеровский член в (2.29) остается порядка $O(\text{poly}(h)/\sqrt{m})$, поскольку это равномерная характеристика емкости класса, а не локальная характеристика кривизны в точке θ^* .

Таблица 2.1 собирает порядки роста худшего случая для μ_f и $\hat{\mathfrak{R}}_m$ в линейном и двухслойном режимах при предположениях данного раздела; теорема 8 фиксирует более точное уточнение для MSE, учитывающее малость остатков в той же локальной постановке.

2.4.6. Численное сопоставление ландшафтной меры и радемахеровской сложности

Таблица 2.1 фиксирует асимптотические порядки. Для двухслойной μ_f в ней приведены как оценка худшего случая, так и оценка с учетом малости остатков. Данный численный раздел сосредоточен на сравнительном поведении μ_f и $\hat{\mathfrak{R}}_m$. Прямая валидация вспомогательной оценки приращения выборки для $\mathcal{L}_{k+1} - \mathcal{L}_k$ здесь не ставится. Вычисляются $\mu_f(f \mid D)$ и эмпирическая радемахеровская сложность (2.25) в трех контролируемых постановках: линейные предикторы при изменении размерности пространства признаков n ; линейные предикторы при изменении объема выборки m ; двухслойная FC ReLU-сеть при изменении ширины скрытого слоя h с покоординатными ограничениями и специально сконструированными данными худшего случая.

В каждом эксперименте результаты повторных генераций данных усредняются по независимым случайным зернам. Там, где это уместно, среднее значение и одно стандартное отклонение показаны затененной областью. Для $\mathcal{F}_{\text{lin}}(W)$ супремум в радемахеровской сложности (2.25) сводится к явной форме, лежащей в основе (2.26)–(2.27). Математическое ожидание по σ аппроксимируется методом Монте-Карло с 4096 реализациями. Для двухслойного класса супремум по θ приближается проекционным градиентным подъемом на покоординатном шаре с тем же значением M , что и в конструкции данных. Каждая оценка использует n_σ радемахеровских реализаций; оптимизатор и бюджет итераций заданы в вычислительном ноутбуке.

Первый эксперимент проверяет линейную модель при изменении n и фиксированном m . Объем выборки фиксируется как $m = 256$, а n изменяется по равномерной сетке из 12 значений от 8 до 128. Для каждой пары (n, m) величина μ_f вычисляется по ранговым матрицам Гессе $\mathbf{H}_i = \mathbf{x}_i \mathbf{x}_i^\top$, а $\hat{\mathfrak{R}}_m(\mathcal{F}_{\text{lin}}(W))$ вычисляется при $W = 2$. Для каждого значения n используется 16 случайных повторов. На рис. 2.2 применяются две вертикальные оси в логарифмическом





Рис. 2.2: Линейный класс: μ_f (левая ось) и эмпирическая $\hat{\mathfrak{R}}_m$ (правая ось) в зависимости от размерности n при фиксированном объеме выборки $m = 256$ и $W = 2$.


масштабе, что позволяет одновременно показать μ_f и $\hat{\mathfrak{R}}_m$. График показывает, что μ_f растет примерно линейно по n , тогда как $\hat{\mathfrak{R}}_m$ при фиксированном m растет как $\sqrt{n}$. Это соответствует сопоставлению в табл. 2.1.

Второй эксперимент относится к линейной модели при изменении m и фиксированном n . Размерность фиксируется как $n = 64$, а m изменяется по геометрической сетке из 14 значений от 16 до 1024; целевые значения используют тот же уровень шума, что и в эксперименте по n . Здесь также используется $W = 2$ и 16 повторов для каждого m . Рисунок 2.3 показывает результаты в двух панелях. На панели (а) изображена зависимость μ_f от m . Если нормы строк $\mathbf{x}_i$ остаются устойчивыми при изменении m , то μ_f также меняется слабо. Это согласуется с оценкой $\mu_f \leq 2 \max_i \|\mathbf{x}_i\|_2^2$ в (2.28). На панели (b) показана $\hat{\mathfrak{R}}_m$ в логарифмических осях. Дополнительно приведен опорный спад $\propto m^{-1/2}$, иллюстрирующий множитель $m^{-1/2}$ в (2.27).

Третий эксперимент рассматривает двухслойную FC ReLU-сеть при изменении h . Используется согласованная учительская модель с покоординатно ограниченными весами и кластеризованными входами из вычислительного кода. Размерность входа связана с шириной, поэтому $n = h$. В постановке используются покоординатное ограничение весов $M = 1$, объем выборки $m = 512$



(a) μ_f в зависимости от m .



(b) $\hat{\mathfrak{R}}_m$ в зависимости от m (логарифмические оси).

Рис. 2.3: Линейный класс: изменение объема выборки m при фиксированных $n = 64$ и $W = 2$.

и ширины скрытого слоя $h \in \{4, 8, 12, 16, 24, 32\}$. Оценивание выполняется в заранее заданной точке θ^* , поэтому шум меток отсутствует. Следовательно, применим анализ с учетом малости остатков из раздела 2.4.3.. Величина μ_f оценивается по батчам пообъектных матриц Гессе с размером блока 64 в реализации. Величина $\hat{\mathfrak{R}}_m$ оценивается покоординатным PGD, как в ноутбуке, с $n_\sigma = 64$ шагами PGD. На рис. 2.4 эмпирическая μ_f сопоставляется с двумя опорными кривыми, нормированными по наименьшему h . Первая отражает спектральное масштабирование худшего случая $\propto (Mh)^4$. Вторая соответствует гаусс-ньютоновскому масштабированию $\propto h^3$ при $n = h$ с учетом малости остатков из подраздела 2.4.5.. На рисунке также показана $\hat{\mathfrak{R}}_m$ на второй логарифмической оси, чтобы ее масштаб не сжимался большими значениями μ_f .

Обсуждение.

Таблицу 2.1 следует читать как сопоставление двух разных понятий сложности, а не как две верхние оценки одной и той же величины. При предположениях о масштабировании входов из подраздела 2.4.4. и нормовых предположениях леммы 7 ландшафтная мера сложности отражает, насколько сильно пообъектные матрицы Гессе отклоняются от своего эмпирического среднего при фиксированном опорном значении параметров. В линейной модели это дает верхнюю




Рис. 2.4: Двухслойная FC ReLU-сеть: эмпирическая μ_f (левая логарифмическая ось) с опорными кривыми худшего случая $\propto (Mh)^4$ и GN-масштабирования с учетом остатков $\propto h^3$; эмпирическая $\hat{\mathfrak{R}}_m$ (правая логарифмическая ось).

оценку, *линейную* по размерности пространства признаков n . В двухслойном ReLU-режиме худшего случая тот же механизм дает *четвертую степень* по ширине скрытого слоя h . Часть теоремы 8, учитывающая малость остатков, показывает, что при квадратичной функции потерь картина худшего случая не является единственно возможной. Когда остатки малы, остаточно-взвешенный член в пообъектной матрице Гессе подавляется, и ландшафтная мера сложности может расти медленнее. Это уточнение имеет локальный характер, и сравнение следует интерпретировать именно в этом смысле.

Эмпирическая радемахеровская сложность играет другую роль. Оценки (2.27) и (2.29) сохраняют общий спад $m^{-1/2}$ по объему выборки, поскольку измеряют глобальную емкость класса предикторов, а не локальную кривизну в одной точке параметрического пространства. Вместо этого меняется архитектурный множитель: в линейном случае он имеет порядок $\sqrt{n}$, а в двухслойном случае при стандартных нормовых ограничениях равен $O(\text{poly}(h))$. В этом состоит основное качественное различие двух величин. Ландшафтная мера сложности чувствительна к локальной вариабельности матриц Гессе и потому зависит от функции потерь, опорной точки и режима остатков. Напротив, $\hat{\mathfrak{R}}_m$ связана с размером класса вещественнозначных функций. Специфическое для

функции потерь упрощение $\|\mathbf{A}_{\text{sq}}\|_2 = 1$ по сравнению с $\|\mathbf{A}_{\text{CE}}\|_2 \leq \sqrt{2}$ делает это различие особенно явным: изменение функции потерь напрямую меняет гессиановую ландшафтную величину через $\|\mathbf{H}_i\|_2$ и внешний множитель $\|\mathbf{A}\|_2$.

Выводы.

В данном подразделе ландшафтная мера сложности развивается для скалярной регрессии с полносвязными ReLU-сетями при квадратичной функции потерь. Рассмотрены линейная и двухслойная постановки. Для сетей без смещений с нормовыми ограничениями предыдущие гессиановые оценки для полносвязных архитектур адаптированы к MSE-режиму, что дает законы масштабирования предложенной меры по глубине, ширине и нормовым ограничениям.

Сопоставление с эмпирической радемахеровской сложностью показывает, что эти две величины являются взаимодополняющими, а не взаимозаменяемыми. Численные эксперименты качественно согласуются с этим различием и с теоретически полученными тенденциями масштабирования.

Естественным развитием представленного анализа являются более глубокие архитектуры, более общие модели входных данных и режимы с ненулевыми остатками, где вклад остаточно-взвешенных гессиановых слагаемых становится существенным. Основной вывод раздела состоит в том, что ландшафтная мера сложности выступает самостоятельной характеристикой сложности для регрессии с квадратичной функцией потерь.

2.5. Динамика ландшафтной меры при обучении языковых моделей

Обучение современных больших параметрических моделей глубокого обучения связано с высокими вычислительными затратами. Качество моделей зависит от архитектуры, данных и метода обучения [30, 29]. Перебор архитектур и режимов данных для выбора модели требует значительных вычислительных ресурсов, что ограничивает чисто эмпирический анализ.

Современные исследования выбора архитектур и режимов обучения опира-

ются, в частности, на эмпирические законы масштабирования, связывающие качество, размер модели и объем данных при ограниченном вычислительном бюджете [30, 29]. Анализ опирается на срезы фиксированного бюджета и сопоставление режимов с разным соотношением числа параметров и числа токенов. Другим направлением анализа моделей глубокого обучения является качественный анализ ландшафта функции потерь и его связи с качеством модели [117, 62, 106, 105]. Они опираются на анализ спектра матриц Гессе и его связи с качеством модели. На основе работ [70, 121], где ландшафтная мера сложности вводится в фиксированной точке, в настоящей главе изучается ее динамика вдоль траектории обучения.

Эмпирически фиксируются смены геометрического режима, в том числе резкие изменения ландшафтной меры μ при переходах между фазами оптимизации. Для анализа проводится вычислительный эксперимент на модели GPT-2 [122] с различным числом параметров и объемом обучающих данных на корпусе WikiText-103 [123].

Обзор предшествующих результатов.

Большое число современных исследований посвящено спектральным свойствам матрицы Гессе эмпирического риска и их связи с динамикой оптимизации и организацией ландшафта [108, 107, 110, 112, 111]. В эмпирическом анализе переобученных сетей [108] изучаются распределения собственных значений матрицы Гессе, где выделяются основная часть спектра и выбросные собственные значения, обсуждается связь этой структуры с ходом градиентного обучения. Работа [107] направлена на анализ плотности распределения собственных значений матрицы Гессе. Данная плотность используется как инструмент анализа оптимизации нейронных сетей, в рамках которого получают количественные характеристики этой плотности в типичных режимах обучения. В [110] анализируется структура спектра матрицы Гессе для крупных моделей глубокого обучения. В частности, показано, как структура спектра соотносится с числом классов и объемом данных. В работе [112] используется аппарат теории случай-

ных матриц для описания геометрии поверхностей потерь нейросетей. В [111] выделяются общие закономерности структуры Гессеана по слоям и типам параметров, то есть анализируется не только спектр одной агрегированной матрицы, но и устойчивые шаблоны внутри архитектуры.

Отдельно исследуется связь обобщения и устойчивости с геометрией минимума около найденного решения [65, 119, 120]. В классической постановке [65] плоские области функции потерь интерпретируются как предпочтительные с точки зрения описательной сложности решения и обобщающей способности. В [119] систематизируются эмпирические закономерности обобщения в глубоких сетях и анализируется связь качества с режимом оптимизации [65] и геометрией ландшафта без сведения к одному скалярному показателю неоднородности разброса матриц Гессе между объектами обучения. В [120] показывается, что формулировки про острые минимумы как худшие для обобщения не универсальны. В частности, приводятся примеры и теоретические конструкции, которые демонстрируют случаи приемлемого обобщения при остром минимуме, то есть постановка опирается на чувствительность решения к возмущениям в окрестности минимума, а не на разброс Гессе по обучающим точкам.

Работы [117, 62, 106, 105] дополняют спектральный анализ качественной картиной организации поверхности потерь. В [117] анализируется структура поверхностей потерь многослойных сетей и связь качественных свойств ландшафта с упрощенными статистическими моделями. В [62] предложены методы снижения размерности и нормировки фильтров для сравнения формы ландшафта между архитектурами и режимами обучения. В работах [106, 105] описывается локальная геометрия, связность областей низкой ошибки, пути между решениями и организация бассейнов при разном распределении данных.

Ближайшим к тематике настоящего раздела направлением исследований является ландшафтная мера на основе матриц Гессе по объектам обучения. В работах [70, 121] развивается конструкция ландшафтной меры на основе матриц Гессе, сопоставляемых каждому объекту обучения. Для полносвязных архи-

текстур в задаче классификации в [70] построены спектральные мажоранты и верхние оценки на ландшафтную меру сложности в оптимуме. В работе [121] проводится обобщение данного подхода для матричных моделей глубокого обучения. Работа [98] посвящена закономерностям кривизны при масштабировании трансформерных моделей. Работы [124, 125] анализируют явление двойного спуска и связанные с ним изменения режимов обучения при обучении моделей глубокого обучения. В режиме предельно широких сетей динамика обучения описывается через нейронное касательное ядро в постановке [114] и последующих работах [115]. В пределе динамика становится линейной в функциональном пространстве относительно фиксированного ядра, что по смыслу отличается от режима сетей конечной ширины и от неоднородности разброса матриц Гессе по объектам, которую отражает ландшафтная мера.

Параллельно изучаются скалярные характеристики кривизны в точке θ . Рассматривается след матрицы Гессе, максимальное собственное значение, плотность спектра и производные от них [107, 110, 111, 98]. Такие величины описывают агрегированную кривизну функции ошибки в окрестности θ и дополняют, но не заменяют, показатели межобъектного рассогласования гессианов, вводимых в работе [70].

2.5.1. Постановка задачи анализа динамики

Пусть Θ — пространство допустимых значений вектора параметров модели глубокого обучения. Эмпирические функции потерь на валидационной и обучающей выборках задаются $\mathcal{L}_{\text{val}}(\theta)$ и $\mathcal{L}_{\text{train}}(\theta)$ соответственно.

Точку минимума эмпирического риска на обучении обозначим через

$$\theta^* \in \arg \min_{\theta \in \Theta} \mathcal{L}_{\text{train}}(\theta).$$

Для анализа локальной геометрии эмпирического риска в точке $\theta \in \Theta$ фикс-

сируется конечное множество

$$D_{\text{probe}} = \{x_1, \dots, x_m\}.$$

Пусть для каждого объекта $x_i \in D_{\text{probe}}$ задана $\mathbf{H}_i(\theta)$ — матрица Гессе функции $\ell(\theta; x_i)$ в точке θ . Здесь x_i — это некоторый токенизированный контекст фиксированной длины L_{ctx} , тогда функция ошибки для языкового моделирования имеет вид

$$\ell(\theta; x_i) = -\frac{1}{L_{\text{ctx}} - 1} \sum_{k=1}^{L_{\text{ctx}}-1} \log p_{\theta}(x_{i,k+1} \mid x_{i,1:k}).$$

Усреднение по объектам из выборки D_{probe} вводится следующим образом:

$$\mathbf{H}_i(\theta) = \nabla_{\theta}^2 \ell(\theta; x_i), \quad \bar{\mathbf{H}}(\theta) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\theta),$$

Рассмотрим ландшафтную меру, задаваемую выражением:

$$\mu(\theta) = \frac{1}{m} \sum_{i=1}^m \|\mathbf{H}_i(\theta) - \bar{\mathbf{H}}(\theta)\|_2, \quad (2.30)$$

где $\|\cdot\|_2$ — спектральная норма матрицы. Заметим, что при $\theta = \theta^*$ величина $\mu(\theta)$ совпадает с ландшафтной мерой сложности в постановке [70].

Величина μ по смыслу отличается от традиционных скалярных показателей “остроты” по спектру агрегированного Гессиана [107, 110, 111]: последние характеризуют одну матрицу в точке θ , тогда как (2.30) измеряет разброс семейства $\{\mathbf{H}_i\}$ между обучающими контекстами.

Рассматривается траектория обучения $\{\theta_t\}_{t=1}^T$, параметризованная неотрицательным накопленным числом токенов t . Вдоль нее рассматривается пара отображений $\mathcal{L}_{\text{val}}(\theta_t)$ и $\mu(\theta_t)$.

Пусть $\mathcal{T} = \{t_j\}_{j=1}^J$ — множество контрольных значений накопленного числа токенов для соответствующих состояний — θ_{t_j} , $j = 1, \dots, J$. На этой дискретизации сопоставляются значения $\mathcal{L}_{\text{val}}(\theta_{t_j})$ и $\mu(\theta_{t_j})$, анализируется совместная динамика при возрастании t_j .

2.5.2. Эксперимент по динамике меры для моделей GPT-2

Таблица 2.2: Множество архитектур модели GPT-2 для экспериментального сравнения динамики ландшафтной меры

L	H	E	L	H	E	L	H	E
2	2	48	2	2	64	2	2	80
2	2	96	2	4	112	2	4	128
3	2	48	3	2	64	3	2	80
3	2	96	3	4	112	3	4	128
4	2	48	4	2	64	4	2	80
4	2	96	4	4	112	4	4	128
5	2	48	5	2	64	5	2	80
5	2	96	5	4	112	5	4	128
6	2	48	6	2	64	6	2	80
6	2	96	6	4	112	6	4	128
7	2	48	7	2	64	7	2	80
7	2	96	7	4	112	7	4	128

Для эмпирического анализа ландшафтной меры используется выборка WikiText-103 [123]. Токенизация текста согласована с языковой моделью GPT-2 [122]. Гиперпараметры архитектур для сравнения приведены в табл. 2.2.

В рамках вычислительного эксперимента спектральная норма разности $\mathbf{H}_i - \bar{\mathbf{H}}$ не считается явно. Для каждого i задается семейство из r независимых случайных направлений $v_j \in \mathbb{R}^d$, $\|v_j\|_2 = 1$, $j = 1, \dots, r$. Далее по полному вектору обучаемых параметров производится вычисление гессиан-векторных произведений и величин $\|(\mathbf{H}_i - \bar{\mathbf{H}})v_j\|_2$ без диагональной аппроксимации и без ограничения подмножества параметров. Оценкой нормы разности служит максимум нормы по j -му направлению. При фиксированном наборе $\{v_j\}$ это дает нижнюю оценку спектральной нормы, причем при каждом вычислении μ выполняется пересэмплирование направлений. Численные значения m и r указаны в табл. 2.3.

Эксперимент состоит из двух частей. В обеих частях используется одина-

Таблица 2.3: Численные параметры эксперимента

Параметр	Значение
Данные	WikiText-103 [123]; токенизатор GPT-2 [122]; длина контекста $L_{\text{ctx}} = 128$ токенов; сетка (L, H, E) числа слоев, голов и размерности эмбединга — табл. 2.2
Первая часть	36 конфигураций; бюджет обучения $\approx 1,2 \cdot 10^7$ токенов; 20 контрольных точек по накопленным обучающим токенам; мини-пакет 128 контекстов; 8 независимых запусков обучения на архитектуру; AdamW: $\text{lr} = 3 \cdot 10^{-4}$, weight decay 0,01
Вторая часть	архитектуры $(2, 2, 48)$, $(5, 2, 96)$, $(7, 4, 128)$; бюджет до $1,5 \cdot 10^8$ токенов; 36 контрольных точек; мини-пакет 128; 8 независимых запусков обучения; AdamW: разогрев 3% итераций, косинусное снижение lr до $3 \cdot 10^{-5}$
Оценка μ	на каждой контрольной точке: новая мини-выборка D_{probe} из $m = 8$ контекстов из текущего обучающего потока; $r = 4$ независимых случайных направления для нижней оценки спектральной нормы через гессиан-векторные произведения

ковый корпус текстов, токенизатор, согласование H с шириной скрытого слоя, оптимизатор AdamW и правила вычисления $\mathcal{L}_{\text{val}}$ и μ . Меняется состав архитектур, горизонт обучения по числу токенов и расписание скорости обучения (англ. learning rate). В первой части проводится обучение всех конфигураций из табл. 2.2. Во второй части — три выбранные конфигурации с увеличенным горизонтом обучения по числу токенов. Для каждой архитектуры выполняется 8 независимых запусков обучения с различными инициализациями и порядком стохастических операций. Во всех экспериментах для динамики по токенам показаны траектории выборочных средних и 95% доверительные интервалы для матожидания по запускам.

Устойчивость оценки μ относительно шума приведена в табл. 2.4. Расширенный регрессионный разбор линейных аппроксимаций для второй части эксперимента приведен в табл. 2.5–2.6. Базовую линейную регрессию $\mu \approx a + b \mathcal{L}_{\text{val}} + c \ln t$ по агрегированным точкам второй части эксперимента обозначим $M0$, в свою очередь различные модификации $M1$ – $M4$ отличаются набором дополнительных признаков, что указано в табл. 2.5.

На рис. 2.5, 2.6 и 2.7 траектории $\mathcal{L}_{\text{val}}(\theta_t)$ и $\mu(\theta_t)$ сопоставлены по оси накоп-




Рис. 2.5: Валидационная ошибка в зависимости от числа обработанных обучающих токенов

ленных токенов. Также на графиках показаны 95% доверительные интервалы матожидания по распределению 8 независимых запусков на каждой контрольной точке. В первой части эксперимента для всех конфигураций табл. 2.2 при росте числа токенов $\mathcal{L}_{\text{val}}$ улучшается на фиксированной сетке контрольных значений t . Кривые $\mu(\theta_t)$ при этом не повторяют форму кривых потерь, так как у части архитектур после начального участка μ возрастает на поздних отрезках горизонта. Во второй части эксперимента для трех выбранных архитектур $\mu(\theta_t)$ не является монотонной функцией t там, где $\mathcal{L}_{\text{val}}$ по контрольным точкам убывает. По рис. 2.11 и табл. 2.4 видно, что амплитуда этих изменений существенно превышает типичный межзапусковый разброс реализаций μ на одной контрольной точке относительно их выборочного среднего.

На рис. 2.8 показана зависимость в координатах $(\mathcal{L}_{\text{val}}, \mu)$. Из диаграммы следует, что одному и тому же интервалу значений $\mathcal{L}_{\text{val}}$ могут соответствовать разные μ , причем разброс зависит от числа обработанных токенов и от номера независимого запуска. Отсюда следует постановка дополнительного экспери-




Рис. 2.6: Ландшафтная мера в процессе обучения

мента, в рамках которого проверяется, можно ли описать основную закономерность простой совместной зависимостью μ от ошибки на валидации и времени обучения.

На каждой контрольной точке второй части эксперимента берется пара $(\mathcal{L}_{\text{val}}, \mu)$ после усреднения по восьми запускам как выборочное приближение совместного матожидания. По совокупности таких точек оценивается базовая регрессия $M0$, то есть $\mu \approx a + b \mathcal{L}_{\text{val}} + c \ln t$, а предсказание модели обозначается $\hat{\mu}$. На трех архитектурах согласование умеренное $R^2 \approx 0,35$. Отдельная подгонка по каждой архитектуре дает заметно более высокие R^2 : порядка 0,50, 0,43 и 0,24. Значит, простая общая линейная форма не улавливает различия между архитектурами и смешивает разные режимы траекторий.

Остатки $\mu - \hat{\mu}$ у $M0$ систематически отличны от нуля, а следовательно одних координат $\mathcal{L}_{\text{val}}$ и $\ln t$ недостаточно, чтобы описать наблюдаемую связь. На рис. 2.9 показано, как меняется средний остаток по квантильным ячейкам по $\ln t$ и по $\mathcal{L}_{\text{val}}$ вместе с доверительными интервалами.

С помощью частных коэффициентов корреляции Пирсона изолируется




Рис. 2.7: Для трех архитектур на одном графике показаны валидационная ошибка сплошной линией и ландшафтная мера пунктиром по числу обработанных токенов

вклад времени при фиксированной ошибке и вклад ошибки при фиксированном времени. Точечные оценки составляют $\rho(\mu, \ln t \mid \mathcal{L}_{\text{val}}) \approx 0,179$ при интервале $[-0,020, 0,351]$ и $\rho(\mu, \mathcal{L}_{\text{val}} \mid \ln t) \approx -0,058$ при интервале $[-0,252, 0,135]$. Доверительный интервал для $\rho(\mu, \ln t \mid \mathcal{L}_{\text{val}})$ почти не пересекает ноль, тогда как интервал для $\rho(\mu, \mathcal{L}_{\text{val}} \mid \ln t)$ содержит ноль, что согласуется с тем, что модель M0 объясняет лишь часть разброса.

Далее сравниваются расширения M1–M4 из табл. 2.5–2.6. Через d обозначено число обучаемых параметров конфигурации, через n — объем обучающей части корпуса в токенах на соответствующем этапе. Добавление слагаемых $\ln N_{\text{params}}$ и $\ln(d/n)$ почти не повышает R^2 относительно M0. Существенный выигрыш дает слагаемое $\mathcal{L}_{\text{val}} \cdot \ln t$, то есть требуется совместный учет ошибки и горизонта, а не только их аддитивное включение вместе с логарифмом времени.

Та же линейная зависимость проверяется на данных первой части эксперимента, чтобы сопоставить две части эксперимента между собой. На рис. 2.10




Рис. 2.8: Зависимость между валидационной ошибкой и ландшафтной мерой для выборочных архитектур

показана тепловая карта остатков по ячейкам (L, E) при $R^2 \approx 0,267$. Качество описания ниже, чем во второй части эксперимента, а профиль остатков по ячейкам неоднороден, то есть отклонения от линейной формы зависят от конфигурации.

Отдельный разрез — согласованность локальных изменений ошибки и меры вдоль одной траектории. На рис. 2.12 по ячейкам (L, E) показана доля последовательных пар контрольных точек, где одновременно $\Delta \mathcal{L}_{\text{val}} < 0$ и $\Delta \mu > 0$. В первой части эксперимента средняя доля таких пар по траекториям составляет около 41,5%, а доверительный интервал для среднего по траекториям равен $[40,7, 42,3]\%$.

На рисунках 2.13 и 2.14 представлена связь финальных значений ошибки и μ с масштабом модели и соотношение значения μ на контрольной точке с почти медианным индексом по горизонту сетки с финальной ошибкой на том же этапе.

Обсуждение.

Валидационная ошибка отражает качество предсказания на отложенной выборке. Ландшафтная мера μ отражает иное свойство геометрии риска: она агрегирует рассогласование пообъектных матриц Гессе по контекстам из D_{probe} в

Таблица 2.4: Устойчивость оценки μ

Конфигурация	med. std	размах	SNR	доля
L2_H2_E48	0.00406	1.25169	308.27	66.7%
L5_H2_E96	0.00949	0.90973	95.87	72.2%
L7_H4_E128	0.01058	0.51444	48.63	75.0%
Первая часть, медиана по 36 архитектурам	0.00462	0.19821	43.17	90.0%

Таблица 2.5: Линейные спецификации для μ

Модель	R^2	$\bar{R}^2$	F vs M0	p	
M0	0.350	0.330	—	—	
M1	0.362	0.335	1.83	$1.79 \cdot 10^{-1}$	
M2	0.777	0.768	188.38	$1.49 \cdot 10^{-24}$	
M3	0.602	0.585	61.99	$4.71 \cdot 10^{-12}$	
M4	0.362	0.335	1.83	$1.79 \cdot 10^{-1}$	

Таблица 2.6: Доверительные интервалы коэффициентов

M0 a	−0.2991 [−1.6756, 0.8722]
M0 $b(\mathcal{L}_{\text{val}})$	−0.0186 [−0.0698, 0.0451]
M0 $c(\ln t)$	0.0463 [−0.0037, 0.1083]
M1 a	0.8541 [−0.7184, 2.3416]
M1 $b(\mathcal{L}_{\text{val}})$	−0.0305 [−0.0774, 0.0294]
M1 $c(\ln t)$	0.0373 [−0.0071, 0.0895]
M1 доп.	−0.0596 [−0.1500, 0.0242]
M2 a	−9.4180 [−12.1149, −6.9555]
M2 $b(\mathcal{L}_{\text{val}})$	0.8868 [0.6819, 1.1191]
M2 $c(\ln t)$	0.5916 [0.4503, 0.7454]
M2 доп.	−0.0550 [−0.0684, −0.0438]




Рис. 2.9: Отклонение наблюдаемой ландшафтной меры от значения, предсказанного линейной моделью по валидационной ошибке и логарифму числа обучающих токенов

текущей точке θ_t . Отсюда следует, что совпадение или расхождение траекторий $\mathcal{L}_{\text{val}}$ и μ не сводится к бинарной классификации режимов обобщения.

Выбор спектральной нормы в (2.30) согласован с этой ролью. Она измеряет максимальное усиление по направлению и тем самым ориентируется на доминирующие “острые” сингулярные режимы локальной кривизны. Норма Фробениуса усредняла бы вклад всех координат матрицы и менее прицельно отражала бы такие доминирующие направления. Отдельная проверка чувствительности выводов к замене нормы в данном эксперименте не проводилась.

Наблюдаемый рост μ при продолжающемся улучшении $\mathcal{L}_{\text{val}}$ интерпретируется как сигнал о смене локального режима геометрии риска. Такой рост мог бы соответствовать усилению кривизны по отдельным контекстам. Он же может частично отражать рост разброса матриц $\mathbf{H}_i$ при более стабильном среднем $\bar{\mathbf{H}}$. Оба механизма совместимы с представленными траекториями, но их разделение требует дополнительных диагностик, например сопоставления норм $\mathbf{H}_i$ и норм отклонений $\mathbf{H}_i - \bar{\mathbf{H}}$.

При оценке μ стохастический вклад неизбежен, так как на каждой кон-




Рис. 2.10: Отклонения меры от линейной модели, после усреднения по восьми независимым запускам в каждой ячейке

трольной точке пересэмплируются и D_{probe} , и пробные направления. Поэтому межзапусковый разброс реализаций μ смешивает различие инициализаций с этой стохастикой оценивания. Тем не менее по табл. 2.4 видно, что размах траектории выборочного среднего μ по токенам на порядки превышает медианное по контрольным точкам выборочное стандартное отклонение μ между восьмью запусками. Это наблюдается и во второй, и в типичной конфигурации первой части эксперимента.

С практической стороны μ логично использовать как дополнительную координату мониторинга рядом с $\mathcal{L}_{\text{val}}$ и временем обучения. Она стыкуется с фазовым представлением на рис. 2.8 и с кросс-архитектурными диаграммами рассеяния рис. 2.13–2.14. При этом не формулируются прямые утверждения о раннем предсказании переобучения или о выборе архитектуры по одной лишь μ . Фиксируется более узкий вывод: величина μ содержит вариацию, которую не




Рис. 2.11: Выборочное среднее μ по восьми независимым запускам

объясняют простые линейные формы, построенные только по паре $(\mathcal{L}_{\text{val}}, \ln t)$; это следует из регрессионного сравнения в табл. 2.5.

Отметим ограничения проведенного эксперимента. Они связаны с узким семейством GPT-2 на WikiText-103 при фиксированном оптимизаторе AdamW; следовательно, перенос выводов на другие архитектуры, корпуса и масштабы остается открытым вопросом. Сопоставление μ со следом или спектральным радиусом агрегированного Гессiana, равно как и более богатые регрессионные модели, отнесены к дальнейшей работе.

Выводы.

В настоящем разделе показано, что динамика μ в процессе обучения содержит дополнительную информацию о геометрическом режиме и не сводится к динамике валидационной функции потерь. Этот вывод поддерживается согласованным анализом иллюстраций рис. 2.5–2.9, тепловых карт рис. 2.10–2.12, количественными данными табл. 2.4 и расширенным регрессионным сравнением в табл. 2.5. Результат согласуется с разделением ролей, где для опорной точки построены теоретические верхние оценки на μ , а здесь тот же показатель оценивается выборочно на пробной мини-выборке вдоль траектории обучения языковых моделей и используется для эмпирического сравнения архитектур.

Дальнейшая работа связана с расширением сетки архитектур и корпусов, увеличением числа независимых запусков обучения, прямым сопоставлением




Рис. 2.12: Доля последовательных пар контрольных точек с $\Delta\mathcal{L}_{\text{val}} < 0$ и $\Delta\mu > 0$ по ячейкам (L, E) первой части эксперимента

μ со следами и спектральными характеристиками агрегированного Гессiana, а также разработкой ускоренных спектральных приближений для оценки μ на больших моделях.

2.6. Вычислительные эксперименты

В настоящем разделе представлены результаты вычислительных экспериментов, направленных на эмпирическую валидацию теоретических результатов, полученных в предыдущих разделах главы.

На рис. 2.15 представлены соответствующие результаты, показывающие, что хотя предположение 1 может быть ослаблено, его выполнимость улучшается с увеличением длины последовательностей.




Рис. 2.13: Финальная контрольная точка первой части эксперимента: μ и $\mathcal{L}_{val}$ против десятичного логарифма числа обучаемых параметров N_{params} для 36 архитектур

2.6.1. Эксперименты для полносвязных сетей

Таблица 2.7: Описание наборов данных для классификации изображений, использованных в экспериментах по валидации теоретических оценок сходимости ландшафта функции потерь. Все наборы данных из библиотеки `torchvision` с нормализацией значений пикселей к диапазону $[-1, 1]$.

Название	Описание	Формат	Разрешение
MNIST [126]	Рукописные цифры	Оттенки серого	28×28
FashionMNIST [127]	Элементы одежды	Оттенки серого	28×28
CIFAR10 [128]	Различные объекты	RGB	32×32
CIFAR100 [128]	Различные объекты	RGB	32×32

Для проверки полученных теоретических оценок проведен вычислительный эксперимент. В настоящем разделе представлены результаты обучения полносвязной нейронной сети для задачи классификации изображений. Основной це-




Рис. 2.14: Выборочное среднее μ по восьми запускам на контрольной точке с индексом, близким к медиане по сетке, и финальная валидационная ошибка по архитектурам первой части эксперимента

лью экспериментов является эмпирическое подтверждение сходимости ландшафта функции потерь с увеличением размера выборки. Для достижения этой цели обучена полносвязная нейронная сеть на полном наборе данных и получены соответствующие параметры $\hat{\theta}$ как точка вблизи минимума.

Для вычислительного эксперимента использовалась библиотека `pytorch` [129] в качестве Python-фреймворка для обучения нейронных сетей. Архитектура сети была единообразной и состояла из нескольких линейных слоев с функцией активации ReLU после каждого слоя, за исключением последнего. Размер h был зафиксирован для всех скрытых слоев L . Обучение сети проводилось в течение нескольких эпох с использованием оптимизатора Adam [130] с постоянной скоростью обучения 10^{-3} . Для обучения использовались различные наборы данных для классификации изображений, доступные в библиотеке `torchvision`. Для процесса обучения был выбран размер батча




Рис. 2.15: Проверка предположения 1 о сходимости локальных минимумов при увеличении объема выборки. График демонстрирует выполнимость предположения о том, что локальный минимум θ^* функции потерь $\mathcal{L}_k(\theta)$ остается локальным минимумом функции $\mathcal{L}_{k+1}(\theta)$ при добавлении нового объекта, причем выполнимость улучшается с увеличением длины последовательностей.




Рис. 2.16: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для полносвязной нейронной сети на наборе данных MNIST. Левый график: при $L = 5$ уменьшение разности с увеличением размера скрытого слоя h от 4 до 64; правый график: при $h = 16$ увеличение разности с увеличением количества слоев L от 1 до 10. Результаты подтверждают теорему 3.




Рис. 2.17: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для полносвязной нейронной сети с предобученным экстрактором признаков (Vision Transformer, ViT) на наборе данных MNIST. Левый график: при $L = 5$ уменьшение разности с увеличением h от 4 до 64; правый график: при $h = 16$ увеличение разности с увеличением L от 1 до 10. Результаты подтверждают независимость сходимости от природы пространства исходных объектов и согласуются с теоремой 3.

(англ. batch size) 64. Эксперименты проводились на GPU Tesla A100 80GB с 16 CPU ядрами и 243 GB оперативной памяти.

В первом эксперименте использовались значения пикселей изображений в качестве входных данных. На рис. 2.16 представлены результаты, полученные при анализе 10 000 объектов из набора данных MNIST [126], при этом сеть обучалась в течение 10 эпох. Соответствующий размер входа составляет 784, а размер выхода — 10. Графики слева были получены при фиксированном количестве слоев $L = 5$ в сети. Размер скрытого слоя во всех слоях варьировался от 4 до 64. График справа иллюстрирует поведение разности потерь при изменении количества скрытых слоев от 1 до 10, при фиксированном размере скрытого слоя $h = 16$. Последовательность была повторена 100 раз для усреднения. К полученным результатам было применено экспоненциальное скользящее среднее с коэффициентом сглаживания 0,99. Из наблюдаемых зависимостей сле-

дует, что, хотя изменение и не является значительным, добавление большего количества слоев приводит к большей разнице в функциях потерь. И наоборот, увеличение размера скрытого слоя приводит к меньшей разнице между функциями потерь. В рассмотренных экспериментах константа M , ограничивающая величину весов, оказывается сравнительно небольшой.

Для задачи классификации на MNIST неглубокая, но широкая нейронная сеть может достигать высокой точности. Наблюдалось, что значения функции потерь ниже для больших значений h , и поэтому их разница также меньше.

В отличие от предыдущего эксперимента, использовался предварительно обученный экстрактор признаков изображений. Полносвязная сеть использовалась в качестве многоклассового классификатора. В качестве модели была выбрана модель Vision Transformer (ViT) [131] от Google. Аналогичным образом были выбраны случайным образом 10 000 объектов из набора данных MNIST и варьировались размер скрытого слоя и количество слоев. Результаты согласуются с наблюдениями при прямой классификации изображений. Согласованность подтверждает, что представленная сходимости не зависит от природы пространства исходных объектов $\mathcal{X}$. Для наблюдения сходимости ландшафта функции потерь достаточно ограниченности этого пространства.

Эксперимент подтверждает сходимости, доказанную в теореме 3. Верхняя оценка скорости этой сходимости остается верной. Изменение параметров нейронной сети, таких как количество слоев и размер слоя, приводит к изменению разности функций потерь, что согласуется с теоретическими предсказаниями.

Приведем расширенную версию проведенных экспериментов. В таблице 2.7 представлено описание используемых наборов данных. Были использованы четыре набора данных из библиотеки `torchvision`: MNIST [126], FashionMNIST [127], CIFAR10 и CIFAR100 [128]. Единственной предобработкой данных являлась нормализация для приведения значений к диапазону $[-1; 1]$.

На рис. 2.18 графики слева получены при фиксированном количестве слоев $L = 5$ в сети, при этом размер скрытого слоя варьировался на всех уровнях

от 4 до 64. График справа демонстрирует поведение разности потерь при изменении количества скрытых слоев от 1 до 10, при сохранении размера $h = 16$ неизменным. Последовательность была повторена 100 раз для усреднения. Для полученных результатов применялось экспоненциальное скользящее среднее с коэффициентом сглаживания 0.99.

Аналогично рис. 2.17, на рис. 2.19 результаты подтверждают сходимость, доказанную в теореме 3. Верхняя оценка скорости этой сходимости также верна. Изменение параметров нейронной сети приводит к изменению разности функций потерь, что согласуется с теоретическими предсказаниями.

2.6.2. Эксперименты для сверточных сетей

В настоящем разделе представлены результаты обучения сверточных сетей с различными параметрами. Основной целью экспериментов является демонстрация зависимости ландшафта функции потерь от таких параметров, как количество слоев, размер ядра, количество каналов и позиции пулинга, а также наблюдение того, как скорость сходимости зависит от этих параметров.

Для достижения указанной цели обучались сверточные сети и получались параметры $\hat{\theta}$ вблизи оптимума. В качестве модели использовалась сверточная архитектура с функцией активации ReLU после каждого слоя. Для прослеживания влияния заданного параметра на сходимость фиксировались все другие параметры нейронной сети, а заданный параметр варьировался.

Исследовалась зависимость между средним абсолютным различием значений функции потерь и доступным размером выборки. Для каждой модели производилось усреднение разности потерь по перемешанным выборкам. Для улучшения визуализации использовалось экспоненциальное сглаживание с коэффициентом 0.995. Использовалось числовое представление пикселей изображений в качестве входных данных. Результаты получены на основе анализа выборок из баз данных MNIST [126], FashionMNIST [127] и CIFAR10 [128]. Во всех экс-

периментах использовались следующие гиперпараметры: постоянная скорость обучения 10^{-3} , оптимизатор Adam, мини-пакеты размером 64, обучение проводилось в течение 10 эпох на наборах данных MNIST и Fashion-MNIST и 15 эпох на наборе данных CIFAR-10. Если параметр не варьировался, он сохранялся одинаковым во всех слоях.

2.6.3. Эксперименты для трансформеров

Для более глубокого изучения зависимости между функцией потерь и ее гессианом проведен эксперимент, соответствующий теореме 6. Использовалась конфигурация модели на наборе данных CIFAR-100 [128]. По сравнению с моделью для набора данных MNIST, указанная модель имеет в 8 раз больше блоков трансформера, а также скрытые слои в 8 раз шире. Во время обучения модель обучалась в течение ряда эпох для достижения точности более 50% на валидационном наборе данных. Результаты представлены на рис. 2.24.

Настройка эксперимента организована следующим образом:

1. Модель обучается до сходимости и сохраняется вектор параметров $\mathbf{w}^*$.
2. Начиная с пустого набора данных, добавляются данные батч за батчем (англ. batch), и вычисляется среднее значение потерь по просмотренным батчам.
3. Вычисляется абсолютная разность в соответствии с выражением:

$$|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|.$$

2.7. Заключение

В настоящей главе разработан теоретический аппарат для анализа сложности параметрических моделей глубокого обучения на основе локальной геометрии ландшафта функции потерь. Общие определения сложности модели и сложности выборки используются как постановочная основа для согласования

модели и данных, тогда как основной вычислимый объект главы задается через разброс пообъектных матриц Гессе.

В главе введены формальные определения меры сложности выборки $\mu_D(D)$ и меры сложности модели $\mu_f(f)$, а также абстрактный критерий согласованности модели и выборки $\mu_f(f) \leq \mu_D(D)$. Этот критерий не является самостоятельной гарантией качества аппроксимации или отсутствия переобучения; он фиксирует общую постановку, в которой далее вводятся вычислимые частные меры, зависящие от параметрической модели, функции потерь и обучающей выборки.

В рамках предложенной постановки введены понятия условной сложности выборки $\mu_D(D|f)$ и условной сложности модели $\mu_f(f|D)$, которые позволяют учитывать зависимость сложности от выбранной модели и данных. Предложение 2 показывает, что при монотонности меры сложности данных критерий согласованности сохраняется при расширении обучающей выборки.

Ключевым частным случаем условной сложности модели является ландшафтная мера сложности, определяемая через спектральные свойства матриц Гессе функции потерь. Установлено, что анализ сходимости ландшафта оптимизационной задачи при увеличении объема выборки сводится к анализу спектральной нормы матрицы Гессе, что позволяет количественно оценить влияние добавления новых объектов данных на локальную геометрию функции потерь в окрестности оптимума.

Для полносвязных нейронных сетей получены строгие теоретические оценки сходимости функции потерь при увеличении размера выборки. Теорема 3 устанавливает, что абсолютная разность между значениями функции потерь при добавлении нового объекта стремится к нулю со скоростью $O(L(hM)^{2L}/k)$ при $k \rightarrow \infty$, где L — число слоев, h — размер скрытого слоя, M — константа, ограничивающая параметры и данные. Следствие 2 определяет асимптотику ландшафтной меры сложности: $\mu_f(f|D) \propto L(hM)^{2L}$, что демонстрирует экспоненциальную зависимость сложности от глубины сети.

Для сверточных нейронных сетей установлены теоретические оценки ландшафтной меры сложности, демонстрирующие экспоненциальную зависимость от глубины и полиномиальную — от остальных гиперпараметров архитектуры. Теоремы 4 и 5 определяют асимптотики для 1D- и 2D-сверточных сетей соответственно: $\mu_f(f|D) \propto L(C^2 M^2 k d)^L$ и $\mu_f(f|D) \propto C^2 k^2 L(C^2 k^2 M^2 m n)^L$.

Для трансформерных моделей получены теоретические оценки сходимости ландшафта функции потерь, восполняющие пробел в анализе путем явного вывода якобианов и гессианов для компонентов LayerNorm и FFN. Теорема 6 устанавливает неравенство сходимости $|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \leq 2L/(k+1) + M\|\mathbf{w} - \mathbf{w}^*\|_2^2/(k+1)$ и демонстрирует гетерогенность гессиана по блокам трансформера.

Отдельно рассмотрена регрессионная постановка для полносвязных ReLU-сетей при квадратичной функции потерь. В этой постановке ландшафтная мера сопоставлена с эмпирической радемахеровской сложностью для тех же классов моделей. Показано, что эти величины отвечают на разные вопросы: радемахеровская сложность характеризует равномерную емкость класса функций, тогда как ландшафтная мера описывает локальный разброс пообъектных матриц Гессе в фиксированной точке параметрического пространства.

Также проведен эмпирический анализ динамики выборочной ландшафтной меры при обучении языковых моделей GPT-2 на корпусе WikiText-103. Результаты показывают, что динамика μ содержит информацию о геометрическом режиме обучения, не сводимую к одной лишь динамике валидационной функции потерь.

Проведенные вычислительные эксперименты подтверждают согласованность теоретических оценок с наблюдаемым поведением для полносвязных, сверточных и трансформерных моделей, а также иллюстрируют различие между локальной ландшафтной мерой и классическими равномерными мерами сложности.

Полученные результаты задают теоретическую основу для анализа соответствия между сложностью модели и характеристиками данных и могут исполь-

зоваться при выборе архитектуры, планировании численных экспериментов и оценке достаточности обучающей выборки.

Основные ограничения исследования связаны с детерминистическим характером анализа, предположением о существовании единой точки минимума для последовательных размеров выборки, а также возможностью улучшения верхних оценок за счет учета специфики разреженных матриц. Полученные результаты вносят вклад в теорию анализа локальной геометрии ландшафтов функции потерь и создают основу для дальнейших исследований в области формализации сложности моделей глубокого обучения.




Рис. 2.18: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\hat{\theta}) - \mathcal{L}_k(\hat{\theta})|$ от размера выборки k для полносвязной нейронной сети при прямой классификации на наборах данных FashionMNIST, CIFAR10 и CIFAR100. Верхний ряд: при $L = 5$ уменьшение разности с увеличением h от 4 до 64; нижний ряд: при $h = 16$ увеличение разности с увеличением L от 1 до 10. Результаты подтверждают теорему 3 для различных наборов данных.




Рис. 2.19: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для полносвязной нейронной сети с предобученным экстрактором признаков (англ. Vision Transformer, ViT) на наборах данных FashionMNIST, CIFAR10 и CIFAR100. Верхний ряд: при $L = 5$ уменьшение разности с увеличением h от 4 до 64; нижний ряд: при $h = 16$ увеличение разности с увеличением L от 1 до 10. Результаты подтверждают независимость сходимости от природы пространства исходных объектов и согласуются с теоремой 3.




Рис. 2.20: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для сверточной нейронной сети при изменении количества сверточных слоев L при фиксированных размере ядра $k = 3$ и количестве каналов $C = 6$. Графики демонстрируют немонотонный характер зависимости разности потерь от количества слоев.




Рис. 2.21: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для сверточной нейронной сети при изменении размера ядра свертки k при фиксированных количестве слоев L и количестве каналов $C = 6$. Графики демонстрируют немонотонный характер зависимости разности потерь от размера ядра.




Рис. 2.22: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для сверточной нейронной сети при изменении количества каналов C при фиксированных количестве слоев L и размере ядра $k = 3$. Графики демонстрируют монотонный характер зависимости: увеличение числа каналов приводит к увеличению разности потерь, что согласуется с теоретическими оценками.




Рис. 2.23: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta)|$ от размера выборки k для сверточной нейронной сети при изменении позиции операции пулинга на наборе данных CIFAR10 при фиксированных количестве слоев L , размере ядра $k = 3$ и количестве каналов C . Графики демонстрируют монотонную зависимость: более раннее применение пулинга приводит к меньшей разности потерь.




Рис. 2.24: Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|$ от количества обучающих примеров k для трансформерной модели на наборе данных CIFAR-100, отображенная в двойном логарифмическом масштабе. Результаты подтверждают теорему 6 и демонстрируют стабилизацию ландшафта функции потерь с ростом объема данных.

Глава 3

Матрицы Гессе параметрических моделей

Как было установлено в предыдущей главе, ландшафтная мера сложности модели определяется через спектральные свойства матриц Гессе функции потерь. Анализ сходимости ландшафта оптимизационной задачи при увеличении объема выборки сводится к анализу спектральной нормы матрицы Гессе. Для применения введенного в главе 2.1. формализма необходимы явные оценки спектральных норм матриц Гессе для основных классов архитектур. Получение таких оценок составляет задачу настоящей главы.

Результаты главы получены совместно с учениками; вклад автора диссертации состоит в постановке задач и научном руководстве. Утверждения, основные доказательства которых принадлежат ученикам, приводятся без развернутых доказательств со ссылкой на соответствующие работы. Содержание главы не выносится на защиту как самостоятельный результат, однако необходимо для обоснования вычислимости ландшафтной меры сложности.

В современных задачах оптимизации, к которым редуцируется процесс обучения моделей глубокого обучения, фундаментальную роль играет анализ свойств целевой функции потерь $\mathcal{L}(\boldsymbol{\theta})$, заданной на многомерном пространстве параметров $\boldsymbol{\theta} \in \mathbb{R}^n$.

Глубокие нейронные сети, обладающие способностью к аппроксимации сложных нелинейных зависимостей, порождают невыпуклые функции потерь с множеством локальных минимумов, седловых точек и сложным ландшафтом.

Если градиент $\nabla \mathcal{L}(\boldsymbol{\theta})$ характеризует скорость и направление наискорейшего спуска в параметрическом пространстве, то матрица Гессе $\mathbf{H}(\mathcal{L})$ — симметричная матрица вторых частных производных функции потерь — задаёт локальную кривизну функции потерь и тем самым описывает геометрию ландшафта в окрестности заданной точки, что используется при анализе траектории оптимизации и устойчивости найденных решений.

Формальное определение матрицы Гессе для функции $\mathcal{L}(\boldsymbol{\theta})$ от n параметров задается следующим выражением:

$$\mathbf{H}(\mathcal{L})_{ij} = \frac{\partial^2 \mathcal{L}}{\partial \theta_i \partial \theta_j},$$

где индексы $i, j = 1, \dots, n$ соответствуют компонентам вектора параметров $\boldsymbol{\theta}$. Для функций, обладающих непрерывными вторыми производными, матрица Гессе симметрична в силу Теоремы Шварца-Клеро-Янга о равенстве смешанных производных. Эта симметричность обеспечивает вещественность всех собственных значений и ортогональность соответствующих собственных векторов, что существенно для спектрального анализа.

В оптимизации на матрице Гессе основаны методы второго порядка, в частности метод Ньютона, использующий $\mathbf{H}^{-1}$ для учёта локальной кривизны; при этом прямое обращение плотной матрицы Гессе вычислительно дорого, что мотивирует квазиньютоновские и приближенные схемы. В теоретическом анализе собственные значения гессиана в стационарной точке описывают геометрию ландшафта: локальную кривизну по направлениям, наличие седловых точек и устойчивость найденного решения.

Во-первых, малые собственные значения соответствуют направлениям с незначительной кривизной — так называемым “плоским” регионам, где параметры могут варьироваться без существенного роста ошибки. Эти направления часто ассоциируются с параметрами, оказывающими незначительное влияние на выход модели, или с симметриями в архитектуре сети. В противоположность этому, большие собственные значения указывают на “острые” минимумы с выраженной кривизной. В литературе плоские минимумы часто связывают с лучшей обобщающей способностью за счет меньшей чувствительности к малым возмущениям данных и параметров; понятие остроты минимума остается предметом активных исследований.

Во-вторых, след матрицы Гессе, равный сумме ее собственных значений, является интегральной характеристикой общей кривизны функции потерь. Де-

тальный анализ спектрального состава матрицы Гессе, в частности оценка кратности собственных значений вблизи нуля, позволяет количественно оценить эффективную размерность пространства параметров, влияющих на выход модели, и идентифицировать структурную избыточность в архитектуре нейронной сети. Кроме того, распределение собственных значений матрицы Гессе тесно связано с устойчивостью модели к шуму, способностью к интерполяции данных и обобщающей способностью на тестовых выборках.

Таким образом, матрица Гессе служит одновременно инструментом оптимизации второго порядка и средством анализа локальной геометрии модели. Для сетей с миллионами и миллиардами параметров хранение и обращение плотной матрицы $n \times n$ непрактично, поэтому необходимы аппроксимации гессиана и аналитические оценки его спектральных характеристик. К числу таких подходов относятся случайное проектирование, разложения Кронекера, диагональные и блочно-диагональные аппроксимации, а также методы теории случайных матриц.

3.1. Полносвязные сети

Рассмотрим формальную постановку задачи K -классовой классификации с использованием функции потерь кросс-энтропии. В данной постановке входные данные представляются вектором $\mathbf{x} \in \mathbb{R}^l$, а выходные данные — вектором $\mathbf{y} \in \mathbb{R}^K$, имеющим структуру one-hot кодирования, где все компоненты равны нулю, за исключением позиции $y_k = 1$, соответствующей истинной метке класса для входного образца $\mathbf{x}$. Такое представление данных является стандартным для задач классификации и позволяет естественным образом использовать категориальное распределение для моделирования неопределенности предсказаний.

Рассматривается L -слойная полносвязная нейронная сеть $f_{\theta}(\cdot)$ с функцией активации ReLU, применяемой после каждого линейного преобразования.

Выбор функции активации ReLU обусловлен ее вычислительной эффективностью и свойством устранять проблему затухающих градиентов, а также удобством теоретического анализа. Для функции активации ReLU, определяемой как $\sigma(\mathbf{x}) = [\mathbf{x} \geq \mathbf{0}] \mathbf{x}$, где $[\cdot]$ обозначает поэлементную индикаторную функцию, выход сети представляет собой вектор логитов $\mathbf{z} \in \mathbb{R}^K$. Вычисление логитов осуществляется посредством последовательного применения следующих рекуррентных соотношений:

$$\begin{aligned}\mathbf{z}^{(p)} &= \mathbf{W}^{(p)} \mathbf{x}^{(p)} + \mathbf{b}^{(p)}, \\ \mathbf{x}^{(p+1)} &= \sigma(\mathbf{z}^{(p)}).\end{aligned}$$

Здесь $\mathbf{x}^{(p)}$ и $\mathbf{z}^{(p)}$ обозначают вход и выход p -го слоя соответственно, при этом полагается $\mathbf{x}^{(1)} = \mathbf{x}$ и $\mathbf{z} = f_{\boldsymbol{\theta}}(\mathbf{x}) = \mathbf{z}^{(L)}$. Совокупность всех параметров модели обозначается как $\boldsymbol{\theta} = \text{col}(\mathbf{w}^{(1)}, \mathbf{b}^{(1)}, \dots, \mathbf{w}^{(L)}, \mathbf{b}^{(L)}) \in \mathbb{R}^n$. Для p -го слоя $\mathbf{w}^{(p)}$ представляет собой векторизованную матрицу весов $\mathbf{W}^{(p)}$, а $\mathbf{b}^{(p)}$ — соответствующий вектор смещений. Общее число параметров n в таких моделях может достигать миллионов и даже миллиардов, что и создает вычислительные трудности для точного вычисления матрицы Гессе.

Выходы модели определяются как $\mathbf{p} = \text{softmax}(\mathbf{z}) \in \mathbb{R}^K$, где каждая компонента вычисляется по формуле:

$$p_i = \text{softmax}(\mathbf{z})_i = \frac{\exp(z_i)}{\sum_{j=1}^K \exp(z_j)} \in (0; 1).$$

Функция потерь представляет собой стандартную кросс-энтропийную функцию ошибки:

$$\ell(\mathbf{z}, \mathbf{y}) = \text{CE}(\mathbf{p}, \mathbf{y}) = - \sum_{k=1}^K y_k \log p_k \in \mathbb{R}^+.$$

Эта функция является выпуклой по логитам $\mathbf{z}$, но невыпуклой по параметрам сети $\boldsymbol{\theta}$ из-за сложной композиционной структуры нейронной сети.

Согласно установленным результатам в литературе [108], применение цепного правила для матриц второго порядка [116] позволяет декомпозировать мат-

рицу Гессе на сумму двух структурно различных компонент:

$$\mathbf{H}_i(\boldsymbol{\theta}) = \underbrace{\nabla_{\boldsymbol{\theta}\mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\boldsymbol{\theta}\mathbf{z}_i}^T}_{\text{G-компонента}} + \underbrace{\sum_{k=1}^K \frac{\partial \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial z_{ik}} \nabla_{\boldsymbol{\theta}}^2 z_{ik}}_{\text{H-компонента}},$$

где $\nabla_{\boldsymbol{\theta}\mathbf{z}_i} \in \mathbb{R}^{P \times K}$ представляет собой матрицу Якоби функции нейронной сети по параметрам, а $\frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2}$ — матрицу Гессе функции потерь относительно выходных логитов для i -го наблюдения. Первое слагаемое (G-компонента) отражает влияние кривизны функции потерь, в то время как второе слагаемое (H-компонента) — кривизну самой нейронной сети.

Эмпирические исследования [107, 108, 110] демонстрируют, что спектральное распределение матрицы Гессе характеризуется наличием основной массы собственных значений, сосредоточенной вблизи нуля, и выбросов, распределенных в области ненулевых значений. Это бимодальное распределение собственных значений является характерной чертой гессианов глубоких нейронных сетей и отражает фундаментальные свойства параметрического пространства таких моделей. Вследствие данной спектральной структуры, для практического анализа наиболее релевантной является G-компонента, что обосновывает использование следующей аппроксимации:

$$\mathbf{H}_i(\boldsymbol{\theta}) \approx \nabla_{\boldsymbol{\theta}\mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\boldsymbol{\theta}\mathbf{z}_i}^T.$$

Дополнительное обоснование этой аппроксимации дает теория нейронного касательного ядра (НТК) [114, 132], в которой логиты $\mathbf{z}$ локально линеаризуются по параметрам $\boldsymbol{\theta}$; тогда $\nabla_{\boldsymbol{\theta}}^2 z_{ik}$ обращается в ноль и H-компонента исчезает.

На основе работ [111], предлагающих аналитическую аппроксимацию G-компоненты для полносвязных нейронных сетей, принимается следующая параметризация: $\mathbf{H}_i(\boldsymbol{\theta}) \approx \mathbf{F}_i^T \mathbf{A}_i \mathbf{F}_i$. Эта факторизация позволяет эффективно вычислять приближения гессиана без явного построения полной матрицы, используя разложения в матрицы меньшей размерности. Введем систему обозначений:

- Матричное представление функции активации ReLU:

$$\mathbf{D}^{(p)} = \text{diag}([\mathbf{z}^{(p)} \geq \mathbf{0}]),$$

Эта диагональная матрица кодирует маску активации нейронов на p -м слое и играет основную роль в определении функциональной структуры сети.

- Матрица прямого распространения от p -го слоя к выходу:

$$\mathbf{G}^{(p)} = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} = \mathbf{W}^{(L)} \mathbf{D}^{(L-1)} \mathbf{W}^{(L-1)} \mathbf{D}^{(L-2)} \cdot \dots \cdot \mathbf{D}^{(p)},$$

Эта матрица описывает, как изменения в активациях на p -м слое через последующие слои к выходу сети.

- Блочная матрица всех производных логитов по параметрам:

$$\mathbf{F}^T = \begin{pmatrix} (\mathbf{G}^{(1)})^T \otimes \mathbf{x}^{(1)} \\ (\mathbf{G}^{(1)})^T \\ \vdots \\ (\mathbf{G}^{(L)})^T \otimes \mathbf{x}^{(L)} \\ (\mathbf{G}^{(L)})^T \end{pmatrix},$$

где $\otimes$ обозначает произведение Кронекера. Эта блочная структура естественным образом отражает слоистую архитектуру сети и позволяет эффективное вычисление.

- Гессиан функции потерь относительно логитов, имеющий структуру ковариационной матрицы [133]:

$$\mathbf{A} = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y}) = \text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^T.$$

Эта матрица является положительно полуопределенной и вырожденной, что отражает инвариантность функции softmax к сдвигам в пространстве логитов.

На основе предложенной параметризации получена верхняя оценка спектральной нормы матрицы Гессе в полносвязной нейронной сети, формулируемая в теореме 9.

3.1.1. Спектральная оценка матрицы Гессе

Теорема 9 устанавливает верхнюю оценку спектральной нормы матрицы Гессе для полносвязной нейронной сети с функцией активации ReLU. Условия теоремы включают ограниченность спектральных норм матриц весов всех слоев и норм входных векторов, что представляет собой естественное предположение для большинства практических приложений.

Полученная оценка демонстрирует экспоненциальную зависимость от глубины сети L , что согласуется с известными результатами о возрастании сложности оптимизационного ландшафта с увеличением глубины нейронной сети.

Теорема 9 (Оценка нормы матрицы Гессе для полносвязных сетей). *Рассмотрим L -слойную полносвязную нейронную сеть с функцией активации ReLU и без членов смещения, применяемую для решения задачи классификации на K классов. Предположим, что выполнены условия:*

$$\begin{aligned}\|\mathbf{W}^{(p)}\|_2 &\leq M_{\mathbf{W}}, \\ \|\mathbf{x}_i\|_2 &\leq M_{\mathbf{x}},\end{aligned}$$

для всех слоев $p = 1, \dots, L$ в сети и для всех объектов $i = 1, \dots, t$. Тогда для любого объекта $i = 1, \dots, t$ выполняется следующее неравенство:

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{W}}^{2L} + \sqrt{2}\frac{M_{\mathbf{W}}^2(M_{\mathbf{W}}^{2L} - 1)}{M_{\mathbf{W}}^2 - 1}.$$

Доказательство теоремы приведено в работе [70].

Замечание 5. В теореме 9 получена оценка на матрицу Гессе для однослойной сети $L = 1$ вида:

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq \sqrt{2}M_{\mathbf{W}}^2 (M_{\mathbf{x}}^2 + 1).$$

Данная оценка соответствует эмпирическому представлению о том, что кривизна функции потерь пропорциональна квадрату нормы весов и квадрату нормы входных данных.

Теорема 10 указывает на зависимость спектральной нормы матрицы Гессе от размера скрытого слоя h . Полученная оценка демонстрирует, что норма гессиана растет экспоненциально как по глубине сети L , так и по размеру скрытого слоя h , причем степень экспоненты определяется произведением hM . Это подчеркивает влияние ширины и глубины сети на сложность оптимизационного ландшафта.

Экспоненциальный характер зависимости объясняет известную эмпирическую оценку о том, что глубокие и широкие сети обладают значительно более сложной геометрией функции потерь, что создает дополнительные сложности для методов оптимизации. Полученный результат также подчеркивает важность контроля норм параметров на протяжении всего процесса обучения для обеспечения устойчивости алгоритмов оптимизации.

Теорема 10 (Асимптотика нормы матрицы Гессе для полносвязных сетей). *Пусть все параметры модели ограничены некоторой константой $M > 0$, то есть для всех $i, j = 1, \dots, h$ и для всех слоев $p = 1, \dots, L$ выполняется условие $|w_{ij}^{(p)}| \leq M$, тогда при выполнении условий Теоремы 9 справедливо следующее неравенство:*

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq L\sqrt{2}M_x^2(hM)^{2L} + \sqrt{2}\frac{(hM)^2((hM)^{2L} - 1)}{(hM)^2 - 1}.$$

Таким образом, имеет место следующая пропорциональность для нормы матрицы Гессе:

$$\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \propto L(hM)^{2L}.$$

Доказательство теоремы приведено в работе [70].

Полученные результаты указывают на то, что норма матрицы Гессе является степенной функцией от размера скрытого слоя h и экспоненциальной функцией от количества слоев L .

С одной стороны, полученная оценка является завышенной. С другой стороны, если выбрать значение h большим, то ограничивающая константа M будет малой, на что указывают эмпирические исследования.

3.2. Матричные и сверточные сети

В настоящем разделе рассматривается общий класс матричных моделей глубокого обучения, которые представляют собой композицию последовательных линейных преобразований и нелинейных функций активации. Частным случаем такого представления являются сверточные нейронные сети (англ. CNN), а также другие архитектуры, где каждый слой может быть представлен в виде линейного оператора.

Данный подход позволяет единообразно анализировать различные архитектуры нейронных сетей через призму матричных операций, что упрощает получение оценок для матриц Гессе.

Пусть $f_{\theta}(\mathbf{x})$ является суперпозицией $L + 1$ слоев с активациями ReLU, что формально записывается как:

$$f_{\theta}(\mathbf{x}) = \mathbf{T}^{(L+1)} \circ \sigma \circ \dots \circ \sigma \circ \mathbf{T}^{(1)}(\mathbf{x}).$$

В этом представлении каждый $\mathbf{T}^{(p+1)}$ представляет собой линейный оператор или его матричное представление, а σ обозначает функцию активации ReLU, применяемую поэлементно. Такая композиционная структура позволяет описывать глубокие нейронные сети как последовательность преобразований, где каждый слой осуществляет линейное отображение с последующей нелинейной активацией.

Промежуточные результаты вычисления функции сети могут быть представлены в виде системы уравнений:

$$\begin{cases} \mathbf{z}^{(p+1)} &= \mathbf{T}^{(p+1)}\mathbf{x}^{(p)}, \\ \mathbf{x}^{(p+1)} &= \sigma(\mathbf{z}^{(p+1)}) \end{cases}$$

где выход сети определяется как $f_{\theta}(\mathbf{x}) = \mathbf{z} := \mathbf{z}^{(L+1)}$, а входные данные задаются как $\mathbf{x}^{(0)} := \mathbf{x}$. Здесь $\mathbf{z}^{(p+1)}$ представляет собой выход линейного оператора на $(p + 1)$ -м слое до применения активации, а $\mathbf{x}^{(p+1)}$ — результат после применения функции активации ReLU, который является входом для следующего слоя.

Рассмотрим матрицу $\mathbf{\Lambda}^{(p+1)} := \text{diag}(\mathbf{x}^{(p+1)} > 0)$, зависящую от входных данных, которая кодирует маску активации нейронов на $(p + 1)$ -м слое. Элементы этой матрицы равны 1 для нейронов с положительной активацией и 0 в противном случае, что отражает свойство функции ReLU "отсекать" отрицательные значения и представляет функцию активации в виде линейного оператора. Используя эти диагональные матрицы, всю функцию нейронной сети можно представить в виде произведения матриц, а именно суперпозиций линейных операторов:

$$f_{\boldsymbol{\theta}}(\mathbf{x}) = \mathbf{T}^{(L+1)} \mathbf{\Lambda}^{(L)} \dots \mathbf{\Lambda}^{(1)} \mathbf{T}^{(1)} \mathbf{x}. \quad (3.1)$$

Данное представление позволяет рассматривать глубокую нейронную сеть с активациями ReLU как кусочно-линейную функцию, где нелинейность возникает исключительно за счет бинарных переключений в матрицах $\mathbf{\Lambda}^{(p)}$, зависящих от входных данных.

Вектор параметров модели объединяет все обучаемые параметры сети: $\boldsymbol{\theta} = \text{col}(\mathbf{W}^{(L+1)}, \dots, \mathbf{W}^{(1)})$, где каждый линейный оператор $\mathbf{T}^{(p)}$ дифференцируемо параметризуется соответствующей частью вектора параметров $\mathbf{W}^{(p)}$. Для анализа модели вводится производная слоя по его параметрам:

$$\mathbf{Q}^{(p)} := \frac{\partial \mathbf{T}^{(p)}}{\partial \mathbf{W}^{(p)}},$$

а затем строится блочно-диагональная матрица, объединяющая эти производные по всем слоям:

$$\mathbf{Q} := \text{diag}(\mathbf{Q}^{(1)}, \dots, \mathbf{Q}^{(L+1)}).$$

Матрица $\mathbf{Q}^{(p)}$ полностью описывает расположение параметров в p -м слое и их влияние на линейное преобразование этого слоя.

Для дальнейшего анализа вводятся дополнительные обозначения, которые описывают предшествующие и последующие преобразования относительно p -го

слоя. Преобразования, которые последуют после p -го слоя:

$$\begin{aligned}\mathbf{G}^{(p)} &:= \mathbf{T}^{(L+1)} \mathbf{\Lambda}^{(L)} \dots \mathbf{T}^{(p+1)} \mathbf{\Lambda}^{(p)}; \\ \mathbf{G}^{(L+1)} &:= \mathbf{I};\end{aligned}$$

и преобразования, которые предшествовали p -му слою:

$$\begin{aligned}\mathbf{R}^{(p)} &:= \mathbf{\Lambda}^{(p)} \mathbf{T}^{(p)} \dots \mathbf{\Lambda}^{(1)} \mathbf{T}^{(1)}; p = \overline{1, L}; \\ \mathbf{R}^{(0)} &:= \mathbf{I}.\end{aligned}$$

Матрица $\mathbf{G}^{(p)}$ описывает линейные преобразования от p -го слоя к выходу сети, в то время как $\mathbf{R}^{(p)}$ описывает линейные преобразование входа до p -го слоя.

Используя введенные обозначения, запишем следующие выражения:

$$\begin{aligned}\mathbf{z} &= \mathbf{G}^{(p)} \mathbf{z}^{(p)}, \\ \mathbf{x}^{(p)} &= \mathbf{R}^{(p)} \mathbf{x}, \\ \mathbf{z} &= f_{\theta}(\mathbf{x}) = \mathbf{G}^{(p)} \mathbf{T}^{(p)} \mathbf{R}^{(p-1)} \mathbf{x}.\end{aligned}$$

Первое уравнение выражает выход сети через промежуточные значения на p -м слое, второе показывает преобразование входного сигнала до p -го слоя, а третье дает полное представление выхода сети через параметры p -го слоя и преобразования до и после него.

Объединяя матрицы $\mathbf{G}^{(p)}$ и $\mathbf{R}^{(p)}$ в единый оператор, получаем расширенную матрицу:

$$\mathbf{F}^T := \begin{pmatrix} \mathbf{G}^{(1)T} \otimes \mathbf{R}^{(0)} \mathbf{x} \\ \vdots \\ \mathbf{G}^{(k)T} \otimes \mathbf{R}^{(k-1)} \mathbf{x} \\ \vdots \\ \mathbf{G}^{(L+1)T} \otimes \mathbf{R}^{(L)} \mathbf{x} \end{pmatrix}.$$

Эта блочная матрица содержит в себе всю информацию о том, как изменения параметров в различных слоях влияют на выход сети. Каждый блок этой

матрицы соответствует определенному слою и содержит информацию как о линейных преобразованиях от этого слоя к выходу ($\mathbf{G}^{(k)T}$), так и о преобразовании входа до этого слоя ($\mathbf{R}^{(k-1)}\mathbf{x}$).

В случае использования функции потерь кросс-энтропии (СЕ) для задач классификации, гессиан функции потерь относительно логитов имеет структуру:

$$\mathbf{A} := \nabla_{\mathbf{z}}^2 \ell = \text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^T,$$

где $\mathbf{p} := \text{softmax}(\mathbf{z})$ представляет вектор вероятностей, предсказанных моделью. Матрица $\mathbf{A}$ является ковариационной матрицей многомерного распределения и обладает свойствами положительной полуопределенности и вырожденности, что отражает инвариантность функции softmax к сдвигам в пространстве логитов.

3.2.1. Факторизация матрицы Гессе

Теорема 11 (Факторизация матрицы Гессе). *Пусть функция нейронной сети $f_{\theta}(\mathbf{x})$ представима в виде (3.1), тогда матрица Гессе функции потерь относительно параметров модели может быть представлена в факторизованной форме: $\mathbf{H}_O(\theta) = \mathbf{Q}^T \mathbf{F}^T \mathbf{A} \mathbf{F} \mathbf{Q}$, где $\mathbf{H}_O$ описывает G -компоненту матрицы Гессе.*

Доказательство. Доказательство теоремы основано на последовательном применении цепного правила матричного дифференцирования и использовании свойств произведения Кронекера. Исходное представление выхода матричной нейросетевой модели:

$$\mathbf{z} = f_{\theta}(\mathbf{x}) = \mathbf{T}^{(L+1)} \mathbf{\Lambda}^{(L)} \mathbf{T}^{(L)} \dots \mathbf{\Lambda}^{(1)} \mathbf{T}^{(1)} \mathbf{x}.$$

Производные выхода сети по параметрам модели вычисляются с использованием цепного правила:

$$\frac{\partial \mathbf{z}}{\partial \mathbf{W}^{(p)}} = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{T}^{(p)}} \frac{\partial \mathbf{T}^{(p)}}{\partial \mathbf{W}^{(p)}}.$$

Для вычисления $\frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{T}^{(p)}}$ используется тождество для векторизации матричных произведений: $\text{vec}(\mathbf{BVA}^T) = (\mathbf{A} \otimes \mathbf{B})\text{vec}(\mathbf{V})$. Применяя это тождество с $\mathbf{A} = \mathbf{I}$ и векторизуя $\mathbf{z}^{(p)} = \mathbf{T}^{(p)}\mathbf{x}^{(p-1)}$, получаем:

$$\text{vec}(\mathbf{z}^{(p)}) = \text{vec}(\mathbf{T}^{(p)}\mathbf{x}^{(p-1)}) = (\mathbf{I} \otimes \mathbf{x}^{(p-1)})\text{vec}(\mathbf{T}^{(p)}).$$

Отсюда следует, что:

$$\frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{T}^{(p)}} = \mathbf{I} \otimes \mathbf{x}^{(p-1)T}.$$

Используя выражение $\mathbf{z} = \mathbf{G}^{(p)}\mathbf{z}^{(p)}$, получаем производную выхода сети по промежуточному значению:

$$\frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}} = \mathbf{G}^{(p)}.$$

По определению $\mathbf{Q}^{(p)}$ имеем:

$$\frac{\partial \mathbf{T}^{(p)}}{\partial \mathbf{W}^{(p)}} = \mathbf{Q}^{(p)}.$$

Для объединения этих выражений используется свойство произведения Кронекера: если $\mathbf{A}_i \in \mathbb{R}^{m_i \times n_i}$, то $\mathbf{A}_1 \otimes \mathbf{A}_2 = (\mathbf{A}_1 \otimes \mathbf{I}_{m_2})(\mathbf{I}_{m_1} \otimes \mathbf{A}_2)$. Применяя это свойство с $m_2 = 1$, получаем:

$$\mathbf{G}^{(p)}(\mathbf{I} \otimes \mathbf{x}^{(p-1)T}) = (\mathbf{G}^{(p)} \otimes \mathbf{I}_1)(\mathbf{I} \otimes \mathbf{x}^{(p-1)T}) = \mathbf{G}^{(p)} \otimes \mathbf{x}^{(p-1)T}.$$

Подставляя все компоненты в исходную формулу для производной, получаем окончательное выражение:

$$\frac{\partial \mathbf{z}}{\partial \mathbf{W}^{(p)}} = (\mathbf{G}^{(p)} \otimes \mathbf{I}_1)(\mathbf{I} \otimes \mathbf{x}^{(p-1)T})\mathbf{Q}^{(p)} = (\mathbf{G}^{(p)} \otimes \mathbf{x}^{(p-1)T})\mathbf{Q}^{(p)}.$$

Используя результаты работ по анализу гессиана в нейронных сетях [134], получаем выражение для блоков матрицы Гессе:

$$\begin{aligned} \mathbf{H}_O^{(kl)} &= J(\boldsymbol{\theta})^T \mathbf{A} J(\boldsymbol{\theta}) = \\ &= \mathbf{Q}^{(k)T} (\mathbf{G}^{(k)T} \otimes \mathbf{R}^{(k-1)} \mathbf{x}) \mathbf{A} (\mathbf{G}^{(l)} \otimes \mathbf{x}^T \mathbf{R}^{(l-1)T}) \mathbf{Q}^{(l)}. \end{aligned}$$

Объединяя все блоки в единую матрицу, получаем итоговое выражение для матрицы Гессе:

$$\mathbf{H}_O = \mathbf{Q}^T \mathbf{F} \mathbf{A} \mathbf{F}^T \mathbf{Q}.$$

□

Теорема 11 устанавливает результат о структуре гессиана в матричных моделях глубокого обучения. Предложенная факторизация позволяет эффективно анализировать и вычислять гессиан без необходимости явного построения полной матрицы вторых производных, что существенно для моделей с большим числом параметров.

Структура $\mathbf{H}_O = \mathbf{Q}^T \mathbf{F} \mathbf{A} \mathbf{F}^T \mathbf{Q}$ подчеркивает, что гессиан может быть представлен как преобразование "внутреннего" гессиана $\mathbf{A}$ с помощью матриц $\mathbf{F}$ и $\mathbf{Q}$, которые отражают (англ. capture) архитектурные свойства сети и параметризацию слоев соответственно.

3.2.2. Оценки спектральных норм для матричных сетей

В настоящем подразделе устанавливаются верхние оценки спектральных норм матрицы Гессе для матричных моделей глубокого обучения.

Теорема 12 устанавливает верхнюю оценку для нормы матрицы Гессе в терминах структурных параметров нейронной сети. Полученная оценка демонстрирует экспоненциальную зависимость от глубины сети L и полиномиальную зависимость от норм параметров $\mathbf{Q}^{(p)}$ и $\mathbf{T}^{(p)}$.

Особенностью данной теоремы является учет влияния всех слоев сети через мультипликативные члены $w_{\mathbf{T}}^{2L}$ и аддитивные члены $(L + 1)$, что качественно отражает накопление сложности при увеличении глубины архитектуры. Оценка также подчеркивает важность контроля норм весовых матриц на протяжении всего процесса обучения для обеспечения устойчивости оптимизации.

Теорема 12 (Оценка нормы матрицы Гессе для матричных сетей). *Пусть нейронная сеть $f_{\theta}(\mathbf{x})$ представима в виде (3.1). Пусть для всех слоев p выполнены*

условия:

$$\begin{aligned}\|\mathbf{Q}^{(p)}\| &\leq q, \\ \|\mathbf{T}^{(p)}\|^2 &\leq w_{\mathbf{T}}^2.\end{aligned}$$

Тогда справедлива оценка:

$$\|\mathbf{H}_O\| \leq \sqrt{2}q^2 \|\mathbf{x}\|^2 (L+1)w_{\mathbf{T}}^{2L}.$$

Доказательство теоремы приведено в работе [121].

В настоящем подразделе рассматривается частный случай модели глубокого обучения, удовлетворяющей условию матричной факторизации для сверточной нейронной сети (англ. CNN) с одномерной сверткой. Оценки на норму матрицы Гессе устанавливаются в теореме 13.

Для сохранения единообразия обозначений используется символ $\mathbf{T}^{(p)}$, который в данном контексте соответствует одномерным сверткам, представленным в виде линейных операторов. Известно, что сверточные сети часто могут быть представлены в виде линейных сверточных нейронных сетей (англ. LCN). Обычно это относится к представлению сверточных сетей с помощью матриц Теплица [135, 136]. Используются обозначения для матриц Теплица из работы [134]. В указанной работе авторы определили специальный тип матрицы $\mathbf{Q}^{(p)}$, соответствующий структуре одномерной матрицы Теплица.

Одномерная сверточная сеть имеет вид $f_{\theta}(\mathbf{x}) = \mathbf{T}^{(L+1)} * (\sigma(\dots(\sigma(\mathbf{T}^{(1)} * \mathbf{x}))\dots))$, где операция $*$ означает свертку.

Пусть C_p обозначает количество каналов после p -го слоя, а d_p - размер последовательности. Здесь $\mathbf{x}^{(p)} \in \mathbb{R}^{C_p \times d_p}$, $\mathbf{T}^{(p)}$ — одномерный сверточный слой с ядром $\mathbf{W}^{(p)} \in \mathbb{R}^{C_{p-1} \times C_p \times k_p}$. Для упрощения дальнейших обозначений заменим $\mathbf{x}^{(p)}$ на $\text{vec}(\mathbf{x}^{(p)}) \in \mathbb{R}^{(C_p d_p)}$. Получили:

$$\mathbf{z}^{(p+1)} = \mathbf{T}^{(p+1)} \mathbf{x}^{(p)}.$$

Теорема 13 доказывает верхнюю оценку нормы гессиана для глубокой одномерной сверточной сети. Особенностью полученной оценки является

ся мультипликативная зависимость от глубины сети L и полиномиально-экспоненциальная зависимость от параметров модели — числа каналов C , размера ядра k и длины последовательности d .

Теорема 13 (Оценка нормы матрицы Гессе для 1D-сверточных сетей). *Пусть задана сеть вида:*

$$f_{\theta}x = C_{\mathbf{W}^{(L+1)}} \circ \sigma \circ \dots \circ \sigma \circ C_{\mathbf{W}^{(1)}},$$

где $C_{\mathbf{W}^{(i)}}$ — одномерная свертка с ядром $\mathbf{W}^{(i)}$, без дополнения (англ. *padding*) и с единичным шагом (англ. *stride*). Пусть заданы следующие верхние оценки на параметры:

$$C_l \leq C,$$

$$k_i \leq k,$$

$$d_i \leq d_1 := d,$$

$$|\mathbf{W}_{i,j,k}^{(p)}|^2 \leq w^2.$$

Тогда норма матрицы Гессе имеет следующую верхнюю оценку:

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|x\|^2 d^2 (L+1) (C^2 w^2 k d)^L.$$

Доказательство теоремы приведено в работе [121].

Переходим к рассмотрению двумерных сверточных сетей. Аналогично, для простоты сохраним обозначение $\mathbf{T}^{(p)}$ для слоев сверточной сети. Пусть задан $\mathbf{x} \in \mathbb{R}^{m \times n \times C}$ — входное изображение, имеющее размеры (m, n) и C каналов. Обозначим $\mathbf{x}^{(l)} \in \mathbb{R}^{m_i \times n_i \times C_i}$ — вход $(l+1)$ -го слоя, а матрицей $\mathbf{W}^{(l)} \in \mathbb{R}^{C_{l-1} \times C_l \times k_l^1 \times k_l^2}$ — свертку с размерами (k_l^1, k_l^2) , входным и выходным количеством каналов C_{l-1} и C_l соответственно.

Аналогично тому как было сделано для 1D-свертки, используем $\text{vec}(\mathbf{x}) \in \mathbb{R}^{m_i n_i C_i}$ вместо $\mathbf{x} \in \mathbb{R}^{m_i \times n_i \times C_i}$. Исследуется операция свертки над входным тензором. В случае векторизованного входа используется структура Теплица, аналогичная представленной в работе [137], при этом применяется конкретная матрица $\mathbf{T}^{(p)}$, строка которой состоит из элементов $\mathbf{W}_{*,c_2,*,*}^{(p)}$ для c_2 -го канала. То

есть каждая строка матрицы $\mathbf{T}^{(p)}$ реализует “применение” ядра к определенной позиции и определенному каналу. Обозначим матрицей $\mathbf{T}_i^{(p)}$ матрицу, которая соответствует $c_2 = c_2(i)$ -му каналу $\mathbf{W}$.

Далее теорема 14 устанавливает оценку нормы гессияна для глубоких двумерных сверточных сетей. Особенностью полученной оценки является экспоненциальная зависимость от глубины сети L и полиномиальная зависимость от основных параметров архитектуры: числа каналов C , размера ядра k и пространственных размеров $m \times n$.

Теорема 14 (Оценка нормы матрицы Гессе для 2D-сверточных сетей). *Пусть задана сеть вида*

$$f_{\theta}\mathbf{x} = C_{\mathbf{W}^{(L+1)}} \circ \dots \circ C_{\mathbf{W}^{(1)}},$$

где $C_{\mathbf{W}^{(i)}}$ — двумерная свертка с ядром $\mathbf{W}^{(i)}$, без дополнения (англ. *padding*) и с единичным шагом (англ. *stride*). Пусть заданы следующие верхние оценки на параметры:

$$C_l \leq C,$$

$$k_i \leq k,$$

$$m_i \leq m_1 := m,$$

$$n_i \leq n_1 := n,$$

$$|\mathbf{W}_{i,j,k}^{(p)}|^2 \leq w^2.$$

Тогда норма матрицы Гессе имеет следующую верхнюю оценку:

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|\mathbf{x}\|^2 q^2 (L+1) (C^2 k^2 w^2 m n)^L,$$

где $q^2 = C^2 k^2 m n$.

Доказательство теоремы приведено в работе [121].

Замечание 6. Полученные оценки в теоремах 13 и 14 имеют недостаток, связанный с тем, что они не учитывают уменьшение размеров после сверточных операций и зависят только от верхних границ параметров.

Рассмотренные выше теоремы 13 и 14 оперируют с сетями, которые состоят исключительно из сверточных слоев, что редко встречается на практике. В теоремах 15, 16, 17 рассматриваются случаи добавления других распространенных слоев в сверточные сети.

Теорема 15 описывает связь между параметрами сети с операцией макс-пулинга и сложностью оптимизационного ландшафта через норму матрицы Гессе. Полученная оценка показывает, что введение слоя макс-пулинга существенно модифицирует зависимость сложности модели от ее параметров.

Теорема 15 (Оценка нормы матрицы Гессе для MaxPool). *Пусть задана сеть вида:*

$$f_{\theta}\mathbf{x} = \mathbf{T}^{(L+1)}\mathbf{\Lambda}^{(L)} \dots \mathbf{\Lambda}^{(1)}\mathbf{T}^{(1)}\mathbf{x},$$

содержащий слой MaxPool2D в позиции $\mathbf{\Lambda}^{(l)}$ с ядром $k_{\text{pool}} \times k_{\text{pool}}$ вместо активации ReLU. Тогда имеет следующую верхнюю оценку нормы матрицы Гессе:

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|\mathbf{x}\|^2 q^2 \left(\frac{1}{k_{\text{pool}}^2} \right)^{L-l+2} (L+1) (k^2 C^2 w^2 m n)^L,$$

где $q^2 = mnC^2k^2$.

Доказательство теоремы приведено в работе [121].

Замечание 7. Как и в предыдущих случаях, норма гессиана растет экспоненциально с глубиной сети L , что согласуется с предыдущими оценками, но появление множителя $\left(\frac{1}{k_{\text{pool}}^2} \right)^{L-l+2}$ указывает на снижающий эффект операции пулинга на сложность оптимизации. Этот фактор отражает уменьшение размерности признакового описания после операции пулинга, что приводит к сокращению эффективной размерности параметрического пространства. Видно, что степень $L-l+2$ показывает, что влияние пулинга распространяется на все последующие слои. Чем раньше расположен слой пулинга, тем сильнее его редуцирующее воздействие на норму гессиана. Следовательно получаем, что операция пулинга частично компенсирует экспоненциальный рост сложности с увеличением глубины сети, однако этот эффект зависит от размера ядра пулинга k_{pool} .

Следующая теорема 16 устанавливает оценку нормы матрицы Гессе для сверточной сети, содержащей слой усредняющего пулинга.

Теорема 16 (Оценка нормы матрицы Гессе для AvgPool). *Пусть задана сеть вида:*

$$f_{\theta}\mathbf{x} = \mathbf{T}^{(L+1)}\mathbf{\Lambda}^{(L)} \dots \mathbf{\Lambda}^{(1)}\mathbf{T}^{(1)}\mathbf{x},$$

содержащая слой AvgPool2D в позиции $\mathbf{\Lambda}^{(l)}$ вместо активации ReLU с ядром размера $k_{\text{pool}} \times k_{\text{pool}}$. Тогда оценка нормы матрицы Гессе имеет следующую верхнюю оценку:

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|\mathbf{x}\|^2 q^2 \left(\frac{1}{k_{\text{pool}}^2} \right)^{L-l+2} (L+1) (k^2 C^2 w^2 m n)^L,$$

где $q^2 = m n C^2 k^2$.

Доказательство теоремы приведено в работе [121].

Замечание 8. *Полученная оценка в рамках Теоремы 16 демонстрирует, что операция усредняющего пулинга оказывает аналогичное макс-пулингу влияние на сложность оптимизационного ландшафта, уменьшая норму гессиана за счет множителя $\left(\frac{1}{k_{\text{pool}}^2} \right)^{L-l+2}$. Это подтверждает гипотезу о том, что операции пулинга любого типа способствуют снижению сложности модели и могут рассматриваться как эффективный механизм регуляризации в глубоких сверточных нейронных сетях.*

Теорема 17 устанавливает оценку нормы матрицы Гессе для гибридной архитектуры, сочетающей сверточные слои и полносвязный слой. Полученная оценка указывает на мультипликативный вклад обеих частей сети, причем сверточная часть вносит множитель $(k^2 C^2 w^2 m n)^L$, а полносвязная — $(h^2 \tilde{w}^2)^P$.

Теорема 17 (Оценка нормы матрицы Гессе для полносвязных выходных слоев). *Пусть задана сеть с P полносвязными слоями следующего вида:*

$$f_{\theta}\mathbf{x} = \mathbf{T}^{(L+P+1)}\mathbf{\Lambda}^{(L+P)} \dots \\ \dots \mathbf{\Lambda}^{(L+1)}\mathbf{T}^{(L+1)}\mathbf{\Lambda}^{(L)} \dots \mathbf{\Lambda}^{(1)}\mathbf{T}^{(1)}\mathbf{x},$$

где $\mathbf{T}^{(L+1+i)}$ — полносвязные слои с h_i параметрами при $i = 1, \dots, P$, а $\mathbf{T}^{(r)}$ — двумерные сверточные слои. Пусть $\left\| \mathbf{T}_{ij}^{(L+1+i)} \right\| \leq \tilde{w}$ и $h_p \leq h$. Тогда в условиях и обозначениях теоремы 14 справедливо неравенство:

$$\begin{aligned} \|\mathbf{H}_O\| &\leq \sqrt{2} \|\mathbf{x}\|^2 q^2 (h^2 \tilde{w}^2)^P (k^2 C^2 w^2 m n)^L \times \\ &\times \left(L + 1 + P \frac{h^2 \tilde{w}^2}{k^2 C^2 w^2 m n} \right). \end{aligned}$$

Доказательство теоремы приведено в работе [121].

3.3. Трансформеры

В настоящем разделе рассматриваются оценки норм матриц Гессе для трансформерных моделей глубокого обучения. Трансформеры представляют собой один из наиболее успешных классов архитектур в современном глубоком обучении, широко применяемых в задачах обработки естественного языка, компьютерного зрения и других областях.

Пусть $f_{\mathbf{w}}(\cdot)$ обозначает нейронную сеть, в данном случае слой самовнимания (англ. self-attention) или полный блок трансформера (англ. transformer), с параметрами $\mathbf{w} \in \Omega$. При наличии дважды дифференцируемых потерь $l(\cdot, \cdot)$ потери на выборку равны $l_i(\mathbf{w}) := l(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i)$. Эмпирические потери для выборок $L = k$ равны $\mathcal{L}_k(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k l_i(\mathbf{w})$, с гессианом $\mathbf{H}^{(k)}(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k \nabla_{\mathbf{w}}^2 l_i(\mathbf{w})$.

Пусть заданы входные вектора эмбедингов (англ. embeddings) $\mathbf{X} \in \mathbb{R}^{L \times d_V}$. Выход слоя одной головы (англ. single-head) слоя самовнимания задается в виде:

$$\mathbf{F}(\mathbf{X}) = \mathbf{A}(\mathbf{X}) \mathbf{X} \mathbf{W}_V, \quad (3.2)$$

где $\mathbf{A}(\mathbf{X}) = \text{softmax} \left(\frac{\mathbf{X} \mathbf{W}_Q \mathbf{W}_K^\top \mathbf{X}^\top}{\sqrt{d_K}} \right)$, а $\mathbf{W}_Q, \mathbf{W}_K \in \mathbb{R}^{d_V \times d_K}$, $\mathbf{W}_V \in \mathbb{R}^{d_V \times d_V}$.

Используя (3.2), полный блок трансформера выглядит следующим образом:

$$\text{LayerNorm} \left(\text{LayerNorm}(\mathbf{X} + \mathbf{F}(\mathbf{X})) + \text{FFN}(\text{LayerNorm}(\mathbf{X} + \mathbf{F}(\mathbf{X}))) \right)$$

где $\text{FFN}(\cdot)$ является блоком полносвязной сети с некоторой нелинейностью.

Слой LayerNorm для входной матрицы $\mathbf{U} \in \mathbb{R}^{m \times n}$ (строки — токены, столбцы —

признаки) описывается выражением:

$$\text{LayerNorm}(\mathbf{U})_{i,j} = \gamma_j \frac{\mathbf{U}_{i,j} - \mu_i}{\sqrt{\sigma_i^2}} + \beta_j,$$

где $\mu_i = \frac{1}{n} \sum_{j=1}^n \mathbf{U}_{i,j}$, $\sigma_i^2 = \frac{1}{n} \sum_{j=1}^n (\mathbf{U}_{i,j} - \mu_i)^2$.

Предположение 3 (Условие положительности дисперсии для LayerNorm).
Для входной матрицы слоя *LayerNorm*: $\mathbf{X} + \mathbf{F}(\mathbf{X})$, $\mathbf{Y} + \text{FFN}(\mathbf{Y})$, построчная дисперсия удовлетворяет условию $\min_i \sigma_i^2 > 0$.

Предположение 3 является техническим и требуется для доказательства ряда теорем. Выполнение данного свойства достигается добавлением к знаменателю положительной константы, что, однако, усложняет вычисления.

Для оценки матрицы Гессе рассматривается среднеквадратичная функция ошибки:

$$l(\cdot, \mathbf{Target}) = \frac{1}{Ld_V} \|\cdot - \mathbf{Target}\|_F^2.$$

В дальнейшем для доказательств используется разложение Гаусса-Ньютона матрицы Гессе $\mathcal{L}_k \circ f_{\mathbf{w}}$:

$$\frac{\partial^2(\mathcal{L}_k \circ f_{\mathbf{w}})}{\partial \mathbf{W}_i \partial \mathbf{W}_j} = \frac{\partial f_{\mathbf{w}}}{\partial \mathbf{W}_i}(\cdot)^\top \frac{\partial^2 \mathcal{L}_k}{\partial f_{\mathbf{w}}^2}(f_{\mathbf{w}}(\cdot)) \frac{\partial f_{\mathbf{w}}}{\partial \mathbf{W}_j}(\cdot) + \left(\frac{\partial \mathcal{L}_k}{\partial f_{\mathbf{w}}}(f_{\mathbf{w}}(\cdot)) \otimes \mathbf{I}_{p_i q_i} \right) \frac{\partial^2 f_{\mathbf{w}}}{\partial \mathbf{W}_i \partial \mathbf{W}_j}(\cdot) \quad (3.3)$$

Вычисляются обобщенные выражения матрицы Гессе для слоя самовнимания, которые затем расширяются до полного блока модели трансформера. Подход основан на теоретической базе работы [138], адаптируя и обобщая ее результаты.

Матрица Гессе функции ошибки $\mathcal{L}_k$ относительно параметров модели $\mathbf{w}$:

$$\mathbf{H}^{(k)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_k(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k \nabla_{\mathbf{w}}^2 l_i(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w})$$

где $\mathbf{H}_k(\mathbf{w})$ является матрицей Гессе блока самовнимания для параметров $\mathbf{w}$, относящихся к матрицам $\{\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V\}$. Используя разложения Гаусса-Ньютона (3.3):

$$\mathbf{H}_k(\mathbf{W}_i, \mathbf{W}_j) = \frac{\partial^2 l}{\partial \mathbf{W}_i \partial \mathbf{W}_j} = \mathbf{H}_o(\mathbf{W}_i, \mathbf{W}_j) + \mathbf{H}_f(\mathbf{W}_i, \mathbf{W}_j),$$

где $\mathbf{H}_o$ является внешнепроизведенной (англ. outer-product) частью матрицы Гессе, а $\mathbf{H}_f$ является матрицей Гессе функции самовнимания. Результаты этого разложения вычисляются согласно теоремам 3.1–3.2 в работе [138].

3.3.1. Слой самовнимания

В настоящем подразделе проводится оценка нормы матрицы Гессе для одного слоя самовнимания. Результат данной оценки формулируется в теореме 18.

Теорема 18 (Оценка нормы матрицы Гессе для слоя самовнимания). *Пусть $\|\cdot\|_2$ является спектральной нормой, тогда для слоя самовнимания получаем:*

$$\|\mathbf{H}_i(\mathbf{w}^*)\|_2 \leq M,$$

где

$$\begin{aligned} M = 3 \cdot \max & \left(\frac{2L}{d_V} \|\mathbf{X}\|_2^2, \right. \\ & \frac{8}{L^3 d_V d_K} \|\mathbf{W}_K\|_2^2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\ & \quad + \frac{12}{d_V d_K} \sqrt{\min(L, d_V)} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^5, \\ & \frac{4}{L d_V \sqrt{d_K}} \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^4 + \\ & \quad + \frac{4 \sqrt{\min(L, d_V)}}{L^2 \sqrt{d_K}} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^3, \\ & \frac{8}{L^3 d_V d_K} \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\ & \quad + \frac{4 \sqrt{\min(L, d_V)} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2)}{L d_V \sqrt{d_K}} \|\mathbf{W}_V\|_2 \cdot \\ & \quad \cdot \left(3L \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{X}\|_2^5 + \frac{d_V}{L} \|\mathbf{X}\|_2^3 \right) \Big). \end{aligned}$$

Доказательство. Используя результаты Леммы А.3 из работы [139], а также свойство 1 и свойство 2 получаем:

$$\left\| \frac{\partial \mathbf{A}}{\partial \mathbf{T}} \right\|_2 = \frac{1}{L} \|\mathbf{I}_L\|_2 \|\mathbf{I}_L - \frac{1}{L} \mathbf{1}_{L \times L}\|_2 \leq \frac{1}{L}$$

Данное неравенство верно в силу того, что $\frac{1}{L}\mathbf{1}_{L \times L}$ является матрицей проекции, поэтому $\mathbf{I}_L - \frac{1}{L}\mathbf{1}_{L \times L}$ также матрица проекции и следовательно норма $\|\mathbf{I}_L - \frac{1}{L}\mathbf{1}_{L \times L}\|_2 \leq 1$.

Далее для аппроксимации нормы матрицы $\mathbf{Z}_1$ используем те же свойства 1 и 2:

$$\begin{aligned} \|\mathbf{Z}_1\|_2 &\leq \|\mathbf{I}_L \otimes \mathbf{X}^\top\|_2 \left\| \frac{\partial \mathbf{A}}{\partial \mathbf{T}} \right\|_2 \|\mathbf{X} \otimes \mathbf{X}\|_2 \leq \\ &\leq \|\mathbf{X}\|_2 \frac{1}{L} \|\mathbf{X}\|_2^2 = \frac{1}{L} \|\mathbf{X}\|_2^3 \end{aligned} \quad (3.4)$$

где дополнительно было использовано свойство 3: $\|\mathbf{X}\|_2 = \|\mathbf{X}^\top\|_2$.

Оценим норму матрицы $\|\mathbf{A}\|_2$, которая является матрицей, где каждая строка является результатом применения функции softmax. Следовательно, каждый элемент матрицы $\mathbf{A}_{i,j} \leq 1$. Далее используя свойства 4 получаем $\|\mathbf{A}\|_{\max} \leq \|\mathbf{A}\|_2 \leq \sqrt{LL} \|\mathbf{A}\|_{\max} = L \|\mathbf{A}\|_{\max} \leq L$. Также получаем, что:

$$\|\mathbf{M}_1\|_2 = \|\mathbf{A}\mathbf{X}\|_2 \leq L \|\mathbf{X}\|_2.$$

Итого, легко получаем outer-product матрицы Гессе $\|\mathbf{H}_o(\mathbf{W}_i, \mathbf{W}_j)\|_2$ для разных матриц. В случае матрицы $\mathbf{W}_V$ и матрицы $\mathbf{W}_V$:

$$\begin{aligned} \|\mathbf{H}_o(\mathbf{W}_V, \mathbf{W}_V)\|_2 &\leq \frac{2}{Ld_V} \|\mathbf{M}_1\|_2^2 \leq \frac{2}{Ld_V} \|\mathbf{A}\|_2^2 \|\mathbf{X}\|_2^2 \leq \\ &\leq \frac{2}{Ld_V} L^2 \|\mathbf{X}\|_2^2 = \frac{2L}{d_V} \|\mathbf{X}\|_2^2. \end{aligned}$$

Для матриц $\mathbf{W}_Q$ и $\mathbf{W}_Q$ получаем:

$$\begin{aligned} \|\mathbf{H}_o(\mathbf{W}_Q, \mathbf{W}_Q)\|_2 &\leq \left\| \frac{2}{Ld_V d_K} (\mathbf{I}_{d_V} \otimes \mathbf{W}_K^\top) \mathbf{Z}_1^\top (\mathbf{I}_L \otimes \mathbf{W}_V \mathbf{W}_V^\top) \mathbf{Z}_1 (\mathbf{I}_{d_V} \otimes \mathbf{W}_K) \right\|_2 \leq \\ &\leq \frac{2}{Ld_V d_K} \|\mathbf{W}_K\|_2^2 \|\mathbf{Z}_1\|_2^2 \|\mathbf{W}_V\|_2^2 \leq \\ &\leq \frac{2}{Ld_V d_K} \|\mathbf{W}_K\|_2^2 \|\mathbf{W}_V\|_2^2 \frac{1}{L^2} \|\mathbf{X}\|_2^6 = \\ &= \frac{2}{L^3 d_V d_K} \|\mathbf{W}_K\|_2^2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6. \end{aligned}$$

Между матрицей $\mathbf{W}_V$ и матрицей $\mathbf{W}_Q$:

$$\begin{aligned}
\|\mathbf{H}_o(\mathbf{W}_V, \mathbf{W}_Q)\|_2 &\leq \frac{2}{Ld_V\sqrt{d_K}} \|\mathbf{M}_1^\top \otimes \mathbf{W}_V^\top\|_2 \|\mathbf{Z}_1\|_2 \|\mathbf{I}_{d_V} \otimes \mathbf{W}_K\|_2 \leq \\
&\leq \frac{2}{Ld_V\sqrt{d_K}} L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 \frac{1}{L} \|\mathbf{X}\|_2^3 \|\mathbf{W}_K\|_2 = \\
&= \frac{2}{Ld_V\sqrt{d_K}} \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^4
\end{aligned}$$

Между матрицей $\mathbf{W}_Q$ и матрицей $\mathbf{W}_K$:

$$\begin{aligned}
\|\mathbf{H}_o(\mathbf{W}_Q, \mathbf{W}_K)\|_2 &\leq \\
&\leq \frac{2}{Ld_Vd_K} \|(\mathbf{I}_{d_V} \otimes \mathbf{W}_K^\top) \mathbf{Z}_1^\top (\mathbf{I}_L \otimes \mathbf{W}_V \mathbf{W}_V^\top) \mathbf{Z}_1 (\mathbf{W}_Q \otimes \mathbf{I}_{d_V}) \mathbf{K} d_K, d_V\|_2 \leq \\
&\leq \frac{2}{L^3 d_V d_K} \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6.
\end{aligned}$$

Для всех оценок использовались свойства 1, 2, а также свойства $\|\mathbf{K}_{d_V d_K}\|_2 = 1$, потому что $\mathbf{K}_{m,n}$ является коммутативной матрицей, описанной в определении 31.

Далее проведем анализ матрицы $\mathbf{H}_f$. Для этого начнем анализ с матрицы $\mathbf{R}_m = \text{vec}_r(\mathbf{F}(\mathbf{X}) - \mathbf{Target})^T \otimes \mathbf{I}_m$, который описан в рамках Теоремы 3.2 в работе [138]. Так, как $\text{vec}_r(\cdot)$ является функцией векторизации:

$$\begin{aligned}
\|\text{vec}_r(\mathbf{F}(\mathbf{X}) - \mathbf{Target})\|_2 &= \|\mathbf{F}(\mathbf{X}) - \mathbf{Target}\|_F \leq \\
&\leq \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \|\mathbf{F}(\mathbf{X}) - \mathbf{Target}\|_2,
\end{aligned}$$

тогда согласно свойству 4 получаем:

$$\begin{aligned}
\|\mathbf{R}_m\| &\leq \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \|\mathbf{F}(\mathbf{X}) - \mathbf{Target}\|_2 \leq \\
&\leq \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} (\|\mathbf{A}\|_2 \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \leq \\
&\leq \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2)
\end{aligned}$$

где для получения оценок были использованы свойства матриц 1 и 6. В свою очередь норма матрицы перемешивания (англ. shuffling matrix) оценивается сле-

дующим образом:

$$\begin{aligned}\|\mathbf{S}\|_2 &= \|(\mathbf{I}_{d_V} \otimes \mathbf{K}_{d_V, d_V})(\text{vec}_r(\mathbf{I}_{d_V}) \otimes \mathbf{I}_{d_V})\|_2 \leq \\ &\leq \|\text{vec}_r(\mathbf{I}_{d_V})\|_2 = \|\mathbf{I}_{d_V}\|_F = \sqrt{d_V}.\end{aligned}$$

Для верхней оценки нормы матрицы $\|\frac{\partial^2 \mathbf{A}}{\partial \mathbf{T}^2}\|_2$ воспользуемся Леммой C1 с работы [138], где указано, что:

$$\frac{\partial^2 \mathbf{A}_{i,j}}{\partial \mathbf{T}_{i,:} \partial \mathbf{T}_{i,:}} = \mathbf{A}_{i,j} \left(2\mathbf{A}_{i,:} \mathbf{A}_{i,:}^\top + \mathbf{E}_{j,j}^{L,L} - \text{diag}(\mathbf{A}_{i,:}) - \mathbf{e}_j \mathbf{A}_{i,:}^\top - \mathbf{A}_{i,:} \mathbf{e}_j^\top \right) \in \mathbb{R}^{L \times L}, \quad (3.5)$$

где

$$\mathbf{E}_{j,j}^{L,L} = \mathbf{e}_j \mathbf{e}_j^\top \in \mathbb{R}^{L \times L},$$

поэтому он содержит только один ненулевой элемент, который равен 1 в позиции (j, j) . Кроме того, вторая производная softmax имеет блочно-диагональную структуру. Используя свойство 7 нормы блочно-диагональной матрицы, получаем:

$$\left\| \frac{\partial^2 \mathbf{A}}{\partial \mathbf{T}^2} \right\|_2 = \max_{i,j} \left\| \frac{\partial^2 \mathbf{A}_{i,j}}{\partial \mathbf{T}_{i,:} \partial \mathbf{T}_{i,:}} \right\|_2.$$

Приходим к тому, что требуется оценить следующую норму:

$$\left\| \frac{\partial^2 \mathbf{A}_{i,j}}{\partial \mathbf{T}_{i,:} \partial \mathbf{T}_{i,:}} \right\|_2.$$

Как было указано ранее, $\mathbf{A}_{i,j} \leq 1$. Следовательно, можем оценить матрицу $\|\mathbf{A}_{i,:} \mathbf{A}_{i,:}^\top\|_2$. Поскольку $\mathbf{A}_{i,:}$ является строкой softmax-матрицы, сумма элементов строки равна 1. Таким образом, используя векторно-матричные неравенства, получаем выражение:

$$\|\mathbf{A}_{i,:} \mathbf{A}_{i,:}^\top\|_2 \leq \|\mathbf{A}_{i,:}\|_2^2 \leq \|\mathbf{A}_{i,:}\|_1^2 = 1. \quad (3.6)$$

Аналогично установим, что

$$\|\mathbf{E}_{j,j}^{m,n}\|_2 = \|\mathbf{e}_j \mathbf{e}_j^\top\|_2 \leq 1. \quad (3.7)$$

Перейдем к оценке нормы диагональной матрицы $\|diag(\mathbf{A}_{i,:})\|_2$. Для диагональной матрицы справедливо следующее выражение:

$$\|diag(\mathbf{A}_{i,:})\|_2 = \max_j \mathbf{A}_{i,j} \leq 1. \quad (3.8)$$

Используя оценки (3.6) и (3.8) и (3.7) оценим нормы $\mathbf{e}_j \mathbf{A}_{i,:}^\top$ и $\mathbf{A}_{i,:} \mathbf{e}_j^\top$. Матрицы $\mathbf{e}_j \mathbf{A}_{i,:}^\top$ и $\mathbf{A}_{i,:} \mathbf{e}_j^\top$ являются матрицами ранга 1, при этом каждая из них содержит только одну ненулевую строку или столбец соответственно с элементами матрицы $\mathbf{A}_{i,:}$. Следовательно их спектральные нормы оцениваются сверху нормой матрицы $\|\mathbf{A}_{i,:}\|_2 \leq 1$.

Все слагаемые в выражении (3.5) имеют верхнюю оценку 1. Следовательно:

$$\left\| \frac{\partial^2 \mathbf{A}}{\partial \mathbf{T}^2} \right\|_2 \leq 6$$

Возвращаясь к выражению (3.4) получаем оценку матрицы $\|\mathbf{Z}_2\|_2$:

$$\begin{aligned} \|\mathbf{Z}_2\|_2 &= \|(\mathbf{I}_L \otimes \mathbf{X}^\top \otimes \mathbf{X}^\top \otimes \mathbf{X}^\top) (\partial^2 \mathbf{A} / \partial \mathbf{T}^2) (\mathbf{X} \otimes \mathbf{X})\|_2 \leq \\ &\leq \|\mathbf{X}\|_2^5 \left\| \frac{\partial^2 \mathbf{A}}{\partial \mathbf{T}^2} \right\|_2 \leq 6 \|\mathbf{X}\|_2^5 \end{aligned}$$

Оцениваем часть $\mathbf{H}_f$. Для нормы между матрицами $\mathbf{W}_V$ и $\mathbf{W}_V$:

$$\|\mathbf{H}_f(\mathbf{W}_V, \mathbf{W}_V)\|_2 = 0$$

Для нормы между матрицами $\mathbf{W}_Q$ и $\mathbf{W}_Q$:

$$\begin{aligned} \|\mathbf{H}_f(\mathbf{W}_Q, \mathbf{W}_Q)\|_2 &= \frac{2}{L d_V d_K} \|\mathbf{R}_{d_V d_K} (\mathbf{I}_L \otimes \mathbf{W}_V^\top \otimes \mathbf{I}_{d_V} \otimes \mathbf{W}_K^\top) \mathbf{Z}_2 (\mathbf{I}_{d_V} \otimes \mathbf{W}_K)\|_2, \\ &\leq \frac{2}{L d_V d_K} \|\mathbf{R}_{d_V d_K}\|_2 \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2 \|\mathbf{Z}_2\|_2 \|\mathbf{W}_K\|_2 \\ &\leq 6 \frac{2}{L d_V d_K} \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \left(L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \right. \\ &\quad \left. + \|\mathbf{Target}\|_2 \right) \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^5 = \\ &= \frac{12}{d_V d_K} \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \left(L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \right. \\ &\quad \left. + \|\mathbf{Target}\|_2 \right) \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^5 \end{aligned}$$

Для нормы между матрицами $\mathbf{W}_V$ и $\mathbf{W}_Q$:

$$\begin{aligned}
\|\mathbf{H}_f(\mathbf{W}_V, \mathbf{W}_Q)\|_2 &= \frac{2}{Ld_V\sqrt{d_K}} \|\mathbf{R}_{d_V^2} (\mathbf{I}_L \otimes \mathbf{S}) \mathbf{Z}_1 (\mathbf{I}_{d_V} \otimes \mathbf{W}_K)\|_2 \leq \\
&\leq \frac{2}{Ld_V\sqrt{d_K}} \|\mathbf{R}_{d_V^2}\|_2 \|\mathbf{S}\|_2 \|\mathbf{Z}_1\|_2 \|\mathbf{W}_K\|_2 \leq \\
&\leq \frac{2}{Ld_V\sqrt{d_K}} \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \left(L\|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \right. \\
&\quad \left. + \|\mathbf{Target}\|_2 \right) \sqrt{d_V} \frac{1}{L} \|\mathbf{X}\|_2^3 \|\mathbf{W}_K\|_2 = \\
&= \frac{2\sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})}}{L^2\sqrt{d_V d_K}} \left(L\|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \right. \\
&\quad \left. + \|\mathbf{Target}\|_2 \right) \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^3
\end{aligned}$$

Для нормы между матрицами $\mathbf{W}_Q$ и $\mathbf{W}_K$:

$$\begin{aligned}
\|\mathbf{H}_f(\mathbf{W}_Q, \mathbf{W}_K)\| &\leq \\
&\leq \frac{2}{Ld_V d_K} \|\mathbf{R}_{d_V d_K} (\mathbf{I}_L \otimes \mathbf{W}_V^\top \otimes \mathbf{I}_{d_V} \otimes \mathbf{W}_K^\top) \mathbf{Z}_2 (\mathbf{W}_Q \otimes \mathbf{I}_{d_V}) \mathbf{K}_{d_K, d_V}\|_2 + \\
&\quad + \frac{2}{Ld_V\sqrt{d_K}} \|\mathbf{R}_{d_V} (\mathbf{I}_L \otimes \mathbf{W}_V^\top \otimes \mathbf{I}_{d_V}) (\mathbf{Z}_1 \otimes \mathbf{I}_{d_V}) \mathbf{S} \otimes \mathbf{I}_{d_K}\|_2 \leq \\
&\leq \frac{2}{Ld_V d_K} \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \left(L\|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \right. \\
&\quad \left. + \|\mathbf{Target}\|_2 \right) \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 6\|\mathbf{X}\|_2^5 + \\
&\quad + \frac{2}{Ld_V\sqrt{d_K}} \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \left(L\|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \right. \\
&\quad \left. + \|\mathbf{Target}\|_2 \right) \|\mathbf{W}_V\|_2 \frac{1}{L} \|\mathbf{X}\|_2^3 \sqrt{d_V} = \\
&= \frac{2\sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} (L\|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2)}{Ld_V\sqrt{d_V d_K}} \|\mathbf{W}_V\|_2 \cdot \\
&\quad \cdot \left(3L\|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{X}\|_2^5 + \frac{d_V}{L} \|\mathbf{X}\|_2^3 \right).
\end{aligned}$$

Собирая все оценки вместе, используя матричное свойство 4 для всех блоков $\{K, Q, V\}$:

$$\|\mathbf{H}(\mathbf{W}_i, \mathbf{W}_j)\|_2 \leq 3 \max_{i,j \in \{Q, K, V\}} \left(\|\mathbf{H}_o(\mathbf{W}_i, \mathbf{W}_j)\|_2 + \|\mathbf{H}_f(\mathbf{W}_i, \mathbf{W}_j)\|_2 \right)$$

Подставляя оценки получаем следующую оценку на матрицу Гессе:

$$\begin{aligned}
& \|\mathbf{H}(\mathbf{W}_i, \mathbf{W}_j)\|_2 \leq \\
& \leq 3 \max \left(\frac{2L}{d_V} \|\mathbf{X}\|_2^2, \right. \\
& \frac{2}{L^3 d_V d_K} \|\mathbf{W}_K\|_2^2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\
& + \frac{12}{d_V d_K} \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \left(L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \right. \\
& \left. + \|\mathbf{Target}\|_2 \right) \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2^2 \|\mathbf{X}\|_2^5, \\
& \frac{2}{L d_V \sqrt{d_K}} \|\mathbf{W}_V\|_2 \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^4 + \\
& + \frac{2 \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})}}{L^2 \sqrt{d_V d_K}} (L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2) \|\mathbf{W}_K\|_2 \|\mathbf{X}\|_2^3, \\
& \frac{2}{L^3 d_V d_K} \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{W}_V\|_2^2 \|\mathbf{X}\|_2^6 + \\
& + \frac{2 \sqrt{\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target})} \left(L \|\mathbf{X}\|_2 \|\mathbf{W}_V\|_2 + \|\mathbf{Target}\|_2 \right)}{L d_V \sqrt{d_V d_K}} \cdot \\
& \cdot \|\mathbf{W}_V\|_2 \left(3L \|\mathbf{W}_K\|_2 \|\mathbf{W}_Q\|_2 \|\mathbf{X}\|_2^5 + \frac{d_V}{L} \|\mathbf{X}\|_2^3 \right) \Bigg).
\end{aligned}$$

Полученное выражение почти полностью соответствует выражению M , где для полного соответствия требуется воспользоваться неравенством $\text{rank}(\mathbf{F}(\mathbf{X}) - \mathbf{Target}) \leq \min(L, d_V)$. $\square$

Теорема 18 устанавливает верхнюю оценку нормы матрицы Гессе для одного слоя самовнимания. Полученная оценка демонстрирует сложную зависимость от размерностей модели, норм весовых матриц и нормы входных данных $\|\mathbf{X}\|_2$. Особенностью оценки является наличие слагаемых, пропорциональных различным степеням $\|\mathbf{X}\|_2$, что отражает нелинейный характер преобразований в слое самовнимания.

Теорема 18 оценивает только один слой самовнимания. Переходим к оценке полного блока трансформера. Полный трансформерный слой содержит слой самовнимания, блок полносвязной сети (англ. FFN) и слои нормализации выходов

(англ. LayerNorm). Весь блок описывается следующими выражениями:

$$\begin{aligned}\mathbf{Y} &= \text{LayerNorm}(\mathbf{X} + \mathbf{F}(\mathbf{X})) \\ \mathbf{Z} &= \text{LayerNorm}(\mathbf{Y} + \text{FFN}(\mathbf{Y})),\end{aligned}\tag{3.9}$$

где

$$\text{FFN}(\mathbf{Y}) = \sigma(\mathbf{Y}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2,$$

с матрицами параметров $\mathbf{W}_1 \in \mathbb{R}^{d_V \times d_{\text{ff}}}$, $\mathbf{W}_2 \in \mathbb{R}^{d_{\text{ff}} \times d_V}$, векторами $\mathbf{b}_1 \in \mathbb{R}^{d_{\text{ff}}}$, $\mathbf{b}_2 \in \mathbb{R}^{d_V}$, а также функцией активации σ . Функция $\text{LayerNorm}(\mathbf{X})$ определяется для входной матрицы $\mathbf{X} \in \mathbb{R}^{L \times d_V}$ следующим образом:

$$\text{LayerNorm}(\mathbf{X})_{i,j} = \gamma_j \cdot \frac{\mathbf{X}_{i,j} - \mu_i}{\sqrt{\sigma_i^2}} + \beta_j,$$

где параметры μ_i, σ_i определяются следующим образом:

$$\mu_i = \frac{1}{d_V} \sum_{j=1}^{d_V} \mathbf{X}_{i,j}, \quad \sigma_i^2 = \frac{1}{d_V} \sum_{j=1}^{d_V} (\mathbf{X}_{i,j} - \mu_i)^2,$$

а параметры γ_j, β_j являются настраиваемым в процессе оптимизации.

Итого, получаем полный список параметров полного слоя трансформера:

$$\mathbf{w} = \{\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V, \mathbf{W}_1, \mathbf{W}_2, \mathbf{b}_1, \mathbf{b}_2, \gamma, \beta\}$$

, где γ, β являются параметрами LayerNorm. Для простоты вычисления в некоторых случаях введем предположение, что параметры γ, β являются постоянными и не меняются в процессе оптимизации.

3.3.2. Слой LayerNorm

Для начала вычислим для функции LayerNorm матрицу Якоби относительно параметров модели, для этого докажем теорему 19.

Теорема 19 (Производная LayerNorm). Пусть задана матрица $\mathbf{X} \in \mathbb{R}^{L \times d_V}$. Определим функцию $\mathbf{M}(\mathbf{X})$ следующим образом:

$$\begin{aligned}\mathbf{M}(\mathbf{X}) &= \mathbf{X} - \frac{1}{d_V} \mathbf{X} \mathbf{1}_{d_V} \mathbf{1}_{d_V}^\top, \\ \sigma(\mathbf{X}) &= \frac{1}{\sqrt{d_V}} (\mathbf{M}(\mathbf{X})^{\circ 2} \mathbf{1}_{d_V})^{\circ 1/2}, \\ \mathbf{P}(\mathbf{X}) &= \text{diag}^{-1}(\sigma(\mathbf{X})).\end{aligned}$$

Тогда для функции *LayerNorm* :

$$\text{LayerNorm}(\mathbf{X}) = \mathbf{P}(\mathbf{X}) \mathbf{M}(\mathbf{X}),$$

матрица Якоби относительно переменной $\mathbf{X}$ определяется следующим образом:

$$\begin{aligned}\frac{\partial \text{LayerNorm}(\mathbf{X})}{\partial \mathbf{X}} &= (\mathbf{P}(\mathbf{X}) \otimes \mathbf{I}_{d_V}) \left(\mathbf{I}_{L d_V} - \frac{1}{d_V} (\mathbf{I}_L \otimes \mathbf{1}_{d_V \times d_V}) \right) + \\ &\quad + (\mathbf{I}_L \otimes \mathbf{M}(\mathbf{X})^\top) \frac{\partial \mathbf{P}(\mathbf{X})}{\partial \mathbf{X}},\end{aligned}$$

где

$$\begin{aligned}\frac{\partial \mathbf{P}}{\partial \mathbf{X}} &= \frac{1}{\sqrt{d_V}} \left(-\mathbf{D}^{-1} \otimes \mathbf{D}^{-\top} \right) \cdot \\ &\quad \cdot (\mathbf{e}_1 \otimes \mathbf{e}_1, \dots, \mathbf{e}_L \otimes \mathbf{e}_L) \cdot \\ &\quad \cdot \left(\text{diag}^{-1}(\text{vec}_r^{1/2}(\mathbf{M}^{\circ 2} \mathbf{1}_{d_V})) (\mathbf{I}_L \otimes \mathbf{1}_{d_V}^\top) \text{diag}(\text{vec}_r(\mathbf{M})) \frac{\partial \mathbf{M}}{\partial \mathbf{X}} \right),\end{aligned}$$

где $\mathbf{D} = \text{diag}(\sigma(\mathbf{X}))$.

Доказательство теоремы приведено в работе [98].

Теперь вычислим для функции матрицу Гессе относительно параметров модели, для этого докажем теорему 20.

Теорема 20 (Вторая производная LayerNorm). Пусть задан оператор *LayerNorm* в виде, аналогичном теореме 19:

$$\text{LayerNorm}(\mathbf{X}) = \mathbf{P}(\mathbf{X}) \mathbf{M}(\mathbf{X}),$$

с матрицей Якоби, полученной в теореме 19:

$$\frac{\partial \text{LayerNorm}}{\partial \mathbf{X}} = (\mathbf{P} \otimes \mathbf{I}_{d_V})\mathbf{G} + (\mathbf{I}_L \otimes \mathbf{M}^\top)\mathbf{H},$$

где дополнительно введены обозначения константы:

$$\mathbf{G} = \left(\mathbf{I}_{Ld_V} - \frac{1}{d_V}(\mathbf{I}_L \otimes \mathbf{1}_{d_V \times d_V}) \right),$$

а также оператор, аналогичный оператору в теореме 19:

$$\mathbf{H} = \frac{\partial \mathbf{P}}{\partial \mathbf{X}}.$$

Тогда для функции LayerNorm матрица Гессе относительно параметров $\mathbf{X}$ имеет вид:

$$\begin{aligned} \frac{\partial^2 \text{LayerNorm}}{\partial \mathbf{X}^2} = & ((\mathbf{P}(\mathbf{X}) \otimes \mathbf{I}_{d_V}) \otimes \mathbf{I}_{Ld_V}) \frac{\partial^2 \mathbf{M}}{\partial \mathbf{X}^2} + \\ & + (\mathbf{I}_{Ld_V} \otimes \mathbf{G}^\top) \frac{\partial(\mathbf{P}(\mathbf{X}) \otimes \mathbf{I}_{d_V})}{\partial \mathbf{X}} + \\ & + ((\mathbf{I}_L \otimes \mathbf{M}^\top) \otimes \mathbf{I}_{Ld_V}) \frac{\partial^2 \mathbf{P}}{\partial \mathbf{X}^2} + (\mathbf{I}_{Ld_V} \otimes \mathbf{H}^\top) \frac{\partial(\mathbf{I}_L \otimes \mathbf{M}^\top)}{\partial \mathbf{X}}. \end{aligned}$$

Все матрицы в данном выражении явно вычислимы и задаются формулами, которые указаны ниже в доказательстве.

Доказательство теоремы приведено в работе [98].

3.3.3. Нелинейность ReLU

Теорема 21 (Производные ReLU). Пусть задана матрица $\mathbf{X} \in \mathbb{R}^{m \times n}$, тогда для оператора ReLU почти всюду верно следующее выражение:

$$\begin{aligned} \frac{\partial \text{ReLU}(\mathbf{X})}{\partial \mathbf{X}} &= \text{diag}(\text{vec}_r(\mathbf{1}_{\{\mathbf{X} > 0\}})), \\ \frac{\partial^2 \text{ReLU}(\mathbf{X})}{\partial \mathbf{X}^2} &= \mathbf{0}. \end{aligned}$$

Доказательство. Оператор ReLU принимает следующий вид:

$$\text{ReLU}(x) = \max(0, x),$$

то есть, для каждого элемента x_{ij} в матрице $\mathbf{X} \in \mathbb{R}^{m \times n}$ получаем:

$$\frac{\partial \text{ReLU}(x_{ij})}{\partial x_{ij}} = \begin{cases} 1 & \text{если } x_{ij} > 0, \\ 0 & \text{если } x_{ij} < 0, \\ \text{неопределенно (субградиент } \in [0, 1]) & \text{если } x_{ij} = 0. \end{cases}$$

В случае скалярной величины $x \in \mathbb{R}$, множеством с неопределенным градиентом является множество $\{0\}$, которое является множеством меры 0. Рассматривая же матрицу $\mathbf{X} \in \mathbb{R}^{m \times n}$ как точку в $\mathbb{R}^{m \times n}$, дифференцируемым множеством является множество:

$$\mathcal{N} = \bigcup_{i,j} \{\mathbf{X} \in \mathbb{R}^{m \times n} : x_{ij} = 0\}.$$

Каждое множество $\{x_{ij} = 0\}$ является гиперплоскостью коразмерности 1 в пространстве $\mathbb{R}^{m \times n}$, следовательно, является множеством меры 0. Так как, множество $\mathcal{N}$ является конечным объединением множеств меры 0, то и множество $\mathcal{N}$ также имеет меру 0. Получили, что оператор ReLU является почти всюду дифференцируем в пространстве $\mathbb{R}^{m \times n}$.

Для каждой дифференцируемой точки $\mathbf{X} \notin \mathcal{N}$, применим построчную векторизацию и Лемму 38:

$$\text{vec}_r(d\text{ReLU}(\mathbf{X})) = \text{diag}(\text{vec}_r(\mathbf{1}_{\{\mathbf{X} > 0\}}))\text{vec}_r(d\mathbf{X}),$$

Используя свойство 10 и лемму 42 для диагональной матрицы, получаем:

$$\frac{\partial \text{ReLU}(\mathbf{X})}{\partial \mathbf{X}} = \text{diag}(\text{vec}_r(\mathbf{1}_{\{\mathbf{X} > 0\}})).$$

В силу того, что матрица Якоби является кусочно-постоянной, то ее дифференциал равен нулю почти всюду:

$$d\left(\frac{\partial \text{ReLU}(\mathbf{X})}{\partial \mathbf{X}}\right) = \mathbf{0}, \quad \mathbf{X} \notin \mathcal{N},$$

а следовательно и матрица Гессе почти всюду равна нулевой матрице:

$$\frac{\partial^2 \text{ReLU}(\mathbf{X})}{\partial \mathbf{X}^2} = \mathbf{0}, \quad \mathbf{X} \notin \mathcal{N}.$$

□

3.3.4. Блок трансформера

Лемма 22 (Оценка нормы для слоя внимания). *Рассмотрим слой внимания следующего вида:*

$$\mathbf{F}(\mathbf{X}) = \mathbf{A}(\mathbf{T})\mathbf{X}\mathbf{W}_V, \quad \mathbf{T} = \frac{1}{\sqrt{d_K}}\mathbf{X}\mathbf{W}_Q\mathbf{W}_K^\top\mathbf{X}^\top,$$

где $\mathbf{X} \in \mathbb{R}^{L \times d_V}$, $\mathbf{W}_Q, \mathbf{W}_K \in \mathbb{R}^{d_V \times d_K}$, $\mathbf{W}_V \in \mathbb{R}^{d_V \times d_V}$. Матрица внимания $\mathbf{A}(\cdot)$ применяет построчный *softmax*. Используем построчную векторизацию $\text{vec}_r(\cdot)$ и матрицы перестановки $\mathbf{K}_{m,n}$ из определения 31.

Определим блоки обобщенного функционального гессиана, используя результаты [138] в наших обозначениях vec_r как

$$\mathbf{H}_f(\mathbf{W}_i, \mathbf{W}_j) = \left(\frac{\partial \ell}{\partial \mathbf{F}} \otimes \mathbf{I}_{p_i q_i} \right) \frac{\partial^2 \mathbf{F}}{\partial \mathbf{W}_i \partial \mathbf{W}_j},$$

где $p_i q_i$ — размер матрицы $\mathbf{W}_i$, а $\frac{\partial \ell}{\partial \mathbf{F}} \in \mathbb{R}^{L \times d_V}$ — градиент функции потерь.

Для квадратичной функции потерь $\ell(\mathbf{F}) = \frac{1}{2} \|\mathbf{F} - \mathbf{Target}\|_F^2$ имеем $\frac{\partial \ell}{\partial \mathbf{F}} = \mathbf{F} - \mathbf{Target}$ и матрицу построчного свертывания

$$\mathbf{R}_m := \text{vec}_r(\mathbf{F}(\mathbf{X}) - \mathbf{Target})^\top \otimes \mathbf{I}_m \in \mathbb{R}^{m \times (m \cdot L d_V)}.$$

Тогда для $i \in \{V, Q, K\}$ с $n_i := p_i q_i$ блоки функционального гессиана могут быть факторизованы как

$$\mathbf{H}_f(\mathbf{W}_i, \mathbf{W}_j) = \mathbf{R}_{n_i} \Phi_{ij}, \quad \Phi_{ij} := \frac{\partial^2 \mathbf{F}}{\partial \mathbf{W}_i \partial \mathbf{W}_j} \in \mathbb{R}^{(L d_V \cdot n_i) \times n_j}.$$

В частности, блоки кривизны модели Φ_{ij} получаются из соответствующих выражений в [138, Теорема. 3.2] удалением левого свертывания $\mathbf{R}_{n_i}$.

Теперь перечислим явные блоки, необходимые для вывода. Определим фиксированный оператор изменения формы

$$\mathbf{S} := (\mathbf{I}_{d_V} \otimes \mathbf{K}_{d_V, d_V}) (\text{vec}_r \mathbf{I}_{d_V} \otimes \mathbf{I}_{d_V}) \in \mathbb{R}^{d_V^2 \times d_V},$$

и операторы производных softmax

$$\mathbf{Z}_1 := (\mathbf{I}_L \otimes \mathbf{X}^\top)(\partial \mathbf{A} / \partial \mathbf{T})(\mathbf{X} \otimes \mathbf{X}) \in \mathbb{R}^{Ld_V \times d_V^2},$$

$$\mathbf{Z}_2 := (\mathbf{I}_L \otimes \mathbf{X}^\top \otimes \mathbf{X}^\top \otimes \mathbf{X}^\top) \frac{\partial^2 \mathbf{A}}{\partial \mathbf{T}^2}(\mathbf{X} \otimes \mathbf{X}) \in \mathbb{R}^{Ld_V^3 \times d_V^2},$$

где $\frac{\partial^2 \mathbf{A}}{\partial \mathbf{T}^2}$ обозначает тензор вторых производных softmax, согласованный с весами и произведениями Кронекера, как указано выше, а $\mathbf{Z}_1$ — линейный оператор первой производной softmax, используемый в [138].

Тогда вторые производные внимания имеют вид:

$$\begin{aligned}\Phi_{VV} &= \mathbf{0}_{(Ld_V \cdot d_V^2) \times d_V^2}, \\ \Phi_{QQ} &= \frac{2}{Ld_V d_K} (\mathbf{I}_L \otimes \mathbf{W}_V^\top \otimes \mathbf{I}_{d_V} \otimes \mathbf{W}_K^\top) \mathbf{Z}_2 (\mathbf{I}_{d_V} \otimes \mathbf{W}_K) \in \mathbb{R}^{(Ld_V \cdot d_V d_K) \times d_V d_K}, \\ \Phi_{VQ} &= \frac{2}{Ld_V \sqrt{d_K}} (\mathbf{I}_L \otimes \mathbf{S}) \mathbf{Z}_1 (\mathbf{I}_{d_V} \otimes \mathbf{W}_K) \in \mathbb{R}^{(Ld_V \cdot d_V^2) \times d_V d_K}, \\ \Phi_{QK} &= \frac{2}{Ld_V d_K} (\mathbf{I}_L \otimes \mathbf{W}_V^\top \otimes \mathbf{I}_{d_V} \otimes \mathbf{W}_K^\top) \mathbf{Z}_2 (\mathbf{W}_Q \otimes \mathbf{I}_{d_V}) \mathbf{K}_{d_K, d_V} \\ &\quad + \frac{2}{Ld_V \sqrt{d_K}} (\mathbf{I}_{d_V} \otimes \mathbf{W}_V^\top \otimes \mathbf{I}_{d_V}) (\mathbf{Z}_1 \otimes \mathbf{I}_{d_V}) \mathbf{S} \otimes \mathbf{I}_{d_K} \in \mathbb{R}^{(Ld_V \cdot d_V d_K) \times d_V d_K}.\end{aligned}$$

Более того, в силу симметрии вторых производных, Φ_{KQ} равен Φ_{QK} с переставленными $\mathbf{W}_Q, \mathbf{W}_K$ и корректировкой перестановки с помощью $\mathbf{K}, \dots$. Аналогичные симметричные соотношения дают Φ_{QV} и Φ_{KV} из Φ_{VQ} .

Доказательство леммы приведено в работе [98].

Лемма 23 (Оценка норм для FFN и LayerNorm). Пусть заданы матрицы $\mathbf{X} \in \mathbb{R}^{L \times d_V}$, $\mathbf{Y} = \text{LayerNorm}(\mathbf{F}(\mathbf{X}) + \mathbf{X}) \in \mathbb{R}^{L \times d_V}$ и задана сеть

$$\text{FFN}(\mathbf{Y}) = \sigma(\mathbf{Y} \mathbf{W}_1) \mathbf{W}_2, \quad \mathbf{W}_1 \in \mathbb{R}^{d_V \times d_{ff}}, \quad \mathbf{W}_2 \in \mathbb{R}^{d_{ff} \times d_V},$$

пусть также задана $\mathbf{S} = \mathbf{Y} + \text{FFN}(\mathbf{Y}) \in \mathbb{R}^{L \times d_V}$. Тогда выполняются следующие оценки спектральных норм:

$$\begin{aligned}\|\mathbf{Y}\|_2 &\leq \|\mathbf{Y}\|_F = \sqrt{Ld_V}, \\ \|\text{FFN}(\mathbf{Y})\|_2 &\leq \sqrt{\min(L, d_{ff})} \|\mathbf{Y}\|_2 \|\mathbf{W}_1\|_2 \|\mathbf{W}_2\|_2, \\ \|\mathbf{S}\|_2 &\leq \|\mathbf{Y}\|_2 + \|\text{FFN}(\mathbf{Y})\|_2 \leq \sqrt{Ld_V} \left(1 + \sqrt{\min(L, d_{ff})} \|\mathbf{W}_1\|_2 \|\mathbf{W}_2\|_2\right).\end{aligned}$$

Доказательство леммы приведено в работе [98].

Лемма 24 (Оценка норм производных LayerNorm). Пусть заданы матрицы $\mathbf{X} \in \mathbb{R}^{m \times n}$. Производная LayerNorm $\mathbf{J}_{\text{LN}}(\mathbf{X}) = \frac{\partial \text{LayerNorm}(\mathbf{X})}{\partial \mathbf{X}}$ вычисляется в соответствии с Теоремой 19, а ее гессиан $\mathbf{H}_{\text{LN}}(\mathbf{X}) = \frac{\partial^2 \text{LayerNorm}(\mathbf{X})}{\partial \mathbf{X}^2}$ вычисляется как в Теореме 20.

Тогда выполняются следующие оценки:

$$\begin{aligned} \|\mathbf{J}_{\text{LN}}(\mathbf{X})\|_2 &\leq \frac{1}{\sigma_{\min}} + \frac{\|\mathbf{X}\|_2^2}{\sqrt{n}\sigma_{\min}^3}, \\ \|\mathbf{H}_{\text{LN}}(\mathbf{X})\|_2 &\leq \frac{\|\mathbf{X}\|_2}{\sigma_{\min}^3} \left(1 + \sqrt{\frac{m}{n}}\right) + \frac{\|\mathbf{X}\|_2^2}{\sqrt{n}\sigma_{\min}^3} + \frac{3\|\mathbf{X}\|_2^3}{n\sigma_{\min}^5}, \end{aligned}$$

где $\sigma_{\min}$ обозначает $\min_i \|\mathbf{M}_i\|_2$, где $\mathbf{M}(\mathbf{X}) = \mathbf{X}(\mathbf{I}_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top)$

Доказательство леммы приведено в работе [98].

Теорема 25 (Матрица Якоби трансформера). Для модели глубокого обучения архитектуры трансформер 3.9 матрица Якоби $\frac{\partial \mathbf{Z}}{\partial \mathbf{W}_i}$ вычисляется в следующем виде:

$$\frac{\partial \mathbf{Z}}{\partial \mathbf{W}_i} = \frac{\partial \text{LayerNorm}(\text{FFN}(\mathbf{Y}) + \mathbf{Y})}{\partial (\text{FFN}(\mathbf{Y}) + \mathbf{Y})} \frac{\partial (\text{FFN}(\mathbf{Y}) + \mathbf{Y})}{\partial \mathbf{W}_i}, \quad i \in \{1, 2\},$$

где

$$\frac{\partial (\text{FFN}(\mathbf{Y}) + \mathbf{Y})}{\partial \mathbf{W}_i} = \begin{cases} (\mathbf{I}_L \otimes \mathbf{W}_2^\top) \text{diag}(\text{vec}_r(\mathbf{1}_{\{\mathbf{Y}\mathbf{W}_1 > \mathbf{0}\}})) (\mathbf{Y} \otimes \mathbf{I}_{d_{ff}}), & \text{при } i = 1 \\ \sigma(\mathbf{Y}\mathbf{W}_1) \otimes \mathbf{I}_{d_v}, & \text{при } i = 2 \end{cases},$$

причем $\frac{\partial \text{LayerNorm}(\text{FFN}(\mathbf{Y}) + \mathbf{Y})}{\partial (\text{FFN}(\mathbf{Y}) + \mathbf{Y})}$ вычисляется согласно Теореме 19.

$$\frac{\partial \mathbf{Z}}{\partial \mathbf{W}_i} = \frac{\partial \text{LayerNorm}(\text{FFN}(\mathbf{Y}) + \mathbf{Y})}{\partial (\text{FFN}(\mathbf{Y}) + \mathbf{Y})} \frac{\partial (\text{FFN}(\mathbf{Y}) + \mathbf{Y})}{\partial \mathbf{Y}} \frac{\partial \mathbf{Y}}{\partial \mathbf{W}_i}, \quad i \in \{K, Q, V\},$$

где

$$\frac{\partial (\text{FFN}(\mathbf{Y}) + \mathbf{Y})}{\partial \mathbf{Y}} = (\mathbf{I}_L \otimes \mathbf{W}_2^\top) \text{diag}(\text{vec}_r(\mathbf{1}_{\{\mathbf{Y}\mathbf{W}_1 > \mathbf{0}\}})) (\mathbf{I}_L \otimes \mathbf{W}_1^\top) + (\mathbf{I}_L \otimes \mathbf{I}_{d_v}),$$

Здесь и далее для ReLU формулы понимаются на дополнении к аффинному множеству нулей соответствующих пред активаций; это не меняет вид

спектральных мажорант при оценке норм матриц, используемых в главе. причем $\frac{\partial \mathbf{Y}}{\partial \mathbf{W}_i} = \frac{\partial \text{LayerNorm}(\mathbf{F}(\mathbf{X}) + \mathbf{X})}{\partial (\mathbf{F}(\mathbf{X}) + \mathbf{X})} \frac{\partial \mathbf{F}(\mathbf{X})}{\partial \mathbf{W}_i}$, где $\frac{\partial \mathbf{F}(\mathbf{X})}{\partial \mathbf{W}_i}$ вычисляется при помощи Леммы A.2 в работе [139], а матрица $\frac{\partial \text{LayerNorm}(\mathbf{F}(\mathbf{X}) + \mathbf{X})}{\partial (\mathbf{F}(\mathbf{X}) + \mathbf{X})}$ вычисляется согласно Теореме 19.

Доказательство теоремы приведено в работе [98].

В теореме 25 получен вид матрицы Якоби для полного блока трансформера. Переходим к вычислению матрицы Гессе, который формулируется в теореме 26.

Теорема 26 (Матрица Гессе трансформера). Пусть заданы матрицы параметров модели трансформера $\mathbf{X} \in \mathbb{R}^{L \times d_V}$, $\mathbf{Y} \in \mathbb{R}^{L \times d_V}$, $\mathbf{W}_1 \in \mathbb{R}^{d_V \times d_{ff}}$, $\mathbf{W}_2 \in \mathbb{R}^{d_{ff} \times d_V}$, $\mathbf{W}_Q, \mathbf{W}_K \in \mathbb{R}^{d_V \times d_K}$, $\mathbf{W}_V \in \mathbb{R}^{d_V \times d_V}$, где блок трансформатор описан в виде следующих матричнозначных функций:

$$\mathbf{S}(\mathbf{Y}, \mathbf{W}_1, \mathbf{W}_2) = \sigma(\mathbf{Y}\mathbf{W}_1)\mathbf{W}_2 + \mathbf{Y} \in \mathbb{R}^{L \times d_V}, \quad \mathbf{Z} = \text{LayerNorm}(\mathbf{S}) \in \mathbb{R}^{L \times d_V},$$

для которых в условиях теорем 19 и 20 вычислимые матрицы Якоби и Гессе вида:

$$\mathbf{J}_Z := \frac{\partial \text{LayerNorm}(\mathbf{S})}{\partial \mathbf{S}} \in \mathbb{R}^{L d_V \times L d_V}, \quad \mathbf{H}_Z := \frac{\partial^2 \text{LayerNorm}(\mathbf{S})}{\partial \mathbf{S}^2} \in \mathbb{R}^{(L d_V)^2 \times L d_V}.$$

Также в условиях теорем 19, 20 и 21 введем следующее:

$$\mathbf{D}_\sigma := \text{diag}(\text{vec}_r(\mathbf{1}_{\{\mathbf{Y}\mathbf{W}_1 > 0\}})) \in \mathbb{R}^{L d_{ff} \times L d_{ff}},$$

$$\mathbf{J}_{SY} := \frac{\partial \mathbf{S}}{\partial \mathbf{Y}} = (\mathbf{I}_L \otimes \mathbf{W}_2^\top) \mathbf{D}_\sigma (\mathbf{I}_L \otimes \mathbf{W}_1^\top) + (\mathbf{I}_L \otimes \mathbf{I}_{d_V}) \in \mathbb{R}^{L d_V \times L d_V},$$

где для матрицы $\mathbf{Y} = \text{LayerNorm}(\mathbf{F}(\mathbf{X}) + \mathbf{X})$ в условиях теорем 19, 20 определено:

$$\mathbf{J}_Y := \frac{\partial \text{LayerNorm}(\mathbf{F}(\mathbf{X}) + \mathbf{X})}{\partial (\mathbf{F}(\mathbf{X}) + \mathbf{X})} \in \mathbb{R}^{L d_V \times L d_V},$$

$$\mathbf{H}_Y := \frac{\partial^2 \text{LayerNorm}(\mathbf{F}(\mathbf{X}) + \mathbf{X})}{\partial (\mathbf{F}(\mathbf{X}) + \mathbf{X})^2} \in \mathbb{R}^{(L d_V)^2 \times L d_V},$$

где для удобства введем следующие обозначения: $n_1 = d_V d_{ff}$, $n_2 = d_{ff} d_V$, $n_Q = n_K = d_V d_K$, $n_V = d_V^2$. Пусть матрицы Якоби вычислимы в условиях теоре-

мы 25 в следующем виде:

$$\begin{aligned}
\mathbf{G}_V &:= \frac{\partial \mathbf{F}}{\partial \mathbf{W}_V} \in \mathbb{R}^{Ld_V \times n_V}, \\
\mathbf{G}_Q &:= \frac{\partial \mathbf{F}}{\partial \mathbf{W}_Q} \in \mathbb{R}^{Ld_V \times n_Q}, \\
\mathbf{G}_K &:= \frac{\partial \mathbf{F}}{\partial \mathbf{W}_K} \in \mathbb{R}^{Ld_V \times n_K}, \\
\mathbf{B}_1 &:= \frac{\partial \mathbf{S}}{\partial \mathbf{W}_1} = (\mathbf{I}_L \otimes \mathbf{W}_2^\top) \mathbf{D}_\sigma(\mathbf{Y} \otimes \mathbf{I}_{d_{ff}}) \in \mathbb{R}^{Ld_V \times n_1}, \\
\mathbf{B}_2 &:= \frac{\partial \mathbf{S}}{\partial \mathbf{W}_2} = \sigma(\mathbf{Y} \mathbf{W}_1) \otimes \mathbf{I}_{d_V} \in \mathbb{R}^{Ld_V \times n_2}, \\
\mathbf{B}_k &:= \frac{\partial \mathbf{S}}{\partial \mathbf{W}_k} = \mathbf{J}_{SY} \mathbf{J}_Y \mathbf{G}_k \in \mathbb{R}^{Ld_V \times n_k}, \quad k \in \{K, Q, V\}.
\end{aligned}$$

Тогда матрицы Гессе трансформера $\mathbf{Z}$ по параметрам модели $(\mathbf{W}_i, \mathbf{W}_j)$ задается в виде:

$$\mathbf{H}_{\text{tr}}^{(i,j)} := \frac{\partial^2 \mathbf{Z}}{\partial \mathbf{W}_i \partial \mathbf{W}_j} = (\mathbf{J}_Z \otimes \mathbf{I}_{n_i}) \boldsymbol{\xi}_{ij} + (\mathbf{I}_{Ld_V} \otimes \mathbf{B}_i^\top) \mathbf{H}_Z \mathbf{B}_j, \quad (3.10)$$

где размерность матрицы Гессе $\mathbf{H}_{\text{tr}}^{(i,j)} \in \mathbb{R}^{(Ld_V \cdot n_i) \times n_j}$, также введены дополнительные матрицы для удобства:

$$\boldsymbol{\xi}_{ij} := \frac{\partial}{\partial \mathbf{W}_j} \left(\frac{\partial \mathbf{S}}{\partial \mathbf{W}_i} \right) \in \mathbb{R}^{(Ld_V \cdot n_i) \times n_j}.$$

Матрицы $\boldsymbol{\xi}_{ij}$ вычисляются для всех пар (i, j) почти всюду.

Для пар FFN:

$$\boldsymbol{\xi}_{11} = \mathbf{0}_{(Ld_V \cdot n_1) \times n_1},$$

$$\boldsymbol{\xi}_{22} = \mathbf{0}_{(Ld_V \cdot n_2) \times n_2},$$

$$\boldsymbol{\xi}_{12} = (\mathbf{I}_L \otimes \mathbf{K}_{d_V, d_{ff}} \otimes \mathbf{I}_{d_V}) (\mathbf{I}_{Ld_{ff}} \otimes \text{vec}_r(\mathbf{I}_{d_V})) (\mathbf{D}_\sigma(\mathbf{Y} \otimes \mathbf{I}_{d_{ff}})),$$

$$\boldsymbol{\xi}_{21} = (\mathbf{I}_{Ld_V} \otimes ((\mathbf{Y} \otimes \mathbf{I}_{d_{ff}})^\top \mathbf{D}_\sigma^\top)) (\mathbf{I}_L \otimes \mathbf{K}_{d_V, L} \otimes \mathbf{I}_{d_{ff}}) (\text{vec}_r(\mathbf{I}_L) \otimes \mathbf{I}_{d_V d_{ff}}) \mathbf{K}_{d_{ff}, d_V},$$

где матрицы $\boldsymbol{\xi}_{12}, \boldsymbol{\xi}_{21}$ имеют размерности $(Ld_V \cdot n_1) \times n_2$ и $(Ld_V \cdot n_2) \times n_1$ соответственно.

Для пар FFN с параметрами слоев внимания для всех $k \in \{K, Q, V\}$:

$$\boldsymbol{\xi}_{1k} = ((\mathbf{I}_L \otimes \mathbf{W}_2^\top) \mathbf{D}_\sigma \otimes \mathbf{I}_{n_k}) (\mathbf{I}_L \otimes \mathbf{K}_{d_{ff}, d_V} \otimes \mathbf{I}_{d_{ff}}) (\mathbf{I}_{L d_V} \otimes \text{vec}_r(\mathbf{I}_{d_{ff}})) (\mathbf{J}_Y \mathbf{G}_k),$$

$$\boldsymbol{\xi}_{2k} = (\mathbf{I}_L \otimes \mathbf{K}_{d_V, d_{ff}} \otimes \mathbf{I}_{d_V}) (\mathbf{I}_{L d_{ff}} \otimes \text{vec}_r(\mathbf{I}_{d_V})) (\mathbf{D}_\sigma (\mathbf{I}_L \otimes \mathbf{W}_1^\top) \mathbf{J}_Y \mathbf{G}_k),$$

где размерности матрицы $\boldsymbol{\xi}_{1k} \in \mathbb{R}^{(L d_V \cdot n_1) \times n_k}$ и матрицы $\boldsymbol{\xi}_{2k} \in \mathbb{R}^{(L d_V \cdot n_2) \times n_k}$.

Для пар слоев внимания $k, \ell \in \{K, Q, V\}$:

$$\boldsymbol{\xi}_{k\ell} = (\mathbf{J}_{SY} \otimes \mathbf{I}_{n_k}) [(\mathbf{I}_{L d_V} \otimes \mathbf{G}_k^\top) (\mathbf{H}_Y \mathbf{G}_\ell) + (\mathbf{J}_Y \otimes \mathbf{I}_{n_k}) \boldsymbol{\Phi}_{k\ell}],$$

где $\boldsymbol{\Phi}_{k\ell} := \frac{\partial \mathbf{G}_k}{\partial \mathbf{W}_\ell} \in \mathbb{R}^{(L d_V \cdot n_k) \times n_\ell}$ является второй производной слоя внимания $\mathbf{F}$ по ее параметрам, которые вычислены в рамках Леммы 22. Все матрицы имеют следующие размерности $\boldsymbol{\xi}_{k\ell} \in \mathbb{R}^{(L d_V \cdot n_k) \times n_\ell}$.

Также матрица Гессе удовлетворяет следующим свойствам почти везде:

$$\mathbf{H}_{\text{tr}}^{(i,j)} = \mathbf{H}_{\text{tr}}^{(j,i)},$$

так как, во первых единственные нелинейности с потенциально ненулевым вторым дифференциалом является оператор *LayerNorm*, для которого получены матрицы $\mathbf{H}_Z, \mathbf{H}_Y$ в рамках Теоремы 20 и которые являются симметричными по построению и оператор *ReLU*, для которого матрица Гессе является нулевой согласно Теоремы 21, а во вторых все другие отображения являются линейными, а следовательно согласно Леммы 37 и свойства производной произведения Кронекера их частные производные являются коммутативными почти всюду.

Доказательство теоремы приведено в работе [98].

3.3.5. Спектральные оценки нормы Гессе трансформера

Теорема 27 (Оценка нормы матрицы Гессе трансформера). Пусть матрица Гессе $\mathbf{H}_{\text{tr}}^{(i,j)}$ описывает матрицу Гессе между (i, j) -м блоком трансформера

модели (3.10), где $i, j \in \{1, 2, K, Q, V\}$, $n_i = \dim(\mathbf{W}_i)$. Тогда для каждой пары (i, j) получаем оценку нормы:

$$\|\mathbf{H}_{\text{tr}}^{(i,j)}\|_2 \leq \|\mathbf{J}_Z\|_2 \|\boldsymbol{\xi}_{ij}\|_2 + \|\mathbf{B}_i\|_2 \|\mathbf{H}_Z\|_2 \|\mathbf{B}_j\|_2,$$

где $\boldsymbol{\xi}_{ij} = \frac{\partial}{\partial \mathbf{W}_j} \left(\frac{\partial \mathbf{S}}{\partial \mathbf{W}_i} \right)$, $\mathbf{B}_i = \frac{\partial \mathbf{S}}{\partial \mathbf{W}_i}$.

Пусть матрица $\mathbf{H}_{\text{tr}}$ является полной матрицей Гессе размера $m_b \times n_b$ состоящей из блоков матрицы $\mathbf{H}_{\text{tr}}^{(i,j)}$, где $m_b = n_b = 5$, $i \in \{1, 2, K, Q, V\}$, $j \in \{1, 2, K, Q, V\}$. Тогда

$$\|\mathbf{H}_{\text{tr}}\|_2 \leq \sqrt{m_b n_b} \max_{i,j} \left(\frac{2}{L d_V} \left\| \frac{\partial \mathbf{Z}}{\partial \mathbf{W}_i} \right\|_2 \left\| \frac{\partial \mathbf{Z}}{\partial \mathbf{W}_j} \right\|_2 + \|\mathbf{R}_m^{\text{tr}}\|_2 \|\mathbf{H}_{\text{tr}}^{(i,j)}\|_2 \right).$$

Доказательство теоремы приведено в работе [98].

3.4. Вычислительные эксперименты

Настоящий раздел посвящен эмпирической проверки теоретических оценок норм матриц Гессе для различных классов моделей глубокого обучения. Основной целью экспериментов является проверка соответствия теоретических предсказаний, полученных в предыдущих разделах, эмпирическим наблюдениям, а также качественный и количественный анализ структуры матриц Гессе для трансформерных архитектур.

Эксперимент проводится для архитектуры трансформера, для которой в разделе 3.3. получены оценки норм матриц Гессе по компонентам.

Эксперименты проводятся на архитектуре Vision Transformer (ViT) с параметрами, указанными в таблице 3.1. В экспериментах используется один блок трансформера, который обучается на наборе данных MNIST [126]. Выбор MNIST позволяет сосредоточиться на структуре гессиана, не усложняя постановку свойствами данных.

Вычисление матриц Гессе осуществляется с использованием пакета `curvlinops`, который обеспечивает эффективное вычисление линейного оператора гессиана без явного построения полной матрицы вторых производных.

Данный подход позволяет анализировать гессианы для моделей с большим количеством параметров, что было бы непрактично при прямом вычислении.

Экспериментальная процедура включает следующие этапы:

1. Инициализация модели с заданными гиперпараметрами.
2. Вычисление матрицы Гессе на одном батче из обучающего загрузчика данных (128 примеров).
3. Визуализация структуры гессиана для инициализированной модели.
4. Обучение модели в течение нескольких эпох до достижения точности на валидационном наборе данных более 50%.
5. Вычисление и визуализация матрицы Гессе для обученной модели.
6. Детальный анализ отдельных блоков гессиана, соответствующих различным компонентам трансформера.
7. Вычисление спектральных норм блоков параметров и соответствующих блоков матрицы Гессе.

Визуализация гессиана в логарифмическом масштабе (рис. 3.1) демонстрирует неоднородность в величинах элементов матрицы для инициализированной модели. Наблюдается блочная структура гессиана, соответствующая различным компонентам трансформера: механизму самовнимания, блоку полносвязной сети (FFN) и слоям нормализации (LayerNorm).

набор данных	размер патча	скрытая размерность	размер FFN	количество бл
MNIST	4	16	64	1
CIFAR-100	4	128	512	8

Таблица 3.1: Гиперпараметры архитектур Vision Transformer (ViT) для экспериментов по анализу матриц Гессе. Параметры включают размер патча, скрытую размерность, размер блока FFN и количество трансформерных блоков для наборов данных MNIST и CIFAR-100.



Рис. 3.1: Визуализация элементов матрицы Гессе для инициализированной модели трансформера (один блок, набор данных MNIST, батч из 128 примеров) в логарифмическом масштабе. Наблюдается неоднородность величин элементов, при этом блоки, соответствующие параметрам Values, демонстрируют наибольшие значения.



Рис. 3.2: Визуализация элементов матрицы Гессе для обученной модели трансформера (один блок, набор данных MNIST, точность на валидации $>50\%$) в логарифмическом масштабе. После обучения все блоки гессиана приобретают большие значения, при этом блок Values-Values демонстрирует максимальные величины, что подтверждает гетерогенность вклада различных параметров в кривизну функции потерь.

После обучения модели в течение нескольких эпох до достижения точности на валидационном наборе данных более 50% элементы матрицы Гессе снова ви-




Рис. 3.3: Спектральные нормы блоков параметров трансформера (слева) и спектральные нормы соответствующих блоков матрицы Гессе (справа), вычисленные на одном батче из 128 примеров набора данных MNIST. Наибольшие значения норм соответствуют блокам Keys и Values, что согласуется с теоретическими оценками теоремы 27.




Рис. 3.4: Визуализация элементов блока матрицы Гессе, соответствующего параметрам Queries трансформера (один блок, набор данных MNIST). Блок демонстрирует структурированное распределение элементов, отражающее взаимосвязи между параметрами механизма самовнимания.

зуализируются (рис. 3.2). Наблюдается существенное изменение структуры гессиана: каждый из блоков приобретает большую величину по сравнению с инициализированной моделью, что отражает накопление кривизны функции потерь в процессе обучения. Блок Values-Values демонстрирует наибольшие значения среди всех блоков гессиана, что согласуется с теоретическими предсказаниями теоремы 27.

Для детального анализа структуры гессиана рассматриваются от-




Рис. 3.5: Визуализация элементов блока матрицы Гессе, соответствующего параметрам Keys трансформера (один блок, набор данных MNIST). Блок демонстрирует значительные значения элементов, что подтверждает важную роль параметров Keys в формировании кривизны функции потерь.




Рис. 3.6: Визуализация элементов блока матрицы Гессе, соответствующего параметрам Values трансформера (один блок, набор данных MNIST). Блок демонстрирует наибольшие значения элементов среди всех блоков гессиана, что согласуется с теоретическими оценками и подтверждает доминирующий вклад параметров Values в общую кривизну функции потерь.




Рис. 3.7: Визуализация элементов блока матрицы Гессе, соответствующего параметрам LayerNorm трансформера (один блок, набор данных MNIST). Блок демонстрирует структурированное распределение элементов, отражающее влияние нормализации слоев на локальную геометрию функции потерь.

дельные блоки, соответствующие различным компонентам трансформера (рис. 3.4, 3.5, 3.6, 3.7, 3.8).




Рис. 3.8: Визуализация элементов блока матрицы Гессе, соответствующего параметрам блока FFN (Feed-Forward Network) трансформера (один блок, набор данных MNIST). Блок демонстрирует умеренные значения элементов по сравнению с блоками Keys и Values, что отражает специфику вклада полносвязных слоев в кривизну функции потерь.

Блок, соответствующий параметрам Queries (рис. 3.4), демонстрирует структурированное распределение элементов, отражающее взаимосвязи между параметрами механизма самовнимания. Блок Keys (рис. 3.5) показывает значительные значения элементов, подтверждая важную роль параметров Keys в формировании кривизны функции потерь.

Наиболее выраженные значения наблюдаются в блоке Values (рис. 3.6), что согласуется с теоретическими оценками и подтверждает доминирующий вклад параметров Values в общую кривизну функции потерь. Данное наблюдение согласуется с результатами теоремы 18, где оценки для блока Values содержат наибольшие слагаемые.

Блок LayerNorm (рис. 3.7) демонстрирует структурированное распределение элементов, отражающее влияние нормализации слоев на локальную геометрию функции потерь. Блок FFN (рис. 3.8) показывает умеренные значения элементов по сравнению с блоками Keys и Values, что отражает специфику вклада полносвязных слоев в кривизну функции потерь.

Для количественной оценки вклада различных компонентов трансформера в кривизну функции потерь вычисляются спектральные нормы блоков параметров и соответствующих блоков матрицы Гессе (рис. 3.3).

Результаты демонстрируют четкую иерархию вклада различных блоков:

наибольшие значения спектральных норм соответствуют блокам Keys и Values, в то время как остальные блоки (Queries, FFN, LayerNorm) демонстрируют значительно меньшие абсолютные значения элементов. Данное наблюдение качественно согласуется с теоретическими оценками, полученными в теореме 27, где оценки для блоков Keys и Values содержат наибольшие слагаемые, пропорциональные высоким степеням норм весовых матриц и входных данных.

Гетерогенность вклада различных блоков параметров в общую кривизну функции потерь, установленная теоретически, подтверждается эмпирически. При анализе методов регуляризации и оптимизации трансформеров различия между компонентами архитектуры следует учитывать явно.

Отметим ограничения проведенных экспериментов. Во-первых, использована сравнительно простая задача (MNIST) и небольшая модель (один блок трансформера), что не исчерпывает режимы более сложных данных и крупных моделей. Во-вторых, вычисления выполняются на одном батче, и поведение гесса на всей выборке может отличаться. В-третьих, количественное сравнение с теоретическими мажорантами ограничено отсутствием точных численных констант в оценках.

Качественное согласие теории и эксперимента подтверждает полученные оценки. Гетерогенность вкладов блоков параметров показывает, что при анализе оптимизации и регуляризации трансформеров необходимо учитывать различия между компонентами архитектуры.

3.5. Заключение

В настоящей главе построены спектральные оценки матриц Гессе для основных классов параметрических моделей глубокого обучения. Эти оценки дают вычислимую основу для ландшафтной меры сложности, введенной в главе 2.1..

Центральным элементом изложения является унифицированный анализ матриц Гессе на основе матричной факторизации. Теорема 11 устанавливает,

что матрица Гессе для широкого класса матричных моделей может быть представлена в факторизованной форме $\mathbf{H}_O(\boldsymbol{\theta}) = \mathbf{Q}^T \mathbf{F}^T \mathbf{A} \mathbf{F} \mathbf{Q}$, что позволяет эффективно анализировать и вычислять гессиан без необходимости явного построения полной матрицы вторых производных. Этот подход охватывает несколько архитектур и служит основой спектральных оценок теоремы 12.

Для полносвязных нейронных сетей установлены точные верхние оценки спектральной нормы матрицы Гессе. Теорема 9 демонстрирует, что норма гессиана ограничена выражением $\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \leq L\sqrt{2}M_{\mathbf{x}}^2M_{\mathbf{w}}^{2L} + \sqrt{2}\frac{M_{\mathbf{w}}^2(M_{\mathbf{w}}^{2L}-1)}{M_{\mathbf{w}}^2-1}$, что устанавливает экспоненциальную зависимость от глубины сети L и полиномиальную зависимость от ширины слоев. Теорема 10 уточняет данную оценку, показывая асимптотическую пропорциональность $\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \propto L(hM)^{2L}$, где h — размер скрытого слоя, а M — константа, ограничивающая параметры.

Для сверточных нейронных сетей получены явные оценки нормы гессиана через структурные параметры архитектуры. Теорема 13 устанавливает оценку для одномерных сверточных сетей: $\|\mathbf{H}_O\| \leq \sqrt{2}\|\mathbf{x}\|^2d^2(L+1)(C^2w^2kd)^L$, демонстрируя мультипликативную зависимость от глубины и полиномиально-экспоненциальную зависимость от числа каналов C , размера ядра k и длины последовательности d . Теорема 14 определяет аналогичную оценку для двумерных сверточных сетей: $\|\mathbf{H}_O\| \leq \sqrt{2}\|\mathbf{x}\|^2q^2(L+1)(C^2k^2w^2mn)^L$, где зависимость от пространственных размеров $m \times n$ является квадратичной. Теоремы 15 и 16 описывают влияние операций пулинга на норму гессиана: введение пулинга уменьшает соответствующую мажоранту.

Для трансформерных архитектур получены оценки нормы гессиана по компонентам, включая механизм самовнимания (теорема 18). Численные результаты (рис. 3.3) согласуются с этими оценками: наибольшие значения норм наблюдаются у блоков Keys и Values.

Полученные спектральные оценки связывают свойства матриц Гессе с ландшафтной мерой сложности из главы 2.1. и заменяют прямое вычисление плотного гессиана для крупных моделей вычислимыми мажорантами. Они приме-

нимы для сравнения архитектур и анализа зависимости кривизны от глубины, ширины и иных структурных параметров.

Ограничения связаны с детерминистическим характером оценок, предположениями об ограниченности параметров и данных, а также возможностью ужесточения мажорант за счет разреженности и стохастических эффектов обучения. Естественным продолжением является учет стохастичности и полного спектра, а также перенос аппарата на рекуррентные и графовые архитектуры.

Глава 4

Достаточный объем выборки

В главе 2 был разработан единый теоретический аппарат для формализации соотношения между сложностью модели и сложностью данных. Ключевым результатом этой главы является введение формальных определений меры сложности выборки $\mu_D(D)$ и меры сложности модели $\mu_f(f)$, а также установление критерия обучаемости модели на выборке: $\mu_f(f) \leq \mu_D(D)$.

В разделе 2.2. главы 2 было показано, что частным случаем условной меры сложности данных $\mu_D(D|f)$ является достаточный размер выборки m^* — минимальный объем данных из выборки D , необходимый для обучения модели f . Для простой генеральной совокупности Γ_C , состоящей из объектов одинаковой сложности C , мера сложности выборки принимает вид $\mu_D(D) = C \cdot |D|$, что устанавливает прямую связь между размером выборки и ее сложностью. Как отмечено в замечании 3, именно этот равновесный учёт данных (обычно при $C = 1$) соответствует постановкам, в которых достаточный объем оценивается только по числу объектов.

В разделе 2.3. главы 2 была введена ландшафтная мера сложности модели $\mu_f(f|D)$, определяемая через спектральные свойства матриц Гессе функции потерь. Установлено, что анализ сходимости ландшафта оптимизационной задачи при увеличении объема выборки сводится к анализу спектральной нормы матрицы Гессе, что позволяет количественно оценить влияние добавления новых объектов данных на локальную геометрию функции потерь в окрестности оптимума.

В главе 3 были получены конкретные оценки спектральных норм матриц Гессе для различных архитектур нейронных сетей. Теорема 9 устанавливает оценку для полносвязных сетей: $\|\mathbf{H}_i(\boldsymbol{\theta})\|_2 \propto L(hM)^{2L}$, теоремы 13 и 14 — для сверточных сетей, а теорема 27 — для трансформерных моделей. Эти оценки дают вычислимую основу ландшафтной меры сложности модели $\mu_f(f|D)$ в

формализме главы 2.

Однако теоретические результаты предыдущих глав не задают явной процедуры вычисления численного значения m^* по конечной выборке; к тому же для глубоких моделей прямая оценка ландшафтной меры через матрицы Гессе остается вычислительно дорогой.

В настоящей главе рассматриваются методы определения достаточного размера выборки — от обобщенных линейных моделей до постановок, пригодных для более сложных параметрических моделей. Методы опираются на наблюдаемые характеристики обучения (статистики критериев, стабильность правдоподобия, близость апостериоров) и используются для оценки необходимого объема данных при планировании эксперимента.

Выбор конкретного метода зависит от постановки задачи: от формулировки гипотезы и статистики критерия в классических схемах до критериев стабилизации при росте объема выборки.

Статистические методы предполагают, что выборка соответствует некоторым предварительным условиям, сформулированным ранее. Эти условия сформулированы как статистический критерий [24, 25, 26, 16]. Метод оценки размера выборки, связанный с этим критерием, гарантирует достижение фиксированной статистической мощности $1 - \beta$ со степенью ошибки первого рода, не превышающей установленное значение α . Такой размер выборки называется достаточным.

Однако практическое применение методов оценки размера выборки предполагает, что модель соответствует измеренным данным [19]. Эти модели выбираются в соответствии с постановкой задачи регрессии или классификации. В настоящей главе рассматриваются обобщенные линейные модели.

В работе [25] предложен подход к оценке мощности и размера выборки на основе теста отношения максимального правдоподобия. Этот подход оказался более точным для ряда независимых переменных. В работе [27] предложен метод оценки мощности для статистики Вальда. В работе [21] в случае логи-

стической регрессии предлагается использовать метод, использующий кривую ROC-AUC и концепцию сдвига.

Классические методы [24, 25, 26, 27, 16] имеют ряд ограничений, связанных с практическим применением. Чтобы оценить размер выборки, необходимо знать дисперсию оценки параметра или, в более общем случае, иметь оценку параметра нецентральности в распределении статистики, используемой при альтернативной гипотезе. Указанные методы не предоставляют алгоритмических процедур для получения этих значений. Кроме того, дисперсия оценки и параметр нецентральности оцениваются с неопределенностью, влияние которой на результат оценки размера выборки не учитывается.

Статистические методы позволяют оценить размер выборки на основе предположений о распределении данных и информации о соответствии между наблюдаемыми значениями и предположениями нулевой гипотезы.

Когда размер исследуемой выборки является достаточным или чрезмерным, возможно применение методов, основанных на наблюдении изменения определенной характеристики процедуры построения модели при увеличении размера выборки. В частности, наблюдая за соотношением качества прогнозирования с контрольной выборкой и обучающей выборкой [21], определяется достаточный размер выборки, который соответствует началу переобучения.

В работе [22] для оценки достаточного размера выборки используется процедура бутстрапа. Превышение текущего размера выборки проверяется на основе анализа доверительных интервалов оцениваемого параметра. Ширина доверительного интервала с разными значениями объема выборки оценивается с помощью метода бутстрапа. Для этого выборки меньшего размера отбираются заданное число раз и вычисляется доверительный интервал ошибки при оценке параметра модели. Размер выборки считается достаточным, если ширина доверительного интервала не превышает заранее установленного значения.

Перечисленные выше ограничения статистических методов оценки размера выборки подробно исследуются в байесовской процедуре [20, 23, 28]. В рамках

данного подхода оценка размера выборки определяется на основе максимизации ожидаемого значения некоторой функции качества [20]. Функция качества может включать в себя явные функции распределения параметров и штрафы за увеличение размера выборки.

Альтернативой подходам [28], основанным на функции качества, является выбор размера выборки путем установления ограничений на определенный критерий качества оценки параметров модели. Примеры критериев: критерий средней апостериорной дисперсии (AVPC), критерий средней длины (ALC), критерий среднего покрытия (ACC). Для каждого перечисленного критерия оценка размера выборки определяется как минимальное значение размера выборки, для которого ожидаемое значение выбранного критерия не превышает какого-либо фиксированного порога.

В работе [21] предлагается считать размер выборки достаточным, если расстояние Кульбака-Лейблера между распределениями, оцененными на основе подвыборок такого размера, достаточно мало. Такой подход не требует дальнейшего обобщения в случае нескольких переменных. Кроме того, оценка может производиться как при наличии предположений о распределении данных, так и при их отсутствии. Недостаток этого подхода заключается в том, что количественная оценка может быть получена только при чрезмерно большом размере выборки.

4.1. Статистические критерии мощности для обобщенных линейных моделей

В настоящем разделе рассматриваются статистические методы определения достаточного размера выборки для обобщенных линейных моделей. Основой данных методов является использование информационной матрицы Фишера и статистических критериев для проверки гипотез о параметрах модели.

Рассмотрим выборку размера m :

$$\mathfrak{D}_m = \{\mathbf{x}_i, y_i\}_{i=1}^m,$$

где $\mathbf{x}_i \in \mathbb{R}^n$ — вектор признаков, $y_i \in \mathbb{Y}$ — целевая переменная. Вектор признаков $\mathbf{x} = [\mathbf{u}, \mathbf{v}]$ объединяет $\mathbf{u}_i \in \mathbb{R}^k$ и $\mathbf{v}_i \in \mathbb{R}^{n-k}$. Выборка $\mathfrak{D}_m$ случайным образом разделяется на обучающую и тестовую части:

$$\mathfrak{D}_{\mathcal{T}_m} = \{\mathbf{x}_i, y_i\}_{i \in \mathcal{T}_m}, \quad \mathfrak{D}_{\mathcal{L}_m} = \{\mathbf{x}_i, y_i\}_{i \in \mathcal{L}_m}, \quad \mathcal{T}_m \sqcup \mathcal{L}_m = \{1, \dots, m\}.$$

Определим параметрическое семейство функций для аппроксимации неизвестного распределения $p(y|\mathbf{x}, \mathfrak{D}_{\mathcal{L}_m})$:

$$\mathfrak{F} = \left\{ f(y, \mathbf{x}, \mathbf{w}) \mid \mathbf{w} \in \mathbb{W}, \int_{y \in \mathbb{Y}, \mathbf{x} \in \mathbb{R}^n} f(y, \mathbf{x}, \mathbf{w}) dy d\mathbf{x} = 1 \right\}.$$

Для модели f с вектором параметров $\mathbf{w}$ определим функцию правдоподобия и логарифм функции правдоподобия выборки $\mathfrak{D}$:

$$L(\mathfrak{D}, \mathbf{w}) = \prod f(y, \mathbf{x}, \mathbf{w}), \quad l(\mathfrak{D}, \mathbf{w}) = \sum \log f(y, \mathbf{x}, \mathbf{w}),$$

где $f(y, \mathbf{x}, \mathbf{w})$ является оценкой плотности вероятности для объекта $(y, \mathbf{x})$ при заданном векторе параметров $\mathbf{w}$.

Используя принцип максимального правдоподобия для оценки параметров $\mathbf{w}$:

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w} \in \mathbb{W}} L(\mathfrak{D}_{\mathcal{L}}, \mathbf{w}).$$

Информационная матрица Фишера (англ. Fisher Information Matrix) имеет вид:

$$\mathbf{I}(\mathfrak{D}, \mathbf{w}) = -\nabla \nabla^T l(\mathfrak{D}, \mathbf{w}), \quad \mathbf{V} = \mathbf{I}^{-1}(\mathfrak{D}, \mathbf{m}), \quad (4.1)$$

где $\mathbf{V}$ — ковариационная матрица оценок параметров. Статистические методы и байесовские методы используют информационную матрицу Фишера для оценки размера выборки.

Основным преимуществом методов, основанных на статистике, является их способность оценивать достаточный размер выборки при недостаточном наборе

данных. Они позволяют прогнозировать необходимое число объектов на ранней стадии эксперимента.

Рассмотрим обобщенную линейную модель, в которой плотность распределения целевой переменной задается выражением

$$p(y|\mathbf{u}, \mathbf{v}, \mathbf{w}_u, \mathbf{w}_v) = \exp(y\theta - b(\theta) + c(y)),$$

где θ является каноническим параметром распределения, получаемым с помощью функции связи $\theta = \theta(\mathbf{u}, \mathbf{v}, \mathbf{w}_u, \mathbf{w}_v)$, а функции $b(\theta)$ и $c(y)$ определяют конкретный тип распределения.

Тестируемая гипотеза

$$H_0 : \mathbf{m}_u = \mathbf{m}_u^0, \quad H_1 : \mathbf{m}_u \neq \mathbf{m}_u^0.$$

Пусть статистики $S_{m,u}(\mathbf{w}_u, \mathbf{w}_v)$ и $S_{m,v}(\mathbf{w}_u, \mathbf{w}_v)$ представляют собой производные логарифма правдоподобия выборки $\mathfrak{D}_m$ по параметрам $\mathbf{w}_u$ и $\mathbf{w}_v$ соответственно. Рассмотрим $\mathbf{s}_m = S_{m,u}(\mathbf{m}_u^0, \hat{\mathbf{w}}_v^0)$, где $\hat{\mathbf{w}}_v^0$ получается из уравнения

$$S_{m,v}(\mathbf{m}_u^0, \mathbf{w}_v) = 0.$$

Статистика множителей Лагранжа (англ. Lagrange Multiplier) определяется как

$$LM = \mathbf{s}_m^\top \mathbf{Q}_m^{-1} \mathbf{s}_m,$$

где $\mathbf{Q}_m$ — ковариационная матрица вектора $\mathbf{s}_m$.

В случае истинности гипотезы H_0 статистика LM асимптотически имеет центральное распределение $\chi^2(k)$. В [24] показано, что при альтернативной гипотезе H_1 статистика LM асимптотически имеет нецентральное распределение $\chi^2(k, \gamma)$, где γ является параметром нецентральности

$$\gamma = \boldsymbol{\xi}_m^\top \boldsymbol{\Sigma}_m^{-1} \boldsymbol{\xi}_m = m \boldsymbol{\xi}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\xi} = m \gamma^0, \quad (4.2)$$

где $\boldsymbol{\xi}_m$ и $\boldsymbol{\Sigma}_m$ — соответственно вектор математического ожидания и матрица ковариации $\mathbf{s}_m$. Обозначим $\boldsymbol{\xi}_1 = \boldsymbol{\xi}$, $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}$.

Альтернативный метод получения γ включает условия на уровне значимости α и вероятность ошибки II рода β :

$$\gamma^* : \chi_{k,1-\alpha}^2 = \chi_{k,\beta}^2(\gamma). \quad (4.3)$$

Используя соотношения (4.2) и (4.3), получаем

$$m^* = \frac{\gamma^*}{\gamma^0}.$$

Полученное значение m^* представляет собой достаточный минимальный размер выборки, необходимый для различения вектора $\mathbf{m}_u$ от $\mathbf{m}_u^0$ с заданными уровнями значимости α и мощности $1 - \beta$.

Рассмотрим случай, когда правдоподобие выборки задается выражением

$$p(y|\mathbf{u}, \mathbf{v}, \mathbf{w}_u, \mathbf{w}_v) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right), \quad (4.4)$$

где θ является параметром распределения, который вычисляется с помощью функции связи $\theta = \theta(\mathbf{u}, \mathbf{v}, \mathbf{w}_u, \mathbf{w}_v)$.

Тестируемая гипотеза

$$H_0 : \mathbf{m}_u = \mathbf{m}_u^0, \quad H_1 : \mathbf{m}_u \neq \mathbf{m}_u^0.$$

Определим логарифм статистики отношения правдоподобий:

$$LR = 2 \left(l(\mathcal{D}, \hat{\mathbf{w}}) - l(\mathcal{D}, \hat{\mathbf{w}}^0) \right),$$

где $\hat{\mathbf{w}} = [\hat{\mathbf{w}}_u, \hat{\mathbf{w}}_v]$ — вектор параметров, максимизирующий правдоподобие (4.4), а $\hat{\mathbf{w}}^0 = [\mathbf{m}_u^0, \hat{\mathbf{w}}_v^0]$ — вектор параметров, максимизирующий правдоподобие (4.4) при фиксированном подвекторе параметров $\mathbf{m}_u^0$.

В случае истинности гипотезы H_0 статистика LR асимптотически имеет центральное распределение $\chi^2(k)$. В [26] показано, что при альтернативной гипотезе H_1 статистика LR асимптотически имеет нецентральное распределение $\chi^2(k, \gamma)$, где γ является параметром нецентральности

$$\gamma = m\Delta^*, \quad \Delta^* = \mathbf{E} \left[2a^{-1}(\phi) \{(\theta - \theta^*) \nabla b(\theta) - b(\theta) + b(\theta^*)\} \right],$$

где параметры θ и θ^* рассчитываются с использованием параметров $\mathbf{w} = [\mathbf{w}_u, \mathbf{w}_v]$ и $\mathbf{w}^* = [\mathbf{w}_u^0, \mathbf{w}_v^*]$. Параметры $\mathbf{w}_v^*$ вычисляются на основе решения уравнения

$$\lim_{m \rightarrow \infty} m^{-1} \mathbb{E} \left(\frac{\partial l(\mathcal{D}, [\mathbf{m}_u^0, \mathbf{w}_v])}{\partial \mathbf{w}_v} \right) = 0.$$

Тогда с учетом α и β достаточный размер выборки m^* вычисляется

$$m^* = \frac{\gamma^*}{\Delta^*}, \quad \gamma^* : \chi_{k,1-\alpha}^2 = \chi_{k,\beta}^2(\gamma),$$

где $\chi_{k,1-\alpha}^2$ и $\chi_{k,\beta}^2(\gamma^*)$ — квантили распределений χ_k^2 и $\chi_k^2(\gamma^*)$ соответственно.

Правдоподобие выборки:

$$p(y|\mathbf{u}, \mathbf{v}, \mathbf{w}_u, \mathbf{w}_v) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right), \quad (4.5)$$

где θ является параметром распределения, который вычисляется с помощью функции связи $\theta = \theta(\mathbf{u}, \mathbf{v}, \mathbf{w}_u, \mathbf{w}_v)$.

Тестируемая гипотеза:

$$H_0 : \mathbf{m}_u = \mathbf{m}_u^0, \quad H_1 : \mathbf{m}_u \neq \mathbf{m}_u^0.$$

Тест Вальда для гипотезы:

$$W = (\hat{\mathbf{w}}_u - \mathbf{m}_u^0)^\top \hat{\mathbf{V}}_u^{-1} (\hat{\mathbf{w}}_u - \mathbf{m}_u^0),$$

где $\hat{\mathbf{w}} = [\hat{\mathbf{w}}_u, \hat{\mathbf{w}}_v]$ вектор параметров, который максимизирует правдоподобие выборки (4.5), где матрица $\hat{\mathbf{V}}_u$ задается в выражении (4.1).

В случае истинности гипотезы H_0 статистика Вальда W асимптотически имеет центральное распределение $\chi^2(k)$. В [27] показано, что в случае истинности альтернативной гипотезы H_1 статистика Вальда W асимптотически имеет нецентральное распределение $\chi^2(k, \gamma)$ с параметром нецентральности γ :

$$\gamma = m\delta, \quad \delta = (\hat{\mathbf{w}}_u - \mathbf{m}_u^0)^\top \Sigma_u^{-1} (\hat{\mathbf{w}}_u - \mathbf{m}_u^0), \quad \Sigma_u = m\hat{\mathbf{V}}_u.$$

Используя заданный уровень значимости α и заданную ошибку второго рода β , определим оптимальный размер выборки:

$$m^* = \frac{\gamma^*}{\delta}, \quad \gamma^* : \chi_{k,1-\alpha^*}^2 = \chi_{k,\beta}^2(\gamma),$$

где $\chi_{k,1-\alpha^*}^2$ и $\chi_{k,\beta}^2(\gamma^*)$ — квантили соответствующих распределений, а параметр α^* представляет собой поправку на уровень значимости:

$$\alpha^* = P(\boldsymbol{\xi}^T \boldsymbol{\Sigma}^{*-1} \boldsymbol{\xi} > \chi_{k,1-\alpha}^2), \quad \boldsymbol{\Sigma}^* = \mathbf{I}^{-1}(\mathfrak{D}, \mathbf{w}^*),$$

где $\mathbf{w}^* = [\mathbf{m}_u^0, \mathbf{w}_v^*]$ представляет собой решение уравнения

$$\lim_{m \rightarrow \infty} m^{-1} \mathbb{E} \left(\frac{\partial l(\mathfrak{D}, [\mathbf{m}_u^0, \mathbf{w}_v])}{\partial \mathbf{w}_v} \right) = 0.$$

Статистические методы, рассмотренные выше, требуют знания дисперсии оценки параметра или параметра нецентральности, что ограничивает их практическое применение. В следующем разделе рассматриваются эвристические методы, которые не требуют таких предположений и могут применяться в более широком классе задач.

4.2. Эвристические критерии по динамике качества

В настоящем разделе рассматриваются эвристические методы определения достаточного размера выборки, основанные на популярных статистических эвристиках, таких как бутстрап, перекрестная проверка и задание функции полезности. В отличие от статистических методов, эвристические подходы не требуют строгих предположений о распределении данных и могут применяться в ситуациях, когда теоретические гарантии недоступны.

Определим набор индексов $\mathcal{A}$ для параметров логистической регрессии $\mathbf{w}$. Тестируется гипотеза

$$H_0 : j \notin \mathcal{A} (w_j = 0), \quad H_1 : j \in \mathcal{A}^* (w_j \neq 0),$$

где w_j является j -м элементом вектора $\mathbf{w}$. Установим параметр отступа c_0 для задачи логистической регрессии:

$$H_0 : 1 - c_0 = p_0, \quad H_1 : 1 - c_0 = p_1,$$

где c_0 оптимальное решение, когда исключен j -й элемент вектора. Используя статистику

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)}}\sqrt{m}, \quad \hat{p} = \frac{1}{m} \sum_{i=1}^m y_i.$$

В случае истинности нулевой гипотезы H_0 статистика Z асимптотически имеет распределение $\mathcal{N}(0, 1)$. В случае истинности альтернативной гипотезы H_1 статистика Z асимптотически имеет распределение $\mathcal{N}\left(p_1 - p_0, \sqrt{\frac{p_1(1-p_1)}{p_0(1-p_0)}}\right)$.

Достаточный объем выборки задается выражением

$$m^* = \frac{p_0(1-p_0) \left(Z_{1-\alpha/2} + Z_{1-\beta} \sqrt{\frac{p_1(1-p_1)}{p_0(1-p_0)}} \right)^2}{(p_1 - p_0)^2},$$

где $Z_{1-\alpha/2}$ и $Z_{1-\beta}$ — квантили стандартного нормального распределения $\mathcal{N}(0, 1)$.

Данный метод не рассматривается далее, поскольку его можно использовать только в задаче логистической регрессии.

Рассмотрим метод на основе кросс-валидации (англ. cross-validation). Определим критерий переобучения как

$$RS(m) = \ln \frac{L(\mathfrak{D}_{\mathcal{L}(m)}, \hat{\mathbf{w}})}{L(\mathfrak{D}_{\mathcal{T}(m)}, \hat{\mathbf{w}})}, \quad \frac{|\mathcal{T}(m)|}{|\mathcal{L}(m)|} = \text{const} \leq 0.5.$$

Справедливо следующее предельное соотношение:

$$\lim_{m \rightarrow \infty} RS(m) = 0.$$

Достаточный размер выборки m^* определяется согласно условию:

$$m^* : \forall m \geq m^* \mathbb{E}_{\mathfrak{D}_m} RS(m) \leq \varepsilon,$$

где ε — заранее выбранный порог.

Этот метод предполагает, что длины доверительных интервалов квантиля не превышают некоторого фиксированного значения l . Для некоторого размера выборки m вычисляются квантильные доверительные интервалы $(a_1^m, b_1^m), (a_2^m, b_2^m), \dots, (a_n^m, b_n^m)$ с уровнем значимости α с использованием бутстрапа для каждого параметра модели. Достаточный размер выборки задается

выражением:

$$m^* : \forall m \geq m^* \max_i (b_i^m - a_i^m) < l.$$

Данный метод является покоординатным, и следовательно для повышения точности прогноза требуется значительное увеличение размера выборки.

Эвристические методы, рассмотренные выше, основаны на наблюдении за поведением модели при изменении размера выборки, но не предоставляют строгих теоретических гарантий. В следующем разделе рассматриваются байесовские методы, которые позволяют формализовать задачу определения достаточного размера выборки в рамках вероятностного подхода.

4.3. Байесовские критерии неопределенности параметров

В настоящем разделе рассматриваются байесовские методы оценки размера выборки, основанные на ограничении некоторых характеристик модели. Для анализа эффективности определяется функция размера выборки. Увеличение этой функции интерпретируется как снижение эффективности модели. Размер выборки m^* выбирается таким, чтобы исследуемая функция принимала значения меньше некоторого порогового значения ε .

Размер выборки m^* определяется условием:

$$\forall m \geq m^* \mathbb{E}_{\mathcal{D}_m} D[\hat{\mathbf{w}} | \mathcal{D}_m] \leq l.$$

где l — заранее выбранный порог, количественно ограничивающий неопределенность оценки параметра.

Обозначим через $A(\mathcal{D}) \subset \mathbb{R}^n$ некоторый набор параметров модели $\mathbf{w}$:

$$A(\mathcal{D}) = \{\mathbf{w} : \|\mathbf{w} - \hat{\mathbf{w}}\| \leq l\},$$

где l — некоторый фиксированный радиус шара. Размер выборки m^* определяется критерием среднего покрытия:

$$\forall m \geq m^* \mathbb{E}_{\mathcal{D}_m} \mathbb{P}\{\mathbf{w} \in A(\mathcal{D}_m)\} \geq 1 - \alpha, \quad (4.6)$$

где α — заранее выбранный уровень.

Определим функцию $A(\mathfrak{D})$:

$$P(A(\mathfrak{D})) = 1 - \alpha.$$

Оценка критерия средней длины m^* , заданная в (4.6):

$$\forall m \geq m^* E_{\mathfrak{D}_m} r_m \leq l,$$

где r_m является радиусом шара $A(\mathfrak{D}_m)$.

Следующие методы максимизируют ожидание некоторой функции полезности $u(\mathfrak{D}, \mathbf{w})$ по размеру выборки:

$$m^* = \arg \max_m E_{\mathfrak{D}_m} \int_{\mathbf{w}} u(\mathfrak{D}_m, \mathbf{w}) p(\mathbf{w}|\mathfrak{D}_m) d\mathbf{w},$$

где функция полезности $u(\mathfrak{D}, \mathbf{w})$ задается в виде:

$$u(\mathfrak{D}_m, \mathbf{w}) = l(\mathfrak{D}_m, \mathbf{w}) - cm,$$

где c — коэффициент штрафа для каждого элемента в наборе выборки.

Назовем индексы $\mathcal{B}_1, \mathcal{B}_2 \subset \{1, \dots, m\}$ по соседству, если

$$|\mathcal{B}_1 \Delta \mathcal{B}_2| = 1.$$

Таким образом, $\mathcal{B}_2$ можно преобразовать в $\mathcal{B}_1$ путем удаления, замены или добавления одного элемента. В [21] показано, что если размер набора выборок $\mathfrak{D}_{\mathcal{B}_1}$ достаточно велик, то параметры модели $\hat{\mathbf{w}}_1$, оптимизированные с помощью $\mathfrak{D}_{\mathcal{B}_1}$, должны находиться в окрестности параметров модели $\hat{\mathbf{w}}_2$, которые оптимизированы с помощью $\mathfrak{D}_{\mathcal{B}_2}$.

Используя дивергенцию Кульбака-Лейблера в качестве функции близости между распределениями параметров модели, оптимизированных с помощью $\mathfrak{D}_{\mathcal{B}_1}$ и $\mathfrak{D}_{\mathcal{B}_2}$:

$$D_{\text{KL}}(p_1, p_2) = \int_{\mathbf{w} \in \mathbb{W}} p_1(\mathbf{w}) \log \frac{p_1(\mathbf{w})}{p_2(\mathbf{w})} d\mathbf{w},$$

где p_1 и p_2 — апостериорные распределения вектора параметров $\mathbf{w}$, рассчитанные на подвыборках $\mathfrak{D}_{\mathcal{B}_1}$ и $\mathfrak{D}_{\mathcal{B}_2}$ соответственно. Также предполагается, что $\mathfrak{D}_{\mathcal{B}_1}$ и $\mathfrak{D}_{\mathcal{B}_2}$ находятся по соседству. Достаточный размер выборки m^* оценивается:

$$\forall \mathfrak{D}_{\mathcal{B}_1} : |\mathfrak{D}_{\mathcal{B}_1}| \geq m^* \mathbb{E}_{\mathfrak{D}_{\mathcal{B}_2}} D_{KL}(p_1, p_2) \leq \varepsilon.$$

Рассмотренные выше классические методы определения достаточного размера выборки имеют существенные ограничения: статистические методы требуют знания дисперсии оценок параметров, байесовские методы — вычислительно сложны для моделей с большим числом параметров, а эвристические методы не предоставляют строгих теоретических гарантий. В следующих разделах предлагаются новые методы, основанные на анализе стабильности функции правдоподобия и близости апостериорных распределений, направленные на смягчение указанных ограничений.

4.4. D- и M-достаточность по функции правдоподобия

В настоящем разделе рассматривается метод определения достаточного размера выборки, основанный на анализе стабильности функции правдоподобия при изменении объема данных. Предполагается, что выполняется условие $m^* \leq m$, где m — размер доступной выборки D , а m^* — искомый достаточный размер. Таким образом, требуется определить минимальный объем выборки, который следует считать достаточным для обучения модели, при условии наличия достаточного количества объектов в самой выборке D .

Для определения достаточности используется функция правдоподобия. Когда доступно достаточное количество объектов, естественно ожидать, что полученная оценка параметров не будет существенно изменяться от одной реализации выборки к другой [17, 18]. Аналогичное утверждение справедливо и для функции правдоподобия. Таким образом, формализуем критерии, позволяющие определить достаточный объем выборки.

Критерий определяется в определении 24.

Определение 24 (D-достаточный размер выборки). Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* назовем D-достаточным, если для всех $k \geq m^*$ выполняется условие:

$$D(k) = \mathbb{D}_{\hat{\mathbf{w}}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon.$$

Определение 24 формализует идею о том, что при достаточном размере выборки дисперсия функции правдоподобия по различным реализациям подвыборок должна быть мала, что указывает на стабильность оценки параметров.

С другой стороны, при наличии достаточного количества объектов естественно ожидать, что при добавлении еще одного объекта к рассмотрению результирующая оценка параметра изменится незначительно; на основе данного свойства получаем определение 25.

Определение 25 (M-достаточный размер выборки). Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* назовем M-достаточным, если для всех $k \geq m^*$ выполняется условие:

$$M(k) = \left| \mathbb{E}_{\hat{\mathbf{w}}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\hat{\mathbf{w}}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \right| \leq \varepsilon.$$

Определение 25 формализует условие, при котором добавление нового объекта к выборке не приводит к существенному изменению математического ожидания функции правдоподобия, что указывает на достижение достаточного объема данных для стабильной оценки параметров модели.

В приведенных выше определениях вместо функции правдоподобия $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$ рассматривается ее логарифм $l(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$, что упрощает математический анализ за счет перехода от произведения к сумме.

Предположим, что $\mathbb{W} = \mathbb{R}^n$, информационная матрица Фишера задана матрицей:

$$[\mathcal{I}(\mathbf{w})]_{ij} = -\mathbb{E} \left[\frac{\partial^2 \log p(\mathbf{y}|\mathbf{x}, \mathbf{w})}{\partial w_i \partial w_j} \right],$$

Известным результатом является асимптотическая нормальность оценки мак-

симального правдоподобия:

$$\sqrt{k}(\hat{\mathbf{w}}_k - \mathbf{w}) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}^{-1}(\mathbf{w})),$$

где $\xrightarrow{d}$ обозначает сходимость по распределению. Следует отметить, что сходимость по распределению, вообще говоря, не влечет сходимости моментов случайного вектора. Однако если предположить сходимость моментов, то в некоторых моделях можно обосновать согласованность предложенного определения М-достаточного размера выборки.

Для удобства обозначим параметры распределения $\hat{\mathbf{w}}_k$ следующим образом: математическое ожидание $\mathbb{E}\hat{\mathbf{w}}_k = \mathbf{m}_k$ и матрица ковариаций $\mathbb{D}\hat{\mathbf{w}}_k = \Sigma_k$. Тогда справедлива теорема 28, которая доказывает сходимость параметров.

Теорема 28 (Корректность М-достаточного размера выборки). *Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$. Тогда в модели линейной регрессии определение М-достаточного размера выборки корректно. А именно, для любого $\varepsilon > 0$ существует такой m^* , что для всех $k \geq m^*$ выполняется $M(k) \leq \varepsilon$.*

Доказательство теоремы приведено в работе [140].

Теорема 28 устанавливает согласованность определения М-достаточного размера выборки для модели линейной регрессии при выполнении условий сходимости моментов оценок параметров. Указанные условия являются естественными для асимптотически нормальных оценок максимального правдоподобия и выполняются при стандартных предположениях о регулярности модели.

Следствие 9 (Корректность М-достаточного размера выборки при сходимости к истинным параметрам). *Пусть $\|\mathbf{m}_k - \mathbf{w}\|_2 \rightarrow 0$ и $\|\Sigma_k - [k\mathcal{I}(\mathbf{w})]^{-1}\|_F \rightarrow 0$ при $k \rightarrow \infty$.*

Тогда в модели линейной регрессии определение М-достаточного размера выборки корректно.

По условию, задана только одна выборка, а следовательно, в эксперименте невозможно вычислить математическое ожидание и дисперсию, указанные в определениях 24 и 25. При численной реализации этих определений величины

$\mathbb{D}$ и $\mathbb{E}$ трактуются относительно бутстрэп-распределения: из заданной выборки $\mathfrak{D}_m$ генерируется некоторое число B подвыборок размера k с возвращением. Для каждой подвыборки получается оценка параметров $\hat{\mathbf{w}}_k$ и вычисляется значение $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$. Для оценки математического ожидания и дисперсии используются выборочное среднее и несмещенная выборочная дисперсия соответственно. Количество подвыборок B выбирается достаточно большим (обычно $B \geq 1000$) для обеспечения точности оценок.

Предложенные выше определения также могут быть применены в тех задачах, где минимизируется произвольная функция потерь, а не максимизируется функция правдоподобия. В этом случае вместо функции правдоподобия $L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$ используется функция потерь $\mathcal{L}(\mathfrak{D}_m, \hat{\mathbf{w}}_k)$, а критерии достаточности формулируются аналогичным образом. Строгое теоретическое обоснование данного обобщения отсутствует, однако численные эксперименты показывают применимость таких методов.

Метод, рассмотренный выше, основан на анализе стабильности функции правдоподобия при изменении объема данных. Альтернативный подход заключается в анализе близости апостериорных распределений параметров модели на близких подвыборках, что составляет содержание следующего раздела.

4.5. KL- и S-достаточность по апостериорным распределениям

В настоящем разделе рассматривается метод определения достаточного размера выборки, основанный на анализе близости апостериорных распределений параметров модели. В работе [21] предлагается использовать расхождение Кульбака-Лейблера для оценки достаточного размера выборки в задаче бинарной классификации.

Идея метода основана на том, что если две подвыборки отличаются друг от друга одним объектом, то полученные по ним апостериорные распределения должны быть близки. Эта близость определяется расхождением Кульбака-

Лейблера.




Рис. 4.1: Визуализация сдвига апостериорных распределений параметров модели при последовательном добавлении объектов в выборку. Иллюстрация демонстрирует концепцию близости распределений, используемую в методах KL- и S-достаточности для определения достаточного размера выборки.

В рамках данного раздела предлагается использовать не только расхождение Кульбака-Лейблера, но и функцию схожести s-score из работы [141], для этого рассмотрим две подвыборки $\mathfrak{D}^1 \subseteq \mathfrak{D}_m$ и $\mathfrak{D}^2 \subseteq \mathfrak{D}_m$. Пусть $\mathcal{I}_1 \subseteq \mathcal{I} = \{1, \dots, m\}$ и $\mathcal{I}_2 \subseteq \mathcal{I} = \{1, \dots, m\}$ — соответствующие им подмножества индексов.

Определение 26 (Бликие подвыборки). Подвыборки $\mathfrak{D}^1$ и $\mathfrak{D}^2$ назовем близкими, если $\mathcal{I}_2$ может быть получено из $\mathcal{I}_1$ путем удаления, замены или добавления одного элемента. Формально это условие записывается как

$$|\mathcal{I}_1 \Delta \mathcal{I}_2| = |(\mathcal{I}_1 \setminus \mathcal{I}_2) \cup (\mathcal{I}_2 \setminus \mathcal{I}_1)| = 1,$$

где Δ обозначает симметрическую разность множеств.

Рассмотрим две близкие подвыборки $\mathfrak{D}_k = (\mathbf{X}_k, \mathbf{y}_k)$ и $\mathfrak{D}_{k+1} = (\mathbf{X}_{k+1}, \mathbf{y}_{k+1})$ размеров k и $k+1$ соответственно, где выборка $\mathfrak{D}_{k+1}$ получена путем добавления одного элемента к выборке $\mathfrak{D}_k$.

Вычислим апостериорное распределение параметров модели по каждой из этих подвыборок:

$$p_j(\mathbf{w}) = p(\mathbf{w} | \mathfrak{D}_j) = \frac{p(\mathfrak{D}_j | \mathbf{w}) p(\mathbf{w})}{p(\mathfrak{D}_j)} \propto p(\mathfrak{D}_j | \mathbf{w}) p(\mathbf{w}), \quad j = k, k+1.$$

Определение 27 (KL-достаточный размер выборки). Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* называется KL-достаточным, если для всех $k \geq m^*$

$$KL(k) = D_{KL}(p_k \| p_{k+1}) = \int p_k(\mathbf{w}) \log \frac{p_k(\mathbf{w})}{p_{k+1}(\mathbf{w})} d\mathbf{w} \leq \varepsilon.$$

Для пары нормальных распределений расхождение Кульбака-Лейблера имеет аналитическое выражение. Предположив, что апостериорное распределение является нормальным, $p_k(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_k, \Sigma_k)$, где $\mathbf{m}_k$ — вектор математического ожидания, а Σ_k — ковариационная матрица, получаем формулировку теоремы 29

Теорема 29 (Корректность KL-достаточного размера выборки). Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$.

Тогда в модели с нормальным апостериорным распределением параметров определение KL-достаточного размера выборки корректно. А именно, для любого $\varepsilon > 0$ существует такой m^* , что для всех $k \geq m^*$ выполняется $KL(k) \leq \varepsilon$.

Доказательство теоремы приведено в работе [142].

Теорема 29 устанавливает, что расхождение Кульбака-Лейблера между двумя нормальными апостериорными распределениями стремится к нулю по мере сходимости их векторов математических ожиданий и ковариационных матриц. Это позволяет использовать KL-дивергенцию в качестве критерия достаточности размера выборки, анализируя аналитические выражения для моментов апостериорных распределений.

Рассмотрим функцию схожести s-score из работы [141] в качестве меры близости распределений по аналогии, как это было с KL-дивергенцией:

$$\text{s-score}(g_1, g_2) = \frac{\int_{\mathbf{w}} g_1(\mathbf{w}) g_2(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int_{\mathbf{w}} g_1(\mathbf{w} - \mathbf{b}) g_2(\mathbf{w}) d\mathbf{w}}.$$

Определение 28 (S-достаточный размер выборки). Пусть задано некоторое $\varepsilon > 0$. Размер выборки m^* называется S-достаточным, если для всех $k \geq$

m^*

$$S(k) = s\text{-score}(p_k, p_{k+1}) \geq 1 - \varepsilon.$$

Как и в случае с KL-достаточным размером выборки, в модели с нормальным апостериорным распределением можно записать выражение для используемого критерия, который записан в виде теоремы 30

Теорема 30 (Корректность S-достаточного размера выборки). *Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ при $k \rightarrow \infty$.*

Тогда в модели с нормальным апостериорным распределением параметров определение S-достаточного размера выборки корректно. А именно, для любого $\varepsilon > 0$ существует такой m^ , что для всех $k \geq m^*$ выполняется $S(k) \geq 1 - \varepsilon$.*

Доказательство теоремы приведено в работе [142].

Теорема 30 устанавливает согласованность определения S-достаточного размера выборки при более слабых условиях, чем теорема 29. В отличие от KL-дивергенции, для сходимости s-score к единице требуется только сходимость математических ожиданий апостериорных распределений, что делает данный критерий менее консервативным.

Пусть в модели линейной регрессии задано нормальное априорное распределение параметров. В силу свойства сопряженности априорного распределения и правдоподобия, апостериорное распределение также будет нормальным. Таким образом, приходим к одному из простейших примеров модели, для которой справедливы приведенные выше теоремы. Фактически, для линейной регрессии могут быть сформулированы более простые утверждения.

Теорема 31 (Сходимость апостериорных распределений в линейной регрессии). *Пусть множества значений признаков и целевой переменной ограничены, то есть существует константа $M \in \mathbb{R}$ такая, что $\|\mathbf{x}\|_2 \leq M$ и $|y| \leq M$ для всех объектов выборки. Если $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$, то в модели линейной регрессии с нормальным априорным распределением параметров $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$.*

Доказательство. Рассмотрим линейную регрессионную модель с нормальным априорным распределением параметров: $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I})$. Данное априорное распределение является сопряженным для нормального правдоподобия, что существенно упрощает анализ. Нормальное правдоподобие задается в виде:

$$p(\mathbf{y}|\mathbf{X}, \mathbf{w}) = \mathcal{N}(\mathbf{y}|\mathbf{X}\mathbf{w}, \sigma^2\mathbf{I}) = (2\pi\sigma^2)^{-m/2} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2\right).$$

Благодаря свойству сопряженности нормального априорного распределения и нормального правдоподобия, апостериорное распределение также является нормальным:

$$p(\mathbf{w}|\mathbf{X}, \mathbf{y}) = \mathcal{N}(\mathbf{w}|\mathbf{m}, \Sigma),$$

где параметры распределения имеют аналитическое выражение:

$$\begin{aligned}\Sigma &= \left(\alpha\mathbf{I} + \frac{1}{\sigma^2}\mathbf{X}^\top\mathbf{X}\right)^{-1}, \\ \mathbf{m} &= \frac{1}{\sigma^2}\Sigma\mathbf{X}^\top\mathbf{y} = (\mathbf{X}^\top\mathbf{X} + \alpha\sigma^2\mathbf{I})^{-1}\mathbf{X}^\top\mathbf{y}.\end{aligned}$$

Перейдем к анализу сходимости ковариационных матриц. Рассмотрим подвыборки размера k и $k+1$, полученные из исходных данных. Нас интересует поведение разности $\|\Sigma_{k+1} - \Sigma_k\|_2$ при $k \rightarrow \infty$. Введем обозначение $\mathbf{A}_k = \frac{1}{\sigma^2}\mathbf{X}_k^\top\mathbf{X}_k$ для нормированной матрицы ковариации признаков. Тогда разность обратных матриц можно преобразовать, используя матричное тождество:

$$\|\Sigma_{k+1} - \Sigma_k\|_2 = \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1} - (\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2.$$

Применяя матричное тождество для разности обратных матриц, получаем:

$$(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1} - (\alpha\mathbf{I} + \mathbf{A}_k)^{-1} = (\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1}(\mathbf{A}_k - \mathbf{A}_{k+1})(\alpha\mathbf{I} + \mathbf{A}_k)^{-1}.$$

Используя субмультипликативное свойство спектральной нормы, оцениваем:

$$\|\Sigma_{k+1} - \Sigma_k\|_2 \leq \left\|(\alpha\mathbf{I} + \mathbf{A}_{k+1})^{-1}\right\|_2 \left\|(\alpha\mathbf{I} + \mathbf{A}_k)^{-1}\right\|_2 \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2.$$

Проанализируем каждый из множителей в полученной оценке. Спектральная норма обратной матрицы выражается через минимальное собственное значение исходной матрицы:

$$\left\|(\alpha \mathbf{I} + \mathbf{A})^{-1}\right\|_2 = \frac{1}{\lambda_{\min}(\alpha \mathbf{I} + \mathbf{A})}.$$

Поскольку $\alpha > 0$ и матрица $\mathbf{A}$ положительно полуопределена, имеем $\lambda_{\min}(\alpha \mathbf{I} + \mathbf{A}) \geq \alpha + \lambda_{\min}(\mathbf{A})$. Однако для получения точной асимптотики используем более слабую оценку:

$$\left\|(\alpha \mathbf{I} + \mathbf{A})^{-1}\right\|_2 \leq \frac{1}{\lambda_{\min}(\mathbf{A})}.$$

Объединяя полученные оценки, получаем цепочку неравенств:

$$\begin{aligned} \|\boldsymbol{\Sigma}_{k+1} - \boldsymbol{\Sigma}_k\|_2 &\leq \frac{1}{\lambda_{\min}(\mathbf{A}_{k+1})} \frac{1}{\lambda_{\min}(\mathbf{A}_k)} \|\mathbf{A}_{k+1} - \mathbf{A}_k\|_2 = \\ &= \sigma^2 \frac{1}{\lambda_{\min}(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1})} \frac{1}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)} \|\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} - \mathbf{X}_k^\top \mathbf{X}_k\|_2. \end{aligned}$$

Поскольку выборка $\mathfrak{D}_{k+1}$ получается из $\mathfrak{D}_k$ добавлением одного наблюдения, имеем:

$$\|\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} - \mathbf{X}_k^\top \mathbf{X}_k\|_2 = \left\| \sum_{i=1}^{k+1} \mathbf{x}_i \mathbf{x}_i^\top - \sum_{i=1}^k \mathbf{x}_i \mathbf{x}_i^\top \right\|_2 = \|\mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top\|_2.$$

Матрица $\mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top$ является матрицей ранга 1, и ее спектральная норма равна квадрату евклидовой нормы вектора $\mathbf{x}_{k+1}$:

$$\|\mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top\|_2 = \lambda_{\max}(\mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top) = \|\mathbf{x}_{k+1}\|_2^2.$$

Из условия ограниченности признаков следует $\|\mathbf{x}_{k+1}\|_2^2 \leq M^2$. Таким образом:

$$\|\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} - \mathbf{X}_k^\top \mathbf{X}_k\|_2 \leq M^2.$$

Теперь рассмотрим условие на минимальное собственное значение. Из предположения $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ следует, что:

$$\frac{1}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)} = o\left(\frac{1}{\sqrt{k}}\right).$$

Комбинируя полученные оценки, приходим к:

$$\|\Sigma_{k+1} - \Sigma_k\|_2 \leq \sigma^2 M^2 \cdot o\left(\frac{1}{\sqrt{k}}\right) \cdot o\left(\frac{1}{\sqrt{k}}\right) = o\left(\frac{1}{k}\right).$$

Для перехода к норме Фробениуса воспользуемся неравенством $\|\mathbf{A}\|_F \leq \sqrt{n}\|\mathbf{A}\|_2$, где n — размерность пространства параметров:

$$\|\Sigma_{k+1} - \Sigma_k\|_F \leq \sqrt{n}\|\Sigma_{k+1} - \Sigma_k\|_2 = \sqrt{n} \cdot o\left(\frac{1}{k}\right) = o\left(\frac{1}{k}\right).$$

Теперь перейдем к анализу сходимости математических ожиданий. Требуется оценить:

$$\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 = \left\| (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_{k+1}^\top \mathbf{y}_{k+1} - (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_k^\top \mathbf{y}_k \right\|_2.$$

Представим расширенную матрицу признаков и вектор ответов через предыдущие значения:

$$\mathbf{X}_{k+1} = \begin{bmatrix} \mathbf{X}_k \\ \mathbf{x}_{k+1}^\top \end{bmatrix}, \quad \mathbf{y}_{k+1} = \begin{bmatrix} \mathbf{y}_k \\ y_{k+1} \end{bmatrix}.$$

Тогда матричные произведения принимают вид:

$$\begin{aligned} \mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} &= \mathbf{X}_k^\top \mathbf{X}_k + \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top, \\ \mathbf{X}_{k+1}^\top \mathbf{y}_{k+1} &= \mathbf{X}_k^\top \mathbf{y}_k + \mathbf{x}_{k+1} y_{k+1}. \end{aligned}$$

Подставляя эти выражения, получаем:

$$\begin{aligned} \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 &= \left\| \left(\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I} + \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} (\mathbf{X}_k^\top \mathbf{y}_k + \mathbf{x}_{k+1} y_{k+1}) \right. \\ &\quad \left. - (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_k^\top \mathbf{y}_k \right\|_2. \end{aligned}$$

Для упрощения первого слагаемого применим лемму о матричном обращении:

$$\begin{aligned} (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I} + \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top)^{-1} &= \\ &= (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} - \frac{(\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1}}{1 + \mathbf{x}_{k+1}^\top (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1}}. \end{aligned}$$

После алгебраических преобразований получаем:

$$\begin{aligned} \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 &= \\ &= \left\| \left[\left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right] (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{X}_k^\top \mathbf{y}_k \right. \\ &\quad \left. + (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} y_{k+1} \right\|_2. \end{aligned}$$

Применяя неравенство треугольника и свойства норм, оцениваем каждый член отдельно:

$$\begin{aligned} \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 &\leq \\ &\leq \left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right\|_2 \left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{X}_k^\top \mathbf{y}_k\|_2 \\ &\quad + \left\| (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{x}_{k+1} y_{k+1}\|_2. \end{aligned}$$

Проанализируем первый множитель в первом слагаемом. Используя матричное тождество, получаем:

$$\begin{aligned} &\left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right\|_2 = \\ &= \left\| - \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right\|_2. \end{aligned}$$

Применяя субмультипликативность нормы и учитывая, что спектральная норма произведения матриц не превышает произведения их норм, получаем оценку:

$$\begin{aligned} &\left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right\|_2 \leq \\ &\leq \left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} \right\|_2 \left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top\|_2. \end{aligned}$$

Оценим каждый из этих множителей. Для первого множителя используем тот факт, что матрица $(\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top$ имеет единичный ранг, и ее максимальное собственное значение равно:

$$\lambda_{\max} \left((\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right) = \mathbf{x}_{k+1}^\top (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1}.$$

Тогда спектральная норма обратной матрицы оценивается как:

$$\left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} \right\|_2 \leq 1.$$

Второй множитель оценивается через минимальное собственное значение:

$$\left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \leq \frac{1}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)}.$$

Третий множитель, как уже было установлено, равен $\|\mathbf{x}_{k+1}\|_2^2 \leq M^2$. Таким образом, получаем оценку для первого множителя:

$$\left\| \left(\mathbf{I} + (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \mathbf{x}_{k+1} \mathbf{x}_{k+1}^\top \right)^{-1} - \mathbf{I} \right\|_2 \leq \frac{M^2}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)}.$$

Теперь оценим второй множитель первого слагаемого вместе с третьим множителем:

$$\left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{X}_k^\top \mathbf{y}_k\|_2 \leq \frac{\|\mathbf{X}_k^\top \mathbf{y}_k\|_2}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)}.$$

Норма $\|\mathbf{X}_k^\top \mathbf{y}_k\|_2$ оценивается с использованием условия ограниченности:

$$\|\mathbf{X}_k^\top \mathbf{y}_k\|_2 = \left\| \sum_{i=1}^k \mathbf{x}_i y_i \right\|_2 \leq \sum_{i=1}^k \|\mathbf{x}_i y_i\|_2 \leq k M^2.$$

Следовательно:

$$\left\| (\mathbf{X}_k^\top \mathbf{X}_k + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{X}_k^\top \mathbf{y}_k\|_2 \leq \frac{k M^2}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)}.$$

Теперь рассмотрим второе слагаемое:

$$\left\| (\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1} + \alpha \sigma^2 \mathbf{I})^{-1} \right\|_2 \|\mathbf{x}_{k+1} y_{k+1}\|_2 \leq \frac{M^2}{\lambda_{\min}(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1})}.$$

Комбинируя все полученные оценки, приходим к итоговой оценке:

$$\begin{aligned} \|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 &\leq \frac{M^2}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)} \cdot \frac{k M^2}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)} + \frac{M^2}{\lambda_{\min}(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1})} \\ &= \frac{k M^4}{\lambda_{\min}^2(\mathbf{X}_k^\top \mathbf{X}_k)} + \frac{M^2}{\lambda_{\min}(\mathbf{X}_{k+1}^\top \mathbf{X}_{k+1})}. \end{aligned}$$

Из условия $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$ следует:

$$\frac{1}{\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)} = o\left(\frac{1}{\sqrt{k}}\right),$$

$$\frac{1}{\lambda_{\min}^2(\mathbf{X}_k^\top \mathbf{X}_k)} = o\left(\frac{1}{k}\right).$$

Поэтому первое слагаемое оценивается как $k \cdot o\left(\frac{1}{k}\right) = o(1)$, а второе слагаемое как $o\left(\frac{1}{\sqrt{k}}\right) = o(1)$. Таким образом:

$$\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 = o(1) \quad \text{при} \quad k \rightarrow \infty.$$

Это завершает доказательство сходимости как ковариационных матриц, так и математических ожиданий апостериорного распределения параметров. $\square$

Теорема 31 является центральной в настоящем разделе: при сравнительно слабых предположениях из нее следует сходимость моментов апостериорного распределения параметров. Первое предположение в теореме 31 касается ограничения на область значений признаков и целевой переменной. Это условие обычно выполняется в практических приложениях, поэтому оно служит в первую очередь для целей теоретического анализа. Второе условие теоремы 31 существенно, поскольку оно опирается на поведение минимального собственного значения выборочной ковариационной матрицы признаков. Строгие теоретические гарантии для данной сходимости в настоящей работе не приводятся; выполнение условия подтверждается численно.

4.6. Вычислительные эксперименты

В настоящем разделе представлены результаты вычислительных экспериментов для методов определения достаточного размера выборки, описанных в предыдущих разделах главы. Эксперименты направлены на проверку теоретических результатов и сравнение различных подходов.

Таблица 4.1: Характеристики выборок, используемых для анализа качества методов определения достаточного размера выборки. Таблица содержит информацию о типе задачи, количестве признаков и общем размере выборки для каждого набора данных.

Выборка	Задача	Число признаков	Размер выборки
Boston Housing	regression	14	506
Diabets	regression	20	576
Forest Fires	regression	13	517
Servo	regression	4	167
NBA	classification	12	2235

4.6.1. Эксперименты для статистических критериев

Проводится эксперимент для анализа свойств методов оценки достаточного размера выборки. Эксперимент состоит из трех частей.

В первой части рассматриваются оценки достаточного размера выборки для различных наборов данных с фиксированным набором гиперпараметров различных методов. В качестве данных использовались выборки, описанные в таблице 4.1. Результаты представлены в таблице 4.2, где показаны оценки размера выборки для соответствующих выборок.

Во второй части исследуется зависимость достаточного размера выборки от имеющегося размера выборки. В третьей части исследуется поведение методов в зависимости от изменения гиперпараметров методов.

В данной части вычислительного эксперимента анализируется сходимость различных методов на различных выборках. В эксперименте используются выборки: Boston Housing [143], Diabetes, Forest Fires, Servo [144], NBA. Результат анализа представлен в таблице 4.2. Символ “—” обозначает, что исходный размер выборки недостаточный для прогноза.

Таблица 4.2: Сравнение оценок достаточного размера выборки, полученных различными статистическими и байесовскими методами для пяти наборов данных. Результаты демонстрируют значительный разброс оценок между методами, что указывает на различную консервативность подходов.

Методы	Boston	Diabetes	Forest Fires	Servo	NBA
Lagrange Multipliers Test	18	25	44	38	218
Likelihood Ratio Test	17	25	43	18	110
Wald Test	66	51	46	76	200
Cross Validation	178	441	172	120	—
Bootstrap	113	117	86	60	405
APVC	98	167	351	20	—
ACC	228	441	346	65	—
ALC	98	267	516	25	—
Utility Function	148	172	206	105	925

Гиперпараметры каждого метода для всех выборок описаны в таблице 4.3. Поскольку критерии Лагранжа, отношения правдоподобия и Вальда асимптотически эквивалентны, то параметры этих методов задавались одинаково. Параметры методов «Average Coverage» и «Average Length» также задаются одинаково.

Вычислительный эксперимент проводился для анализа описанных методов. Выбирается некоторый размер выборки m и методом бутстрап семплируется множество подвыборок размером m . Для разных значений m вычисляется m^* .

На рис. 4.2 демонстрируется зависимость статистических показателей каждого метода для разных выборок с фиксированным размером выборки m . Пороговые значения для каждого метода фиксируются заранее и задают требуемый уровень соответствующих статистических характеристик.

Представленные функции являются монотонными и асимптотически стре-

Таблица 4.3: Гиперпараметры методов оценки достаточного размера выборки, заранее заданные для экспериментов. Параметры включают уровни значимости α , вероятности ошибки второго рода β , пороговые значения ε и l , а также параметры обобщенных линейных моделей.

Method	GLM parameters	l	ε	α	β
Lagrange Multipliers Test	$\mathbf{w}_u^0$	—	0.2	0.05	0.2
Likelihood Ratio Test	$\mathbf{w}_u^0$	—	0.2	0.05	0.2
Wald Test	$\mathbf{w}_u^0$	—	0.2	0.05	0.2
Cross Validation	—	—	0.05	—	—
Bootstrap	—	0.5	—	0.05	—
APVC	—	0.5	—	—	—
ACC	—	0.25	—	0.05	—
ALC	—	0.5	—	0.05	—
Utility function	—	—	0.005	—	—

мятся к константе, что согласуется с ожидаемой монотонной стабилизацией соответствующих критериев.

На рис. 4.3 показаны результаты методов на выборках различного размера. Наблюдается различие методов в дисперсии вычисленного m^* . Все представленные методы демонстрируют сходимость, причем результат предсказания в асимптотике не зависит от доступного размера выборки m .

Небольшое значение дисперсии интерпретируется как вычислительная устойчивость рассмотренных методов.

Показано, что некоторые методы не дают оценку достаточного размера выборки, если доступный размер выборки недостаточен для применения метода. Это означает, что указанные методы не эффективны с точки зрения прогнозирования необходимого объема данных на ранних этапах эксперимента, однако могут быть использованы для ретроспективного анализа уже проведенных экс-




Рис. 4.2: Зависимость статистических значений различных методов определения достаточного размера выборки от размера подвыборки для наборов данных Boston Housing, Diabetes, Forest Fires, Servo и NBA. Все представленные функции монотонны и асимптотически стремятся к константе, что согласуется с ожидаемой монотонной стабилизацией критериев.

периментов.

Анализируется оценка достаточного размера выборки в зависимости от гиперпараметров для байесовских методов, а также эвристических методов. Для




Рис. 4.3: Зависимость оцененного достаточного размера выборки m^* от доступного размера выборки t для различных методов на наборе данных Boston Housing. Результаты демонстрируют сходимость методов и низкую дисперсию оценок, что указывает на вычислительную устойчивость рассмотренных подходов.

анализа рассмотрена выборка Boston Housing.

Байесовские методы используют решающее правило над скалярной функцией для определения достаточного размера выборки. На рис. 4.2 показана зависимость скалярных функций от размера подвыборки. Наблюдается, что указанные функции являются монотонными. Характер поведения функции определяется выбранным методом. Изменение заранее заданных порогов позволяет варьировать размер выборки, отвечающий выбранным ограничениям.

4.6.2. Эксперименты для D- и M-достаточности

В настоящем разделе представлено эмпирическое исследование предложенных методов. Эксперименты проводились на синтетических данных и наборе данных Liver Disorders из [145].

Синтетические данные были сгенерированы из моделей линейной регрессии




Рис. 4.4: Сходимость функций $D(k)$ и $M(k)$ для синтетического набора данных регрессии. Обе функции стремятся к нулю с увеличением размера выборки, что подтверждает теорему 28.




Рис. 4.5: Сходимость функций $D(k)$ и $M(k)$ для синтетического набора данных классификации. Обе функции демонстрируют монотонное убывание к нулю с увеличением размера выборки, подтверждая применимость методов D- и M-достаточности для задач классификации.

и логистической регрессии. Количество объектов составляет 1000, количество признаков — 20. Использовалось $B = 1000$ бутстрэп-подвыборок. Вычислялись значения $D(k)$ и $M(k)$. Набор данных регрессии Liver Disorders содержит 345 объектов и 5 признаков. Также использовалось $B = 1000$ подвыборок, получен-




Рис. 4.6: Сходимость функций $D(k)$ и $M(k)$ для набора данных Liver Disorders (345 объектов, 5 признаков, $B = 1000$ бутстрэп-подвыборок). Обе функции демонстрируют сходимость к нулю, что подтверждает теоретические результаты и демонстрирует применимость методов на реальных данных.




Рис. 4.7: Зависимость достаточного размера выборки m^* от порогового параметра ε для методов D- и M-достаточности на трех наборах данных. С увеличением значения порога ε достаточный размер выборки монотонно уменьшается, что позволяет выбирать меньше объектов для достижения заданного уровня стабильности функций $D(k)$ и $M(k)$.

ных методом бутстрэпа, для оценки математического ожидания и дисперсии функции потерь.

На рис. 4.4 показаны полученные зависимости между доступным размером выборки k и предложенными функциями $D(k)$ и $M(k)$ для синтетического на-

Таблица 4.4: Сравнение оценок достаточного размера выборки методами D- и M-достаточности для 13 наборов данных с задачей регрессии. Методы демонстрируют сопоставимые результаты для большинства наборов данных, при этом M-достаточность иногда требует большего размера выборки.

Dataset name	Objects m	Features n	D	M
Abalone	4177	8	96	96
Auto MPG	392	8	15	15
Automobile	159	25	70	156
Liver Disorders	345	6	12	19
Servo	167	4	41	—
Forest fires	517	12	208	—
Wine Quality	6497	12	144	144
Energy Efficiency	768	9	24	442
Student Performance	649	32	129	177
Facebook Metrics	495	18	31	388
Real Estate Valuation	414	7	15	23
Heart Failure Clinical Records	299	12	63	224
Bone marrow transplant: children	142	36	—	—

бора данных регрессии. Результаты для синтетического набора данных классификации представлены на рис. 4.5. На рис. 4.6 представлены графики для набора данных Liver Disorders. Наблюдается, что во всех случаях значения $D(k)$ и $M(k)$ приближаются к нулю с увеличением размера выборки. Эти эмпирические результаты подтверждают полученные ранее теоретические выводы.

В определениях D-достаточности и M-достаточности присутствует гиперпараметр ε , который соответствует порогу для достаточного размера выборки m^* . Для изучения зависимости между указанными величинами построена зависимость на рис. 4.7, которая демонстрирует возможные размеры выборки для

обеспечения заданного уровня достоверности.

Для сравнения производительности предложенных методов на различных наборах данных были выбраны выборки из открытого репозитория [145]. Подробная информация о каждом наборе данных, количестве наблюдений и количестве признаков представлена в Таблице 4.4. В демонстрационных целях было выбрано значение гиперпараметра ε , при котором значение целевой функции, $D(k)$ или $M(k)$, уменьшается вдвое. Соответствующие результаты представлены в Таблице 4.4. Пропуски означают, что исходный размер выборки недостаточен.

4.6.3. Эксперименты для KL- и S-достаточности




Рис. 4.8: Зависимость минимального собственного значения $\lambda_{\min}(\mathbf{X}_k^T \mathbf{X}_k)$ от размера выборки k для синтетических данных регрессии (500 объектов, 10 признаков) и набора данных Liver Disorders (345 объектов, 5 признаков). Асимптотическое поведение соответствует условию теоремы 31: $\lambda_{\min} = \omega(\sqrt{k})$ при $k \rightarrow \infty$.

В настоящем разделе представлено расширенное эмпирическое исследование предложенных методов определения достаточного размера выборки на основе близости апостериорных распределений. Эксперименты состоят из трех частей.




Рис. 4.9: Сходимость функций $KL(k)$ и $S(k)$ для синтетического набора данных регрессии. Функция $KL(k)$ стремится к нулю, а $S(k)$ стремится к единице, что подтверждает теоремы 29 и 30.




Рис. 4.10: Сходимость функций $KL(k)$ и $S(k)$ для набора данных Liver Disorders (345 объектов, 5 признаков, нормальное априорное распределение, $B = 100$ повторений). Результаты демонстрируют сходимость $KL(k)$ к нулю и $S(k)$ к единице, подтверждая теоретические предсказания и применимость методов KL- и S-достаточности на реальных данных.

В первой части проверяются сходимости, полученные в ходе теоретического анализа. А именно, сначала рассматривается поведение минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ при увеличении размера выборки, что необходи-




Рис. 4.11: Зависимость достаточного размера выборки m^* от порогового параметра ϵ для методов KL- и S-достаточности на синтетических данных регрессии и наборе данных Liver Disorders. Метод S-достаточности требует более низких значений порога для достижения заданного уровня близости распределений, что указывает на его более строгие требования к качеству оценки.

Таблица 4.5: Характеристики выборок, используемых для сравнения методов определения достаточного размера выборки на основе близости апостериорных распределений. Все наборы данных соответствуют задаче регрессии и используются для оценки методов KL- и S-достаточности.

Выборка	Количество признаков, n	Количество объектов, m
Boston Housing	14	506
Diabetes	10	576
Forest Fires	13	517
Servo	4	167

мо для выполнения условий теоремы 31. Затем исследуется сходимость предложенных функций $KL(k)$ и $S(k)$ к их предельным значениям. Наконец, изучается зависимость достаточного размера выборки от пороговых параметров ϵ .

Таблица 4.6: Сравнение оценок достаточного размера выборки, полученных классическими методами и предложенными методами KL- и S-достаточности для четырех наборов данных регрессии. Метод KL-достаточности дает более консервативные оценки, требующие почти полной выборки, в то время как S-достаточность указывает на минимальные размеры выборки.

Methods and sample sets	Boston	Diabetes	Forest Fires	Servo
Lagrange Multipliers Test	18	25	44	38
Likelihood Ratio Test	17	25	43	18
Wald Test	66	51	46	76
Cross Validation	178	441	171	120
Bootstrap	113	117	86	60
APVC	98	167	351	20
ACC	228	441	346	65
ALC	98	267	516	25
Utility function	148	172	206	105
KL (ours)	493	437	86	165
S (ours)	28	22	26	10

Эксперимент проводится на двух наборах данных: синтетическая регрессия и Liver Disorders.

Во второй части оцениваются размеры выборок для различных наборов данных, используя разные подходы (KL- и S-достаточность, а также классические методы). В третьей части изучается зависимость достаточного размера выборки от объема доступных данных, что позволяет оценить стабильность методов при различных объемах выборок.

Синтетические данные генерируются из модели линейной регрессии. Количество объектов составляет 500, количество признаков — 10. Для генерации син-




Рис. 4.12: Зависимость оцененного достаточного размера выборки m^* от доступного размера выборки m для классических методов и предложенных методов KL- и S-достаточности на наборе данных Boston Housing. Критерий KL-достаточности является наиболее консервативным и требует почти полной выборки, в то время как S-достаточность указывает на минимальные размеры, что связано с высокой чувствительностью расхождения Кульбака-Лейблера к изменениям распределений.

тетического набора данных регрессии исходные признаки, параметры модели и шумовые остатки генерируются из стандартного нормального распределения.

Априорное распределение параметров также задано как стандартное нормальное, как для синтетической регрессии, так и для набора данных Liver Disorders, который содержит 345 объектов и 5 признаков. Входные признаки предобрабатываются с использованием стандартного метода масштабирования данных (англ. Standard Scaler).

Процедура эксперимента организована следующим образом. Один объект последовательно удалялся из заданной выборки до тех пор, пока количество объектов в подвыборке не становилось равным количеству признаков. Для каждого размера выборки k вычисляется минимальное собственное значение мат-

рицы $\mathbf{X}_k^\top \mathbf{X}_k$, а также значения $KL(k)$ и $S(k)$. Этот процесс повторялся $B = 100$ раз для обеспечения статистической надежности результатов.

На рис. 4.8 показано асимптотическое поведение минимального собственного значения матрицы $\mathbf{X}_k^\top \mathbf{X}_k$ при увеличении размера выборки. Наблюдается, что при стремлении размера выборки к бесконечности минимальное собственное значение также стремится к бесконечности. При этом, как и требуется для теоремы 31, график лежит выше $\sqrt{k}$.

На рис. 4.9 представлены зависимости между доступным размером выборки k и предложенными функциями $KL(k)$ и $S(k)$ для синтетического набора данных регрессии. На рис. 4.10 представлены аналогичные графики для набора данных Liver Disorders. Наблюдается, что в обоих случаях значение $KL(k)$ приближается к нулю с увеличением размера выборки, а $S(k)$ стремится к единице. Эти эмпирические результаты подтверждают полученные ранее теоретические выводы.

В определениях KL-достаточности и S-достаточности присутствует гиперпараметр ϵ , который соответствует порогу для достаточного размера выборки m^* . На рис. 4.11 показана зависимость между уровнем достоверности и размером выборки. Для сравнения предложенных методов с базовыми использовалась следующая схема эксперимента. Модель машинного обучения — линейная регрессия. Выбрано 4 набора данных с задачей регрессии из открытых источников: Boston, Diabetes, Forestfires и Servo. Их описательная статистика представлена в Таблице 4.5. К данным применяются 9 различных базовых методов оценки размера выборки: Тест множителей Лагранжа, Тест отношения правдоподобий, Тест Вальда, Кросс-валидация, Бутстрэп, Критерий средней апостериорной дисперсии (APVC), Критерий среднего покрытия (ACC), Критерий средней длины (ALC) и Функция полезности.

Далее в экспериментах достаточность определяется в терминах относительного изменения, а именно, размер выборки достаточным, если функция $KL(k)$ имеет относительное отклонение от своего значения на всей выборке не более

чем ε . Аналогично с функцией $S(k)$, зафиксировав $\varepsilon = 0.05$ получаем результирующие размеры выборок.

Результаты в Таблице 4.6 указывают на то, что критерий на основе расхождения Кульбака-Лейблера является более консервативным и требует большего размера выборки, в то время как критерий S-достаточности предполагает, что минимального размера выборки может быть достаточно. Предполагается, что это типичный результат для функции схожести s-score, которая была разработана для сравнения различных моделей машинного обучения, особенно в случаях с неинформативными распределениями. Если распределения имеют высокую дисперсию, функция близости приближается к единице, что приводит к тому, что критерий считает достаточным даже небольшой размер выборки.

Далее проводится комплексный анализ различных методов определения размера выборки. Анализируется зависимость достаточного размера выборки от объема доступного набора данных. В частности, при увеличении объема доступной выборки вычисляется достаточный размер на основе различных методов. Результаты представлены на рис. 4.12, который сравнивает вышеупомянутые методы с точки зрения их консервативности.

Наблюдается, что S-достаточный размер выборки часто является минимальным. KL-достаточный размер выборки, как правило, требует почти полной выборки. Предполагается, что это связано с тем, что расхождение Кульбака-Лейблера чрезвычайно чувствительно к изменениям математического ожидания и дисперсии сравниваемых распределений. Таким образом, стабилизация расстояния между ними достигается лишь при больших объемах выборки.

4.7. Заключение

В настоящей главе построены и проанализированы методы определения достаточного размера выборки m^* на основе наблюдаемых характеристик обучения. Эти методы дополняют формализм сложности модели и данных из глав 2

и 3 в постановках, где прямая оценка ландшафтной меры через матрицы Гессе затруднена.

Рассмотрены классические статистические, эвристические и байесовские подходы. Их ограничения связаны с необходимостью знать дисперсию или параметр нецентральности, отсутствием явных процедур их оценки и вычислительной сложностью для моделей с большим числом параметров.

Основные теоретические результаты главы относятся к двум классам критериев, основанных на стабилизации процесса обучения.

Первый класс использует функцию правдоподобия при изменении объема данных: D-достаточность (дисперсия правдоподобия на бутстрэп-подвыборках) и M-достаточность (разность средних значений правдоподобия при добавлении объекта). Теорема 28 устанавливает сходимость критерия M-достаточности для линейной регрессии при сходимости моментов оценок параметров; следствие 9 описывает условия сходимости к истинным параметрам и информационной матрице Фишера.

Второй класс использует близость апостериорных распределений на подвыборках, отличающихся одним объектом: KL-достаточность и S-достаточность (s-score). Теорема 31 для линейной регрессии с нормальным априорным распределением задает достаточные условия сходимости моментов апостериора при росте $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)$ как $\omega(\sqrt{k})$.

Численные эксперименты на синтетических данных и наборах Liver Disorders, Boston Housing, Diabetes, Forest Fires, Servo согласуются с теорией: $D(k)$, $M(k)$ и $KL(k)$ убывают к нулю, $S(k)$ стремится к единице. В сравнении с классическими методами KL-критерий обычно консервативнее, а S-достаточность чаще указывает на меньшие объемы; это связано с различной чувствительностью мер близости распределений.

В экспериментах для критериев по правдоподобию использовались относительные отклонения порядка 0,05–0,1 и бутстрэп с $B = 1000$; для S-достаточности — порог $\varepsilon = 0,05$. Перенос обоснования на нейронные сети, отказ

от нормальности апостериора и согласование критериев с ландшафтной мерой сложности остаются направлениями дальнейшего анализа.

Глава 5

Методы снижения сложности моделей

В настоящей главе рассматриваются методы снижения сложности параметрических моделей глубокого обучения. Цель — уменьшить число обучаемых параметров или использовать передачу информации между моделями так, чтобы качество аппроксимации на целевой задаче сохранялось в приемлемых пределах.

Рассматриваются четыре направления: удаление параметров по ковариации градиентов функции ошибки, байесовская дистилляция, многодоменная дистилляция и антидистилляция. Методы опираются на аппарат глав 2 и 3. Байесовская дистилляция развивается из кандидатской постановки и не выносятся отдельным положением на защиту докторской работы; на защиту опираются прореживание по ковариации градиентов, многодоменная дистилляция и антидистилляция.

5.1. Удаление параметров по ковариации градиентов

В настоящем разделе рассматривается удаление параметров по ковариационной матрице градиентов функции ошибки. Параметры упорядочиваются по вкладу в эту матрицу; наименее существенные удаляются при контроле качества модели.

Рассмотрим выборку:

$$\mathfrak{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m, \quad \mathbf{x}_i \in \mathbb{X} = \mathbb{R}^n, \quad y_i \in \mathbb{Y},$$

где n — размерность признакового пространства, m — число объектов в выборке. Пространство ответов $\mathbb{Y} = \mathbb{R}$ в случае задачи регрессии и $\mathbb{Y} = \{1, \dots, R\}$ в случае задачи классификации, где R — число классов.

Определим семейство моделей параметрических функций с заранее задан-

ной структурой:

$$\begin{aligned}\mathfrak{F} &= \{f(\mathbf{w}) : \mathbb{X} \rightarrow \mathbb{Y} | \mathbf{w} \in \mathbb{R}^p\}, \\ \mathbf{h}(\mathbf{w}, \mathbf{x}) &= \mathbf{W}_1 \boldsymbol{\sigma}(\mathbf{W}_2 \boldsymbol{\sigma}(\dots \boldsymbol{\sigma}(\mathbf{W}_r \mathbf{x}) \dots)), \\ f_{\text{cl}}(\mathbf{w}, \mathbf{x}) &= \arg \max_{j \in \{1, \dots, R\}} \text{softmax}(\mathbf{h}(\mathbf{w}, \mathbf{x}))_j, \\ f_{\text{reg}}(\mathbf{w}, \mathbf{x}) &= \mathbf{h}(\mathbf{w}, \mathbf{x}),\end{aligned}$$

где p — размерность пространства параметров, r — число слоев нейросети, $\mathbf{w} = \text{vec}[\mathbf{W}_1, \mathbf{W}_2, \dots, \mathbf{W}_r]$, а $\boldsymbol{\sigma}$ — функция активации. В случае задачи регрессии структура модели имеет вид f_{reg} , а в случае классификации имеет вид f_{cl} . Определим функцию потерь:

$$\begin{aligned}\mathcal{L}(\mathbf{w}, \mathfrak{D}) &= \frac{1}{m} \sum_{i=1}^m l(\mathbf{x}_i, y_i, \mathbf{w}), \\ l_{\text{reg}}(\mathbf{x}, y, \mathbf{w}) &= (y - f(\mathbf{w}, \mathbf{x}))^2, \\ l_{\text{cl}}(\mathbf{x}, y, \mathbf{w}) &= - \sum_{j=1}^R ([y = j] \ln \text{softmax}_j(\mathbf{h}(\mathbf{w}, \mathbf{x}))),\end{aligned}$$

где l_{reg} — это функция ошибки на одном элементе для задачи регрессии, l_{cl} — для задачи классификации. Оптимальный вектор параметров $\hat{\mathbf{w}}$ получается минимизацией функции потерь:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w} \in \mathbb{R}^p} \mathcal{L}(\mathbf{w}, \mathfrak{D}).$$

Для поиска оптимальных параметров модели используется градиентный метод оптимизации:

$$\mathbf{w}_t = \mathbf{w}_{t-1} + \Delta \mathbf{w}(\mathbf{g}_{S,t}, \mathbf{w}_{t-1}, \mathbf{w}_{t-2}, \dots), \quad \mathbf{g}_{S,t} = \frac{\partial \mathcal{L}(\mathbf{w}_t, \mathbf{X}_S, \mathbf{Y}_S)}{\partial \mathbf{w}}, \quad (5.1)$$

где t — номер итерации, $\mathbf{g}_{S,t}$ — значение градиента на подвыборке размера S , $\Delta \mathbf{w}$ — приращение вектора параметров.

Порядок на множестве параметров модели задается при помощи ковариационной матрицы $\mathbf{C}$ градиентов функции ошибки $\mathcal{L}$ по параметрам модели

$\mathbf{w}$. Для вычисления ковариационной матрицы $\mathbf{C}$ используется итерационная формула [146], вычисляемая на каждой итерации (5.1) градиентного метода оптимизации параметров:

$$\mathbf{C}_t = (1 - \kappa_t) \mathbf{C}_{t-1} + \kappa_t (\mathbf{g}_{1,t} - \mathbf{g}_{S,t}) (\mathbf{g}_{1,t} - \mathbf{g}_{S,t})^\top,$$

где t — номер итерации, $\mathbf{g}_{S,t}$ — значение градиента на подвыборке размера S , $\mathbf{g}_{1,t}$ — значение градиента на первом элементе подвыборки, $\kappa_t = \frac{1}{t}$ — параметр сглаживания, $\mathbf{C}_0$ инициализируются из равномерного распределения.

Пусть известно t_0 — число итераций, после которого все параметры находятся в некоторой локальной окрестности минимума, тогда, как показано в работе [146], матрица $\mathbf{C}_{t_0}$ аппроксимирует истинную ковариационную матрицу $\mathbf{C}$. Ковариационная матрица $\mathbf{C}_{t_0}$ используется для упорядочения параметров модели $\mathbf{w}_{t_0}$.

Пусть $\mathcal{I}$ — упорядоченный вектор индексов $[1, 2, \dots, p]$. Обозначим $\mathcal{I}_{\mathbf{w}_{t_0}}$ вектор индексов, порядок которого задан при помощи ковариационной матрицы $\mathbf{C}_{t_0}$.

Например, если ковариационная матрица $\mathbf{C}_{t_0}$ имеет вид

$$\begin{bmatrix} 0,3 & 0 & 0 \\ 0 & 0,2 & 0 \\ 0 & 0 & 0,25 \end{bmatrix},$$

то вектор индексов $\mathcal{I}_{\mathbf{w}_{t_0}} = [3, 1, 2]$.

Для фиксации параметров $\mathbf{w}_{t_0}$ при помощи вектора индексов $\mathcal{I}_{\mathbf{w}_{t_0}}$ используется бинарный вектор $\boldsymbol{\alpha}(\zeta)$:

$$\alpha_i(\zeta) = \begin{cases} 1, & \text{если } \mathcal{I}_{\mathbf{w}_{t_0}}[j] \leq \zeta; \\ 0 & \text{иначе,} \end{cases} \quad (5.2)$$

где ζ — число фиксирующих параметров.

Учитывая (5.2), уравнение (5.1) приводится к виду

$$\mathbf{w}_t = \mathbf{w}_{t-1} + \boldsymbol{\alpha}(\zeta) \cdot \Delta \mathbf{w}(\mathbf{g}_{S,t}, \mathbf{w}_{t-1}, \mathbf{w}_{t-2}, \dots),$$

где t — номер итерации, $\mathbf{g}_{S,t}$ — значение градиента на подвыборке размера S , $\Delta \mathbf{w}$ — приращение вектора параметров. После умножения на бинарный вектор $\boldsymbol{\alpha}$ часть параметров не оптимизируется, что приводит к фиксации параметров.

Предлагается метод, основанный на модификации метода Белсли. Пусть $\mathbf{w}$ — вектор параметров, доставляющий минимум функционалу потерь $\mathcal{L}$ на множестве $\mathbb{W}_{\mathcal{A}}$, а $\mathbf{A}_{\text{ps}}$ — соответствующая ему ковариационная матрица.

Выполним сингулярное разложение матрицы

$$\mathbf{A}_{\text{ps}} = \mathbf{U} \boldsymbol{\Lambda} \mathbf{V}^{\top}.$$

Индекс обусловленности η_j определим как отношение максимального элемента к j -му элементу матрицы $\boldsymbol{\Lambda}$. Для нахождения мультиколлинеарных признаков требуется найти индекс ξ вида:

$$\xi = \arg \max_{j \in \mathcal{A}} \eta_j.$$

Таблица 5.1: Индексы обусловленности η и дисперсионные доли q_j для синтетических данных, демонстрирующие работу метода Белсли. Максимальный индекс обусловленности $\eta_6 = 1.2 \cdot 10^{16}$ соответствует максимальным дисперсионным долям признаков с индексами 1 и 4, которые являются линейно зависимыми.

η	q_1	q_2	q_3	q_4	q_5	q_6
1.0	$2 \cdot 10^{-17}$	$4 \cdot 10^{-17}$	$1 \cdot 10^{-16}$	$2 \cdot 10^{-17}$	$6 \cdot 10^{-17}$	$3 \cdot 10^{-4}$
1.5	$5 \cdot 10^{-17}$	$9 \cdot 10^{-17}$	$2 \cdot 10^{-16}$	$5 \cdot 10^{-17}$	$3 \cdot 10^{-20}$	$3 \cdot 10^{-2}$
3.3	$9 \cdot 10^{-18}$	$1 \cdot 10^{-17}$	$2 \cdot 10^{-17}$	$9 \cdot 10^{-18}$	$2 \cdot 10^{-19}$	$9 \cdot 10^{-1}$
$2 \cdot 10^{15}$	$1 \cdot 10^{-2}$	$1 \cdot 10^{-1}$	$8 \cdot 10^{-1}$	$2 \cdot 10^{-3}$	$9 \cdot 10^{-2}$	$1 \cdot 10^{17}$
$8 \cdot 10^{15}$	$6 \cdot 10^{-2}$	$8 \cdot 10^{-1}$	$9 \cdot 10^{-2}$	$8 \cdot 10^{-2}$	$9 \cdot 10^{-1}$	$2 \cdot 10^{17}$
$1 \cdot 10^{16}$	$9 \cdot 10^{-1}$	$1 \cdot 10^{-2}$	$4 \cdot 10^{-2}$	$9 \cdot 10^{-1}$	$1 \cdot 10^{-3}$	$5 \cdot 10^{-21}$

Дисперсионный доленой коэффициент q_{ij} определим как вклад j -го признака в дисперсию i -го элемента вектора параметра $\mathbf{w}$:




Рис. 5.1: Иллюстрация метода Белсли для анализа мультиколлинеарности параметров на синтетических данных. Слева показана матрица ковариации параметров, справа — дисперсионные доли, демонстрирующие вклад каждого признака в дисперсию параметров модели.

$$q_{ij} = \frac{u_{ij}^2 / \lambda_{jj}}{\sum_{j=1}^n u_{ij}^2 / \lambda_{jj}}.$$

Большие значения дисперсионных долей указывают на наличие зависимости между параметрами. Находим долевые коэффициенты, вносящие максимальный вклад в дисперсию параметра w_ξ :

$$\zeta = \arg \max_{j \in \mathcal{A}} q_{\xi j}.$$

Параметр с индексом ζ определяется как наименее релевантный параметр нейросети.

Проиллюстрируем принцип работы метода Белсли на примере. Гипотеза

порождения данных:

$$\mathbf{w} = \begin{bmatrix} \sin(x) \\ \cos(x) \\ 2+\cos(x) \\ 2+\sin(x) \\ \cos(x) + \sin(x) \\ x \end{bmatrix}$$

с матрицей ковариации на рис. 5.1.a, где $x \in [0.0, 0.02, \dots, 20.0]$.

В таблице 5.1 приведены индексы обусловленности и соответствующие им дисперсионные доли, изображенные на рис. 5.1.b. Согласно этим данным, максимальный индекс обусловленности $\eta_6 = 1.2 \cdot 10^{16}$. Ему соответствуют максимальные дисперсионные доли признаков с индексами 1 и 4, которые, согласно построению выборки, являются линейно зависимыми.

5.2. Байесовская дистилляция

Раздел развивает кандидатскую постановку и не выносится отдельным положением на защиту докторской работы. В настоящем разделе рассматривается байесовская постановка дистилляции, в которой информация от модели учителя передается модели ученика не только через ответы модели, но и через априорное распределение параметров ученика. Пусть задана выборка

$$\mathfrak{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m,$$

модель учителя $\mathbf{f}$ с вектором параметров $\mathbf{u} \in \mathbb{R}^{N_{\text{tr}}}$ и модель ученика $\mathbf{g}$ с вектором параметров $\mathbf{w} \in \mathbb{R}^{N_{\text{st}}}$. Обозначим через $n_t^{(\text{tr})}$ и $n_t^{(\text{st})}$ размеры соответствующих слоев учителя и ученика. В байесовской постановке априорное распределение параметров ученика $p(\mathbf{w}|\mathbf{A})$ задается с учетом апостериорного распределения параметров учителя $p(\mathbf{u}|\mathfrak{D})$, где $\mathbf{A}$ — параметры априорного распределения ученика.

Маргинальное правдоподобие модели ученика имеет вид

$$\mathcal{M}(\mathcal{D}, \mathbf{A}) = \log p(\mathcal{D}|\mathbf{A}) = \log \int_{\mathbf{w} \in \mathbb{R}^{N_{\text{st}}}} p(\mathcal{D}|\mathbf{w}) p(\mathbf{w}|\mathbf{A}) d\mathbf{w}.$$

Так как прямое вычисление интеграла обычно затруднительно, используется вариационное распределение $q(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$, аппроксимирующее апостериорное распределение параметров ученика. Оптимизация параметров записывается как

$$\hat{\boldsymbol{\mu}}, \hat{\boldsymbol{\Sigma}} \in \arg \min_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} \left(D_{\text{KL}}(q(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) \| p(\mathbf{w}|\mathbf{A})) - \mathbb{E}_{\mathbf{w} \sim q(\cdot|\boldsymbol{\mu}, \boldsymbol{\Sigma})} \left[\sum_{i=1}^m \log p(y_i|\mathbf{x}_i, \mathbf{w}) \right] \right),$$

где функцию $q(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$ обычно выбирают из экспоненциального семейства (например, нормальное распределение), а ожидание по q оценивают методом репараметризации или однотоочечным приближением.

Если структуры учителя и ученика совпадают, то априорное распределение параметров ученика можно задавать непосредственно через апостериорное распределение параметров учителя:

$$p(\mathbf{w}|\mathbf{A}) = p(\mathbf{u}|\mathcal{D}).$$

Если архитектуры различаются, требуется выравнивание пространств параметров. Ниже приведены два частных случая такого выравнивания для полносвязных нейронных сетей.

Теорема 32 (Распределение параметров при удалении нейрона). *Пусть выполняются условия:*

1) апостериорное распределение параметров модели учителя имеет вид

$$p(\mathbf{u}|\mathcal{D}) = \mathcal{N}(\mathbf{m}, \boldsymbol{\Sigma});$$

2) число слоев модели учителя равно числу слоев модели ученика: $T = L$;

3) размеры соответствующих слоев удовлетворяют условию $n_t^{(\text{tr})} \geq n_t^{(\text{st})}$.

Пусть преобразование $\phi(t, \mathbf{u})$ удаляет один нейрон из t -го слоя модели учителя, а $\mathbf{v} = \phi(t, \mathbf{u})$ — вектор оставшихся параметров. Тогда распределение параметров после такого преобразования также является нормальным:

$$p(\mathbf{v}|\mathcal{D}) = \mathcal{N}(\boldsymbol{\mu}_v, \boldsymbol{\Xi}_{v,v}).$$

При этом параметры условного нормального распределения вычисляются как

$$\boldsymbol{\mu} = \mathbf{m}_{\bar{\nu}_1} + \boldsymbol{\Sigma}_{\bar{\nu}_1, \nu_1} \boldsymbol{\Sigma}_{\nu_1, \nu_1}^{-1} (\mathbf{0} - \mathbf{m}_{\nu_1}),$$

$$\boldsymbol{\Xi} = \boldsymbol{\Sigma}_{\bar{\nu}_1, \bar{\nu}_1} - \boldsymbol{\Sigma}_{\bar{\nu}_1, \nu_1} \boldsymbol{\Sigma}_{\nu_1, \nu_1}^{-1} \boldsymbol{\Sigma}_{\nu_1, \bar{\nu}_1},$$

где ν_1 — зануляемые параметры, ν_2 — удаляемые параметры, $\bar{\nu}_1 = [\nu^\top, \nu_2^\top]^\top$, а $\boldsymbol{\mu}_v$ и $\boldsymbol{\Xi}_{v,v}$ являются соответствующими подвектором и подматрицей.

Доказательство теоремы приведено в работе [34].

Теорема 33 (Распределение параметров при удалении слоя). Пусть выполняются условия:

1) апостериорное распределение параметров модели учителя имеет вид

$$p(\mathbf{u}|\mathfrak{D}) = \mathcal{N}(\mathbf{m}, \boldsymbol{\Sigma});$$

2) размеры соседних слоев модели учителя совпадают, $n_t^{(\text{tr})} = n_{t-1}^{(\text{tr})}$, то есть матрица $\mathbf{U}_t$ является квадратной;

3) функция активации удовлетворяет свойству идемпотентности $\boldsymbol{\sigma} \circ \boldsymbol{\sigma} = \boldsymbol{\sigma}$.

Пусть преобразование $\boldsymbol{\psi}(t, \mathbf{u})$ удаляет t -й слой модели учителя, а $\mathbf{v} = \boldsymbol{\psi}(t, \mathbf{u})$ — вектор оставшихся параметров. Тогда апостериорное распределение оставшихся параметров также является нормальным:

$$p(\mathbf{v}|\mathfrak{D}) = \mathcal{N}(\mathbf{m}_v + \boldsymbol{\Sigma}_{v, \bar{v}} \boldsymbol{\Sigma}_{\bar{v}, \bar{v}}^{-1} (\mathbf{i} - \mathbf{m}_{\bar{v}}), \\ \boldsymbol{\Sigma}_{v,v} - \boldsymbol{\Sigma}_{v, \bar{v}} \boldsymbol{\Sigma}_{\bar{v}, \bar{v}}^{-1} \boldsymbol{\Sigma}_{\bar{v}, v}),$$

где $\bar{v}$ — вектор параметров удаляемого слоя, а

$$\mathbf{i} = [\underbrace{1, 0, \dots, 0}_{n_t}, \underbrace{0, 1, \dots, 0}_{n_t}, \dots, \underbrace{0, \dots, 1}_{n_t}]^\top.$$

Доказательство теоремы приведено в работе [34].

Для численной проверки байесовской дистилляции сравниваются три варианта модели ученика: обучение без дистилляции со стандартным нормальным априорным распределением, дистилляция только математического ожидания

апостериорного распределения учителя и полная дистилляция математического ожидания и ковариационной матрицы. В качестве интегрального критерия используется преимущество дистиллированной модели по логарифму правдоподобия вдоль траектории оптимизации:

$$S = \sum_s [\log p(\mathbf{y}|\mathbf{X}, \mathbf{w}_{\text{ds}}^s) - \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}_s^s)],$$

где $\mathbf{w}_s^s$ и $\mathbf{w}_{\text{ds}}^s$ — параметры обычной и дистиллированной модели ученика после s -й итерации оптимизации. Положительное значение S означает, что дистиллированная модель имеет большее правдоподобие на траектории обучения.

Результаты показывают, что задание априорного распределения параметров ученика на основе апостериорного распределения учителя повышает правдоподобие модели ученика и ускоряет стабилизацию вариационной оптимизации. При этом основной вклад в качество дистилляции в рассмотренных экспериментах дает перенос математического ожидания апостериорного распределения, тогда как учет ковариационной матрицы уточняет результат.

5.3. Многодоменная дистилляция

В настоящем разделе рассматривается метод дистилляции моделей глубокого обучения на многодоменных данных. В отличие от классической дистилляции, где модель учителя и модель ученика обучаются на данных из одного домена, предлагаемый метод позволяет передавать знания между моделями, обученными на данных из различных доменов, связанных инъективным отображением.

Определение 29 (Близкие генеральные совокупности). *Генеральная совокупность объектов B называется близкой к генеральной совокупности A , если существует инъективное отображение $\varphi : A \rightarrow B$.*

Предлагается использовать, помимо меток учителя на одном из доменов, связь между доменами при обучении модели ученика. В этом случае в качестве доменов должны выступать близкие генеральные совокупности.

Таблица 5.2: Сравнение моделей ученика с априорным распределением, заданным на основе апостериорного распределения параметров учителя

Эксперимент	Учитель	Ученик	S для полной дистилляции
Синтетическая выборка, удаление нейронов	6050 параметров	210 параметров	16864
Синтетическая выборка, удаление слоя	6050 параметров	550 параметров	25506
Fashion-MNIST, удаление слоя	667700 параметров	39700 параметров	1145

На рис. 5.2 показан процесс обучения модели ученика в базовой постановке задачи дистилляции. Модель учителя обучается на большом наборе данных из генеральной совокупности A , затем ее выходы используются для обучения модели ученика на меньшем наборе данных из того же домена. На рис. 5.3 представлен предложенный метод, задействующий выходы модели учителя, обученной на другом домене, и связь между доменами.




Рис. 5.2: Схема базовой дистилляции моделей глубокого обучения, где модель учителя обучается на большом наборе данных из генеральной совокупности A , а затем ее выходы используются для обучения модели ученика на меньшем наборе данных из того же домена.




Рис. 5.3: Схема дистилляции моделей глубокого обучения с доменной адаптацией, где модель учителя обучается на данных из домена A , а модель ученика — на данных из домена B , связанных инъективным отображением φ .

Рассмотрим базовую постановку задачи дистилляции. Задан набор данных

$$\mathfrak{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^n, \quad \mathbf{x}_i \in \mathbb{X}, \quad \mathbf{y}_i \in \{1, \dots, R\},$$

где R — количество классов в задаче классификации.

Предполагается, что задана обученная модель с большим количеством параметров — модель учителя. Требуется обучить модель ученика с меньшим количеством параметров, учитывая ответы учителя. Модель учителя $\mathbf{f}$ и модель ученика $\mathbf{g}$ принадлежат параметрическому семейству функций:

$$\mathfrak{F} = \{\mathbf{f} | \mathbf{f} = \text{softmax}(\mathbf{v}(\mathbf{x})/T), \mathbf{v} : \mathbb{R}^n \rightarrow \mathbb{R}^R\},$$

где $\mathbf{v}$ — дифференцируемая параметрическая функция заданной структуры, T — параметр температуры, используемый для сглаживания распределения веро-

ятностей.

Функция потерь $\mathcal{L}$, учитывающая модель учителя $\mathbf{f}$ при выборе модели ученика $\mathbf{g}$, имеет вид:

$$\begin{aligned}\mathcal{L}(\mathbf{w}, \mathbf{X}, \mathbf{Y}, \mathbf{f}) = & - \sum_{i=1}^m \sum_{r=1}^R y_i^r \log g^r(x_i) \Big|_{T=1} \\ & - \sum_{i=1}^m \sum_{r=1}^R f^r(x_i) \Big|_{T=T_0} \log g^r(x_i) \Big|_{T=T_0},\end{aligned}$$

где $\cdot|_{T=t}$ означает, что параметр температуры T в предыдущей функции равен t . Первое слагаемое в функции потерь соответствует стандартной задаче классификации с температурой $T = 1$, второе слагаемое — дистилляции с температурой $T = T_0$, где $T_0 > 1$ позволяет получить более мягкое распределение вероятностей от модели учителя.

Задача оптимизации формулируется следующим образом:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w} \in \mathbb{W}} \mathcal{L}(\mathbf{w}, \mathbf{X}, \mathbf{Y}, \mathbf{f}).$$

Перейдем к постановке задачи дистилляции для многодоменной выборки. Даны две выборки:

$$\mathfrak{D}_s = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^n, \quad \mathbf{x}_i \in \mathbb{X}_s, \quad \mathbf{y}_i \in \mathbb{Y}$$

$$\mathfrak{D}_t = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m, \quad \mathbf{x}_i \in \mathbb{X}_t, \quad \mathbf{y}_i \in \mathbb{Y},$$

где $\mathfrak{D}_s, \mathfrak{D}_t$ — исходный и целевой наборы данных. В базовой постановке задачи дистилляции предполагается, что $\mathfrak{D}_t \subset \mathfrak{D}_s, \mathbb{X}_t = \mathbb{X}_s$. Предполагается, что количество объектов в наборах данных не совпадает:

$$n \gg m$$

Пусть задана модель учителя на выборке большей мощности:

$$\mathbf{f} : \mathbb{X}_s \rightarrow \mathbb{Y}',$$

где $\mathbf{f}$ — модель учителя, $\mathbb{Y}'$ — пространство вероятностей классов.

Связь между исходной и целевой выборками задается:

$$\varphi : \mathbb{X}_t \rightarrow \mathbb{X}_s,$$

где φ — инъективное отображение. Требуется получить модель ученика для малоресурсной выборки:

$$\mathbf{g} : \mathbb{X}_t \rightarrow \mathbb{Y}',$$

где $\mathbf{g}$ — модель ученика.

В работе рассматривается функция потерь, учитывающая метки учителя и связь между доменами:

$$\begin{aligned} \mathcal{L}(\mathbf{w}, \mathbf{X}, \mathbf{Y}, \mathbf{f}, \varphi) = & \\ & - \lambda \sum_{i=1}^m \sum_{r=1}^R \mathbb{I}[y_i = r] \log g^r(\mathbf{x}_i, \mathbf{w}) \\ & - (1 - \lambda) \sum_{i=1}^m \sum_{r=1}^R (f \circ \varphi)^r(\mathbf{x}_i) \log g^r(\mathbf{x}_i, \mathbf{w}), \end{aligned}$$

где λ — метапараметр, задающий вес дистилляции, $\mathbb{I}$ — индикаторная функция.

Задача оптимизации для многодоменной дистилляции формулируется следующим образом:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w} \in \mathbb{W}} \mathcal{L}(\mathbf{w}, \mathbf{X}, \mathbf{Y}, \mathbf{f}, \varphi).$$

Функция потерь объединяет информацию от истинных меток и от модели учителя, примененной к преобразованным данным другого домена.

5.4. Антидистилляция

В настоящем разделе описывается постановка задачи антидистилляции для задачи классификации. В отличие от классической дистилляции, где знания передаются от более сложной модели к более простой, антидистилляция решает обратную задачу: передачу знаний от простой модели к более сложной для работы с более сложными наборами данных. Аналогичный подход может быть применен для произвольных задач машинного обучения.

Даны два набора данных

$$\begin{aligned}\mathfrak{D}_1 &= \{(\mathbf{x}_i, y_i)\}_{i=1}^{m_1}, \quad \mathbf{x}_i \in \mathbb{R}^n, \quad y_i \in C_1 = \{1, \dots, c_1\}, \\ \mathfrak{D}_2 &= \{(\mathbf{x}_i, y_i)\}_{i=1}^{m_2}, \quad \mathbf{x}_i \in \mathbb{R}^n, \quad y_i \in C_2 = \{1, \dots, c_2\},\end{aligned}$$

где m_1 и m_2 — количество объектов в $\mathfrak{D}_1$ и $\mathfrak{D}_2$ соответственно, n — размерность входного пространства. C_1 и C_2 — множества меток классов $1, \dots, c_1, \dots, c_2$.

Предполагается, что объекты $\mathbf{x}_i$ порождены из генеральной совокупности, общей для обоих наборов данных $\mathfrak{D}_1, \mathfrak{D}_2$, и имеют схожие свойства для этих наборов. Предполагается, что набор данных $\mathfrak{D}_2$ является более сложным для классификации и требует более сложной модели классификации.

Рассмотрим модель учителя $\mathbf{g}_{\text{tr}}$, обученную на первом наборе данных $\mathfrak{D}_1$:

$$\mathbf{g}_{\text{tr}} : \mathbb{R}^n \rightarrow \Delta^{c_1}, \quad \mathbf{g}_{\text{tr}}(\mathbf{x}) = \mathbf{g}(\mathbf{x}, \hat{\mathbf{u}}),$$

где Δ^c — множество c -мерных вероятностных векторов,

Параметры модели учителя $\mathbf{g}_{\text{tr}}$ определяются следующим образом:

$$\hat{\mathbf{u}} = \arg \min_{\mathbf{u}} \mathcal{L}_{\text{ce}}(\mathbf{u}, \mathfrak{D}_1) = \arg \min_{\mathbf{u}} \sum_{i=1}^{m_1} l(y_i, g(\mathbf{x}_i, \mathbf{u})),$$

здесь l — перекрестная энтропия:

$$l(y, \hat{y}) = - \sum_{k=1}^c [y = k] \log \hat{y}_k, \quad y \in C, \quad \hat{y} \in \Delta^c.$$

Задача состоит в построении модели ученика

$$\mathbf{f}_{\text{st}} : \mathbb{R}^n \rightarrow \Delta^{c_2}, \quad \mathbf{f}_{\text{st}}(\mathbf{x}) = \mathbf{f}(\mathbf{x}, \hat{\mathbf{w}}),$$

, минимизирующей перекрестную энтропию на валидационной части второго набора данных $\mathfrak{D}_2$

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \mathcal{L}_{\text{ce}}(\mathbf{w}, \mathfrak{D}_2^{\text{val}}),$$

, где $\mathfrak{D}_2 = \mathfrak{D}_2^{\text{train}} \sqcup \mathfrak{D}_2^{\text{val}}$ и $\hat{\mathbf{w}}$ — оптимальные параметры модели.

Поскольку валидационная функция потерь не оптимизируется напрямую, используются градиентные методы оптимизации на обучающей части $\mathfrak{D}_2^{\text{train}}$ набора данных $\mathfrak{D}_2$. Чтобы уменьшить переобучение и использовать больше информации о данных, используется информация от модели учителя $\mathbf{g}_{\text{tr}}$. Предполагается, что наборы данных $\mathfrak{D}_1$ и $\mathfrak{D}_2$ имеют общие свойства.

Функция

$$\varphi : \mathbb{R}^{N_{\text{tr}}} \rightarrow \mathbb{R}^{N_{\text{st}}}$$

отображает параметры модели учителя в начальные параметры модели ученика $\mathbf{w} = \varphi(\hat{\mathbf{u}})$.

Гипотеза 1. *Модели ученика, инициализированные результатом применения функции φ к параметрам предварительно обученной модели учителя, являются более устойчивыми и достигают более высокой точности, чем модели с параметрами по умолчанию.*

Основная проблема предложенного метода заключается в том, что модель учителя $\mathbf{g}_{\text{tr}}$, обученная на простом наборе данных $\mathfrak{D}_1$, может быть намного проще, чем модель ученика $\mathbf{f}_{\text{st}}$. Для использования большего объема информации из параметров модели учителя $\hat{\mathbf{u}}$ требуется расширить размерность пространства параметров модели учителя N_{tr} до размерности N_{st} пространства параметров модели ученика.

Для решения данной проблемы оптимизируется следующая составная функция потерь:

$$\varphi(\mathbf{u}) = \arg \min_{\mathbf{w} \in \mathbb{R}^{N_{\text{st}}}} \mathcal{L}(\mathbf{w}), \quad (5.3)$$

где

$$\mathcal{L}(\mathbf{w}) = \lambda_1 \mathcal{L}_{\text{ce}}(\mathbf{w}, \mathfrak{D}_1) + \lambda_2 \mathcal{L}_2(\mathbf{w}, \mathbf{u}) + \lambda_3 \mathcal{L}_3^\delta(\mathbf{w}, \mathfrak{D}_1) + \lambda_4 \mathcal{L}_4(\mathbf{w}),$$

$$\forall i \in \overline{1, 4} \lambda_i \geq 0$$

Первое слагаемое $\mathcal{L}_{\text{ce}}(\mathbf{w}, \mathfrak{D}_1)$ представляет собой перекрестную энтропию, отвечающую за качество модели ученика на простом наборе данных $\mathfrak{D}_1$. Это сла-

гаемое обеспечивает сохранение способности модели ученика решать исходную задачу классификации.

Второе слагаемое

$$\mathcal{L}_2(\mathbf{w}, \mathbf{u}) = \|\mathbf{u} - \mathbf{Pr}[\mathbf{w}]\|_2^2$$

обеспечивает близость параметров модели учителя и модели ученика в соответствующих местах, где $\mathbf{Pr}$ — оператор проекции, выбирающий только первые параметры, общие для обеих моделей. В случае моделей многослойного перцептрона оператор $\mathbf{Pr}$ выбирает параметры тех же нейронов для каждого слоя модели. Данное слагаемое способствует передаче знаний от модели учителя к модели ученика через близость параметров.

Третье слагаемое

$$\mathcal{L}_3^\delta(\mathbf{w}, \mathfrak{D}_1) = \sum_{(\mathbf{x}, y) \in \mathfrak{D}_1} \mathbb{E}_{\mathbf{x}' \in U_\delta(\mathbf{x})} \mathcal{L}_{ce}(\mathbf{w}, \mathbf{x}', y)$$

отвечает за устойчивость решения к шуму во входных данных, где $U_\delta(\mathbf{x})$ представляет равномерное распределение в окрестности $[\delta - \mathbf{x}, \delta + \mathbf{x}]$. Данное слагаемое обеспечивает сглаживание функции потерь в окрестности обучающих примеров, что повышает устойчивость модели к небольшим искажениям входных данных.

Четвертое слагаемое

$$\mathcal{L}_4(\mathbf{w}) = \text{tr} \left(\frac{\partial^2 \mathcal{L}_{ce}}{\partial \mathbf{w}^2} \right)$$

выполняет регуляризацию гессиана функции потерь, что способствует нахождению решений в более плоских областях ландшафта функции потерь и повышает устойчивость модели к возмущениям параметров.

Последнее слагаемое $\mathcal{L}_4$ включает вычисление гессиана, наивное вычисление которого может быть ресурсоемким. Для эффективного вычисления следа гессиана используется метод стохастической аппроксимации [147] с быстрым умножением гессиан-вектор [148]. Сложность такой процедуры линейна от количества параметров модели ученика $\mathbf{f}_{st}$.

В рассматриваемом случае антидистилляции подразумевается $\lambda_2 > 0$, то есть оптимизация, делающая параметры модели учителя и ученика достаточно близкими. Это обеспечивает передачу знаний от модели учителя к модели ученика через близость параметров.

Важным свойством модели является устойчивость к искажению входных данных. Для обеспечения этого свойства используются слагаемые $\mathcal{L}_3$ и $\mathcal{L}_4$. Оба этих слагаемых регулируют гессиан функции перекрестной энтропии [149, 150], способствуя нахождению решений в более плоских областях ландшафта функции потерь.

5.5. Вычислительные эксперименты

В настоящем разделе представлены результаты вычислительных экспериментов для методов снижения сложности моделей, описанных в предыдущих разделах главы. Эксперименты направлены на проверку предложенных методов и сравнение с базовыми подходами.

5.5.1. Эксперименты по удалению параметров

Для анализа свойств предложенного алгоритма и сравнения его с существующими подходами проведен вычислительный эксперимент, в котором параметры нейросети удалялись стандартными методами прореживания и методом Белсли.

В качестве данных использовались три выборки. Выборки Wine [151] и Boston Housing [143] представляют собой реальные данные, широко используемые в задачах машинного обучения. Синтетические данные сгенерированы таким образом, чтобы параметры сети были мультиколлинеарными, что позволяет проверить эффективность метода Белсли в условиях, для которых он был разработан. Генерация синтетических данных состояла из двух этапов. На

первом этапе генерировался вектор параметров $\mathbf{w}_{\text{synthetic}}$:

$$\mathbf{w}_{\text{synthetic}} \sim \mathcal{N}(\mathbf{m}_{\text{synthetic}}, \mathbf{A}_{\text{synthetic}}),$$

где $\mathbf{m}_{\text{synthetic}} = \begin{bmatrix} 1.0 \\ 0.0025 \\ \dots \\ 0.0025 \end{bmatrix}$, $\mathbf{A}_{\text{synthetic}} = \begin{bmatrix} 1.0 & 10^{-3} & \dots & 10^{-3} & 10^{-3} \\ 10^{-3} & 1.0 & \dots & 0.95 & 0.95 \\ \dots & \dots & \dots & \dots & \dots \\ 10^{-3} & 0.95 & \dots & 0.95 & 1.0 \end{bmatrix}$.

На втором этапе генерировалась выборка $\mathcal{D}_{\text{synthetic}}$:

$$\mathcal{D}_{\text{synthetic}} = \{(\mathbf{x}_i, y_i) | \mathbf{x}_i \sim \mathcal{N}(\mathbf{1}, \mathbf{I}), y_i = x_{i0}, i = 1 \dots 10000\}.$$

В приведенном выше векторе параметров $\mathbf{w}_{\text{synthetic}}$ для выборки $\mathcal{D}_{\text{synthetic}}$ наиболее релевантным является первый параметр, а все остальные параметры нерелевантны. Матрица ковариации выбрана таким образом, чтобы все нерелевантные параметры были зависимыми величинами, что приводит к максимальной эффективности метода Белсли.

Таблица 5.3: Характеристики выборок, использованных для анализа метода задания порядка параметров методом Белсли. Включает реальные данные (Wine для классификации, Boston Housing для регрессии) и синтетические данные с мультиколлинеарными параметрами.

Выборка	Тип задачи	Размер выборки	Число признаков
Wine	классификация	178	13
Boston Housing	регрессия	506	13
Synthetic data	регрессия	10000	100

Для всех алгоритмов тренировочная и тестовая выборки составили 80% и 20% соответственно. Критерием качества прореживания служит процент параметров нейросети, удаление которого не влечет значимой потери качества прогноза. Дополнительным критерием качества служит устойчивость нейросети к зашумленности данных.

Качеством прогноза R_{cl} модели для задачи классификации является точность прогноза модели:

$$R_{cl} = \frac{\sum_{(\mathbf{x}, y) \in \mathcal{D}} [f(\mathbf{x}, \mathbf{w}) = y]}{|\mathcal{D}|},$$

где $[\cdot]$ — индикаторная функция.

Качеством прогноза R_{rg} модели для задачи регрессии является среднеквадратическое отклонение результата модели от точного:

$$R_{rg} = \frac{\sum_{(\mathbf{x}, y) \in \mathcal{D}} (f(\mathbf{x}, \mathbf{w}) - y)^2}{|\mathcal{D}|}.$$

Для эксперимента на выборке Wine [151] рассматривается нейронная сеть с 13 нейронами на входе, 13 нейронами в скрытом слое и 3 нейронами на выходе.






Рис. 5.4: Зависимость точности классификации R_{cl} от процента удаленных параметров для различных методов прореживания на выборке Wine. Метод оптимального прореживания, вариационный метод и метод Белсли позволяют удалить $\approx 80\%$ параметров без существенной потери качества.


На рис. 5.4 показана зависимость точности прогноза R_{cl} от процента удаленных параметров для различных методов прореживания. Метод оптимального прореживания, вариационный метод и метод Белсли допускают удаление до $\approx 80\%$ параметров при умеренном изменении качества. При удалении $\approx 90\%$ параметров качество всех методов снижается.



(a) Произвольное удаление параметров



(b) Оптимальное прореживание



(c) Вариационный метод

Рис. 5.5: Поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для различных методов прореживания на выборке Wine. Метод Белсли демонстрирует наименьший уровень шума, что видно по более низкому положению соответствующей поверхности.

На рис. 5.5 показаны поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для разных методов прореживания. Анализ поверхностей показывает, что метод Белсли демонстрирует наименьший уровень шума в выходных данных по сравнению с другими методами, на что указывает более низкое положение соответствующей поверхности. Это указывает на меньшую чувствительность модели, полученной методом Белсли, к зашумлению входных данных.

Для эксперимента на выборке Boston Housing [143] рассматривается нейронная сеть с 13 нейронами на входе, 39 нейронами в скрытом слое и одним

нейроном на выходе.





Рис. 5.6: Зависимость среднеквадратического отклонения прогноза R_{rg} от процента удаленных параметров для различных методов прореживания на выборке Boston Housing. В этой постановке метод Белсли допускает удаление большей доли параметров при сопоставимом качестве.

На рис. 5.6 показана зависимость среднеквадратического отклонения прогноза R_{rg} от процента удаленных параметров для различных методов прореживания. По графику метод Белсли допускает удаление большей доли параметров при меньшей ошибке, чем сравниваемые методы.


На рис. 5.7 показаны поверхности изменения уровня шума ответов нейронной сети при изменении процента удаленных параметров и уровня шума входных данных для разных методов прореживания. Анализ показывает, что уровень шума всех методов примерно одинаковый, поскольку соответствующие поверхности находятся на близком уровне. Это указывает на то, что для данной задачи регрессии устойчивость к шуму во входных данных не зависит существенно от выбранного метода прореживания.

Для эксперимента на синтетических данных рассматривается нейронная сеть с 100 нейронами на входе и одним нейроном на выходе.


На рис. 5.8 показана зависимость среднеквадратического отклонения про-



(a) Произвольное удаление параметров



(b) Оптимальное прореживание



(c) Вариационный метод

Рис. 5.7: Поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для различных методов прореживания на выборке Boston Housing. Все методы демонстрируют одинаковый уровень шума, так как соответствующие поверхности находятся на одном уровне.

гноза от точного ответа от процента удаленных параметров для различных методов. По графику удаление параметров методом Белсли даёт меньшую ошибку, чем сравниваемые методы прореживания, в том числе при удалении шумовых параметров.

На рис. 5.9 показаны поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для разных методов прореживания. Анализ показывает, что метод Белсли демонстрирует наименьший уровень шума, поскольку соответствующая поверхность находится ниже других поверхностей. Это подтверждает эффективность




Рис. 5.8: Зависимость среднеквадратического отклонения прогноза от процента удаленных параметров для различных методов прореживания на синтетической выборке с мультиколлинеарными параметрами. Метод Белсли здесь даёт уменьшение ошибки при удалении шумовых параметров.


метода Белсли для работы с мультиколлинеарными параметрами, что соответствует его теоретическому обоснованию.

5.5.2. Эксперименты по многодоменной дистилляции


В настоящем подразделе представлены результаты вычислительных экспериментов для метода многодоменной дистилляции, описанного выше. Цель вычислительного эксперимента — сравнить производительность моделей учителя и ученика на реальных наборах данных с использованием отображения φ и без него для задач компьютерного зрения и обработки естественного языка. Для анализа качества дистилляции используется интегральный критерий качества [152].

Эксперименты проводятся на двух типах данных:


- Подмножество ImageNet [153] — набор изображений для задачи классификации на 10 классов. Набор данных состоит из обучающей и тестовой частей, причем обучающая часть разделена на мультиресурсную и мало-



(a) Произвольное удаление параметров



(b) Оптимальное прореживание



(c) Вариационный метод

Рис. 5.9: Поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для различных методов прореживания на синтетической выборке. Метод Белсли демонстрирует наименьший уровень шума, что видно по более низкому положению соответствующей поверхности.

ресурсную части, что позволяет моделировать сценарий передачи знаний от модели, обученной на большом наборе данных, к модели, обучаемой на малом наборе данных.

- OPUS-100 [154] — англоцентричный набор данных для машинного перевода, в котором все обучающие пары включают английский язык на стороне источника или цели. Используются языковые пары fr-en и de-en, что позволяет проверить эффективность многодоменной дистилляции при работе с различными языковыми парами.

Конфигурация алгоритма многодоменной дистилляции для задачи компьютерного зрения.

Таблица 5.4: Архитектура модели учителя для эксперимента по многодоменной дистилляции в задаче компьютерного зрения. Модель представляет собой сверточную нейронную сеть с пятью сверточными слоями и четырьмя полносвязными слоями, общее число параметров составляет 4 455 984.

Слой	Размер входного вектора	Количество параметров
Входной слой	(3, 200, 200)	0
CONV1 (ядро=5)	(24, 196, 196)	1800
POOL1	(24, 98, 98)	0
CONV2 (ядро = 5)	(48, 94, 94)	28800
POOL2	(48, 47, 47)	0
CONV3 (ядро = 8)	(96, 40, 40)	294912
POOL3	(96, 20, 20)	0
CONV4 (ядро = 5)	(192, 16, 16)	460800
POOL4	(192, 8, 8)	0
CONV5 (ядро = 7)	(384, 2, 2)	3612672
POOL5	(384, 1, 1)	0
Полносвязный слой	(384)	0
Полносвязный слой	(120)	46080
Полносвязный слой	(84)	10080
Полносвязный слой	(10)	840
		$\Sigma = 4455984$

Структуры модели учителя **f** и модели ученика **g** описаны в таблице 5.4 и таблице 5.5. Функция активации после каждого скрытого слоя — ReLu. Для решения задачи оптимизации используется метод градиентной оптимизации Adam [130].

В таблице 5.6 описаны наборы данных для вычислительного эксперимента по компьютерному зрению. Каждый из наборов данных состоит из обучающей

Таблица 5.5: Архитектура модели ученика для эксперимента по многодоменной дистилляции в задаче компьютерного зрения. Модель имеет упрощенную структуру по сравнению с моделью учителя, с двумя сверточными слоями и тремя полносвязными слоями, общее число параметров составляет 12 755 640.

Слой	Размер входного вектора	Количество параметров
Входный слой	(3, 200, 200)	0
CONV1 (ядро=5)	(24, 196, 196)	1800
POOL1	(24, 98, 98)	0
CONV2 (ядро = 5)	(48, 94, 94)	28800
POOL2	(48, 47, 47)	0
Полносвязный слой	(106032)	0
Полносвязный слой	(120)	12723840
Полносвязный слой	(10)	1200
		$\sum = 12755640$

Таблица 5.6: Характеристики подмножеств набора данных ImageNet, использованных в эксперименте по многодоменной дистилляции. ImageNet-Big содержит 1 281 167 изображений для обучения и 50 000 для валидации, ImageNet-Small — 64 058 и 2 500 соответственно, оба набора содержат 200 классов.

Набор данных	Описание	Размер набора
ImageNet-Train	Обучающая часть	9469
ImageNet-Big	Мультиресурсная часть	8469
ImageNet-Small	Малоресурсная часть	1000
ImageNet-Test	Тестовая часть	3925

и тестовой части, при этом обучающая часть разделена на мультиресурсную и малоресурсную части. Обучающая часть содержит 9 469 объектов, мультире-

сурсная часть содержит 8 469 объектов, малоресурсная часть содержит 1 000 объектов, а тестовая часть содержит 3 925 объектов.

Цель эксперимента — сравнить производительность модели ученика, обучающейся без учителя, с учителем и с учителем на другом домене с использованием адаптации домена. Экспериментальная процедура включает три этапа. На первом этапе обучается модель ученика на малоресурсной части и происходит ее тестирование на тестовой части для получения базовой оценки качества. На втором этапе используются метки модели учителя, обученной на мультиресурсной части, для обучения модели ученика. На третьем этапе происходит обучение модели учителя на изображениях из мультиресурсной части и используется модель учителя и отображение для обучения модели ученика. Предобученная модель CycleGAN [155] используется в качестве отображения φ для доменной адаптации.



Рис. 5.10: Пример применения инъективного отображения φ для доменной адаптации между ImageNet-Small и ImageNet-Big. Демонстрирует визуальное преобразование объекта из исходного домена в целевой домен для использования в многодоменной дистилляции.

На рис. 5.10 показано одно из изображений в наборе данных ImageNet [153] и то же изображение после преобразования с помощью модели CycleGAN [155]. Результаты усредняются по 5 запускам для вычисления среднего значения и дисперсии метрик.

Конфигурация алгоритма многодоменной дистилляции для задачи обработки естественного языка.

Набор данных OPUS-100 был разделен следующим образом: обучающая часть для учителя состояла из 5 000 немецко-английских предложений, обучающая часть для модели ученика — из 2 000 французско-английских предложений, тестовая часть — из 500 французско-английских предложений. Такое разделение позволяет проверить эффективность многодоменной дистилляции при работе с различными языковыми парами.

Таблица 5.7: Характеристики подмножеств набора данных OPUS-100, использованных в эксперименте по многодоменной дистилляции для задачи машинного перевода. Показаны размеры обучающих и валидационных выборок для языковых пар fr-en и de-en.

Набор данных	Описание	Язык	Размер набора
Teacher-Train	Обучающая часть модели учителя	de-en	5000
Student-Train	Обучающая часть модели ученика	fr-en	2000
Student-Test	Тестовая часть	fr-en	500

В таблице 5.7 описаны наборы данных для вычислительного эксперимента по обработке естественного языка.

Использовались модель ученика $\mathbf{g}$ и модель учителя $\mathbf{f}$ в качестве трансформерной модели на основе статьи [156] и метод градиентной оптимизации Adam [130] для решения задачи оптимизации. Модель NLLB [157] использовалась в качестве отображения φ , переводящего французские предложения в немецкие.

Аналогично эксперименту по компьютерному зрению, сравнивается производительность модели ученика без учителя, с учителем и с учителем и адаптацией домена. Результаты усреднялись по 5 запускам для вычисления среднего значения и дисперсии метрик, что обеспечивает статистическую надежность полученных оценок.

На рис. 5.11 и рис. 5.12 представлены результаты обучения моделей на на-




Рис. 5.11: Зависимость точности аппроксимации от числа эпох обучения на тестовой выборке ImageNet для различных методов дистилляции. Результаты усреднены по 5 запускам; выше показатели у вариантов с учителем и доменной адаптацией.




Рис. 5.12: Зависимость ошибки перекрестной энтропии между истинными и предсказанными метками от числа эпох обучения на тестовой выборке ImageNet для различных методов дистилляции. Результаты усреднены по 5 запускам и показывают снижение ошибки при использовании методов дистилляции.

боре данных ImageNet. Анализ графиков показывает, что модели, обученные с использованием учителя, дают более высокие значения точности и меньшие потери, чем модель без учителя. Модель ученика, обученная с использованием меток учителя на том же домене, даёт наибольшую точность и наименьшие потери среди рассмотренных вариантов, что ожидаемо, поскольку отсутствует необходимость в адаптации домена. Модель ученика, обученная с использованием меток учителя и адаптации домена, улучшает качество аппроксимации относительно модели без учителя, что согласуется с использованием меток учителя и доменной адаптации в этой постановке.

Таким образом, экспериментально показано, что дистилляция с использованием адаптации домена приводит к более эффективным нейронным сетям с меньшим количеством параметров, сохраняя при этом высокое качество аппроксимации.

Таблица 5.8: Сравнение качества моделей для задачи компьютерного зрения на наборе данных ImageNet. Показаны валидационная точность, потери и интегральный критерий для различных комбинаций учителя и ученика с использованием доменной адаптации и без нее, результаты усреднены по нескольким запускам.

Ученика	Учитель	Отображение φ	Точность	Потери перекрестной энтропии	Интегральный критерий
ImageNet-Small	—	—	$0,34 \pm 0,01$	$4,41 \pm 1,10$	$53,89 \pm 14,99$
ImageNet-Small	ImageNet-Big	StyleTransfer	$0,37 \pm 0,01$	$2,01 \pm 0,03$	$28,30 \pm 0,79$
ImageNet-Small	ImageNet-Big	—	$0,44 \pm 0,01$	$2,03 \pm 0,02$	$28,08 \pm 1,22$

В таблице 5.8 представлены количественные результаты эксперимента по компьютерному зрению: валидационная точность, потери и интегральный критерий для моделей, обученных с дистилляцией и адаптацией домена и без них.

На рис. 5.13 представлена зависимость ошибки перекрестной энтропии от числа эпох обучения для задачи машинного перевода. Анализ показывает, что




Рис. 5.13: Зависимость ошибки перекрестной энтропии от числа эпох обучения на тестовом наборе данных OPUS-100 для задачи машинного перевода. Результаты усреднены по 3 запускам; ниже ошибка у моделей с учителем.

модели, обученные с использованием учителя, дают более быстрое снижение ошибки и меньшие потери, чем модель без учителя.

В таблице 5.9 представлены количественные результаты сравнения моделей ученика, полученных с использованием дистилляции и без нее. Результаты подтверждают эффективность многодоменной дистилляции для задачи машинного перевода.

Таблица 5.9: Сравнение качества моделей для задачи машинного перевода на наборе данных OPUS-100. Показаны потери перекрестной энтропии и метрика BLEU для модели ученика, обученной с использованием учителя и доменной адаптации (NLLB) и без них.

Ученик	Учитель	Отображение φ	Потери перекрестной энтропии	BLEU
Student-Train	—	—	$5,367 \pm 0,015$	0,0282
Student-Train	Teacher-Train	NLLB	$5,233 \pm 0,007$	0,0572

5.5.3. Эксперименты по антидистилляции

В настоящем подразделе представлены результаты вычислительных экспериментов для метода антидистилляции, описанного выше. Цель вычислитель-

ного эксперимента — сравнить производительность моделей в зависимости от инициализации параметров.

Производится сравнение различных подходов к инициализации:

1. Xavier — заполнение всех параметров модели $U[-\frac{1}{\sqrt{n}}, \frac{1}{\sqrt{n}}]$, где n — количество нейронов входного слоя [158], т.е. инициализация параметров модели по умолчанию.
2. Zero pad — заполнение расширенных параметров нулями.
3. Uniform pad — заполнение расширенных параметров равномерно распределенными случайными величинами $U[-\frac{1}{\sqrt{n}}, \frac{1}{\sqrt{n}}]$, где n — количество нейронов входного слоя.
4. Transfer learning — взятие предобученной модели и изменение только классификационного слоя для новой задачи классификации. Сначала модель обучалась с замороженными параметрами на всех слоях, кроме классификационного. После 3 эпох обучения все параметры размораживались. Начиная с четвертой эпохи, оптимизировались все параметры нейронной сети.
5. Net2Net — инкрементальный алгоритм расширения пространства параметров модели [159].
6. With Data Noise — получение инициализации модели ученика путем решения задачи оптимизации 5.3 с $\lambda_1, \lambda_3 = 1$ и $\lambda_2, \lambda_4 = 0$.
7. Anti-Distillation, $\lambda_4 = 0$ — инициализация методом антидистилляции с оптимизацией гиперпараметров $\lambda_1, \lambda_2, \lambda_3$ с помощью байесовской оптимизации ($\lambda_4 = 0$) [160].
8. Anti-Distillation — оптимизация всех λ_i .

Критериями качества являются: точность на валидационном наборе, искаженном атакой FGSM [161], и точность на валидационном наборе при условии, что параметры модели искажены шумом: $\mathbf{w}_\varepsilon = \mathbf{w} + \varepsilon \boldsymbol{\xi}$, где $\boldsymbol{\xi} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

В качестве набора данных используется Fashion-MNIST [162] — набор данных изображений статей Zalando, состоящий из обучающего набора из 60 000

примеров и тестового набора из 10 000 примеров. Каждый пример представляет собой полутоновое изображение размером 28×28 пикселей, связанное с меткой из 10 классов.

Экспериментальная процедура включает следующие этапы: обучение модели учителя, увеличение ее сложности и сравнение различных способов инициализации параметров модели.

Рассматривается модель полносвязной сети. Модель учителя имеет следующие размеры скрытых слоев: $[128, 64, 32]$. Модель ученика имеет $[256, 128, 64]$ нейронов в скрытых слоях.

Модель учителя обучалась в течение 30 эпох с начальной скоростью обучения 10^{-2} , уменьшавшейся до 10^{-3} после 10 эпох. Модели ученика сравнивались при обучении в течение 10 эпох со скоростью обучения 10^{-3} . Оптимизация проводится с использованием алгоритма оптимизации Adam [130]. Методы инициализации сравниваются по следующим критериям: точность предсказаний на валидационной выборке, значение функции потерь перекрестной энтропии и дисперсия предсказаний. Дополнительно исследуется устойчивость методов к зашумленным входным данным, для чего указанные критерии качества анализируются в зависимости от процента искаженных изображений.

Набор данных $\mathfrak{D}_2$ состоит из Fashion-MNIST, а $\mathfrak{D}_1 = \{(\mathbf{x}, y) | (\mathbf{x}, y) \in \mathfrak{D}_2, y \in C_1\}$, где $C_1 \subset C_2$, $C_1 = \{0, \dots, 4\}$, $C_2 = \{0, \dots, 9\}$. Таким образом, набор данных $\mathfrak{D}_1$ представляет собой подмножество $\mathfrak{D}_2$, содержащее только первые пять классов, что позволяет моделировать сценарий перехода от простой задачи к более сложной.

На рис. 5.14 представлено сравнение валидационной точности для различных методов инициализации параметров модели. Модели с антидистилляцией в среднем имеют меньшую дисперсию предсказаний и более высокую точность, чем сравниваемые инициализации. Обучение с нуля уступает остальным вариантам инициализации. Антидистилляция достигает сопоставимой или более высокой точности при меньшем числе итераций до стабилизации, используя




Рис. 5.14: Сравнение валидационной точности для различных методов инициализации параметров модели на наборе данных Fashion-MNIST. Модели с антидистилляцией имеют меньшую дисперсию и более высокую точность, чем сравниваемые инициализации.




Рис. 5.15: Зависимость валидационной точности от уровня адверсарного шума в данных для различных методов инициализации на наборе данных Fashion-MNIST. Антидистилляция сохраняет более высокую точность при высоких уровнях шума, чем сравниваемые методы.

информацию предобученной модели учителя.




Рис. 5.16: Зависимость валидационной точности от параметра интенсивности нормального шума ϵ в параметрах модели для различных методов инициализации на наборе данных Fashion-MNIST. Вариант без регуляризации гессиана ($\lambda_4 = 0$) сохраняет более высокую точность при максимальном уровне шума.

В представленных экспериментах не учитывалось количество итераций, необходимых для расширения модели учителя, которое также требует процедуры оптимизации. Во многих постановках этим временем можно пренебречь: расширение учителя выполняется один раз на $\mathfrak{D}_1$ и затем используется в нескольких задачах обучения ученика [163].

На рис. 5.15 представлена зависимость валидационной точности от уровня адверсарного шума в данных. При высоких уровнях адверсарного шума антидистилляция сохраняет более высокую валидационную точность, чем сравниваемые инициализации.

На рис. 5.16 представлена зависимость валидационной точности от уровня нормального шума в параметрах модели. При максимальном уровне нормального шума в параметрах вариант антидистилляции без регуляризации гессиана ($\lambda_4 = 0$) сохраняет более высокую точность, чем сравниваемые методы.

В таблице 5.10 представлены количественные результаты сравнения методов инициализации: валидационная точность после последней эпохи обучения,

Таблица 5.10: Сравнение точности на валидационном наборе Fashion-MNIST для различных методов инициализации параметров модели. Показаны базовая точность, точность при адверсарной атаке FGSM и точность при нормальном шуме в параметрах, результаты усреднены по нескольким запускам.

Метод инициализации	Точность	Атака FGSM	Шум в параметрах
Xavier	0.68 ± 0.08	0.42 ± 0.04	0.58 ± 0.06
Zero Pad	0.86 ± 0.02	0.50 ± 0.01	0.71 ± 0.03
Uniform Pad	0.85 ± 0.04	0.52 ± 0.03	0.73 ± 0.03
Transfer Learning	0.74 ± 0.09	0.50 ± 0.06	0.53 ± 0.05
Net2Net	0.85 ± 0.04	0.51 ± 0.02	0.70 ± 0.03
With Data Noise	0.81 ± 0.07	0.51 ± 0.03	0.70 ± 0.05
Anti-Distillation, $\lambda_4=0$	0.86 ± 0.05	0.53 ± 0.03	0.73 ± 0.04
Anti-Distillation	0.86 ± 0.05	0.57 ± 0.03	0.67 ± 0.03

точность при максимальном уровне шума изображения от адверсарной атаки FGSM и точность при максимальном уровне шума в параметрах модели.

5.6. Заключение

В настоящей главе рассмотрены методы снижения сложности параметрических моделей: удаление параметров по ковариации градиентов, байесовская дистилляция, многодоменная дистилляция и антидистилляция. Они опираются на аппарат глав 2 и 3. Байесовская дистилляция относится к развитию кандидатской постановки и не выносится отдельным положением на защиту; положения защиты опираются на прореживание, многодоменную дистилляцию и антидистилляцию.

Удаление параметров использует итеративную оценку ковариационной матрицы $\mathbf{S}$ градиентов функции ошибки и упорядочение параметров по диагональным элементам; дополнительно применяется модификация процедуры Белсли

на сингулярном разложении $\mathbf{C}$ и анализе дисперсионных долей. На наборах Wine, Boston Housing и синтетических данных с мультиколлинеарностью рассмотренные методы допускали удаление порядка 80% параметров при умеренном изменении качества; процедура Белсли давала меньшую чувствительность к шуму во входах.

В байесовской дистилляции информация учителя передаётся ученику через априорное распределение параметров. Приведены вариационная постановка и утверждения о сохранении нормального вида распределения при удалении нейрона и слоя в полносвязной модели. На синтетических данных и Fashion-MNIST использование апостериора учителя как основы априора ученика повышало логарифм правдоподобия вдоль траектории обучения.

Многодоменная дистилляция передаёт знания между моделями на доменах, связанных инъективным отображением φ , через функцию потерь с метками учителя и композицией $(f \circ \varphi)$. На ImageNet варианты с учителем и доменной адаптацией улучшали точность и потери относительно обучения без учителя; обучение в одном домене оставалось сильнее варианта с адаптацией. На OPUS-100 для перевода снижалась перекрёстная энтропия и росла метрика BLEU при использовании учителя.

Антидистилляция передаёт знания от более простой модели к более сложной. Составная функция потерь включает перекрёстную энтропию, близость параметров, устойчивость к шуму во входах и регуляризацию следа гесса (оценка через гессиан-векторное умножение). На Fashion-MNIST инициализация антидистилляцией давала валидационную точность $0,86 \pm 0,05$ (Xavier $0,68 \pm 0,08$, transfer learning $0,74 \pm 0,09$) и более высокую устойчивость к FGSM и к нормальному шуму в параметрах среди сравниваемых инициализаций.

Связь рассмотренных процедур с ландшафтной мерой сложности главы 2 и перенос на более широкий класс архитектур остаются предметом дальнейшего анализа.

Глава 6

Прикладные задачи

В предыдущих главах построен формализм соотношения сложности модели и данных, ландшафтная мера и её спектральные оценки, методы оценки достаточного объёма выборки и процедуры снижения числа обучаемых параметров. В настоящей главе эти конструкции применяются к трём прикладным постановкам.

Во-первых, радемахеровская сложность используется для сравнения однозадачного и многозадачного обучения с LoRA-адаптерами. Во-вторых, в задаче декодирования фМРТ из видеопоследовательностей рассматривается снижение размерности томографических данных при сохранении качества реконструкции. В-третьих, для детекции машинно-генерированного текста вводятся метрики качества обучающих наборов на основе топологической статистики и устойчивости к возмущениям.

6.1. Сложность моделей в многозадачном обучении с LoRA-адаптерами

6.1.1. Оценки радемахеровской сложности

Пусть $\mathcal{X}$ обозначает входное пространство, а $\mathcal{Y} = \{1, \dots, C\}$ — общее пространство меток для всех доменов. Домен определяется как пара $\mathcal{D} = (\mathcal{X}, P(X))$, где $P(X)$ — распределение над $\mathcal{X}$.

Предполагается наличие K размеченных исходных доменов

$$\mathcal{D}_{S_k} = (\mathcal{X}, P_{S_k}(X)), \quad k = 1, \dots, K,$$

с размеченными выборками

$$\mathcal{S}_k = \{(x_i^{S_k}, y_i^{S_k})\}_{i=1}^{n_{S_k}}, \quad x_i^{S_k} \sim P_{S_k}(X), y_i^{S_k} \in \mathcal{Y}.$$

Также рассматривается целевой домен

$$\mathcal{D}_T = (\mathcal{X}, P_T(X)),$$

с выборками

$$\mathcal{T} = \{(x_j^T, y_j^T)\}_{j=1}^{n_T^{\text{lab}}} \cup \{x_j^T\}_{j=1}^{n_T^{\text{unlab}}}.$$

Цель кросс-доменной классификации — обучить классификатор

$$f_\theta : \mathcal{X} \rightarrow \mathcal{Y}, \quad f_\theta(x) = \arg \max_{y \in \mathcal{Y}} p_\theta(y \mid x),$$

такой, чтобы ожидаемая целевая ошибка

$$\epsilon_T(f_\theta) = \mathbb{E}_{(x,y) \sim P_T(X,Y)}[\mathbf{1}\{f_\theta(x) \neq y\}]$$

минимизировалась за счет использования знаний из всех источников $\{\mathcal{S}_k\}_{k=1}^K$.

Цель состоит в обучении классификатора, с приемлемыми метриками качества на примерах из доменов, не встречавшихся во время обучения или представленных лишь ограниченными данными.

Современные задачи классификации часто решаются путем адаптации больших предобученных моделей к конкретному домену или набору данных [164]. Распространенная стратегия — тонкая настройка (fine-tuning), когда параметры предобученной модели обновляются с использованием размеченных данных из целевой задачи. Хотя этот подход обычно даёт высокие значения целевых метрик, он может быть вычислительно дорогим из-за большого числа обучаемых параметров.

Основная идея LoRA заключается в том, что для адаптации к задаче не обязательно обновлять всю матрицу параметров. Вместо этого обновления могут быть эффективно представлены в низкоразмерном подпространстве, которое отражает существенные изменения параметров, необходимые для адаптации. Это значительно сокращает количество обучаемых параметров, в значительной степени сохраняя выразительную способность модели.

Таблица 6.1: Сравнение формул обновления параметров для полной тонкой настройки и метода LoRA. В полной тонкой настройке обновление ΔW оценивается напрямую, тогда как в LoRA обновление параметризуется в виде низкоранговой факторизации AB , где $r \ll \min(d, k)$, что значительно сокращает количество обучаемых параметров.

Полная тонкая настройка	Тонкая настройка с LoRA
$W_{\text{upd}} = W + \Delta W$	$W_{\text{upd}} = W + AB$
$\hat{y} = x(W + \Delta W)$	$\hat{y} = x(W + AB)$

Формально, пусть $\Delta W \in \mathbb{R}^{d \times k}$ обозначает обновление параметров для данного слоя. При стандартной тонкой настройке ΔW оценивается напрямую. LoRA ограничивает ΔW условием низкого ранга путем факторизации:

$$\Delta W \approx AB,$$

где $A \in \mathbb{R}^{d \times r}$ и $B \in \mathbb{R}^{r \times k}$ с $r \ll \min(d, k)$. Обновленная матрица параметров тогда имеет вид:

$$W_{\text{upd}} = W + \Delta W = W + AB,$$

где W обозначает замороженные предобученные веса, а AB — изучаемое низкоранговое обновление. Ранг r выступает в качестве гиперпараметра, контролирующего размер изучаемого подпространства.

В задачах классификации предсказание обычно имеет вид

$$p(c \mid \mathbf{x}) = \text{softmax}(W^\top \mathbf{x}),$$

где $\mathbf{x}$ — это вектор признаков входного объекта, а W — обучаемая матрица весов. LoRA может быть применена здесь путем замены W на ее низкоранговую адаптированную форму $W + AB$.

Многозадачное обучение — это подход, в котором несколько связанных задач изучаются совместно с целью достижения лучшей обобщающей способности

по сравнению с обучением каждой задачи независимо. Ключевое предположение заключается в том, что задачи разделяют некоторую базовую структуру, так что обмен информацией между ними уменьшает переобучение и улучшает прогнозную производительность.

Формально, пусть $\{(x_{t,i}, y_{t,i})\}_{i=1}^{n_t}$ обозначает обучающие данные для задачи $t \in \{1, \dots, T\}$, взятые из распределения P_t над $\mathcal{X} \times \mathcal{Y}$. Цель — обучить дискриминативные функции $f_t : \mathcal{X} \rightarrow \mathcal{Y}$ для всех задач. Распространенный подход формулирует это как задачу регуляризованной минимизации эмпирического риска:

$$\min_{f=(f_1, \dots, f_T)} \frac{1}{T} \sum_{t=1}^T \frac{1}{n_t} \sum_{i=1}^{n_t} \ell(f_t(x_{t,i}), y_{t,i}) + \lambda \Omega(f),$$

где первое слагаемое — это средняя эмпирическая ошибка по задачам, а $\Omega(f)$ — регуляризующее слагаемое, поощряющее обмен информацией.

С теоретической точки зрения, преимущество MTL может быть интерпретировано как эффективное сокращение пространства гипотез за счет использования связанности задач, что приводит к более узким обобщающим границам.

Традиционные методы машинного обучения часто обучаются в однозадачной постановке. В отличие от этого, многозадачное обучение (MTL) совместно обучается на нескольких задачах с целью улучшения общей производительности за счет использования общих представлений [165].

Такая постановка особенно эффективна, когда задачи связаны, так как передача информации может уменьшить переобучение и улучшить обобщение. Кроме того, даже для одной целевой задачи вспомогательные задачи могут служить формой индуктивного смещения, помогая модели изучать более устойчивые представления.

Центральный вопрос в многозадачном обучении, как и в стандартном обучении с учителем, заключается в способности изученных функций обобщаться на новые данные. Границы обобщающей ошибки предоставляют теоретические гарантии, связывая истинный риск с его эмпирическим аналогом. В постановке

MTL границы часто выводятся в рамках упомянутого выше подхода регуляризованной минимизации эмпирического риска.

Пусть даны обучающие примеры $\{(X_1, Y_1), \dots, (X_n, Y_n)\}$, взятые i.i.d. из неизвестного распределения P . Цель — обучить функцию $f \in \mathcal{F}$ с малой ожидаемой потерей $\mathbb{E}_{(X,Y) \sim P}[\ell(f(X), Y)]$. Поскольку P неизвестно, обычно связывают этот риск со средним эмпирическим значением функции потерь плюс слагаемое сложности, которое зависит от богатства гипотезного класса $\mathcal{F}$:

$$\mathbb{E}_{(X,Y) \sim P}[\ell(f(X), Y)] \leq \frac{1}{n} \sum_{i=1}^n \ell(f(X_i), Y_i) + h(\text{complexity}(\mathcal{F}), n).$$

Среди различных мер сложности широко используется сложность Радемахера. Эта мера количественно определяет, насколько хорошо гипотезный класс может аппроксимировать случайный шум, что связано с обобщающей способностью модели. Формально:

Определение 30 (Сложность Радемахера). Пусть $\mathcal{G} := \{g : \mathcal{Z} \rightarrow \mathbb{R}\}$ — гипотезный класс, а $S := \{z_1, \dots, z_n\}$ — i.i.d. выборка из P . Эмпирическая сложность Радемахера для $\mathcal{G}$ определяется как

$$\widehat{R}(\mathcal{G}) := \mathbb{E}_{\sigma} \left[\sup_{g \in \mathcal{G}} \frac{1}{n} \sum_{i=1}^n \sigma_i g(z_i) \right],$$

где σ_i — независимые случайные величины Радемахера, равномерно распределенные в $\{\pm 1\}$. (Ожидаемая) сложность Радемахера определяется как

$$R(\mathcal{G}) := \mathbb{E}_{S \sim P^n} [\widehat{R}(\mathcal{G})].$$

Интуитивно, меньшая сложность Радемахера соответствует менее выразительному предсказательному классу, что, в свою очередь, приводит к более узким границам обобщения. В настоящем разделе выполняется сопоставление сложности модели в условиях многозадачного и однозадачного обучения. Сравниваются не различные типы границ обобщения, а сложности моделей в двух режимах обучения.

Отдельно отметим, что теоретическое и численное сопоставление эмпирической радемахеровской сложности и ландшафтной меры разброса пообъектных матриц Гессе для одних и тех же архитектур в задаче регрессии (полносвязные сети ReLU, квадратичная функция потерь) приведено в главе 2, раздел 2.4.3.. Радемахеровская сложность отражает емкость класса предикторов в худшем случае, тогда как ландшафтная мера описывает локальную геометрическую неоднородность риска при фиксированном значении параметров.

Для эмпирической проверки теоретического анализа рассматривается задача обнаружения машинно-генерированного текста. Эта задача требует высокой точности классификации с низкой частотой ложных срабатываний, чтобы избежать некорректного помечания контента, написанного человеком. Развитие больших языковых моделей привело к тому, что машинно-сгенерированные тексты стали все труднее отличать от текстов, написанных человеком [166, 167]. Это усиливает необходимость в устойчивых методах обнаружения для сохранения академической честности и борьбы с дезинформацией.

Большинство подходов рассматривают это как задачу бинарной классификации текста [168, 169]. Тонкая настройка архитектур на основе трансформеров стала одним из основных решений [170], демонстрируя высокую производительность, когда тестовые данные поступают из того же или близкородственного домена. Однако производительность часто резко падает при появлении новых доменов, делая модели менее надежными [171]. Чтобы решить эту проблему, можно либо использовать более мощные модели, либо интегрировать дополнительную информацию о тексте, такую как его источник, домен или стилистические особенности. Эти сигналы могут выступать в качестве вспомогательных регуляризаторов, улучшая обобщение. Многозадачное обучение предоставляет естественную основу для объединения нескольких задач, включая интеграцию такой вспомогательной информации, при этом сохраняя основную цель классификации.

6.1.2. Многозадачное обучение и низкоранговые адаптеры

Предполагается, что решается задача классификации с использованием моделей трансформерной архитектуры [156]. Тонкая настройка таких моделей в режиме обучения с учителем является современным методом для задач классификации.

Анализ LoRA показывает, что минимизация эмпирического риска при параметризации LoRA остается согласованной с минимизацией истинного риска в рассматриваемой постановке.

Теорема 34 (Состоятельность оценки). *Пусть $\mathcal{D} = \{(X_i, c_i)\}_{i=1}^n$ — независимые одинаково распределенные пары из распределения P_{true} на $\mathcal{X} \times [N_c]$, где $[N_c] = \{1, \dots, N_c\}$. Рассмотрим компактное множество $K \subset \mathbb{R}^p$ и параметрическую модель $P_{\Phi_0 + \Theta}(c \mid X)$ при $\Theta \in K$, где Φ_0 — замороженный вектор предобученных параметров. Предположим:*

1. *Существует единственная точка $\Theta^* \in K$, минимизирующая ожидаемый риск*

$$L(\Theta) = \mathbb{E}_{(X,c) \sim P_{\text{true}}} [-\log P_{\Phi_0 + \Theta}(c \mid X)], \quad \Theta \in K.$$

2. *Функция $(X, c, \Theta) \mapsto -\log P_{\Phi_0 + \Theta}(c \mid X)$ непрерывна на своей области допустимых значений и*

$$\mathbb{E}_{(X,c) \sim P_{\text{true}}} \left[\sup_{\Theta \in K} |\log P_{\Phi_0 + \Theta}(c \mid X)| \right] < \infty.$$

3. *Эмпирический риск задается в виде*

$$\mathcal{L}_n(\Theta) = -\frac{1}{n} \sum_{i=1}^n \log P_{\Phi_0 + \Theta}(c_i \mid X_i),$$

а оценка $\hat{\Theta}_n$ выбирается как измеримый минимизатор $\mathcal{L}_n$ на K (если минимум достигается; иначе — ε_n -минимизатор с $\varepsilon_n \downarrow 0$).

Тогда $\hat{\Theta}_n \xrightarrow{P} \Theta^$ при $n \rightarrow \infty$.*

Доказательство. По закону больших чисел для каждого фиксированного $\Theta \in K$ имеем $\mathcal{L}_n(\Theta) \xrightarrow{P} L(\Theta)$. Из компактности K , непрерывности по Θ и конечности интегральных L^1 -ограничений следует равномерная сходимость $\sup_{\Theta \in K} |\mathcal{L}_n(\Theta) - L(\Theta)| \xrightarrow{P} 0$; достаточные условия приведены, например, в [2]. При единственности минимизатора L на K стандартный аргумент сходимости минимизаторов дает $\hat{\Theta}_n \xrightarrow{P} \Theta^*$. $\square$

Теорема 35 (Корректность при низкоранговых обновлениях). *Предположим следующее:*

1. *Выходной слой задается в виде*

$$\hat{\mathbf{y}} = \text{softmax}(W_{\text{upd}}^\top \mathbf{x}),$$

где $\mathbf{x} \in \mathbb{R}^d$ — это вектор признаков BERT, $W \in \mathbb{R}^{d \times k}$ — замороженные предобученные веса, а

$$W_{\text{upd}} = W + \Delta W.$$

2. *Вместо непосредственного обучения $\Delta W \in \mathbb{R}^{d \times k}$, обновление параметризуется в низкоранговой форме:*

$$\Delta W = AB, \quad A \in \mathbb{R}^{d \times r}, B \in \mathbb{R}^{r \times k}, r \ll \min(d, k). \quad (6.1)$$

3. *Выполнены условия Теоремы 34, т.е. модель остается статистически состоятельной при минимизации эмпирического риска.*

Тогда при параметризации (6.1) выход модели $\hat{\mathbf{y}}$ сохраняется в том смысле, что низкоранговое обновление не искажает корректность классификационного слоя.

Доказательство. Пусть выходной слой определен как

$$\hat{\mathbf{y}} = \text{softmax}(W_{\text{upd}}^\top \mathbf{x}), \quad W_{\text{upd}} = W + \Delta W,$$

где $W \in \mathbb{R}^{d \times k}$ — замороженные предобученные веса, а $\mathbf{x} \in \mathbb{R}^d$ — вектор признаков энкодера. В силу дистрибутивности матричного сложения,

$$W_{\text{upd}}^\top \mathbf{x} = W^\top \mathbf{x} + \Delta W^\top \mathbf{x}.$$

Следовательно, предсказанные вероятности могут быть записаны как

$$\hat{\mathbf{y}} = \frac{\exp(W^\top \mathbf{x} + \Delta W^\top \mathbf{x})}{\sum_{i=1}^k \exp((W^\top \mathbf{x} + \Delta W^\top \mathbf{x})_i)}. \quad (6.2)$$

При параметризации LoRA $\Delta W = AB$ с $A \in \mathbb{R}^{d \times r}$ и $B \in \mathbb{R}^{r \times k}$, член обновления принимает вид

$$\Delta W^\top \mathbf{x} = (AB)^\top \mathbf{x} = B^\top (A^\top \mathbf{x}) \in \mathbb{R}^k.$$

Это показывает, что низкоранговая форма лишь ограничивает ΔW рангом r в подпространстве $\mathbb{R}^{d \times k}$, но не изменяет выходную размерность или отображение $\mathbf{x} \mapsto \hat{\mathbf{y}}$. Логиты в (6.2) остаются хорошо определенными и дифференцируемыми для всех $\mathbf{x}$.

Более того, обновление ΔW изучается через минимизацию эмпирического риска в постановке теоремы 34. Следовательно, низкоранговая параметризация сохраняет корректность выходного слоя в том смысле, что $\hat{\mathbf{y}}_{\text{LoRA}} = \text{softmax}((W + AB)^\top \mathbf{x})$ остается корректно определенным распределением вероятностей на том же пространстве классов. Таким образом, введение модулей LoRA не меняет размерность выходного распределения и сохраняет стандартную форму классификационного правила. $\square$

Следствие 10 (LoRA с теоретическим обоснованием). *Объединяя теорему 34 и теорему 35, получаем, что тонкая настройка на основе LoRA одновременно сохраняет:*

1. *Статистическую состоятельность: при выполнении условий теоремы 34 оценки параметров, минимизирующие эмпирический риск, сходятся по вероятности к Θ^* ;*
2. *Корректность выходного слоя: низкоранговые обновления AB не искажают выход классификации.*

Таким образом, адаптация с помощью LoRA сохраняет статистическую постановку полной тонкой настройки и корректность выходного слоя, при этом требуя значительно меньшего количества обучаемых параметров.

Приведенные выше результаты показывают, что LoRA сохраняет основные свойства тонкой настройки в рассматриваемой постановке. Со статистической точки зрения, метод сохраняет состоятельность минимизации эмпирического риска при выполнении условий теоремы 34. С функциональной точки зрения, ограничение обновлений низкоранговым подпространством не искажает выход классификационного слоя. В совокупности эти свойства согласуются с тем, что LoRA часто даёт метрики, близкие к полной тонкой настройке, при существенно меньшем числе обучаемых параметров.

В настоящем разделе анализируется влияние многозадачного обучения на сложность обобщения для каждой задачи. Для этого выполняется сравнение однозадачного обучения модели на основе трансформера с MTL-подходом, использующим общий энкодер. Для обеспечения справедливого сравнения предполагается, что архитектуры энкодера и головы идентичны и состоят из линейных слоев. Это позволяет изолировать эффект многозадачного обучения от влияния различий в архитектуре. В случае STL присутствует единственная голова для целевой задачи, тогда как в настройке MTL вводятся дополнительные головы для связанных задач, обеспечивая неявную регуляризацию для целевой задачи.

Формально, в случаях STL и MTL гипотезные классы имеют вид:

$$\begin{aligned}\mathcal{F}_{\text{STL}} &= \left\{ x \mapsto w_{\text{head}}^\top \phi(x; w_{\text{enc}}) \right. \\ &\quad \left. \mid w_{\text{enc}} \in \mathcal{W}_{\text{enc}}, w_{\text{head}} \in \mathcal{W}_{\text{head}} \right\}, \\ \mathcal{F}_{\text{MTL}} &= \left\{ (x \mapsto w_t^\top \phi(x; w_{\text{shared}}))_{t=1}^T \right. \\ &\quad \left. \mid w_{\text{shared}} \in \mathcal{W}_{\text{shared}}, w_t \in \mathcal{W}_{\text{head}} \right\}.\end{aligned}$$

Теорема 36 (Сложность Радемахера на задачу при MTL). *Пусть $S_t = \{x_i\}_{i=1}^n$ — выборка фиксированной целевой задачи t с $\|x_i\|_2 \leq R$. Пусть $\phi(\cdot; w)$ — энкодер, и рассмотрим линейные головы $f_{w,h}(x) = h^\top \phi(x; w)$ с $\|h\|_2 \leq B_{\text{head}}$. Предположим:*

1. Ограничение на признаки: для всех x, w $\|\phi(x; w)\|_2 \leq L \|w\|_2 \|x\|_2$.
2. Энкодер STL удовлетворяет $\|w_{\text{enc}}\| \leq B_{\text{enc}}$, общий энкодер MTL удовлетворяет $\|w_{\text{shared}}\| \leq B_{\text{shared}}$.
3. Многозадачное масштабирование: $B_{\text{shared}} \leq B_{\text{enc}}/\sqrt{T}$.

Обозначим через $\hat{\mathfrak{R}}_n(\cdot; S_t)$ эмпирическую сложность Радемахера на S_t . Пусть $\mathcal{F}_{\text{STL}}^{(t)}$ совпадает с семейством $\mathcal{F}(B_{\text{enc}})$, а $\mathcal{F}_{\text{MTL}}^{(t)}$ — с семейством $\mathcal{F}(B_{\text{shared}})$, где класс $\mathcal{F}(B)$ задается в доказательстве. Введем функцию

$$U_n(B) := \frac{B_{\text{head}} L R B}{\sqrt{n}}. \quad (6.3)$$

Тогда

$$\hat{\mathfrak{R}}_n(\mathcal{F}_{\text{MTL}}^{(t)}; S_t) \leq U_n(B_{\text{shared}}) \leq \frac{1}{\sqrt{T}} U_n(B_{\text{enc}}), \quad \hat{\mathfrak{R}}_n(\mathcal{F}_{\text{STL}}^{(t)}; S_t) \leq U_n(B_{\text{enc}}). \quad (6.4)$$

Следовательно, одна и та же величина вида (6.3) дает верхнюю оценку эмпирической сложности Радемахера в STL - и MTL -постановках, а предположение 3 обеспечивает не менее чем $1/\sqrt{T}$ -кратное уменьшение шаблонной верхней оценки при переходе от B_{enc} к B_{shared} .

Доказательство. Пусть $S_t = \{x_i\}_{i=1}^n$ — выборка для целевой задачи t с $\|x_i\|_2 \leq R$. Для $B > 0$ определим гипотезный класс

$$\mathcal{F}(B) = \{x \mapsto h^\top \phi(x; w) \mid \|h\|_2 \leq B_{\text{head}}, \|w\|_2 \leq B\}.$$

Эмпирическая сложность Радемахера на S_t равна

$$\hat{\mathfrak{R}}_n(\mathcal{F}(B); S_t) = \frac{1}{n} \mathbb{E}_\sigma \sup_{\|h\| \leq B_{\text{head}}, \|w\| \leq B} \sum_{i=1}^n \sigma_i h^\top \phi(x_i; w),$$

где $\sigma_i \in \{\pm 1\}$ — независимые одинаково распределенные величины Радемахера.

Для фиксированных w и σ , по дуальности Коши-Буняковского,

$$\sup_{\|h\| \leq B_{\text{head}}} \sum_{i=1}^n \sigma_i h^\top \phi(x_i; w) = B_{\text{head}} \left\| \sum_{i=1}^n \sigma_i \phi(x_i; w) \right\|_2.$$

Следовательно,

$$\hat{\mathfrak{R}}_n(\mathcal{F}(B); S_t) \leq \frac{B_{\text{head}}}{n} \mathbb{E}_\sigma \sup_{\|w\| \leq B} \left\| \sum_{i=1}^n \sigma_i \phi(x_i; w) \right\|_2.$$

По неравенствам Йенсена и Хинчина,

$$\mathbb{E}_\sigma \left\| \sum_{i=1}^n \sigma_i a_i \right\|_2 \leq \left(\sum_{i=1}^n \|a_i\|_2^2 \right)^{1/2},$$

что дает

$$\hat{\mathfrak{R}}_n(\mathcal{F}(B); S_t) \leq \frac{B_{\text{head}}}{n} \sup_{\|w\| \leq B} \left(\sum_{i=1}^n \|\phi(x_i; w)\|_2^2 \right)^{1/2}.$$

Используя ограничение на признаки $\|\phi(x; w)\|_2 \leq L \|w\|_2 \|x\|_2$ и $\|x_i\|_2 \leq R$, получаем

$$\hat{\mathfrak{R}}_n(\mathcal{F}(B); S_t) \leq \frac{B_{\text{head}} L R B}{\sqrt{n}} = U_n(B).$$

Подставляя $B = B_{\text{shared}}$ и $B = B_{\text{enc}}$ и пользуясь предположением $B_{\text{shared}} \leq B_{\text{enc}}/\sqrt{T}$, получаем (6.4). $\square$

Полученный результат сравнивает величины $U_n(B)$ одинакового вида (6.3) и тем самым описывает усиление, вносимое масштабированием энкодера в верхнюю оценку эмпирической сложности Радемахера при справедливом предположении 3. Это согласуется с современными анализами многозадачного обучения, основанными на средних Радемахера, как показано в [172].

В частности, при совместном использовании параметров энкодера между T задачами стандартная скалярная верхняя оценка вида (6.3) для MTL уменьшается не менее чем в $1/\sqrt{T}$ раз по сравнению с верхней оценкой при STL, что согласуется с типичными выводами анализа средних Радемахера. Однако более ранняя работа [173] установила более сильное улучшение типа $1/T$ в другой постановке. В постановке Бакстера, количество задач T само по себе способствует оценке общего индуктивного смещения: с ростом T сложность данных на задачу уменьшается пропорционально $1/T$. В отличие от этого, приведенный анализ сохраняет размер выборки целевой задачи n фиксированным и сравнивает STL

и MTL на одном и том же n ; улучшение проявляется как множитель $1/\sqrt{T}$ в сравниваемой верхней оценке вида (6.3).

Обе сложности на задачу оцениваются на одной и той же выборке S_t размера n , поэтому общий множитель $1/\sqrt{n}$ сокращается; разница обусловлена только бюджетом энкодера.

Более того, в анализе обеспечивается, чтобы обе модели STL и MTL обучались на одинаковом общем количестве примеров (nT). Для STL энкодер обучается на nT примерах только из целевой задачи. Для MTL каждая из T голов получает n примеров из своей соответствующей задачи, так что общий энкодер видит те же самые nT примеров, причем одна из голов соответствует целевой задаче. Это гарантирует, что наблюдаемое снижение сложности на задачу обусловлено совместным использованием параметров, а не неравными бюджетами данных.

Наш теоретический анализ показывает, что при выполнении условий теоремы 34 LoRA-постановка наследует состоятельность оценивания, а теорема 36 дает сопоставимые верхние оценки эмпирической сложности Радемахера на задачу для STL и MTL при справедливом масштабировании энкодера. Вместе эти результаты показывают, что оба подхода сохраняют основные свойства классической тонкой настройки, но достигают большей эффективности с точки зрения параметров (LoRA) или обобщения (MTL).

Полученные теоретические результаты создают основу для практического применения LoRA и многозадачного обучения в реальных задачах, обеспечивая теоретическое обоснование их эффективности и количественную оценку преимуществ по сравнению с полной тонкой настройкой.

6.2. Снижение размерности данных при декодировании фМРТ

В предыдущем разделе рассматривалось снижение сложности моделей через низкоранговую параметризацию и многозадачное обучение. В настоящем разделе

ле демонстрируется альтернативный подход — снижение сложности данных без изменения архитектуры модели. Такой подход особенно актуален в задачах, где данные имеют высокую размерность, но могут быть эффективно сжаты без существенной потери информации. В задаче декодирования фМРТ-изображений из видеопоследовательностей предварительное сжатие томографических данных позволяет существенно сократить время обучения при сохранении качества реконструкции, что иллюстрирует снижение размерности данных в прикладной задаче нейровизуализации.

Частота кадров $\nu \in \mathbb{R}$ и продолжительность $t \in \mathbb{R}$ видеопоследовательности задаются. Видеопоследовательность задается как

$$\mathbf{P} = [\mathbf{p}_1, \dots, \mathbf{p}_{\nu t}], \quad \mathbf{p}_\ell \in \mathbb{R}^{W \times H \times C},$$

где W , H и C — ширина, высота и количество каналов изображения соответственно.

Обозначим частоту фМРТ-изображений через $\mu \in \mathbb{R}$. Зададим последовательность изображений

$$\mathbf{S} = [\mathbf{s}_1, \dots, \mathbf{s}_{\mu t}], \quad \mathbf{s}_\ell \in \mathbb{R}^{X \times Y \times Z},$$

где X , Y и Z — размеры воксельного изображения.

Задача состоит в построении отображения, учитывающего задержку Δt между фМРТ-изображением и видеопоследовательностью, а также предыдущие томографические данные. Формально необходимо найти такое отображение $\mathbf{g}$, что

$$\mathbf{g}(\mathbf{p}_1, \dots, \mathbf{p}_{k_\ell - \nu \Delta t}; \mathbf{s}_1, \dots, \mathbf{s}_{\ell-1}) = \mathbf{s}_\ell, \quad \ell = 1, \dots, \mu t,$$

где для ℓ -го фМРТ-изображения номер соответствующего кадра k_ℓ определяется по формуле

$$k_\ell = \frac{\ell \cdot \nu}{\mu}.$$

Схема предложенного метода реконструкции фМРТ-изображений показана на рис. 6.1.




Рис. 6.1: Схема метода декодирования фМРТ-изображений из видеопоследовательностей. Метод использует архитектуру ResNet152 для векторизации видеок кадров и линейную регрессию с L_2 -регуляризацией для предсказания разностей между последовательными фМРТ-снимками с учетом временной задержки Δt .

Обозначим фМРТ-изображение как $\mathbf{s}_\ell = [v_{ijk}^\ell] \in \mathbb{R}^{X \times Y \times Z}$, где $v_{ijk}^\ell \in \mathbb{R}_+$ — значение соответствующего вокселя. Для сокращения времени работы метода предлагается использовать сжатие фМРТ-изображений путем снижения размерности. Сжатие в 2 раза представляется в виде отображения

$$\chi : \mathbb{R}^{X \times Y \times Z} \rightarrow \mathbb{R}^{X/2 \times Y/2 \times Z/2}.$$

Сжатие в 2^k раз получается последовательным применением χ k раз. В дальнейшем для простоты сохраняем обозначения размерностей изображения $X \times Y \times Z$.

Предположим, что для последовательности снимков выполняется свойство Маркова, т.е. каждый снимок зависит только от одного изображения и предыдущего снимка. Тогда соответствующее отображение записывается в виде

$$\mathbf{g}(\mathbf{p}_{k_\ell - \nu \Delta t}) = \mathbf{s}_\ell - \mathbf{s}_{\ell-1} = \boldsymbol{\delta}_\ell, \quad \ell = 2, \dots, \mu t.$$

где $\boldsymbol{\delta}_\ell = [v_{ijk}^\ell - v_{ijk}^{\ell-1}] = [\delta_{ijk}^\ell] \in \mathbb{R}^{X \times Y \times Z}$ — разность двух последовательных снимков.

Отображение $\mathbf{g} : \mathbf{P} \rightarrow \mathbf{S}$ представляется как композиция двух других:

$$\mathbf{g} = \varphi \circ \psi,$$

где

$\psi : \mathbf{P} \rightarrow \mathbb{R}^d$ — векторизация изображения,

$\varphi : \mathbb{R}^d \rightarrow \mathbf{S}$ — целевое отображение.

Для каждого изображения из видеопоследовательности имеем вектор вложения размерности d :

$$\mathbf{x}_\ell = [x_1^\ell, \dots, x_d^\ell]^\top \in \mathbb{R}^d, \quad \ell = 1, \dots, \nu t.$$

В качестве архитектуры используется нейронная сеть ResNet152 без последнего линейного слоя.

При заданном $k_\ell = \ell \cdot \nu / \mu$ общее количество пар составляет $N = \mu(t - \Delta t)$. Таким образом, для каждого вокселя задана выборка

$$\mathfrak{D}_{ijk} = \{(\mathbf{x}_\ell, \delta_{ijk}^\ell) \mid \ell = 2, \dots, N\}.$$

Задача формулируется как регрессия

$$y_{ijk} : \mathbb{R}^d \rightarrow \mathbb{R}.$$

В качестве модели используется линейная регрессия с вектором параметров

$$\mathbf{w}_{ijk} = [w_1^{ijk}, \dots, w_d^{ijk}]^\top \in \mathbb{R}^d :$$

$$f_{ijk}(\mathbf{x}, \mathbf{w}_{ijk}) = \langle \mathbf{x}, \mathbf{w}_{ijk} \rangle.$$

Для модели f_{ijk} с соответствующим вектором параметров $\mathbf{w}_{ijk} \in \mathbb{R}^d$ определим квадратичную функцию потерь с L_2 -регуляризацией:

$$\mathcal{L}_{ijk}(\mathbf{w}_{ijk}) = \sum_{\ell=2}^N (f_{ijk}(\mathbf{x}_\ell, \mathbf{w}_{ijk}) - \delta_{ijk}^\ell)^2 + \alpha \|\mathbf{w}_{ijk}\|_2^2,$$

где $\alpha \in \mathbb{R}$ — коэффициент регуляризации.

Требуется найти параметры, доставляющие минимум функционалу потерь $\mathcal{L}_{ijk}(\mathbf{w}_{ijk})$ при заданных гиперпараметрах Δt и α . Задача оптимизации формулируется следующим образом:

$$\hat{\mathbf{w}}_{ijk} = \arg \min_{\mathbf{w}_{ijk}} \mathcal{L}_{ijk}(\mathbf{w}_{ijk}).$$

Минимум функции потерь находится методом наименьших квадратов. Введем матрицу объектов-признаков

$$\mathbf{X} = [\mathbf{x}_2, \dots, \mathbf{x}_N]^\top = [x_j^i] \in \mathbb{R}^{(N-1) \times d}$$

и вектор, компонентами которого являются разности значений одного и того же вокселя на разных изображениях:

$$\Delta_{ijk} = [\delta_{ijk}^2, \dots, \delta_{ijk}^N]^\top \in \mathbb{R}^{N-1}.$$

Решение задачи оптимизации записывается в виде

$$\hat{\mathbf{w}}_{ijk} = (\mathbf{X}^\top \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^\top \Delta_{ijk}.$$

Выведем формулу для восстановленных фМРТ-изображений. Введем матрицу весов

$$\hat{\mathbf{W}} = [\hat{\mathbf{w}}_1, \dots, \hat{\mathbf{w}}_{XYZ}]^\top = [\hat{w}_j^i] \in \mathbb{R}^{XYZ \times d}.$$

Введем для тензоров $\mathbf{s}_\ell, \boldsymbol{\delta}_\ell \in \mathbb{R}^{X \times Y \times Z}$ векторы

$$\mathbf{s}_\ell^R = [v_1^\ell, \dots, v_{XYZ}^\ell]^\top, \boldsymbol{\delta}_\ell^R = [\delta_1^\ell, \dots, \delta_{XYZ}^\ell]^\top \in \mathbb{R}^{XYZ}.$$

Тогда вектор прогнозируемого изображения находится по формуле

$$\hat{\mathbf{s}}_\ell^R = \mathbf{s}_{\ell-1}^R + \hat{\boldsymbol{\delta}}_\ell^R = \mathbf{s}_{\ell-1}^R + \hat{\mathbf{W}} \mathbf{x}_\ell.$$

6.3. Оценка качества данных для детекции машинно-генерированного контента

В предыдущих разделах рассматривались методы снижения сложности моделей и данных в контексте обучения. В настоящем разделе акцент смещается

на оценку качества самих данных, что является критически важным аспектом для обеспечения надежности моделей машинного обучения. Низкое качество обучающих данных может приводить к завышенным оценкам производительности моделей и их неспособности к обобщению на реальные данные. Это особенно актуально для задачи детекции машинно-генерированного контента, где качество обучающих наборов напрямую влияет на надежность детекторов.

В последние годы появилось значительное количество детекторов машинно-генерированного текста и коллекций с машинно-сгенерированными фрагментами. Несколько методов детекции продемонстрировали качество распознавания до 99,9% согласно целевым метрикам в таких коллекциях. Однако качество таких детекторов часто резко падает в реальных условиях, что ставит вопрос о надежности детекторов: действительно ли они высоконнаджны, или их высокие показатели на тестовых наборах связаны с низким качеством оценочных данных? Для оценки сгенерированных данных нужны критерии, устойчивые к смещениям и к различиям в обобщении детекторов по доменам. В настоящем разделе рассматриваются работы, посвященные детекции машинно-генерированного контента, и предлагаются методы оценки качества наборов данных, содержащих машинно-сгенерированные фрагменты.

Предлагается сравнить наборы данных в единой постановке и оценить поведение стандартных детекторов на них. Целью исследования является не достичь максимальных показателей, а сравнить производительность одного и того же метода на разных наборах данных.

Базовые методы. Для методов, основанных на возмущениях, использовался подход DetectGPT с GPT-2 [122] в качестве базовой модели и T5-Large [174] в качестве генератора возмущений. Однако из-за высоких вычислительных затрат DetectGPT использовался Fast-DetectGPT [175], который заменяет этап возмущения в DetectGPT более эффективным этапом сэмплирования. Для методов без дообучения использовался Binoculars [176] с улучшенной оценкой перплексии. Эти два базовых метода не требуют тонкой настройки, что является

важным аспектом для задачи детекции, поскольку обучать детектор для каждого домена и генератора непрактично. Наконец, в качестве метода на основе энкодера использовалась модель mDeBERTa [177], которая является современной моделью для детекции машинно-генерированного текста в мультиязычном контексте [178]. Эти три детектора, охватывают все основные категории детекторов.

Топологическая статистика. В работе [179] было показано, что если рассмотреть внутреннюю размерность многообразия на множестве эмбедингов, то можно отделить тексты, написанные человеком, от машинно-сгенерированных. Авторы использовали размерность персистентной гомологии (англ. PHD) и показали, что статистически тексты, сгенерированные человеком, имеют более высокую PHD, чем машинно-сгенерированные тексты, предложив таким образом новый детектор. Дополнительно, в [180] было предложено вычислять PHD внутри скользящего окна. Эти внутренние размерности текста в пределах скользящего окна могут быть использованы в качестве признака для детекторов. Авторы демонстрируют, что метрика устойчива к изменению домена и генераторов. Для возможности сравнения наборов данных между собой разработана симметричная оценка, использующая KL-дивергенцию. Пусть h_d, m_d — распределения внутренних размерностей для двух типов текстов из одного набора данных, человеческого и машинного происхождения, тогда оценка KL_{TTS} имеет вид:

$$KL_{TTS}(h_d, m_d) = |D_{KL}(h_d||m_d) - D_{KL}(m_d||h_d)|$$

Чем ниже эта оценка, тем ближе друг к другу h_d и m_d , что означает почти неразличимые тексты, и наоборот.

Возмущения и перемешивание. Основываясь на результатах исследований модификации текста [181, 182], которые показывают, как небольшие возмущения влияют на системы машинного понимания текста, рассмотрим этот способ как возможный метод оценки качества набора данных. Ключевая идея

заключается в том, что языковые модели чувствительны к таким адверсарным изменениям сильнее, чем человек. Рассматриваются две модификации: Адверсарное возмущение токенов и перемешивание предложений.

В данном подходе текст разбивается на токены, и каждый токен случайным образом заменяется на синоним из коллекции WordNet [183] с вероятностью 70%. Далее данная техника применяется к каждому представленному классу, и с использованием модели-энкодера получаются эмбединги для каждого из текстов в текущем наборе данных. Наконец, измеряются средние сдвиги эмбедингов для классов человеческих и сгенерированных текстов, используя косинусное расстояние между эмбедингами исходных текстов и модифицированных. В итоге, после модификаций получаем Δ_{shift} — логарифм разности средних сдвигов эмбедингов.

$$\Delta_{\text{shift}} = \log \frac{\frac{1}{n} \sum_{i=1}^n \cos_d(h_{h_i}^o, h_{h_i}^p)}{\frac{1}{m} \sum_{j=1}^m \cos_d(h_{m_j}^o, h_{m_j}^p)},$$

где n и m — количество примеров в человеческой и сгенерированной частях набора данных соответственно, $h_{h_i}^o$ — эмбединг i -го фрагмента человеческой части данных, $h_{h_i}^p$ — тот же эмбединг после пертурбации. Аналогично, $h_{m_i}^o$ и $h_{m_i}^p$ — эмбединги для машинно-сгенерированных текстов. Функция $\cos_d$ измеряет косинусное расстояние между двумя векторами.

В данном подходе предложения случайным образом меняются местами, что влияет на связность текста. Фрагмент разделяется на предложения, и случайным образом изменяется порядок 70% выбранных предложений. Данная техника применяется к каждому представленному классу. Затем, используя модель кодирования текста, получаются эмбединги для каждого из текстов текущего набора данных. Наконец, выполняется измерение сдвига эмбедингов для класса человеческих и сгенерированных текстов, после чего сдвиги преобразуются в распределения, подобные вероятностным. Это в итоге приводит к $\text{KL}_{\text{shuffle}}(H, M)$ — дивергенции Кульбака-Лейблера между сдвигами челове-

ских и сгенерированных текстов.

$$\text{KL}_{\text{shuffle}}(H, M) = \sum_i H(i) \log \frac{H(i)}{M(i)},$$

$$H(i) = \frac{\cos_d(h_{h_i}^o, h_{h_i}^p) + \epsilon}{\sum_j (\cos_d(h_{h_j}^o, h_{h_j}^p) + \epsilon)},$$

где $M(i)$ имеет ту же структуру, что и $H(i)$, за исключением того, что вместо текстов человеческого класса используются тексты сгенерированного класса, ϵ — малая константа, добавляемая для избежания деления на ноль.

6.4. Вычислительные эксперименты

6.4.1. Эксперименты по многозадачному обучению с LoRA




Рис. 6.2: Зависимость метрики F_1 от ранга r адаптеров LoRA для модели DeBERTa-v3-base на задаче детекции машинно-генерированного текста. В данном эксперименте наибольшие значения F_1 наблюдаются при $r = 8$; дальнейший рост ранга не улучшает метрику.

Для эмпирической проверки теоретических свойств, установленных выше, рассматривается задача обнаружения машинно-генерированного текста. Данная задача формулируется как проблема бинарной классификации, что служит компактным, но информативным эталоном для оценки как прогнозной производительности, так и эффективности обучения.

Выбор задачи обусловлен разнообразием доменов в наборе данных и необходимостью компактных стратегий адаптации.

В качестве набора данных используется GenAI Detection Challenge (COLING 2025, Task 1), представленный в [184]. Из исходных 600 000 примеров выбирается 60 000 для обучения и 5 000 для тестирования, сохраняя распределение меток.

Набор данных охватывает широкий спектр доменов. Внутрираспределительные категории включают финансы, право, психологию, новости и медицину. Внераспределительные категории включают эссе IELTS, научные статьи, биомедицинские аннотации и юридические статьи.

Результаты предыдущих соревнований указывают на то, что стандартные методы тонкой настройки дают более низкие метрики на этом гетерогенном тестовом наборе, что мотивирует сравнение стратегий адаптации.

В экспериментах фиксируется энкодер как DeBERTa-base [185], который продемонстрировал высокую производительность в недавних задачах классификации текста. Для анализа качества рассматриваются следующие метрики: доля верных ответов (accuracy), точность (precision), полнота (recall), F1-мера, потеря на валидации и общее время обучения.

Для эмпирической проверки сохранения формы выходного классификационного правила при LoRA (теорема 35) выполняется сравнение DeBERTa-v3-base в двух режимах тонкой настройки: полная тонкая настройка всех параметров и адаптация с помощью LoRA. Цели эксперимента состоят в следующем: (i) проверить, что LoRA сохраняет прогнозное качество при существенном сокращении числа обучаемых параметров, и (ii) оценить, приводит ли низкоранговая

адаптация к сокращению времени обучения. Все условия обучения сохраняются идентичными.

При полной тонкой настройке обновляются все параметры DeBERTa-v3-base. Для LoRA исходные веса замораживаются, а низкоранговые адаптеры вставляются в каждый блок трансформера с рангом $r = 8$, коэффициентом масштабирования $\alpha = 32$ и долей отсева для адаптеров 0.1. Эта конфигурация была выбрана после дополнительного анализа чувствительности к рангу, представленного на рис. 6.2.

Результаты суммированы в таблице 6.2. По сравнению с полной тонкой настройкой, LoRA демонстрирует лишь незначительное снижение прогнозных метрик (1.4–3.2%), при этом обеспечивая существенно более низкие потери на валидации (снижение на 0.657, или 36.3%).

Дополнительная диагностика по нормам градиентов и траекториям потерь показывает более гладкую динамику обучения для LoRA. Это согласуется с более гладкой сходимостью LoRA по сравнению с полной тонкой настройкой в данном эксперименте. Полученные результаты согласуются с теоретическим утверждением о том, что низкоранговые обновления сохраняют корректность выходного слоя (теорема 35). Для оценки вычислительной эффективности также рассматривается общее время обучения. LoRA обеспечивает ускорение в 12.6%, что указывает на то, что низкоранговая адаптация снижает эффективную сложность и ускоряет оптимизацию при незначительной потере в метриках, основанных на точности.

Задача GenAI Detection предоставляет, помимо бинарной метки, вспомогательные метаданные, такие как поддомен и источник оценочного набора. Эта информация используется для создания многозадачной постановки с тремя выходными головками: исходная задача бинарной классификации и две вспомогательные многоклассовые задачи. Такая конфигурация побуждает модель изучать более богатые текстовые представления и отражает теоретическое преимущество MTL в снижении сложности на задачу.

Таблица 6.2: Сравнение метрик модели DeBERTa-v3-base при полной тонкой настройке и адаптации с LoRA на задаче детекции машинно-генерированного текста. LoRA даёт небольшое снижение метрик точности (1.4–3.2%), меньшие потери на валидации (36.3%) и ускорение обучения (12.6%), что согласуется с сохранением формы выходного слоя при низкоранговых обновлениях.

Метрика	DeBERTa	DeBERTa & LoRA	Изменение, %
Точность $\uparrow$	0.7104	0.6876	−3.2
Точность положительного класса $\uparrow$	0.6573	0.6413	−2.4
Полнота $\uparrow$	0.9608	0.9470	−1.4
F_1 -мера $\uparrow$	0.7806	0.7648	−2.0
Потери на валидации $\downarrow$	1.8094	1.1522	+36.3
Время обучения, с $\downarrow$	5570	4867	+12.6

На основе аналитического результата об эффективности Радемахера (теорема 36) выполняется адаптация DeBERTa-base для выполнения необходимых предположений. Обеспечивается: (i) ограничения нормы весов через проецирование параметров на L_2 -шары после каждого обновления; (ii) липшицева непрерывность с помощью спектральной нормализации всех линейных слоев; и (iii) ограниченность входов через нормализацию токеновых эмбеддингов.

Эти модификации обеспечивают соответствие эмпирической постановки теоретическим условиям и позволяют проводить оценку преимуществ MTL в рамках установленной схемы. Подробный процесс подготовки модели описан в алгоритме 1.

Сначала оценивается прогнозная производительность в условиях STL и MTL. Выполняется обучение двух вариантов: (i) базовой STL-модели с частичной тонкой настройкой энкодера и классификационной головой, и (ii) MTL-модели с общим энкодером, обновляемым совместно по всем трем задачам.

Таблица 6.3: Сравнение производительности и эмпирической сложности Радемахера (ERC) модели DeBERTa-v3-base в условиях однозадачного (STL) и многозадачного (MTL) обучения на задаче бинарной классификации GenAI Detection. MTL демонстрирует улучшение метрик качества (F1: 0.781→0.826, ROC-AUC: 0.788→0.834) и более низкий ERC (0.0159 ± 0.0009 против 0.0111 ± 0.0010), что качественно согласуется с тем, что многозадачная постановка может уменьшать измеряемую сложность целевой задачи; прямого вывода $ERC_{MTL} \leq ERC_{STL}/\sqrt{T}$ из теоремы 36 на уровне точных значений не делается.

Модель	Режим	F1 ↑	ROC-AUC ↑	Точность ↑	ERC ↓
DeBERTa	STL	0.781	0.788	0.710	0.0159 ± 0.0009
DeBERTa	MTL	0.826	0.834	0.781	0.0111 ± 0.0010

На этапе тестирования для MTL-модели используется только общий энкодер и бинарная голова, отбрасывая вспомогательные головы. Результаты в таблице 6.3 показывают, что включение вспомогательных задач в процесс обучения улучшает точность на исходной бинарной задаче, подтверждая, что многозадачные сигналы действуют как полезное индуктивное смещение.

Далее, для оценки не только прогнозных улучшений, но и сложности модели на целевой задаче, выполняется прямое сравнение эмпирической сложности Радемахера (ERC). В соответствии с определением, ERC измеряется на тех же данных, что использовались для обучения, после замены истинных меток случайным шумом.

Это гарантирует, что оценка отражает только емкость гипотезного класса, а не информацию о реальных метках. После обучения ERC оценивается исключительно для целевой задачи как для STL, так и для MTL. Результаты представлены в колонке ERC в таблице 6.3.

Процесс подготовки модели к оценке эмпирической сложности Радемахера приведен в алгоритме 1.

Анализ показывает, что MTL не только улучшает прогнозную производительность, но и достигает более низкой эмпирической сложности Радемахера по сравнению с STL. Это демонстрирует, что вспомогательные задачи обеспечивают полезное индуктивное смещение, которое как улучшает обобщающую способность на целевой задаче, так и снижает оцениваемую эмпирическую сложность Радемахера, качественно согласуясь с тем, что многозадачное масштабирование уменьшает шаблонные верхние оценки из теоремы 36.

Таблица 6.4: Сравнение моделей DeBERTa-v3-base при полной тонкой настройке и адаптации с LoRA ($r = 8$) после 5 эпох обучения. LoRA обеспечивает более низкие потери (0.2972 vs 0.3058), более гладкие нормы градиентов (17.41 vs 24.65) и требует только 0.16% параметров от полной модели (296,450 vs 184M), демонстрируя эффективность низкоранговой адаптации.

Модель	Потери	Норма градиента	Время, с	Параметры	Эпох
Полная настройка	0.3058	24.65	679,660	184M (100%)	5
LoRA ($r = 8$)	0.2972	17.41	700,284	296,450 ($\approx 0.16\%$)	5

Все исходные параметры DeBERTa были заморожены, а низкоранговые адаптерные модули были вставлены в каждый блок трансформера. Ранг адаптера выбран $r = 8$, коэффициент масштабирования $\alpha = 32$; в слоях адаптера использовалась доля отсева 0.1. Данная конфигурация выбрана как наиболее эффективная после проведения поиска по сетке для $r = \{8, 16, 32\}$. Это оставляет обучаемыми только 296 450 параметров из 184 млн общих ($\approx 0.16\%$), что согласуется с теоретической мотивацией снижения размерности. Все конфигурации экспериментов указаны в таблице 6.4.

Кроме того, на рис. 6.4 представлена производительность модели: модели

Таблица 6.5: Сравнение конфигураций LoRA с различными рангами $r \in \{8, 16, 32\}$ для модели DeBERTa-v3-base. Анализ показывает, что более высокие ранги ($r = 32$) обеспечивают более низкие потери при обучении, но $r = 8$ обеспечивает лучшее обобщение в данной задаче.

Ранг (r)	Потери	Норма градиента	Время, с
8	0.3413	2.95	1681
16	0.3358	5.18	1684
32	0.3194	2.55	1688

DeBERTa и DeBERTa & LoRA обучались в течение 5 эпох с размороженными 6 слоями из 12. Анализ показывает, что норма градиента является значительно более гладкой для модели, использующей LoRA, по сравнению с моделью без нее. Тот же эффект наблюдается на графике функции потерь обучения: потери при обучении модели с LoRA являются более гладкими и сходятся быстрее, чем у модели без нее.

Для определения оптимального ранга адаптера сравнивается $r = 8, 16, 32$ с точки зрения потерь при обучении, представленных на рис. 6.3. Хотя более высокие ранги, в частности $r = 32$, демонстрировали более быструю сходимость и более низкие финальные потери при обучении, $r = 8$ даёт более высокие метрики на валидации, несмотря на более медленную сходимость. В целом, $r = 8$ был выбран в качестве наиболее эффективной конфигурации в текущей настройке. Конфигурации экспериментов показаны в таблице 6.5.

На основе аналитических результатов об эффективности Радемахера выполняется адаптация DeBERTa-base для выполнения необходимых предположений. Введенные модификации обеспечивают соответствие эмпирической постановки теоретическим условиям и позволяют провести оценку преимуществ MTL в рамках установленной схемы. Подробный процесс подготовки описан в Алго-

ритме 1.

Algorithm 1: Алгоритм обеспечения условий теоремы 36 для оценки эмпирической сложности Радемахера (ERC) с использованием модели DeBERTa. Алгоритм применяет спектральную нормализацию к линейным слоям энкодера, нормализует входные последовательности и проецирует параметры на L_2 -шары для выполнения ограничений на нормы весов, необходимых для теоретического анализа.

Input : Модель $f_t(x) = w_t^\top \phi(x; w_{\text{shared}})$, с ограничениями $B_{\text{shared}}, B_{\text{head}}, R$

Output: Модель удовлетворяющая условиям теоремы 36.

for each *linear layer* W *in encoder* $\phi(\cdot; w_{\text{shared}})$ **do**

$W \leftarrow \text{SpectralNorm}(W)$; // $\|\phi(x; w)\|_2 \leq L\|w\|\|x\|_2$

for each *input sequence* $x = [x_1 \dots x_m]$ **do**

$\tilde{x}_i \leftarrow x_i / \max(1, \|x_i\|_2) \quad \forall i \quad x \leftarrow [\tilde{x}_1 \dots \tilde{x}_m] \cdot \min\left(1, \frac{R}{\|\tilde{x}\|_F}\right)$; // $\|x\| \leq R$

for each *training step* **do**

for each *parameter group* (w, B) *in*

$\{(w_{\text{shared}}, B_{\text{shared}})\} \cup \{(w_t, B_{\text{head}}) \mid t \in [T]\}$ **do**

$w \leftarrow w \cdot \min\left(1, \frac{B}{\|w\|_2}\right)$; // $\|w\|_2 \leq B$

Для оценки ERC обучается как STL, так и MTL модели в контролируемых и сопоставимых условиях. В обоих случаях использовалось одинаковое общее количество обучающих примеров (nT), что гарантирует, что любые наблюдаемые различия в ERC вызваны совместным использованием параметров, а не дисбалансом данных.


В эксперименте STL использовался энкодер DeBERTa-v3-base с одной бинарной классификационной головой, соответствующей целевой задаче. Модель обучалась на $nT = 90,000$ примерах ($n = 30,000, T = 3$), выбранных исключительно из набора данных целевой бинарной классификации. Чтобы гарантиро-




Рис. 6.3: Динамика потерь при обучении модели DeBERTa-v3-base с адаптерами LoRA различных рангов ($r \in \{8, 16, 32\}$) на задаче детекции машинно-генерированного текста. Анализ показывает, что более высокие ранги обеспечивают более быструю сходимость и более низкие финальные потери, но $r = 8$ даёт более высокие метрики обобщения в данном эксперименте.

вать, что ERC отражает репрезентационную способность модели, а не ее соответствие истинному распределению меток, все целевые метки были заменены случайным шумом из $\{-1, 1\}$. Энкодер и классификационная головка подвергались тонкой настройке на этих зашумленных метках в течение 3 эпох. После обучения ERC вычислялась на том же наборе данных со случайными метками.

В настройке MTL использовался тот же энкодер DeBERTa-v3-base, разделяемый между $T = 3$ классификационными головками. Одна головка соответствовала целевой бинарной задаче, в то время как две другие обучались на вспомогательных многоклассовых задачах: предсказание поддомена с 5 классами и предсказание поддомена с 6 классами. Каждая задача предоставляла $n = 30,000$ примеров, так что общий энкодер обрабатывал в сумме $nT = 90,000$ обучающих примеров. Только вспомогательные задачи использовали свои исходные метки; целевая задача использовала зашумленные метки для обеспечения независимости от емкости модели. После обучения ERC оценивалась только



(a) Норма градиента



(b) Ошибка на обучающей выборке

Рис. 6.4: Динамика нормы градиента и потерь при обучении моделей DeBERTa-v3-base с полной тонкой настройкой и адаптацией LoRA ($r = 8$) в течение 5 эпох на задаче детекции машинно-генерированного текста. LoRA демонстрирует более гладкие траектории нормы градиента и потерь, что указывает на более стабильную сходимость в данном эксперименте.

на подмножестве целевой задачи.

Данная процедура гарантирует, что как STL, так и MTL модели обучались в идентичных условиях по объему данных и вычислительным ресурсам. Наблюдаемое в эксперименте уменьшение ERC согласуется с качественной картиной снижения сложности на целевой задаче при совместном обучении энкодера, однако не отождествляется с точным коэффициентом $1/\sqrt{T}$ из верхних оценок теоремы 36.

6.4.2. Эксперименты по декодированию фМРТ

Для анализа производительности предложенного метода и проверки гипотез был проведен вычислительный эксперимент. В качестве данных использовалась выборка, представленная в [186].

Набор данных содержит результаты обследования 63 испытуемых. Для тридцати из них известны данные фМРТ. В выборке 16 мужчин и 14 женщин в возрасте от 7 до 47 лет. Средний возраст испытуемых составляет 22 года. Характеристики выборки: продолжительность обследования, частоты кадров видеопоследовательностей фМРТ и изображений, а также их размеры суммированы в таблице 6.6.

Выборка разделена на обучающую и тестовую части в соотношении 70% и 30% соответственно. Критерием качества реконструкции фМРТ-изображений является MSE — сумма квадратов отклонений между истинными и реконструированными изображениями, усредненная по всем вокселям каждого изображения из тестовой выборки.

Для сокращения времени работы алгоритма фМРТ-изображение предварительно сжимается с использованием слоя MaxPool3D. Рассматриваются коэффициенты сжатия 1, 2, 4 и 8. Значения вокселей нормализованы к диапазону $[0; 1]$ с помощью процедуры MinMaxScale.

Была проанализирована зависимость MSE от параметра регуляризации α .

Таблица 6.6: Характеристики выборки для эксперимента по декодированию фМРТ-изображений из видеопоследовательностей. Выборка содержит данные 30 испытуемых с продолжительностью обследования 390 с, частотой кадров видео 25 Гц и частотой фМРТ-изображений 1.64 Гц, что обеспечивает временное соответствие между видеокадрами и томографическими данными.

Name	Notation	Value
Duration of examination	t	390 s
Video frame rate	ν	25 Hz
fMRI frame rate	μ	1.64 Hz
Video dimensions	W, H, C	640, 480, 3
fMRI dimensions	X, Y, Z	40, 64, 64

Рассматривались коэффициенты сжатия 1, 2, 4 и 8. Соответствующие графики показаны на рис. 6.5. Для построения графика было выполнено усреднение по испытуемым. Показаны границы стандартного отклонения. Графики демонстрируют, что оптимальное значение коэффициента $\alpha \approx 1000$. Форма кривой сохраняется независимо от коэффициента сжатия фМРТ-изображений.

Выполняется сравнение времени обучения модели при использовании различных коэффициентов сжатия фМРТ-изображений. Рассматриваются коэффициенты 1, 2, 4 и 8. Для каждого значения коэффициента сжатия вычисляется среднее значение времени обучения модели для всех испытуемых.

Результаты экспериментов представлены в таблице 6.7. Время работы метода существенно сокращается при использовании предварительного сжатия фМРТ-изображений. Эксперимент с подбором оптимального коэффициента регуляризации подтверждает, что сжатие изображений не изменяет характер зависимостей между параметрами и качеством реконструкции.




Рис. 6.5: Зависимость метрики MSE от параметра регуляризации α для метода декодирования фМРТ-изображений на тестовой выборке при различных коэффициентах сжатия (1, 2, 4, 8). Оптимальное значение коэффициента $\alpha \approx 1000$ сохраняется независимо от коэффициента сжатия, что подтверждает стабильность метода при снижении размерности данных.

6.4.3. Эксперименты по оценке качества данных детекции

Из каждого набора данных выбрано 1000 документов из тестовой выборки, сбалансированных между двумя классами. Для базовых методов выполняется тонкая настройка mdeberta-v3-base для каждого набора данных, после чего модель оценивается. Для оценки качества Binoculars и Fast-DetectGPT использовался falcon-rw-1b [187] и gpt-neo-2.7B [188] соответственно. Следует отметить, что для последних двух методов качество измерялось только на англоязычных выборках. В эксперименте с топологическими признаками использовалась модель roberta-base, как и авторы оригинальной работы. В эксперименте с пертурбациями и перемешиванием энкодер multilingual-e5-large использовался для построения эмбедингов текстов, который показывает высокие метрики для кодирования высокоресурсных языков [189]. Результаты сравнения разработан-

Таблица 6.7: Зависимость среднего времени обучения модели декодирования фМРТ-изображений от коэффициента сжатия данных. Использование предварительного сжатия фМРТ-изображений с коэффициентами 2, 4 и 8 обеспечивает существенное сокращение времени обучения (с 36.3 с до 6.7 с, 1.6 с и 1.4 с соответственно), что показывает сокращение времени обучения при сохранении качества реконструкции в данной постановке.

Compression coefficient	Mean time, s	Std, s
1	36.3	6.1
2	6.7	0.5
4	1.6	0.1
8	1.4	0.3

ных признаков в выбранных наборах данных представлены в таблице 6.9.

Относительно PND и оценки TTS, в предыдущих работах было показано, что тексты языковых моделей имеют меньшие значения PND, чем написанные человеком. Однако данный результат был получен для моделей GPT-2, GPT-3.5 и OPT. Для более современных языковых моделей, которые генерируют более похожие на человеческие тексты, данная тенденция могла измениться.

Высокое значение KL_{TTS} для текстов разного происхождения означает, что детектору легче разделить такие тексты. Следует отметить, что KL_{TTS} также ограничена для более коротких текстов. Относительно PND предполагается, что сгенерированные тексты, близкие к человеческим, имеют близкие значения PND.

Дополнительно сравниваются распределения PND для всех наборов данных на рис. 6.6. Распределения для текстов обоих типов происхождения должны быть схожими, что в основном соблюдается для текстов из SemEval, PAN24 и MGT-1.

Dataset	DeBERTa	Binoculars	DetectGPT
GPT-2	0.972	0.495	0.412
HC3	0.998	0.931	0.972
GhostBuster	0.910	0.683	0.711
MGTBench	0.961	0.364	0.447
MAGE	0.835	0.632	0.654
M4	0.987	0.871	0.881
OutFox	0.901	0.692	0.707
TweepFake	0.941	0.845	0.864
SemEval24 Mono	0.991	0.913	0.924
SemEval24 Multi	0.994	—	—
RuATD	0.765	—	—
DAGPap22	0.968	0.333	0.562
PAN24	0.826	0.411	0.890
AuTex23en	0.941	0.783	0.911
AuTex23es	0.933	—	—
IberAuTex	0.964	—	—
MGT-1 Mono	0.904	0.665	0.683
MGT-1 Multi	0.934	—	—

Таблица 6.8: Результаты классификации различных детекторов машинно-генерированного текста (DeBERTa, Binoculars, DetectGPT) на множественных наборах данных, оцененные с помощью метрики F_1 -score. Детектор на основе DeBERTa демонстрирует наиболее стабильную производительность на различных наборах данных, тогда как Binoculars и DetectGPT показывают значительные вариации, что указывает на проблемы с устойчивостью этих методов к различным доменам.

Dataset	KL _{TTS} ↓	PHD _{human}	PHD _{machine}	Δ_{shift} ↓	KL _{shuffle} ↓
GPT-2	0.014	9.23 ± 1.98	10.27 ± 1.84	0.084	1.255
HC3	0.053	8.76 ± 1.83	7.38 ± 1.05	0.264	1.167
GhostBuster	0.053	9.84 ± 1.18	9.76 ± 1.15	0.024	0.359
MGTBench	0.043	8.77 ± 1.31	9.97 ± 1.02	0.031	0.421
MAGE	0.011	9.8 ± 2.14	9.38 ± 3.04	0.094	0.310
M4	0.036	7.26 ± 1.99	8.59 ± 1.4	0.107	0.483
OutFox	0.025	8.96 ± 1.21	11.48 ± 1.13	0.095	0.237
TweepFake	-	9.02 ± 3.19	8.12 ± 4.02	0.116	1.001
SemEval24 Mono	0.012	9.11 ± 1.19	9.41 ± 1.2	0.191	2.576
SemEval24 Multi	0.001	9.65 ± 1.81	9.42 ± 1.44	0.059	2.046
RuATD	<u>0.007</u>	7.33 ± 1.4	7.46 ± 1.41	0.315	14.028
DAGPap22	0.083	8.35 ± 1.33	7.48 ± 2.01	0.039	0.472
PAN24	0.053	9.4 ± 1.05	8.52 ± 1.59	0.050	0.331
AuTex23 Eng	<u>0.021</u>	8.07 ± 2.26	8.1 ± 2.68	0.110	4.331
AuTex23 Esp	<u>0.001</u>	9.16 ± 3.49	9.25 ± 3.26	0.105	1.306
IberAuTex	0.012	9.33 ± 2.45	8.47 ± 2.73	0.223	5.516
MGT-1 Mono	0.019	9.19 ± 1.75	8.96 ± 2.24	0.031	0.587
MGT-1 Multi	0.006	8.76 ± 1.85	8.6 ± 2.29	0.027	0.522

Таблица 6.9: Статистика качества данных для выбранных наборов данных детекции машинно-генерированного текста, включающая метрики KL_{TTS}, PHD, Δ_{shift} и KL_{shuffle}. Высокие значения метрик указывают на различимость текстов разного происхождения, тогда как низкие значения отражают схожую устойчивость к модификациям, что является признаком качественных данных.

В следующих столбцах приводится статистика, наблюдаемая на модифицированных текстах. Для обеих метрик (Δ_{shift} и KL_{shuffle}) чем ниже значение, тем




Рис. 6.6: Распределения размерности персистентной гомологии (PHD) для человеческих и машинно-сгенерированных текстов в различных наборах данных детекции. Качественные наборы данных (SemEval, PAN24, MGT-1) демонстрируют схожие распределения PHD для обоих типов текстов, что указывает на высокое качество сгенерированных данных и их близость к человеческим текстам по топологическим характеристикам.

лучше, так как это отражает схожую степень устойчивости сгенерированных и человеческих текстов к адверсарным атакам. Качественно сгенерированные




Рис. 6.7: Топологические временные ряды (TTS) для четырех наборов данных с высокими значениями метрики KL_{TTS} : GhostBuster, PAN24, MGTBench и DAGPap22. Высокие значения KL_{TTS} для GhostBuster и PAN24 обусловлены расхождением в текстах с более высокими размерностями, тогда как для MGTBench и DAGPap22 — разницей в самих распределениях PHD, что указывает на различные типы различий между человеческими и машинно-сгенерированными текстами.

данные без смещений должны принимать значения, близкие к человеческим.

В таблице 6.8 показаны результаты применения современных детекторов к выбранным тестовым наборам данных. На наборах данных с низкими значениями метрик качества в таблице 6.9 может быть достигнуто качество, близкое к 1, что указывает на явное наличие смещения детектора в их сторону или структурной особенности, которая слишком очевидна для модели детекции.

Невозможно судить о качестве данных только по достижению значений F_1 , близких к 1. Однако комбинирование значений двух таблиц позволяет оценить, какой набор имеет данные лучшего качества, а какой — худшего.

Относительно KL_{TTS} , на рис. 6.7 показаны 4 набора данных с высоким значением этого показателя. GhostBuster и PAN24 получили такой высокий балл из-за расхождения в текстах с более высокими размерностями, тогда как MGTBench и DAGPap22 — из-за разницы в самих распределениях.

Отметим, что KL_{TTS} неустойчива на очень коротких текстах, поскольку

внутренний метод вычисления PND требует достаточно длинных текстов для стабильного вычисления. По этой причине KL_{TTS} для RuATD, AuTex23-es и Tweerfake отбрасываются, так как они не соответствуют критериям. Кроме того, показано, что тексты должны быть достаточной длины [190] для построения надежных детекторов.

Значения в таблице 6.9 различаются по наборам данных; предложенные атрибуты отражают разные аспекты качества коллекции.

Предлагается использовать эти атрибуты в сочетании с другими статистическими инструментами для оценки качества данных, например, с законом Ципфа [191].

Представленная статистика может быть использована для оценки качества коллекций и их улучшения. Кроме того, наборы данных, собирающие машинно-генерированный контент, могут быть полезны для двух более общих целей. Во-первых, высококачественные сгенерированные данные могут быть использованы для оценки качества каузальной модели во время обучения, что служит одной из целей обучения для улучшения ответов модели и приближения их к человеческим. Во-вторых, надёжные детекторы могут помочь очистить обучающие наборы, поскольку большая доля низкокачественных сгенерированных текстов в этих наборах может привести к возникновению смещений в сторону некорректной структуры и артефактов в выходных данных модели в будущем.

Вопрос о том, означает ли низкая производительность детекторов низкое качество набора данных, не имеет однозначного ответа. Например, в [176] метод Binoculars достигает оценки F_1 , близкой к 1.0, в то время как в проведенных экспериментах был получен широкий диапазон оценок: от 0.33 на DAGPar22 до 0.93 на HC3. Для HC3 все три детектора показали схожие результаты, что позволяет предположить, что тексты HC3 относительно легко обнаружить. Однако данная согласованность не распространяется на DAGPar22. Детектор на основе DeBERTa достиг оценки F_1 0.96, в то время как DetectGPT показал только 0.562. Данная закономерность, когда детектор на основе DeBERTa демонстри-

рует заметно более высокие результаты, чем два других метода, наблюдалась на значительной части проанализированных наборов данных.

Низкие оценки для Binoculars требуют отдельного анализа. Даже при фокусировке на доменах, специально протестированных его авторами, таких как PAN24 и Outfox, оценки оказываются значительно ниже почти идеальных результатов, представленных в [176]. Данное расхождение позволяет предположить, что результаты Binoculars существенно зависят от постановки оценки. Аналогично, в проведенных экспериментах оценки DetectGPT сопоставимы с оценками Binoculars, что указывает на схожие базовые проблемы с устойчивостью этих детекторов.

6.5. Заключение

В настоящей главе формализм сложности модели и данных применён к трём прикладным постановкам.

Для LoRA и многозадачного обучения получены утверждения о состоятельности минимизации эмпирического риска (теорема 34), о сохранении формы выходного классификационного правила при низкоранговых обновлениях (теорема 35) и о сравнении верхних оценок радемахеровской сложности STL и MTL при справедливом масштабировании параметров энкодера (теорема 36). В численных экспериментах на детекции машинно-генерированного текста LoRA с $r = 8$ давала небольшое снижение метрик точности (порядка 1,4–3,2%) при меньших потерях на валидации, ускорении обучения и доле обучаемых параметров около 0,16% от полной модели. Многозадачное обучение с тремя выходными головками повышало F1 и ROC-AUC и снижало эмпирическую радемахеровскую сложность, что качественно согласуется с оценками теоремы 36.

В задаче декодирования фМРТ из видеопоследовательностей использованы векторизация кадров (ResNet152) и линейная регрессия с L_2 -регуляризацией разностей последовательных снимков. Предварительное сжатие томограмм с

коэффициентами 2, 4 и 8 сокращало время обучения (с 36,3 с до 6,7 с, 1,6 с и 1,4 с) при сохранении качества реконструкции; оптимальное $\alpha \approx 1000$ сохранялось при разных коэффициентах сжатия.

Для оценки качества наборов детекции машинной генерации введены метрики KL_{TTS} , RHD , Δ_{shift} и $KL_{shuffle}$. На рассмотренных коллекциях детектор на основе DeBERTa давал более устойчивые значения метрик по доменам, чем DetectGPT и Binoculars; наборы SemEval, PAN24 и MGT-1 имели близкие распределения RHD для человеческих и машинных текстов.

Ограничения связаны с чувствительностью топологических характеристик на коротких текстах, с доменной зависимостью детекторов и с тем, что обоснование сжатия фМРТ в текущей постановке опирается на линейную регрессию. Согласование прикладных метрик с ландшафтной мерой сложности и выбор ранга LoRA по теоретическим оценкам Радемахера остаются направлениями дальнейшего анализа.

Заключение

В диссертации решена проблема отсутствия аппарата согласования сложности параметрических моделей машинного обучения с характеристиками обучающей выборки и методов снижения сложности таких моделей. Цель исследований достигнута: построен теоретический аппарат оценки согласованности сложности модели и выборки на основе анализа ландшафта функции потерь, а также методы снижения сложности параметрических моделей.

Основные результаты диссертационной работы перечислены в следующих пунктах:

1. Введены формальные определения мер сложности модели и выборки, сформулирован критерий их согласованности.
2. Введена ландшафтная мера сложности модели на основе спектральных свойств матриц Гессе; установлена ее связь с приращением эмпирического риска при изменении выборки.
3. Получены оценки ландшафтной меры для полносвязных, сверточных и трансформерных архитектур: оценки растут экспоненциально с глубиной сети и полиномиально с шириной и числом каналов.
4. Показано, что методы оценки достаточного объема выборки по близости апостериорных распределений параметров сходятся в модели линейной регрессии.
5. Предложены методы снижения сложности на основе редукции пространства обучаемых параметров; показано, что редукция уменьшает число параметров модели при сохранении порядка качества аппроксимации.
6. Для низкоранговой адаптации доказана состоятельность оценки; для многозадачного обучения получено сравнение верхних оценок эмпирической радемахеровской сложности на задачу.

В целом совокупность полученных теоретических и практических результатов позволяет считать научную проблему формализованной в рамках единого

подхода, применимого к широкому классу параметрических моделей машинного обучения. Получены вычислимо интерпретируемые методы оценки сложности и снижения числа обучаемых параметров, подтвержденные экспериментально на реальных задачах. Перечисленные результаты получили апробацию на ведущих международных конференциях и в научных публикациях.

Общие свойства и определения

Свойство 1 (Норма матричного произведения). Пусть матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$ и $\mathbf{B} \in \mathbb{R}^{n \times q}$, тогда справедливо неравенство

$$\|\mathbf{AB}\|_2 \leq \|\mathbf{A}\|_2 \|\mathbf{B}\|_2$$

Свойство 2 (Норма матричного произведения Кронекера). Пусть матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$ и $\mathbf{B} \in \mathbb{R}^{p \times q}$, тогда справедливо равенство

$$\|\mathbf{A} \otimes \mathbf{B}\|_2 = \|\mathbf{A}\|_2 \|\mathbf{B}\|_2$$

Свойство 3 (Норма матричного транспонирования). Пусть матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$, тогда справедливо равенство

$$\|\mathbf{A}\|_2 = \|\mathbf{A}^\top\|_2$$

Свойство 4 (Соотношения между матричными нормами). Пусть матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$, тогда следующие неравенства между матричными нормами справедливы:

$X \backslash Y$	$\ \mathbf{A}\ _{\max}$	$\ \mathbf{A}\ _1$	$\ \mathbf{A}\ _\infty$	$\ \mathbf{A}\ _2$	$\ \mathbf{A}\ _F$
$\ \mathbf{A}\ _{\max}$		1	1	1	1
$\ \mathbf{A}\ _1$	m		m	$\sqrt{m}$	$\sqrt{m}$
$\ \mathbf{A}\ _\infty$	n	n		$\sqrt{n}$	$\sqrt{n}$
$\ \mathbf{A}\ _2$	$\sqrt{mn}$	$\sqrt{n}$	$\sqrt{m}$		1
$\ \mathbf{A}\ _F$	$\sqrt{mn}$	$\sqrt{n}$	$\sqrt{m}$	$\sqrt{d}$	1

где $d = \text{rank}(\mathbf{A})$. Таблица читается следующим образом: для каждой пары норм $\|\cdot\|_X$ и $\|\cdot\|_Y$,

$$\|\mathbf{A}\|_X \leq c \cdot \|\mathbf{A}\|_Y$$

где $c \geq 0$ — неотрицательная константа на пересечении строки X и столбца Y .

Свойство 5 (Связь между vec и vec_r). Пусть задана матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$. Тогда оператор построчной векторизации vec_r и стандартный оператор по координатной векторизации vec связаны через операцию транспонирования:

$$\text{vec}_r(\mathbf{A}) = \text{vec}(\mathbf{A}^\top)$$

Свойство 6 (Норма матричной суммы). Пусть матрицы $\mathbf{A}$ и $\mathbf{B}$ принадлежат пространству матриц $\mathbb{R}^{m \times n}$, тогда

$$\|\mathbf{A} + \mathbf{B}\|_2 \leq \|\mathbf{A}\|_2 + \|\mathbf{B}\|_2$$

Свойство 7 (Неравенство для нормы блочной матрицы). Пусть матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$ представляет собой блочную матрицу, разбитую на блоки $\mathbf{B}_{i,j}$ размеров $m_i \times n_j$, где $\sum_i m_i = m$ и $\sum_j n_j = n$. Тогда справедливо неравенство:

$$\|\mathbf{A}\|_2 \leq \sqrt{mn} \max_{i,j} \|\mathbf{B}_{i,j}\|_2$$

Отметим, что если матрица $\mathbf{A}$ является блочно-диагональной, то имеет место строгое равенство $\|\mathbf{A}\|_2 = \max_i \|\mathbf{B}_{i,i}\|_2$, что следует из того, что спектральная норма блочно-диагональной матрицы равна максимальной спектральной норме диагональных блоков.

Свойство 8 (Поэлементное деление). Пусть задана матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$ и вектор $\mathbf{b} \in \mathbb{R}^{m \times 1}$ такой, что $b_i \neq 0$ для всех $i = 1, \dots, m$. Тогда для матрицы $\mathbf{C} \in \mathbb{R}^{m \times n}$, где $c_{i,j} = \frac{a_{i,j}}{b_i}$, справедливо равенство

$$\mathbf{C} = \text{diag}^{-1}(\mathbf{b})\mathbf{A}$$

Свойство 9 (Производная матричного произведения). Пусть заданы матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{X} \in \mathbb{R}^{n \times q}$ и $\mathbf{B} \in \mathbb{R}^{q \times p}$, тогда

$$\frac{\partial \mathbf{A}\mathbf{X}\mathbf{B}}{\partial \mathbf{X}} = \mathbf{A} \otimes \mathbf{B}^\top$$

где $\mathbf{A}$ и $\mathbf{B}$ не зависят от $\mathbf{X}$.

Свойство 10 (Построчная векторизация произведения Адамара). Пусть заданы матрицы $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$. Тогда

$$\text{vec}_r(\mathbf{A} \circ \mathbf{B}) = \text{diag}(\text{vec}_r(\mathbf{A}))\text{vec}_r(\mathbf{B})$$

где $\circ$ обозначает произведение Адамара.

Утверждение непосредственно следует из [192], где был получен аналогичный результат для покоординатной векторизации.

Свойство 11 (Построчная векторизация матричного произведения). Пусть заданы матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{X} \in \mathbb{R}^{n \times q}$ и $\mathbf{B} \in \mathbb{R}^{q \times p}$, тогда

$$\text{vec}_r(\mathbf{A}\mathbf{X}\mathbf{B}) = (\mathbf{A} \otimes \mathbf{B}^\top)\text{vec}_r(\mathbf{X})$$

Свойство 12 (Производная произведения Кронекера). Пусть заданы матрица $\mathbf{X} \in \mathbb{R}^{n \times q}$ и матрица $\mathbf{Y} \in \mathbb{R}^{p \times r}$. Тогда

$$\frac{\partial(\mathbf{X} \otimes \mathbf{Y})}{\partial \mathbf{X}} = (\mathbf{I}_n \otimes \mathbf{K}_{p,q} \otimes \mathbf{I}_r) (\mathbf{I}_{nq} \otimes \text{vec}_r(\mathbf{Y})),$$

и аналогично

$$\frac{\partial(\mathbf{X} \otimes \mathbf{Y})}{\partial \mathbf{Y}} = (\mathbf{I}_n \otimes \mathbf{K}_{p,q} \otimes \mathbf{I}_r) (\text{vec}_r(\mathbf{X}) \otimes \mathbf{I}_{pr}).$$

Определение 31 (Матрица перестановки). Матрица перестановки $\mathbf{K}_{m,n} \in \mathbb{R}^{mn \times mn}$ — это единственная матрица такая, что для любой матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$ выполняется:

$$\mathbf{K}_{m,n}\text{vec}(\mathbf{A}) = \text{vec}(\mathbf{A}^\top)$$

В силу свойства 5 справедливо соотношение:

$$\text{vec}_r(\mathbf{A}) = \mathbf{K}_{m,n}\text{vec}(\mathbf{A}) \quad \text{и} \quad \text{vec}(\mathbf{A}) = \mathbf{K}_{n,m}\text{vec}_r(\mathbf{A})$$

поскольку $\mathbf{K}_{n,m}\mathbf{K}_{m,n} = \mathbf{I}_{mn}$.

Определение 32 (Векторизация и поэлементные операции). Пусть задана матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$ и вектор $\mathbf{v} \in \mathbb{R}^n$. Тогда

- $\text{vec}_r(\mathbf{A})$ обозначает построчную векторизацию матрицы $\mathbf{A}$, отображающую матрицу $\mathbf{A}$ в вектор размерности tn путем последовательной записи строк матрицы.
- $\mathbf{A}^{\circ\alpha}$ обозначает поэлементное возведение матрицы $\mathbf{A}$ в степень α , то есть $(\mathbf{A}^{\circ\alpha})_{ij} = (\mathbf{A}_{ij})^\alpha$ для всех $i = 1, \dots, m$ и $j = 1, \dots, n$.
- $\text{diag}(\mathbf{v})$ создает диагональную матрицу размерности $n \times n$ с вектором $\mathbf{v}$ на главной диагонали и нулями вне главной диагонали.

Определение 33 (Матричные нормы). Для матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$, где $r = \text{rank}(\mathbf{A})$ и $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ — упорядоченные по убыванию сингулярные числа матрицы $\mathbf{A}$ (с учетом кратности), определены следующие нормы:

$$\begin{aligned}\|\mathbf{A}\|_2 &= \sigma_1, \\ \|\mathbf{A}\|_F &= \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\sum_{i=1}^r \sigma_i^2}, \\ \|\mathbf{A}\|_1 &= \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|, \\ \|\mathbf{A}\|_\infty &= \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|, \\ \|\mathbf{A}\|_{\max} &= \max_{i,j} |a_{ij}|.\end{aligned}$$

Дополнительные леммы и утверждения

Лемма 37 (Производная умножения матричнозначных функций). Пусть заданы $\mathbf{A}(\mathbf{X}) \in \mathbb{R}^{p \times r}$ и $\mathbf{B}(\mathbf{X}) \in \mathbb{R}^{r \times q}$ матричнозначные функции переменной $\mathbf{X}$, тогда справедливо равенство

$$\frac{\partial \mathbf{A}(\mathbf{X})\mathbf{B}(\mathbf{X})}{\partial \mathbf{X}} = (\mathbf{A} \otimes \mathbf{I}_q) \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + (\mathbf{I}_p \otimes \mathbf{B}^\top) \frac{\partial \mathbf{A}}{\partial \mathbf{X}}$$

Доказательство. Применим цепное правило для вычисления производной сложной функции, а затем объединим его со свойством 9

$$\begin{aligned} \frac{\partial \mathbf{A}(\mathbf{X})\mathbf{B}(\mathbf{X})}{\partial \mathbf{X}} &= \frac{\partial \mathbf{A}\mathbf{B}}{\partial \mathbf{B}} \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + \frac{\partial \mathbf{A}\mathbf{B}}{\partial \mathbf{A}} \frac{\partial \mathbf{A}}{\partial \mathbf{X}} = \\ &= \frac{\partial \mathbf{A}\mathbf{B}\mathbf{I}_q}{\partial \mathbf{B}} \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + \frac{\partial \mathbf{I}_p \mathbf{A}\mathbf{B}}{\partial \mathbf{A}} \frac{\partial \mathbf{A}}{\partial \mathbf{X}} = \\ &= (\mathbf{A} \otimes \mathbf{I}_q) \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + (\mathbf{I}_p \otimes \mathbf{B}^\top) \frac{\partial \mathbf{A}}{\partial \mathbf{X}} \end{aligned}$$

□

Лемма 38 (Теорема идентификации для построчной векторизации). Пусть отображение $\mathbf{F} : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$ является дифференцируемой матричнозначной функцией от $\mathbf{X} \in \mathbb{R}^{m \times n}$. Если дифференциал функции $\mathbf{F}$ может быть записан в виде:

$$d\text{vec}_r(\mathbf{F}(\mathbf{X})) = \mathbf{J} \cdot d\text{vec}_r(\mathbf{X}),$$

где матрица $\mathbf{J} \in \mathbb{R}^{pq \times mn}$ является некоторой константной матрицей относительно переменной $d\mathbf{X}$, тогда матрица $\mathbf{J}$ является матрицей Якоби преобразования $\mathbf{F}(\mathbf{X})$ относительно построчной векторизации. Обозначим это в следующем виде:

$$\frac{\partial \mathbf{F}(\mathbf{X})}{\partial \mathbf{X}} := \frac{\partial \text{vec}_r(\mathbf{F}(\mathbf{X}))}{\partial (\text{vec}_r(\mathbf{X}))^\top} = \mathbf{J}$$

Доказательство. Это построчный vec_r -аналог первой теоремы об идентификации (англ. first identification theorem) в главе 12 [192] для векторизации по столбцам. □

Лемма 39 (Производная квадрата Адамара). Для матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$ справедливо равенство

$$\frac{\partial \mathbf{A}^{\circ 2}}{\partial \mathbf{A}} = 2 \cdot \text{diag}(\text{vec}_r(\mathbf{A})).$$

Доказательство. Используем определение 32, а именно $(\mathbf{A}^{\circ 2})_{ij} = (\mathbf{A}_{ij})^2$. Выполняя поэлементное взятие дифференциала, получим:

$$d(\mathbf{A}^{\circ 2}) = 2\mathbf{A} \circ d\mathbf{A}.$$

Далее, применяя оператор vec_r и используя свойство 10, получим выражение:

$$\text{vec}_r(d(\mathbf{A}^{\circ 2})) = 2\text{diag}(\text{vec}_r(\mathbf{A}))\text{vec}_r(d\mathbf{A}),$$

причем, используя построчный аналог первой теоремы об идентификации 38, получим следующий вид:

$$\frac{\partial \mathbf{A}^{\circ 2}}{\partial \mathbf{A}} = \frac{\partial \text{vec}_r(\mathbf{A}^{\circ 2})}{\partial \text{vec}_r(\mathbf{A})} = 2 \cdot \text{diag}(\text{vec}_r(\mathbf{A})).$$

□

Лемма 40 (Производная корня Адамара). Для матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$ такой, что $a_{ij} > 0$ для всех $i = 1, \dots, m$ и $j = 1, \dots, n$, справедливо равенство

$$\frac{\partial \mathbf{A}^{\circ \frac{1}{2}}}{\partial \mathbf{A}} = \frac{1}{2} \text{diag}^{-1}(\text{vec}_r^{\circ \frac{1}{2}}(\mathbf{A})).$$

Доказательство. Аналогично доказательству леммы 39 получим $d(\mathbf{A}^{\circ 1/2}) = \frac{1}{2} \mathbf{A}^{\circ -1/2} \circ d\mathbf{A}$, откуда в векторном виде получим следующее выражение:

$$\frac{\partial \mathbf{A}^{\circ \frac{1}{2}}}{\partial \mathbf{A}} = \frac{\partial \text{vec}_r(\mathbf{A}^{\circ \frac{1}{2}})}{\partial \text{vec}_r(\mathbf{A})} = \frac{1}{2} \text{diag}^{-1}(\text{vec}_r^{\circ \frac{1}{2}}(\mathbf{A})).$$

□

Лемма 41 (Производная обратной матрицы). Пусть задана обратимая квадратная матрица $\mathbf{D} \in \mathbb{R}^{n \times n}$ такая, что $\det(\mathbf{D}) \neq 0$, тогда справедливо равенство:

$$\frac{\partial \mathbf{D}^{-1}}{\partial \mathbf{D}} = -\mathbf{D}^{-1} \otimes \mathbf{D}^{-\top}.$$

Доказательство. По определению из [193] и [192]:

$$d(\mathbf{D}^{-1}) = -\mathbf{D}^{-1}(d\mathbf{D})\mathbf{D}^{-1}.$$

Используя оператор vec_r и свойство 11, получим

$$\text{vec}_r(-\mathbf{D}^{-1}(d\mathbf{D})\mathbf{D}^{-1}) = (-\mathbf{D}^{-1} \otimes \mathbf{D}^{-\top})\text{vec}_r(d\mathbf{D}),$$

причем, используя лемму 38, получим:

$$\text{vec}_r(d\mathbf{D}^{-1}) = \frac{\partial \text{vec}_r \mathbf{D}^{-1}}{\partial \text{vec}_r \mathbf{D}} \text{vec}_r(d\mathbf{D}).$$

Следовательно, получим выражение, которое завершает доказательство леммы:

$$\frac{\partial \text{vec}_r \mathbf{D}^{-1}}{\partial \text{vec}_r \mathbf{D}} = (-\mathbf{D}^{-1} \otimes \mathbf{D}^{-\top}).$$

□

Лемма 42 (Производная $\text{diag}(\cdot)$). Для вектора $\mathbf{v} \in \mathbb{R}^{L \times 1}$ справедливо равенство:

$$\frac{\partial \text{diag}(\mathbf{v})}{\partial \mathbf{v}} = (\mathbf{e}_1 \otimes \mathbf{e}_1 \quad \dots \quad \mathbf{e}_L \otimes \mathbf{e}_L),$$

где векторы $\mathbf{e}_i$ являются базисными в пространстве $\mathbb{R}^L$.

Доказательство. По определению 32 оператор $\text{diag}(\mathbf{v})$ отображает элемент v_i в позицию (i, i) результирующей диагональной матрицы. Тогда производная оператора $\text{diag}(\mathbf{v})$ является матрицей $\mathbf{E}_{ii} = \mathbf{e}_i \mathbf{e}_i^\top$, в которой 1 в позиции (i, i) и 0 иначе. Причем, используя свойство 11 и применяя оператор построчной векторизации, получим:

$$\text{vec}_r(\mathbf{E}_{i,i}) = \mathbf{e}_i \otimes \mathbf{e}_i.$$

Таким образом, применяя для всех $i = 1, \dots, L$, матрица Якоби принимает вид:

$$\frac{\partial \text{diag}(\mathbf{v})}{\partial \mathbf{v}} = (\mathbf{e}_1 \otimes \mathbf{e}_1 \quad \dots \quad \mathbf{e}_L \otimes \mathbf{e}_L).$$

□

Лемма 43 (Производная транспонированной матрицы). Пусть задана матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$, тогда справедливо следующее равенство:

$$\frac{\partial \mathbf{A}^\top}{\partial \mathbf{A}} = \mathbf{K}_{n,m},$$

где матрица $\mathbf{K}_{n,m}$ является коммутационной матрицей (англ. *commutation matrix*) описанной в определении 31.

Доказательство. Объединяя аналогичное утверждение из [192] для постолбцовой векторизации с правилом соединения столбцов и строк 5 и 31, получим утверждение леммы. $\square$

Лемма 44 (Производная произведения Кронекера матричнозначных функций). Пусть заданы матричнозначные функции $\mathbf{A}(\mathbf{X}) \in \mathbb{R}^{n \times q}$ и $\mathbf{B}(\mathbf{X}) \in \mathbb{R}^{p \times r}$ переменной $\mathbf{X} \in \mathbb{R}^{m \times s}$, тогда справедливо равенство

$$\frac{\partial \mathbf{A}(\mathbf{X}) \otimes \mathbf{B}(\mathbf{X})}{\partial \mathbf{X}} = (\mathbf{I}_n \otimes \mathbf{K}_{p,q} \otimes \mathbf{I}_r) \left((\text{vec}_r \mathbf{A} \otimes \mathbf{I}_{pr}) \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + (\mathbf{I}_{nq} \otimes \text{vec}_r \mathbf{B}) \frac{\partial \mathbf{A}}{\partial \mathbf{X}} \right).$$

Доказательство. Применим цепное правило для вычисления производной сложной функции, а затем объединим его со свойством 12

$$\begin{aligned} \frac{\partial \mathbf{A}(\mathbf{X}) \otimes \mathbf{B}(\mathbf{X})}{\partial \mathbf{X}} &= \frac{\partial \mathbf{A} \otimes \mathbf{B}}{\partial \mathbf{B}} \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + \frac{\partial \mathbf{A} \otimes \mathbf{B}}{\partial \mathbf{A}} \frac{\partial \mathbf{A}}{\partial \mathbf{X}} = \\ &= (\mathbf{I}_n \otimes \mathbf{K}_{p,q} \otimes \mathbf{I}_r) (\text{vec}_r \mathbf{A} \otimes \mathbf{I}_{pr}) \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + \\ &\quad + (\mathbf{I}_n \otimes \mathbf{K}_{p,q} \otimes \mathbf{I}_r) (\mathbf{I}_{nq} \otimes \text{vec}_r \mathbf{B}) \frac{\partial \mathbf{A}}{\partial \mathbf{X}} = \\ &= (\mathbf{I}_n \otimes \mathbf{K}_{p,q} \otimes \mathbf{I}_r) \left((\text{vec}_r \mathbf{A} \otimes \mathbf{I}_{pr}) \frac{\partial \mathbf{B}}{\partial \mathbf{X}} + (\mathbf{I}_{nq} \otimes \text{vec}_r \mathbf{B}) \frac{\partial \mathbf{A}}{\partial \mathbf{X}} \right). \end{aligned}$$

$\square$

Лемма 45 (Спектральная норма матрицы из единиц). Пусть задана матрица $\mathbf{A} = \mathbf{1}_{L \times L}$, все элементы которой равны единице. Тогда ее спектральная норма принимает следующее значение:

$$\|\mathbf{A}\|_2 = L$$

Доказательство. Используя основные свойства линейной алгебры, получим $\text{tr}(\mathbf{A}) = L$ и $\text{rank}(\mathbf{A}) = 1 = \dim(\text{Im}(\mathbf{A}))$. Следовательно, используя $\dim(\text{Im}(\mathbf{A})) + \dim(\text{Ker}(\mathbf{A})) = L$, получим $\dim(\text{Ker}(\mathbf{A})) = L - 1$. Таким образом, для $i \in \{2, \dots, L\}$ имеем $\lambda_i = 0$, а $\lambda_1 = L$. Тогда единственное ненулевое сингулярное число матрицы $\mathbf{A}$ равно $\sqrt{L^2} = L$. Следовательно, получим, что $\|\mathbf{A}\|_2 = L$, в соответствии с определением 33. $\square$

Список иллюстраций

2.1	Изменение функции потерь $\mathcal{L}_k(\boldsymbol{\theta})$ при добавлении нового объекта в выборку. Иллюстрация демонстрирует зависимость абсолютной разности $ \mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta}) $ от размера выборки k , что является основой для анализа сходимости ландшафта и определения ландшафтной меры сложности модели.	69
2.2	Линейный класс: μ_f (левая ось) и эмпирическая $\hat{\mathfrak{R}}_m$ (правая ось) в зависимости от размерности n при фиксированном объеме выборки $m = 256$ и $W = 2$	104
2.3	Линейный класс: изменение объема выборки m при фиксированных $n = 64$ и $W = 2$	105
2.4	Двухслойная FC ReLU-сеть: эмпирическая μ_f (левая логарифмическая ось) с опорными кривыми худшего случая $\propto (Mh)^4$ и GN-масштабирования с учетом остатков $\propto h^3$; эмпирическая $\hat{\mathfrak{R}}_m$ (правая логарифмическая ось).	106
2.5	Валидационная ошибка в зависимости от числа обработанных обучающих токенов	114
2.6	Ландшафтная мера в процессе обучения	115
2.7	Для трех архитектур на одном графике показаны валидационная ошибка сплошной линией и ландшафтная мера пунктиром по числу обработанных токенов	116
2.8	Зависимость между валидационной ошибкой и ландшафтной мерой для выборочных архитектур	117
2.9	Отклонение наблюдаемой ландшафтной меры от значения, предсказанного линейной моделью по валидационной ошибке и логарифму числа обучающих токенов	119
2.10	Отклонения меры от линейной модели, после усреднения по восьми независимым запускам в каждой ячейке	120

2.11	Выборочное среднее μ по восьми независимым запускам	121
2.12	Доля последовательных пар контрольных точек с $\Delta\mathcal{L}_{\text{val}} < 0$ и $\Delta\mu > 0$ по ячейкам (L, E) первой части эксперимента	122
2.13	Финальная контрольная точка первой части эксперимента: μ и $\mathcal{L}_{\text{val}}$ против десятичного логарифма числа обучаемых параметров N_{params} для 36 архитектур	123
2.14	Выборочное среднее μ по восьми запускам на контрольной точке с индексом, близким к медиане по сетке, и финальная валидаци- онная ошибка по архитектурам первой части эксперимента	124
2.15	Проверка предположения 1 о сходимости локальных миниму- мов при увеличении объема выборки. График демонстрирует вы- полнимость предположения о том, что локальный минимум θ^* функции потерь $\mathcal{L}_k(\theta)$ остается локальным минимумом функции $\mathcal{L}_{k+1}(\theta)$ при добавлении нового объекта, причем выполнимость улучшается с увеличением длины последовательностей.	125
2.16	Зависимость абсолютного значения разности функций потерь $ \mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta) $ от размера выборки k для полносвязной ней- ронной сети на наборе данных MNIST. Левый график: при $L = 5$ уменьшение разности с увеличением размера скрытого слоя h от 4 до 64; правый график: при $h = 16$ увеличение разности с увели- чением количества слоев L от 1 до 10. Результаты подтверждают теорему 3.	125

- 2.17 Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})|$ от размера выборки k для полносвязной нейронной сети с предобученным экстрактором признаков (Vision Transformer, ViT) на наборе данных MNIST. Левый график: при $L = 5$ уменьшение разности с увеличением h от 4 до 64; правый график: при $h = 16$ увеличение разности с увеличением L от 1 до 10. Результаты подтверждают независимость сходимости от природы пространства исходных объектов и согласуются с теоремой 3.126
- 2.18 Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})|$ от размера выборки k для полносвязной нейронной сети при прямой классификации на наборах данных FashionMNIST, CIFAR10 и CIFAR100. Верхний ряд: при $L = 5$ уменьшение разности с увеличением h от 4 до 64; нижний ряд: при $h = 16$ увеличение разности с увеличением L от 1 до 10. Результаты подтверждают теорему 3 для различных наборов данных.133
- 2.19 Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})|$ от размера выборки k для полносвязной нейронной сети с предобученным экстрактором признаков (англ. Vision Transformer, ViT) на наборах данных FashionMNIST, CIFAR10 и CIFAR100. Верхний ряд: при $L = 5$ уменьшение разности с увеличением h от 4 до 64; нижний ряд: при $h = 16$ увеличение разности с увеличением L от 1 до 10. Результаты подтверждают независимость сходимости от природы пространства исходных объектов и согласуются с теоремой 3. 134

- 2.20 Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})|$ от размера выборки k для сверточной нейронной сети при изменении количества сверточных слоев L при фиксированных размере ядра $k = 3$ и количестве каналов $C = 6$. Графики демонстрируют немонотонный характер зависимости разности потерь от количества слоев. 135
- 2.21 Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})|$ от размера выборки k для сверточной нейронной сети при изменении размера ядра свертки k при фиксированных количестве слоев L и количестве каналов $C = 6$. Графики демонстрируют немонотонный характер зависимости разности потерь от размера ядра. 135
- 2.22 Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})|$ от размера выборки k для сверточной нейронной сети при изменении количества каналов C при фиксированных количестве слоев L и размере ядра $k = 3$. Графики демонстрируют монотонный характер зависимости: увеличение числа каналов приводит к увеличению разности потерь, что согласуется с теоретическими оценками. 136
- 2.23 Зависимость абсолютного значения разности функций потерь $|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})|$ от размера выборки k для сверточной нейронной сети при изменении позиции операции пулинга на наборе данных CIFAR10 при фиксированных количестве слоев L , размере ядра $k = 3$ и количестве каналов C . Графики демонстрируют монотонную зависимость: более раннее применение пулинга приводит к меньшей разности потерь. 136

2.24	Зависимость абсолютного значения разности функций потерь $ \mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) $ от количества обучающих примеров k для трансформерной модели на наборе данных CIFAR-100, отображенная в двойном логарифмическом масштабе. Результаты подтверждают теорему 6 и демонстрируют стабилизацию ландшафта функции потерь с ростом объема данных.	137
3.1	Визуализация элементов матрицы Гессе для инициализированной модели трансформера (один блок, набор данных MNIST, батч из 128 примеров) в логарифмическом масштабе. Наблюдается неоднородность величин элементов, при этом блоки, соответствующие параметрам Values, демонстрируют наибольшие значения.	178
3.2	Визуализация элементов матрицы Гессе для обученной модели трансформера (один блок, набор данных MNIST, точность на валидации $>50\%$) в логарифмическом масштабе. После обучения все блоки гессиана приобретают большие значения, при этом блок Values-Values демонстрирует максимальные величины, что подтверждает гетерогенность вклада различных параметров в кривизну функции потерь.	178
3.3	Спектральные нормы блоков параметров трансформера (слева) и спектральные нормы соответствующих блоков матрицы Гессе (справа), вычисленные на одном батче из 128 примеров набора данных MNIST. Наибольшие значения норм соответствуют блокам Keys и Values, что согласуется с теоретическими оценками теоремы 27.	179

3.4	Визуализация элементов блока матрицы Гессе, соответствующего параметрам Queries трансформера (один блок, набор данных MNIST). Блок демонстрирует структурированное распределение элементов, отражающее взаимосвязи между параметрами механизма самовнимания.	179
3.5	Визуализация элементов блока матрицы Гессе, соответствующего параметрам Keys трансформера (один блок, набор данных MNIST). Блок демонстрирует значительные значения элементов, что подтверждает важную роль параметров Keys в формировании кривизны функции потерь.	180
3.6	Визуализация элементов блока матрицы Гессе, соответствующего параметрам Values трансформера (один блок, набор данных MNIST). Блок демонстрирует наибольшие значения элементов среди всех блоков гессиана, что согласуется с теоретическими оценками и подтверждает доминирующий вклад параметров Values в общую кривизну функции потерь.	180
3.7	Визуализация элементов блока матрицы Гессе, соответствующего параметрам LayerNorm трансформера (один блок, набор данных MNIST). Блок демонстрирует структурированное распределение элементов, отражающее влияние нормализации слоев на локальную геометрию функции потерь.	180
3.8	Визуализация элементов блока матрицы Гессе, соответствующего параметрам блока FFN (Feed-Forward Network) трансформера (один блок, набор данных MNIST). Блок демонстрирует умеренные значения элементов по сравнению с блоками Keys и Values, что отражает специфику вклада полносвязных слоев в кривизну функции потерь.	181

4.1	Визуализация сдвига апостериорных распределений параметров модели при последовательном добавлении объектов в выборку. Иллюстрация демонстрирует концепцию близости распределений, используемую в методах KL- и S-достаточности для определения достаточного размера выборки.	201
4.2	Зависимость статистических значений различных методов определения достаточного размера выборки от размера подвыборки для наборов данных Boston Housing, Diabetes, Forest Fires, Servo и NBA. Все представленные функции монотонны и асимптотически стремятся к константе, что согласуется с ожидаемой монотонной стабилизацией критериев.	213
4.3	Зависимость оцененного достаточного размера выборки m^* от доступного размера выборки m для различных методов на наборе данных Boston Housing. Результаты демонстрируют сходимость методов и низкую дисперсию оценок, что указывает на вычислительную устойчивость рассмотренных подходов.	214
4.4	Сходимость функций $D(k)$ и $M(k)$ для синтетического набора данных регрессии. Обе функции стремятся к нулю с увеличением размера выборки, что подтверждает теорему 28.	215
4.5	Сходимость функций $D(k)$ и $M(k)$ для синтетического набора данных классификации. Обе функции демонстрируют монотонное убывание к нулю с увеличением размера выборки, подтверждая применимость методов D- и M-достаточности для задач классификации.	215
4.6	Сходимость функций $D(k)$ и $M(k)$ для набора данных Liver Disorders (345 объектов, 5 признаков, $B = 1000$ бутстрэп-подвыборок). Обе функции демонстрируют сходимость к нулю, что подтверждает теоретические результаты и демонстрирует применимость методов на реальных данных.	216

4.7	Зависимость достаточного размера выборки m^* от порогового параметра ε для методов D- и M-достаточности на трех наборах данных. С увеличением значения порога ε достаточный размер выборки монотонно уменьшается, что позволяет выбирать меньше объектов для достижения заданного уровня стабильности функций $D(k)$ и $M(k)$	216
4.8	Зависимость минимального собственного значения $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)$ от размера выборки k для синтетических данных регрессии (500 объектов, 10 признаков) и набора данных Liver Disorders (345 объектов, 5 признаков). Асимптотическое поведение соответствует условию теоремы 31: $\lambda_{\min} = \omega(\sqrt{k})$ при $k \rightarrow \infty$	218
4.9	Сходимость функций $KL(k)$ и $S(k)$ для синтетического набора данных регрессии. Функция $KL(k)$ стремится к нулю, а $S(k)$ стремится к единице, что подтверждает теоремы 29 и 30.	219
4.10	Сходимость функций $KL(k)$ и $S(k)$ для набора данных Liver Disorders (345 объектов, 5 признаков, нормальное априорное распределение, $B = 100$ повторений). Результаты демонстрируют сходимость $KL(k)$ к нулю и $S(k)$ к единице, подтверждая теоретические предсказания и применимость методов KL- и S-достаточности на реальных данных.	219
4.11	Зависимость достаточного размера выборки m^* от порогового параметра ε для методов KL- и S-достаточности на синтетических данных регрессии и наборе данных Liver Disorders. Метод S-достаточности требует более низких значений порога для достижения заданного уровня близости распределений, что указывает на его более строгие требования к качеству оценки.	220

4.12	Зависимость оцененного достаточного размера выборки m^* от доступного размера выборки m для классических методов и предложенных методов KL- и S-достаточности на наборе данных Boston Housing. Критерий KL-достаточности является наиболее консервативным и требует почти полной выборки, в то время как S-достаточность указывает на минимальные размеры, что связано с высокой чувствительностью расхождения Кульбака-Лейблера к изменениям распределений.	222
5.1	Иллюстрация метода Белсли для анализа мультиколлинеарности параметров на синтетических данных. Слева показана матрица ковариации параметров, справа — дисперсионные доли, демонстрирующие вклад каждого признака в дисперсию параметров модели.	231
5.2	Схема базовой дистилляции моделей глубокого обучения, где модель учителя обучается на большом наборе данных из генеральной совокупности A , а затем ее выходы используются для обучения модели ученика на меньшем наборе данных из того же домена.	237
5.3	Схема дистилляции моделей глубокого обучения с доменной адаптацией, где модель учителя обучается на данных из домена A , а модель ученика — на данных из домена B , связанных инъективным отображением φ	237
5.4	Зависимость точности классификации R_{cl} от процента удаленных параметров для различных методов прореживания на выборке Wine. Метод оптимального прореживания, вариационный метод и метод Белсли позволяют удалить $\approx 80\%$ параметров без существенной потери качества.	245

5.5	Поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для различных методов прореживания на выборке Wine. Метод Белсли демонстрирует наименьший уровень шума, что видно по более низкому положению соответствующей поверхности.	246
5.6	Зависимость среднеквадратического отклонения прогноза R_{rg} от процента удаленных параметров для различных методов прореживания на выборке Boston Housing. В этой постановке метод Белсли допускает удаление большей доли параметров при сопоставимом качестве.	247
5.7	Поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для различных методов прореживания на выборке Boston Housing. Все методы демонстрируют одинаковый уровень шума, так как соответствующие поверхности находятся на одном уровне.	248
5.8	Зависимость среднеквадратического отклонения прогноза от процента удаленных параметров для различных методов прореживания на синтетической выборке с мультиколлинеарными параметрами. Метод Белсли здесь даёт уменьшение ошибки при удалении шумовых параметров.	249
5.9	Поверхности изменения уровня шума ответов нейросети при изменении процента удаленных параметров и уровня шума входных данных для различных методов прореживания на синтетической выборке. Метод Белсли демонстрирует наименьший уровень шума, что видно по более низкому положению соответствующей поверхности.	250

5.10	Пример применения инъективного отображения φ для доменной адаптации между ImageNet-Small и ImageNet-Big. Демонстрирует визуальное преобразование объекта из исходного домена в целевой домен для использования в многодоменной дистилляции. . . .	253
5.11	Зависимость точности аппроксимации от числа эпох обучения на тестовой выборке ImageNet для различных методов дистилляции. Результаты усреднены по 5 запускам; выше показатели у вариантов с учителем и доменной адаптацией.	255
5.12	Зависимость ошибки перекрестной энтропии между истинными и предсказанными метками от числа эпох обучения на тестовой выборке ImageNet для различных методов дистилляции. Результаты усреднены по 5 запускам и показывают снижение ошибки при использовании методов дистилляции.	255
5.13	Зависимость ошибки перекрестной энтропии от числа эпох обучения на тестовом наборе данных OPUS-100 для задачи машинного перевода. Результаты усреднены по 3 запускам; ниже ошибка у моделей с учителем.	257
5.14	Сравнение валидационной точности для различных методов инициализации параметров модели на наборе данных Fashion-MNIST. Модели с антидистилляцией имеют меньшую дисперсию и более высокую точность, чем сравниваемые инициализации. . .	260
5.15	Зависимость валидационной точности от уровня адверсарного шума в данных для различных методов инициализации на наборе данных Fashion-MNIST. Антидистилляция сохраняет более высокую точность при высоких уровнях шума, чем сравниваемые методы.	260

5.16	Зависимость валидационной точности от параметра интенсивности нормального шума ε в параметрах модели для различных методов инициализации на наборе данных Fashion-MNIST. Вариант без регуляризации гессiana ($\lambda_4 = 0$) сохраняет более высокую точность при максимальном уровне шума.	261
6.1	Схема метода декодирования фМРТ-изображений из видеопоследовательностей. Метод использует архитектуру ResNet152 для векторизации видеок кадров и линейную регрессию с L_2 -регуляризацией для предсказания разностей между последовательными фМРТ-снимками с учетом временной задержки Δt . . .	278
6.2	Зависимость метрики F_1 от ранга r адаптеров LoRA для модели DeBERTa-v3-base на задаче детекции машинно-генерированного текста. В данном эксперименте наибольшие значения F_1 наблюдаются при $r = 8$; дальнейший рост ранга не улучшает метрику. .	284
6.3	Динамика потерь при обучении модели DeBERTa-v3-base с адаптерами LoRA различных рангов ($r \in \{8, 16, 32\}$) на задаче детекции машинно-генерированного текста. Анализ показывает, что более высокие ранги обеспечивают более быструю сходимость и более низкие финальные потери, но $r = 8$ даёт более высокие метрики обобщения в данном эксперименте.	292
6.4	Динамика нормы градиента и потерь при обучении моделей DeBERTa-v3-base с полной тонкой настройкой и адаптацией LoRA ($r = 8$) в течение 5 эпох на задаче детекции машинно-генерированного текста. LoRA демонстрирует более гладкие траектории нормы градиента и потерь, что указывает на более стабильную сходимость в данном эксперименте.	293

6.5	Зависимость метрики MSE от параметра регуляризации α для метода декодирования фМРТ-изображений на тестовой выборке при различных коэффициентах сжатия (1, 2, 4, 8). Оптимальное значение коэффициента $\alpha \approx 1000$ сохраняется независимо от коэффициента сжатия, что подтверждает стабильность метода при снижении размерности данных.	296
6.6	Распределения размерности персистентной гомологии (PHD) для человеческих и машинно-сгенерированных текстов в различных наборах данных детекции. Качественные наборы данных (SemEval, PAN24, MGT-1) демонстрируют схожие распределения PHD для обоих типов текстов, что указывает на высокое качество сгенерированных данных и их близость к человеческим текстам по топологическим характеристикам.	300
6.7	Топологические временные ряды (TTS) для четырех наборов данных с высокими значениями метрики KL_{TTS} : GhostBuster, PAN24, MGTBench и DAGPap22. Высокие значения KL_{TTS} для GhostBuster и PAN24 обусловлены расхождением в текстах с более высокими размерностями, тогда как для MGTBench и DAGPap22 — разницей в самих распределениях PHD, что указывает на различные типы различий между человеческими и машинно-сгенерированными текстами.	301

Список таблиц

2.1	Теоретические верхние порядки μ_f и эмпирической радемахеровской сложности для линейной модели и двухслойной FC ReLU-сети при квадратичной функции потерь. Для двухслойной μ_f спектральная оценка худшего случая сопоставляется с оценкой из теоремы 8, учитывающей малость остатков в окрестности θ^*	102
2.2	Множество архитектур модели GPT-2 для экспериментального сравнения динамики ландшафтной меры	112
2.3	Численные параметры эксперимента	113
2.4	Устойчивость оценки μ	118
2.5	Линейные спецификации для μ	118
2.6	Доверительные интервалы коэффициентов	118
2.7	Описание наборов данных для классификации изображений, использованных в экспериментах по валидации теоретических оценок сходимости ландшафта функции потерь. Все наборы данных из библиотеки <code>torchvision</code> с нормализацией значений пикселей к диапазону $[-1, 1]$	123
3.1	Гиперпараметры архитектур Vision Transformer (ViT) для экспериментов по анализу матриц Гессе. Параметры включают размер патча, скрытую размерность, размер блока FFN и количество трансформерных блоков для наборов данных MNIST и CIFAR-100.	177
4.1	Характеристики выборок, используемых для анализа качества методов определения достаточного размера выборки. Таблица содержит информацию о типе задачи, количестве признаков и общем размере выборки для каждого набора данных.	210

4.2	Сравнение оценок достаточного размера выборки, полученных различными статистическими и байесовскими методами для пяти наборов данных. Результаты демонстрируют значительный разброс оценок между методами, что указывает на различную консервативность подходов.	211
4.3	Гиперпараметры методов оценки достаточного размера выборки, заранее заданные для экспериментов. Параметры включают уровни значимости α , вероятности ошибки второго рода β , пороговые значения ε и l , а также параметры обобщенных линейных моделей.	212
4.4	Сравнение оценок достаточного размера выборки методами D- и M-достаточности для 13 наборов данных с задачей регрессии. Методы демонстрируют сопоставимые результаты для большинства наборов данных, при этом M-достаточность иногда требует большего размера выборки.	217
4.5	Характеристики выборок, используемых для сравнения методов определения достаточного размера выборки на основе близости апостериорных распределений. Все наборы данных соответствуют задаче регрессии и используются для оценки методов KL- и S-достаточности.	220
4.6	Сравнение оценок достаточного размера выборки, полученных классическими методами и предложенными методами KL- и S-достаточности для четырех наборов данных регрессии. Метод KL-достаточности дает более консервативные оценки, требующие почти полной выборки, в то время как S-достаточность указывает на минимальные размеры выборки.	221

5.1	Индексы обусловленности η и дисперсионные доли q_j для синтетических данных, демонстрирующие работу метода Белсли. Максимальный индекс обусловленности $\eta_6 = 1.2 \cdot 10^{16}$ соответствует максимальным дисперсионным долям признаков с индексами 1 и 4, которые являются линейно зависимыми.	230
5.2	Сравнение моделей ученика с априорным распределением, заданным на основе апостериорного распределения параметров учителя	236
5.3	Характеристики выборок, использованных для анализа метода задания порядка параметров методом Белсли. Включает реальные данные (Wine для классификации, Boston Housing для регрессии) и синтетические данные с мультиколлинеарными параметрами.	244
5.4	Архитектура модели учителя для эксперимента по многодоменной дистилляции в задаче компьютерного зрения. Модель представляет собой сверточную нейронную сеть с пятью сверточными слоями и четырьмя полносвязными слоями, общее число параметров составляет 4 455 984.	251
5.5	Архитектура модели ученика для эксперимента по многодоменной дистилляции в задаче компьютерного зрения. Модель имеет упрощенную структуру по сравнению с моделью учителя, с двумя сверточными слоями и тремя полносвязными слоями, общее число параметров составляет 12 755 640.	252
5.6	Характеристики подмножеств набора данных ImageNet, использованных в эксперименте по многодоменной дистилляции. ImageNet-Big содержит 1 281 167 изображений для обучения и 50 000 для валидации, ImageNet-Small — 64 058 и 2 500 соответственно, оба набора содержат 200 классов.	252

5.7	Характеристики подмножеств набора данных OPUS-100, использованных в эксперименте по многодоменной дистилляции для задачи машинного перевода. Показаны размеры обучающих и валидационных выборок для языковых пар fr-en и de-en.	254
5.8	Сравнение качества моделей для задачи компьютерного зрения на наборе данных ImageNet. Показаны валидационная точность, потери и интегральный критерий для различных комбинаций учителя и ученика с использованием доменной адаптации и без нее, результаты усреднены по нескольким запускам.	256
5.9	Сравнение качества моделей для задачи машинного перевода на наборе данных OPUS-100. Показаны потери перекрестной энтропии и метрика BLEU для модели ученика, обученной с использованием учителя и доменной адаптации (NLLB) и без них.	257
5.10	Сравнение точности на валидационном наборе Fashion-MNIST для различных методов инициализации параметров модели. Показаны базовая точность, точность при адверсарной атаке FGSM и точность при нормальном шуме в параметрах, результаты усреднены по нескольким запускам.	262
6.1	Сравнение формул обновления параметров для полной тонкой настройки и метода LoRA. В полной тонкой настройке обновление ΔW оценивается напрямую, тогда как в LoRA обновление параметризуется в виде низкоранговой факторизации AB , где $r \ll \min(d, k)$, что значительно сокращает количество обучаемых параметров.	266

- 6.2 Сравнение метрик модели DeBERTa-v3-base при полной тонкой настройке и адаптации с LoRA на задаче детекции машинно-генерированного текста. LoRA даёт небольшое снижение метрик точности (1.4–3.2%), меньшие потери на валидации (36.3%) и ускорение обучения (12.6%), что согласуется с сохранением формы выходного слоя при низкоранговых обновлениях. 287
- 6.3 Сравнение производительности и эмпирической сложности Радемахера (ERC) модели DeBERTa-v3-base в условиях однозадачного (STL) и многозадачного (MTL) обучения на задаче бинарной классификации GenAI Detection. MTL демонстрирует улучшение метрик качества (F1: 0.781→0.826, ROC-AUC: 0.788→0.834) и более низкий ERC (0.0159 ± 0.0009 против 0.0111 ± 0.0010), что качественно согласуется с тем, что многозадачная постановка может уменьшать измеряемую сложность целевой задачи; прямого вывода $\text{ERC}_{\text{MTL}} \leq \text{ERC}_{\text{STL}}/\sqrt{T}$ из теоремы 36 на уровне точных значений не делается. 288
- 6.4 Сравнение моделей DeBERTa-v3-base при полной тонкой настройке и адаптации с LoRA ($r = 8$) после 5 эпох обучения. LoRA обеспечивает более низкие потери (0.2972 vs 0.3058), более гладкие нормы градиентов (17.41 vs 24.65) и требует только 0.16% параметров от полной модели (296,450 vs 184M), демонстрируя эффективность низкоранговой адаптации. 289
- 6.5 Сравнение конфигураций LoRA с различными рангами $r \in \{8, 16, 32\}$ для модели DeBERTa-v3-base. Анализ показывает, что более высокие ранги ($r = 32$) обеспечивают более низкие потери при обучении, но $r = 8$ обеспечивает лучшее обобщение в данной задаче. 290

6.6	Характеристики выборки для эксперимента по декодированию фМРТ-изображений из видеопоследовательностей. Выборка содержит данные 30 испытуемых с продолжительностью обследования 390 с, частотой кадров видео 25 Гц и частотой фМРТ-изображений 1.64 Гц, что обеспечивает временное соответствие между видеокадрами и томографическими данными.	295
6.7	Зависимость среднего времени обучения модели декодирования фМРТ-изображений от коэффициента сжатия данных. Использование предварительного сжатия фМРТ-изображений с коэффициентами 2, 4 и 8 обеспечивает существенное сокращение времени обучения (с 36.3 с до 6.7 с, 1.6 с и 1.4 с соответственно), что показывает сокращение времени обучения при сохранении качества реконструкции в данной постановке.	297
6.8	Результаты классификации различных детекторов машинно-генерированного текста (DeBERTa, Binoculars, DetectGPT) на множественных наборах данных, оцененные с помощью метрики F_1 -score. Детектор на основе DeBERTa демонстрирует наиболее стабильную производительность на различных наборах данных, тогда как Binoculars и DetectGPT показывают значительные вариации, что указывает на проблемы с устойчивостью этих методов к различным доменам.	298
6.9	Статистика качества данных для выбранных наборов данных детекции машинно-генерированного текста, включающая метрики KL_{TTS} , PHD, Δ_{shift} и $KL_{shuffle}$. Высокие значения метрик указывают на различимость текстов разного происхождения, тогда как низкие значения отражают схожую устойчивость к модификациям, что является признаком качественных данных.	299

Список литературы

1. *Стрижов Вадим Викторович*. Порождение и выбор моделей в задачах прогнозирования. — ВЦ РАН, Москва, Россия: Рукопись, 2014.
2. *Ванник В.Н., Червоненкис А.Я.* Теория распознавания образов: статистические проблемы обучения. — Наука, 1974.
3. *Valiant L. G.* A theory of the learnable // *Commun. ACM*. — 1984. — nov. — Vol. 27, no. 11. — P. 1134–1142.
4. *Koltchinskii Vladimir, Panchenko Dmitriy.* Rademacher Processes and Bounding the Risk of Function Learning // *High Dimensional Probability II* / Ed. by Evarist Giné, David M. Mason, Jon A. Wellner. — Boston, MA: Birkhäuser Boston, 2000. — Pp. 443–457.
5. *Vorontsov K. V.* Combinatorial Bounds for Learning Performance // *Doklady Mathematics*. — 2004. — Vol. 69, no. 1. — Pp. 145—148.
6. *Cybenko George V.* Approximation by superpositions of a sigmoidal function // *Mathematics of Control, Signals and Systems*. — 1989. — Vol. 2. — Pp. 303–314. <https://api.semanticscholar.org/CorpusID:3958369>.
7. *Håstad Johan.* Computational limitations of small-depth circuits. — Cambridge, MA, USA: MIT Press, 1987.
8. *Bengio Yoshua, Lecun Yann.* Scaling Learning Algorithms towards AI // *Large-Scale Kernel Machines* / Ed. by L. Bottou, O. Chapelle, D. Decoste, J. Weston. — MIT Press, 2007.
9. *Delalleau Olivier, Bengio Yoshua.* Shallow vs. Deep Sum-Product Networks // *Advances in Neural Information Processing Systems* / Ed. by J. Shawe-Taylor, R. Zemel, P. Bartlett et al. — Vol. 24. — Curran Associates, Inc., 2011.
10. *Cohen Nadav, Sharir Or, Shashua Amnon.* On the Expressive Power of Deep Learning: A Tensor Analysis // *Annual Conference Computational Learning Theory*. — 2015. <https://api.semanticscholar.org/CorpusID:215826733>.

11. Eldan Ronen, Shamir Ohad. The Power of Depth for Feedforward Neural Networks // *Conference on Learning Theory*. — 2015. — 12.
12. Грабовой А. В., Бахтеев О. Ю., Стрижов В. В. Ordering the set of neural network parameters // *Информатика и ее применения*. — 2020. — Vol. 14, no. 2.
13. Грабовой А. В., Бахтеев О. Ю., Стрижов В. В. Estimation of the relevance of the neural network parameters // *Информатика и ее применения*. — 2019.
14. MacKay David J. C. Information Theory, Inference, and Learning Algorithms. — Copyright Cambridge University Press, 2003.
15. Numerical Methods of Sufficient Sample Size Estimation for Generalised Linear Models / A. V. Grabovoy, T. T. Gadaev, A. P. Motrenko, V. V. Strijov // *Lobachevskii Journal of Mathematics*. — 2022. — Vol. 43, no. 9. — Pp. 2453–2462.
16. Demidenko E. Sample size determination for logistic regression revisited // *Statistics in medicine*. — 2006. — Vol. 26. — Pp. 3385–97.
17. Joseph L., Berger R., Bélisle P. Bayesian and mixed Bayesian/likelihood criteria for sample size determination // *Statistician*. — 1997. — Vol. 16, no. 7. — Pp. 769–781.
18. Lawrence J., Wolfson D., Berger R. Sample Size Calculations for Binomial Proportions Via Highest Posterior Density Intervals // *Statistician*. — 1995. — Vol. 44. — Pp. 143–154.
19. Klock T. Note on a large-sample result in specification analysis // *Econometrica*. — 1975. — Vol. 43. — Pp. 933–936.
20. Lindley D. The choice of sample size // *Statistician*. — 1997. — Vol. 46. — Pp. 129–138.
21. Motrenko A., Strijov V., Weber G. Sample Size Determination for Logistic Regression // *J. Comput. Appl. Math.* — 2014. — Vol. 255, no. C. — Pp. 743–752.

22. *Qumsiyeh M.* Using the bootstrap for estimation the sample size in statistical experiments // *Journal of modern applied statistical methods*. — 2013. — Vol. 8. — Pp. 305–321.
23. *Rubin D., Stern H.* Sample size determination using posterior predictive distributions // *Sankhya: The Indian Journal of Statistics Special Issue on Bayesian Analysis*. — 1998. — Vol. 60. — Pp. 161–175.
24. *Self S., Mauritsen R.* Power sample size calculations for generalized linear models // *Biometrics*. — 1988. — Vol. 44. — Pp. 79–86.
25. *Self S., Mauritsen R., Ohara J.* Power calculations for likelihood ratio tests in generalized linear models // *Biometrics*. — 1992. — Vol. 48. — Pp. 31–39.
26. *Shieh G.* On power and sample size calculations for likelihood ratio tests in generalized linear models // *Biometrics*. — 2000. — Vol. 56. — Pp. 1192–1196.
27. *Shieh G.* On power and sample size calculations for Wald tests in generalized linear models // *Journal of Statistical Planning and Inference*. — 2005. — Vol. 128. — Pp. 43–59.
28. *Wang F., Gelfand A.* A Simulation-based Approach to Bayesian Sample Size Determination for Performance under a Given Model and for Separating Models // *Statistical Science*. — 2002. — Vol. 17. — Pp. 193–208.
29. Training compute-optimal large language models / Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch et al. // Proceedings of the 36th International Conference on Neural Information Processing Systems. — NIPS '22. — Red Hook, NY, USA: Curran Associates Inc., 2022. — 15 pp.
30. Scaling Laws for Neural Language Models / Jared Kaplan, Sam McCandlish, Tom Henighan et al. // *CoRR*. — 2020. — Vol. abs/2001.08361. <https://arxiv.org/abs/2001.08361>.
31. Scaling Language Models: Methods, Analysis & Insights from Training Gopher. — 2022. <https://arxiv.org/abs/2112.11446>.

32. *Hinton G., Vinyals O., Dean J.* Distilling the Knowledge in a Neural Network // NIPS Deep Learning and Representation Learning Workshop. — 2015.
33. Unifying distillation and privileged information / D. Lopez-Paz, L. Bottou, B. Schölkopf, V. Vapnik // ICLR. — 2016.
34. *Grabovoy A. V., Strijov V. V.* Bayesian Distillation of Deep Learning Models // *Automation and Remote Control*. — 2021. — Vol. 82, no. 11. — Pp. 1846–1856.
35. *Воронцов Константин Вячеславович.* Комбинаторная теория надежности обучения по прецедентам: Ph.D. thesis / МГУ. — 2010. <http://www.machinelearning.ru/wiki/images/b/b6/Voron10doct.pdf>.
36. *Bartlett Peter L., Mendelson Shahar.* Rademacher and Gaussian Complexities: Risk Bounds and Structural Results // *Journal of Machine Learning Research*. — 2002. — Vol. 3. — Pp. 463–482.
37. *Truong Lan V.* On Rademacher Complexity-Based Generalization Bounds for Deep Learning. — 2022.
38. *Sachs Sarah, van Erven Tim, Hodgkinson Liam et al.* Generalization Guarantees via Algorithm-Dependent Rademacher Complexity. — 2023.
39. *Hole Arne.* Vapnik–Chervonenkis generalization bounds for real valued neural networks // *Neural Computation*. — 1996.
40. Model complexity control for regression using VC generalization bounds / Vladimir Cherkassky, Xuhui Shao, Filip Mulier, Vladimir Vapnik // *IEEE Transactions on Neural Networks*. — 1999.
41. *Golowich Noah, Rakhlin Alexander, Shamir Ohad.* Size-Independent Sample Complexity of Neural Networks // *Journal of Machine Learning Research*. — 2018. — Vol. 19, no. 1. — Pp. 2978–3019.
42. *Valle-Perez Guillermo, Louis Ard A.* Generalization Bounds for Deep Learning. — 2020.

43. *McAllester David A.* Some PAC-Bayesian Theorems // *Machine Learning*. — 1999. — Vol. 37, no. 3. — Pp. 355–363.
44. *Dziugaite Gintare Karolina, Roy Daniel M.* Computing Nonvacuous Generalization Bounds for Deep (Stochastic) Neural Networks with Many More Parameters than Training Data // *Proceedings of the Conference on Uncertainty in Artificial Intelligence*. — 2017.
45. *Zhou Wenda, Veitch Victor, Austern Morgane et al.* Non-Vacuous Generalization Bounds at the ImageNet Scale: A PAC-Bayesian Compression Approach. — 2018.
46. *Hodgkinson Liam, van der Heide Chris, Salomone Robert et al.* A PAC-Bayesian Perspective on the Interpolating Information Criterion. — 2023.
47. *Ghojogh Benjamin, Ghodsi Ali.* PAC Learnability and Information Bottleneck in Deep Learning: Tutorial and Survey. — 2024.
48. Generalization Bounds: Perspectives from Information Theory and PAC-Bayes / *Fredrik Hellstrom, Giuseppe Durisi, Benjamin Guedj, Maxim Raginsky* // *Foundations and Trends in Machine Learning*. — 2025. — Vol. 18, no. 4. — Pp. 433–785.
49. *London Ben.* A PAC-Bayesian Analysis of Randomized Learning with Application to Stochastic Gradient Descent // *Advances in Neural Information Processing Systems*. — 2017.
50. *Sakamoto Keitaro, Sato Issei.* Analyzing Lottery Ticket Hypothesis from PAC-Bayesian Theory Perspective. — 2022.
51. *Xu Aolin, Raginsky Maxim.* Information-Theoretic Analysis of Generalization Capability of Learning Algorithms // *Advances in Neural Information Processing Systems*. — Vol. 30. — 2017.
52. *Hu Xia, Chu Lingyang, Pei Jian et al.* Model Complexity of Deep Learning: A Survey. — 2021.

53. *He Fengxiang, Tao Dacheng*. Recent Advances in Deep Learning Theory. — 2020.
54. *Dar Yehuda, Muthukumar Vidya, Baraniuk Richard G.* A Farewell to the Bias-Variance Tradeoff? An Overview of the Theory of Overparameterized Machine Learning. — 2021.
55. *Nagarajan Vaishnavh*. Explaining Generalization in Deep Learning: Progress and Fundamental Limits: Ph.D. thesis / Carnegie Mellon University. — 2021.
56. *Kawaguchi Kenji, Kaelbling Leslie Pack, Bengio Yoshua*. Generalization in Deep Learning. — 2017.
57. *Poggio Tomaso, Banburski Andrzej, Liao Qianli*. Theoretical Issues in Deep Networks: Approximation, Optimization and Generalization. — 2019.
58. *Poggio Tomaso, Kawaguchi Kenji, Liao Qianli et al.* Theory of Deep Learning III: Explaining the Non-Overfitting Puzzle. — 2017.
59. *Bousquet Olivier, Elisseeff Andre*. Stability and Generalization // *Journal of Machine Learning Research*. — 2002. — Vol. 2. — Pp. 499–526.
60. *Hardt Moritz, Recht Benjamin, Singer Yoram*. Train Faster, Generalize Better: Stability of Stochastic Gradient Descent // Proceedings of the 33rd International Conference on Machine Learning. — 2016. — Pp. 1225–1234.
61. Understanding Deep Learning (Still) Requires Rethinking Generalization / Chiyuan Zhang, Samy Bengio, Moritz Hardt et al. // *Communications of the ACM*. — 2021. — Vol. 64, no. 3. — Pp. 107–115.
62. Visualizing the Loss Landscape of Neural Nets / Hao Li, Zheng Xu, Gavin Taylor et al. // Advances in Neural Information Processing Systems / Ed. by S. Bengio, H. Wallach, H. Larochelle et al. — Vol. 31. — Curran Associates, Inc., 2018. https://proceedings.neurips.cc/paper_files/paper/2018/file/a41b3bb3e6b050b6c9067c67f663b915-Paper.pdf.
63. *Wu Lei, Zhu Zhanxing, Weinan E.* Towards Understanding Generalization of Deep Learning: Perspective of Loss Landscapes. — 2017.

64. *Zhou Pan, Feng Jiashi*. The Landscape of Deep Learning Algorithms. — 2017.
65. *Hochreiter Sepp, Schmidhuber Jurgen*. Flat Minima // *Neural Computation*. — 1997. — Vol. 9, no. 1. — Pp. 1–42.
66. *Tsuzuku Yusuke, Sato Issei, Sugiyama Masashi*. Normalized Flat Minima: Exploring Scale Invariant Definition of Flat Minima for Neural Networks using PAC-Bayesian Analysis. — 2019.
67. *Sagun Levent, Bottou Leon, LeCun Yann*. Eigenvalues of the Hessian in Deep Learning: Singularity and Beyond. — 2017.
68. *Wei Mingwei, Schwab David J.* How Noise Affects the Hessian Spectrum in Overparameterized Neural Networks. — 2019.
69. *Xie Zeke, Tang Qian-Yuan, Cai Yunfeng et al.* On the Power-Law Hessian Spectrums in Deep Learning. — 2022.
70. *Kiselev N. S., Grabovoy A. V.* Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*. — 2024. — Vol. 110, no. S1. — Pp. S49–S61.
71. *Natekar Parth, Sharma Manik*. Representation Based Complexity Measures for Predicting Generalization in Deep Learning. — 2020.
72. *Valle-Perez Guillermo, Camargo Chico Q., Louis Ard A.* Deep Learning Generalizes Because the Parameter-Function Map is Biased Towards Simple Functions. — 2018.
73. *Keskar Nitish Shirish, Mudigere Dheevatsa, Nocedal Jorge et al.* On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima. — 2017.
74. Sharpness-Aware Minimization for Efficiently Improving Generalization / Pierre Foret, Ariel Kleiner, Hossein Mobahi, Behnam Neyshabur // *Proceedings of the International Conference on Machine Learning*. — Vol. 119. — 2020. — Pp. 7295–7305.

75. *Long Philip M., Bartlett Peter L.* Sharpness-Aware Minimization and the Edge of Stability. — 2023.
76. *Bisla Devansh, Wang Jing, Choromanska Anna.* Low-Pass Filtering SGD for Recovering Flat Optima in the Deep Learning Optimization Landscape. — 2022.
77. *Xie Zeke, Sato Issei, Sugiyama Masashi.* A Diffusion Theory for Deep Learning Dynamics: Stochastic Gradient Descent Exponentially Favors Flat Minima. — 2020.
78. *Wu Lei, Su Weijie J.* The Implicit Regularization of Dynamical Stability in Stochastic Gradient Descent. — 2023.
79. *Lei Yunwen, Ying Yiming.* Fine-Grained Analysis of Stability and Generalization for Stochastic Gradient Descent. — 2020.
80. *Arora Sanjeev, Li Zhiyuan, Panigrahi Abhishek.* Understanding Gradient Descent on Edge of Stability in Deep Learning. — 2022.
81. *Camuto Alexander, Deligiannidis George, Erdogdu Murat A. et al.* Fractal Structure and Generalization Properties of Stochastic Optimization Algorithms. — 2021.
82. Reconciling Modern Machine-Learning Practice and the Classical Bias-Variance Trade-Off / Mikhail Belkin, Daniel Hsu, Siyuan Ma, Soumik Mandal // *Proceedings of the National Academy of Sciences*. — 2019. — Vol. 116, no. 32. — Pp. 15849–15854.
83. Deep double descent: Where bigger models and more data hurt / Preetum Nakkiran, Gal Kaplun, Yamini Bansal et al. // *Journal of Statistical Mechanics: Theory and Experiment*. — 2021. — Vol. 2021, no. 12. — P. 124003.
84. *Lee Eng Hock, Cherkassky Vladimir.* Understanding Double Descent Using VC-Theoretical Framework // *IEEE Transactions on Neural Networks and Learning Systems*. — 2024.

85. *Song Mei, Montanari Andrea.* The Generalization Error of Random Features Regression: Precise Asymptotics and Double Descent Curve. — 2019.
86. *Advani Madhu, Saxe Andrew, Sompolinsky Haim.* High-dimensional dynamics of generalization error in neural networks // *Neural Networks*. — 2020.
87. *Jacot Arthur, Gabriel Franck, Hongler Clement.* Neural Tangent Kernel: Convergence and Generalization in Neural Networks // *Advances in Neural Information Processing Systems*. — Vol. 31. — 2018.
88. *Adlam Ben, Pennington Jeffrey.* The Neural Tangent Kernel in High Dimensions: Triple Descent and a Multi-Scale Theory of Generalization. — 2020.
89. *Vakili Sattar, Bromberg Michael, Garcia Jezabel et al.* Uniform Generalization Bounds for Overparameterized Neural Networks. — 2021.
90. Fine-Grained Analysis of Optimization and Generalization for Overparameterized Two-Layer Neural Networks / Sanjeev Arora, Simon Du, Wei Hu et al. // *Proceedings of the International Conference on Machine Learning*. — 2019. — Pp. 322–332.
91. *Suzuki Taiji, Akiyama Shunta.* Benefit of Deep Learning with Non-Convex Noisy Gradient Descent: Provable Excess Risk Bound and Superiority to Kernel Methods. — 2020.
92. *Bachmann Gregor, Hofmann Thomas, Lucchi Aurelien.* Generalization Through the Lens of Leave-One-Out Error. — 2022.
93. *Vyas Nikhil, Bansal Yamini, Nakkiran Preetum.* Limitations of the NTK for Understanding Generalization in Deep Learning. — 2022.
94. *Wang Jing, Choromanska Anna.* A Survey of Optimization Methods for Training DL Models: Theoretical Perspective on Convergence and Generalization. — 2025.
95. Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws. — 2023.

96. Attention Is All You Need / Ashish Vaswani, Noam Shazeer, Niki Parmar et al. // Advances in Neural Information Processing Systems. — Vol. 30. — 2017.
97. *Ho Jonathan, Jain Ajay, Abbeel Pieter*. Denoising Diffusion Probabilistic Models // Advances in Neural Information Processing Systems. — Vol. 33. — 2020. — Pp. 6840–6851.
98. *Petrov Egor, Kiselev Nikita, Meshkov Vladislav, Grabovoy Andrey*. Closing the Curvature Gap: Full Transformer Hessians and Their Implications for Scaling Laws. — 2025.
99. Understanding Scaling Laws with Statistical and Approximation Theory for Transformer Neural Networks on Intrinsically Low-Dimensional Data. — 2024.
100. Scaling Laws for Transformers on Low-Dimensional Data: A Statistical and Approximation Theory Perspective. — 2022.
101. Generalization and Scaling Laws for Mixture-of-Experts Transformers. — 2026.
102. Understanding Scaling Laws in Deep Neural Networks via Feature Learning Dynamics. — 2025.
103. Scaling Laws for Diffusion Transformers. — 2024.
104. *Johannsen Zeran*. Implicit Regularization and Generalization in Overparameterized Neural Networks. — 2026.
105. *Fort Stanislav, Jastrzebski Stanislaw*. Large Scale Structure of Neural Network Loss Landscapes // Advances in Neural Information Processing Systems / Ed. by H. Wallach, H. Larochelle, A. Beygelzimer et al. — Vol. 32. — Curran Associates, Inc., 2019. https://proceedings.neurips.cc/paper_files/paper/2019/file/48042b1dae4950fef2bd2aafa0b971a1-Paper.pdf.
106. *Fort S., Ganguli S*. Emergent Properties of the Local Geometry of Neural Loss Landscapes. — 2019.

107. *Ghorbani Behrooz, Krishnan Shankar, Xiao Ying.* An Investigation into Neural Net Optimization via Hessian Eigenvalue Density // Proceedings of the 36th International Conference on Machine Learning / Ed. by Kamalika Chaudhuri, Ruslan Salakhutdinov. — Vol. 97 of *Proceedings of Machine Learning Research*. — PMLR, 2019. — 09–15 Jun. — Pp. 2232–2241. <https://proceedings.mlr.press/v97/ghorbani19b.html>.
108. *Sagun Levent, Evci Utku, Guney V. Ugur et al.* Empirical Analysis of the Hessian of Over-Parametrized Neural Networks. — 2018. <https://arxiv.org/abs/1706.04454>.
109. *Vapnik V. N.* Statistical Learning Theory. — New York: Wiley, 1998. — P. 736.
110. *Papayan Vardan.* The Full Spectrum of Deepnet Hessians at Scale: Dynamics with SGD Training and Sample Size. — 2019. <https://arxiv.org/abs/1811.07062>.
111. *Wu Yikai, Zhu Xingyu, Wu Chenwei et al.* Dissecting Hessian: Understanding Common Structure of Hessian in Neural Networks. — 2022.
112. *Pennington Jeffrey, Worah Pratik.* The Spectrum of the Fisher Information Matrix of a Single-Hidden-Layer Neural Network // Advances in Neural Information Processing Systems / Ed. by S. Bengio, H. Wallach, H. Larochelle et al. — Vol. 31. — Curran Associates, Inc., 2018. https://proceedings.neurips.cc/paper_files/paper/2018/file/18bb68e2b38e4a8ce7cf4f6b2625768c-Paper.pdf.
113. Nearly-tight VC-dimension and pseudodimension bounds for piecewise linear neural networks / P. L. Bartlett, N. Harvey, C. Liaw, A. Mehrabian // *Journal of Machine Learning Research*. — 2019. — Vol. 20, no. 63. — Pp. 1–17.
114. *Jacot Arthur, Gabriel Franck, Hongler Clement.* Neural Tangent Kernel: Convergence and Generalization in Neural Networks // Advances in Neural Information Processing Systems. — Vol. 31. — 2018.

115. Wide Neural Networks of Any Depth Evolve as Linear Models under Gradient Descent / J. Lee, L. Xiao, S. S. Schoenholz et al. // Advances in Neural Information Processing Systems. — 2019.
116. *Skorski Maciej*. Chain Rules for Hessian and Higher Derivatives Made Easy by Tensor Calculus. — 2019. <https://arxiv.org/abs/1911.13292>.
117. The Loss Surfaces of Multilayer Networks / A. Choromanska, M. Henaff, M. Mathieu et al. // Proceedings of the 18th International Conference on Artificial Intelligence and Statistics. — 2015. — Pp. 192–204.
118. *Xie Z., Tang Q.-Y., Cai Y. et al.* On the Power-Law Hessian Spectrums in Deep Learning. — 2022.
119. Exploring Generalization in Deep Learning / B. Neyshabur, S. Bhojanapalli, D. McAllester, N. Srebro // Advances in Neural Information Processing Systems. — 2017.
120. Sharp Minima Can Generalize For Deep Nets / Laurent Dinh, Razvan Pascanu, Samy Bengio, Yoshua Bengio // International Conference on Machine Learning. — 2017. <https://api.semanticscholar.org/CorpusID:7636159>.
121. *Meshkov Vladislav, Kiselev Nikita, Grabovoy Andrey*. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // 2024 Ivannikov Ispras Open Conference (ISPRAS). — IEEE: 2024. — Pp. 1–10.
122. Language Models are Unsupervised Multitask Learners / Alec Radford, Jeffrey Wu, Rewon Child et al. // *OpenAI*. — 2019.
123. *Merity S., Xiong C., Bradbury J., Socher R.* Pointer Sentinel Mixture Models. — 2016.
124. *Singh S. P., Adilova L., Kamp M. et al.* Landscaping Linear Mode Connectivity. — 2024.
125. Phenomenology of Double Descent in Finite-Width Neural Networks / S. P. Singh, A. Lucchi, T. Hofmann, B. Schölkopf // International Conference on Learning Representations. — 2022.

126. *Deng Li*. The mnist database of handwritten digit images for machine learning research // *IEEE Signal Processing Magazine*. — 2012. — Vol. 29, no. 6. — Pp. 141–142.
127. *Xiao Han, Rasul Kashif, Vollgraf Roland*. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. — 2017. <https://arxiv.org/abs/1708.07747>.
128. *Krizhevsky Alex*. Learning Multiple Layers of Features from Tiny Images // *International Journal of Intelligence Science*. — 2009. — Vol. 13. <https://api.semanticscholar.org/CorpusID:18268744>.
129. PyTorch: An Imperative Style, High-Performance Deep Learning Library / Adam Paszke, Sam Gross, Francisco Massa et al. // *Advances in Neural Information Processing Systems* 32. — Curran Associates, Inc., 2019. — Pp. 8024–8035. <http://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-lib.pdf>.
130. *Kingma Diederik, Ba Jimmy*. Adam: A Method for Stochastic Optimization // *International Conference on Learning Representations (ICLR)*. — San Diego, CA, USA: 2015.
131. *Wu Bichen, Xu Chenfeng, Dai Xiaoliang et al*. Visual Transformers: Token-based Image Representation and Processing for Computer Vision. — 2020.
132. Wide neural networks of any depth evolve as linear models under gradient descent* / Jaehoon Lee, Lechao Xiao, Samuel S Schoenholz et al. // *Journal of Statistical Mechanics: Theory and Experiment*. — 2020. — dec. — Vol. 2020, no. 12. — P. 124002. <https://dx.doi.org/10.1088/1742-5468/abc62b>.
133. *Singla Sahil, Wallace Eric, Feng Shi, Feizi Soheil*. Understanding Impacts of High-Order Loss Approximations and Features in Deep Learning Interpretation. — 2019.
134. *Singh Sidak Pal, Hofmann Thomas, Schölkopf Bernhard*. The Hessian perspective into the nature of convolutional neural networks // *Proceedings*

- of the 40th International Conference on Machine Learning. — ICML'23. — JMLR.org, 2023. — 39 pp.
135. Geometry of Linear Convolutional Networks / Kathlén Kohn, Thomas Merkh, Guido Montúfar, Matthew Trager // *SIAM Journal on Applied Algebra and Geometry*. — 2022. — Vol. 6, no. 3. — Pp. 368–406. <https://doi.org/10.1137/21M1441183>.
 136. *Qin Zhen, Han Xiaodong, Sun Weixuan et al.* Toeplitz Neural Network for Sequence Modeling. — 2023. <https://arxiv.org/abs/2305.04749>.
 137. *Gnacik Michal, Łapa Krystian.* Using Toeplitz Matrices to obtain 2D convolution. — 2022. — 10.
 138. *Ormaniec Weronika, Dangel Felix, Singh Sidak Pal.* What Does It Mean to Be a Transformer? Insights from a Theoretical Hessian Analysis // *arXiv preprint arXiv:2410.10986*. — 2024. — Self-Attention Block decomposition.
 139. *Noci Lorenzo, Anagnostidis Sotiris, Biggio Luca et al.* Signal Propagation in Transformers: Theoretical Perspectives and the Role of Rank Collapse. — 2022. <https://arxiv.org/abs/2206.03126>.
 140. *Kiselev N. S., Grabovoy A. V.* Sample Size Determination: Likelihood Bootstrapping // *Computational Mathematics and Mathematical Physics*. — 2025. — Vol. 65, no. 2. — Pp. 416–423.
 141. *Aduenko Alexander.* Selection of multimodels in classification tasks: Ph.D. thesis / MIPT. — 2017. https://www.frccsc.ru/diss-council/00207305/diss/list/aduenko_aa.
 142. *Kiselev Nikita, Grabovoy Andrey.* Sample size determination: posterior distributions proximity // *Computational Management Science*. — 2025. — Vol. 22, no. 1. — P. 1.
 143. *Harrison D., Rubinfeld D.* Hedonic housing prices and the demand for clean air // *Journal of environmental economics and management*. — 1978. — Vol. 5, no. 1. — Pp. 81–102.

144. *Quinlan J.* Learning With Continuous Classes // Proceedings of Australian Joint Conference on Artificial Intelligence. — World Scientific, 1992. — Pp. 343–348.
145. *Markelle Kelly, Rachel Longjohn, Kolby Nottingham.* The UCI Machine Learning Repository. <https://archive.ics.uci.edu>.
146. Preconditioned stochastic gradient Langevin dynamics for deep neural networks / C. Li, C. Chen, D. Carlson, L. Carin // AAAI. — 2016. — Pp. 1788–1794.
147. *Bai Zhaojun, Fahey Gark, Golub Gene.* Some large-scale matrix computation problems // *Journal of Computational and Applied Mathematics*. — 1996. — Vol. 74, no. 1-2. — Pp. 71–89.
148. *Pearlmutter Barak A.* Fast exact multiplication by the Hessian // *Neural computation*. — 1994. — Vol. 6, no. 1. — Pp. 147–160.
149. Pyhessian: Neural networks through the lens of the hessian / Zhewei Yao, Amir Gholami, Kurt Keutzer, Michael W Mahoney // 2020 IEEE international conference on big data (Big data) / IEEE. — 2020. — Pp. 581–590.
150. *Chen Xiangning, Hsieh Cho-Jui.* Stabilizing differentiable architecture search via perturbation-based regularization // International conference on machine learning / PMLR. — 2020. — Pp. 1554–1565.
151. *Aeberhard S.* Wine Dataset. — <https://archive.ics.uci.edu/ml/datasets/Wine>.
152. *Grabovoy A. V., Strijov V. V.* Probabilistic Interpretation of the Distillation Problem // *Automation and Remote Control*. — 2022. — Vol. 83, no. 1. — Pp. 123–137.
153. ImageNet: A large-scale hierarchical image database. / J. Deng, W. Dong, R. Socher et al. // CVPR. — IEEE Computer Society, 2009. — Pp. 248–255.
154. Improving massively multilingual neural machine translation and zero-shot translation / Biao Zhang, Philip Williams, Ivan Titov, Rico Sennrich // *arXiv preprint arXiv:2004.11867*. — 2020.

155. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks / Jun-Yan Zhu, Taesung Park, Phillip Isola, Alexei A Efros // Computer Vision (ICCV), 2017 IEEE International Conference on. — 2017.
156. Attention is All you Need / A. Vaswani, N. Shazeer, N. Parmar et al. // Advances in Neural Information Processing Systems. — Vol. 30. — Curran Associates, Inc., 2017.
157. No language left behind: Scaling human-centered machine translation / Marta R Costa-jussà, James Cross, Onur Çelebi et al. // *arXiv preprint arXiv:2207.04672*. — 2022.
158. *Glorot Xavier, Bengio Yoshua*. Understanding the difficulty of training deep feedforward neural networks // Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics / Ed. by Yee Whye Teh, Mike Titterton. — Vol. 9 of *Proceedings of Machine Learning Research*. — Chia Laguna Resort, Sardinia, Italy: PMLR, 2010. — 13–15 May. — Pp. 249–256. <https://proceedings.mlr.press/v9/glorot10a.html>.
159. *Chen Tianqi, Goodfellow Ian, Shlens Jonathon*. Net2Net: Accelerating Learning via Knowledge Transfer. — 2015. <https://arxiv.org/abs/1511.05641>.
160. Optuna: A next-generation hyperparameter optimization framework / Takuya Akiba, Shotaro Sano, Toshihiko Yanase et al. // Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. — 2019. — Pp. 2623–2631.
161. *Goodfellow Ian J, Shlens Jonathon, Szegedy Christian*. Explaining and harnessing adversarial examples // *arXiv preprint arXiv:1412.6572*. — 2014.
162. *Xiao Han, Rasul Kashif, Vollgraf Roland*. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. — 2017.
163. Meta-transfer learning for few-shot learning / Qianru Sun, Yaoyao Liu, Tat-Seng Chua, Bernt Schiele // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. — 2019. — Pp. 403–412.

164. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding / Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT). — 2019. — Pp. 4171–4186.
165. *Anonymous*. Title Redacted for Double-Blind Review // *Journal Name Redacted*. — 2024.
166. Defending Against Neural Fake News / Rowan Zellers, Ari Holtzman, Hannah Rashkin et al. // Advances in Neural Information Processing Systems (NeurIPS). — 2019. — Pp. 9051–9062.
167. Release strategies and the social impacts of language models / Irene Solaiman, Miles Brundage, Jack Clark et al. // *arXiv preprint arXiv:1908.09203*. — 2019.
168. *Jawahar Ganesh, Abdul-Mageed Muhammad, Lyu Chin-Yew*. Automatic detection of machine generated text: A critical survey // Proceedings of the 28th International Conference on Computational Linguistics (COLING). — 2020. — Pp. 2296–2309.
169. Authorship Attribution for Neural Text Generation / Adaku Uchendu, Thai Le, Kai Shu, Dongwon Lee // Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP). — 2021. — Pp. 4275–4291.
170. *Valiaiev Dmytro*. Detection of Machine-Generated Text: Literature Survey. — 2024. <https://arxiv.org/abs/2402.01642>.
171. *Anonymous*. Title Redacted for Double-Blind Review // *Journal Name Redacted*. — 2025.
172. *Maurer Andreas*. Bounds for Linear Multi-Task Learning // *J. Mach. Learn. Res.* — 2006. — dec. — Vol. 7. — P. 117–139.
173. *Baxter J.* A Model of Inductive Bias Learning // *Journal of Artificial Intelligence Research*. — 2000. — mar. — Vol. 12. — P. 149–198. <http://dx.doi.org/10.1613/jair.731>.

174. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer / Colin Raffel, Noam M. Shazeer, Adam Roberts et al. // *J. Mach. Learn. Res.* — 2019. — Vol. 21. — Pp. 140:1–140:67. <https://api.semanticscholar.org/CorpusID:204838007>.
175. *Bao Guangsheng, Zhao Yanbin, Teng Zhiyang et al.* Fast-DetectGPT: Efficient Zero-Shot Detection of Machine-Generated Text via Conditional Probability Curvature. — 2024. <https://arxiv.org/abs/2310.05130>.
176. *Hans Abhimanyu, Schwarzschild Avi, Cherepanova Valeriia et al.* Spotting LLMs With Binoculars: Zero-Shot Detection of Machine-Generated Text. — 2024.
177. *He Pengcheng, Liu Xiaodong, Gao Jianfeng, Chen Weizhu.* DeBERTa: Decoding-enhanced BERT with Disentangled Attention. — 2021.
178. MULTITuDE: Large-Scale Multilingual Machine-Generated Text Detection Benchmark / Dominik Macko, Robert Moro, Adaku Uchendu et al. // *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing* / Ed. by Houda Bouamor, Juan Pino, Kalika Bali. — Singapore: Association for Computational Linguistics, 2023. — dec. — Pp. 9960–9987. <https://aclanthology.org/2023.emnlp-main.616>.
179. Intrinsic dimension estimation for robust detection of AI-generated texts / Eduard Tulchinskii, Kristian Kuznetsov, Laida Kushnareva et al. // *Proceedings of the 37th International Conference on Neural Information Processing Systems*. — NIPS '23. — Red Hook, NY, USA: Curran Associates Inc., 2023. — 20 pp.
180. Boundary detection in mixed AI-human texts / Laida Kushnareva, Tatiana Gaintseva, Dmitry Abulkhanov et al. // *First Conference on Language Modeling*. — 2024. <https://openreview.net/forum?id=kzzwTrt04Z>.
181. *Sadasivan Vinu Sankar, Kumar Aounon, Balasubramanian Sriram et al.* Can AI-Generated Text be Reliably Detected? — 2024. <https://openreview.net/forum?id=NvSwR4IvL0>.

182. DetectGPT: zero-shot machine-generated text detection using probability curvature / Eric Mitchell, Yoonho Lee, Alexander Khazatsky et al. // Proceedings of the 40th International Conference on Machine Learning. — ICML'23. — 2023. — 13 pp.
183. *Miller George A.* WordNet: A Lexical Database for English // Human Language Technology: Proceedings of a Workshop held at Plainsboro, New Jersey, March 8-11, 1994. — 1994. <https://aclanthology.org/H94-1111>.
184. *Wang Yuxia, Shelmanov Artem, Mansurov Jonibek et al.* GenAI Content Detection Task 1: English and Multilingual Machine-Generated Text Detection: AI vs. Human. — 2025. <https://arxiv.org/abs/2501.11012>.
185. *He Pengcheng, Gao Jianfeng, Chen Weizhu.* DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing. — 2023. <https://arxiv.org/abs/2111.09543>.
186. Open multimodal iEEG-fMRI dataset from naturalistic stimulation with a short audiovisual film / Julia Berezutskaya, Mariska J. Vansteensel, Erik J. Aarnoutse et al. // *Scientific Data*. — 2022. — mar. — Vol. 9, no. 1. <https://doi.org/10.1038/s41597-022-01173-0>.
187. *Almazrouei Ebtesam, Alobeidli Hamza, Alshamsi Abdulaziz et al.* The Falcon Series of Open Language Models. — 2023. <https://arxiv.org/abs/2311.16867>.
188. *Black Sid, Gao Leo, Wang Phil et al.* GPT-Neo: Large Scale Autoregressive Language Modeling with Mesh-Tensorflow. — 2021. — mar. — If you use this software, please cite it using these metadata. <https://doi.org/10.5281/zenodo.5297715>.
189. *Wang Liang, Yang Nan, Huang Xiaolong et al.* Multilingual E5 Text Embeddings: A Technical Report. — 2024. <https://arxiv.org/abs/2402.05672>.

190. *Gritsay German, Grabovoy Andrey, Chekhovich Yury*. Automatic Detection of Machine Generated Texts: Need More Tokens // Ivannikov Memorial Workshop Proceedings 2022. — 2022.
191. *Powers David M. W.* Applications and explanations of Zipf's law // Proceedings of the Joint Conferences on New Methods in Language Processing and Computational Natural Language Learning. — NeMLaP3/CoNLL '98. — USA: Association for Computational Linguistics, 1998. — P. 151–160.
192. *Magnus Jan R., Neudecker Heinz*. Matrix Differential Calculus with Applications in Statistics and Econometrics. — Chichester: Wiley, 1988.
193. *Petersen Kaare Brandt, Pedersen Michael Syskind*. The Matrix Cookbook. — <https://www2.imm.dtu.dk/pubdb/edoc/imm3274.pdf>. — 2012. — Version November 15, 2012.
194. *Варламова К. Д., Дорин Д. Д., Грабовой А. В.* За чертой знакомых доменов: исследование обобщающей способности детекторов машинно сгенерированных изображений // Доклады Российской академии наук. Математика, информатика, процессы управления. — 2025. — Т. 527. — С. 103–116.
195. *Дорин Д. Д., Грабовой А. В., Стрижов В. В.* Улучшение декодирования данных ФМРТ с использованием пространственно-временных характеристик в условиях ограниченного набора данных // Доклады Российской академии наук. Математика, информатика, процессы управления. — 2025. — Т. 527. — С. 11–30.
196. *Зверева А. К., Грабовой А. В., Каприелова М. С.* Динамическое разделение труда в гибридном ИИ: стратегии кодировщиков и их воздействие на модуляторы на основе сетей долгой краткосрочной памяти // Доклады Российской академии наук. Математика, информатика, процессы управления. — 2025. — Т. 527. — С. 117–133.
197. *Грицай Г. М., Грабовой А. В.* Интерпретация классификаторов на основе архитектуры трансформера с помощью кластеризации // Доклады Российской

- ской академии наук. *Математика, информатика, процессы управления*. — 2025. — Т. 527. — С. 432–448.
198. Дорин Д. Д., Варламова К. Д., Грабовой А. В. Попарное сравнение изображений для обнаружения плагиата // *Доклады Российской академии наук. Математика, информатика, процессы управления*. — 2025. — Т. 527. — С. 68–83.
 199. Zvereva Anna K., Kaprielova Mariam, Grabovoy Andrey. AnomLite: Efficient binary and multiclass video anomaly detection // *Results in Engineering*. — 2025. — Vol. 25. — P. 104162.
 200. Gritsai G. M., Khabutdinov I. A., Grabovoy A. V. Stack More LLM's: Efficient Detection of Machine-Generated Texts via Perplexity Approximation // *Doklady Mathematics*. — 2024. — Vol. 110, no. S1. — Pp. S203–S211.
 201. Forecasting fMRI images from video sequences: linear model analysis / Daniil Dorin, Nikita Kiselev, Andrey Grabovoy, Vadim Strijov // *HEALTH INFORMATION SCIENCE AND SYSTEMS*. — 2024. — Vol. 12, no. 1. — P. 55.
 202. RuGECToR: Rule-Based Neural Network Model for Russian Language Grammatical Error Correction / I. A. Khabutdinov, A. V. Chashchin, A. V. Grabovoy et al. // *Programming and Computer Software*. — 2024. — Vol. 50, no. 4. — Pp. 315–321.
 203. Text Reuse Detection in Handwritten Documents / A. V. Grabovoy, M. S. Kaprielova, A. S. Kildyakov et al. // *Doklady Mathematics*. — 2024.
 204. Artificially Generated Text Fragments Search in Academic Documents / G. M. Gritsay, A. V. Grabovoy, A. S. Kildyakov, Yu V. Chekhovich // *Doklady Mathematics*. — 2024.
 205. Bazarova A. I., Grabovoy A. V., Strijov V. V. Analysis of the Properties of Probabilistic Models in Expert-Augmented Learning Problems // *Automation and Remote Control*. — 2022. — Vol. 83, no. 10. — Pp. 1527–1537.

206. Grabovoy A. V., Strijov V. V. Prior Distribution Selection for a Mixture of Experts // *Computational Mathematics and Mathematical Physics*. — 2021. — Vol. 61, no. 7. — Pp. 1140–1152.
207. Grabovoy A. V., Strijov V. V. Quasi-Periodic Time Series Clustering for Human Activity Recognition // *Lobachevskii Journal of Mathematics*. — 2020. — Vol. 41, no. 3. — Pp. 333–339.
208. Voznyuk A., Gritsai G., Grabovoy A. Team advacheck at PAN: multitasking does all the magic // Working Notes of CLEF 2025 - Conference and Labs of the Evaluation Forum. — Vol. 4038 of *CEUR Workshop Proceedings (CEUR-WS.org)*. — CEUR-WS.org: 2025. — Pp. 4007–4014.
209. Voznyuk Anastasia, Gritsai German, Grabovoy Andrey. Advacheck at SemEval-2025 Task 3: Combining NER and RAG to Spot Hallucinations in LLM Answers // Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025). — Association for Computational Linguistics Vienna, Austria: 2025. — Pp. 1204–1210.
210. Structure Extractor: Multilingual Extraction of Sections from Scientific Document / Ilia Kopanichuk, Artem Chashchin, Inga Ochneva et al. // 2025 37th Conference of Open Innovations Association (FRUCT). — IEEE: 2025. — Pp. 122–128.
211. Advacheck at GenAI Detection Task 1: AI Detection Powered by Domain-Aware Multi-Tasking / German Gritsai, Anastasia Voznuyk, Ildar Khabutdinov, Andrey Grabovoy // Proceedings of the 1st Workshop on GenAI Content Detection (GenAIDetect). — International Conference on Computational Linguistics Abu Dhabi, UAE: 2025. — Pp. 236–243.
212. Asvarov Alidar, Grabovoy Andrey. Neural Machine Translation System for Lezgian, Russian and Azerbaijani Languages // 2024 Ivannikov Ispras Open Conference (ISPRAS). — IEEE: 2024. — Pp. 1–7.

213. *Poimanov Dmitrii, Mestetsky Leonid, Grabovoy Andrey.* N-Gram Perplexity-Based AI-Generated Text Detection // 2024 Ivannikov Ispras Open Conference (ISPRAS). — IEEE: 2024. — Pp. 1–8.
214. *Boeva G., Gritsay G., Grabovoy A.* Team ap-team at PAN: LLM Adapters for Various Datasets // Working Notes of the Conference and Labs of the Evaluation Forum (CLEF 2024). — Vol. 3740 of *CEUR Workshop Proceedings*. — CEUR-WS.org: 2024. — Pp. 2527–2535.
215. *Gritsay G., Grabovoy A.* Automated Text Identification on Languages of the Iberian Peninsula: LLM and BERT-based Models Aggregation // Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2024) co-located with the Conference of the Spanish Society for Natural Language Processing (SEPLN 2024). — Vol. 3756 of *CEUR Workshop Proceedings*. — CEUR-WS.org: 2024.
216. *Gritsai German, Khabutdinov Ildar, Grabovoy Andrey.* Multi-head Span-based Detector for AI-generated Fragments in Scientific Papers // Proceedings of the Fourth Workshop on Scholarly Document Processing (SDP 2024). — Association for Computational Linguistics Bangkok, Thailand: 2024. — Pp. 220–225.
217. *Asvarov Alidar, Grabovoy Andrey.* The Impact of Multilinguality and Tokenization on Statistical Machine Translation // 2024 35th Conference of Open Innovations Association (FRUCT). — IEEE: 2024. — Pp. 149–157.
218. Automated Text Identification: Multilingual Transformer-based Models Approach / G. Gritsay, Andrey Grabovoy, A. Kildyakov, Yury Chekhovich // Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2023) co-located with the Conference of the Spanish Society for Natural Language Processing (SEPLN 2023). — Vol. 3496 of *CEUR Workshop Proceedings*. — CEUR-WS.org: 2023.

219. Anti-Distillation: Knowledge Transfer from a Simple Model to the Complex One / Kseniia Petrushina, Oleg Bakhteev, Andrey Grabovoy, Vadim Strijov // 2022 Ivannikov Ispras Open Conference (ISPRAS). — IEEE: 2022.
220. *Зверева Анна Константиновна, Грабовой Андрей Валериевич, Каприелова Мариам Семеновна.* Структурно-ориентированная синтетическая аугментация как регуляризатор в задаче распознавания пространственно-временных паттернов // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — Математические методы распознавания образов. — Москва: ООО "МАКС Пресс", 2025. — С. 18–21.
221. *Грабовой Андрей Валериевич.* О сложности моделей и данных в задачах обучения нейросетевых моделей // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — Математические методы распознавания образов. — Москва: ООО "МАКС Пресс", 2025. — С. 72–73.
222. *Киселев Никита Сергеевич, Мешков Владислав Сергеевич, Грабовой Андрей Валериевич.* Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — Математические методы распознавания образов. — Москва: ООО "МАКС Пресс", 2025. — С. 73–76.
223. *Грицай Герман Михайлович, Грабовой Андрей Валериевич.* Неявная регуляризация векторного представления текстов в подходе многозадачного обучения // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов

- (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — Математические методы распознавания образов. — Москва: ООО "МАКС Пресс", 2025. — С. 78–79.
224. *Дорин Даниил Дмитриевич, Киселев Никита Сергеевич, Грабовой Андрей Валериевич.* Декодирование визуальных стимулов из мультимодальных сигналов мозга // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — Математические методы распознавания образов. — Москва: ООО "МАКС Пресс", 2025. — С. 124–126.
225. Применение синтетических данных, полученных с помощью генеративной нейросети, для повышения качества моделей детекции / И. Д. Степанов, А. В. Филатов, Д. Д. Дорин и др. // Труды 67-й Всероссийской научной конференции МФТИ. — Прикладная математика и информатика. — Физматкнига: 2025.
226. *Мешков В. С., Киселев Н. С., Грабовой А. В.* Сходимость ландшафта сверточных нейронных сетей: анализ матричных сетей на основе гесиана // Труды 67-й Всероссийской научной конференции МФТИ. — Прикладная математика и информатика. — Физматкнига: 2025.
227. *Киселев Н. С., Грабовой А. В.* Сходимость поверхности функции потерь как признак достаточного размера выборки // Труды 67-й Всероссийской научной конференции МФТИ. — Прикладная математика и информатика. — Физматкнига: 2025.
228. *Дорин Д. Д., Грабовой А. В.* Улучшение декодирования фМРТ в условиях ограниченной выборки // Труды 67-й Всероссийской научной конференции МФТИ. — Прикладная математика и информатика. — Физматкнига: 2025.
229. *Грицай Г. М., Грабовой А. В.* Выравнивание представлений в подходе многозадачного обучения для детектирования машинно-сгенерированных

- текстов // Труды 67-й Всероссийской научной конференции МФТИ. — Прикладная математика и информатика. — Физматкнига: 2025.
230. *Киселев Никита, Грабовой Андрей.* Определение достаточного размера выборки по апостериорному распределению параметров модели // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. — Прикладная математика и информатика. — Физматкнига: 2024. — С. 141.
231. *Дорин Даниил, Киселев Никита, Грабовой Андрей.* Пространственно-временные методы анализа временных рядов // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. — Прикладная математика и информатика. — Физматкнига: 2024. — С. 127.
232. *Грицай Г., Грабовой А.* Многозадачное обучение для распознавания машинно-сгенерированных текстов // Труды 65-й Всероссийской научной конференции МФТИ в честь 115-летия Л.Д.Ландау, 3–8 апреля 2023 г. Прикладная математика и информатика. — Физматкнига Москва: 2023. — С. 117–119.
233. *Грабовой Андрей Валериевич, Хабутдинов Ильдар.* Анализ работы BERT-подобных моделей в задачах классификации грамматических ошибок на русском языке // Труды 65-й Всероссийской научной конференции МФТИ в честь 115-летия Л.Д.Ландау, 3–8 апреля 2023 г. Прикладная математика и информатика. — Физматкнига Москва: 2023. — С. 117.
234. *Баязитов К. М., Грабовой А. В., Стрижов В. В.* Дистилляция моделей глубокого обучения на многодоменных выборках // Интеллектуализация обработки информации: Тезисы докладов 14-й Международной конференции. — Москва: Российская академия наук, 2022. — С. 98–99.
235. *Грабовой Андрей Валериевич, Стрижов Вадим Викторович.* Байесовское выравнивание структур нейросетевых моделей // Труды 64-й Всероссийской научной конференции МФТИ 22-25 ноября 2021. Прикладная математика и информатика. — МФТИ Москва: 2021. — С. 148–149.

236. Грабовой А. В., Стрижов В. В. Априорное распределение параметров в задачах выбора моделей глубокого обучения // «Математические методы распознавания образов» (ММРО-2021): Тезисы докладов 20-й Всероссийской конференции с международным участием. — Москва: Российская академия наук, 2021. — С. 142–143.
237. Грабовой Андрей Валериевич, Стрижов Вадим Викторович. Вероятностный подход к задаче привилегированного обучения и дистилляции // Труды 63-й Всероссийской научной конференции МФТИ. 23-29 ноября 2020 года. Прикладная математика и информатика. — М.: МФТИ, 2020. — С. 197–198.
238. Грабовой А. В., Стрижов В. В. Задача обучения с экспертом для построение интерпретируемых моделей машинного обучения // Тезисы докладов 13-й Международной конференции "Интеллектуализация обработки информации". — РАН Москва: 2020. — С. 16–17.
239. Выбор моделей и ансамблей / В. В. Стрижов, А. А. Адуенко, О. Ю. Бахтеев и др. // Тезисы докладов 13-й Международной конференции "Интеллектуализация обработки информации". — РАН Москва: 2020. — С. 16–17.
240. Грабовой Андрей Валериевич, Стрижов Вадим Викторович. Анализ априорных распределений в задаче смеси экспертов // Труды 62-й Всероссийской научной конференции МФТИ. — Прикладная математика и информатика. — МФТИ М: 2019.
241. Численные методы оценки оптимального объема выборки для логистической и линейной регрессии / Тамаз Тезикоевич Гадаев, Андрей Валериевич Грабовой, Анастасия Петровна Мотренко, Вадим Викторович Стрижов // Тезисы докладов 19-й Всероссийской конференции с международным участием. — Математические методы распознавания образов. — Москва: Российская академия наук, 2019. — С. 40–41.
242. Грабовой А. В., Бахтеев О. Ю., Стрижов В. В. Введение отношения порядка на множестве параметров нейронной сети // Тезисы докладов 19-й

- Всероссийской конференции с международным участием. — Математические методы распознавания образов. — Москва: Российская академия наук, 2019. — С. 38–39.
243. *Грабовой Андрей Валериевич, Бахтеев Олег Юрьевич, Стрижов Вадим Викторович*. Прореживание нейросетевых моделей методом Белсли // Труды 61-й всероссийской научной конференции МФТИ. — Прикладная математика и информатика. — МФТИ Москва: 2018. — С. 114–115.
244. *Грабовой Андрей Валериевич, Бахтеев Олег Юрьевич, Стрижов Вадим Викторович*. Определение релевантности параметров нейросети методом белсли // Тезисы докладов 12-й Международной конференции «Интеллектуализация обработки информации (ИОИ-2018)», Москва, Россия – Гаэта, Италия. — Интеллектуализация обработки информации. — TORUS PRESS: 2018. — С. 36–37.
245. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization / Yann N Dauphin, Razvan Pascanu, Caglar Gulcehre et al. // Advances in Neural Information Processing Systems / Ed. by Z. Ghahramani, M. Welling, C. Cortes et al. — Vol. 27. — Curran Associates, Inc., 2014. https://proceedings.neurips.cc/paper_files/paper/2014/file/04192426585542c54b96ba14445be996-Paper.pdf.
246. On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima / Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal et al. // *ArXiv*. — 2016. — Vol. abs/1609.04836. <https://api.semanticscholar.org/CorpusID:5834589>.
247. *Pennington Jeffrey, Schoenholz Samuel S., Ganguli Surya*. The Emergence of Spectral Universality in Deep Networks // *ArXiv*. — 2018. — Vol. abs/1802.09979. <https://api.semanticscholar.org/CorpusID:3569532>.
248. Gradient Descent Finds Global Minima of Deep Neural Networks / Simon Du, Jason Lee, Haochuan Li et al. // Proceedings of the 36th

- International Conference on Machine Learning / Ed. by Kamalika Chaudhuri, Ruslan Salakhutdinov. — Vol. 97 of *Proceedings of Machine Learning Research*. — PMLR, 2019. — 09–15 Jun. — Pp. 1675–1685. <https://proceedings.mlr.press/v97/du19c.html>.
249. Entropy-SGD: biasing gradient descent into wide valleys / Pratik Chaudhari, Anna Choromańska, Stefano Soatto et al. // *Journal of Statistical Mechanics: Theory and Experiment*. — 2016. — Vol. 2019. <https://api.semanticscholar.org/CorpusID:13807351>.
250. *Fort Stanislav, Scherlis Adam*. The Goldilocks zone: Towards better understanding of neural network loss landscapes // *ArXiv*. — 2018. — Vol. abs/1807.02581. <https://api.semanticscholar.org/CorpusID:49655834>.
251. *Krizhevsky Alex, Nair Vinod, Hinton Geoffrey*. CIFAR-10 (Canadian Institute for Advanced Research). <http://www.cs.toronto.edu/~kriz/cifar.html>.
252. Cortical network responses map onto data-driven features that capture visual semantics of movie fragments / Julia Berezutskaya, Zachary V. Freudenburg, Luca Ambrogioni et al. // *Scientific Reports*. — 2020. — jul. — Vol. 10, no. 1. <https://doi.org/10.1038/s41598-020-68853-y>.
253. *McAllester David A*. A PAC-Bayesian Tutorial with A Dropout Bound // *ArXiv*. — 2013. — Vol. abs/1307.2118. <https://api.semanticscholar.org/CorpusID:1936248>.
254. *Vapnik Vladimir N., Chervonenkis Alexey Y*. On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities // *Theory of Probability and its Applications*. — 1971. — Vol. 16, no. 2. — Pp. 264–280.
255. *Valiant Leslie G*. A Theory of the Learnable // *Communications of the ACM*. — 1984. — Vol. 27, no. 11. — Pp. 1134–1142.
256. *Vapnik Vladimir N*. Statistical Learning Theory. — Wiley, 1998.
257. *Воронцов Константин В*. Комбинаторный подход к оценке качества обучаемых алгоритмов // *Математические вопросы кибернетики*. — 2004. — Vol. 13. — Pp. 5–51.

258. *Koltchinskii Vladimir*. Rademacher Penalties and Structural Risk Minimization // *IEEE Transactions on Information Theory*. — 2001. — Vol. 47, no. 5. — Pp. 1902–1914.
259. *Kiselev Nikita, Grabovoy Andrey*. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*. — 2025. — Vol. 110, no. S1. — P. S42.
260. *Kaplan Jared, McCandlish Sam, Henighan Tom et al*. Scaling Laws for Neural Language Models. — 2020.
261. Training Compute-Optimal Large Language Models / Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch et al. // Proceedings of the 36th International Conference on Neural Information Processing Systems. — 2022.